



Guía para ser un Data Scientist

Madrid, 2023

Índice general

I	Álgebra Lineal	1
1.	Espacios Vectoriales	3
1.	¿Qué es un vector?	4
1.1.	Operaciones con Vectores	4
2.	Dependencia e independencia lineal	7
2.1.	Vectores linealmente dependientes	7
2.2.	Vectores linealmente independientes	9
2.3.	Propiedades de la dependencia lineal	9
2.	Matrices de Números Reales	11
1.	Matrices de Números Reales	11
1.1.	Igualdad de Matrices	12
1.2.	Traspuesta de una matriz	13
1.3.	Tipos de matrices	13
2.	Suma de matrices y producto por números	15
2.1.	Combinaciones lineales	18
3.	Producto de matrices	19
3.1.	Propiedades	20
4.	Producto de matrices cuadradas	21
5.	Transformaciones elementales	22
5.1.	Transformaciones elementales fila	22
5.2.	Transformaciones elementales columna	23
6.	Algoritmo de Gauss-Jordan	25
7.	Inversa de una matriz	27
7.1.	Potencias de una matriz	29
7.2.	Ecuaciones matriciales	30
3.	Determinantes de una matriz	31
1.	Determinantes de segundo orden	31
1.1.	Propiedades fundamentales	31
2.	Determinantes de tercer orden	33
2.1.	Propiedades fundamentales	33
2.2.	Desarrollo con respecto a una columna o fila	34
3.	Determinantes de orden superior a tres	36
3.1.	Cálculo de determinantes	37
3.2.	Determinante de un producto de matrices	38
4.	Cálculo de la matriz inversa	38

4. Sistemas de ecuaciones lineales.	39
1. Notación y definiciones	40
2. Método de eliminación Gaussiana	41
2.1. Sistemas de ecuaciones lineales homogéneos	44
3. Rango de una matriz	46
4. Teorema de Rouché-Fröbenius	50
5. Ortogonalidad	51
1. Producto escalar	51
1.1. Norma de un vector	52
2. Ortogonalidad	53
6. Autovalores y autovectores	55
1. Definiciones y propiedades	55
1.1. Propiedades de los autovalores	55
2. Polinomio característico de una matriz	56
3. Diagonalización de una matriz	59
3.1. Condiciones que tiene que cumplir una matriz para ser diagonalizable	60
3.2. Aplicaciones de la diagonalización	60
4. Diagonalización de matrices simétricas	64
7. Formas cuadráticas	65
1. Definición de forma cuadrática	65
II Cálculo	67
8. Funciones	69
1. Funciones reales de variable real	69
1.1. Dominio de una función	70
1.2. Conjunto imagen o recorrido	72
1.3. Funciones acotadas	73
1.4. Funciones crecientes y decrecientes	75
2. Límites de Funciones	76
2.1. Entorno de un número real	76
2.2. Idea intuitiva de límite	76
2.3. Límite de una función en un punto	77
2.4. Límites Laterales	77
2.5. Límites en el infinito	78
3. Funciones Continuas	78
9. Sucesiones	81
1. Sucesión y acotación	82
2. Sucesiones convergentes	82
2.1. Sucesiones Monótonas	83
2.2. Operaciones con sucesiones	83
2.3. Convergencia y orden	84
3. Criterio de convergencia	86
3.1. Criterio de Stolz	86

3.2.	Criterio de la raíz	87
3.3.	Criterio del número e	87
4.	Ejercicios resueltos	89
5.	Ejercicios propuestos	96
10.	Series	97
1.	Convergencia y divergencia de series	100
2.	Serie de términos positivos	101
2.1.	Criterios de convergencia para series de términos positivos	101
3.	Series alternadas	108
3.1.	Criterios de convergencia para series alternadas	108
3.2.	Series de términos positivos y negativos	109
4.	Series sumables	109
4.1.	Series geométricas	109
4.2.	Series Aritmético-geométricas	110
11.	Derivación de funciones de una variable	111
1.	Definición de derivada. Interpretaciones	111
1.1.	Tasa de variación instantánea de una función	111
1.2.	Definición de la derivada	112
2.	Resultados relacionados con la derivación	112
3.	Calculo de derivadas. Reglas de derivación	113
3.1.	Derivadas y operaciones con funciones	113
4.	Aplicaciones de las derivadas	113
4.1.	Monotonía, puntos críticos y extremos locales de una función	114
4.2.	Curvatura y puntos de inflexión de una función	115
5.	Funciones en Python	116
12.	Cálculo diferencial de funciones de varias variables	117
1.	Concepto Fundamental	118
1.1.	Representación Geométrica de la función $z = f(x, y)$. . .	118
1.2.	Límites de una Función de Varias Variables.	118
1.3.	Operaciones con Límites	119
1.4.	Límites Direccionales	120
2.	Continuidad de una Función de Varias Variables	120
2.1.	Continuidad de una Función $z=f(x,y)$	120
2.2.	Composición de Funciones Continuas	121
3.	Derivadas Parciales de una Función de Varias Variables	121
3.1.	Derivadas Parciales de Segundo Orden	122
3.2.	Diferenciabilidad	123
III	Estadística Descriptiva	125
13.	Variable Estadística Unidimensional	127
1.	Variables Estadísticas. Tablas Estadísticas	127
1.1.	Historia de la Estadística	128
1.2.	Estadística Descriptiva	130
1.3.	Variables Estadísticas	130
1.4.	Tablas Estadísticas	133

1.5.	Representaciones Gráficas	137
2.	Momentos Centrados y No Centrados	145
2.1.	Momentos no Centrados	145
2.2.	Momentos Centrados	145
2.3.	Calculo de Momentos	146
3.	Medidas de Posición	149
3.1.	Importancia de las medidas de posición	149
3.2.	Media Aritmética	150
3.3.	Media Geométrica	152
3.4.	Media Armónica	155
3.5.	Moda	157
3.6.	Mediana	159
3.7.	Percentiles	161
4.	Medidas de Dispersión	164
4.1.	Recorridos	164
4.2.	Varianza	164
4.3.	Desviación Típica	165
4.4.	Desigualdad de Tchebycheff	166
4.5.	Variable Tipificada	167
4.6.	Coficiente de Variación	168
5.	Medidas de Forma	170
5.1.	Asimetría	170
5.2.	Coficiente de Curtosis de Fisher	171
6.	Medidas de Concentración	172
6.1.	Curva de Concentración de Lorenz	172
6.2.	Índice de Gini	174
6.3.	Mediala	175
14. Variables Estadísticas Bidimensionales		179
1.	Representaciones Numéricas en Dos Columnas y en Tablas de Contingencia	179
1.1.	Dos Columnas	179
1.2.	Tablas de Contingencia	180
1.3.	Distribuciones Marginales y Condicionadas. Independencia de Variables Estadísticas	181
2.	Covarianza y coeficiente de correlación lineal	184
2.1.	Covarianza	184
3.	Coficiente de Correlación Lineal	188
4.	Recta de Regresión de Mínimos Cuadrados	191
4.1.	Regresión Lineal	194
4.2.	Correlación Lineal	196
4.3.	Varianza Residual. Coficiente de Determinación	196
4.4.	Predicciones	198
15. Números Índices		201
1.	Tasas de Variación	201
1.1.	Variación Absoluta	201
1.2.	Variación Relativas: Tasas de Variación	202
1.3.	Equivalencia entre Tasas de Variación de Diferentes Períodos	204
1.4.	Tasas Medias de Variación	205

2.	Índice elemental. Índice sintético.	207
2.1.	Índice Sintético	209
2.2.	Índices sintéticos sin ponderar	209
2.3.	Índices Sintéticos Ponderados	209
3.	Índices de Precios, de Cantidades y de Valor	210
3.1.	Índices de Precios	211
3.2.	Índices de Cantidades	211
3.3.	Índices de Valor	212
4.	Enlace de Series de Números Índices con Distinta Base	213
5.	Deflación de series económicas	215
6.	Dependencia de un índice general respecto de un grupo de productos	218
16. Análisis Descriptivo de Series Cronológicas		221
1.	Definición de una serie cronológica. Representaciones numérica y gráfica	221
2.	Componentes de una serie cronológica. Modelos	222
3.	Tendencia secular: ajuste de una recta de mínimos cuadrados y medias móviles	225
3.1.	Método del ajuste de una recta de mínimos cuadrados	225
3.2.	Método de las medias móviles	226
4.	Variación estacional. Desestacionalización	229
4.1.	Método de las medias simples	229
4.2.	Método de la razón (o diferencia) a la tendencia	232
4.3.	Método de la razón (o Diferencia) a las Medias Móviles	238
5.	Desestacionalización	239
6.	Predicción	241
17. Probabilidad		245
1.	Definición de Probabilidad. Asignación de Probabilidades	245
1.1.	Operaciones y Relaciones con Sucesos	246
1.2.	Definición de Probabilidad	247
1.3.	Propiedades	248
1.4.	Asignación de Probabilidad	249
2.	Definición de Probabilidad Condicionada. Sucesos Dependientes e Independientes	252
2.1.	Probabilidad Condicionada	252
2.2.	Sucesos Dependientes e Independientes	254
3.	Formula de la Probabilidad Total. Fórmula de Bayes	256
18. Variables Aleatorias Y Distribuciones De Probabilidad		259
1.	Concepto de Variable Aleatoria y Distribución de Probabilidad	259
2.	Función de Distribución. Variables Aleatorias Discretas y Variables Aleatorias Continuas	261
2.1.	Variables Aleatorias Discretas y Variables Aleatorias Continuas	262
3.	Valor Esperado de una Variable Aleatoria. Momentos	263
4.	Otras medidas de Posición, Dispersión y Forma	264
4.1.	Moda	264
4.2.	Mediana, Cuartiles y Percentiles	265
4.3.	Coefficiente de Variación	265

4.4.	Coeficiente de Asimetría	265
4.5.	Coeficiente de Apuntamiento o Curtosis	265
5.	Variables Aleatorias Bidimensionales. Independencia de Variables Aleatorias	266
5.1.	Función de Distribución Bidimensional. Función de Densidad Bidimensional	268
5.2.	Distribuciones de Probabilidad Marginales	269
5.3.	Independencia de Variables Aleatorias	270
5.4.	Principales Momentos en Variables Aleatorias Bidimensionales	270
19.	Distribuciones Discretas de Probabilidad	273
1.	Distribución Uniforme Discreta	273
2.	Distribución Binomial	274
2.1.	Distribución Binomial de Parámetros 1 y p (Distribución de Bernoulli)	274
2.2.	Distribución Binomial de Parámetros n y p	275
3.	Distribución de Poisson	278
4.	Distribución de Poisson Como Límite de la Distribución Binomial	280
5.	Distribución Hipergeométrica	281
6.	Distribución Geométrica	283
IV	Inferencia Estadística	285
20.	Modelos Probabilísticos Univariantes Continuos	287
1.	Distribución Rectangular Uniforme	288
1.1.	Condiciones de la función de densidad	288
1.2.	Función de Distribución	289
1.3.	Esperanza Matemática o Media o Valor Esperado	290
1.4.	Varianza	291
1.5.	Momentos	292
1.6.	Función Generatriz de Momentos	292
1.7.	Medidas de Forma	292
2.	Distribución Exponencial	294
2.1.	Función de Distribución	295
2.2.	Esperanza Matemática o Media o Valor Esperado	295
2.3.	Varianza	295
2.4.	Momentos	296
2.5.	Función Generatriz de Momentos	296
2.6.	Medidas de Forma	296
3.	Función de Distribución Gamma $\Gamma(\alpha, \theta)$	298
3.1.	Función Gamma $\Gamma(\alpha)$	298
3.2.	Función de Distribución Gamma	299
4.	Distribución Beta	302
5.	Distribución Normal	305
5.1.	Función de Distribución	306
5.2.	Relación entre $\mathcal{N}(\mu, \sigma^2)$ y $\mathcal{N}(0, 1)$	307
5.3.	Teorema Central del Límite	309

5.4.	Cálculo de probabilidades asociado a una distribución normal. Manejo de tablas	309
6.	Relaciones entre Modelos	310
6.1.	Aproximación de una Binomial a una Poisson	310
6.2.	Aproximación de una Binomial por una Normal	311
6.3.	Aproximación de una Binomial por una Normal	311
7.	Distribuciones Relacionadas con la Distribución Normal	312
7.1.	Distribución χ^2 de Pearson	312
7.2.	Distribución t de Student	313
7.3.	Distribución F de Snedecor	314

21.Distribuciones Asociadas a los Estadísticos Muestrales de una Población Normal 317

1.	Concepto de Muestra y Estadístico	318
1.1.	Muestra Aleatoria	318
1.2.	Parámetros Poblacionales	318
1.3.	Estadísticos Muestrales	319
1.4.	Valores Esperado y Varianza de algunos Estadísticos	320
2.	Distribución para la media de una muestra procedente de una población normal con varianza conocida	325
3.	Distribución para la cuasivarianza y la varianza y de una muestra procedente de una población normal	325
4.	Distribución para la media de una muestra procedente de una población normal con varianza desconocida: El cociente t-Student	327
5.	Distribuciones de probabilidad para la diferencia de medias de dos muestras independientes procedentes de sendas poblaciones normales	328
5.1.	Caso en el que las varianzas de ambas poblaciones son conocidas	328
5.2.	Caso en el que las varianzas de ambas poblaciones son desconocidas pero iguales	328
5.3.	Caso en el que la varianza de ambas poblaciones son desconocidas y desiguales (Aproximación de Welch)	329
5.4.	Caso en que las dos varianzas son desconocidas y tamaños muestrales elevados	329
6.	Distribución para el cociente de varianzas	330
7.	Distribución para la proporción muestral	330
8.	Distribución para la diferencia de proporciones muestrales	331

22.Estimación Puntual de Parámetros 333

1.	Introducción a la Estimación: Concepto de Estimador de un Parámetro	333
1.1.	Estimador de un Parámetro	334
2.	Método de la Máxima Verosimilitud para la Obtención de Estimadores Puntuales	334
2.1.	Función de Verosimilitud	334
3.	Método de los Momentos para la Obtención de Estimadores Puntuales	336
4.	Relación Entre los Métodos de Máxima Verosimilitud y de los Momentos	337

5.	Propiedades Deseables para un Estimador Paramétrico	337
5.1.	Estimadores Insegados	338
5.2.	Eficiencia de un Estimador. Cota de Frechet - Kramer - Rao	338
5.3.	Estimadores Consistentes	338
5.4.	Estimadores Suficientes	339
6.	Error Cuadrático Medio del Estimador $\hat{\theta}$	339
23.	Estimación de Parámetros Mediante Intervalos de Confianza	341
1.	Introducción	341
2.	Funciones de Decisión e Intervalos de Confianza	341
3.	Construcción de un Intervalo de Confianza	342
3.1.	Intervalo de confianza para la media de una distribución normal	343
3.2.	Intervalos de confianza para la proporción	346
4.	Intervalo de confianza para la diferencia de medias de dos poblaciones normales	347
4.1.	Se conocen las varianzas	347
4.2.	Varianzas poblacionales desconocidas pero iguales $\sigma_1^2 = \sigma_2^2$	348
4.3.	Varianzas poblacionales desconocidas y desiguales (Aproximación de Welch)	350
5.	Intervalo de confianza para la diferencia de proporciones	351
6.	Intervalo de confianza para la varianza de una población normal	352
6.1.	Intervalos unilaterales cuando la media de la población es conocida	353
6.2.	Intervalos unilaterales cuando la media de la población es desconocida	354
6.3.	Intervalos de confianza bilaterales	355
7.	Intervalo de confianza para la razón de varianzas	357
24.	Contraste de Hipótesis Paramétricos	359
1.	Formulación de un Contraste	359
2.	Contraste de hipótesis paramétricos	361
2.1.	Contraste de Hipótesis de una Población Normal	362
3.	Contraste de hipótesis para la proporción	365
4.	Contraste de hipótesis para la diferencia de medias	365
4.1.	Caso en el que se conocen las varianzas	366
4.2.	Caso en el que se desconocen las varianzas	366
5.	Contraste de hipótesis para la diferencia de proporciones	367
6.	Contraste de hipótesis para la varianza	368
6.1.	Región de rechazo	368
7.	Contraste de hipótesis para la razón de varianzas	369
7.1.	Contraste de dos colas	369
7.2.	Contraste de una cola a la derecha	370

V Machine Learning 371

25.Introducción a la Ciencia de Datos 373

1.	¿Qué es la Ciencia de Datos?	373
----	--	-----

1.1.	Gama de Análisis	374
1.2.	¿Por qué es importante y por qué ahora?	378
1.3.	Problemas que puede solucionar el Machine Learning	378
1.4.	Los datos como activo competitivos	380
1.5.	Potencia de Procesamiento más Rápida y Económica	382
2.	El Proceso de Ciencia de Datos	382
2.1.	Cinco fases del ciclo de vida	383
3.	Técnicas Comunes en la Ciencia de Datos	385
3.1.	Algoritmos de Clasificación	385
3.2.	Algoritmos de Clusterización	386
3.3.	Algoritmos de Regresión	388
3.4.	Algoritmos de Simulación	388
3.5.	Algoritmo Análisis de Contenido	389
3.6.	Algoritmos de Recomendación	389
4.	Vanguardia de la Ciencia de Datos	390
4.1.	El Auge de los Modelos de Conjuntos	390
4.2.	Real Aplicación de los Modelos de Conjuntos	390
4.3.	Construcción de Modelos de Conjuntos	391
26.Sistemas de Recomendación		393
1.	Tipos de Motores	393
2.	Filtro Colaborativo	394
2.1.	¿Cómo se encuentra a alguien similar?	395
2.2.	Pensando a lo “Grande”	397
2.3.	Otras Métricas	398
3.	Filtro Basados en Elementos	400
3.1.	El Problema del Éxito	401
3.2.	Filtrado Basado en Elementos	402
3.3.	Slope One	406
3.4.	Slope One Ponderado	409
27.Diseñando Modelos		411
1.	¿Qué es un Modelo?	411
1.1.	Terminología Machine Learning	412
1.2.	Modelos y Frameworks	412
1.3.	Ingeniería de datos y características	414
2.	El Proceso de Machine Learning	415
2.1.	Roles	416
3.	Desafíos Comunes en el Machine Learning	418
3.1.	Calidad del Dato	418
3.2.	Reproducibilidad	420
3.3.	La Deriva de los Datos	421
3.4.	Escala	421
3.5.	Múltiples Objetivos	422
4.	Primera Aplicación: Clasificación Especies de Iris	422
4.1.	Conociendo los Datos	423
4.2.	k-Nearest Neighbors	423

28. Aprendizaje Supervisado	429
1. Clasificación y Regresión	429
2. Generalización, Overfitting, y Underfitting	430
2.1. Relación entre la Complejidad del Modelo y el Tamaño del Conjunto de Datos	432
3. Algoritmo Supervisados de Machine Learning	433
3.1. Algunas Muestras de Dataset	433
4. K-Nearest Neighbors	436
4.1. Clasificación K-Neighbors	437
4.2. Regresión k-neighbors	442
5. Modelos Lineales	446
5.1. Modelos de Regresión Lineal	446
5.2. Regresión Lineal por Mínimos Cuadrados Ordinarios	447
5.3. Modelos Lineales para Clasificación	456
5.4. Modelos Lineales para Clasificación Multiclase	462
6. Clasificador Naive Bayes	467
7. Árboles de Decisión	469
7.1. Términos Asociados	470
7.2. Árboles de Regresión	473
7.3. Árboles de Clasificación	476
7.4. Controlar la complejidad de los árboles de decisión	478
7.5. Importancia de las variables en los árboles	481
8. Ensamble de Árboles de Decisión	485
8.1. Random Forests	485
 VI Series Temporales	 491
29. Modelos tradicionales: conceptos iniciales	493
1. Introducción	493
2. Proceso estocástico	493
2.1. Distribuciones marginales	494
3. Series temporales	495
3.1. Objetivo del análisis de series temporales	495
3.2. Operadores de retardo y de diferencias	498
4. Ruido blanco	498
5. Estacionariedad	498
5.1. Función de autocovarianzas y de autocorrelación	501
5.2. Función de autocorrelación simple	501
5.3. Función de autocorrelación parcial	502
6. Estimaciones muestrales	503
7. Ergodicidad	504
 30. Modelos univariantes lineales estacionarios	 505
1. Proceso autorregresivo	505
1.1. Proceso autorregresivo de primer orden	506
1.2. Proceso autorregresivo de segundo orden	511
1.3. Proceso autorregresivo de orden p	515
2. Proceso de medias móviles	520
2.1. Proceso de medias móviles de primer orden	522

2.2.	Proceso de medias móviles de segundo orden	525
2.3.	Proceso de medias móviles de orden q	528
3.	Procesos autorregresivos y de medias móviles	533
3.1.	Proceso autorregresivo de medias móviles $ARMA(1, 1)$. .	534
4.	Teorema de Wold	540
5.	Identificación	540
5.1.	Estadísticos muestrales	540
5.2.	Inferencia	541
31.	Modelos univariantes lineales no estacionarios	545
1.	Transformaciones que inducen estacionariedad en media y varianza	545
2.	Estacionalidad	547
2.1.	Proceso estacional autorregresivo	548
2.2.	Comportamiento de medias móviles	549
2.3.	Proceso estacional autorregresivo y de medias móviles . .	551
3.	Modelos autorregresivos y de medias móviles integrados (ARIMA) multiplicativos	551
4.	Estimación de modelos ARIMA	553
5.	Predicción puntual en modelos ARIMA	553
5.1.	Procesos autorregresivos	554
5.2.	Procesos de medias móviles	555
5.3.	Procesos autorregresivos y de medias móviles	555
6.	Actualización de predicciones en modelos ARIMA	556
7.	Predicción mediante intervalos de confianza en modelos ARIMA	557
7.1.	Procesos autorregresivos	558
7.2.	Procesos de medias móviles	559
7.3.	Procesos autorregresivos y de medias móviles	559
7.4.	Cálculo de la varianza del error de predicción en cualquier proceso ARIMA	560
8.	Diagnóstico de modelos	561
8.1.	Diagnos sobre los parámetros	561
8.2.	Diagnos sobre los residuos	562
8.3.	Capacidad predictiva del modelo	563
8.4.	Selección de modelos	563
32.	Modelos de volatilidad estocástica	565
1.	Introducción	565
2.	Modelo autorregresivo condicionalmente heterocedástico: ARCH	566
2.1.	Modelo ARCH(1)	566
2.2.	Modelo ARCH(q)	568
3.	Modelo condicionalmente heterocedástico generalizado: GARCH	568
3.1.	Modelo GARCH(1,1)	568
3.2.	Modelo GARCH(p, q)	569
4.	Construcción de modelos GARCH	570
4.1.	Identificación de modelos GARCH	570
4.2.	Estimación y adecuación de modelos GARCH	571

VII	Ejercicios	573
33.	Ejercicios Álgebra Lineal	575
34.	Ejercicios Calculo Diferencial	579
35.	Estadística Descriptiva	581
1.	Variable Estadística Unidimensional	581
2.	Variables Estadísticas Bidimensionales	584
3.	Números Índices	587
4.	Análisis Descriptivo de Series Cronológicas	588
5.	Probabilidad	590
6.	Distribuciones Discretas de Probabilidad	590
36.	Inferencia Estadística	593
1.	Modelos Probabilísticos Univariantes Contínuos	593

Índice de figuras

8.1. Función no acotada	74
8.2. Función acotada inferiormente	74
8.3. Función acotada	74
8.4. Función creciente	75
8.5. Función decreciente	76
8.6. Función no creciente ni decreciente	76
13.1. Gráfico de Barras	138
13.2. Histograma	141
13.3. Pirámide Poblacional	143
13.4. Diagrama de sectores	144
13.5. Curva de concentración de Lorenz	173
20.1. Función de Densidad Distribución Rectangular Uniforme	290
20.2. Función de Distribución Distribución Rectangular Uniforme	290
20.3. Función de Densidad Distribución Normal	306
20.4. Función de Distribución Normal	307
25.1. Disciplinas que constituyen la ciencia de datos	374
25.2. Gama de Análisis	375
25.3. Análisis Prescriptivo Telecomunicaciones	377
25.4. Algoritmo de clusterización	387
26.1. Puntuación de Libros	395
26.2. inflación de calificaciones	399
26.3. Slope One	407
27.1. Diferentes Tipos de Algoritmos de Machine Learning	413
28.1. Compensación de la complejidad del modelo contra exactitud de entrenamiento y test	432
28.2. Gráfico de dispersión	434
28.3. Gráfico del dataset de onda	434
28.4. Predicciones hechas por el modelo de un vecino más cercano en el conjunto de datos de Forge	437
28.5. Predicciones hechas por el modelo de tres vecino más cercano en el conjunto de datos de Forge	438
28.6. Frontera de decisión creada para los diferentes modelos	440
28.7. Comparación de exactitud entre entrenamiento y test en función de los n_vecinos	441

28.8. Predicción hecha por la regresión de un vecino más cercano en el dataset de ondas	442
28.9. Predicción hecha por la regresión de tres vecino más cercano en el dataset de ondas	443
28.10 Comparación de predicciones hechas por regresion de k vecinos cercanos por diferentes valores de vecinos	445
28.11 Predicción del modelo lineal en el dataset de ondas	447
28.12 Comparación de magnitudes de coeficientes para regresión de ridge con diferentes valores de regresión alfa y lineal	452
28.13 Comparación de magnitudes de coeficientes para regresión de lasso con diferentes valores de regresión alfa y ridge	455
28.14 Límites de decisión de una SVM lineal y regresión logística en el conjunto de datos de forge con los parámetros predeterminados .	458
28.15 Límites de decisión de una SVM lineal en el conjunto de datos de force para diferentes valores de C	458
28.16 Coeficientes aprendidos por regresión logística en el conjunto de datos de cáncer de mama para diferentes valores de C	461
28.17 Coeficientes aprendidos por regresión logística con penalización L1 en el conjunto de datos de cáncer de mama para diferentes valores de C	463
28.18 Conjunto de datos de juguetes bidimensionales que contiene tres clases	464
28.19 Límites de decisión aprendidos por los tres clasificadores uno versus resto	465
28.20 Límites de decisión multiclase derivados de los tres clasificadores uno versus resto	466
29.1. Representación gráfica de algunas series temporales	496
29.2. Paseo aleatorio (izquierda) y su primera diferencia (derecha) . . .	500
29.3. Correlograma de un paseo aleatorio (izquierda) y de su primera diferencia (derecha)	502
30.1. Procesos AR(1) con $\phi = 0.8$ y $\phi = -0.3$	506
30.2. FAC para $\phi = 0.8$ y $\phi = -0.7$	510
30.3. Procesos AR(2) con $(\phi_1 = 0.8, \phi_2 = -0.3)$ y $(\phi_1 = 0.4, \phi_2 = 0.5)$	512
30.4. FAC para $(\phi_1 = 0.8, \phi_2 = -0.7)$ y $(\phi_1 = -0.6, \phi_2 = 0.2)$	514
30.5. Procesos MA(1) con $\theta = -0.8$ y $\theta = 0.3$	522
30.6. FAC para $\theta = 0.8$ y $\theta = -0.7$	524
30.7. Procesos MA(2) con $(\theta_1 = -0.8$ y $\theta_2 = 0.3)$ y $(\theta_1 = -0.4$ y $\theta_2 = -0.5)$	526
30.8. FAC de MA(2) con $(\theta_1 = 0.9, \theta_2 = -0.3)$ y $(\theta_1 = -0.6, \theta_2 = 0.2)$	528
30.9. Proceso ARMA(1,1) con $\theta = 0.8$ y $\phi = 0.8$	535
30.10 FAC y FACP de ARMA(1,1) con $\theta = -0.5$ y $\phi = 0.8$	537
30.11 Correlogramas de las series simuladas	542
31.1. Gráfico, FAC y FACP de un paseo aleatorio	546
31.2. Gráfico, FAC y FACP de las primeras diferencias	546
31.3. Número de fallecidos desde Enero de 1993 a Diciembre de 2013 y su logaritmo	547

31.4. Número de fallecidos desde Enero de 1993 a Diciembre de 2013:	
orden de las transformaciones	547
31.5. FAC y FACP para un proceso $AR(1)_4$ con $\Phi = 0.8$	549
31.6. FAC y FACP para un proceso $AR(1)_4$ con $\Phi = -0.7$	549
31.7. FAC y FACP para un proceso $MA(1)_4$ con $\Phi = 0.8$	550
31.8. FAC y FACP para un proceso $MA(1)_4$ con $\Phi = -0.7$	551
31.9. FAC y FACP del proceso Temperaturas	552
31.10Ciclo de identificación, estimación y diagnóstico de series temporales	561
31.11Capacidad predictiva del modelo	563
32.1. Observaciones de la bolsa de Nueva York cada 5 días (izquierda)	
y sus primeras diferencias	566
32.2. Correlograma de los residuos al cuadrado de los datos de la bolsa	
de New York	571

Índice de tablas

29.1. Representación de s muestras de un proceso estocástico	495
30.1. Comportamiento de la FAC y FACP para los procesos AR, MA y ARMA	541

Parte I

Álgebra Lineal

CAPÍTULO 1

Espacios Vectoriales

Puede salirse con la suya sin aprender álgebra lineal por un tiempo, utilizando bibliotecas de machine learning y estadísticas que lo hacen todo. Pero si se va a poner la intuición detrás de estas cajas negras y ser más efectivos al trabajar con datos, comprender los fundamentos del álgebra lineal es inevitable. El álgebra lineal es un tema enorme que puede llenar libros de texto gruesos, por lo que, por supuesto, no se puede obtener un dominio total en un solo capítulo de este libro. Sin embargo, se puede aprender lo suficiente para sentirse más cómodos con él y navegar por el dominio de la ciencia de datos de manera efectiva. También habrá oportunidades para aplicarlo en capítulos posteriores.

A veces la gente confunde el álgebra lineal con el álgebra básica, pensando que tal vez tiene que ver con trazar líneas usando la función algebraica $y = mx + n$. Esta es la razón por la que el álgebra lineal probablemente debería haberse llamado “álgebra de vectores” o “álgebra de matrices” porque es mucho más abstracto. Los sistemas lineales juegan un papel, pero de una manera mucho más metafísica.

Formalmente, el álgebra lineal es el estudio de ecuaciones lineales, en las que la potencia más alta de la variable es uno. Sin embargo, para nuestros propósitos, el álgebra lineal se refiere a objetos matemáticos multidimensionales, como vectores y matrices, y operaciones sobre ellos. Así es como se aplica típicamente el álgebra lineal en el **deep learning** y cómo se manipulan los datos en programas que implementan algoritmos de deep learning.

Entonces, ¿qué es exactamente el álgebra lineal?

Se conoce como álgebra lineal a la especialización del álgebra que trabaja con matrices, vectores, espacios vectoriales y ecuaciones de tipo lineal. Se trata de un área del conocimiento que se desarrolló especialmente en la década de 1840 con los aportes del alemán Hermann Grassmann (1809-1877) y el irlandés William Rowan Hamilton (1805-1865), entre otros matemáticos.

Los espacios vectoriales son estructuras que surgen cuando se registra un conjunto que no está vacío, una operación externa y una operación interna. Los vectores son los elementos que forman parte del espacio vectorial. En cuanto a las matrices, se trata de un conjunto bidimensional de números que permiten la

representación de los coeficientes que tienen los sistemas de ecuaciones lineales.

William Rowan Hamilton es uno de los nombres más destacados del ámbito de las matemáticas, ya que fue quien acuñó el término “vector”, además de haber creado los cuaterniones. Este concepto se extiende de los números reales, así como ocurre con los complejos, y se trata de grupos de cuatro números resultan muy útiles al estudiar cantidades en tres dimensiones que esperan contar con una magnitud y una dirección.

Los números que componen el cuaternión deben satisfacer determinadas reglas de adición, multiplicación e igualdad. Este descubrimiento tuvo una importancia considerable para las matemáticas. Con respecto al conjunto de los números reales, se define como aquél en el cual se encuentran los racionales (el cero, los positivos y los negativos) y los irracionales (aquellos que no pueden ser expresados).

Siguiendo con la definición de los elementos con los que trata el álgebra lineal, es importante saber que un sistema de ecuaciones lineales se compone, como su nombre lo indica, de ecuaciones lineales (un conjunto de ecuaciones que son de primer grado), definidas sobre un anillo conmutativo o un cuerpo.

Los espacios vectoriales, el foco de estudio del álgebra lineal, cuentan con dos conjuntos: uno de vectores y otro de escalares.

1. ¿Qué es un vector?

En pocas palabras, un vector es una flecha en el espacio con una dirección y longitud específicas, que a menudo representa un dato. Es el bloque de construcción central del álgebra lineal, incluidas las matrices y las transformaciones lineales. En su forma fundamental, no tiene concepto de ubicación, por lo que siempre se debe imaginar que su cola comienza en el origen de un plano cartesiano $(0,0)$.

La figura 1 muestra un vector $\vec{v}$ que se mueve 3 pasos en la dirección horizontal y 2 pasos en la dirección vertical.

Sea $\mathfrak{A}_2$ el conjunto de puntos de un plano. Se designará estos puntos mediante letras mayúsculas A, B, P, Q, ...

Un desplazamiento desde un punto A hasta otro punto B se representa por un **vector fijo** en A y con extremo B. Dos vectores fijos se llaman **equipolentes** si están sobre la misma recta o sobre rectas paralelas, tienen la misma longitud y también tienen el mismo sentido 1.



El conjunto de vectores equipolentes a uno dado recibe el nombre de **vector libre**. Obsérvese que un vector libre tiene un representante en cada punto del plano. Se puede decir que un vector libre es un vector que se puede colocar en cualquier parte del plano, manteniendo la equipolencia.

El conjunto de todos los vectores desplazamientos nulos $\vec{A}$ forman el **vector libre nulo**, que se denota por $\mathbf{0}$

Se designará por $\mathfrak{V}_2$ al conjunto de vectores libres del plano

1.1. Operaciones con Vectores


Los vectores libres se pueden sumar y multiplicar por números. Con estas operaciones, los vectores libres adquieren estructura de **espacio vectorial**.



Definición 1.1 (Suma de vectores libres) Sean $\mathbf{u}$ y $\mathbf{v}$ dos vectores. Entonces la suma $\mathbf{w} = \mathbf{v} + \mathbf{u}$ es el vector libre correspondiente a la diagonal del paralelogramo (figura 1.1).

Además de la regla del paralelogramo, se puede usar la regla del polígono, de gran valor práctico. Para sumar dos vectores libres $\mathbf{u}$ y $\mathbf{v}$, trasladamos uno de ellos, por ejemplo $\mathbf{v}$, hasta colocar su origen sobre el extremo del otro, $\mathbf{u}$. El vector libre suma se obtiene uniendo el origen de $\mathbf{u}$ con el extremo de $\mathbf{v}$.

Definición 1.2 (Propiedades) La suma de vectores tiene las siguientes propiedades, consecuencia directa de su interpretación geométrica:



- *Propiedad conmutativa:* $\mathbf{v} + \mathbf{u} = \mathbf{u} + \mathbf{v}$
- *Propiedad asociativa:* $(\mathbf{v} + \mathbf{u}) + \mathbf{w} = \mathbf{v} + (\mathbf{u} + \mathbf{w})$
- *Vector nulo:* El vector nulo verifica que $\mathbf{v} + \mathbf{0} = \mathbf{v}$ para cualquier $\mathbf{v}$
- *Vector opuesto:* A cada vector $\mathbf{v}$ le corresponde otro $\mathbf{v}'$ que se llama vector opuesto de $\mathbf{v}$, tal que $\mathbf{v} + \mathbf{v}' = \mathbf{0}$. El opuesto es un vector con el mismo módulo y dirección, pero sentido contrario.

Se define la **resta** de vectores $\mathbf{v} - \mathbf{u}$ como el resultado de sumar a $\mathbf{v}$ el opuesto de $\mathbf{u}$, es decir, $\mathbf{v} + \mathbf{u}' = \mathbf{v} - \mathbf{u}$

Definición 1.3 (Multiplicación de un número por un vector) Se define el producto de un número λ por un vector $\mathbf{v}$ como otro vector $\lambda\mathbf{v}$ que tiene su misma dirección pero con una longitud multiplicada por $|\lambda|$; además si λ es positivo, $\lambda\mathbf{v}$ tiene el mismo sentido que $\mathbf{v}$, mientras que si λ es negativo, $\lambda\mathbf{v}$ apunta en sentido opuesto a $\mathbf{v}$

Definición 1.4 (Propiedades) El producto de números por vectores tiene las siguientes propiedades:

- *Asociativa con respecto al producto de números.* Si λ y μ son números se obtiene: $(\lambda \times \mu)\mathbf{v} = \lambda \times (\mu \times \mathbf{v})$
- *Distributiva con respecto a la suma de números:* $(\lambda + \mu) \times \mathbf{w} = \lambda \times \mathbf{w} + \mu \times \mathbf{w}$
- *Distributiva con respecto a la suma de vectores:* $\lambda \times (\mathbf{v} + \mathbf{w}) = \lambda \times \mathbf{v} + \lambda \times \mathbf{w}$
- $1\mathbf{w} = \mathbf{w}$

```
import numpy as np
u=np.array([3,2])
v=np.array([2,-1])
# Suma de vectores
u_mas_v=u+v
print(u_mas_v)
# [5,1]
# Multiplicación de un número por un vector
multi_v=2*v
print(multi_v)
#[4,-2]
```

2. Dependencia e independencia lineal

Los siguientes conceptos son fundamentales para el estudio de los espacios vectoriales, ya que la idea de independencia lineal nos llevará a las definiciones de base, rango, dimensión, etc.

Consideramos un espacio vectorial $\mathbb{V}$ y sean $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ vectores de $\mathbb{V}$. Se llama **combinación lineal** de los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ a un vector $\mathbf{u}$ definido como:

$$\mathbf{u} = \alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + \dots + \alpha_n \mathbf{u}_n$$

Siendo $\alpha_1, \alpha_2, \dots, \alpha_n$ números cualesquiera, que se llaman **coeficientes** de la combinación lineal.

En este caso también se dice que el vector $\mathbf{u}$ depende linealmente de los vectores $u_1, u_2, \dots, u_n$.

El vector cero es combinación lineal de cualquier vectores $u_1, u_2, \dots, u_n$ ya que

$$\mathbf{0} = 0\mathbf{u}_1 + 0\mathbf{u}_2 + \dots + 0\mathbf{u}_n$$

Ejemplo 1.1 Sean $\mathbf{u}=(-2,1)$, $\mathbf{v}=(0,5)$ y $\mathbf{w}=(7,3)$ vectores de $\mathbb{R}^3$. Formar dos vectores que sean combinación lineal de ellos.

Hacemos combinaciones lineales de estos vectores eligiendo valores concretos para los coeficientes, por ejemplo:

$$\begin{aligned}\mathbf{x} &= \mathbf{u} - \mathbf{v} + 2\mathbf{w} = (12, -10) \\ \mathbf{y} &= -5\mathbf{u} + 2\mathbf{w} = (24, -11)\end{aligned}$$

Observa que en la formación de $\mathbf{y}$ podemos decir que entra el vector $\mathbf{v}$, aunque con coeficiente cero

$$\mathbf{y} = -5\mathbf{u} + 0\mathbf{v} + 2\mathbf{w}$$

2.1. Vectores linealmente dependientes

Los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ se llaman **linealmente dependientes** si hay alguna combinación lineal de ellos que da como resultado el vector cero, pero siendo alguno de los coeficientes distinto de cero, es decir:

$$\alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + \dots + \alpha_n \mathbf{u}_n = \mathbf{0} \quad \text{con algún } \alpha_i \neq 0$$

Ejemplo 1.2 Los vectores $\mathbf{x}=(-1,2)$ e $\mathbf{y}=(-3,6)$ de $\mathbb{R}^2$ son linealmente dependientes.

En efecto, la siguiente combinación lineal:

$$3\mathbf{x} - \mathbf{y} = 3(-1, 2) - (-3, 6) = (0, 0)$$

da como resultado el vector cero, y no son nulos todos los coeficientes

Podemos expresar esta definición de dependencia lineal de una forma equivalente, como muestra el siguiente teorema

Teorema 1.1 *Los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ son linealmente dependientes si y sólo si alguno de ellos es combinación lineal de los demás*

Para demostrarlo, ponemos el caso de tres vectores $\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3$. En el caso general, la prueba es completamente análoga.

Probamos en primer lugar que si los vectores son linealmente dependientes, entonces alguno de ellos es combinación lineal de los demás.

Si los tres vectores son linealmente dependientes, hay una combinación lineal nula,

$$\alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + \alpha_3 \mathbf{u}_3 = 0$$

, con algun escalar distinto de cero, podemos pensar que es $\alpha_1 \neq 0$. Entonces “despejamos” en la igualdad anterior del vector $\mathbf{u}_1$:

$$\begin{aligned} \alpha_1 \mathbf{u}_1 &= -\alpha_2 \mathbf{u}_2 - \alpha_3 \mathbf{u}_3 \\ \mathbf{u}_1 &= -\frac{\alpha_2}{\alpha_1} \mathbf{u}_2 - \frac{\alpha_3}{\alpha_1} \mathbf{u}_3 \end{aligned}$$

y ya tenemos expresado uno de los vectores como combinación lineal de los otros dos.

Demostramos ahora que si uno de los tres vectores es combinación lineal de los otros dos entonces son linealmente dependientes.

Sea $\mathbf{u}_1$ combinación lineal de los otros dos puntos $\mathbf{u}_1 = \alpha_2 \mathbf{u}_2 + \alpha_3 \mathbf{u}_3$. Entonces igualando a cero,

$$\mathbf{u}_1 - \alpha_2 \mathbf{u}_2 - \alpha_3 \mathbf{u}_3 = 0$$

Tenemos una combinación lineal de tres vectores que no es nula, y como el coeficiente de $\mathbf{u}_1$, vale uno podemos asegurar que es distinto de cero. Así pues, según la definición, los tres vectores son linealmente dependientes.

Ejemplo 1.3 *Tres vectores de un espacio vectorial, $\mathbf{x}, \mathbf{y}, \mathbf{z}$, verifican la relación $2\mathbf{x} - 4\mathbf{y} + \mathbf{z} = 0$. ¿Son linealmente dependientes? En este caso, expresar uno de ellos como combinación lineal de los demás.*

Son linealmente dependientes porque la expresión $2\mathbf{x} - 4\mathbf{y} + \mathbf{z} = 0$ es una combinación lineal de los vectores cuyo resultado es cero, siendo algún coeficiente (de hecho, todos) no nulos.

Para expresar uno de ellos como combinación lineal de los demás, basta con despejar alguno de los vectores en la igualdad. Por ejemplo, despejando $\mathbf{z}$ obtenemos:

$$\mathbf{z} = -2\mathbf{x} + 4\mathbf{y}$$

Ejemplo 1.4 *¿Es el vector $\mathbf{x} = (-1, 5, 7) \in \mathbb{R}^3$ combinación lineal de los vectores $\mathbf{u} = (1, 1, -1), \mathbf{v} = (1, -1, 1), \mathbf{w} = (-1, 1, 1)$? En ese caso, hallar los coeficientes de la combinación lineal.*

Para resolver el problema planteamos una combinación lineal de los vectores $\mathbf{u}, \mathbf{v}, \mathbf{w}$, con coeficientes desconocidos, que dé como resultado el vector $\mathbf{x} = (-1, 5, 7)$ e intentamos averiguar si hay o no valores para esos coeficientes

$$\alpha(1, 1, -1) + \beta(1, -1, 1) + \gamma(-1, 1, 1) = (-1, 5, 7)$$

entonces realizando operaciones resulta

$$(\alpha + \beta - \gamma, \alpha - \beta + \gamma, -\alpha + \beta + \gamma) = (-1, 5, 7)$$

Identificando las respectivas componentes obtenemos el sistema lineal:

$$\begin{cases} \alpha + \beta - \gamma = -1 \\ \alpha - \beta + \gamma = 5 \\ -\alpha + \beta + \gamma = 7 \end{cases}$$

Cuya solución es $\alpha = 2; \beta = 3; \gamma = 6$. Por tanto, el vector $\mathbf{x}$ es combinación lineal de los vectores $\mathbf{u}, \mathbf{v}, \mathbf{w}$. Con estos valores de los respectivos coeficientes.

2.2. Vectores linealmente independientes

Cuando m vectores no son linealmente dependientes se llaman linealmente independientes. Observa que la siguiente definición equivale a la negación de la dependencia lineal.

Los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ se llaman **linealmente independientes** si hay combinación lineal de ellos que dé como resultado el vector cero, salvo la que tiene todos los coeficientes nulos; es decir:

$$\alpha_1 \mathbf{u}_1 + \alpha_2 \mathbf{u}_2 + \dots + \alpha_m \mathbf{u}_m = \mathbf{0} \Rightarrow \alpha_1 = \alpha_2 = \dots = \alpha_m = 0$$

El teorema del apartado anterior se puede enunciar ahora de otra manera; expresa la independencia lineal de forma equivalente a la dada en la definición

Teorema 1.2 Los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ son linealmente independientes si y solo si ninguno de ellos es combinación lineal de los demás

Ejemplo 1.5 Aplicando la definición, probar que los vectores $(4, -2), (0, 3)$ de $\mathfrak{M}_{1 \times 2}$ son linealmente independientes.

Para probarlo suponemos una combinación lineal de ambos vectores que dé como resultado el vector cero, y hacemos operaciones

$$\begin{aligned} \alpha \begin{pmatrix} 4 \\ -2 \end{pmatrix} + \beta \begin{pmatrix} 0 \\ 3 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \begin{pmatrix} 4\alpha \\ -2\alpha + 3\beta \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \end{aligned}$$

Al igualar los respectivos elementos se obtiene $4\alpha = 0$, de donde $\alpha = 0$ y $-2\alpha + 3\beta = 0$ y de aquí, sustituyendo $\alpha = 0$, resulta que $\beta = 0$

Puesto que se ha probado que ambos escalares deben ser cero, queda establecido que los vectores son linealmente independientes

2.3. Propiedades de la dependencia lineal

Se verifican las siguientes propiedades de fácil demostración

1. Si entre los vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m$ de $\mathbf{V}$ figura el vector $\mathbf{0}$, son linealmente dependientes.

Se debe a que el vector cero es combinación linealmente dependientes.

2. Un solo vector, si es distinto de cero, es linealmente independiente.
En efecto, si $\alpha \mathbf{u} = \mathbf{0}$ debe ser $\alpha = 0$; en otro caso, despejamos en la igualdad y resulta que $\mathbf{u} = \alpha^{-1} \mathbf{0} = \mathbf{0}$, lo cual contradice la hipótesis que nos dan.
3. Dos vectores de $\mathbb{R}^n$ son linealmente dependientes si y sólo si tienen las respectivas componentes proporcionales.

En efecto, sean $\mathbf{x} = (x_1, \dots, x_n)$, $\mathbf{y} = (y_1, \dots, y_n)$ los dos vectores, son linealmente dependientes si uno de ellos es combinación lineal de otro:

$$\mathbf{x} = (x_1, \dots, x_n) = \alpha \mathbf{y} = (\alpha y_1, \dots, \alpha y_n)$$

es decir si $x_1 = \alpha y_1; x_2 = \alpha y_2, \dots, x_n = \alpha y_n$, lo cual se puede expresar como:

$$\frac{x_1}{y_1} = \frac{x_2}{y_2} = \dots = \frac{x_n}{y_n}$$

CAPÍTULO 2

Matrices de Números Reales

Las aplicaciones de las matemáticas han impulsado a la creación de distintos conjuntos de números: números naturales, enteros, racionales, reales y, por último, números complejos.

Pero todo este arsenal no es suficiente para satisfacer la necesidades de la ciencia. En el siglo XIX, el científico irlandés W.R. Hamilton (1805-1865) se propuso la tarea de representar las rotaciones en el espacio por alguna clase de números y tropezó con una dificultad inesperada: el producto de dos rotaciones no es conmutativo.

La representación matemática de las rotaciones creó la necesidad de inventar una nueva clase de “hipernúmeros”, porque todos los conjuntos conocidos hasta entonces compartían la propiedad de que su producto era conmutativo. En la actualidad las rotaciones se representan mediante **matrices**.

1. Matrices de Números Reales

Una tabla de números reales con m filas y n columnas se llama **matriz de orden** $m \times n$. Denotaremos las matrices por letras mayúsculas como:

$$\begin{aligned} B &= \begin{pmatrix} 4 \\ -2 \end{pmatrix} \\ C &= \begin{pmatrix} 3 & 2 \\ -2 & 1 \\ 4 & 9 \end{pmatrix} \\ D &= (-3 \quad 6) \end{aligned}$$

B es una matriz de orden 2×1 (2 filas y 1 columna); C es una matriz 3×2 (3 filas y 2 columna); D es una matriz 1×2 (1 fila y 2 columna).

Dada una matriz A, designaremos por a_{ij} al elemento que ocupa la intersección de la fila i y la columna j . Por ejemplo si A es una matriz de orden 3×4 (3 filas por 4 columnas) se pondrá

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \end{pmatrix}$$

Por tanto, el primer subíndice de un elemento indica la fila y el segundo la columna en la que está dicho elemento.

Designamos el conjunto de las matrices de orden $m \times n$ por $\mathcal{M}_{m \times n}$. Una matriz cualquiera de este conjunto se denota por

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix}$$

1.1. Igualdad de Matrices

Dos **matrices** A y B del mismo orden $m \times n$, se consideran iguales si tienen iguales los elementos que ocupan la misma posición; es decir, si $a_{ij} = b_{ij}$ para cualesquiera $i = 1, \dots, m$ y $j = 1, \dots, n$. Por ejemplo, la igualdad matricial

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}$$

conlleva las cuatro igualdades

$$\begin{aligned} a_{11} &= b_{11} & a_{12} &= b_{12} \\ a_{21} &= b_{21} & a_{22} &= b_{22} \end{aligned}$$

Ejemplo 2.1 Sabiendo que las matrices A y B de orden 2×3 son iguales, hallar los valores a, b, c, d, x, y, z

$$\begin{aligned} A &= \begin{pmatrix} 1 & a & b \\ c & -2 & 6 \end{pmatrix} \\ B &= \begin{pmatrix} c & 5 & 0 \\ x+y & y & z \end{pmatrix} \end{aligned}$$

puesto que $A=B$, deben ser iguales los respectivos elementos. Igualándolos, se obtiene

$$\begin{aligned} c &= 1 & a &= 5 & b &= 0 \\ z &= 6 & y &= -2 & x+y &= c \end{aligned}$$

De estas relaciones obtenemos la incógnita que falta $x=3$

La definición de igualdad de matrices permite escribir sistemas de ecuaciones como una simple igualdad matricial. Por ejemplo, el sistema:

$$\begin{cases} x + y = 2 \\ x - y = -1 \end{cases}$$

Se puede expresar como la igualdad matricial:

$$\begin{aligned} A &= B \\ A &= \begin{pmatrix} x + y \\ x - y \end{pmatrix} \\ B &= \begin{pmatrix} 2 \\ -1 \end{pmatrix} \end{aligned}$$

1.2. Traspuesta de una matriz

Dada una matriz de orden $m \times n$ se llamará matriz traspuesta de A , y se denota por A^t , a una nueva matriz que se obtiene convirtiendo ordenadamente las filas en columnas; es decir, la primera fila de A es la primera columna de A^t , la segunda fila de A es la segunda columna de A^t , y así sucesivamente. Es claro que la matriz A^t es de orden $n \times m$.

Ejemplo 2.2 Dada la matriz A de orden 2×3 se calcula la matriz A^t que es de orden 3×2 :

$$\begin{aligned} A &= \begin{pmatrix} -1 & 2 & 3 \\ 0 & 4 & 6 \end{pmatrix} \\ A^t &= \begin{pmatrix} -1 & 0 \\ 2 & 4 \\ 3 & 6 \end{pmatrix} \end{aligned}$$

1.3. Tipos de matrices

Definición 2.1 (Matriz fila) Una matriz fila es una matriz que solo posee una fila, es decir, es de orden $1 \times n$:

$$(a_{11} \quad a_{12} \quad \dots \quad a_{1n})$$

Definición 2.2 (Matriz columna) Una matriz columna es una matriz que solo posee una columna, es decir, es de orden $m \times 1$:

$$\begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{pmatrix}$$

También reciben el nombre de vector fila y vector columna. La traspuesta de una matriz fila es una matriz columna y recíprocamente

Ejemplo 2.3 En la geometría del plano se utilizan las matrices column de orden 2 porque cada vector se representa por una de estas matrices. En especial, se usan mucho las matrices canónicas de $\mathcal{M}_{2 \times 1}$

$$E_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad E_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Definición 2.3 (Matriz cuadrada) Una matriz se llama cuadrada si tiene igual número de filas que de columnas, es decir, $m=n$. Entonces se dice que es una matriz cuadrada de orden n . Se denotará como $\mathcal{M}_n$ al conjunto de todas las matrices cuadradas de orden n

Definición 2.4 (Diagonal principal) Se llama diagonal principal de una matriz cuadrada a los elementos $a_{11}, a_{22}, \dots, a_{nn}$, que tienen el mismo índice de fila que de columna

Definición 2.5 (Matriz simétrica) Una matriz cuadrada A se llama simétrica si coincide con su traspuesta, es decir, $A = A^t$. Para que esta condición pueda cumplirse, la matriz ha de ser necesariamente cuadrada.

Teniendo en cuenta cómo se forma la matriz traspuesta, está claro que A es simétrica si y solo si $a_{ij} = a_{ji}$ para cualquier $i, j = 1, \dots, n$

Ejemplo 2.4 Sea la matriz:

$$A = \begin{pmatrix} 1 & -1 & 6 \\ -1 & 0 & 5 \\ 6 & 5 & 7 \end{pmatrix}$$

Es una matriz cuadrada de orden 3. Si hallamos su traspuesta obtenemos

$$A^t = \begin{pmatrix} 1 & -1 & 6 \\ -1 & 0 & 5 \\ 6 & 5 & 7 \end{pmatrix}$$

que es la propia matriz de A . Es por tanto una matriz simétrica.

En una matriz simétrica los elementos que ocupan una posición simétrica respecto a la diagonal principal son iguales

Definición 2.6 (Matriz nula) Una matriz de orden $m \times n$ formada enteramente por ceros se llama matriz nula. Por ejemplo, son matrices nulas:

$$\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \in \mathcal{M}_3$$
$$\begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \in \mathcal{M}_2$$
$$\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \in \mathcal{M}_{2 \times 3}$$

Definición 2.7 (Matriz diagonal) Una matriz cuadrada se llama diagonal si todos los elementos que no están en la diagonal principal son nulos, es decir, $a_{ij} = 0$ para cualesquiera $i \neq j$, $i, j = 1, \dots, n$

Un caso particular de matriz diagonal es la matriz unidad de orden n , cuya diagonal principal está formada por unos:

$$I_n = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}$$

Definición 2.8 (Matriz triangular superior) Una matriz cuadrada se llama triangular superior si tiene nulos todos los elementos que están por debajo de la diagonal principal

Definición 2.9 (Matriz triangular inferior) Una matriz cuadrada se llama triangular inferior si tiene nulos todos los elementos que están por encima de la diagonal principal

Ejemplo 2.5 Las matrices:

$$\begin{aligned} A &= \begin{pmatrix} -1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 0 \end{pmatrix} \\ I_2 &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \\ I_3 &= \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \end{aligned}$$

Son diagonales. I_2 es la matriz unidad de orden dos e I_3 la de orden tres.

De las siguientes matrices, B es triangular superior y C es triangular inferior:

$$\begin{aligned} B &= \begin{pmatrix} 2 & 3 & 5 & 0 \\ 0 & -5 & 4 & 7 \\ 0 & 0 & 0 & -2 \\ 0 & 0 & 0 & 6 \end{pmatrix} \\ C &= \begin{pmatrix} 3 & 0 & 0 \\ -1 & 2 & 0 \\ 3 & -3 & 5 \end{pmatrix} \end{aligned}$$

2. Suma de matrices y producto por números

En el conjunto de todas las matrices de un mismo orden, $\mathcal{M}_{m \times n}$ se puede definir dos operaciones: la suma de matrices y el producto de un número real por una matriz. Con respecto a estas operaciones, las matrices tienen propiedades similares a la de los vectores de la geometría o de la física.

Definición 2.10 (Suma de matrices) Sean dos matrices A y $B \in \mathcal{M}_{m \times n}$. Se define su suma $A + B$ como una nueva matriz obtenida sumando los elementos de A y B que ocupan el mismo lugar. Por ejemplo, para matrices 2×3

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} + \begin{pmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \end{pmatrix} = \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{12} & a_{13} + b_{13} \\ a_{21} + b_{21} & a_{22} + b_{22} & a_{23} + b_{23} \end{pmatrix}$$

de forma general, si $C = A + B$, entonces $c_{ij} = a_{ij} + b_{ij}$ para $i = 1, \dots, m$ y $j = 1, \dots, n$

Es fácil comprobar que esta operación definida en $\mathcal{M}_{m \times n}$ verifica las siguientes propiedades:

Conmutativa : $A + B = B + A$

Asociativa : $(A + B) + C = A + (B + C)$

Elemento Neutro : Es la matriz nula de orden $m \times n$. Se denota por 0 y verifica $A + 0 = A$, para cualquier matriz A

Elemento Opuesto : Dada una matriz A , se llama matriz opuesta de A , y se denota por $-A$, a la que se forma con los elementos de A cambiados de signo; verifica que $A + (-A) = 0$

Se define la resta de las matrices A y B como el resultado de sumar la matriz A con la opuesta de B , es decir:

$$A - B = A + (-B)$$

de forma general, si $C = A - B$, entonces $c_{ij} = a_{ij} - b_{ij}$ para $i = 1, \dots, m$ y $j = 1, \dots, n$

Ejemplo 2.6 Sean las matrices A, B, C de orden 2×3

$$A = \begin{pmatrix} -1 & 2 & 0 \\ 3 & -4 & 6 \end{pmatrix}; B = \begin{pmatrix} 5 & 7 & -1 \\ 0 & 4 & 0 \end{pmatrix}; C = \begin{pmatrix} -3 & 0 & 6 \\ 2 & 1 & 1 \end{pmatrix}$$

Halla las siguientes matrices

A+B :

$$\begin{pmatrix} -1+5 & 2+7 & 0-1 \\ 3+0 & -4+4 & 6+0 \end{pmatrix} = \begin{pmatrix} 4 & 9 & -1 \\ 3 & 0 & 6 \end{pmatrix}$$

-B :

$$\begin{pmatrix} -5 & -7 & 1 \\ 0 & -4 & 0 \end{pmatrix}$$

A-B :

$$\begin{pmatrix} -1-5 & 2-7 & 0+1 \\ 3-0 & -4-4 & 6-0 \end{pmatrix} = \begin{pmatrix} -6 & -5 & 1 \\ 3 & -8 & 6 \end{pmatrix}$$

A+B+C :

$$\begin{pmatrix} 1 & 9 & 5 \\ 5 & 1 & 7 \end{pmatrix}$$

Definición 2.11 (Producto de un número real por una matriz) Sea α un número y A una matriz de orden $m \times n$. Se define el producto $C = \alpha A$ como otra matriz que se obtiene multiplicando por α cada elemento de la matriz A , es decir, $c_{ij} = \alpha a_{ij}$ para $i = 1, \dots, m$, $j = 1, \dots, n$

Ejemplo 2.7 Con matrices cuadradas de orden dos:

$$\alpha \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} \alpha a & \alpha b \\ \alpha c & \alpha d \end{pmatrix}$$

es decir

$$7 \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix} = \begin{pmatrix} 7 & 21 \\ 14 & 28 \end{pmatrix}$$

es fácil comprobar que esta operación verifica las siguientes propiedades, siendo α y β números cualesquiera y A y B matrices de orden $m \times n$

1. $(\alpha + \beta)A = \alpha A + \beta A$
2. $\alpha(A + B) = \alpha A + \alpha B$
3. $(\alpha\beta)A = \alpha(\beta A)$
4. $1 A = A$

Ejemplo 2.8 Sean las matrices A , B , C de orden 2×3

$$A = \begin{pmatrix} -1 & 2 & 0 \\ 3 & -4 & 6 \end{pmatrix}; B = \begin{pmatrix} 5 & 7 & -1 \\ 0 & 4 & 0 \end{pmatrix}; C = \begin{pmatrix} -3 & 0 & 6 \\ 2 & 1 & 1 \end{pmatrix}$$

Halla las siguientes matrices

2A :

$$2 \begin{pmatrix} -1 & 2 & 0 \\ 3 & -4 & 6 \end{pmatrix} = \begin{pmatrix} -2 & 4 & 0 \\ 6 & -8 & 12 \end{pmatrix}$$

3A-2B :

$$3 \begin{pmatrix} -1 & 2 & 0 \\ 3 & -4 & 6 \end{pmatrix} - 2 \begin{pmatrix} 5 & 7 & -1 \\ 0 & 4 & 0 \end{pmatrix} = \begin{pmatrix} -13 & -8 & 2 \\ 9 & -20 & 18 \end{pmatrix}$$

Se puede observar que las matrices tienen las mismas propiedades que los números ordinarios en lo referente a la suma y al producto por otros números.

Definición 2.12 (Matriz antisimétrica) Una matriz cuadrada A se llama antisimétrica si coincide con la opuesta de su traspuesta, es decir, $A = -A^t$. Observa que para cumplir esta condición tiene que ser necesariamente cuadrada.

Teniendo en cuenta cómo se forma la matriz traspuesta, está claro que A es antisimétrica si y sólo si $a_{ij} = -a_{ji}$ para cualquier $i, j = 1, \dots, n$. En una matriz antisimétrica los elementos de la diagonal principal son nulos.

Ejemplo 2.9 Sea una matriz

$$\begin{pmatrix} 0 & 5 & 6 \\ -5 & 0 & 9 \\ -6 & -9 & 0 \end{pmatrix}$$

Es una matriz cuadrada de orden tres. Si hallamos su traspuesta se obtiene:

$$\begin{pmatrix} 0 & 5 & 6 \\ -5 & 0 & 9 \\ -6 & -9 & 0 \end{pmatrix}$$

que, como se puede comprobar, coincide con la matriz $-A$. Por tanto, A es antisimétrica

Definición 2.13 (Matriz Ortogonal) Una matriz cuadrada y no singular se dice ortogonal si su traspuesta coincide con su inversa, es decir, si $A^t = A^{-1}$ o lo que es lo mismo

$$A \text{ ortogonal} \Leftrightarrow A^t A = A A^t = I_n$$

Definición 2.14 (Traza de una Matriz) Se define la traza de A y se denota por $\text{tr } A$ como la suma de los elementos de su diagonal principal

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}$$

Propiedades de la traza de una matriz

- $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$
- $\text{tr}(\alpha A) = \alpha \text{tr}(A)$

2.1. Combinaciones lineales

Una suma de varias matrices multiplicadas por números recibe el nombre de **combinación lineal** de matrices. Por ejemplo, la expresión:

$$3 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - 2 \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} + \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

es una combinación lineal de tres matrices. Los números 3, -2 y 1 se denominan **coeficientes** de la combinación lineal.

Ejemplo 2.10 Comprobar que la matriz

$$A = \begin{pmatrix} a \\ b \end{pmatrix}$$

se puede expresar como combinación lineal de las matrices canónicas de $\mathcal{M}_{2 \times 1}$.

Las matrices canónicas de $\mathcal{M}_{2 \times 1}$ son

$$E_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$
$$E_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Se encuentra que A es combinación lineal de ellas “deshaciendo operaciones”:

$$A = \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} a \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ b \end{pmatrix} = a \begin{pmatrix} 1 \\ 0 \end{pmatrix} + b \begin{pmatrix} 0 \\ 1 \end{pmatrix} = aE_1 + bE_2$$

3. Producto de matrices

Se define ahora una operación entre matrices llamada producto. Es una operación especial porque no está definida para matrices cualesquiera, sino para las que cumplen una determinada condición.

Sean dos matrices, A de orden $m \times n$ y B de orden $n \times p$. Obsérvese que el número de columnas de la primera matriz coincide con el número de filas de la segunda matriz.

Se define **producto** como una nueva matriz $C=AB$ de orden $m \times p$ en el que el elemento c_{ij} que ocupa el lugar ij se obtiene multiplicando ordenadamente los elementos de la fila i de la matriz A por los de la columna j de la matriz B y sumando los resultados:

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \dots + a_{in}b_{nj}$$
$$= \sum_{k=1}^n a_{ik}b_{kj}$$

Así por ejemplo, el elemento c_{12} de un producto AB se obtiene multiplicando cada elemento de la primera fila de A por la correspondiente de la segunda columna de B y sumando los resultados.

Ejemplo 2.11 Calcular los productos AB y BA siendo

$$A = \begin{pmatrix} 1 & 1 \\ 0 & \frac{1}{2} \end{pmatrix}$$
$$B = \begin{pmatrix} -2 & 4 \\ 6 & 2 \end{pmatrix}$$

AB

$$\begin{pmatrix} 1 & 1 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} -2 & 4 \\ 6 & 2 \end{pmatrix} =$$
$$\begin{pmatrix} 1 \times -2 + 1 \times 6 & 1 \times 4 + 1 \times 2 \\ 0 \times -2 + \frac{1}{2} \times 6 & 0 \times 4 + \frac{1}{2} \times 2 \end{pmatrix} = \begin{pmatrix} 4 & 6 \\ 3 & 1 \end{pmatrix}$$

BA

$$\begin{pmatrix} -2 & 4 \\ 6 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & \frac{1}{2} \end{pmatrix} = \begin{pmatrix} -2 \times 1 + 4 \times 0 & -2 \times 1 + 4 \times \frac{1}{2} \\ 6 \times 1 + 2 \times 0 & 6 \times 1 + 2 \times \frac{1}{2} \end{pmatrix} = \begin{pmatrix} -2 & 0 \\ 6 & 7 \end{pmatrix}$$

Observe que en general, el producto de matrices no es conmutativo.

3.1. Propiedades

El producto de matrices cumple las siguientes propiedades:

Asociativa: Si $(AB)C$ está definido, también lo está $A(BC)$ y se cumple:

$$(AB)C = A(BC)$$

Distributiva respecto a la suma, a los dos lados: Siempre que las dimensiones de las matrices sean adecuadas para realizar los productos, se verifica:

$$\begin{aligned} A(B + C) &= AB + AC \\ (A + B)C &= AC + BC \end{aligned}$$

Factor constante: Si α es un número y el producto AB está definido, entonces

$$(\alpha A)B = A(\alpha B) = \alpha(AB)$$

Ejemplo 2.12 *Comprobar la propiedad asociativa del producto con las matrices*

$$A = \begin{pmatrix} 1 & -1 \\ 0 & 2 \end{pmatrix} \quad B = \begin{pmatrix} 2 & 1 & 0 \\ -3 & 5 & 9 \end{pmatrix} \quad C = \begin{pmatrix} -4 \\ -6 \\ -2 \end{pmatrix}$$

Para comprobarlo se calcula los productos $(AB)C$ y $A(BC)$ y se observa si se obtiene el mismo resultado

$$\begin{aligned} AB &= \begin{pmatrix} 1 & -1 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 2 & 1 & 0 \\ -3 & 5 & 9 \end{pmatrix} = \begin{pmatrix} 5 & -4 & -9 \\ -6 & 10 & 18 \end{pmatrix} \\ (AB)C &= \begin{pmatrix} 5 & -4 & -9 \\ -6 & 10 & 18 \end{pmatrix} \begin{pmatrix} -4 \\ -6 \\ -2 \end{pmatrix} = \begin{pmatrix} 22 \\ -72 \end{pmatrix} \end{aligned}$$

$$BC = \begin{pmatrix} 2 & 1 & 0 \\ -3 & 5 & 9 \end{pmatrix} \begin{pmatrix} -4 \\ -6 \\ -2 \end{pmatrix} = \begin{pmatrix} -14 \\ -36 \end{pmatrix}$$

$$A(BC) = \begin{pmatrix} 1 & -1 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} -14 \\ -36 \end{pmatrix} = \begin{pmatrix} 22 \\ -72 \end{pmatrix}$$

Se ha obtenido $(AB)C = A(BC)$, con lo que queda comprobada la propiedad asociativa

El producto de matrices permite expresar un sistema de ecuaciones lineales como una sola ecuación, pero matricial. Observese los pasos en el siguiente ejemplo:

$$\begin{cases} 2x + y = 9 \\ -4x + 3y = -2 \end{cases}$$

$$\begin{pmatrix} 2x + y \\ -4x + 3y \end{pmatrix} = \begin{pmatrix} 9 \\ 2 \end{pmatrix}$$

La matriz del primer miembro se puede poner como un producto de matrices

$$\begin{pmatrix} 2 & 1 \\ -4 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 9 \\ 2 \end{pmatrix}$$

Se denota por A, X y B las matrices

$$A = \begin{pmatrix} 2 & 1 \\ -4 & 3 \end{pmatrix} \quad X = \begin{pmatrix} x \\ y \end{pmatrix} \quad B = \begin{pmatrix} 9 \\ 2 \end{pmatrix}$$

Ahora el sistema se escribe abreviadamente: $AX=B$

Hay matrices A,B distintas de cero cuyo producto es cero. Como se muestra en el siguiente ejemplo:

Ejemplo 2.13 *Comprobar que las matrices A y B verifican que $AB = 0$, en cambio $BA \neq 0$*

$$A = \begin{pmatrix} 0 & 1 & -1 \\ 0 & -1 & 1 \\ 0 & 1 & -1 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

Realizando ambos productos, se obtiene:

$$AB = \begin{pmatrix} 0 & 1 & -1 \\ 0 & -1 & 1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

$$BA = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & -1 \\ 0 & -1 & 1 \\ 0 & 1 & -1 \end{pmatrix} = \begin{pmatrix} 0 & 2 & -2 \\ 0 & -1 & 1 \\ 0 & -1 & 1 \end{pmatrix}$$

Se ve que, en efecto, AB es una matriz cero, pero BA es una matriz no nula

4. Producto de matrices cuadradas

En el conjunto $\mathcal{M}_n$ de las matrices cuadradas de orden n el producto es una operación que está definida siempre, para dos matrices cualesquiera. Es así porque el número de columnas de una (n) coincide siempre con el número de filas de la otra (n). El resultado es otra matriz cuadrada de orden n.

Además de las propiedades citadas, el producto de matrices de $\mathcal{M}_n$, tiene elemento neutro o unidad, que es la matriz unidad de orden n :

$$I_n = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}$$

En efecto, se verifica:

$$AI_n = I_n A = A \quad \text{para toda matriz } A \in \mathcal{M}_n$$

La matriz unidad se denota sólo por I cuando no hay ambigüedad

5. Transformaciones elementales

Se denominan **transformaciones elementales** a ciertas transformaciones que se realizan en una matriz y que nos serán de gran utilidad en la resolución de sistemas de ecuaciones lineales así como en otras operaciones con matrices que estudiaremos en temas posteriores. Estas transformaciones modifican, de determinadas formas, los elementos de una fila o una columna de la matriz o intercambian dos filas o columnas de esta. Las clasificaremos en dos grupos:

- Transformaciones elementales fila.
- Transformaciones elementales columna.

5.1. Transformaciones elementales fila

Transformaciones F_{ij}

Intercambian las filas i y j de una matriz $A \in \mathbb{R}^{m \times n}$. Este efecto se produce al multiplicar, por la izquierda, la matriz A por la matriz F_{ij} , siendo esta el resultado de intercambiar las filas i y j de la matriz I_m .

Ejemplo 2.14

$$A = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix}$$

Para intercambiar las filas 2º y 3º aplicaremos F_{23} cuya matriz es

$$F_{23} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

En I_3 se han permutado la segunda y tercera fila

$$F_{23}A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 1 & 0 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{pmatrix}$$

observándose que han quedado permutadas las filas segunda y tercera de la matriz A .

Transformaciones $F_i(\alpha)$

Multiplican la fila i de una matriz $A \in \mathbb{R}^{m \times n}$ por un número $\alpha \neq 0$. Este efecto se produce al multiplicar, por la izquierda, la matriz A por la matriz $F_i(\alpha)$, siendo esta el resultado de multiplicar por α la fila i de la matriz I_m .

Ejemplo 2.15 Siguiendo con el ejemplo 2.14. Para multiplicar por 3 la segunda fila de A , se aplica

$$F_2(3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

(se ha multiplicado por 3 la segunda fila de I_3).

$$F_2(3)A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 12 & 6 & 3 & 9 \\ 1 & 0 & 2 & 3 \end{pmatrix}$$

pudiéndose ver que ha quedado multiplicada por 3 la segunda fila de la matriz A .

Transformaciones $F_{ij}(\alpha)$

Suman a la fila i de una matriz $A \in \mathbb{R}^{m \times n}$ su fila j multiplicada por un número $\alpha \neq 0$. Este efecto se produce al multiplicar, por la izquierda, la matriz A por la matriz $F_{ij}(\alpha)$, siendo esta la resultante de sumar a la fila i de la matriz I_m su fila j multiplicada por α , es decir, la matriz resultante de sustituir el elemento $i_{ij} = 0$ por α .

Ejemplo 2.16 Siguiendo con el ejemplo 2.14. Si se quiere restar a la segunda fila de A el doble de la primera, aplicamos $F_{21}(-2)$ cuya matriz asociada es

$$F_{21}(-2) = \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

(se ha sustituido por -2 el elemento $i_{21} = 0$ de la matriz I_3)

$$F_{21}(-2)A = \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 0 & 0 & -5 & -3 \\ 1 & 0 & 2 & 3 \end{pmatrix}$$

observándose que se ha producido en la matriz A el efecto deseado

5.2. Transformaciones elementales columna

Son las mismas que las transformaciones elementales fila pero operando por columnas:

Transformaciones C_{ij}

Intercambian las columnas i y j de una matriz $A \in \mathbb{R}^{m \times n}$. Este efecto se produce al multiplicar, por la derecha, la matriz A por la matriz C_{ij} , siendo esta el resultado de intercambiar las columnas i y j de la matriz I_n .

Ejemplo 2.17 Siguiendo con el ejemplo 2.14. Si deseamos intercambiar las columnas primera y cuarta de la matriz A aplicamos C_{14} cuya matriz asociada es

$$C_{14} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

(se han permutado las columnas 1 y 4 de la matriz I_4).

$$AC_{14} = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 4 & 1 & 3 & 2 \\ 5 & 2 & 1 & 4 \\ 3 & 0 & 2 & 1 \end{pmatrix}$$

Se han permutado las columnas 1 y 4 de la matriz A .

Transformaciones $C_i(\alpha)$

Multiplican la columna i de una matriz $A \in \mathbb{R}^{m \times n}$ por un número $\alpha \neq 0$. Este efecto se produce al multiplicar, por la derecha, la matriz A por la matriz $C_i(\alpha)$, siendo esta el resultado de multiplicar por α la columna i de la matriz I_n .

Ejemplo 2.18 Siguiendo con el ejemplo 2.14. Para multiplicar por 2 la tercera columna de A , se aplica

$$C_3(2) = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

(se ha multiplicado por 2 la tercera columna de I_4).

$$AC_3(2) = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 6 & 4 \\ 12 & 6 & 2 & 9 \\ 1 & 0 & 4 & 3 \end{pmatrix}$$

pudiéndose ver que ha quedado multiplicada por 2 la tercera columna de la matriz A .

Transformaciones $C_{ij}(\alpha)$

Suman a la columna i de una matriz $A \in \mathbb{R}^{m \times n}$ su columna j multiplicada por un número $\alpha \neq 0$. Este efecto se produce al multiplicar, por la derecha, la matriz A por la matriz $C_{ij}(\alpha)$, siendo esta la resultante de sumar a la columna i de la matriz I_n su columna j multiplicada por α , es decir, la matriz resultante de sustituir el elemento $i_{ji} = 0$ por α .

Ejemplo 2.19 Siguiendo con el ejemplo 2.14. Si se quiere sumar a la tercera columna de A el doble de la primera aplicamos $C_{31}(2)$ cuya matriz asociada es

$$C_{31}(2) = \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

(se ha sustituido el elemento i_{13} de la matriz I_4 por 2)

$$F_{21}(-2)A = \begin{pmatrix} 2 & 1 & 3 & 4 \\ 4 & 2 & 1 & 5 \\ 1 & 0 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 7 & 4 \\ 4 & 2 & 9 & 5 \\ 1 & 0 & 4 & 3 \end{pmatrix}$$

observándose que se ha producido en la matriz A el efecto deseado

6. Algoritmo de Gauss-Jordan

Teorema 2.1 Dada una matriz cualquiera $A \in \mathbb{R}^{m \times n}$ existen matrices F y U tales que $FA = U$ siendo U una matriz escalonada.

Demostración

- Comencemos por anular todos los elementos a_{i1} con $1 < i \leq n$.
 - Si $a_{11} \neq 0$ mediante transformaciones elementales filas $F_{ij}(\alpha)$ podemos anular todos los elementos de la primera columna situados por debajo de él. Estas transformaciones serían de la forma $F_{i1}(\frac{-a_{i1}}{a_{11}})$.
 - Si $a_{11} = 0$ y algún elemento de la primera columna es no nulo, podemos llevarlo al lugar (11) mediante una transformación F_{ij} y proceder después como en el caso anterior.
 - Si $a_{i1} = 0 \forall i = 1, \dots, m$, la primera columna es de ceros y por tanto, $a_{i1} = 0 \forall i > 1$, es decir, se trata de una columna del tipo de las matrices escalonadas.
- Procedemos después con a_{22} (el elemento a_{22} resultante de las transformaciones anteriores) al igual que procedimos con a_{11} anteriormente, es decir, si $a_{22} \neq 0$ lo utilizamos para hacer ceros por debajo de él en la segunda columna. Si fuese $a_{22} = 0$ vemos si existe por debajo de él algún elemento $a_{i2} \neq 0$ y, en caso de haberlo, realizamos la transformación F_{2i} , etc.
- Reiterando el proceso, llegamos a una matriz escalonada U .

La matriz F no es más que el producto de las matrices de las transformaciones elementales filas realizadas para pasar de A a U .

Ejemplo 2.20 Consideremos la matriz A del ejemplo 2.14

$$\begin{aligned} A &\xrightarrow{F_{21}(-2)} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 0 & 0 & -5 & -3 \\ 1 & 0 & 2 & 3 \end{pmatrix} \\ &\xrightarrow{F_{31}(\frac{-1}{2})} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 0 & 0 & -5 & -3 \\ 0 & \frac{-1}{2} & \frac{1}{2} & 1 \end{pmatrix} \\ &\xrightarrow{F_{23}} \begin{pmatrix} 2 & 1 & 3 & 4 \\ 0 & \frac{-1}{2} & \frac{1}{2} & 1 \\ 0 & 0 & -5 & -3 \end{pmatrix} = U \end{aligned}$$

que es una matriz escalonada. Dado que

$$F_{23}F_{31}\left(\frac{-1}{2}\right)F_{21}(-2)A = U \Rightarrow FA = U$$

con

$$\begin{aligned} F &= F_{23}F_{31}\left(\frac{-1}{2}\right)F_{21}(-2) = \\ &\begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ \frac{-1}{2} & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \\ F &= \begin{pmatrix} 1 & 0 & 0 \\ \frac{-1}{2} & 0 & 1 \\ -2 & 1 & 0 \end{pmatrix} \end{aligned}$$

Definición 2.15 (Matriz escalonada canónica) Se denomina matriz escalonada canónica a una matriz escalonada con la propiedad de que el primer elemento no nulo de una fila es un uno y además, es el único elemento no nulo de su columna.

Teorema 2.2 Toda matriz puede ser reducida mediante transformaciones elementales fila a una escalonada canónica.

Demostración Basta con observar que una vez obtenida la matriz U , si en una fila hay algún elemento no nulo, la dividimos por el primer elemento no nulo de ella mediante $F_i(\alpha)$ y lo utilizamos para hacer ceros todos los de su columna (que se encontrarán por encima de él).

Ejemplo 2.21 En el Ejemplo 2.20 se vió que

$$\begin{aligned}
 A \rightarrow U &= \begin{pmatrix} 2 & 1 & 3 & 4 \\ 0 & -\frac{1}{2} & \frac{1}{2} & 1 \\ 0 & 0 & -5 & -3 \end{pmatrix} \xrightarrow{F_1(\frac{1}{2})} \begin{pmatrix} 1 & \frac{1}{2} & \frac{3}{2} & 2 \\ 0 & -\frac{1}{2} & \frac{1}{2} & 1 \\ 0 & 0 & -5 & -3 \end{pmatrix} \\
 &\xrightarrow{F_2(-2)} \begin{pmatrix} 1 & \frac{1}{2} & \frac{3}{2} & 2 \\ 0 & 1 & -1 & -2 \\ 0 & 0 & -5 & -3 \end{pmatrix} \xrightarrow{F_{12}(-\frac{1}{2})} \begin{pmatrix} 1 & 0 & 2 & 3 \\ 0 & 1 & -1 & -2 \\ 0 & 0 & 1 & \frac{3}{5} \end{pmatrix} \\
 &\xrightarrow{F_3(-\frac{1}{5})} \begin{pmatrix} 1 & 0 & 2 & 3 \\ 0 & 1 & -1 & -2 \\ 0 & 0 & 1 & \frac{3}{5} \end{pmatrix} \xrightarrow{F_{13}(-2)} \begin{pmatrix} 1 & 0 & 0 & \frac{9}{5} \\ 0 & 1 & -1 & -2 \\ 0 & 0 & 1 & \frac{3}{5} \end{pmatrix} \\
 &\xrightarrow{F_{23}(1)} \begin{pmatrix} 1 & 0 & 0 & \frac{9}{5} \\ 0 & 1 & 0 & -\frac{7}{5} \\ 0 & 0 & 1 & \frac{3}{5} \end{pmatrix}
 \end{aligned}$$

que se trata de una escalonada canónica.

Los elementos que utilizamos para anular a los demás elementos de una columna se denominan pivotes. Si en un determinado paso del proceso de pasar de A a U alguna columna es de ceros, diremos que el correspondiente pivote es nulo.

Teorema 2.3 Una condición necesaria y suficiente para que una matriz cuadrada posea inversa es que su forma escalonada canónica sea la matriz unidad.

7. Inversa de una matriz

Una matriz cuadrada $A \in \mathcal{M}_n$ se llama **invertible** o regular si existe otra matriz $A^{-1} \in \mathcal{M}_n$ tal que $AA^{-1} = A^{-1}A = I_n$. Si tal matriz A^{-1} existe, es única y se llama **inversa** de A. Esta definición es simétrica, es decir si A^{-1} es inversa de A, A es inversa de A^{-1} . Por lo tanto $(A^{-1})^{-1} = A$.

Ejemplo 2.22 Comprobar que las matrices A y B son inversas:

$$\begin{aligned}
 A &= \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \\
 B &= \begin{pmatrix} 1 & -1 & 0 \\ -1 & 1 & 1 \\ 1 & 0 & -1 \end{pmatrix}
 \end{aligned}$$

Se debe probar que $AB=I_3$ y que $BA=I_3$, para la primera igualdad se tiene:

$$AB = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & -1 & 0 \\ -1 & 1 & 1 \\ 1 & 0 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

La segunda igualdad queda para la demostración del lector

Aunque el producto de dos matrices no tiene la propiedad conmutativa, se puede demostrar que si dos matrices cuadradas verifican $AB=I$, entonces son inversas, sin que haya que comprobar que $BA=I$

No todas las matrices son inversibles. Más adelante se verá un criterio para saber cuando una matriz tiene inversa, así como una forma de hallarla. Cuando el orden es pequeño, se puede estudiar si tiene inversa y también hallarla mediante un sistema de ecuaciones, como se demuestra en el siguiente ejemplo.

Ejemplo 2.23 *Hallar la inversa, si la tiene, de*

$$A = \begin{pmatrix} 2 & 4 \\ -1 & 4 \end{pmatrix}$$

Se busca la matriz

$$A^{-1} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

que verifique que:

$$\begin{pmatrix} 2 & 4 \\ -1 & 4 \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Haciendo operaciones, se tiene que

$$\begin{pmatrix} 2a + 3c & 2b + 3d \\ -a + 4c & -b + 4d \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Igualando los respectivos elementos de las matrices, por columnas, se obtiene dos sistemas lineales independientes que, si tienen solución, dará la matriz A^{-1} :

$$\begin{cases} 2a + 3c = 1 \\ -a + 4c = 0 \end{cases} \quad \begin{cases} 2b + 3d = 0 \\ -b + 4d = 1 \end{cases}$$

En este caso se obtiene que

$$\begin{aligned} a &= \frac{4}{11} & b &= \frac{-3}{11} \\ c &= \frac{1}{11} & d &= \frac{2}{11} \end{aligned}$$

con lo que la matriz buscada es:

$$A^{-1} = \begin{pmatrix} \frac{4}{11} & \frac{-3}{11} \\ \frac{1}{11} & \frac{2}{11} \end{pmatrix} = \frac{1}{11} \begin{pmatrix} 4 & -3 \\ 1 & 2 \end{pmatrix}$$

Se puede comprobar este resultado realizando nuevamente el producto AA^{-1} y viendo que $AA^{-1} = I$

En el caso que alguno de los sistemas lineales no tenga solución, la matriz no es inversible

Hay que tener precaución al multiplicar los dos miembros de una igualdad de matrices por una matriz. Al no tener el producto la propiedad conmutativa, se debe multiplicar siempre por el mismo lado en los dos miembros de la igualdad, como se ve en el siguiente ejemplo

Ejemplo 2.24 Sean A y B matrices cuadradas del mismo orden no nulas que verifican que $AB=0$. Probar que ninguna de ellas es inversible.

En primer lugar se demostrará que A no es inversible. Para ello, se razonará por reducción al absurdo, es decir, se supondrá que A tiene inversa, llegando a una contradicción.

Se supondrá entonces que A es inversible, por tanto si se multiplica a la izquierda los dos miembros de la igualdad $AB=0$ por A^{-1} y puesto que $A^{-1}0 = 0$, resulta

$$A^{-1}(AB) = 0$$

Aplicando la propiedad asociativa y la del elemento neutro, se tiene que

$$A^{-1}(AB) = (A^{-1}A)B = IB = B$$

Sustituyendo en la igualdad anterior, se obtiene que:

$$B = 0$$

Pero esto es una contradicción, puesto que se especifica en el enunciado que A y B son no nulas. Por tanto, queda probado que A no es inversible.

Se demuestra de forma analoga que B no es inversible

7.1. Potencias de una matriz

Sea A una matriz cuadrada y n un numero natural. Se define A^n como el producto de la matriz A por si misma n veces

$$A^n = \underbrace{A \cdot A \cdot \dots \cdot A}_n$$

Ejemplo 2.25 Dada la matriz

$$A = \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix}$$

Hallar A^2, A^3

$$A^2 = AA = \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix} \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix} = \begin{pmatrix} 43 & -12 \\ 18 & -5 \end{pmatrix}$$

$$A^3 = AA^2 = \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix} \begin{pmatrix} 43 & -12 \\ 18 & -5 \end{pmatrix} = \begin{pmatrix} 265 & -74 \\ 111 & -31 \end{pmatrix}$$

Para algunas matrices es posible encontrar una ley general para la formación de sus potencias.

Ejemplo 2.26 Sea la matriz

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

Hallar A^2, A^3, A^4 , ¿Hay una ley general para A^n ?

$$A^2 = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}$$

$$A^3 = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 3 \\ 0 & 1 \end{pmatrix}$$

$$A^4 = \begin{pmatrix} 1 & 3 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 4 \\ 0 & 1 \end{pmatrix}$$

se puede conjeturar fácilmente que, para cualquier n , se verifica que:

$$A^n = \begin{pmatrix} 1 & n \\ 0 & 1 \end{pmatrix}$$

Para demostrar esto se aplica el principio de inducción.

7.2. Ecuaciones matriciales

Una ecuación matricial es una ecuación en la que la incógnita es una matriz. Para resolverlas, se combina las propiedades de las operaciones que se han estudiado

Ejemplo 2.27 Resolver la ecuación matricial $AX - B = X$ siendo

$$A = \begin{pmatrix} 1 & 2 \\ 3 & -1 \end{pmatrix} \quad B = \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix}$$

En la ecuación dada se procurará despejar X . Para ello se pasará al primer miembro los términos en X y se sacará factor común

$$AX - B = X \quad AX - X = B \quad (A - I)X = B$$

Si la matrix $A-I$ tiene inversa, se podrá despejar X multiplicando a la izquierda por $(A - I)^{-1}$:

$$X = (A - I)^{-1}B$$

Haciendo las operaciones se obtiene:

$$A - I = \begin{pmatrix} 0 & 2 \\ 3 & -2 \end{pmatrix}; (A - I)^{-1} = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} \\ \frac{1}{2} & 0 \end{pmatrix}$$

con lo que resulta

$$X = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} \\ \frac{1}{2} & 0 \end{pmatrix} \begin{pmatrix} 7 & -2 \\ 3 & -1 \end{pmatrix}$$

CAPÍTULO 3

Determinantes de una matriz

Se introducirá a continuación el concepto de determinante asociado a una matriz cuadrada. Este concepto permite simplificar operaciones matriciales tales como el cálculo de la matriz inversa.

1. Determinantes de segundo orden

Sea A una matriz cuadrada de orden 2:

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$$

se denomina **determinante de la matriz** A al número real

$$|A| = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}$$

Este valor también se denota por $\det(a)$

1.1. Propiedades fundamentales

El determinante de una matriz tiene las siguientes propiedades:

- El determinante de una matriz unidad vale uno:

$$\begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1$$

- El determinante cambia de signo cuando se intercambian sus columnas

$$\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = - \begin{vmatrix} a_{12} & a_{11} \\ a_{22} & a_{21} \end{vmatrix}$$

Ésta es la llamada **propiedad de alternancia**. Se demuestra por cálculo directo

$$\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21} = -(a_{12}a_{21} + a_{11}a_{22}) = - \begin{vmatrix} a_{12} & a_{11} \\ a_{22} & a_{21} \end{vmatrix}$$

- El determinante cambia de signo cuando se intercambian sus filas

$$\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = - \begin{vmatrix} a_{21} & a_{22} \\ a_{11} & a_{12} \end{vmatrix}$$

Se demuestra análogamente al anterior

- si una columna de la matriz se multiplica por un número, el determinante se multiplica por ese mismo número. Así, para la primera columna se obtiene:

$$\begin{vmatrix} ra_{11} & a_{12} \\ ra_{21} & a_{22} \end{vmatrix} = r \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}$$

se demuestra por cálculo directo:

$$\begin{vmatrix} ra_{11} & a_{12} \\ ra_{21} & a_{22} \end{vmatrix} = (ra_{11}a_{22} - a_{12}ra_{21}) = r(a_{11}a_{22} - a_{12}a_{21}) = r \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}$$

- Si una columna de una matriz se expresa como una suma de dos columnas parciales, su determinante es igual a la suma de dos determinantes, uno con cada una de las columnas parciales. Así para la primera columna

$$\begin{vmatrix} a_{11} + b_{11} & a_{12} \\ a_{21} + b_{21} & a_{22} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} + \begin{vmatrix} b_{11} & a_{12} \\ b_{21} & a_{22} \end{vmatrix}$$

Las dos ultimas propiedades, conjuntamente, constituyen la propiedad de la linealidad, que se puede enunciar así:

Proposición 3.1 *El determinante es lineal con respecto a cada columna de la matriz*

- El determinante de su matriz coincide con el de su traspuesta:

$$\det(A) = \det(A^t)$$

Dado que A^t tiene por columnas a las filas de A, la igualdad de los respectivos determinantes implica que el determinante hereda con respecto a las filas las mismas propiedades que tiene con respecto a las columnas. Así por ejemplo, se puede afirmar que:

- El determinante cambia de signo si se intercambian su filas
- El determinante es lineal con respecto a cualquiera de sus filas
- Si dos columnas (o filas) son iguales, el determinante es nulo. Se demuestra directamente a partir de la propiedad de alternancia aplicada a una matriz con dos columnas iguales
- Si sumamos a una columna (o fila) de una matriz un múltiplo de otra, el determinante no varía. Por ejemplo, para la primera columna:

$$\begin{vmatrix} a_{11} + ra_{12} & a_{12} \\ a_{21} + ra_{22} & a_{22} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}$$

Ejemplo 3.1 Probar, sin desarrollar el determinante que:

$$\begin{vmatrix} 2x-4 & 2-x \\ -8 & 4 \end{vmatrix} = 0$$

Se transforma el determinante sumando la segunda columna a la primera, con lo que no cambia su valor, después se aplica la propiedad de linealidad.

$$\begin{vmatrix} 2x-4 & 2-x \\ -8 & 4 \end{vmatrix} = \begin{vmatrix} x-2 & 2-x \\ -4 & 4 \end{vmatrix} = - \begin{vmatrix} 2-x & 2-x \\ 4 & 4 \end{vmatrix} = 0$$

El último determinante es nulo por tener dos columnas iguales.

2. Determinantes de tercer orden

Sea A una matriz cuadrada de orden 3:

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

se denomina **determinante de la matriz** A al número real

$$\begin{aligned} |A| &= \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = \\ &= a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} \\ &\quad - a_{13}a_{22}a_{31} - a_{12}a_{21}a_{33} - a_{11}a_{23}a_{33} \end{aligned}$$

2.1. Propiedades fundamentales

El determinante de una matriz tiene las siguientes propiedades:

- El determinante de una matriz unidad vale uno:

$$\begin{vmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{vmatrix} = 1$$

- El determinante cambia de signo cuando se intercambian sus columnas o filas

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = - \begin{vmatrix} a_{12} & a_{11} & a_{13} \\ a_{22} & a_{21} & a_{23} \\ a_{32} & a_{31} & a_{33} \end{vmatrix} =$$

Ésta es la llamada **propiedad de alternancia**. Se demuestra por cálculo directo

- El determinante es lineal con respecto a cada columna (o fila) de la matriz

$$\begin{vmatrix} ra_{11} & a_{12} & a_{13} \\ ra_{21} & a_{22} & a_{23} \\ ra_{31} & a_{32} & a_{33} \end{vmatrix} = r \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

- Si una columna de una matriz se expresa como una suma de dos columnas parciales, su determinante es igual a la suma de dos determinantes, uno con cada una de las columnas parciales. Así para la primera columna

$$\begin{vmatrix} a_{11} + b_{11} & a_{12} & a_{13} \\ a_{21} + b_{21} & a_{22} & a_{23} \\ a_{31} + b_{31} & a_{32} & a_{33} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} + \begin{vmatrix} b_{11} & a_{12} & a_{13} \\ b_{21} & a_{22} & a_{23} \\ b_{31} & a_{32} & a_{33} \end{vmatrix}$$

- El determinante de su matriz coincide con el de su traspuesta:

$$\det(A) = \det(A^t)$$

Dado que A^t tiene por columnas a las filas de A, la igualdad de los respectivos determinantes implica que el determinante hereda con respecto a las filas las mismas propiedades que tiene con respecto a las columnas. Así por ejemplo, se puede afirmar que:

- Si dos columnas (o filas) son iguales, el determinante es nulo. Se demuestra directamente a partir de la propiedad de alternancia aplicada a una matriz con dos columnas iguales
- Si sumamos a una columna (o fila) de una matriz un múltiplo de otra, el determinante no varía. Por ejemplo, para la primera columna:

$$\begin{vmatrix} a_{11} + ra_{12} & a_{12} & a_{13} \\ a_{21} + ra_{22} & a_{22} & a_{23} \\ a_{31} + ra_{32} & a_{32} & a_{33} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

- Un determinante de orden dos se puede poner como uno de tercer orden:

$$\begin{vmatrix} 1 & \bullet & \bullet \\ 0 & a & b \\ 0 & c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix}$$

2.2. Desarrollo con respecto a una columna o fila

Sea una matriz cuadrada de orden tres:

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

Se considera el elemento a_{ij} que está en la intersección de la fila i con la columna j

Definición 3.1 (Menor complementario) Se llama menor complementario del elemento a_{ij} al determinante de la matriz que resulta de eliminar en la matriz A la fila i y la columna j . Se designa por M_{ij}

Por ejemplo, los menores de los elementos a_{23} y a_{22} son:

$$M_{23} = \begin{pmatrix} a_{11} & a_{12} \\ a_{31} & a_{32} \end{pmatrix}$$

$$M_{22} = \begin{pmatrix} a_{11} & a_{13} \\ a_{31} & a_{33} \end{pmatrix}$$

Definición 3.2 (Adjunto) Se define adjunto A_{ij} del elemento a_{ij} mediante la relación:

$$A_{ij} = (-1)^{i+j} M_{ij}$$

Donde M_{ij} designa al menor de a_{ij} . El adjunto y el menor únicamente se pueden diferenciar en el signo

Definición 3.3 (Matriz adjunta) Se llama matriz adjunta de A a la matriz que resulta de sustituir en A cada elemento por su adjunto. Se designa $\text{adj } A$:

$$\text{adj } A = \text{adj} \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} A_{11} & A_{12} & A_{13} \\ A_{21} & A_{22} & A_{23} \\ A_{31} & A_{32} & A_{33} \end{pmatrix}$$

El cálculo de un determinante de orden 3 se puede reducir al cálculo de determinantes de orden 2, como consecuencia del siguiente teorema

Teorema 3.1 (Desarrollo por una columna o fila) El determinante de una matriz es igual a la suma de los productos de los elementos de una columna o fila por sus correspondientes adjuntos

Así, para la primera columna y primera fila respectivamente se tiene:

$$\begin{aligned} \det(A) &= a_{11}A_{11} + a_{21}A_{21} + a_{31}A_{31} \\ \det(A) &= a_{11}A_{11} + a_{12}A_{12} + a_{13}A_{13} \end{aligned}$$

y expresiones análogas para las demás filas y columnas.

Se demostrará para la primera relación. Para ello, se expresa la primera columna como suma y se aplica la propiedad lineal

$$\begin{aligned} \det(A) &= \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} \\ &= \begin{vmatrix} a_{11} + 0 + 0 & a_{12} & a_{13} \\ 0 + a_{21} + 0 & a_{22} & a_{23} \\ 0 + 0 + a_{31} & a_{32} & a_{33} \end{vmatrix} \\ &= \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{vmatrix} + \begin{vmatrix} 0 & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{vmatrix} + \begin{vmatrix} 0 & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} \end{aligned}$$

De nuevo por la propiedad de la linealidad, permite extraer cada determinante un factor de la primera columna

$$\det(A) = a_{11} \begin{vmatrix} 1 & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{vmatrix} + a_{21} \begin{vmatrix} 0 & a_{12} & a_{13} \\ 1 & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{vmatrix} + a_{31} \begin{vmatrix} 0 & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 1 & a_{32} & a_{33} \end{vmatrix}$$

Ahora permitiendo filas y teniendo en cuenta las propiedades, se llega al resultado buscado

$$\begin{aligned} \det(A) &= a_{11} \begin{vmatrix} 1 & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{vmatrix} - a_{21} \begin{vmatrix} 1 & a_{22} & a_{23} \\ 0 & a_{12} & a_{13} \\ 0 & a_{32} & a_{33} \end{vmatrix} + a_{31} \begin{vmatrix} 1 & a_{32} & a_{33} \\ 0 & a_{22} & a_{23} \\ 0 & a_{12} & a_{13} \end{vmatrix} \\ &= a_{11}M_{11} - a_{21}M_{21} + a_{31}M_{31} \\ &= a_{11}A_{11} + a_{21}A_{21} + a_{31}A_{31} \end{aligned}$$

se demuestra de forma análoga con respecto a cualquier otra fila o columnas

Proposición 3.2 (Propiedad) *La suma de los productos elementales de una columna (o fila) por los adjuntos de otra es igual a cero.*

Por ejemplo, tomando los elementos de la primera columna y los adjuntos de la segunda en la matriz A, se tiene la relación

$$a_{11}A_{12} + a_{21}A_{22} + a_{31}A_{32} = 0$$

Para demostrarlo, se tomará el determinante de la matriz que resulta de igualar en A las dos primera columnas y se desarrollara por la segunda columna

$$0 = \begin{vmatrix} a_{11} & a_{11} & a_{13} \\ a_{21} & a_{21} & a_{23} \\ a_{31} & a_{31} & a_{33} \end{vmatrix} = a_{11}A_{12} + a_{21}A_{22} + a_{31}A_{32}$$

Es claro que el determinante habrá que ser nulo porque tiene dos columnas iguales. Por otra parte, obsérvese que los adjuntos de los elementos de la segunda columna de esta matriz coinciden con los de la misma columna de la matriz original A. Esto es así porque los adjuntos se calculan prescindiendo de la propia columna, que es lo único en que se diferencian ambas matrices.

3. Determinantes de orden superior a tres

Para el determinante de matrices cuadradas de cualquier orden se toma como definición las tres propiedades fundamentales. Partiendo de ellas se deduce el valor de cualquier determinante.

Sea A una matriz cuadrada de orden n; se define su **determinante** $|A|$ o $\det(A)$, como una función que verifica las siguientes propiedades:

- El determinante de la matriz unidad vale 1

$$|I_n| = 1$$

- El determinante es lineal con respecto a cada columna (o fila).

Por ejemplo, para la primera columna

$$\begin{vmatrix} ra_{11} & a_{12} & \dots & a_{1n} \\ ra_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ ra_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} = r \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix}$$

$$\begin{vmatrix} a_{11} + b_{11} & a_{12} & \dots & a_{1n} \\ a_{21} + b_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} + b_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} + \begin{vmatrix} b_{11} & a_{12} & \dots & a_{1n} \\ b_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ b_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix}$$

- Cuando se intercambian dos columnas o dos filas, el determinante cambia de signo.

Por ejemplo, para las dos primera filas columna se tiene:

$$\begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} = - \begin{vmatrix} a_{12} & a_{11} & \dots & a_{1n} \\ a_{22} & a_{21} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n2} & a_{n1} & \dots & a_{nn} \end{vmatrix}$$

Para una matriz cuadrada de orden n se define el menor complementario, M_{ij} y el adjunto A_{ij} de un elemento a_{ij} de la misma forma en que se hizo en el orden tres.

- El determinante de una matriz coincide con el de su transpuesta

$$\det(A) = \det(A^t)$$

- El determinante de una matriz con dos columnas (filas) iguales vale cero
- El valor del determinante de una matriz no varía si a una columna (fila) se le añade un múltiplo de otra
- El determinante de una matriz triangular es igual al producto de los elementos de la diagonal principal
- El determinante de una matriz es igual a la suma de los productos de los elementos de una columna o fila por sus correspondientes adjuntos

$$\det(A) = a_{11}A_{11} + a_{21}A_{21} + \dots + a_{n1}A_{n1}$$

y expresiones análogas para cualquier fila o columna

- La suma de los productos de los elementos de una columna o fila por los adjuntos de otra, vale cero:

$$a_{11}A_{13} + a_{21}A_{23} + \dots + a_{n1}A_{n3}$$

3.1. Cálculo de determinantes

Para hallar el valor de determinantes de órdenes 2 o 3 se puede usar directamente la definición. En general, el cálculo de un determinante de cualquier orden se puede reducir al de un determinante de un orden inferior, desarrollándolo por una fila o por una columna. La existencia de muchos ceros en el determinante facilita el proceso.

Por esta razón, antes de desarrollar un determinante por una fila o columna, se aplica las propiedades con el fin de hacer cero todos los elementos de esa fila o columna salvo uno.

3.2. Determinante de un producto de matrices

Se verifica la siguiente propiedad

Teorema 3.2 Sean A y B dos matrices cuadradas del mismo orden; entonces el determinante de su producto es igual al producto de los correspondientes determinantes

$$\det(AB) = \det(A)\det(B)$$

Como consecuencia de este teorema se obtiene una importante propiedad de las matrices.

Proposición 3.3 Toda matriz inversible tiene determinante distinto de cero

En efecto, partiendo de la relación $AA^{-1} = I_n$ se deduce:

$$1 = \det(I_n) = \det(AA^{-1}) = \det(A)\det(A^{-1})$$

Como el producto $\det(A)\det(A^{-1})$ es distinto de cero, sus factores han de serlo también.

4. Cálculo de la matriz inversa

Sea A una matriz cuadrada de orden n , tiene inversa si hay otra matriz A^{-1} , que cumple $AA^{-1} = I_n$. Se sabe que, en ese caso, tiene que ser $|A| \neq 0$. También es cierta la propiedad recíproca, como afirma el siguiente teorema

Teorema 3.3 Una matriz cuadrada A tiene inversa si y solo si su determinante es distinto de cero, y en ese caso A^{-1} se obtiene como el inverso del determinante de A multiplicando por la traspuesta de la matriz adjunta de A :

$$A^{-1} = \frac{1}{|A|} [\text{adj} A]^t$$

Para el orden 3 se expresa

$$A^{-1} = \frac{1}{|A|} \begin{pmatrix} A_{11} & A_{21} & A_{31} \\ A_{12} & A_{22} & A_{32} \\ A_{13} & A_{23} & A_{33} \end{pmatrix}$$

CAPÍTULO 4

Sistemas de ecuaciones lineales.

Uno de los problemas fundamentales del Álgebra Lineal es la resolución simultánea de ecuaciones lineales, siendo el caso más simple aquel en el que el número de incógnitas coincide con el número de ecuaciones.

Desde los textos de secundaria se proponen tres métodos para resolver tales sistemas de ecuaciones lineales:

- Eliminación.
- Determinantes.

El primer método, eliminación, consiste en sustraer múltiplos de la primera ecuación de las restantes, de tal manera que sea posible eliminar una misma incógnita en el resto de las ecuaciones, con lo que se obtiene un sistema con una ecuación y una incógnita menos. El proceso se repite una y otra vez hasta que sólo queda una ecuación con una incógnita, que se resuelve inmediatamente.

No es difícil recorrer los pasos seguidos en sentido contrario y calcular el resto de las incógnitas. El procedimiento permite además detectar aquellos casos en que no existe solución o, por el contrario, existe infinitud de ellas.

El segundo método, determinantes, más complicado, introduce la idea de los determinantes y mediante la regla de Cramer se obtienen las soluciones como cocientes de dos determinantes. El coste de cálculo de dicho método lo hace viable para tamaño $n = 2$ o 3 , pero cuando se trata de resolver sistemas con un número grande de incógnitas, se utiliza el método de eliminación, de coste bastante inferior. Esta primera parte corresponde al “Álgebra Clásica” que se ocupa, fundamentalmente, de la resolución de ecuaciones y sistemas de ecuaciones. La segunda parte corresponde al “Álgebra Moderna”, que estudia las llamadas estructuras algebraicas. Éstas se pueden interpretar como sistemas de elementos entre los que se definen operaciones similares a las que podemos realizar con números. El estudio abstracto de tales estructuras permite su aplicación casi inmediata en numerosos áreas donde aparecen estructuras particulares de forma natural, lo que pone de manifiesto la unidad profunda entre los diversos campos de la matemática. Una de las estructuras algebraicas

más relevantes, dentro del álgebra lineal, es la estructura de espacio vectorial, íntimamente ligada al estudio y resolución de sistemas de ecuaciones lineales.

1. Notación y definiciones

Se denomina sistema de m -ecuaciones lineales con n -incógnitas a un sistema de ecuaciones de la forma:

$$S = \begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n & = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & = b_2 \\ \vdots & \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & = b_m \end{cases}$$

siendo $x_1, x_2, \dots, x_n$ las incógnitas del sistema y todos los a_{ij} y b_i representan valores escalares pertenecientes a un cuerpo de números, $\mathbf{K}$, que para nuestros propósitos en esta asignatura corresponderá con el cuerpo de los números reales, $\mathbb{R}$.

- Una solución del sistema consiste en la asignación de valores de $\mathbb{R}$ a cada una de las incógnitas de tal forma que se verifique cada una de las ecuaciones que componen el sistema.
- Sea $\mathcal{S}(S)$ el conjunto de todas las posibles soluciones de un sistema S . Se pueden presentar los siguientes casos:
 - Si $\mathcal{S}(S) = \emptyset \Rightarrow$ Sistema Incompatible
 - Si $\mathcal{S}(S) \neq \emptyset \Rightarrow$ Sistema Compatible
 - Si $\mathcal{S}(S)$ unitario $\Rightarrow$ Sistema Compatible Determinado
 - Si $\mathcal{S}(S)$ unitario $\Rightarrow$ Sistema Compatible Indeterminado
- Dos ecuaciones se dicen equivalentes cuando las soluciones de la primera lo son también de la segunda y viceversa. Por extensión, dos sistemas se dicen equivalentes cuando sus conjuntos de soluciones son idénticos.

Definición 4.1 (Propiedades de los sistemas de ecuaciones lineales) ■

Si se multiplican los dos miembros de una ecuación por un escalar (real) no nulo, la ecuación resultante es equivalente a la primitiva.

- *Si se suman, miembro a miembro, dos ecuaciones con soluciones comunes, la ecuación resultante conserva las soluciones comunes.*

Los sistemas lineales admiten una sencilla representación matricial. Así, podemos denotar $Ax = b$ siendo:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix} \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

gracias a la definición dada para el producto entre matrices y la de igualdad entre matrices.

Es importante observar que en esta notación matricial se establece un orden para las variables del sistema ya que los coeficientes asociados a una variable se corresponden con una columna de la matriz A , llamada por ello matriz de los coeficientes; x es la matriz de las variables y b es la matriz de los términos independientes del sistema.

Para hacer más operativa la notación a la hora de resolver sistemas lineales, podemos prescindir de la matriz columna de las variables del sistema y en su lugar representar el sistema mediante una única matriz ampliada, $(A|b)$, que consiste en añadir a la matriz A una última columna correspondiente a la matriz b . De esta forma, una vez ordenadas las variables del sistema podemos identificar visualmente cada fila de la nueva matriz con una de las ecuaciones del sistema. Las propiedades enunciadas anteriormente pueden expresarse ahora en términos de las transformaciones elementales fila.

- Si se aplica a la matriz ampliada de un sistema una transformación elemental fila $F_i(\alpha)$, con α no nulo, la matriz resultante representa un sistema lineal equivalente al anterior.
- Si se aplica a la matriz ampliada de un sistema una transformación elemental fila $F_{ij}(1)$, la matriz resultante representa un sistema lineal equivalente al anterior.

Evidentemente, la combinación de ambos tipos de transformaciones elementales, nos permite aplicar transformaciones fila del tipo $F_{ij}(\alpha)$, obteniéndose sistemas equivalentes.

Finalmente, la transformación elemental F_{ij} tan solo representa una permuta entre las ecuaciones i -ésima y j -ésima, por lo que resulta un sistema equivalente. Estamos en condiciones de abordar el primer método para la resolución de sistemas de ecuaciones lineales.

2. Método de eliminación Gaussiana

Este método de resolución de sistemas de ecuaciones admite una fácil programación, lo que permite resolver un sistema con la ayuda del ordenador. La idea del método consiste en aplicar a la matriz ampliada del sistema transformaciones elementales sobre las filas (no pueden realizarse transformaciones columna) obteniendo, de esta forma, sistemas equivalentes al dado pero cada vez más manejables. Mediante transformaciones, se consigue obtener un sistema equivalente al dado que tiene por matriz de los coeficientes una matriz escalonada. La notación quedará simplificada empleando matrices ampliadas para representar en todo momento a los sistemas lineales equivalentes que resultan tras las transformaciones.

Vamos a iniciar el método con un ejemplo de orden tres.

Ejemplo 4.1 *Sea el sistema*

$$S = \begin{cases} 2x + y + z = 1 \\ 4x + y = -2 \\ -2x + 2y + z = 7 \end{cases}$$

2. MÉTODO DE ELIMINACIÓN GAUSSIANA

y nuestro problema es determinar los valores de x , y , z . En primer lugar, tomaremos la matriz ampliada del sistema, siguiendo el orden natural para las variables de mismo:

$$\left(\begin{array}{ccc|c} 2 & 1 & 1 & 1 \\ 4 & 1 & 0 & -2 \\ -2 & 2 & 1 & 7 \end{array} \right)$$

Este método, también conocido como de eliminaciones sucesivas o método de escalonamiento comienza restando múltiplos de la primera ecuación (fila) a las restantes, con el fin de eliminar una incógnita, la x de las últimas ecuaciones. Para ello:

- Sumamos a la segunda ecuación la primera multiplicada por -2 .
- Sumamos a la tercera ecuación la primera multiplicada por 1 .

$$(A|b) \xrightarrow{F_{21}(-2)} \left(\begin{array}{ccc|c} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ -2 & 2 & 1 & 7 \end{array} \right) \xrightarrow{F_{31}(1)} \left(\begin{array}{ccc|c} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ 0 & 3 & 2 & 8 \end{array} \right)$$

El resultado es un sistema equivalente al dado:

$$S' = \begin{cases} 2x + y + z = 1 \\ -y - 2z = -4 \\ 3y + 2z = 8 \end{cases}$$

El coeficiente de x en la primera ecuación se denomina pivote. En el segundo paso, ignoramos la primera ecuación y aplicamos el proceso a las dos ecuaciones restantes, donde las incógnitas son y y z . En este caso, el pivote es -1 (coeficiente de y en la segunda ecuación).

- Sumamos a la tercera ecuación la segunda multiplicada por 3

$$\left(\begin{array}{ccc|c} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ 0 & 3 & 2 & 8 \end{array} \right) \xrightarrow{F_{32}(3)} \left(\begin{array}{ccc|c} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ 0 & 0 & -4 & -4 \end{array} \right)$$

y llegamos al sistema equivalente:

$$S'' = \begin{cases} 2x + y + z = 1 \\ -y - 2z = -4 \\ -4z = -4 \end{cases}$$

Ahora, el proceso de eliminación está completo. Hay un orden evidente para resolver este sistema: de la última ecuación obtenemos:

$$-4z = -4 \Rightarrow z = 1$$

Sustituyendo este resultado en la segunda ecuación obtenemos

$$-y - 2 = -4 \Rightarrow y = 2$$

Por último, sustituyendo ambos resultados en la primera ecuación, se obtiene

$$2x + 2 + 1 = 1 \Rightarrow x = -1$$

Este proceso para obtener los valores de las incógnitas, se conoce con el nombre de sustitución regresiva.

CAPÍTULO 4. SISTEMAS DE ECUACIONES LINEALES.

Es fácil entender cómo podemos extender la idea de la eliminación gaussiana a un sistema de n -ecuaciones con n -incógnitas:

1. En un primer paso, utilizamos múltiplos de la primera ecuación para anular todos los coeficientes bajo el primer pivote.
2. A continuación, se anula la segunda columna bajo el segundo pivote, etc.
3. La última columna contiene sólo a la última de las incógnitas.
4. La sustitución regresiva conduce a la solución en sentido contrario, es decir, comenzando por la última incógnita hasta llegar a la primera.

Las preguntas que nos podríamos hacer tras ver el ejemplo 26.2 son **¿Conduce siempre a la solución el proceso de eliminación gaussiana?** y, en caso contrario **¿Bajo qué condiciones puede fallar el proceso?**

Ejemplo 4.2 Sea el sistema

$$S = \begin{cases} x + y + z = 1 \\ 2x + 2y + z = 2 \\ x + y = 1 \end{cases}$$

Procedemos a escalar la matriz ampliada del sistema:

$$\begin{aligned} & \left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 2 & 2 & 1 & 2 \\ 1 & 1 & 0 & 1 \end{array} \right) \xrightarrow{F_{21}(-2)} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 0 & -1 & 0 \\ 1 & 1 & 0 & 1 \end{array} \right) \xrightarrow{F_{31}(-1)} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & -1 & 0 \end{array} \right) \\ & \xrightarrow{F_{32}(-1)} \left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right) \end{aligned}$$

La presencia de la Última fila de ceros indica que existían dos ecuaciones proporcionales en el Último paso (la segunda y tercera ecuaciones son idénticas) por lo que puede ser eliminada del sistema equivalente:

$$S = \begin{cases} x + y + z = 1 \\ -z = 0 \end{cases}$$

La sustitución regresiva, proporciona los valores $z = 0$ y $x = 1 - y$. Obsérvese que en este ejemplo existe una relación de dependencia entre las variables x e y . Si tomamos un valor cualquiera para y , éste determina otro para la x . Existen infinitas soluciones en este caso, que podemos expresar de forma paramétrica como

$$S = \begin{cases} x = 1 - \lambda \\ y = \lambda \\ z = 0 \end{cases}$$

Se dice que y actúa como **variable independiente** y x, z son **variables dependientes**. Estamos ante un **sistema compatible indeterminado**.

Ejemplo 4.3 Para resolver el sistema

$$S = \begin{cases} x - 2y + 2z = 3 \\ 3x - 5y + 4z = 1 \\ 2x - 3y + 2z = 1 \end{cases}$$

Una vez más procedemos a escalar la matriz ampliada del sistema:

$$\begin{aligned} & \left(\begin{array}{ccc|c} 1 & -2 & 2 & 3 \\ 3 & -5 & 4 & 1 \\ 2 & -3 & 2 & 1 \end{array} \right) \xrightarrow{F_{21}(-3)} \left(\begin{array}{ccc|c} 1 & -2 & 2 & 3 \\ 0 & 1 & -2 & -8 \\ 2 & -3 & 2 & 1 \end{array} \right) \\ & \xrightarrow{F_{31}(-2)} \left(\begin{array}{ccc|c} 1 & -2 & 2 & 3 \\ 0 & 1 & -2 & -8 \\ 0 & 1 & -2 & -5 \end{array} \right) \xrightarrow{F_{32}(-1)} \left(\begin{array}{ccc|c} 1 & -2 & 2 & 3 \\ 0 & 1 & -2 & -8 \\ 0 & 0 & 0 & 3 \end{array} \right) \end{aligned}$$

La última fila representa la ecuación $0x + 0y + 0z = 3$ lo que produce un sistema incompatible ya que $0 \neq 3$. Por tanto, no hay soluciones para nuestro sistema original. Se trata de un **sistema incompatible**.

Tras estos tres ejemplos, podemos analizar el comportamiento del método de eliminación gaussiana en relación con los pivotes del método de escalonamiento de Gauss-Jordan.

- El caso de sistema incompatible (Ejemplo 4.3) se identifica fácilmente por el hecho de que existe un pivote en la última columna de la matriz ampliada.
- En caso contrario, resulta un sistema compatible
 - Determinado si el número de pivotes coincide con el de variables.
 - Indeterminado si el número de pivotes es menor que el de variables.

2.1. Sistemas de ecuaciones lineales homogéneos

Un sistema de ecuaciones lineales se dice que es homogéneo cuando todos sus términos independientes son nulos, es decir, es un sistema del tipo:

$$S = \begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n & = 0 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & = 0 \\ \vdots & \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & = 0 \end{cases}$$

De la sección anterior se deduce que si aplicamos el método de eliminación gaussiana, puesto que la matriz ampliada tiene su última columna nula, por más transformaciones elementales fila que hagamos, siempre resultará otra columna nula.

En conclusión: nunca habrá un pivote en esa columna y por tanto el sistema siempre es compatible. Si el número de pivotes es igual al número de variables, el sistema es compatible determinado con solución única trivial (todas las variables toman el valor nulo) mientras que si el número de pivotes es menor, habrá infinitas soluciones y el sistema es compatible indeterminado.

Podemos por tanto clasificar a los sistemas homogéneos como:

- Incompatibles: aquellos que sólo admiten la solución trivial.
- Compatibles: aquellos que admiten infinitas soluciones.

Al resolver un sistema homogéneo compatible mediante eliminación gaussiana, las variables asociadas a las columnas que contienen a los pivotes se denominan variables dependientes, siendo todas las demás variables independientes.

Podemos despejar, mediante sustitución regresiva, las variables dependientes en función de las independientes. Las infinitas soluciones pueden expresarse mediante una serie de parámetros, tantos como variables independientes haya. Veamos un ejemplo:

Ejemplo 4.4 *Resolvamos el sistema homogéneo:*

$$S = \begin{cases} 2x + y - z + t = 0 \\ x + 2y + z - t = 0 \\ 3x - y - 2t = 0 \end{cases}$$

Como ya comentamos, la matriz ampliada tiene su última columna llena de ceros y éstos permanecerán por muchas transformaciones elementales fila que hagamos.

Así pues, para resolver sistemas homogéneos mediante escalonamiento se prescinde de emplear la matriz ampliada y en su lugar tomamos simplemente la matriz de los coeficientes.

Procedemos a escalonar dicha matriz:

$$\begin{aligned} & \begin{pmatrix} 2 & 1 & -1 & 1 \\ 1 & 2 & 1 & -1 \\ 3 & -1 & 0 & -2 \end{pmatrix} \xrightarrow{F_{21}(\frac{-1}{2})} \begin{pmatrix} 2 & 1 & -1 & 1 \\ 0 & \frac{3}{2} & \frac{3}{2} & \frac{-3}{2} \\ 3 & -1 & 0 & -2 \end{pmatrix} \\ & \xrightarrow{F_{31}(\frac{-3}{2})} \begin{pmatrix} 2 & 1 & -1 & 1 \\ 0 & \frac{3}{2} & \frac{3}{2} & \frac{-3}{2} \\ 0 & \frac{-5}{2} & \frac{3}{2} & \frac{-7}{2} \end{pmatrix} \xrightarrow{F_{32}(\frac{-5}{3})} \begin{pmatrix} 2 & 1 & -1 & 1 \\ 0 & \frac{3}{2} & \frac{3}{2} & \frac{-3}{2} \\ 0 & 0 & 4 & -6 \end{pmatrix} \end{aligned}$$

Aunque el proceso de escalonamiento ha concluido, podemos simplificar algunas ecuaciones aplicando ahora:

$$\xrightarrow{F_2(\frac{2}{3})} \begin{pmatrix} 2 & 1 & -1 & 1 \\ 0 & 1 & 1 & -1 \\ 0 & 0 & 4 & -6 \end{pmatrix} \xrightarrow{F_3(\frac{1}{2})} \begin{pmatrix} 2 & 1 & -1 & 1 \\ 0 & 1 & 1 & -1 \\ 0 & 0 & 2 & -3 \end{pmatrix}$$

con lo que resulta el sistema equivalente

$$S = \begin{cases} 2x + y - z + t = 0 \\ y + z - t = 0 \\ 2z - 3t = 0 \end{cases}$$

Los pivotes se encuentran sobre las tres primeras columnas por lo que tomaremos como variables dependientes x, y, z , resultando t la única variable independiente. El sistema homogéneo es compatible; presenta infinitas soluciones que podemos

expresar, paramétricamente, como:

$$\begin{aligned} x &= \frac{1}{2}\lambda & y &= \frac{-1}{2}\lambda \\ z &= \frac{3}{2}\lambda & t &= \lambda \end{aligned}$$

Habitualmente, cuando los cálculos se realizan a mano, con objeto de reducir la cantidad de anotaciones, se realizan transformaciones elementales paralelamente a varias filas a la vez. Por otra parte, también es deseable evitar, en la medida de lo posible, la manipulación de fracciones. Para ello, realizaremos transformaciones entre las filas que denotaremos $aF_i - bF_j$ y que representan el equivalente a dos transformaciones elementales filas consecutivas: $F_i(a)$ seguida de $F_{ij}(-b)$.

Aunque no se sigue el método de Gauss-Jordan en sentido estricto, los sistemas resultantes también son equivalentes.

3. Rango de una matriz

El objetivo de esta sección se definir el rango de una matriz. La idea es “convertir” una matriz dada en otra mas sencilla que estar formada por 1 y 0 y el numero de unos sea fijo *independientemente* de las transformaciones que hagamos en la matriz original. También hay que definir que tipos de transformaciones son las permitidas.

En $\mathcal{M}_n(\mathbb{R})$ definimos las matrices elementales como:

1. F_{ij} es la matriz que resulta de la matriz identidad I al intercambiar la fila i por la j.
2. $F_i(\lambda)$ es la matriz que resulta de I cuando multiplicamos la fila i por el escalar λ .
3. $F_{ij}(\lambda)$ es la matriz que resulta de I cuando se suma a la i-fila la fila j multiplicada por λ .

Definimos las transformaciones permitidas para una matriz dada. Sea $A \in \mathcal{M}_{m \times n}(\mathbb{R})$ y multiplicando por la izquierda por matrices elementales, obtenemos tres tipos de matrices, a saber:

1. $F_{ij}A$ Esta matriz resulta de A al intercambiar la fila i y la j.
2. $F_i(\lambda)A$. Esta matriz resulta de A multiplicando la fila i por λ .
3. $F_{ij}(\lambda)A$. Esta matriz resulta de sumar a la fila i de A, la fila j de A multiplicada por λ .

A cada una de las anteriores operaciones definidas en A se llama transformación elemental (por filas). Ya que solo nos interesa transformaciones elementales que resultan de producto de A por matrices elementales regulares, supondremos a partir de ahora que cuando se multiplica por una matriz elemental del tipo $F_i(\lambda)$, el escalar λ no es cero

Del mismo modo, se definen las transformaciones elementales por columnas de la matriz A , sin mas que multiplicar a la derecha de A por matrices elementales. Hay que observar ahora que dichas matrices elementales son de orden n (debe coincidir con el numero de columnas de A). En esta situación escribiremos dichas matrices por los símbolos C_{ij} , $C_i(\lambda)$ y $C_{ij}(\lambda)$. Y también, si no necesitamos indicar a que tipo de las tres pertenece, escribiremos simplemente C_i .

Definición 4.2 *La matriz A se llama equivalente a B y escribiremos $A \sim B$, si se puede pasar de A a B por transformaciones elementales (por filas), es decir, si existen matrices elementales por filas $F_1 \dots F_p$ tales que*

$$B = F_1 \dots F_p A$$

De la misma se tendría otra relación de equivalencia trabajando con transformaciones por columnas.

Definición 4.3 *Sea $A \in \mathcal{M}_{m \times n}(\mathbb{R})$. Se dice que A es una matriz escalonada (por filas) si satisface las siguientes propiedades:*

1. *Si A tiene filas de ceros, estas se encuentran en las últimas filas de A .*
2. *El primer elemento no nulo de una fila no nula es un 1. A este elemento se llama elemento principal o pivote de dicha fila.*
3. *Cada pivote se encuentra en una columna posterior al pivote de la fila anterior.*

Además, si todos los elementos de la columna donde se encuentra el pivote son 0, se dice que la matriz es escalonada reducida.

De manera análoga se tiene el concepto de matriz escalonada reducida por columnas, es decir, una matriz donde las columnas de ceros se encuentran en las últimas columnas de la matriz, el primer elemento no nulo de la columna es un 1, y cada uno de estos unos, llamado pivote, se encuentra en una fila posterior a la fila del pivote de la columna anterior.

Las siguientes matrices son matrices escalonadas (por filas) pero no reducidas:

$$\begin{pmatrix} 1 & 2 & 3 \\ 0 & 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 \\ 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 & 1 & 2 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

y las siguientes son escalonadas reducidas:

$$\begin{pmatrix} 1 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

El siguiente paso, el cual es clave en toda esta sección, es que para una matriz dada, es posible hacer transformaciones elementales por filas y convertirla en una matriz escalonada reducida. Además esta matriz es única, es decir, aunque el número y tipo de transformaciones elementales que hagamos pueda variar de una persona a otra, la matriz escalonada reducida es la misma.

Teorema 4.1 Sea $A \in \mathcal{M}_{m \times n}(\mathbb{R})$.

1. Existen transformaciones elementales (no únicas) sobre filas tales que A se convierte en una matriz escalonada reducida $H_f(A)$, es decir,

$$H_f(A) = F_1 \dots F_p A,$$

donde F_i son matrices elementales (por filas).

2. La matriz $H_f(A)$ es única y se llama forma normal de Hermite de A (por filas).

Describimos el método para hallarla. Mediante transformaciones de la forma F_{ij} , colocamos todas las filas nulas en las últimas filas de la matriz A . En cada una de las transformaciones elementales que se haga a A , llamaremos de nuevo por a_{ij} al elemento (i, j) de la nueva matriz. Tomamos la primera columna j no nula, y sea $a_{ij} \neq 0$ para cierto i . Mediante F_{1i} colocamos la fila i en la primera, obteniendo un número no nulo en el lugar $(1, 1)$. Con la transformación $F_1(1/a_{11})$, dicho elemento se convierte en un 1, y será el primer pivote de la nueva matriz. Ahora hacemos 0 en todos los demás elementos no nulos de la matriz que se encuentran en los lugares $(i, 1)$ para $i = 2$ mediante apropiadas transformaciones del tipo $F_{i1}(-a_{i1}/a_{11})$. Esto nos convierte la matriz A en una en la que los elementos que se encuentran en la misma columna del primer pivote (y debajo de él) son 0.

Pasamos ahora a la segunda fila (si esta fuera nula, la matriz resultante ya es escalonada reducida) y nos olvidamos por ahora de la primera. Se toma la siguiente columna k no nula a la derecha de la columna j (recordemos que j nos indica la columna del pivote de la primera fila de A). Entonces algún elemento a_{ik} , con $i = 2$ es no nulo. Mediante una transformación del tipo F_{2i} colocamos un elemento no nulo en el lugar $(2, k)$. Mediante $F_2(1/a_{2k})$, dicho elemento se convierte en un 1, siendo el pivote de la segunda fila. Posteriormente, mediante transformaciones del tipo $F_{i2}(-a_{ik}/a_{2k})$, $i = 3$, vamos poniendo ceros debajo del elemento $(2, k)$, es decir, para todos los s con $s = 3$.

Este proceso se va repitiendo, hasta acabar todas las columnas. Por construcción, la matriz obtenida es escalonada por filas. Queda por hacer 0 en los elementos por encima de todos los pivotes de A . Para el primero, a_{1j} , no hay nada que hacer. Para el segundo pivote, a saber, a_{2k} , se hacen transformaciones del tipo $F_{12}(-a_{1k})$, obteniendo un 0 en el lugar $(1, k)$. Y así se va haciendo para las siguientes columnas y para los elementos que se encuentran encima de los pivotes.

De la misma forma, se tendría la forma normal de Hermite por columnas de A y que denotamos por $H_c(A)$. Observemos que las matrices $H_f(A)$ y $H_c(A)$ no tiene porque coincidir

Corolario 4.1 Sean $A, B \in \mathcal{M}_{\mathbb{F} \times \mathbb{N}}(\mathbb{R})$. Entonces $A \sim B$ si y solamente si $H_f(A) = H_f(B)$.

En particular, si $A \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$ es regular, entonces sus formas de Hermite por filas y columnas son la matriz identidad: $H_f(A) = H_c(A) = I_m$.

Corolario 4.2 Sea $A \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$ una matriz. Si existe $B \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$ tal que $AB = Im$ (o $BA = Im$), entonces A es regular y $A^{-1} = B$.

Definición 4.4 Sea $A \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$. Entonces existe un unico número natural r , llamado el rango de A , $r(A)$, tal que

$$H_f(H_c(A)) = \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix}$$

A esta matriz se le llama la forma normal de A . Es lo mismo que decir que existen producto de matrices elementales $F_1, \dots, F_P \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$, $C_1, \dots, C_q \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$ tales que

$$F_1, \dots, F_P A C_1, \dots, C_q = \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix}$$

Para hallar el rango de la matriz A no es necesario hacer primero la forma de Hermite por filas y luego la forma de Hermite por columnas, sino ir combinando transformaciones por filas y/o columnas de A hasta obtener la matriz deseada. A continuación demostramos algunas propiedades que tiene el rango de una matriz.

Teorema 4.2 1. $r(A^t) = r(A)$.

2. El rango de A es el numero de filas (resp. columnas) no nulas de una matriz escalonada por filas (resp. por columnas) equivalente o el numero de pivotes de su forma de Hermite por filas (resp. por columnas).

3. $r(A) \leq \min n, m$.

4. El rango no cambia por transformaciones elementales .

5. Si B es una submatriz de A , entonces $r(B) \leq r(A)$.

Por tanto, para calcular el rango de una matriz no es necesario obtener la forma de Hermite, sino obtener su forma normal de Hermite por filas (o por columnas)

Teorema 4.3 Sea $A \in \mathcal{M}_{\mathbb{R}}(\mathbb{R})$. Son equivalentes:

1. A es regular.

2. $r(A) = m$.

3. $A \sim I_m$.

4. $H_f(A) = I_m$.

5. $|A| \neq 0$

En particular, A no es regular si y solamente si $r(A) < m$

El teorema 4.3 nos relaciona, en cierto sentido, el concepto de rango de una matriz con el de determinante. Concretamente, gracias a dicho teorema, y para una matriz cuadrada, sabemos que si el determinante no es cero, el rango es el máximo posible, esto es, m . Sin embargo si el determinante se anula no sabemos el valor exacto del rango. Damos ahora un resultado que nos resuelve completamente este problema.

Previamente damos el concepto de menor de una matriz. Un menor de una matriz $A \in \mathcal{M}_{\uparrow \times \downarrow}(\mathbb{R})$ es el determinante de una submatriz cuadrada suya y diremos que el menor es de orden p si la submatriz es de orden p . El número de menores es grande. Así, hay $m \times n$ menores de orden 1 y $\binom{m}{2} \binom{n}{2}$ menores de orden 2.

Teorema 4.4 *Sea $A \in \mathcal{M}_{\uparrow \times \downarrow}(\mathbb{R})$. Entonces el rango de A es r si y solamente hay un menor de orden r no nulo y todos los menores de orden $r+1$ son 0.*

Observemos que si los menores de orden $r+1$ son cero, también lo son los de orden mayor, sin mayor que ir desarrollando por una fila o una columna, pues el orden del menor se reduce en uno.

Según este resultado, tendríamos que calcular muchos menores para calcular el rango de la matriz. Sin embargo, se puede “reducir el esfuerzo” del siguiente modo.

Corolario 4.3 *Sea $A \in \mathcal{M}_{m \times n}(\mathbb{R})$. Supongamos que existe una submatriz M de orden r con determinante no nulo. Si todas los menores obtenidos al añadir una fila y una columna a M son nulos, entonces el rango de la matriz es r .*

4. Teorema de Rouché-Fröbenius

El teorema de Rouché-Fröbenius, a la vez que proporciona una buena base firme para la discusión de sistemas lineales, conduce a un método alternativo de discusión basado en el cálculo de rango de matrices.

Consideremos el sistema de ecuaciones lineales no homogéneo

$$S = \begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n & = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & = b_2 \\ \vdots & \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & = b_m \end{cases} \Rightarrow Ax = b$$

donde $A \in R^{m \times n}$, $x \in R^{n \times 1}$, $b \in R^{m \times 1}$.

Teorema 4.5 (Teorema de Rouché-Fröbenius) *Sea un sistema lineal con m ecuaciones y n incógnitas. Es compatible si y solo si $\text{rg}(A) = \text{rg}(A|b)$. En ese caso, sea $r = \text{rg}(A) = \text{rg}(A|b)$ el sistema es compatible determinado si $r = n$ y es compatible indeterminado si $r < n$ y se necesitará $n - r$ parámetros para expresar la solución*

CAPÍTULO 5

Ortogonalidad

El concepto de espacio vectorial surgió como una generalización del espacio de los vectores geométricos tomando como punto de partida las propiedades de dichos vectores que provenían de la suma y el producto por un escalar.

Así se definieron: subespacios vectoriales, dependencia e independencia lineal, transformaciones lineales, etc. Para los vectores geométricos hay otros conceptos como los de longitud o norma, ángulo de dos vectores, etc., que no se contemplan al hacer la anterior abstracción y que, por tanto, hasta ahora no tienen significado alguno en un espacio vectorial abstracto.

Se trata ahora de superponer a una estructura de espacio vectorial una nueva estructura que nos permita hablar de ángulos y distancias y conviene tener en cuenta que a partir de este momento el cuerpo base del espacio vectorial, que antes era un cuerpo $\mathbf{K}$ cualquiera, será el cuerpo $\mathbb{R}$ de los números reales o $\mathbb{C}$ de los números complejos.

En el estudio de los vectores geométricos, se definen ángulos y distancias y, a partir de ellos, se introduce el concepto de producto escalar o producto interior de vectores. En el proceso de abstracción se tomarán como axiomas para definir un producto escalar las propiedades que caracterizan al producto escalar de los vectores geométricos y, a partir de él, se introducirán los conceptos métricos de ángulos y distancias.

1. Producto escalar

Definición 5.1 (Producto escalar) *Se denomina producto escalar sobre un espacio vectorial $\mathbf{V}$ a cualquier forma bilineal, simétrica y definida positiva definida sobre $\mathbf{V}$. El producto escalar de dos vectores $\mathbf{x}$ e $\mathbf{y}$ se representa por $\langle \mathbf{x}, \mathbf{y} \rangle$ y, teniendo en cuenta que se trata de una forma bilineal simétrica y*

definida positiva, viene dado por

$$\langle x, y \rangle = x^t A y$$

donde A^1 representa la matriz del producto escalar respecto de una determinada base $\mathbf{B}$ de $\mathbf{V}$.

1.1. Norma de un vector

Definición 5.2 (Norma de un vector) Sea $[\mathbf{V}, \langle, \rangle]$ un espacio vectorial euclídeo. Se denomina norma del vector $x \in \mathbf{V}$ al número real positivo

$$||x|| = +\sqrt{\langle x, x \rangle}$$

que tiene sentido ya que $\langle x, x \rangle \geq 0 \quad \forall x \in \mathbf{V}$.

Proposición 5.1 ■ $\forall x \in \mathbf{V} \quad ||x|| \geq 0$ con $||x|| = 0 \Leftrightarrow 0$.

- $\forall x \in \mathbf{V} \text{ y } \forall \alpha \in \mathbb{R} \text{ entonces } ||\alpha \cdot x|| = |\alpha| \cdot ||x||$
- Ley del Paralelogramo

$$\forall x, y \in \mathbf{V} \Rightarrow ||x + y||^2 + ||x - y||^2 = 2(||x||^2 + ||y||^2)$$

- Desigualdad de Cauchy-Schwartz

$$\forall x, y \in \mathbf{V} \Rightarrow |\langle x, y \rangle| \leq ||x|| \cdot ||y||$$

- Desigualdad de Minkowski

$$\forall x, y \in \mathbf{V} \Rightarrow ||x + y|| \leq ||x|| + ||y||$$

- $\forall x, y \in \mathbf{V} \Rightarrow ||x - y|| \geq ||x|| - ||y||$

Definición 5.3 (Ángulo de dos vectores) Sea $x, y \in \mathbf{V}$ no nulos. De la desigualdad de Cauchy-Schwartz se deduce que

$$-||x|| \cdot ||y|| \leq \langle x, y \rangle \leq ||x|| \cdot ||y||$$

y como $||x|| \neq 0$ y $||y|| \neq 0$ entonces

$$-1 \leq \frac{\langle x, y \rangle}{||x|| \cdot ||y||} \leq 1$$

Al número $\frac{\langle x, y \rangle}{||x|| \cdot ||y||}$ se le define como $\cos \alpha$ diciéndose que α es el ángulo que forman los vectores x e y

$$\langle x, y \rangle = ||x|| \cdot ||y|| \cos \widehat{x, y}$$

¹Durante este curso la matriz A será la matriz I_n

2. Ortogonalidad

Definición 5.4 (Vectores ortogonales) Sea $[\mathbf{V}, \langle \rangle]$ un espacio vectorial euclídeo. Se dice que los vectores $x, y \in \mathbf{V}$, no nulos, son ortogonales respecto del producto escalar $\langle \rangle$ si se verifica que

$$\langle x, y \rangle = 0.$$

Teorema 5.1 (Teorema de Pitágoras) Sea $[\mathbf{V}, \langle \rangle]$ un espacio vectorial euclídeo. Dos vectores $x, y \in \mathbf{V}$ son ortogonales si, y sólo si,

$$\|x + y\|^2 = \|x\|^2 + \|y\|^2$$

CAPÍTULO 6

Autovalores y autovectores

1. Definiciones y propiedades

Definición 6.1 (Autovalores y autovectores) Sea A una matriz cuadrada de orden m . Diremos que un escalar $\lambda \in K (= \mathbb{R} \text{ o } \mathbb{C})$ es un autovalor de A si existe un vector $\mathbf{v} \in \mathbf{V}$, $\mathbf{v} \neq 0$ tal que $A\mathbf{v} = \lambda\mathbf{v}$, en cuyo caso se dice que $\mathbf{v}$ es un autovector de A asociado al autovalor λ .

1.1. Propiedades de los autovalores

Proposición 6.1 Sea λ un autovalor de A y $\mathbf{v}$ un autovector asociado, entonces:

- λ es un autovalor de A si, y sólo si, $\det(\lambda I - A) = 0$.
- $\alpha\lambda$ es un autovalor de αA con autovector $\mathbf{v}$.
- $(\lambda - \mu)$ es un autovalor de $A - \mu I$ con autovector $\mathbf{v}$.
- λ^k es un autovalor de A^k con autovector $\mathbf{v}$.
- Si $q(\cdot)$ es un polinomio, entonces $q(\lambda)$ es un autovalor de $q(A)$ con autovector $\mathbf{v}$. (Ejemplo: $3\lambda^3 + 5\lambda^2 - 7\lambda + 2$ es un autovalor de la matriz $3A^3 + 5A^2 - 7A + 2I$).
- Si A tiene inversa, entonces $\lambda \neq 0$ y λ^{-1} es un autovalor de A^{-1} con autovector $\mathbf{v}$.

Ejemplo 6.1 Dada la matriz

$$A = \begin{pmatrix} 4 & 4 & 2 \\ 0 & 2 & 1 \\ 3 & 2 & 1 \end{pmatrix}$$

$\lambda = 6$ es un autovalor asociado al autovector $x = (1, \frac{1}{6}, \frac{2}{3})$ ya que:

$$\begin{pmatrix} 4 & 4 & 2 \\ 0 & 2 & 1 \\ 3 & 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ \frac{1}{6} \\ \frac{2}{3} \end{pmatrix} = \begin{pmatrix} 6 \\ 1 \\ 4 \end{pmatrix} = 6 \begin{pmatrix} 1 \\ \frac{1}{6} \\ \frac{2}{3} \end{pmatrix} \Leftrightarrow Ax = 6x$$

El vector propio asociado al autovalor propio 6 viene dado por las soluciones del sistema:

$$\begin{aligned} (6I - A)x = 0 &\Leftrightarrow \begin{pmatrix} 2 & -4 & -2 \\ 0 & 4 & 1 \\ -3 & -2 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \\ &\Rightarrow \begin{cases} x_1 = 6\alpha \\ x_2 = \alpha \\ x_3 = 4\alpha \end{cases} \end{aligned}$$

por tanto el vector propio asociado es $(6, 1, 4)$

2. Polinomio característico de una matriz

Definición 6.2 (Polinomio característico) Se denomina polinomio característico de una matriz $A \in \mathbf{M}_{n \times n}$ al polinomio de grado n que se obtiene desarrollando el determinante de la matriz $\lambda I - A$.

$$p(\lambda) = \det(\lambda I - A)$$

La ecuación $p(\lambda) = 0$ se denomina ecuación característica.

Teorema 6.1 Matrices semejantes tienen el mismo polinomio característico.

Corolario 6.1 El polinomio característico de una transformación no depende de la matriz representación que se tome.

Teorema 6.2 Los autovalores de una matriz son las raíces de su polinomio característico.

Una consecuencia inmediata de los resultados anteriores es que tanto los autovalores como los autovectores son valores intrínsecos de la transformación y no dependen de la matriz que la represente, es decir, no dependen de la base que se tome del espacio $\mathbf{V}$.

Definición 6.3 (Multiplicidad aritmética de un autovalor) Se define multiplicidad aritmética de un autovalor λ de una matriz A , como la multiplicidad de λ como raíz del polinomio característico de A .

Teorema 6.3 Si $p(\lambda) = \lambda^n + a_1\lambda^{n-1} + \Delta\Delta\Delta + a_{n-1}\lambda + a_n$ es el polinomio característico de una matriz A , se tiene que:

$$a_i = (-1)^i \sum M_i(A)$$

donde $M_i(A)$ representan a los menores principales de orden i de la matriz A . En particular se verifica que:

- La suma de los autovalores coincide con la traza de la matriz

$$\sum_{i=1}^n \lambda_i = \text{tr}(A)$$

- El producto de los autovalores es igual al determinante de la matriz

$$\prod_{i=1}^n \lambda_i = \det(A)$$

Teorema 6.4 *Los valores propios de una matriz triangular son las entradas sobre su diagonal principal.*

Teorema 6.5 *Si $\mathbf{v}_1, \dots, \mathbf{v}_r$ son vectores propios que corresponden a distintos valores propios $\lambda_1, \dots, \lambda_r$ de una matriz A de $n \times n$, entonces el conjunto $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ es linealmente independiente.*

Ejemplo 6.2 Si

$$A = \begin{pmatrix} 1 & 0 & 2 \\ 2 & -1 & 3 \\ 1 & 2 & 0 \end{pmatrix}$$

su polinomio característico

$$p(\lambda) = \lambda^3 + a_1\lambda^2 + a_2\lambda + a_3$$

verifica que

$$\begin{aligned} a_1 &= (-1)^1(1 - 1 + 0) = 0 \\ a_2 &= (-1)^2 \left(\begin{vmatrix} 1 & 0 \\ 2 & -1 \end{vmatrix} + \begin{vmatrix} 1 & 2 \\ 1 & 0 \end{vmatrix} + \begin{vmatrix} -1 & 3 \\ 2 & 0 \end{vmatrix} \right) \\ &= -1 - 2 - 6 = -9 \\ a_3 &= (-1)^3 \begin{vmatrix} 1 & 0 & 2 \\ 2 & -1 & 3 \\ 1 & 2 & 0 \end{vmatrix} = -4 \end{aligned}$$

El polinomio característico de A es entonces

$$p(\lambda) = \lambda^3 - 9\lambda - 4$$

Ejemplo 6.3 Sea la matriz

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 3 & 3 & 4 \end{pmatrix}$$

vamos a calcular los valores propios y vectores propios

2. POLINOMIO CARACTERÍSTICO DE UNA MATRIZ

Los valores propios son las raíces del polinomio característico, que es

$$\begin{aligned}
 p(\lambda) &= \det(\lambda I - A) \\
 &= \begin{vmatrix} \lambda - 2 & -1 & -1 \\ -2 & \lambda - 3 & -2 \\ -3 & -3 & \lambda - 4 \end{vmatrix} \\
 &= 15\lambda - 9\lambda^2 + \lambda^3 - 7 \\
 &= \lambda^3 - 9\lambda^2 + 15\lambda - 7 \\
 p(\lambda) &= (\lambda - 7)(\lambda - 1)^2
 \end{aligned}$$

por tanto los valores propios son:

$$\lambda_1 = 1 \quad \lambda_2 = 1 \quad \lambda_3 = 7$$

El valor propio 1, tiene multiplicidad 2.

Para calcular el vector propio, correspondiente al valor propio 7, debemos resolver el sistema de ecuaciones:

$$\begin{pmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 3 & 3 & 4 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = 7 \begin{pmatrix} x \\ y \\ z \end{pmatrix}$$

es decir

$$\begin{pmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 3 & 3 & 4 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} - 7 \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Entonces se tiene que:

$$\begin{pmatrix} -5 & 1 & 1 \\ 2 & -4 & 2 \\ 3 & 3 & -3 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Una vez más procedemos a escalar la matriz ampliada del sistema:

$$\begin{aligned}
 &\left(\begin{array}{ccc|c} -5 & 1 & 1 & 0 \\ 2 & -4 & 2 & 0 \\ 3 & 3 & -3 & 0 \end{array} \right) \xrightarrow{F_{21}(\frac{2}{5})} \left(\begin{array}{ccc|c} -5 & 1 & 1 & 0 \\ 0 & -\frac{18}{5} & \frac{12}{5} & 0 \\ 3 & 3 & -3 & 0 \end{array} \right) \\
 &\xrightarrow{F_{31}(\frac{3}{5})} \left(\begin{array}{ccc|c} -5 & 1 & 1 & 0 \\ 0 & -\frac{18}{5} & \frac{12}{5} & 0 \\ 0 & \frac{5}{5} & -\frac{5}{5} & 0 \end{array} \right) \xrightarrow{F_{32}(1)} \left(\begin{array}{ccc|c} -5 & 1 & 1 & 0 \\ 0 & -\frac{18}{5} & \frac{12}{5} & 0 \\ 0 & 0 & 0 & 0 \end{array} \right) \\
 &\xrightarrow{F_2(-\frac{5}{18})} \left(\begin{array}{ccc|c} -5 & 1 & 1 & 0 \\ 0 & 1 & -\frac{2}{3} & 0 \\ 0 & 0 & 0 & 0 \end{array} \right) \xrightarrow{F_{12}(-1)} \left(\begin{array}{ccc|c} -5 & 0 & \frac{5}{3} & 0 \\ 0 & 1 & -\frac{2}{3} & 0 \\ 0 & 0 & 0 & 0 \end{array} \right) \\
 &\xrightarrow{F_1(\frac{-1}{5})} \left(\begin{array}{ccc|c} 1 & 0 & -\frac{1}{3} & 0 \\ 0 & 1 & -\frac{2}{3} & 0 \\ 0 & 0 & 0 & 0 \end{array} \right)
 \end{aligned}$$

por tanto tenemos la soluciones

$$S = \begin{cases} x &= \frac{1}{3}\lambda \\ y &= \frac{2}{3}\lambda \\ z &= \lambda \end{cases}$$

por tanto el vector propio es $(\frac{1}{3}, \frac{2}{3}, 1)$, que al ser un vector podemos modificarlo como $(1, 2, 3)$

Para calcular los vectores propios, correspondientes al valor propio 1, debemos resolver el sistema:

$$\begin{pmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 3 & 3 & 4 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = 1 \begin{pmatrix} x \\ y \\ z \end{pmatrix}$$

es decir

$$\begin{pmatrix} 2 & 1 & 1 \\ 2 & 3 & 2 \\ 3 & 3 & 4 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} - 1 \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Entonces se tiene que:

$$\begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Una vez más procedemos a escalar la matriz ampliada del sistema:

$$\begin{pmatrix} 1 & 1 & 1 & | & 0 \\ 2 & 2 & 2 & | & 0 \\ 3 & 3 & 3 & | & 0 \end{pmatrix} \xrightarrow{F_{21}(-2)} \begin{pmatrix} 1 & 1 & 1 & | & 0 \\ 0 & 0 & 0 & | & 0 \\ 3 & 3 & 3 & | & 0 \end{pmatrix} \\ \xrightarrow{F_{31}(-3)} \begin{pmatrix} 1 & 1 & 1 & | & 0 \\ 0 & 0 & 0 & | & 0 \\ 0 & 0 & 0 & | & 0 \end{pmatrix}$$

por tanto tenemos la soluciones

$$S = \begin{cases} x &= -(\lambda + \mu) \\ y &= \lambda \\ z &= \mu \end{cases}$$

por tanto la solución es $(-\lambda - \mu, \lambda, \mu)$, que se puede expresar como la combinación lineal de dos vectores $(-\lambda, \lambda, 0) + (-\mu, 0, \mu)$ es decir $\lambda(-1, 1, 0) + \mu(-1, 0, 1)$

3. Diagonalización de una matriz

Definición 6.4 (Matriz diagonalizable) Sea $A \in \mathbf{M}_n$ se dice que A es diagonalizable si sólo si A es semejante a una matriz diagonal si y sólo si existe $P \in \mathbf{M}_n$ inversible tal que

$$PAP^{-1} = D$$

donde D es una matriz diagonal.

Es un caso especial de semejanza. Una matriz es diagonalizable cuando es semejante a una matriz diagonal.

3.1. Condiciones que tiene que cumplir una matriz para ser diagonalizable

Corolario 6.2 Sea $A \in \mathbf{M}_n$ es diagonalizable si y sólo si A tiene n autovectores linealmente independientes.

Sean $(v_1, v_2, \dots, v_n)$ autovectores linealmente independientes de la matriz $A \in \mathbf{M}_n$

Podemos construir una matriz P cuyas columnas sean dichos autovectores:

$$P = (v_1, v_2, \dots, v_n)$$

P es inversible porque sus columnas son linealmente independientes y por lo tanto tiene rango n $\det(P) \neq 0$

Puede demostrarse que:

$$PAP^{-1} = D$$

donde D es una matriz diagonal cuyos elementos son los respectivos autovalores:

$$D = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix}$$

Ejemplo 6.4 Si continuamos el ejemplo 6.3 la matriz D sería

$$D = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 7 \end{pmatrix}$$

y la matriz P sería:

$$P = \begin{pmatrix} -1 & -1 & 1 \\ 1 & 0 & 2 \\ 0 & 1 & 3 \end{pmatrix}$$

Los vectores propios en la matriz P se deben colocar en la misma posición que su correspondiente valor propio y viceversa.

3.2. Aplicaciones de la diagonalización

Corolario 6.3 (Potencias de matrices) Si A es una matriz diagonalizable, existe otra matriz no singular P tal que $P^{-1}AP = D \Rightarrow A = PDP^{-1}$. Entonces:

$$\begin{aligned} A^m &= (PDP^{-1})^m = PDP^{-1} \underbrace{\dots}_m PDP^{-1} \\ &= PD^m P^{-1} \\ \Rightarrow A^m &= PD^m P^{-1} \end{aligned}$$

Corolario 6.4 (Inversa de una matriz)

$$A^{-1} = (PDP^{-1})^{-1} = PD^{-1}P^{-1}$$

Si

$$\begin{aligned} D &= \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix} \\ \Rightarrow \\ D^{-1} &= \begin{pmatrix} \frac{1}{\lambda_1} & 0 & \dots & 0 \\ 0 & \frac{1}{\lambda_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{\lambda_n} \end{pmatrix} \\ \Rightarrow \\ A^{-1} &= P \begin{pmatrix} \frac{1}{\lambda_1} & 0 & \dots & 0 \\ 0 & \frac{1}{\lambda_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{\lambda_n} \end{pmatrix} P^{-1} \end{aligned}$$

Los valores y vectores propios tienen la clave para la evolución discreta de un sistema dinámico, como ocurrió en 1990 con el búho manchado norteno ya que se convirtió en el centro de una controversia nacional sobre el uso y el mal uso de los majestuosos bosques en el Pacífico Noroccidental de Estados Unidos. Los ambientalistas convencieron al gobierno federal de que el búho estaría en riesgo de extinción si continuaba la tala en los antiguos bosques (con árboles de más de 200 años de edad), donde el búho prefiere vivir. La industria maderera, anticipando la pérdida de 30,000 a 100,000 puestos de trabajo como resultado de las nuevas restricciones gubernamentales sobre la tala, argumentó que el búho no debería estar clasificado como “especie amenazada” y citó diferentes reportes científicos publicados para apoyar su caso¹.

En medio del fuego cruzado entre los grupos antagónicos, los ecologistas matemáticos intensificaron su afán de comprender la dinámica poblacional del búho. El ciclo de vida de un búho manchado se divide naturalmente en tres etapas: juvenil (hasta un año de edad), subadulto (de 1 a 2 años) y adulto (más de 2 años). Los búhos se aparean de por vida en las etapas de subadulto y adulto, y empiezan a criar cuando son adultos. Viven alrededor de 20 años y cada pareja requiere aproximadamente 1000 hectáreas (4 millas cuadradas) como su propio territorio. Un tiempo fundamental en el ciclo de vida es cuando los búhos juveniles dejan el nido. Para sobrevivir y convertirse en un subadulto, un búho juvenil debe tener éxito para encontrar un nuevo territorio para vivir (y en general, una pareja).

Un primer paso en el estudio de la dinámica poblacional consiste en modelar la población a intervalos anuales, en tiempos que se denotan con $k = 0, 1, 2, \dots$

¹ “The Great Spotted Owl War”, Reader’s Digest, noviembre de 1992, pp. 91-95

En general, se supone que hay una relación 1:1 de machos a hembras en cada etapa del ciclo de vida y se cuentan solamente las hembras. La población en cada año k se describe con un vector:

$$\mathbf{x}_k = (j_k, s_k, a_k)$$

donde j_k, s_k, a_k son los números de hembras en las etapas juvenil, subadulto y adulto, respectivamente.

Utilizando datos reales de estudios demográficos, R. Lamberson y sus colaboradores considerando el siguiente *modelo matricial por etapas*

$$\begin{pmatrix} j_{k+1} \\ s_{k+1} \\ a_{k+1} \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0.33 \\ 0.18 & 0 & 0 \\ 0 & 0.71 & 0.97 \end{pmatrix} \begin{pmatrix} j_k \\ s_k \\ a_k \end{pmatrix}$$

Aquí, el número de nuevas hembras juveniles en el año $k+1$ es 0.33 veces el número de hembras adultas en el año k (según la tasa promedio de nacimientos por pareja de búhos). Asimismo, 18 % de los búhos juveniles sobreviven para convertirse en subadultos en tanto que 71 % de los subadultos y 94 % de los adultos sobreviven para contarse como adultos.

El modelo matricial por etapas es una ecuación en diferencias de la forma

$$\mathbf{x}_{k+1} = A\mathbf{x}_k$$

A esta ecuación con frecuencia se le llama **sistema dinámico** (o **sistema dinámico lineal discreto**) ya que describe los cambios en un sistema conforme transcurre el tiempo.

Ejemplo 6.5 Sea

$$A = \begin{pmatrix} 0.95 & 0.03 \\ 0.05 & 0.97 \end{pmatrix}$$

Analice el comportamiento de sistema dinámico definido por $\mathbf{x}_{k+1} = A\mathbf{x}_k$ con ($k = 0, 1, 2, \dots$) con

$$\mathbf{x}_0 = \begin{pmatrix} 0.6 \\ 0.4 \end{pmatrix}$$

El primer paso consiste en determinar los valores y vectores propios de A . La ecuación característica de A es:

$$\begin{aligned} 0 &= \det \begin{pmatrix} 0.95 - \lambda & 0.03 \\ 0.05 & 0.97 - \lambda \end{pmatrix} \\ &= (0.95 - \lambda)(0.97 - \lambda) - (0.03)(0.05) \\ &= \lambda^2 - 1.92\lambda + 0.92 \end{aligned}$$

por tanto

$$\begin{aligned} \lambda &= \frac{1.92 \pm \sqrt{1.92^2 - 4 \times 0.92}}{2} \\ &= \frac{1.92 \pm \sqrt{0.0064}}{2} \\ &= \frac{1.92 \pm 0.08}{2} \end{aligned}$$

las soluciones son $\lambda_1 = 0.92$ y $\lambda_2 = 1$ Ahora calcularemos los vectores propios.

Para $\lambda_1 = 0.92$ se tiene que:

$$\begin{pmatrix} 0.95 - 0.92 & 0.03 \\ 0.05 & 0.97 - 0.92 \end{pmatrix} = \begin{pmatrix} 0.03 & 0.03 \\ 0.05 & 0.05 \end{pmatrix}$$

por lo que el vector propio asociado es $\mathbf{v}_1^t = (1, -1)$

Para $\lambda_2 = 1$ se tiene que:

$$\begin{pmatrix} 0.95 - 1 & 0.03 \\ 0.05 & 0.97 - 1 \end{pmatrix} = \begin{pmatrix} -0.05 & 0.03 \\ 0.05 & -0.03 \end{pmatrix}$$

por lo que el vector propio asociado es $\mathbf{v}_2^t = (3, 5)$

El siguiente paso es escribir $\mathbf{x}_0$ en términos de $\mathbf{v}_1$ $\mathbf{v}_2$

$$\begin{aligned} \mathbf{x}_0 &= c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 \\ &= [\mathbf{v}_1, \mathbf{v}_2] \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} \end{aligned}$$

de hecho

$$\begin{aligned} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} &= [\mathbf{v}_1, \mathbf{v}_2]^{-1} \mathbf{x}_0 \\ &= \begin{pmatrix} 1 & 3 \\ -1 & 5 \end{pmatrix}^{-1} \begin{pmatrix} 0.6 \\ 0.4 \end{pmatrix} \\ &= \frac{1}{8} \begin{pmatrix} 5 & -3 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0.6 \\ 0.4 \end{pmatrix} = \begin{pmatrix} 0.225 \\ 0.125 \end{pmatrix} \end{aligned}$$

Cada $\mathbf{x}_k$ es fácil de calcular, ya que $\mathbf{v}_1$ y $\mathbf{v}_2$ son vectores propios de A , por tanto:
 $A\mathbf{v}_1 = 0.92\mathbf{v}_1$ y $A\mathbf{v}_2 = \mathbf{v}_2$

$$\begin{aligned} \mathbf{x}_1 &= A\mathbf{x}_0 \\ &= c_1 A\mathbf{v}_1 + c_2 A\mathbf{v}_2 \\ &= c_1 0.92\mathbf{v}_1 + c_2 \mathbf{v}_2 \\ \mathbf{x}_2 &= A\mathbf{x}_1 \\ &= A(c_1 A\mathbf{v}_1 + c_2 A\mathbf{v}_2) \\ &= c_1 A^2\mathbf{v}_1 + c_2 A^2\mathbf{v}_2 \\ &= c_1 (0.92)^2 \mathbf{v}_1 + c_2 \mathbf{v}_2 \end{aligned}$$

Y así sucesivamente. En general

$$\begin{aligned} \mathbf{x}_k &= A\mathbf{x}_{k-1} \\ &= c_1 (0.92)^k \mathbf{v}_1 + c_2 \mathbf{v}_2 \end{aligned}$$

Por tanto se tiene que

$$\mathbf{x}_k = .225(0.92)^k (1, -1)^t + 0.125(3, 5)$$

Esta fórmula explícita para $\mathbf{x}_k$ da la solución de la ecuación en diferencias $\mathbf{x}_{k+1} = A\mathbf{x}_k$.

Conforme $k \rightarrow \infty$ $(0.92)^k$ tiende a cero y $\mathbf{x}_k$ tiende a

$$\begin{pmatrix} 0.375 \\ 0.625 \end{pmatrix} = 0.125\mathbf{v}_2$$

4. Diagonalización de matrices simétricas

Supongamos que tenemos una matriz cuadrada real A de orden n que es simétrica (recordemos que esto significa que $A = A^t$). Vamos a considerar el espacio vectorial euclídeo $\mathbb{R}^n$ en el que se considera el producto escalar euclídeo. Entonces:

- A es siempre diagonalizable sobre $\mathbb{R}$, en particular sus valores propios son todos reales (no hay valores propios imaginarios).
- Vectores propios de la matriz asociados a distintos valores propios son ortogonales.
- Puede encontrarse una base ortogonal (e incluso ortonormal) de $\mathbb{R}^n$ formada por vectores propios de la matriz

Ejemplo 6.6 Si es posible, diagonalice la matriz

$$A = \begin{pmatrix} 6 & -2 & -1 \\ -2 & 6 & -1 \\ -1 & -1 & 5 \end{pmatrix}$$

La ecuación característica de A es:

$$0 = -(\lambda - 8)(\lambda - 6)(\lambda - 3)$$

por tanto, obtenemos los siguientes valores propios:

$$\begin{aligned} \lambda_1 = 3 & \rightarrow \mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \\ \lambda_2 = 6 & \rightarrow \mathbf{v}_2 = \begin{pmatrix} -1 \\ -1 \\ 2 \end{pmatrix} \\ \lambda_3 = 8 & \rightarrow \mathbf{v}_3 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} \end{aligned}$$

por tanto nuestra matriz

$$P = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 2 & 0 \end{pmatrix}$$

CAPÍTULO 7

Formas cuadráticas

En este capítulo estudiaremos el concepto de formas cuadráticas y sus varios tipos. Veremos cómo podemos identificar el tipo de una forma cuadrática dada conociendo únicamente los valores propios de su representación matricial. Esto se conoce como Teorema de Clasificación. En algunos casos, no hace falta calcular explícitamente tales valores propios para poder clasificar la forma cuadrática, sino que basta con conocer si estos son positivos, negativos o nulos. La cantidad de valores propios positivos y negativos, por otro lado, podemos determinarla mediante un resultado conocido como la Regla de Descartes.

1. Definición de forma cuadrática

A lo largo de este capítulo, trabajaremos únicamente con el espacio vectorial real de n -uplas $\mathbb{R}^n$. Nuestro objetivo principal es estudiar un tipo particular de funciones de $\mathbb{R}^n$ en $\mathbb{R}$, definidas a continuación.

Definición 7.1 Una forma cuadrática sobre $\mathbb{R}^n$ es una función $Q : \mathbb{R}^n \rightarrow \mathbb{R}$ de la forma

$$Q(x_1, \dots, x_n) = \sum_{i,j=1}^n c_{ij} x_i x_j \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n$$

donde $c_{ij} \in \mathbb{R}$ para todo $1 \leq i, j \leq n$

El ejemplo más sencillo de una forma cuadrática diferente a cero es $Q(x) = \mathbf{x}^t I \mathbf{x} = \|\mathbf{x}\|^2$

En otras palabras, una forma cuadrática sobre $\mathbb{R}^n$ es un polinomio homogéneo de grado 2, de n variables, y con coeficientes reales. Recuerde que los polinomios homogéneos son aquéllos cuyos términos tienen todos el mismo grado.

Ejemplo 7.1

1. La función $Q(x, y) = x^2 + y^2$ es una forma cuadrática sobre $\mathbb{R}^2$
2. La función $Q(x, y, z) = 3x^2 + 5y^2 - z^2 + 2xy + \sqrt{2}xz$ es una forma cuadrática sobre $\mathbb{R}^3$
3. La función $f(x, y, z, t) = y^2 - 3t^2 + 8z$ no es una forma cuadrática sobre $\mathbb{R}^4$. Nótese que el término $8z$ tiene grado 1, mientras que los términos restantes y^2 y $-3t^2$ tienen grado 2.

En el estudio de formas cuadráticas muchas veces resulta más útil representarlas mediante una matriz simétrica. Los valores propios de esta matriz arrojan de información sobre la forma cuadrática, muy útil al momento de clasificarla o de querer representarla mediante un polinomio más sencillo a través de un cambio de variables

Parte II

Cálculo

CAPÍTULO 8

Funciones

El concepto de función es la piedra angular de las Matemáticas. Sirve para modelar experiencias tanto de Física, como de Biología, como del resto de las Ciencias. Sin embargo su génesis ha sido lenta. En el famoso trabajo sobre la difusión del calor de Jean Baptiste Joseph Fourier (1768-1830) comenzado en 1807 y publicado en 1822, indicaba que las funciones que podían representarse como una suma infinita de funciones trigonométricas es amplia. Por entonces las tres grandes L (Lagrange, Laplace y Legendre) criticaron la memoria de Fourier por sus lagunas y vaguedad de razonamiento, y quizás esta sea la causa para que comenzara en Matemáticas la época del rigor. El trabajo de Fourier desempeñó un papel catalizador en la nueva fundamentación, pues suscitó cuestiones como las condiciones exactas de representabilidad de funciones mediante series trigonométricas. El primer resultado riguroso en esta línea fue obtenido por Dirichlet, en 1829, un año antes de la muerte de Fourier

1. Funciones reales de variable real

Una función f , de una variable real x , es una regla que asigna un único número real y a cada número x de su dominio.

Puede indicarse así:

$$f : \mathbb{R} \rightarrow \mathbb{R}; x \rightarrow y = f(x)$$

Por tanto, una función puede definirse como un conjunto de pares (x, y) de manera que no hay pares con el mismo primer elemento. Así, por ejemplo, los pares $(2, 1)$ y $(2, 3)$ no pueden pertenecer a la misma función, pues eso indicaría que al número 2 le corresponden dos números, el 1 y el 3, en contra de que la correspondencia debe ser única.

- A x se la llama variable independiente. Cuando se representa se hace en el eje horizontal, el eje de abscisas, el eje OX.
- La y es la variable dependiente. Se representa en el eje vertical o de ordenadas, el eje OY.

Ambas variables son números reales. Las funciones reales suelen darse mediante una fórmula o expresión algebraica. Por ejemplo:

$$\begin{aligned} f(x) &= x^2 - 3x \\ g(x) &= +\sqrt{3-x} \end{aligned}$$

también puede escribirse como

$$\begin{aligned} y &= x^2 - 3x \\ y &= +\sqrt{3-x} \end{aligned}$$

1.1. Dominio de una función

Definición 8.1 (Dominio de una función) *El conjunto A sobre el que la función está definida recibe el nombre de dominio de f . Cuando no se especifique el dominio de una función se entenderá que éste es el subconjunto más grande de $\mathbb{R}$ en el que la expresión analítica que define a la función tiene sentido. Lo denotamos $Dom(f)$.*

$$Dom(f) = \{x \in \mathbb{R}; f(x) \in \mathbb{R}\}$$

En otras palabras, se trata de determinar qué valores podemos dar a la variable independiente, x , de modo que podamos calcular la función f . Por ello, debemos recordar (una vez más) qué funciones presentan alguna limitación a la hora de ser calculadas en el cuerpo de los números reales, pues esas serán las que debemos estudiar con detalle:

- Suma, resta y producto: pueden evaluarse para cualquier número real.
- División: no se puede dividir entre cero.
- Raíces:
 - De orden impar: pueden evaluarse en cualquier número real.
 - De orden par: el radicando debe ser mayor o igual que cero.
- Potencias:
 - De exponente natural: pueden evaluarse siendo la base cualquier número real.
 - De exponente negativo: pueden evaluarse si la base es un real positivo.
- Logaritmos: el argumento debe ser rigurosamente mayor que cero.
- Otras veces será la naturaleza del problema lo que restrinja su dominio; por ejemplo, un tiempo o una longitud no pueden tomar valores negativos.

Funciones polinómicas

El dominio de estas funciones es el conjunto de los números reales.

$$f(x) = P(x) \rightarrow Dom(f) = \mathbb{R}$$

Ejemplo 8.1 Para la función

$$\begin{aligned}f(x) &= x^3 - x^2 + 5 \\ \text{Dom}(f) &= \mathbb{R}\end{aligned}$$

Funciones racionales

Son de la forma $f(x) = \frac{P(x)}{Q(x)}$ Su dominio es el conjunto de los reales excepto los ceros o raíces del denominador.

$$\begin{aligned}f(x) &= \frac{P(x)}{Q(x)} \\ \text{Dom}(f) &= x \in \mathbb{R}\end{aligned}$$

Ejemplo 8.2 Si $f(x) = \frac{x-3}{x^2-4}$ es fácil ver que para $x = -2$ y $+2$ el denominador se anula, por tanto:

$$\begin{aligned}\text{Dom}(f) &= (-\infty, -2) \cup (-2, 2) \cup (2, \infty) \\ &= \mathbb{R} - \{-2, 2\}\end{aligned}$$

Ejemplo 8.3 Si $f(x) = \frac{1}{\tan x}$, $\text{Dom}(f) = \mathbb{R} - x = k \times \pi$, pues

$$\frac{1}{\tan x} = \frac{\cos x}{\sin x}$$

$\sin x = 0$ cuando $x = k \times \pi$, con $k \in \mathbb{Z}$

Funciones irracionales

Son de la forma $f(x) = \sqrt[n]{g(x)}$. Hay dos casos posibles:

- Si n es impar el dominio de la función coincidirá con el dominio del radicando: $\text{Dom}(f) = \text{Dom}(g)$.
- Si n es par el dominio de la función estará formado por todos los valores de x que hagan que el radicando sea mayor o igual que cero: $\text{Dom } f = \{x \in \mathbb{R}; g(x) \geq 0\}$.

Ejemplo 8.4 Si $f(x) = \sqrt{x+5}$, en este caso $\text{Dom } f = \{x \in \mathbb{R}; x+5 \geq 0\}$, por lo que habrá que resolver la inecuación $x+5 \geq 0$, cuya solución es $x \geq -5$. Es decir, $\text{Dom } f = [-5, +\infty)$.

Ejemplo 8.5 Si se trata de una función $f(x) = \sqrt[3]{\frac{x-3}{x^2-4}}$, en este caso el dominio de la función coincide con el dominio del radicando, y éste está visto en el ejemplo anterior 26.1:

$$\begin{aligned}\text{Dom}(f) &= (-\infty, -2) \cup (-2, 2) \cup (2, +\infty) \\ &= \mathbb{R} - \{-2, 2\}\end{aligned}$$

Funciones exponenciales

Son funciones de la forma $f(x) = a^{g(x)}$, siendo a un número positivo. El dominio de estas funciones coincide con el dominio de la función que aparece en el exponente:

$$\text{Dom}(f) = \text{Dom}(g).$$

Ejemplo 8.6 Sea

$$f(x) = \frac{x+2}{2x-3}$$

El dominio de $f(x)$ coincidirá con el dominio del exponente que, como se trata de una función racional, será todos los números reales excepto los que anulan el denominador. Por tanto:

$$\begin{aligned}\text{Dom}(f) &= \text{Dom}(f) = (-\infty, 3) \cup (3, +\infty) \\ &= \mathbb{R} - \{3\}\end{aligned}$$

Funciones logarítmicas

Son de la forma $f(x) = \log_a g(x)$, siendo a positivo y distinto de 1. Como los logaritmos sólo tienen sentido para los números positivos se tiene:

$$\text{Dom} f = \{x \in \mathbb{R}; g(x) > 0\}.$$

Ejemplo 8.7 Si $f(x) = \log(x+1)$, el dominio de la función serán todos los valores de x que hagan que el argumento sea positivo:

$$x+1 > 0 \Rightarrow x > -1$$

por tanto

$$\text{Dom}(f) = \{x \in \mathbb{R}; x+1 > 0\} = (-1, +\infty)$$

1.2. Conjunto imagen o recorrido

Definición 8.2 (Conjunto imagen o recorrido) Se llama imagen o recorrido de f al conjunto, que representaremos por $f(A)$ o por $\text{Im}(f)$, cuyos elementos son las imágenes de los puntos de A mediante f , es decir:

$$f(A) = \text{Im}(f) = \{y \in \mathbb{R} : \text{exist } x \in A \text{ con } f(x) = y\}$$

Una manera práctica de decidir si un punto y está o no en $\text{Im}(f)$ consiste en intentar resolver la ecuación $f(x) = y$, siendo x la incógnita de la ecuación. Si somos capaces de despejar la x en función de y con $x \in A$, entonces $y \in \text{Im}(f)$; de lo contrario $y \notin \text{Im}(f)$.

Ejemplo 8.8 Si $f(x) = x^2 + 2x - 3$ sabemos que es una parábola con forma de "U", que el vértice es un mínimo y se encuentra en:

$$x = \frac{-b}{2a} \Rightarrow x = \frac{-2}{2 \times 1} = -1$$

y

$$f(-1) = (-1)^2 + 2(-1) - 3 = -4$$

por tanto:

$$\begin{aligned} \text{Dom}(f) &= (-\infty, +\infty) = \mathbb{R} \\ \text{Im}(f) &= [-4, +\infty) \end{aligned}$$

Ejemplo 8.9 Para la función $f : \mathbb{R} \rightarrow \mathbb{R}$ dada por $f(x) = x^2$ su dominio es $\mathbb{R}$. Su expresión analítica es la fórmula $y = x^2$, que nos indica como calcular la imagen de cualquier elemento x . El recorrido de esta función estará formada por aquellos $y \in \mathbb{R}$ tales que la ecuación $x^2 = y$ tiene solución en la incógnita x . Ahora, si queremos despejar la x en la ecuación $x^2 = y$, necesitamos hacer la raíz cuadrada de y , para lo que se precisa que $y \geq 0$. En tal caso, al despejar tendríamos $x = \pm\sqrt{y}$. Concluimos que $\text{Im}(f) = [0, +\infty)$. Por otro lado, es bien sabido que la gráfica de f es una parábola cuyo vértice es el punto $(0,0)$.

Ejemplo 8.10 Para la función $f : (0,1) \rightarrow \mathbb{R}$ dada por $f(x) = \frac{1}{x}$ su dominio está especificado y es el intervalo abierto y acotado $(0,1)$. Su expresión analítica es la fórmula $y = \frac{1}{x}$, que nos indica como calcular la imagen de cualquier elemento x . Por otro lado, como no se puede dividir por cero, el conjunto más grande donde la función está bien definida es $\text{Dom}(f) = \mathbb{R} - \{0\} = \mathbb{R}^*$. La gráfica de f es el trozo de la hipérbola $xy = 1$ cuando $x \in (0,1)$.

1.3. Funciones acotadas

Definición 8.3 (Funciones acotadas superiormente) Se dice que una función $f : A \rightarrow \mathbb{R}$ está acotada superiormente si su gráfica se queda siempre por debajo de una recta horizontal, es decir, existe $K \in \mathbb{R}$ tal que $f(x) \leq K$ para cada $x \in A$.

Definición 8.4 (Funciones acotadas inferiormente) Se dice que $f : A \rightarrow \mathbb{R}$ está acotada inferiormente si su gráfica se queda siempre por encima de una recta horizontal, es decir, existe $M \in \mathbb{R}$ tal que $f(x) \geq M$ para cada $x \in A$.

Definición 8.5 (Funciones acotadas) Se dice que $f : A \rightarrow \mathbb{R}$ está acotada si lo está superior e inferiormente.

Geométricamente, ésto significa que la gráfica de f está contenida dentro de una banda horizontal del plano, equivalentemente, el recorrido de la función está contenido en un intervalo cerrado y acotado de $\mathbb{R}$.

Ejemplo 8.11 La función $f : \mathbb{R} \rightarrow \mathbb{R}$ dada por $f(x) = x^3$ no está acotada ni superior ni inferiormente, ya que su recorrido es todo $\mathbb{R}$.

La función $g(x) = x^2 + 1$ está acotada inferiormente por 1 pero no está acotada superiormente ya que toma valores arbitrariamente grandes.

La función $g(x) = \frac{1}{x^2 + 1}$ está acotada superiormente por 1 ya que el denominador está acotado inferiormente por 1. Además, está también acotada inferiormente ya que toma siempre valores positivos.




Figura 8.1: Función no acotada




Figura 8.2: Función acotada inferiormente




Figura 8.3: Función acotada

1.4. Funciones crecientes y decrecientes

Definición 8.6 (Función creciente) Se dice que una función f es creciente si para cualesquiera $x < y$ se cumple que $f(x) \leq f(y)$. Geométricamente, esto significa que la gráfica de la función siempre sube o se mantiene constante. Se dice que f es estrictamente creciente si para cualesquiera $x < y$ se cumple $f(x) < f(y)$ (siempre sube)

Definición 8.7 (Función decreciente) Se dice que una función f es decreciente si para cualesquiera $x < y$ se cumple que $f(x) \geq f(y)$. Geométricamente, esto significa que la gráfica de la función siempre baja o se mantiene constante. Se dice que f es estrictamente decreciente si para cualesquiera $x < y$ se cumple $f(x) > f(y)$ (siempre baja)

Ejemplo 8.12 La función $f : \mathbb{R} \rightarrow \mathbb{R}$ dada por $f(x) = x$ es una función creciente: su gráfica es la recta que pasa por $(0,0)$ y $(1,1)$ como se puede ver en figura 8.4.




Figura 8.4: Función creciente

La función $f(x) = -x$ es decreciente: su gráfica es la recta que pasa por $(0,0)$ y $(1,-1)$ como se puede ver en figura 8.5.

La función $f : \mathbb{R} \rightarrow \mathbb{R}$ dada por $g(x) = x^2$ no es creciente ni decreciente como se puede ver en figura 8.6.




Figura 8.5: Función decreciente




Figura 8.6: Función no creciente ni decreciente

2. Límites de Funciones

2.1. Entorno de un número real

Sea x_0 un número real y δ un número real positivo, $\delta > 0$. Se llama entorno de x_0 de radio δ al intervalo abierto $(x_0 - \delta, x_0 + \delta)$. Se denota también por $E(x_0, \delta)$ y está formado por todos los números cuya distancia a x_0 es menor que δ .

$$x \in (x_0 - \delta, x_0 + \delta) \quad \text{Equivale a} \quad |x - x_0| < \delta$$

El radio de un entorno debe ser siempre un número positivo; se denota con letras griegas (sobre todo ϵ o δ).

Una forma muy conveniente de referirse a números muy cercanos a x_0 es fijar entornos de x_0 de radios cada vez menores.

2.2. Idea intuitiva de límite

Sea f una función definida alrededor de un punto x_0 (no es necesario que x_0 , pero sí alrededor de x_0). Sea $L \in \mathbb{R} \cup \pm\infty$ (esto significa que L puede representar a $+\infty$ o a $-\infty$, que no son números). Diremos que f tiene límite L cuando x tiende a x_0 si cada vez que le damos a la variable independiente x valores muy

cercanos a x_0 entonces los valores de la función $f(x)$ están muy cercanos del valor L . En tal caso escribimos:

$$\lim_{x \rightarrow x_0} f(x) = L$$

Diremos que f tiene límite L cuando x tiende a $+\infty$ (resp. $-\infty$) si cada vez que le damos a la variable independiente x valores muy grandes (resp. muy pequeños) entonces los valores de la función $f(x)$ están muy cercanos del valor L . En tal caso escribimos:

$$\begin{aligned} \lim_{x \rightarrow +\infty} f(x) &= L \\ \text{respectivamente} \\ \lim_{x \rightarrow -\infty} f(x) &= L \end{aligned}$$

2.3. Límite de una función en un punto

Sea f una función definida alrededor de un punto x_0 (no es necesario que x_0 pertenezca al dominio de la función, es decir, podría no existir $f(x_0)$).

El límite de $f(x)$ en el punto x_0 es un número real L tal que, elegido cualquier entorno $(L - \epsilon, L + \epsilon)$ de L , existe un entorno de x_0 , $(x_0 - \delta, x_0 + \delta)$ verificándose que para todo número $x \in (x_0 - \delta, x_0 + \delta)$, $x \neq x_0$ se cumple que $f(x) \in (L - \epsilon, L + \epsilon)$.

Significa que los valores que toma la función $f(x)$ se acercan al número L tanto como se desee, siempre que se elijan los valores de la variable independiente x en un entorno adecuado de x_0 .

De esta definición se desprende una importante característica del concepto de límite: el que una función tenga límite en un punto, y su valor, sólo depende de cómo esté definida la función en un entorno del punto, excluyendo dicho punto, y no en el resto del dominio.

2.4. Límites Laterales

Hay ocasiones en las que una función tiene distintas expresiones a la izquierda y a la derecha de un punto x_0 (funciones definidas a trozos). Para estudiar estas situaciones se definen los límites laterales, que permiten estudiar el comportamiento de la función a ambos lados de x_0 .

Definición 8.8 (Límite por la izquierda) Sea f una función definida a la izquierda de x_0 . Decimos que el límite lateral por la izquierda de f en x_0 es L , y lo representamos:

$$\lim_{x \rightarrow x_0^-} f(x) = L$$

Definición 8.9 (Límite por la derecha) Sea f una función definida a la derecha de x_0 . Decimos que el límite lateral por la derecha de f en x_0 es L , y lo representamos:

$$\lim_{x \rightarrow x_0^+} f(x) = L$$

La idea de los límites laterales consiste en estudiar hacia dónde tiende una función cuando nos acercamos a un punto por ambos lados del mismo. El siguiente resultado relaciona la existencia y el valor del límite de una función en un punto con la existencia y el valor de los límites laterales de la función en dicho punto.

Teorema 8.1 *Sea f una función definida alrededor de un punto x_0 y $L \in \mathbb{R} \cup \{\pm\infty\}$. Entonces se tiene:*

$$\lim_{x \rightarrow x_0} f(x) = L \Leftrightarrow \lim_{x \rightarrow x_0^-} f(x) = L \Leftrightarrow \lim_{x \rightarrow x_0^+} f(x) = L$$

(el límite existe si y sólo si existen los dos límites laterales y son iguales).

los límites laterales en un punto x_0 hay que calcularlos cuando la función tiene distinta expresión analítica a la izquierda y a la derecha de x_0 (funciones a trozos). Cuando la función sólo está definida a un lado de x_0 hay que estudiar el límite lateral por ese lado y nada más.

2.5. Límites en el infinito

Hasta ahora hemos estudiado el comportamiento de una función en las cercanías de un punto $x_0 \rightarrow \mathbb{R}$. Ahora estudiaremos el comportamiento que puede presentar una función cuando la variable x toma valores arbitrariamente grandes ($x \rightarrow +\infty$) o pequeños ($x \rightarrow -\infty$).

El límite de $f(x)$ cuando $x \rightarrow +\infty$ es L si, elegido cualquier entorno de L , $(L - \epsilon, L + \epsilon)$ existe un número M tal que $f(x) \in (L - \epsilon, L + \epsilon)$ para todos los valores $x > M$. Se escribe

$$\lim_{x \rightarrow +\infty} f(x) = L$$

Significa que los valores que toma la función $f(x)$ se acercan al número L tanto como se desee. Siempre que se consideren valores de x mayores que un número adecuado, es decir, lo suficientemente grandes.

Análogamente se dice que

El límite de $f(x)$ cuando $x \rightarrow -\infty$ es L si, elegido cualquier entorno de L , $(L - \epsilon, L + \epsilon)$ existe un número M tal que $f(x) \in (L - \epsilon, L + \epsilon)$ para todos los valores $x < M$. Se escribe

$$\lim_{x \rightarrow -\infty} f(x) = L$$

Significa que los valores que toma la función $f(x)$ se acercan al número L tanto como se desee. Siempre que se consideren valores de x menores que un número adecuado, es decir, lo suficientemente grandes en valor absoluto y negativos.

3. Funciones Continuas

Intuitivamente las funciones continuas son aquellas cuyas gráficas no presentan saltos ni interrupciones. El concepto riguroso de función continua en un punto es el siguiente.

Definición 8.10 Se dice que una función f es continua en un punto $x_0 \rightarrow \mathbb{R}$ si se cumplen tres condiciones:

1. Existe $f(x_0)$, es decir, $x_0 \in \text{Dom}(f)$
2. Existe $\lim_{x \rightarrow x_0} f(x)$ y es finito
3. $\lim_{x \rightarrow x_0} f(x) = f(x_0)$

Observación 8.1 A diferencia del concepto de límite, la definición de continuidad exige que la función tiene que estar definida en el punto

Observación 8.2 La propiedad 3 nos indica que los límites de funciones continuas se calculan evaluando directamente la función en el punto

Definición 8.11 Se dice que una función f es discontinua en $x_0 \in \mathbb{R}$ si no es continua en x_0 . Esto significa que f no cumple alguna de las 3 condiciones en la definición de continuidad. Según sea la propiedad que no se cumple clasificamos las discontinuidades en:

- discontinuidad esencial cuando no se cumple 2
- discontinuidad evitable cuando se cumple 2 pero falla 1 o 3

Observación 8.3 Un caso particular de discontinuidad esencial ocurre cuando los límites laterales de f en x_0 existen, son finitos, pero son distintos. En este caso hablamos de discontinuidad de salto finito.

Observación 8.4 El nombre de discontinuidad evitable se debe a que podemos “reparar la discontinuidad”. Concretamente, si f presenta una discontinuidad evitable en x_0 , entonces la función f^* , definida por $f^*(x) = f(x)$ si $x \neq x_0$ y por

$$f^*(x_0) = \lim_{x \rightarrow x_0} f(x)$$

es una función continua en x_0 . En una discontinuidad esencial no es posible la construcción de f^* al no existir $\lim_{x \rightarrow x_0} f(x)$.

Definición 8.12 Sea I un intervalo de $\mathbb{R}$. Se dice que una función f es continua en I si f es continua en cada punto $x_0 \in I$

Teorema 8.2 (Conservación del signo) Si $f : I \rightarrow \mathbb{R}$ es una función continua sobre un intervalo abierto I , y x_0 es un punto de I en el que $f(x_0) \neq 0$, entonces existe un entorno abierto $B(x_0, r)$ en el que el signo de $f(x)$ es el mismo signo que el de $f(x_0)$.

Teorema 8.3 (Teorema de los valores intermedios) Sea f una función continua en un intervalo $[a, b]$ de forma que $f(a) \neq f(b)$. Entonces f toma todos los valores comprendidos entre $f(a)$ y $f(b)$, es decir, para cada y en el intervalo determinado por $f(a)$ y $f(b)$, existe $x \in [a, b]$ tal que $f(x) = y$.

Una de las aplicaciones más conocidas del resultado anterior es la siguiente:

Teorema 8.4 (Teorema de Bolzano) *Sea f una función continua sobre un intervalo cerrado y acotado $[a, b]$. Si se cumple que $f(a) \times f(b) < 0$ (es decir, el signo de $f(a)$ es distinto al signo de $f(b)$), entonces existe un valor $c \in (a, b)$ tal que $f(c) = 0$.*

La interpretación geométrica del Teorema de Bolzano es la siguiente: una gráfica continua en el plano que pasa del semiplano superior al inferior (o al revés) tiene que cortar en algún punto al eje x . El Teorema de Bolzano se puede aplicar para asegurar la existencia de solución de ciertas ecuaciones difíciles de resolver por métodos directos.

CAPÍTULO 9

Sucesiones

Representamos por $\mathbb{N}$ al conjunto de los números naturales. Una sucesión de números reales es una manera de hacer corresponder a cada número natural $n \in \mathbb{N}$ un único número real, que representamos por x_n , y que llamamos término n -ésimo de la sucesión. Por ejemplo, la sucesión $\{\frac{1}{n}\}$ viene dada por la familia de números $\{1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots\}$. El término 5-ésimo de esta sucesión es $\frac{1}{5}$.

Definición 9.1 *Una sucesión de números reales es una aplicación del conjunto de los números naturales al conjunto de los números reales*

$$\mathbb{N} \rightarrow \mathbb{R}$$

$$n \mapsto x_n$$

donde el término general lo denotaremos como

$$x_n$$

Y a la sucesión como

$$\{x_n\}$$

Diremos que una sucesión $\{x_n\}$ tiende a un número real L si podemos hacer que todos los términos n -ésimos de la sucesión se aproximen tanto como queramos al número L sin más que tomar n suficientemente grande. Esto lo representamos por $\{x_n\} \rightarrow L$ o por $\lim_{n \rightarrow +\infty} x_n = L$

Ejemplo 9.1 *Fibonacci*

$$\begin{cases} x_{n+2} = x_{n+1} + x_n \\ x_1 = 0 \\ x_2 = 1 \end{cases}$$

Diremos que una sucesión es convergente si $\exists x \in \mathbb{R}$ verificando $\varepsilon > 0$ existe $n_0 \in \mathbb{N}$

$$|x_n - x| < \varepsilon \quad \forall n \geq n_0$$

También se puede escribir como

$$\begin{array}{rcl} \lim_{n \rightarrow +\infty} x_n & = & x \\ & \text{o} & \\ \{x_n\} & \rightarrow & x \end{array}$$

1. Sucesión y acotación

Definición 9.2 Una sucesión $\{a_n\}$ es acotada si $\{a_1, a_2, \dots\}$ es un conjunto acotado.

Es decir, si existe $K \in \mathbb{R}$ tal que $|a_n| \leq K \quad \forall n \in \mathbb{N}$

Definición 9.3 La sucesión $\{a_n\}_{n \in \mathbb{N}}$ está acotada superiormente si $\exists M \in \mathbb{N}$ tal que $a_n \leq M \quad \forall n$

Ejemplo 9.2 Sea $a_n = \frac{1}{n}$. Entonces la sucesión $\{a_n\}$ es acotada superiormente por $M=1$

Definición 9.4 La sucesión $\{a_n\}_{n \in \mathbb{N}}$ está acotada inferiormente si $\exists m \in \mathbb{N}$ tal que $a_n \geq m \quad \forall n$

Ejemplo 9.3 Sea $a_n = n$. Entonces la sucesión $\{a_n\}$ es acotada inferiormente por $m=1$

Proposición 9.1 La sucesión $\{a_n\}_{n \in \mathbb{N}}$ es acotada si y sólo si $\{a_n\}$ es acotada superiormente y $\{a_n\}$ es acotada inferiormente

2. Sucesiones convergentes

En lo que sigue $\{a_n\}$ denotará una sucesión de números reales.

Definición 9.5 $\lim_{n \rightarrow \infty} a_n = L$ si para todo $\varepsilon > 0$ existe $N \in \mathbb{N}$ tal que si $n \geq N$ entonces $|a_n - L| < \varepsilon$

En este caso se dice que la sucesión $\{a_n\}$ converge a $L \in \mathbb{R}$, o límite de $\{a_n\}$ es L

Se dice que una sucesión $\{a_n\}$ es convergente si existe $L \in \mathbb{R}$ tal que $\{a_n\}$ converge a L ; se dice que es divergente (o que diverge) si no es convergente

Ejemplo 9.4 Sea $\{a_n\} = \frac{1}{n}$ entonces $\lim_{n \rightarrow \infty} a_n = 0$

Ejemplo 9.5 Sea $\{a_n\} = n!$ entonces $\{a_n\}$ es divergente

Proposición 9.2 *Toda sucesión convergente es acotada*

Teorema 9.1 *Unicidad del límite Una sucesión convergente tiene uno y sólo un límite*

Proposición 9.3 *Si $\{a_n\}$ es una sucesión que converge a cero y $\{b_n\}$ es una sucesión acotada entonces la sucesión $\{a_nb_n\}$ converge a cero*

2.1. Sucesiones Monótonas

Definición 9.6 *Una sucesión $\{a_n\}$ es monótona creciente si $a_n \leq a_{n+1}$ para todo $n \in \mathbb{N}$*

Ejemplo 9.6 *Sea $\{a_n\} = n$. Entonces la sucesión $\{a_n\}$ es monótona creciente.*

Definición 9.7 *Una sucesión $\{a_n\}$ es monótona decreciente si $a_{n+1} \leq a_n$ para todo $n \in \mathbb{N}$*

Ejemplo 9.7 *Sea $\{a_n\} = \frac{1}{n}$. Entonces la sucesión $\{a_n\}$ es monótona decreciente.*

Teorema 9.2

- *Toda sucesión monótona creciente y acotada superiormente es convergente*
- *Toda sucesión monótona decreciente y acotada inferiormente es convergente*

2.2. Operaciones con sucesiones

$$\lim(a_n \pm b_n) = \lim a_n \pm \lim b_n$$

$$\lim(a_n \cdot b_n) = \lim a_n \cdot \lim b_n$$

$$\lim \frac{a_n}{b_n} = \frac{\lim a_n}{\lim b_n}$$

Ejemplo 9.8

$$\lim_{n \rightarrow \infty} \frac{\ln(3n^4 - 2n + 7)}{\ln(2n^2 + 2n - 1)}$$

$$\begin{aligned}
\lim_{n \rightarrow \infty} \frac{\ln \left(n^4 \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right) \right)}{\ln \left(n^2 \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right) \right)} &= \lim_{n \rightarrow \infty} \frac{\ln(n^4) + \ln \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} \\
&= \lim_{n \rightarrow \infty} \frac{\ln(n^4)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} \\
&\quad + \frac{\ln \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} \\
&= \lim_{n \rightarrow \infty} \frac{\ln(n^4)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} \\
&\quad + \lim_{n \rightarrow \infty} \frac{\ln \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)}
\end{aligned}$$

Estudiaremos los límites por separado ya que

$$\lim(x_n \pm y_n) = \lim x_n \pm \lim y_n$$

$$\begin{aligned}
\lim_{n \rightarrow \infty} \frac{\ln(n^4)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} &= \lim_{n \rightarrow \infty} \frac{4 \ln(n)}{2 \ln(n) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} \\
&= \frac{4 \ln(+\infty)}{2 \ln(+\infty) + \ln \left(3 - \frac{2}{+\infty} + \frac{1}{+\infty} \right)} = \frac{+\infty}{+\infty}
\end{aligned}$$

estamos en una indeterminación del tipo $\frac{\infty}{\infty}$ pero si nos fijamos en los grados del numerador y denominador es el mismo. Por tanto tenemos que ver los coeficientes.

$$\lim_{n \rightarrow \infty} \frac{4 \ln(n)}{2 \ln(n) + \ln \left(3 - \frac{2}{n} + \frac{1}{n} \right)} \rightarrow \frac{4}{2} = 2$$

$$\begin{aligned}
\lim_{n \rightarrow \infty} \frac{\ln \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right)}{\ln(n^2) + \ln \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right)} &= \lim_{n \rightarrow \infty} \frac{\ln \left(3 - \frac{2}{n^3} + \frac{7}{n^4} \right)}{2 \ln(n) + \ln \left(2 + \frac{2}{n} - \frac{1}{n^2} \right)} \\
&= \frac{\ln \left(3 - \frac{2}{\infty} + \frac{7}{\infty} \right)}{2 \ln(\infty) + \ln \left(2 + \frac{2}{\infty} - \frac{1}{\infty} \right)} \\
&= \frac{\ln(3)}{2 \ln(\infty) + \ln(2)} \rightarrow 0
\end{aligned}$$

Por tanto

$$\lim_{n \rightarrow \infty} \frac{\ln \left(n^4 \left(3 - \frac{2n}{n^4} + \frac{7}{n^4} \right) \right)}{\ln \left(n^2 \left(2 + \frac{2n}{n^2} - \frac{1}{n^2} \right) \right)} \rightarrow 2$$

2.3. Convergencia y orden

Si $\{a_n\}$ e $\{b_n\}$ son dos sucesiones de números reales convergentes. Supongamos que

$$\{\forall n \in \mathbb{N} : a_n \leq b_n\} \Rightarrow \lim_{n \rightarrow \infty} a_n \leq \lim_{n \rightarrow \infty} b_n$$

Lema 9.1 *Lema del Sandwich o Bocadillo Sean $\{a_n\}$, $\{b_n\}$ y $\{c_n\}$ dos sucesiones de números reales que verifica*

- $\lim a_n = \lim c_n$
- $a_n \leq b_n \leq c_n \quad \forall n$

Entonces $\{b_n\}$ es convergente y $\lim a_n = \lim b_n = \lim c_n$

Ejemplo 9.9

$$\lim_{n \rightarrow \infty} \frac{1}{n^2 \sqrt{n}} + \frac{2}{n^2 \sqrt{n}} + \cdots + \frac{n}{n^2 \sqrt{n}}$$

Como sabemos que

$$\frac{1}{n^2 \sqrt{n}} \leq \frac{m}{n^2 \sqrt{n}} \leq \frac{n}{n^2 \sqrt{n}} \quad \forall m \in [1, n]$$

entonces creamos la sucesión

$$\begin{aligned} \{x_n\} &= \frac{1}{n^2 \sqrt{n}} + \cdots + \frac{1}{n^2 \sqrt{n}} \\ &= \sum_{i=1}^n \frac{1}{n^2 \sqrt{n}} \\ &= n \frac{1}{n^2 \sqrt{n}} \\ &= \frac{1}{n \sqrt{n}} \end{aligned}$$

$$\begin{aligned} \{z_n\} &= \frac{n}{n^2 \sqrt{n}} + \cdots + \frac{n}{n^2 \sqrt{n}} \\ &= \sum_{i=1}^n \frac{n}{n^2 \sqrt{n}} \\ &= n \frac{n}{n^2 \sqrt{n}} = \frac{1}{\sqrt{n}} \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \{x_n\} &\rightarrow 0 \\ \lim_{n \rightarrow \infty} \{z_n\} &\rightarrow 0 \end{aligned}$$

como $\{y_n\} = \sum_{i=1}^n \frac{i}{n^2 \sqrt{n}}$ y se verifica el Lema del Bocadillo la sucesión

$$\lim_{n \rightarrow \infty} \frac{1}{n^2 \sqrt{n}} + \frac{2}{n^2 \sqrt{n}} + \cdots + \frac{n}{n^2 \sqrt{n}} \rightarrow 0$$

3. Criterio de convergencia

3.1. Criterio de Stolz

Proposición 9.4 Sea $\{a_n\}$ e $\{b_n\}$ son dos sucesiones de números reales y se verifica una de las dos condiciones

- $\{b_n\}$ es creciente y diverge positivamente
- $\lim a_n = \lim b_n = 0$ e $\{b_n\}$ es monótona

Entonces si

$$\lim_{n \rightarrow \infty} \frac{x_{n+1} - x_n}{y_{n+1} - y_n} \rightarrow L$$

con $L \in \mathbb{R}$ ¹

$$\Rightarrow \lim_{n \rightarrow \infty} \frac{x_n}{y_n} \rightarrow L$$

Ejemplo 9.10

$$\lim_{n \rightarrow \infty} \frac{1^2 + 2^2 + \dots + n^2}{n^3}$$

Denotamos por

$$\begin{aligned}\{a_n\} &= 1^2 + 2^2 + \dots + n^2 \\ \{b_n\} &= n^3\end{aligned}$$

veamos si se verifica alguna de las dos condiciones del criterio de Stolz

$\{b_n\}$ es creciente y diverge positivamente ✓

Entonces podemos usar el criterio de Stolz

$$\{x_{n+1}\} = 1^2 + 2^2 + \dots + n^2 + (n+1)^2$$

$$\{x_n\} = 1^2 + 2^2 + \dots + n^2$$

$$\{x_{n+1}\} - \{x_n\} = 1^2 + 2^2 + \dots + n^2 + (n+1)^2 - (1^2 + 2^2 + \dots + n^2) = (n+1)^2$$

$$\{y_{n+1}\} = (n+1)^3$$

$$\{y_n\} = n^3$$

$$\{y_{n+1}\} - \{y_n\} = (n+1)^3 - n^3 = n^3 + 3n^2 + 3n + 1 - n^3 = 3n^2 + 3n + 1$$

$$\lim_{n \rightarrow \infty} \frac{\{x_{n+1}\} - \{x_n\}}{\{y_{n+1}\} - \{y_n\}} = \lim_{n \rightarrow \infty} \frac{(n+1)^2}{3n^2 + 3n + 1} = \lim_{n \rightarrow \infty} \frac{n^2 + 2n + 1}{3n^2 + 3n + 1} \rightarrow \frac{1}{3}$$

Por tanto

$$\lim_{n \rightarrow \infty} \frac{1^2 + 2^2 + \dots + n^2}{n^3} \rightarrow \frac{1}{3}$$

¹A veces por comodidad se utiliza

$$\lim_{n \rightarrow \infty} \frac{x_n - x_{n-1}}{y_n - y_{n-1}}$$

3.2. Criterio de la raíz

Sea $\{a_n\}$ una sucesión de términos positivos y la razón

$$\frac{a_{n+1}}{a_n}$$

es convergente o divergente, se verifica que

$$\lim_{n \rightarrow \infty} \sqrt[n]{a_n} = \lim_{n \rightarrow \infty} \frac{a_{n+1}}{a_n}$$

Ejemplo 9.11

$$\lim_{n \rightarrow \infty} \sqrt[n]{n}$$

Denotamos por $\{a_n\} = n$

$$\lim_{n \rightarrow \infty} \frac{a_{n+1}}{a_n} = \lim_{n \rightarrow \infty} \frac{n+1}{n} \rightarrow 1$$

Entonces

$$\lim_{n \rightarrow \infty} \sqrt[n]{n} \rightarrow 1$$

3.3. Criterio del número e

Proposición 9.5 Criterio del número e

Sea $\{a_n\}$ una sucesión de números reales convergente a 1 y $\{b_n\}$ una sucesión cualquiera

- $\lim_{n \rightarrow \infty} b_n(a_n - 1) \rightarrow L \Leftrightarrow \lim_{n \rightarrow \infty} a_n^{b_n} = e^L$
- $\lim_{n \rightarrow \infty} b_n(a_n - 1) \rightarrow +\infty \Leftrightarrow \lim_{n \rightarrow \infty} a_n^{b_n} = e^{+\infty} = +\infty$
- $\lim_{n \rightarrow \infty} b_n(a_n - 1) \rightarrow -\infty \Leftrightarrow \lim_{n \rightarrow \infty} a_n^{b_n} = e^{-\infty} = 0$

Ejemplo 9.12

$$\{z_n\} = \left(\frac{n^2 - n + 3}{n^2 + 2n - 2} \right)^{n+3}$$

Tenemos que comprobar si $\{a_n\} = \frac{n^2 - n + 3}{n^2 + 2n - 2}$ converge a 1

$$\lim_{n \rightarrow \infty} \frac{n^2 - n + 3}{n^2 + 2n - 2} = \frac{\infty}{\infty}$$

Al tener mismo grado, vemos los coeficientes. Por tanto

$$\lim_{n \rightarrow \infty} \frac{n^2 - n + 3}{n^2 + 2n - 2} \rightarrow 1$$

Se verificar el criterio del número e

$$\lim_{n \rightarrow \infty} \left(\frac{n^2 - n + 3}{n^2 + 2n - 2} \right)^{n+3} \Rightarrow \lim_{n \rightarrow \infty} (n+3) \left(\frac{n^2 - n + 3}{n^2 + 2n - 2} - 1 \right)$$

$$\begin{aligned}
 \lim_{n \rightarrow \infty} (n+3) \left(\frac{n^2 - n + 3}{n^2 + 2n - 2} - 1 \right) &= \lim_{n \rightarrow \infty} (n+3) \left(\frac{n^2 - n + 3 - (n^2 + 2n - 2)}{n^2 + 2n - 2} \right) = \\
 &= \lim_{n \rightarrow \infty} (n+3) \left(\frac{-3n + 5}{n^2 + 2n - 2} \right) = \lim_{n \rightarrow \infty} \frac{(n+3)(-3n + 5)}{n^2 + 2n - 2} = \\
 &= \lim_{n \rightarrow \infty} \frac{-3n^2 - 4n + 15}{n^2 + 2n - 2} \rightarrow -3
 \end{aligned}$$

por tanto $L = -3$ Por el criterio del número e

$$\{z_n\} \rightarrow e^{-3}$$

4. Ejercicios resueltos

Ejercicio 9.1 *Calcular el siguiente límite*

$$\lim_{n \rightarrow \infty} \frac{\ln(n) \sin(n)}{n}$$

Solución

Podemos expresar

$$\lim_{n \rightarrow \infty} \frac{\ln(n) \sin(n)}{n} = \lim_{n \rightarrow \infty} \frac{\ln(n)}{n} \sin(n)$$

Por la proposición 3

$$\lim_{n \rightarrow \infty} \frac{\ln(n)}{n} \rightarrow 0$$

La función $\sin(n)$ es acotada entonces

$$\lim_{n \rightarrow \infty} \frac{\ln(n) \sin(n)}{n} \rightarrow 0$$

Ejercicio 9.2 *Calcular el siguiente límite*

$$\lim_{n \rightarrow \infty} \frac{e^n + 2^n}{5^n}$$

Solución

Podemos expresar

$$\lim_{n \rightarrow \infty} \frac{e^n}{5^n} + \frac{2^n}{5^n} = \lim_{n \rightarrow \infty} \left(\frac{e}{5}\right)^n + \left(\frac{2}{5}\right)^n$$

como se verifica que $\frac{e}{5} < 1$, $\frac{2}{5} < 1$ y como un número menor a 1 elevado a infinito tiende a cero

$$\lim_{n \rightarrow \infty} \frac{e^n + 2^n}{5^n} \rightarrow 0$$

Ejercicio 9.3 *Calcular el siguiente límite*

$$\lim_{n \rightarrow \infty} \frac{e^n - 2^n}{n}$$

Solución

Podemos expresar

$$\lim_{n \rightarrow \infty} \frac{e^n}{n} \left(1 - \frac{2^n}{e^n}\right) = \lim_{n \rightarrow \infty} \frac{e^n}{n} \left(1 - \left(\frac{2}{e}\right)^n\right)$$

como se verifica que $\frac{2}{e} < 1$ y como un número menor a 1 elevado a infinito tiende a cero y

$$\lim_{n \rightarrow \infty} \frac{e^n}{n} \rightarrow \infty$$

entonces

$$\lim_{n \rightarrow \infty} \frac{e^n}{n} \left(1 - \left(\frac{2}{e}\right)^n\right) = \infty * 1 = \infty$$

Ejercicio 9.4 Estudiar el límite de la siguiente sucesión

$$\lim_{n \rightarrow \infty} \left(\frac{4n^3 + 2n - 1}{4n^3 + n^2 - 2n + 1} \right)^n$$

Solución

Utilizamos el criterio del número e

$$\begin{aligned} \lim_{n \rightarrow \infty} n \left(\frac{4n^3 + 2n - 1}{4n^3 + n^2 - 2n + 1} - 1 \right) &= \lim_{n \rightarrow \infty} n \left(\frac{-n^2 + 4n - 2}{4n^3 + n^2 - 2n + 1} \right) = \\ &= \lim_{n \rightarrow \infty} \left(\frac{-n^3 + 4n^2 - 2n}{4n^3 + n^2 - 2n + 1} \right) \rightarrow \frac{-1}{4} \end{aligned}$$

Por tanto

$$\lim_{n \rightarrow \infty} \left(\frac{4n^3 + 2n - 1}{4n^3 + n^2 - 2n + 1} \right)^n \rightarrow e^{\frac{-1}{4}}$$

Ejercicio 9.5 Estudiar el límite de la siguiente sucesión

$$\lim_{n \rightarrow \infty} \left(\frac{\sin(1) + \cdots + \sin(n)}{n^2} \right)$$

Solución

Para calcular el límite aplicaremos el criterio de Stolz, con $a_n = \sin(1) + \cdots + \sin(n)$ y $b_n = n^2$ ya que b_n es creciente

$$\begin{aligned} a_{n+1} &= \sin(1) + \cdots + \sin(n+1) \\ a_n &= \sin(1) + \cdots + \sin(n) \\ b_{n+1} &= (n+1)^2 \\ b_n &= n^2 \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{a_{n+1} - a_n}{b_{n+1} - b_n} &= \lim_{n \rightarrow \infty} \frac{(\sin(1) + \cdots + \sin(n+1)) - (\sin(1) + \cdots + \sin(n))}{(n+1)^2 - n^2} = \lim_{n \rightarrow \infty} \frac{\sin(n+1)}{2n+1} = \\ &= \lim_{n \rightarrow \infty} \sin(n+1) \lim_{n \rightarrow \infty} \frac{1}{2n+1} \end{aligned}$$

Por tanto por la proposición 3

$$\lim_{n \rightarrow \infty} \left(\frac{\sin(1) + \cdots + \sin(n)}{n^2} \right) \rightarrow 0$$

Ejercicio 9.6 Estudiar el límite de la siguiente sucesión

$$\lim_{n \rightarrow \infty} \left(\frac{\ln(1+1) + \ln(1+\frac{1}{2}) + \cdots + \ln(1+\frac{1}{n})}{n^2} \right)$$

Solución

Para calcular el límite aplicaremos el criterio de Stolz, con $a_n = \sin(1) + \dots + \sin(n)$ y $b_n = n^2$ ya que b_n es creciente y diverge positivamente

$$a_{n+1} = \ln(1+1) + \ln(1+\frac{1}{2}) \cdots + \ln(1+\frac{1}{n+1})$$

$$a_n = \ln(1+1) + \ln(1+\frac{1}{2}) \cdots + \ln(1+\frac{1}{n})$$

$$b_{n+1} = (n+1)^2$$

$$b_n = n^2$$

$$\lim_{n \rightarrow \infty} \frac{a_{n+1} - a_n}{b_{n+1} - b_n} = \lim_{n \rightarrow \infty} \frac{\ln(1+\frac{1}{n})}{2n+1} =$$

2

Por tanto

$$\lim_{n \rightarrow \infty} \frac{1}{(n+1)(n+2)} \rightarrow 0$$

Ejercicio 9.7 Estudiar el límite de la siguiente sucesión según los valores de a

$$\lim_{n \rightarrow \infty} \left(\frac{\ln(1+a) + \ln(1+a^2) \cdots + \ln(1+a^n)}{n} \right)$$

con $a > 0$

Solución

Para calcular el límite aplicaremos el criterio de Stolz, con $a_n = \ln(1+a) + \ln(1+a^2) \cdots + \ln(1+a^n)$ y $b_n = n$ ya que b_n es creciente y diverge positivamente

$$a_{n+1} = \ln(1+a) + \ln(1+a^2) \cdots + \ln(1+a^n)$$

$$a_n = \ln(1+a) + \ln(1+a^2) \cdots + \ln(1+a^{n+1})$$

$$b_{n+1} = n+1$$

$$b_n = n$$

$$\lim_{n \rightarrow \infty} \frac{a_{n+1} - a_n}{b_{n+1} - b_n} = \lim_{n \rightarrow \infty} \frac{\ln(1+a^{n+1})}{(n+1) - n} = \lim_{n \rightarrow \infty} \ln(1+a^{n+1}) = \begin{cases} 0 & \text{si } a \in (0, 1) \\ \ln(2) & \text{si } a = 1 \\ \infty & \text{si } a > 1 \end{cases}$$

Ejercicio 9.8 Estudiar el límite de la siguiente sucesión según los valores de a

$$\lim_{n \rightarrow \infty} \frac{1 + \frac{1}{a} + \cdots + \frac{1}{a^n}}{\ln(n)}$$

con $a > 0$

²Por los infinitésimos equivalentes sabemos que $\ln(1+a_n) \approx a_n$, para $a_n \rightarrow 0$

Solución

Para calcular el límite aplicaremos el criterio de Stolz, con $a_n = 1 + \frac{1}{a} + \dots + \frac{1}{a^n}$ y $b_n = \ln(n)$ ya que b_n es creciente y diverge positivamente

$$a_{n+1} = 1 + \frac{1}{a} + \dots + \frac{1}{a^{n+1}}$$

$$a_n = 1 + \frac{1}{a} + \dots + \frac{1}{a^n}$$

$$b_{n+1} = \ln(n+1)$$

$$b_n = \ln(n)$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{a_{n+1} - a_n}{b_{n+1} - b_n} &= \lim_{n \rightarrow \infty} \frac{\frac{1}{a^{n+1}}}{\ln(n+1) - \ln(n)} \\ &= \lim_{n \rightarrow \infty} \frac{1}{a^{n+1} \ln\left(\frac{n+1}{n}\right)} \\ &= \lim_{n \rightarrow \infty} \frac{1}{a^{n+1} \ln\left(1 + \frac{1}{n}\right)} \\ &= \lim_{n \rightarrow \infty} \frac{n}{a^{n+1}} \frac{1}{\ln\left(1 + \frac{1}{n}\right)} \\ &= \lim_{n \rightarrow \infty} \frac{n}{a^{n+1}} \frac{1}{n \ln\left(1 + \frac{1}{n}\right)} \\ &= \lim_{n \rightarrow \infty} \frac{n}{a^{n+1}} \frac{\frac{1}{n}}{\ln\left(1 + \frac{1}{n}\right)} \end{aligned}$$

Aplicando el ejercicio anterior solo tenemos que estudiar

$$\lim_{n \rightarrow \infty} \frac{n}{a^{n+1}} = \begin{cases} +\infty, & \text{si } a \leq 1 \\ 0, & \text{si } a > 1 \end{cases}$$

Ejercicio 9.9 Estudiar el límite de la siguiente sucesión

$$\lim_{n \rightarrow \infty} \frac{(\ln n)^2}{n}$$

Solución Sea

$$A = \lim_{n \rightarrow \infty} \frac{(\ln n)^2}{n}$$

Haciendo

$$\sqrt{A} = \lim_{n \rightarrow \infty} \frac{\ln n}{\sqrt{n}}$$

Solo tengo que estudiar la sucesión

$$\lim_{n \rightarrow \infty} \frac{\ln n}{\sqrt{n}}$$

Aplicando el criterio de Stolz tenemos

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{\ln n - \ln(n-1)}{\sqrt{n} - \sqrt{n-1}} &= \lim_{n \rightarrow \infty} \frac{\ln \left(1 + \frac{1}{n-1} \right)}{\sqrt{n} - \sqrt{n-1}} \\ &= \lim_{n \rightarrow \infty} \frac{\frac{1}{n-1}}{\sqrt{n} - \sqrt{n-1}} \\ &= \lim_{n \rightarrow \infty} \frac{1}{(n-1)(\sqrt{n} - \sqrt{n-1})} \\ &= \lim_{n \rightarrow \infty} \frac{\sqrt{n} + \sqrt{n-1}}{(n-1)(n - (n-1))} \\ &= \lim_{n \rightarrow \infty} \frac{\sqrt{n} + \sqrt{n-1}}{(n-1)} \\ &= \lim_{n \rightarrow \infty} \frac{\sqrt{n}}{(n-1)} + \frac{\sqrt{n-1}}{(n-1)} \end{aligned}$$

Como

$$\left\{ \begin{array}{l} \lim_{n \rightarrow \infty} \frac{\sqrt{n}}{(n-1)} = 0 \\ \lim_{n \rightarrow \infty} \frac{\sqrt{n-1}}{(n-1)} = 0 \end{array} \right.$$

entonces $\sqrt{A} = 0$ por tanto $A = 0$ entonces

$$\lim_{n \rightarrow \infty} \frac{(\ln n)^2}{n} = 0$$

Ejercicio 9.10 Estudiar el límite de la siguiente sucesión

$$\frac{\sqrt{1^3} + \sqrt{2^3} + \dots + \sqrt{n^3}}{n^\alpha}$$

en función de $\alpha > 0$

Solución

Aplicamos el criterio de Stolz ya que para $\alpha > 0$ n^α es creciente y divergente positivamente.

Donde

$$a_n = \sqrt{1^3} + \sqrt{2^3} + \dots + \sqrt{n^3}$$

$$a_{n-1} = \sqrt{1^3} + \sqrt{2^3} + \dots + \sqrt{(n-1)^3}$$

$$b_n = n^\alpha$$

$$b_{n-1} = (n-1)^\alpha$$

$$\begin{aligned} \frac{a_n - a_{n-1}}{b_n - b_{n-1}} &= \frac{\left(\sqrt{1^3} + \sqrt{2^3} + \dots + \sqrt{n^3}\right) - \left(\sqrt{1^3} + \sqrt{2^3} + \dots + \sqrt{(n-1)^3}\right)}{n^\alpha - (n-1)^\alpha} \\ &= \frac{\sqrt{n^3}}{n^\alpha - (n-1)^\alpha} \\ &= \frac{\sqrt{n^3}}{n^\alpha - (n^\alpha - \alpha n^{(\alpha-1)} + \dots + 1)} \\ &= \frac{\sqrt{n^3}}{\alpha n^{(\alpha-1)} + \dots + (-1)} \end{aligned}$$

Se ha utilizado el binomio de Newton $(a+b)^n = \sum_{i=1}^n \binom{n}{i} a^i b^{n-i}$ tenemos que estudiar

$$\lim_{n \rightarrow \infty} \frac{\sqrt{n^3}}{\alpha n^{(\alpha-1)} + \dots + (-1)}$$

Lo podemos escribir como

$$\lim_{n \rightarrow \infty} \frac{1}{n^{-\frac{3}{2}} (\alpha n^{(\alpha-1)} + \dots + (-1))} = \lim_{n \rightarrow \infty} \frac{1}{\alpha n^{(\alpha-1-\frac{3}{2})} + \dots + \left(-n^{-\frac{3}{2}}\right)}$$

Pero nos interesa saber que pasa con el término que tiene mayor grado

entonces tenemos que discutir si

- $\alpha - \frac{5}{2} < 0$
- $\alpha - \frac{5}{2} > 0$
- $\alpha - \frac{5}{2} = 0$

Si $\alpha < \frac{5}{2} \rightarrow \infty$ diverge

Si $\alpha > \frac{5}{2} \rightarrow 0$ converge

Si $\alpha = \frac{5}{2}$ entonces el límite es $\frac{1}{\alpha}$, es decir, $\frac{2}{5}$

Ejercicio 9.11 Calcular el siguiente límite, donde se supone que a, b y c son constantes positivas

$$\lim_{n \rightarrow \infty} \ln \left(\frac{\sqrt[3]{((n+a)(n+b)(n+c))^n}}{n^n} \right)$$

Solución

Puesto que

$$\begin{aligned}\lim_{n \rightarrow \infty} \ln \left(\frac{\sqrt[3]{((n+a)(n+b)(n+c))^n}}{n^n} \right) &= \lim_{n \rightarrow \infty} \frac{n}{3} \ln((n+a)(n+b)(n+c)) - \ln(n^n) \\&= \lim_{n \rightarrow \infty} \frac{n}{3} \ln((n+a)(n+b)(n+c)) - n \ln(n) \\&= \lim_{n \rightarrow \infty} \frac{n}{3} \ln((n+a)(n+b)(n+c)) - \frac{n}{3} \ln(n^3) \\&= \lim_{n \rightarrow \infty} \frac{n}{3} \ln \left(\frac{(n+a)(n+b)(n+c)}{n^3} \right) \\&= \lim_{n \rightarrow \infty} \frac{n}{3} \ln \left(\frac{(n+a)}{n} \frac{(n+b)}{n} \frac{(n+c)}{n} \right) \\&= \lim_{n \rightarrow \infty} \frac{n}{3} \left(\ln \left(\frac{n+a}{n} \right) + \ln \left(\frac{n+b}{n} \right) + \ln \left(\frac{n+c}{n} \right) \right) \\&= \lim_{n \rightarrow \infty} \frac{1}{3} \left(n \left(\ln \left(1 + \frac{a}{n} \right) + \ln \left(1 + \frac{b}{n} \right) + \ln \left(1 + \frac{c}{n} \right) \right) \right)\end{aligned}$$

Vamos a estudiar por partes. Vamos a calcular

$$\lim_{n \rightarrow \infty} n \left(\ln \left(1 + \frac{a}{n} \right) \right)$$

Ya que para b y c es lo mismo

$$\lim_{n \rightarrow \infty} n \left(\ln \left(1 + \frac{a}{n} \right) \right) = \lim_{n \rightarrow \infty} n \frac{a}{n} \left(\frac{\ln \left(1 + \frac{a}{n} \right)}{\frac{a}{n}} \right) = a$$

en consecuencia el límite buscado es:

$$\frac{a+b+c}{3}$$

5. Ejercicios propuestos

Ejercicio 9.12 *Halle, si convergen, el límite de las siguientes sucesiones*

$$\blacksquare \lim_{n \rightarrow \infty} \frac{3 + 6 + \cdots + 3n}{n^2}$$

$$\blacksquare \lim_{n \rightarrow \infty} \frac{4^{n+1} + 7^{n+1}}{4^n + 7^n}$$

$$\blacksquare \lim_{n \rightarrow \infty} \frac{n(\sqrt{n} + 2n + 1)}{n^2 + 3}$$

$$\blacksquare \lim_{n \rightarrow \infty} \frac{\sin\left(\frac{\pi n}{2}\right)}{\ln n}$$

$$\blacksquare \lim_{n \rightarrow \infty} \frac{1^2 + 2^2 + \cdots + (n-1)^2}{n^3}$$

$$\blacksquare \lim_{n \rightarrow \infty} \frac{(n+2)! + (n+1)!}{(n+3)!}$$

$$\blacksquare \lim_{n \rightarrow \infty} \sqrt[n]{3n^2 + n}$$

CAPÍTULO 10

Series

Las series permiten entender la idea de querer hacer sumas en las que hay una cantidad infinita de sumandos (tantos sumandos como números naturales). Para dar la idea de una *serie* debemos considerar dos tipos de números reales:

- la expresión para cada sumando: a_n
- La expresión para la suma finita de los primeros n sumandos:

$$s_n = a_1 + \cdots + a_n = \sum_{k=1}^n a_k$$

La siguiente terminología es usual:

- A a_n se le llama término general de la serie.
- A s_n se le llama la suma parcial de la serie.

Por lo tanto una serie está relacionada con dos sucesiones:

- la sucesión a_n de los términos generales de la serie.
- La sucesión s_n de sumas parciales de la serie.

La siguiente notación es usual: En vez de referirse a la serie como un par de sucesiones es usual hablar de la serie como

$$\sum_{n=1}^{\infty} a_n$$

Ejemplo 10.1

$$\sum_{n=1}^{\infty} n$$

tenemos que

$$a_n = n$$

$$s_n = 1 + 2 + \cdots + n = \sum_{k=1}^n k = \frac{n(n+1)}{2}$$

A la hora de estudiar las series es útil clasificarlas en tres grupos:

1. Serie de términos positivos: son las que, a partir de un cierto término, tienen todos sus términos con el mismo signo.
2. Series alternadas: son aquellas en las que, a partir de un cierto término, dos términos consecutivos cualesquiera tienen distinto signo.
3. Series de términos positivos y negativos: en éstas el orden de aparición de los términos positivos y negativos es arbitrario

En otras palabras

Una serie $\sum_{n=1}^{+\infty} a_n$ es una *serie de términos positivos* cuando $a_n > 0$ para cada n

Una serie $\sum_{n=1}^{+\infty} a_n$ es una *serie alternada* cuando $a_n = (-1)^n c_n$ para alguna sucesión $\{c_n\}$ tal que $c_n > 0$ para cada n

Ejemplo 10.2 *la serie armónica es:*

$$\sum_{n=1}^{+\infty} \frac{1}{n}$$

Para esta serie

$$a_n = \frac{1}{n}$$

Entonces se trata de una serie de términos positivos. Además

$$\begin{aligned} s_n &= 1 + \frac{1}{2} + \cdots + \frac{1}{n} \\ &= \sum_{k=1}^n \frac{1}{k} \end{aligned}$$

Una cuenta interesante es la siguiente

$$\begin{aligned} s_{2n} - s_n &= \left(1 + \frac{1}{2} + \cdots + \frac{1}{n} + \frac{1}{n+1} + \cdots + \frac{1}{2n} \right) - \left(1 + \frac{1}{2} + \cdots + \frac{1}{n} \right) \\ &= \frac{1}{n+1} + \cdots + \frac{1}{2n} \geq \frac{1}{2n} + \cdots + \frac{1}{2n} \\ &= n \frac{1}{2n} \\ &= \frac{1}{2} \end{aligned}$$

En conclusión, para la serie armónica:

$$s_{2n} - s_n \geq \frac{1}{2}$$

Ejemplo 10.3 Para la serie

$$\sum_{n=1}^{+\infty} (-1)^n$$

tenemos que $a_n = (-1)^n$ entonces se trata de una serie alternada. Además

$$\begin{aligned} s_n &= \sum_{k=1}^n (-1)^k = -1 + 1 - 1 + \cdots + (-1)^n \\ &= \begin{cases} -1 & \text{si } n \text{ es impar} \\ 0 & \text{si } n \text{ es par} \end{cases} \end{aligned}$$

Ejemplo 10.4 La serie geométrica (de razón r) es:

$$\sum_{n=0}^{+\infty} r^n$$

Para esta serie $a_n = r^n$

Si $r > 0$ entonces se trata de una serie de términos positivos. si $r < 0$ entonces se trata de una serie alternada. Además

$$s_n = 1 + r + \cdots + r^n = \sum_{k=0}^n r^k$$

Un hecho curioso es que para esta serie:

$$rs_n = r + r^2 + \cdots + r^{n+1}$$

Por lo tanto

$$\begin{aligned} (1-r)s_n &= s_n - rs_n \\ &= (1 + r + \cdots + r^n) - (r + r^2 + \cdots + r^{n+1}) \\ &= 1 - r^{n+1} \end{aligned}$$

En conclusión, si $r \neq 1$ para la serie geométrica:

$$s_n = \frac{1 - r^{n+1}}{1 - r}$$

A veces se puede decir con exactitud cuánto da la suma finita (la suma $\sum_{k=1}^n a_k$), pero en general es muy difícil decir cuánto da la suma infinita (la suma $\sum_{k=1}^{\infty} a_k$)

Ejemplo 10.5 Para la serie

$$\sum_{n=1}^{\infty} \frac{2 + \cos(n^3)}{2^n + n}$$

tenemos que

$$a_n = \frac{2 + \cos(n^3)}{2^n + n}$$

Esta serie es de términos positivos. Además

$$s_n = \sum_{k=1}^n \frac{2 + \cos(k^3)}{2^k + k}$$

1. Convergencia y divergencia de series

Se dice que la serie $\sum_{n=1}^{+\infty} a_n$ converge o es una *serie convergente* cuando la sucesión de sumas parciales s_n tiene límite finito.

Se dice que la serie $\sum_{n=1}^{+\infty} a_n$ diverge o es una *serie divergente* cuando la sucesión de sumas parciales s_n no converge (ya sea porque el límite da $+\infty$, da $-\infty$ ó no existe).

Sea $s \in \mathbb{R}$, si la sucesión s_n converge a s se suele escribir

$$\sum_{n=1}^{+\infty} a_n = s$$

En otras palabras, la expresión anterior quiere decir:

$$\lim_{n \rightarrow +\infty} \sum_{k=1}^n a_k = \lim_{n \rightarrow +\infty} s_n = s$$

En este ultimo caso debe quedar claro que s no se obtiene simplemente por adición, s es el límite de una sucesión de sumas.

Definición 10.1 Si la serie no es convergente ni divergente diremos que es *oscilante*

El estudio de una serie consiste en resolver dos problemas fundamentales:

- Determinar su carácter, es decir, averiguar si es convergente, divergente u oscilante
- En caso de convergencia, hallar su suma

Proposición 10.1 Si se modifica los valores de un número finito de términos, la serie conserva su carácter y en el caso de ser convergente la variación en la suma de la serie es la suma de las variaciones de los términos alterados.

Proposición 10.2 Propiedad Asociativa Si en una serie convergente (divergente) se agrupan términos consecutivos, la serie que resulta también es convergente(divergente) y tiene la misma suma.

Proposición 10.3 Si $\sum x_n$ y $\sum y_n$ son dos series convergentes y $\lambda, \mu \in \mathbb{R}$ entonces la serie

$$\sum (\lambda x_n + \mu y_n)$$

es convergente y la suma es

$$S = \lambda \sum_{n=1}^{\infty} x_n + \mu \sum_{n=1}^{\infty} y_n$$

Teorema 10.1 *Criterio general de convergencia de Cauchy* La condición necesaria y suficiente para que una serie de términos reales sea convergente es que a partir de un la diferencia entre dos sumas parciales se pueda hacer tan pequeña como se quiera; es decir:

$$\forall \varepsilon > 0 \exists v \in \mathbb{N} / \forall p, q \geq 0 \Rightarrow |S_q - S_p| \leq \varepsilon$$

ó

$$|x_{p+1} + x_{p+2} + \cdots + x_q| \leq \varepsilon$$

2. Serie de términos positivos

Proposición 10.4 *Para que una serie términos positivos sea convergente es condición necesaria y suficiente que esté acotada superiormente la sucesión de las sumas parciales. Entonces la suma de la series será*

$$S = \sup\{S_n\}$$

Si la sucesión (S_n) no está acotada superiormente, la serie $\sum x_n$ es divergente. Las series de términos positivos son convergentes o divergentes pero nunca oscilantes.

2.1. Criterios de convergencia para series de términos positivos

Vamos a estudiar las series de la forma

$$\sum_{n=1}^{+\infty} a_n$$

donde $a_n > 0$. En estas condiciones

$$S_n = a_1 + \cdots + a_n > 0$$

Para indicar que una serie de términos positivos es convergente se suele escribir

$$\sum_{n=1}^{+\infty} a_n < +\infty$$

Esta notación **NO** se usa para otro tipo de series

Criterio de acotación

Dada $\sum_{n=1}^{+\infty} a_n > 0$. Si la sucesión de sumas parciales $\{S_n\}$ es acotada entonces $\sum_{n=1}^{+\infty} a_n < +\infty$

Criterio de comparación

Sea $\{a_n\}$ y $\{b_n\}$ sucesiones tales que $0 < a_n \leq b_n$ para todo n .

1. Si $\sum_{n=1}^{+\infty} b_n$ convergente entonces $\sum_{n=1}^{+\infty} a_n$ también converge.
2. Si $\sum_{n=1}^{+\infty} a_n$ divergente entonces $\sum_{n=1}^{+\infty} b_n$ también diverge.

Ejemplo 10.6 Estudiar la convergencia de la siguiente serie

$$\sum_{n=1}^{+\infty} \frac{2 + \cos(n^3)}{2^n + n}$$

sabemos que

$$0 \leq \frac{2 + \cos(n^3)}{2^n + n} \leq \frac{3}{2^n} = 3 \left(\frac{1}{2}\right)^n$$

Sean

$$a_n = \frac{2 + \cos(n^3)}{2^n + n}$$

$$b_n = 3 \left(\frac{1}{2}\right)^n$$

entonces $0 \leq a_n \leq b_n$. Como

$$\sum_{n=1}^{+\infty} b_n = \sum_{n=1}^{+\infty} 3 \left(\frac{1}{2}\right)^n = 3 \sum_{n=1}^{+\infty} \left(\frac{1}{2}\right)^n < +\infty$$

Porque la serie de la derecha es una geométrica de razón $\frac{1}{2} < 1$. Es decir, tenemos que la serie $\sum_{n=1}^{+\infty} b_n$ converge. Por el criterio de comparación, obtenemos $\sum_{n=1}^{+\infty} a_n < +\infty$. Esto es,

$$\sum_{n=1}^{+\infty} \frac{2 + \cos(n^3)}{2^n + n} < +\infty$$

Criterio de comparación paso al límite

Sea $\{a_n\}$ y $\{b_n\}$ dos sucesiones tales que $0 \leq a_n$, $0 < b_n$ y sea

$$\lambda = \lim_{n \rightarrow \infty} \frac{a_n}{b_n}$$

1. Si λ es finito y $\lambda \neq 0$, entonces $\sum_{n=1}^{+\infty} b_n$ converge si y sólo si $\sum_{n=1}^{+\infty} a_n$ converge
2. Si $\lambda = \infty$ y $\sum_{n=1}^{+\infty} b_n$ diverge entonces $\sum_{n=1}^{+\infty} a_n$ diverge
3. En otro caso no hay información

Ejemplo 10.7 Estudiar la convergencia de

$$\sum_{n=1}^{+\infty} \frac{1}{3n^2 - n}$$

Vamos a considerar la serie

$$\sum_{n=1}^{+\infty} \frac{1}{n^2}$$

que sabemos que converge y utilizaremos el criterio de comparación de paso al límite.

$$a_n = \frac{1}{n^2}$$

$$b_n = \frac{1}{3n^2 - n}$$

Se verifica que tanto $a_n > 0$ y $b_n > 0$

$$\lambda = \lim_{n \rightarrow +\infty} \frac{\frac{1}{n^2}}{\frac{1}{3n^2 - n}} = \lim_{n \rightarrow +\infty} \frac{3n^2 - n}{n^2} = \lim_{n \rightarrow +\infty} \frac{3n^2}{n^2} - \frac{n}{n^2} = \lim_{n \rightarrow +\infty} 3 - \frac{1}{n} = 3$$

Por tanto

$$\lambda = 3$$

Es finito y como $\sum_{n=1}^{+\infty} \frac{1}{n^2}$ converge entonces $\sum_{n=1}^{+\infty} \frac{1}{3n^2 - n}$ converge

Criterio de condensación de Cauchy

Sea (x_n) una sucesión decreciente, entonces la serie $\sum x_n$ es convergente si y sólo si la serie $\sum 2^n x_{2^n}$

Ejemplo 10.8 estudiar el carácter de la serie

$$\sum \frac{1}{3^{\ln n}}$$

Aplicamos el criterio de condensación de Cauchy.
Para ello estudiamos el carácter de la serie $\sum 2^n x_{2^n}$, que será el mismo que el de la serie dada.

$$2^n x_{2^n} = 2^n \frac{1}{3^{\ln 2^n}} = \frac{2^n}{3^{\ln 2^n}} = \frac{2^n}{3^{n \ln 2}} = \left(\frac{2}{3^{\ln 2}} \right)^n$$

Ésta es una progresión geométrica de razón $\frac{2}{3^{\ln 2}} < 1$. Por tanto es convergente.

Criterio de la raíz

Sea $\sum x_n$ una serie de términos positivos y $\lambda = \lim_{n \rightarrow \infty} \sqrt[n]{x_n}$

- Si $\lambda < 1$, la serie es convergente.
- Si $\lambda > 1$, la serie es divergente.
- Si $\lambda = 1$, este criterio no aporta información (puede ser que la serie converja o puede que la serie diverja).

Ejemplo 10.9 *Estudiaremos la serie*

$$\sum_{n=1}^{+\infty} \frac{1}{(\ln n)^n}$$

Tenemos

$$x_n = \frac{1}{(\ln n)^n}$$

$$\sqrt[n]{x_n} = \sqrt[n]{\frac{1}{(\ln n)^n}} = \frac{1}{\ln n}$$

$$\lambda = \lim_{n \rightarrow +\infty} \sqrt[n]{a_n} = \lim_{n \rightarrow +\infty} \frac{1}{\ln n} = 0 < 1$$

Por el criterio de la raíz

$$\sum_{n=1}^{+\infty} \frac{1}{(\ln n)^n} < +\infty$$

Criterio del cociente o de D'Alembert

Sea $\sum x_n$ una serie de términos positivos y $\beta = \lim_{n \rightarrow \infty} \frac{x_{n+1}}{x_n}$

- Si $\beta < 1$, la serie es convergente.
- Si $\beta > 1$, la serie es divergente.
- Si $\beta = 1$, este criterio no aporta información (puede ser que la serie converja o puede que la serie diverja).

Ejemplo 10.10 *Estudiaremos la serie*

$$\sum_{n=1}^{+\infty} \frac{n!}{n^n}$$

Tenemos

$$\begin{aligned}x_n &= \frac{n!}{n^n} \\x_{n+1} &= \frac{(n+1)!}{(n+1)^{n+1}} \\ \beta = \lim_{n \rightarrow +\infty} \frac{x_{n+1}}{x_n} &= \lim_{n \rightarrow +\infty} \frac{\frac{(n+1)!}{(n+1)^{n+1}}}{\frac{n!}{n^n}} \\ &= \lim_{n \rightarrow +\infty} \frac{(n+1)!}{n!} \frac{n^n}{(n+1)^{n+1}} \\ &= \lim_{n \rightarrow +\infty} \frac{(n+1) \cdot n!}{n!} \frac{n^n}{(n+1)^{n+1}} \\ &= \lim_{n \rightarrow +\infty} \frac{n^n}{(n+1)^n} \\ &= \lim_{n \rightarrow +\infty} \left(\frac{n}{n+1} \right)^n \\ &= \lim_{n \rightarrow +\infty} \left(1 - \frac{1}{n+1} \right)^n \\ &= \frac{1}{e} < 1\end{aligned}$$

Por el criterio del cociente

$$\sum_{n=1}^{+\infty} \frac{n!}{n^n} < +\infty$$

Criterio de Pringsheim

Sea $\sum x_n$ una serie de términos positivos y supongamos que existe un número positivo α tal que $\lim_{n \rightarrow \infty} n^\alpha x_n$ sea finito y distinto de cero.

- Si $\alpha > 1$, la serie es convergente.
- Si $\alpha \leq 1$, la serie es divergente.

Criterio de Raabe

Sea $\sum x_n$ una serie de términos positivos y $\lambda = \lim_{n \rightarrow \infty} n \left(1 - \frac{x_{n+1}}{x_n} \right)$

- Si $\lambda > 1$, la serie es convergente.
- Si $\lambda < 1$, la serie es divergente.
- Si $\lambda = 1$, este criterio no aporta información (puede ser que la serie converja o puede que la serie diverja).

Ejemplo 10.11

$$\sum_{n=1}^{+\infty} = \frac{1 \cdot 3 \cdot 5 \cdots (2n-1)}{2 \cdot 4 \cdot 6 \cdots 2n}$$

$$\text{Aplicando el criterio de D'Álembert } \lim_{n \rightarrow \infty} \frac{x_{n+1}}{x_n} = \lim_{n \rightarrow \infty} \frac{2n+1}{2n+2} = 1$$

Puesto que es dudoso aplicamos el criterio de Raabe

$$\lim_{n \rightarrow \infty} n \left(1 - \frac{x_{n+1}}{x_n} \right) = \lim_{n \rightarrow \infty} n \left(1 - \frac{2n+1}{2n+2} \right) = \lim_{n \rightarrow \infty} \frac{n}{2n+2} = \frac{1}{2} < 1$$

Por tanto es divergente

Criterio logarítmico

$$\text{Sea } \sum x_n \text{ una serie de términos positivos y } \lambda = \lim_{n \rightarrow \infty} \frac{\ln \frac{1}{x_n}}{\ln n}$$

- Si $\lambda > 1$, la serie es convergente.
- Si $\lambda < 1$, la serie es divergente.
- Si $\lambda = 1$, este criterio no aporta información (puede ser que la serie converja o puede que la serie diverja).

Ejemplo 10.12 *Estudia el carácter de la serie*

$$\sum x_n = \sum \frac{1}{3^{\ln n}}$$

$$\frac{\ln \frac{1}{x_n}}{\ln n} = \frac{\ln 3^{\ln n}}{\ln n} = \ln 3 > 1$$

Por tanto es convergente

Resumen

Criterio	λ	Converge	Diverge
Cauchy	$\lim_{n \rightarrow \infty} \sqrt[n]{x_n}$	$\lambda < 1$	$\lambda > 1$ $\lambda = 1 \vee \forall n > n_0 \sqrt[n]{x_n} > 1$
D'Alembert	$\lim_{n \rightarrow \infty} \frac{x_n}{x_{n+1}}$	$\lambda < 1$	$\lambda > 1$ $\lambda = 1 \vee \forall n > n_0 \frac{x_n}{x_{n+1}} > 1$
Raabe	$\lim_{n \rightarrow \infty} n \left(1 - \frac{x_n}{x_{n+1}} \right)$	$\lambda > 1$	$\lambda < 1$ $\lambda = 1 \vee \forall n > n_0 n \left(1 - \frac{x_n}{x_{n+1}} \right) < 1$
Logarítmico	$\lim_{n \rightarrow \infty} \frac{\ln \frac{x_n}{\ln n}}{\ln n}$	$\lambda > 1$	$\lambda < 1$ $\lambda = 1 \vee \forall n > n_0 \frac{1}{\ln \frac{x_n}{\ln n}} < 1$
Pringsheim	Hallar α tal que $\lim_{n \rightarrow \infty} n^\alpha x_n$	$\lambda > 1$	$\lambda < 1$ $\lambda = 1 \vee \forall n > n_0 \frac{1}{\ln \frac{x_n}{\ln n}} < 1$

3. Series alternadas

Definición 10.2 Una serie se llama **alternada** si sus términos son alternativamente positivos y negativos

Teorema 10.2 Teorema de Leibnitz Una serie alternada tal que los valores absolutos de sus términos forman una sucesión decreciente es convergente si y solo si su término general tiende a cero.

Además el error que se comete al tomar como suma de la serie una suma parcial cualquiera es menor que el primer término despreciado.

3.1. Criterios de convergencia para series alternadas

Criterio de Leibnitz

Sea $\{c_n\}$ una sucesión tal que:

- $c_1 \geq c_2 \geq \dots \geq 0$
- $\lim_{n \rightarrow +\infty} c_n = 0$

Entonces la serie $\sum_{n=1}^{+\infty} (-1)^n c_n$ converge

Ejemplo 10.13 Estudiaremos la serie

$$\sum_{n=1}^{+\infty} (-1)^n \frac{1}{n}$$

En este caso el término general es

$$a_n = (-1)^n \frac{1}{n}$$

Sea

$$c_n = \frac{1}{n}$$

Entonces

$$c_1 \geq c_2 \geq \dots \geq 0$$

$$\lim_{n \rightarrow +\infty} c_n = \lim_{n \rightarrow +\infty} \frac{1}{n} = 0$$

Por el criterio de Leibnitz tenemos que

$$\sum_{n=1}^{+\infty} (-1)^n \frac{1}{n}$$

converge

3.2. Series de términos positivos y negativos

Nos referimos ahora a series con infinitos términos positivos y negativos de las que las alternadas son un caso particular.

Si la serie fuera de términos negativos podemos reducir su estudio a las series de términos positivos de la forma siguiente: Si $x_n < 0 \forall n \Rightarrow \sum x_n = -\sum |x_n|$. Si hubiera un número finito de términos de distinto signo estudiamos el carácter de la serie que resulta sin tener en cuenta dichos términos pues el carácter no varía si descartamos un número finito de términos.

Si hubiera infinitos términos positivos y negativos una forma de estudiar el carácter de la serie es considerando por separado la serie formada por los términos positivos y la serie de los valores absolutos de sus términos negativos.

Definición 10.3 *Convergencia absoluta* Decimos que una serie $\sum x_n$ de términos cualesquiera, es **absolutamente convergente** si es convergente la serie de los valores absolutos de sus términos, es decir, si $\sum |x_n|$ converge

Teorema 10.3 Si $\sum |x_n|$ converge entonces $\sum x_n$ converge y además:

$$\left| \sum_{n=1}^{+\infty} x_n \right| \leq \sum_{n=1}^{+\infty} |x_n|$$

El recíproco no es cierto.

Ejemplo 10.14 La serie $\sum \frac{(-1)^n}{n}$ es convergente ya que es alternada, $\left| \frac{(-1)^n}{n} \right|$

es decreciente y cumple que $\lim_{n \rightarrow +\infty} \frac{1}{n} = 0$. Sin embargo la serie de sus valores absolutos es divergente pues se trata de la serie armónica.

Definición 10.4 Una serie se llama **incondicionalmente convergente** si es convergente y su suma no se altera al cambiar el orden de sus términos.

Una serie se llama **condicionalmente convergente** si es convergente pero su suma se altera al cambiar el orden de sus términos.

Teorema 10.4 Sea $\sum x_n$ una serie de términos positivos y negativos. Es absolutamente convergente si y sólo si es incondicionalmente convergente.

4. Series sumables

4.1. Series geométricas

Son aquellas de la forma $\sum x_n = \sum a \cdot r^{n-1} \quad a > 0, r \in \mathbb{R}$

Proposición 10.5 La serie geométrica $\sum x_n = \sum a \cdot r^{n-1}$ es convergente si y sólo si $|r| < 1$ y la suma es:

$$S = \frac{x_1}{1-r}.$$

Demostración

Si $r = 1$ $x_n = a \quad \forall n \in \mathbb{N}$ por tanto S_n no está acotada $\sum x_n$ diverge.

Si $r = -1$ $x_n = \pm a \quad \forall n \in \mathbb{N}$ $\sum x_n$ es oscilante.

Si $r > 1$ $x_n = a \cdot r^{n-1}$ tiende a $+\infty$ por tanto $\sum_{n=1}^{+\infty} x_n$ diverge.

Si $r < -1$ La serie varía entre $\pm\infty$ por lo tanto es oscilante.

Si $-1 < r < 1$ $x_n = a \cdot r^{n-1}$ converge a 0.

Veamos que la serie es sumable calculando su suma

$$\begin{array}{rcl} S_n & = & x_1 + x_2 + \cdots + x_n \\ r \cdot S_n & = & x_2 + \cdots + x_n + x_{n+1} \\ \hline S_n - r \cdot S_n & = & x_1 - x_{n+1} \end{array} \quad \text{de donde:}$$

$$S_n = \frac{x_1 - x_{n+1}}{1 - r} \Rightarrow S = \lim_{n \rightarrow +\infty} S_n = \frac{x_1}{1 - r}$$

□

4.2. Series Aritmético-geométricas

Son de la forma: $\sum x_n = \sum a_n b_n$ donde (a_n) es una progresión aritmética y (b_n) es una progresión geométrica de razón r .

Proposición 10.6 *Una serie aritmético-geométrica es convergente si y sólo si el valor absoluto de la razón es menor que 1*

Ejemplo 10.15 *Estudiar el carácter de la siguiente serie y sumarla si es posible:*

$$\begin{aligned} & \sum_{n=1}^{+\infty} \frac{3n-1}{2^n} \\ & \sum_{n=1}^{+\infty} \frac{3n-1}{2^n} = \sum_{n=1}^{+\infty} (3n-1) \frac{1}{2^n} \\ \begin{array}{rcl} S_n & = & 1 + \frac{5}{4} + \frac{8}{8} + \cdots + \frac{3n-1}{2^n} \\ \frac{1}{2} S_n & = & \frac{1}{2} + \frac{5}{8} + \frac{8}{16} + \cdots + \frac{3n-4}{2^n} + \frac{3n-1}{2^{n+1}} \\ \hline S_n - \frac{1}{2} S_n & = & 1 + \frac{3}{4} + \frac{3}{8} + \cdots + \frac{3}{2^n} - \frac{3n-1}{2^{n+1}} \end{array} \\ S_n &= 2 + 6 \left(\frac{1}{4} + \frac{1}{8} + \cdots + \frac{1}{2^n} \right) - \frac{3n-1}{2^{n+1}} \Rightarrow S = \lim_{n \rightarrow +\infty} S_n = 2 + 6 \left(\frac{\frac{1}{4}}{1 - \frac{1}{2}} \right) = 5 \end{aligned}$$

CAPÍTULO 11

Derivación de funciones de una variable

1. Definición de derivada. Interpretaciones

La derivación es una herramienta muy potente del cálculo. Si las funciones continuas son aquellas cuyas gráficas no presentan saltos, las funciones derivables tienen la propiedad de que su gráfica, además de ser continua, no presenta picos, cambios bruscos de dirección, o rectas tangentes verticales.

Existen varias formas de aproximarse al concepto de derivada de una función de una variable en un punto. Nosotros eligiremos dos: la primera, a través de la tasa de variación instantánea de una función; la segunda, a partir del problema de la recta tangente a una gráfica en un punto

1.1. Tasa de variación instantánea de una función

En Física, la velocidad media de un móvil es el cociente entre el espacio recorrido y el tiempo empleado en ello. Ahora bien, ¿que significado tiene entonces la llamada velocidad instantánea? En un instante, un móvil no recorre nada, y la cantidad de tiempo necesitada es también cero. Por tanto, el concepto de velocidad instantánea sólo puede ser entendido como un paso al límite. Es decir, si medimos el espacio recorrido por el vehículo en un tiempo h pequeño, y lo dividimos entre h , el resultado será próximo a nuestra idea de velocidad instantánea. Y será más próximo cuanto más pequeño sea h . Así pues, la velocidad $v(t_0)$ en un instante t_0 no es otra cosa que:

$$v(t_0) = \lim_{h \rightarrow 0} \frac{e(t_0 + h) - e(t_0)}{h}$$

donde $e(t)$ es el espacio recorrido en función del tiempo t . Cuando dicho límite existe y es finito se llama derivada de $e(t)$ en t_0 .

En general, siguiendo la idea que se ha visto en el ejemplo anterior, la derivada representa la tasa instantánea de cambio de una magnitud.

Sea $f : I \rightarrow \mathbb{R}$ una función definida en un intervalo abierto I .

Se llama tasa de variación media de f en $[u, v] \in I$ al número real:

$$TVM(f, [u, v]) = \frac{\Delta f}{\Delta x} = \frac{f(v) - f(u)}{v - u}$$

que representa como cambia la magnitud $y = f(x)$ respecto de x en $[u, v]$. Si nos preguntamos por la tasa de variación instantánea de f en un punto concreto $a \in I$, entonces debemos calcular tasas de variación media en intervalos de la forma $[a, a + h]$ con h cada vez más pequeño. De este modo:

$$TVI(f, a) = \lim_{h \rightarrow 0} TVM(f, [a, a + h]) = \lim_{h \rightarrow 0} \frac{f(a + h) - f(a)}{h}$$

Cuando este límite existe y es finito se llama derivada de $f(x)$ en a .

1.2. Definición de la derivada

Definición 11.1 Sea $I \subset \mathbb{R}$ un intervalo abierto, $a \in I$ y $f : I \rightarrow \mathbb{R}$ una función. Diremos que f es derivable en a si existe y es finito el límite dado por:

$$\lim_{h \rightarrow 0} \frac{f(a + h) - f(a)}{h}$$

En tal caso, a dicho límite lo llamamos derivada de f en a , y lo representamos por $f'(a)$ o por $\frac{df}{dx}(a)$. Obsérvese que el límite que aparece en la definición de derivada conduce a una indeterminación de tipo $\left(\frac{0}{0}\right)$. Diremos que f es derivable en I si f es derivable en cada punto $a \in I$. En tal caso, se llama función derivada de f a la función $f' : I \rightarrow \mathbb{R}$, que asocia a cada punto $a \in I$ la derivada $f'(a)$.

Teorema 11.1 Sea $f : I \rightarrow \mathbb{R}$ una función definida sobre un intervalo abierto de $\mathbb{R}$. Dado $a \in I$ se tiene que f es derivable en a si y solo si existen las dos derivadas laterales, son iguales y son finitas. En tal caso, $f'(a) = f'_-(a) = f'_+(a)$.

Teorema 11.2 Sea $f : I \rightarrow \mathbb{R}$ una función definida en un intervalo abierto I . Si f es derivable en un punto $a \in I$, entonces f es continua en a .

2. Resultados relacionados con la derivación

Teorema 11.3 (de Rolle) Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en $[a, b]$, derivable en (a, b) , y tal que $f(a) = f(b)$. Entonces existe $c \in (a, b)$ de forma que $f'(c) = 0$.

El próximo resultado es una generalización del Teorema de Rolle:

Teorema 11.4 (del valor medio) Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en $[a, b]$, derivable en (a, b) . Entonces existe $c \in (a, b)$ de forma que

$$f'(c) = \frac{f(b) - f(a)}{b - a}$$

3. Cálculo de derivadas. Reglas de derivación

Ahora aprenderemos a calcular de forma sistemática la derivada de cualquier función de una variable. Evidentemente, la definición original, pese a su clara interpretación, no es práctica a la hora de calcular derivadas de funciones complicadas. Realizaremos el cálculo de derivadas de forma mucho más fácil a partir de las reglas de derivación, basadas en dos herramientas fundamentales.

1. El comportamiento de las derivadas frente a las operaciones de suma, producto y composición.
2. El cálculo concreto de la derivada de las funciones elementales.

3.1. Derivadas y operaciones con funciones

Sean $f, g : I \subset \mathbb{R}$ dos funciones derivables sobre un intervalo abierto I . Entonces:

- $f+g$ es derivable en I y $(f+g)'(x) = f'(x) + g'(x)$
- $\lambda \cdot f$ es derivable en I para cada $\lambda \in \mathbb{R}$ y $(\lambda \cdot f)'(x) = \lambda \cdot f'(x)$
- $f \cdot g$ es derivable en I y $(f \cdot g)'(x) = f'(x) \cdot g(x) + f(x) \cdot g'(x)$
- $\frac{f}{g}$ es derivable en $I - \{x : g(x) \neq 0\}$ y $\left(\frac{f}{g}\right)'(x) = \frac{f'(x) \cdot g(x) - f(x) \cdot g'(x)}{g(x)^2}$
- f^g es derivable en I y $f^g(x) = g(x)f(x)^{g(x)-1}f'(x) + f(x)^{g(x)} \ln(f(x))g'(x)$ siempre que $f(x) > 0$ para cada $x \in I$
- Regla de la cadena: La composición $(g \circ f)(x) = g(f(x))$ es derivable en I con derivada:

$$(g \circ f)'(x) = g'(f(x))f'(x)$$

Definición 11.2 Sea $f : I \subset \mathbb{R}$ una función derivable en un intervalo abierto I . Recordemos que la función derivada es la función $f' : I \subset \mathbb{R}$, que a cada $x \in I$ le hace corresponder $f'(x)$. Diremos que f es dos veces derivable en $a \in I$ si la función derivada f' es derivable en a . En este caso, representamos $f''(a) = (f')'(a)$ y lo llamamos derivada segunda de f en a . Así se pueden definir, sucesivamente, las derivadas tercera, cuarta, etc.

4. Aplicaciones de las derivadas

Las aplicaciones del cálculo diferencial son muy numerosas. Aquí nos preocuparemos sobre todo de aspectos relacionados con la representación gráfica de funciones de una variable.

4.1. Monotonía, puntos críticos y extremos locales de una función

Estudiar la monotonía de una función consiste en decidir en qué intervalos la función es creciente y en cuales es decreciente. Cuando la función es derivable esto se realiza de forma sencilla discutiendo el signo de la derivada primera de la función.

Teorema 11.5 *Sea I un intervalo abierto y $f : I \rightarrow \mathbb{R}$ una función derivable en I . Entonces:*

1. *Si $f'(x) > 0$ para todo $x \in I$, entonces f es (estrictamente) creciente en I .*
2. *Si $f'(x) < 0$ para todo $x \in I$, entonces f es (estrictamente) decreciente en I .*
3. *Si $f'(x) = 0$ para todo $x \in I$, entonces f es constante en I .*

Ahora nos preocuparemos de estudiar los puntos en los que de algún modo cambia la monotonía de una función.

Definición 11.3 *Sea $f : I \rightarrow \mathbb{R}$ una función definida sobre un intervalo abierto I . Dado un punto $a \in I$, diremos que f tiene en a un:*

Mínimo local: *si hay un entorno $B(a, r)$ contenido en I en el que se cumple que $f(x) \geq f(a)$ (geométricamente, esto significa que el valor más bajo de la gráfica de f en un entorno pequeño alrededor de a se alcanza justamente en a).*

Máximo local: *si hay un entorno $B(a, r)$ contenido en I en el que se cumple que $f(x) \leq f(a)$ (geométricamente, esto significa que el valor más alto de la gráfica de f en un entorno pequeño alrededor de a se alcanza justamente en a).*

Extremo local: *si f tiene en a un mínimo local o un máximo local.*

Punto crítico: *si f es derivable en a y $f'(a) = 0$ (geométricamente, esto significa que la recta tangente a la curva $y = f(x)$ en el punto $(a, f(a))$ es horizontal).*

La derivación se muestra como una herramienta útil a la hora de estudiar los extremos locales de una función.

Teorema 11.6 (Principio de Fermat) *Sea $f : I \rightarrow \mathbb{R}$ una función definida sobre un intervalo abierto. Si f es derivable en $a \in I$ y f alcanza en a un extremo local, entonces a es un punto crítico de f .*

Por tanto, los extremos locales de una función derivable sobre un intervalo abierto hay que buscarlos entre los puntos críticos de la función dentro de dicho intervalo. Como observación importante destacaremos que no es cierto que en un punto crítico se alcance siempre un extremo local.

Teorema 11.7 (Criterio de la derivada primera) *Sea $f : I \rightarrow \mathbb{R}$ una función derivable en un intervalo abierto. Dado un punto crítico a de f en I , estudiamos el signo de $f'(x)$ en un entorno pequeño alrededor de a . Se tiene:*

- Si $f'(x) < 0$ a la izquierda de a y $f'(x) > 0$ a la derecha, entonces a es un mínimo local de f .
- Si $f'(x) > 0$ a la izquierda de a y $f'(x) < 0$ a la derecha, entonces a es un máximo local de f .
- Si $f'(x)$ no cambia de signo alrededor de a , entonces no hay extremo local en a .

Teorema 11.8 (Criterio de la derivada segunda) Sea $f : I \rightarrow \mathbb{R}$ una función derivable dos veces sobre un intervalo abierto I . Dado un punto crítico a de f en I , estudiamos el signo de $f''(a)$. Entonces, se tiene lo siguiente:

1. Si $f''(a) > 0$, entonces a es un mínimo local de f .
2. Si $f''(a) < 0$, entonces a es un máximo local de f .
3. Si $f''(a) = 0$, entonces no se puede asegurar nada.

4.2. Curvatura y puntos de inflexión de una función

En esta sección realizaremos un tratamiento muy parecido al de la anterior para estudiar un nuevo aspecto de la gráfica de una función que, en este caso, está controlado por la derivada segunda: la curvatura de la función. Necesitaremos unos conceptos previos.

Definición 11.4 Sea $f : I \rightarrow \mathbb{R}$ una función definida en un intervalo abierto I . Diremos que f es:

1. *Convexa en I* si cada recta secante a la curva $y = f(x)$ deja a la gráfica por debajo.
2. *Cóncava en I* si cada recta secante a la curva $y = f(x)$ deja a la gráfica por encima.

Estudiar la curvatura de una función consiste en decidir los intervalos donde f es convexa y aquellos donde es cóncava. Cuando la función es derivable dos veces el estudio de su curvatura se realiza de forma sencilla discutiendo el signo de la derivada segunda de la función.

Teorema 11.9 Sea I un intervalo abierto y $f : I \rightarrow \mathbb{R}$ una función derivable dos veces en I . Entonces:

1. Si $f''(x) > 0$ para todo $x \in I$, entonces f es convexa en I .
2. Si $f''(x) < 0$ para todo $x \in I$, entonces f es cóncava en I .
3. Si $f''(x) = 0$ para todo $x \in I$, entonces la gráfica de f en I es una recta.

Ahora estudiaremos los puntos en los que cambia la curvatura de una función.

Definición 11.5 Sea $f : I \rightarrow \mathbb{R}$ una función definida sobre un intervalo abierto I . Dado un punto $a \in I$, diremos que f tiene en a un:

Punto de inflexión convexo-cóncavo si hay un entorno $B(a, r)$ contenido en I de forma que f es convexa en $(a - r, a)$ y cóncava en $(a, a + r)$.

Punto de inflexión cóncavo-convexo si hay un entorno $B(a, r)$ contenido en I de forma que f es cóncava en $(a - r, a)$ y convexa en $(a, a + r)$.

La derivación se muestra como una herramienta útil a la hora de estudiar los puntos de inflexión de una función.

Teorema 11.10 Sea $f : I \rightarrow \mathbb{R}$ una función derivable sobre un intervalo abierto I . Si f es derivable dos veces en $a \in I$ y f presenta un punto de inflexión en a , entonces $f''(a) = 0$, lo que geoméricamente significa que la recta tangente a la curva $y = f(x)$ en $(a, f(a))$ atraviesa a la gráfica.

Por tanto, los puntos de inflexión de una función derivable dos veces sobre un intervalo abierto hay que buscarlos entre los puntos que anulan a la derivada segunda. Como observación importante destacaremos que no es cierto que en un punto con derivada segunda nula se alcance siempre un punto de inflexión.

5. Funciones en Python

Si creamos nuestra propia función como se ha visto en 1.2

```
def derivada_x(f, x, h):
    m = (f(x + h) - f(x)) / ((x + h) - x)
    return m
def funcion(x):
    return x**2
derivada = derivada_x(funcion, 2, .000001)
```

Python tiene su propio paquete para derivar que sería:

```
from sympy import *
# Declaramos la variable que se va a derivar
x = symbols('x')

# Declaramos la función
f = x**2

# Calculamos la derivada
dx_f = diff(f)
print(dx_f)
```

CAPÍTULO 12

Cálculo diferencial de funciones de varias variables

Ahora nos ocuparemos del cálculo diferencial de funciones de más de una variable. Nuestro propósito en este tema es el de extender los conceptos de límite, continuidad y diferenciabilidad a las funciones de dos o más variables. Los resultados obtenidos se aplicarán entonces al estudio de las derivadas direccionales, los planos tangentes a las superficies, y los extremos de las funciones de varias variables. Algunas fórmulas de las matemáticas elementales suministran ejemplos sencillos de tales funciones. Así, en la fórmula para el volumen de un cilindro circular recto,

$$v = \pi x^2 y \quad (12.1)$$

v es una función de las dos variables independientes x (=radio) y y (=altura). Asimismo, en la fórmula para el área u de un triángulo plano oblicuángulo,

$$v = \frac{1}{2} x y \sin(\alpha) \quad (12.2)$$

u es una función de las tres variables independientes x, y y α , que representan, respectivamente, dos lados y el ángulo comprendido. Evidentemente, tanto en (12.1) como en (12.2), los valores que pueden asignarse a las variables en el segundo miembro son enteramente independiente el uno del otro. A estas expresiones se les llama funciones de tres o más argumentos. Las funciones de valores reales de varias variables reales independientes se definen en forma parecida a como se definen las funciones de una sola variable. Los dominios son conjuntos de pares (o tríadas o cuádruplos, etc.) ordenados de números reales, y los rangos son conjuntos de números reales del tipos de los que hemos usado. A continuación se presenta un concepto fundamental de funciones de varias variables. (Designaciones de las funciones).

1. Concepto Fundamental

Una magnitud variable z se denomina función uniforme de dos variables x e y , si a cada conjunto de valores de éstas (x,y) del campo dado, corresponde un valor único y determinado de z . Las variables x e y se llaman argumentos o variables independientes. (B. Demidovich). La dependencia funcional se representa así:

$$z = f(x, y)$$

El valor de la función $z=f(x,y)$ en el punto $P(a,b)$, es decir, cuando $x=a$ e $y=b$, se designa por $f(a,b)$ o $f(P)$.

1.1. Representación Geométrica de la función $z = f(x, y)$

La representación geométrica de la función $z=f(x,y)$ es un sistema de coordenadas cartesianas X,Y y Z es, en términos generales, una superficie

Observación 12.1 *La gráfica de una función de dos variables $z=f(x,y)$ puede interpretarse geoméricamente como una superficie S en el espacio de forma tal que su proyección sobre el plano xy es D , el dominio de f . En consecuencia, a cada punto (x,y) en D le corresponde un punto (x,y,z) en la superficie y, a la inversa, a cada punto (x,y,z) en la superficie le corresponde un punto (x,y) en D .*

1.2. Límites de una Función de Varias Variables.

Mucha de la terminología relacionada con los límites fue introducida por el matemático alemán Karl Weierstrass (1815-1897). Su forma de tratar rigurosamente los límites y otros temas del cálculo le han dado la reputación de padre del análisis moderno. El estudio de los límites de funciones de varias variables es mucho más complejo que el de funciones de una variable, pues en este, únicamente se tiene dos caminos para acercarse a un punto, por la derecha o por la izquierda; mientras que en el caso de varias variables existe una infinidad de caminos para acercarnos a un punto (a,b) ,

Límite de una Función $z = f(x, y)$

Comenzaremos el estudio de los límites para funciones de dos variables, el caso para funciones de n variables es análogo. Primero definimos el análogo a un intervalo abierto de $\mathbb{R}$.

Definición 12.1 (Disco de Radio δ y Centro P) *Un disco $D(P,\delta)$ abierto, o simplemente un disco, de radio $\delta > 0$ y centro en $P=(a,b)$ es el conjunto de todos los puntos (x,y) tales que su distancia a (a,b) es menor que δ , es decir*

$$D(P, \delta) = \left\{ (x, y) \in \mathbb{R}^2 : \sqrt{(x-a)^2 + (y-b)^2} < \delta \right\}$$

Definición 12.2 (Límite de una Función.) *Sea $f : D((a,b), \delta) \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ una función de dos variables definidas en el disco abierto $D((a,b), \delta)$, excepto posiblemente en (a,b) . Entonces*

$$\lim_{(x,y) \rightarrow (a,b)} f(x,y) = L$$

CAPÍTULO 12. CÁLCULO DIFERENCIAL DE FUNCIONES DE VARIAS VARIABLES

Si y sólo si para $\varepsilon > 0$ existe un correspondiente $\delta > 0$ tal que

$$|f(x, y) - L| = \varepsilon, \quad \text{siempre que} \quad 0 < \sqrt{(x - a)^2 + (y - b)^2} < \delta$$

Observación 12.2 Gráficamente, esta definición significa que para un punto cualquiera $(x, y) \in D((a, b), \delta)$ el valor de $f(x, y)$ está entre $L + \varepsilon$ y $L - \varepsilon$

Propiedades de Límites de Funciones de dos Variables

Las siguientes reglas son válidas si

$$\lim_{(x,y) \rightarrow (a,b)} f(x, y) = A \quad \text{y} \quad \lim_{(x,y) \rightarrow (a,b)} h(x, y) = A$$

Regla de la Suma: $\lim[f(x,y)+h(x,y)]=A+B$

Regla de la Diferencia: $\lim[f(x,y)-h(x,y)]=A-B$

Regla del Producto: $\lim[f(x,y) \cdot h(x,y)]=A \cdot B$

Regla del Múltiplo Constante: $\lim \lambda \cdot f(x,y) = \lambda A$, ($\lambda \in \mathbb{R}$)

Regla del Cociente: $\lim \frac{f(x,y)}{h(x,y)} = \frac{A}{B}$

Regla de la Potencia: si m y n son enteros, entonces

$$\lim [f(x, y)]^{\frac{m}{n}} = A^{\frac{m}{n}}$$

, siempre que $A^{\frac{m}{n}}$ sea un número real.

Cuando aplicamos las propiedades a los límites a las funciones de una sola variable, obtenemos el resultado útil de que los límites de polinomios y funciones racionales, cuando $(x, y) \rightarrow (a, b)$, puede calcularse evaluando las funciones en (a, b) . El único requisito es que las funciones estén definidas en (a, b) .

1.3. Operaciones con Límites

Límites de una Función Vectorial

Para determinar la existencia del límite de una función vectorial basta estudiar el límite de sus funciones coordenadas. De este modo nos centraremos en estudiar límites de funciones reales. Esto se debe al siguiente resultado:

Para una función $f = (f_1, \dots, f_m) : R^n \rightarrow R^m$ y un punto a se tiene que existe $\lim_{x \rightarrow a} f(x)$ y vale $L = (L_1, L_2, \dots, L_m)$ si y sólo si existen los límites de las funciones coordenadas $\lim_{x \rightarrow a} f_1(x), \dots, \lim_{x \rightarrow a} f_m(x)$ y valen $L_1, \dots, L_m$, respectivamente.

1.4. Límites Direccionales

A la hora de estudiar el límite de una función de dos variables mediante límites a través de algunos conjuntos es típico considerar conjuntos del tipo rectas, parábolas y en general curvas de la forma $y = g(x)$ ó $x = h(y)$. Una situación especial es el caso de los límites a través de rectas que contienen al punto, denominados también límites direccionales. Estas rectas, como ya sabemos, son las de la forma $y - b = m(x - a)$, junto con la recta vertical $x = a$.

Notemos que la existencia de los límites direccionales no garantiza la existencia del límite, ni siquiera cuando todos ellos coinciden. Lo más que se puede decir es lo siguiente:

“Si no existe algún límite direccional o al menos dos de ellos son distintos entonces no existe el límite”.

Observación 12.3 *Se puede generalizar el efecto anterior y deducir que si el límite a través de al menos dos conjuntos da un valor distinto (pueden ser dos direccionales, dos no direccionales o uno direccional y otro no direccional) entonces el límite no existe.*

2. Continuidad de una Función de Varias Variables

2.1. Continuidad de una Función $z=f(x,y)$

Igual que con las funciones de una sola variable, la continuidad se define en términos de límites

Definición 12.3 *Una función $f(x,y)$ es continua en un punto (a,b) si:*

1. *f está definida en (a,b) , es decir, que f tenga un valor en (a,b) .*
2. *$\lim_{(x,y) \rightarrow (a,b)} f(x,y)$ existe, es decir, f tenga un límite en (a,b)*
3. *$\lim_{(x,y) \rightarrow (a,b)} f(x,y) = f(a,b)$, es decir, el valor de f en (a,b) sea igual al límite en ese punto.*

Una función es continua si es continua en todo punto de su dominio. Con base a la percepción, esto significa que f no presenta saltos o fluctuaciones violentas en (a,b) . Igual que con la definición de límite, la definición de continuidad se aplica en puntos fronteras (a,b) , así como en puntos interiores de dominio de f . El único requisito es que el punto (x,y) permanezca en el dominio todo el tiempo. Así como las funciones de una sola variable, también son continuas, las Sumas, Productos y Cocientes de funciones continuas (una vez que, el último caso, se evite la división entre cero). Se deduce entonces lo siguiente que:

- Funciones polinomiales de dos variables son continuas en toda su extensión, dado que son sumas y productos de las funciones continuas ax, by y c , dado que a, b y c son constantes.

- Funciones racionales de dos variables son cocientes de funciones polinomiales y, por lo tanto, son continuas siempre que el denominador no sea cero.

Una función continua de una función continua, es continua.

2.2. Composición de Funciones Continuas

Si una función $z=f(x,y)$ es continua en (a,b) , y $w=g(z)$ es una función continua en z , entonces la función compuesta $(w \circ z)((x,y) = g(f(x,y))$ es continua en (a,b) .

3. Derivadas Parciales de una Función de Varias Variables

La derivada de una función de una variable mide la rapidez de cambio de la variable dependiente respecto a la variable independiente. Para funciones de dos variables x e y podemos medir dos razones de cambio: según cambia x , dejando a y fija y otra según cambia y dejando a x fija. Supongamos que dejamos variar solo a x , dejando a y fija, digamos que $y=b$, en donde b es una constante. Entonces, estamos en presencia de una función de una sola variable x , a saber que $g(x)=f(x,b)$. Si g tiene una derivada en a entonces la llamamos la derivada parcial de f con respecto a x en (a,b) . De forma análoga podemos hacerlo para y como variable y x fija, es decir, x es una constante

Definición 12.4 (Derivada Parcial) Si $z=(x,y)$, entonces las derivadas parciales primeras de f con respecto a x y a y son las funciones f_x y f_y respectivamente, definidas mediante,

$$\begin{aligned} f_x &= \lim_{h \rightarrow 0} \frac{f(x+h, y) - f(x, y)}{h} \\ f_y &= \lim_{h \rightarrow 0} \frac{f(x, y+h) - f(x, y)}{h} \end{aligned}$$

Siempre y cuando existan los límites.

Su derivada para cuando $x=a$ se llama derivada parcial de f con respecto a x en (a,b) y se denota como $f_x(a,b)$ y esta dada por la expresión.

$$f_x(a,b) = \lim_{h \rightarrow 0} \frac{f(a+h, b) - f(a, b)}{h}$$

Análogamente, cuando $y=b$ se llama derivada parcial de f con respecto a y en (a,b) y se denota como $f_y(a,b)$ y esta dada por la expresión.

$$f_y(a,b) = \lim_{h \rightarrow 0} \frac{f(a, b+h) - f(a, b)}{h}$$

Esta definición indica que si $z=f(x,y)$, entonces para calcular f_x consideramos que y es constante y derivamos con respecto a x . De forma análoga, para

obtener f_y consideramos que x es constante y derivamos con respecto a y .

Es evidente que para hallar las derivadas parciales pueden utilizarse las fórmulas ordinarias de derivación.

Notación de la Derivada Parcial

Si $z=f(x,y)$, usamos las siguientes alternativas de notación:

- Con respecto a x tenemos lo siguiente: $f_x = f_x(x, y) = \frac{\partial f(x, y)}{\partial x} = \frac{\partial f}{\partial x}$
- Con respecto a y tenemos lo siguiente: $f_y = f_y(x, y) = \frac{\partial f(x, y)}{\partial y} = \frac{\partial f}{\partial y}$

El símbolo ∂ se llama signo de la derivada parcial.

3.1. Derivadas Parciales de Segundo Orden

Cuando diferenciamos una función $f(x,y)$ dos veces, producimos sus derivadas de segundo orden. Estas derivadas son usualmente denotadas por

$\frac{\partial^2 f}{\partial x^2}$: se lee segunda derivada de f con respecto a x cuadrado.

$\frac{\partial^2 f}{\partial y^2}$: se lee segunda derivada de f con respecto a y cuadrado.

$\frac{\partial^2 f}{\partial x \partial y}$: se lee segunda derivada de f con respecto a x de la derivada de y . También se puede leer: la segunda derivada de f de la derivada de y con respecto a x .

$\frac{\partial^2 f}{\partial y \partial x}$: se lee segunda derivada de f con respecto a y de la derivada de x . También se puede leer: la segunda derivada de f de la derivada de x con respecto a y .

Estas dos últimas son llamadas derivadas parciales mixtas.

Teorema 12.1 (Igualdad de las Derivadas Mixtas) Sea $f : D \subset \mathbb{R} \rightarrow \mathbb{R}$ una función escalar donde D es un disco abierto con centro en (a,b) y radio δ , entonces si las funciones $\frac{\partial^2 f}{\partial x \partial y}$ y $\frac{\partial^2 f}{\partial y \partial x}$ son continuas en D , entonces

$$\frac{\partial^2 f}{\partial x \partial y}(a, b) = \frac{\partial^2 f}{\partial y \partial x}(a, b)$$

Es decir, la función $f(x,y)$ es continua en su dominio.

3.2. Diferenciabilidad

Después del estudio de los límites de funciones de dos variables retomamos la discusión sobre diferenciabilidad, y aprovechamos para fijar en una definición y un teorema lo que hemos avanzado hasta ahora.

Definición 12.5 *La función $z=f(x,y)$ es diferenciable en el punto $P=(a,b)$ si existen unos números A y B tales que*

$$\lim_{(x,y) \rightarrow (a,b)} \frac{f(x,y) - (f(a,b) + A(x-a) + B(y-b))}{\sqrt{(x-a)^2 + (y-b)^2}} = 0$$

En ese caso diremos que el plano $z=f(a,b)+A(x-a)+B(y-b)$ es el plano tangente a la gráfica de f en (a,b) .

3. DERIVADAS PARCIALES DE UNA FUNCIÓN DE VARIAS VARIABLES

Parte III

Estadística Descriptiva

CAPÍTULO 13

Variable Estadística Unidimensional

1. Variables Estadísticas. Tablas Estadísticas

La palabra **estadística** procede del latín Status debido a que sus primeras aplicaciones tuvieron que ver con la recogida y cuantificación de información referente al estado: censos de población, ejército, cosechas, impuestos, etc.

También se ha utilizado para referirse a los métodos que tratan la información. Sin embargo, cabe destacar que existe una diferencia entre lo que se entiende por método estadístico y datos estadístico (información). En resumen podríamos decir que:

La estadística es un cuerpo de conceptos y métodos empleados para recolectar e interpretar datos referentes a un área de investigación particular y para extraer conclusiones en situaciones en que la incertidumbre y la variabilidad están presentes.

El término estadística se ha utilizado en tres ámbitos

1. Estadística como enumeración de datos.
2. Estadística como descripción, es decir, a través de un análisis de conjuntos coherentes de datos para su posterior comprensión y análisis.
3. Estadística matemática o inferencia, unida a la teoría de probabilidades. Se encarga de extraer conclusiones a partir de una muestra al total de la población con un pequeño margen de error.

Por tanto otra definición podría ser: La ciencia que permite estudiar las regularidades o patrones en un conjunto de datos para tomar decisiones racionales.

1.1. Historia de la Estadística

Los comienzos de la estadística pueden ser hallados en el antiguo Egipto, cuyos faraones lograron recopilar, hacia el año 3050 antes de Cristo, prolijos datos relativos a la población y riqueza del país. De acuerdo con el historiador griego Heródoto, dicho registro de riqueza y población se hizo con el objetivo de preparar la construcción de las pirámides. En el mismo Egipto, Ramsés II hizo un censo de las tierras con el objeto de verificar un nuevo reparto.

En el antiguo Israel la Biblia da referencias, en el libro de los Números, de los datos estadísticos obtenidos en dos recuentos de la población hebrea. El rey David por otra parte, ordenó a Joab, general del ejército hacer un censo de Israel con la finalidad de conocer el número de la población.

También en China efectuaron censos hace más de cuarenta siglos. Los griegos efectuaron censos periódicamente con fines tributarios, sociales (división de tierras) y militares (cálculo de recursos y hombres disponibles). La investigación histórica revela que se realizaron 69 censos para calcular los impuestos, determinar los derechos de voto y ponderar la potencia guerrera.

Pero fueron los romanos, maestros de la organización política, quienes mejor supieron emplear los recursos de la estadística. Cada cinco años realizaban un censo de la población y sus funcionarios públicos tenían la obligación de anotar nacimientos, defunciones y matrimonios, sin olvidar los recuentos periódicos del ganado y de las riquezas contenidas en las tierras conquistadas. Para el nacimiento de Cristo sucedía uno de estos empadronamientos de la población bajo la autoridad del imperio.

Durante los mil años siguientes a la caída del imperio Romano se realizaron muy pocas operaciones Estadísticas, con la notable excepción de las relaciones de tierras pertenecientes a la Iglesia, compiladas por Pipino el Breve en el 758 y por Carlomagno en el 762 DC. Durante el siglo IX se realizaron en Francia algunos censos parciales de siervos. En Inglaterra, Guillermo el Conquistador recopiló el Domesday Book o libro del Gran Catastro para el año 1086, un documento de la propiedad, extensión y valor de las tierras de Inglaterra. Esa obra fue el primer compendio estadístico de Inglaterra. Aunque Carlomagno, en Francia; y Guillermo el Conquistador, en Inglaterra, trataron de revivir la técnica romana, los métodos estadísticos permanecieron casi olvidados durante la Edad Media.

Durante los siglos XV, XVI, y XVII, autores como Leonardo de Vinci, Nicolás Copérnico, Galileo, Neper, William Harvey, Sir Francis Bacon y René Descartes, hicieron grandes operaciones al método científico, de tal forma que cuando se crearon los Estados Nacionales y surgió como fuerza el comercio internacional existía ya un método capaz de aplicarse a los datos económicos.

Para el año 1532 empezaron a registrarse en Inglaterra las defunciones debido al temor que Enrique VII tenía por la peste. Más o menos por la misma época, en Francia la ley exigió a los clérigos registrar los bautismos, fallecimientos y matrimonios. Durante un brote de peste que apareció a fines de la década de 1500, el gobierno inglés comenzó a publicar estadística semanales de los decesos. Esa costumbre continuó muchos años, y en 1632 estos Bills of Mortality (Cuentas de Mortalidad) contenían los nacimientos y fallecimientos por sexo. En 1662, el capitán John Graunt usó documentos que abarcaban treinta años y efectuó predicciones sobre el número de personas que morirían de varias enfermedades y sobre las proporciones de nacimientos de varones y mujeres que cabría esperar.

El trabajo de Graunt, condensado en su obra *Natural and Political Observations ... Made upon the Bills of Mortality* (Observaciones Políticas y Naturales ... Hechas a partir de las Cuentas de Mortalidad), fue un esfuerzo innovador en el análisis estadístico.

Por el año 1540 el alemán Sebastián Muster realizó una compilación estadística de los recursos nacionales, comprensiva de datos sobre organización política, instrucciones sociales, comercio y poderío militar. Durante el siglo XVII aportó indicaciones más concretas de métodos de observación y análisis cuantitativo y amplió los campos de la inferencia y la teoría Estadística. Los eruditos del siglo XVII demostraron especial interés por la Estadística Demográfica como resultado de la especulación sobre si la población aumentaba, decrecía o permanecía estática.

En los tiempos modernos tales métodos fueron resucitados por algunos reyes que necesitaban conocer las riquezas monetarias y el potencial humano de sus respectivos países. El primer empleo de los datos estadísticos para fines ajenos a la política tuvo lugar en 1691 y estuvo a cargo de Gaspar Neumann, un profesor alemán que vivía en Breslau. Este investigador se propuso destruir la antigua creencia popular de que en los años terminados en siete moría más gente que en los restantes, y para lograrlo hurgó pacientemente en los archivos parroquiales de la ciudad. Después de revisar miles de partidas de defunción pudo demostrar que en tales años no fallecían más personas que en los demás. Los procedimientos de Neumann fueron conocidos por el astrónomo inglés Halley, descubridor del cometa que lleva su nombre, quien los aplicó al estudio de la vida humana. Sus cálculos sirvieron de base para las tablas de mortalidad que hoy utilizan todas las compañías de seguros.

Durante el siglo XVII y principios del XVIII, matemáticos como Bernoulli, Francis Maseres, Lagrange y Laplace desarrollaron la teoría de probabilidades. No obstante durante cierto tiempo, la teoría de las probabilidades limitó su aplicación a los juegos de azar y hasta el siglo XVIII no comenzó a aplicarse a los grandes problemas científicos. Godofredo Achenwall, profesor de la Universidad de Gotinga, acuñó en 1760 la palabra estadística, que extrajo del término italiano *statista* (estadista). Creía, y con sobrada razón, que los datos de la nueva ciencia serían el aliado más eficaz del gobernante consciente. La raíz remota de la palabra se halla, por otra parte, en el término latino *status*, que significa estado o situación; Esta etimología aumenta el valor intrínseco de la palabra, por cuanto la estadística revela el sentido cuantitativo de las más variadas situaciones.

Jacques Quételet es quien aplica las Estadísticas a las ciencias sociales. Este interpretó la teoría de la probabilidad para su uso en las ciencias sociales y resolver la aplicación del principio de promedios y de la variabilidad a los fenómenos sociales. Quételet fue el primero en realizar la aplicación práctica de todo el método Estadístico, entonces conocido, a las diversas ramas de la ciencia.

Entretanto, en el período del 1800 al 1820 se desarrollaron dos conceptos matemáticos fundamentales para la teoría Estadística; la teoría de los errores de observación, aportada por Laplace y Gauss; y la teoría de los mínimos cuadrados desarrollada por Laplace, Gauss y Legendre. A finales del siglo XIX, Sir Francis Gaston ideó el método conocido por Correlación, que tenía por objeto medir la influencia relativa de los factores sobre las variables. De aquí partió el desarrollo del coeficiente de correlación creado por Karl Pearson y otros cultivadores de la ciencia biométrica como J. Pease Norton, R. H. Hooker y G. Udny Yule, que

efectuaron amplios estudios sobre la medida de las relaciones.

Los progresos más recientes en el campo de la Estadística se refieren al ulterior desarrollo del cálculo de probabilidades, particularmente en la rama denominada indeterminismo o relatividad, se ha demostrado que el determinismo fue reconocido en la Física como resultado de las investigaciones atómicas y que este principio se juzga aplicable tanto a las ciencias sociales como a las físicas.

1.2. Estadística Descriptiva

La descripción de la información es el objetivo de la Estadística Descriptiva. Para llevar a cabo esta tarea nos apoyaremos fundamentalmente en las representaciones gráficas de dichos datos y en su síntesis mediante medidas que resuman las características más relevantes.

Se pueden distinguir, fundamentalmente, dos tipo de fenómenos:

Fenómenos causales o determinísticos: Son aquellos que presentan los mismos resultados si se realizan en idénticas condiciones. (Por ejemplo las reacciones químicas)

Fenómenos aleatorios o estadísticos: Son los que no se pueden predecir el resultado aunque sean conocidas las condiciones de realización. (Por ejemplo el lanzamiento de un dado) Fenómenos de naturaleza social, económica, . . . , en los que la incertidumbre de su comportamiento se debe también a la imposibilidad de repetirlos en las mismas condiciones, son tratados como fenómenos estadísticos.

El área de la cual los datos estadísticos son recopilados es generalmente referida como la población o universo. Una población puede ser finita o infinita. Una población finita tiene un número limitado de individuos u objetos, mientras que una población infinita tiene un número ilimitado.

La tarea de recopilar un conjunto completo de datos de una población finita pequeña es relativamente simple. Sin embargo, recopilar tales datos de una población finita pero grande, es algunas veces imposible o impráctico.

A fin de evitar la tarea imposible o impráctica, usualmente se extrae una muestra de los elementos representativos de la población. La muestra es utilizada para el estudio estadístico y los resultados de la muestra son usados como las bases para describir, estimar o predecir las características de la población.

Entre otras muchas razones para restringir el estudio de muestras se destaca:

- Rapidez. Por ejemplo, las elecciones.
- Evitar la destrucción de la población. Como control de calidad.
- Economía y precisión. El estudio de una población completa puede llevar a cometer muchos errores, mientras que en una muestra se puede dedicar más atención a la calidad de los datos.

1.3. Variables Estadísticas

Se utiliza el término variable (variable estadística) para referirse a una característica o cualidad de un individuo que está propensa a adquirir diferentes

valores. La variable estadística, de acuerdo con las características que la definen, puede ser cualitativa o cuantitativa.

Variable Cualitativa

Una variable cualitativa es un tipo de variable estadística que describe las cualidades, circunstancias o características de un objeto o persona, sin hacer uso de números.

De esta manera, las variables cualitativas permiten expresar una característica, atributo, cualidad o categoría no numérica. Por ejemplo, el sexo de una persona es una variable cualitativa, ya que es masculino o femenino.

Definición 13.1 (Características de las variables cualitativas) *Algunas características notables de la variable cualitativa son las siguientes:*

- *No se puede medir numéricamente.*
- *No otorga datos específicos y a veces tampoco un orden.*
- *Especifica una condición, cualidad o característica.*
- *Cuando los valores de dicha variable son solamente dos, se llama dicotómica.*
- *Cuando distingue tres valores o más, se la llama politómica.*

Tipos de variables cualitativas *La variable cualitativa puede ser nominal, ordinaria o binaria.*

Nominal *Variable que no es representada por números ni tiene algún tipo de orden, y por lo tanto es matemáticamente menos precisa. Por ejemplo, son variables nominales los colores: negro, azul, rojo, amarillo, naranja, etc.*

Ordinaria *La variable cualitativa ordinaria, también conocida como variable cuasicuantitativa, es representada por una modalidad que no requiere números pero sí consta de un orden o un puesto. Por ejemplo, el nivel socioeconómico: alto, medio, bajo.*

Binaria *La variable cualitativa binaria trabaja con valores específicos del tipo binario. Por ejemplo, el sexo de una persona será masculino o femenino.*

Observación 13.1 (Ejemplos de variables cualitativas) *Algunos ejemplos que nos pueden ayudar a comprender la variable cualitativa son los siguientes:*

Estado civil: *soltera/o, casada/o, viuda/o.*

La sed de una persona: *mucha, poca, nada.*

Calificación no numérica de un examen: *aprobado, sobresaliente, aceptado, reprobado.*

Color de ojos: *marrones, azules, verdes.*

Profesión: *arquitecto, médico, ingeniero, abogado.*

Variables Cuantitativas

Las variables cuantitativas son aquellas variables estadísticas que otorgan, como resultado, un valor numérico.

Por ejemplo, variables tales como el peso (62 kg, 80 kg), la altura (1.72 cm, 1.85 cm) o la cantidad de miembros en una familia (2, 3 o 4), son variables cuantitativas.

Definición 13.2 (Características de las variables cuantitativas) *Las principales características de las variables cuantitativas son las siguientes:*

- *Expresan sus valores con números.*
- *Son utilizadas generalmente en encuestas o entrevistas.*
- *Utilizan gráficos llamados diagramas integrales y diagramas diferenciales para mostrar la frecuencia relativa de las variables.*
- *También pueden servirse de diagramas de barra para otorgar cifras.*

Tipos de las variables cuantitativas

Las variables cuantitativas pueden ser discretas o continuas.

Definición 13.3 (Discreta) *La variable discreta otorga cifras que se encuentran separadas en escalas, es decir que no poseen valores entre ellas, sino que el resultado comprende un valor exacto.*

De esta manera, dichas variables solo pueden adquirir un valor en números enteros. Por ejemplo, una persona puede tener 1, 2, 3 o más perros, pero no un perro y medio.

Definición 13.4 (Continua) *Una variable continua es un tipo de variable cuantitativa que puede expresar una cantidad infinita de valores, sin importar que sea un valor intermedio. Es decir, es aquella variable cuyo valor puede encontrarse entre dos valores exactos, generalmente representados por números decimales. Esta variable estadística se contrapone a la variable discreta, que solo puede adquirir como valor un conjunto de números. Una persona tiene un perro, 2 camas o 3 hijos (variable discreta), pero nunca tendrá 2 y medio. Sin embargo, si hablamos de tazas de sal, podríamos decir que tenemos una taza y media de sal; así también que algo mide 1 metro 82 centímetros o que se demora 1:15 horas en entregar un pedido. Estas son variable continuas. La variable continua es infinitesimal, y por esto sirve para medir y presentar los valores con mayor exactitud. Además, una variable continua puede incluir valores exactos, por ejemplo una taza de sal o una taza y media de sal.*

Diferencias entre cualitativas y cuantitativas

Los valores de las variables cualitativas se expresan en cualidades o características, mientras que los valores que aportan las variables cuantitativas son numéricos. Las variables cualitativas se concentran en la naturaleza de tales realidades y su dinámica, mientras que las variables cuantitativas se concentran en determinar la fuerza que tienen las variables. Aunque ambas se utilizan para

determinar un proceso estadístico o económico, las variables cualitativas otorgan un valor general (aunque específico cuando se trata de cualidades), mientras que el resultado de las variables cuantitativas es específico y no da margen de duda.

1.4. Tablas Estadísticas

Una vez recogidos los datos se procede a su descripción con la finalidad de obtener el mayor conocimiento acerca del fenómeno.

El primer paso de esta descripción consiste en la ordenación, clasificación, recuento y representación de los datos. Posteriormente se procede a resumirlos en cantidades que miden características del fenómeno.

Ejemplo 13.1 *Un estudio sobre el grupo sanguíneo en un bloque de pisos ha sido:*

RH de la sangre		Grupo Sanguíneo	
Positivo	56	A	23
Negativo	14	B	14
Total	70	AB	25
		0	8
		Total	70

Ejemplo 13.2 *Para conocer el estudio/hora del alumnado de un determinado bootcamp se ha observado una muestra de 100 alumnos. Los datos se han recogido en la siguiente tabla*

Estudio/hora	
0-10	25
10-20	40
20-40	20
40-50	15
Total	100

A estas representaciones numéricas se denominan tablas estadísticas.

Estas tablas estadísticas recogen la siguiente información: las **Modalidades**, x_i valores que ha presentado el fenómeno de forma individual o agrupadas en **intervalos** y las **frecuencias absolutas** de cada modalidad o intervalo, n_i , número de veces que se ha observado esa modalidad o valores del intervalo. El número total de observaciones, n , se obtiene sumando todas las frecuencias absolutas (lo que se ha llamado total en los ejemplos 26.1 y 13.2)

$$\sum_{i=1}^k n_i = n$$

A las tablas estadísticas se le puede añadir más información, como:

La frecuencia relativa de la modalidad o intervalo i , f_i , es el cociente de la frecuencia absoluta sobre el total de observaciones:

$$f_i = \frac{n_i}{n}$$

Ejemplo 13.3 *si continuamos el ejemplo 13.2, la frecuencia relativa sería*

Estudio/hora	f_i
0-10	0.25
10-20	0.4
20-40	0.2
40-50	0.15

A menudo las frecuencias relativas se multiplican por 100 para expresar en tanto por ciento la medida en que se presenta cada modalidad o intervalo de valores.

La frecuencia absoluta acumulada de la modalidad o intervalo i , N_i , es el número de veces que se han observado los valores menores o iguales que dicha modalidad o intervalo.

$$N_i = \sum_{j=1}^i n_j$$

Análogamente se define la frecuencia relativa acumulada, F_i , a partir de las frecuencias relativas.

$$\begin{aligned} F_i &= \sum_{j=1}^i f_j \\ &= \frac{N_i}{n} \\ &= \frac{\sum_{j=1}^i n_j}{n} \end{aligned}$$

Ejemplo 13.4 *si continuamos el ejemplo 13.3, obtendríamos la siguiente tabla*

Estudio/hora	f_i	N_i	F_i
0-10	0.25	25	0.25
10-20	0.4	65	0.65
20-40	0.2	85	0.85
40-50	0.15	100	1

Tabla de Frecuencias

Se denomina tabla de frecuencias o distribución de frecuencias al conjunto de valores que presenta una variable estadística juntos con sus frecuencias.

La tabla de frecuencias es una herramienta que permite ordenar los datos de manera que se presentan numéricamente las características de la distribución de un conjunto de datos o muestra.

Construcción de la Tabla de Frecuencias

Cabe distinguir entre:

- Tabla de frecuencias con datos no agrupados.
- Tabla de frecuencias con datos agrupados.

Observación 13.2 (Construcción de una tabla de frecuencias con datos no agrupados)

Para construir una tabla de frecuencias con datos no agrupados se seguirán los siguientes pasos:

1. *En la primera columna se ordenan de menor a mayor los diferentes valores que tiene la variable en el conjunto de datos.*
2. *En las siguientes columnas (segunda y tercera) se ponen las frecuencias absolutas y las frecuencias absolutas acumuladas.*
3. *Las columnas cuarta y quinta contienen las frecuencias relativas y las frecuencias relativas acumuladas.*
4. *Adicionalmente (opcional) se pueden incluir dos columnas (sexta y séptima), representando la frecuencia relativa y la frecuencia relativa acumulada como tanto por cien. Estos porcentajes se obtienen multiplicando las dos frecuencias por cien.*

Construcción de una tabla de frecuencias con datos agrupados Se emplea cuando hay un número alto de datos. Estos se agrupan en intervalos o clases para facilitar su tabulación y análisis. Está indicado para representarlos en un histograma.

Como en el caso anterior, se utiliza tanto para variables cuantitativas como en variables cualitativas ordinales.

Los pasos iniciales para formar una tabla de frecuencias con datos agrupados están encaminados a determinar el número de intervalos y definirlos (siempre que no se conozcan de antemano). Los pasos son:

1. Obtener el rango R de los datos. Es la diferencia entre el dato mayor y el menor del conjunto de valores que toma la variable a tabular. Se llama también amplitud total. Ésta se representa según el siguiente modelo donde no todas las columnas son necesarias y su posición puede cambiarse.

$$R = X_{max} - X_{min}$$

2. Fijar cuántos intervalos o clases se desea. Se tiende a que el número de clases sea impar y que esté entre 5 y 15. Hay dos maneras de hacerlo:
 - A criterio del investigador.
 - Mediante el método de Sturges, que emplea la siguiente fórmula:

$$n_{int} = 1 + 3,322 \log N$$

Donde n_{int} es el número de intervalos, el logaritmo es natural o base 10 y N es el número total de datos. El resultado se redondea al número entero más próximo.

3. Determinar la amplitud del intervalo o clase I: Es el resultado de dividir el rango R o amplitud total por el número de clases o intervalos n_{int} que se han fijado:

$$I = \frac{R}{n_{int}}$$

El valor obtenido en esta división no tiene porqué ser un número entero. En ese caso, se redondearía al valor entero más próximo. Los dos redondeos, el que se haya podido hacer en el número de intervalos n_{int} y el de la amplitud del intervalo I modificarán el valor de la amplitud total o rango, apareciendo un nuevo valor ajustado, con los valores definitivos, repartiendo la diferencia entre R' y R entre los dos extremos del rango:

$$R' = I \times n_{int}$$

4. Formar los diferentes intervalos o clases, partiendo del valor mínimo del nuevo rango R' . Cada intervalo tendrá unos extremos a y b separados por la amplitud de clase o intervalo I. En variables continuas, normalmente los intervalos son cerrados por la izquierda y abiertos por la derecha, $[a, b)$ en el que b no pertenece a este intervalo si no que es el valor mínimo del intervalo siguiente. En variables discretas ordinales o en variables continuas en los que el procedimiento de medición no pueda apreciar más allá de un valor entero, los intervalos o clases serán cerrados por los extremos $[a, b]$.
5. Cada intervalo está representado por la llamada marca de clase. Es la media entre sus extremos:

$$x_i = \frac{L_{i-1} + L_i}{2}$$

se representa según el siguiente modelo donde no todas las columnas son necesarias y su posición puede cambiarse

$L_{i-1} - L_i$	x_i	n_i	N_i	f_i	F_i
$L_0 - L_1$	x_1	n_1	N_1	f_1	F_1
$L_1 - L_2$	x_2	n_2	N_2	f_2	F_2
...	...	...	...	...	...
$L_{k-1} - L_k$	x_k	n_k	N_k	f_k	F_k
		n		1	

Ejemplo 13.5 Usando los datos de los ejemplos 26.1 y 13.2

x_i	n_i	f_i
Positivo	56	0.8
Negativo	14	0.2
Total	70	1

x_i	n_i	N_i	f_i	F_i
A	23	23	0,33	0,33
B	14	37	0,20	0,53
AB	25	62	0,36	0,89
0	8	70	0,11	1,00
Total	70		1	

$L_{i-1} - L_i$	x_i	n_i	N_i	f_i	F_i
0 - 10	5	25	25	0,25	0,25
10 - 20	15	40	65	0,40	0,60
20 - 40	30	20	85	0,20	0,85
40 - 50	45	15	100	0,15	1
Total		100			

Nota: en las variables de tipo continuo cada intervalo de valores o clase esta representado por su punto medio o marca de clase x_i

1.5. Representaciones Gráficas

Aunque es cierto que una tabla estadística contiene toda la información observada de un fenómeno, es conveniente en ocasiones traducir toda esa información en un gráfico que nos permita realizar una rápida síntesis visual. Un gráfico es una representación visual figurativa que describe conceptos y relaciones. Los gráficos estadísticos plasman datos conceptuales o numéricos y muestran la relación que estos datos poseen entre sí. Existen múltiples tipos de gráficos según el tipo de información que se quiera volcar. Por ejemplo: gráficos de barras, gráficos circulares, gráficos de dispersión. Los gráficos son una herramienta fundamental en la estadística. Condensan una gran cantidad de información en un espacio reducido, lo que facilita la lectura y asimilación de los datos de manera más rápida y simple. Pueden transmitir información administrativa, demográfica, científica, tecnológica. Por ejemplo: los resultados de elecciones de autoridades nacionales o provinciales, las ventas de una empresa, los datos de un censo poblacional.

Gráfico de barras

En los gráficos de barras o columnas a cada valor del eje X le corresponde un valor del eje Y que determina el alto de una columna. La longitud de la barra nos informa de la frecuencia con que se ha observado cada valor de la variable.

Las principales características del diagrama de barras son:

- En el eje de abscisas se colocan las cualidades de la variable, si la variable es cualitativa, o los valores de dicha variable, si es discreta.
- En el eje de ordenadas se colocan las barras proporcionales a la frecuencia relativa o absoluta del dato.
- Las barras pueden ser horizontales o verticales, según si los valores de la variable se reflejan en el eje horizontal o vertical.

- Todas las barras deben tener el mismo ancho y no deben superponerse las unas con las otras.

Ejemplo 13.6 *Un estudio sobre el numero de habitaciones en una gran ciudad aporta los siguientes datos Su programación en python si se quisiera la*

x_i	n_i
1	7
2	14
3	21
4	21
5	7

representación gráfica sería:

```
import matplotlib.pyplot as plt
import numpy as np
x=np.array([1,2,3,4,5])
n=np.array([7,14,21,21,7])
plt.bar(x,n)
```




Figura 13.1: Gráfico de Barras

Histograma

En esta representación y en la siguiente es el área de las figuras utilizadas (rectángulos o sectores) la que nos indica con qué frecuencia se observa cada clase o modalidad. El histograma es entonces un gráfico que permite mostrar cómo se distribuyen los datos de una muestra estadística o de una población. Esto, respecto a alguna variable numérica.

En el histograma se suelen usar barras, cuya altura dependerá de la frecuencia de los datos, que corresponde al eje Y. En tanto, en el eje X podemos observar la variable de estudio.

Se utiliza cuando se estudia una variable continua, como franjas de edades o altura de la muestra, y, por comodidad, sus valores se agrupan en clases, es decir, valores continuos. En los casos en los que los datos son cualitativos, es preferible un diagrama de sectores.

Construcción de un histograma

1. Determinar el rango de los datos. Rango es igual al dato mayor menos el dato menor
2. Obtener los números de clases, existen varios criterios para determinar el número de clases (o barras) -por ejemplo la regla de Sturges-. Sin embargo ninguno de ellos es exacto. Algunos autores recomiendan de cinco a quince clases, dependiendo de cómo estén los datos y cuántos sean. Un criterio usado frecuentemente es que el número de clases debe ser aproximadamente a la raíz cuadrada del número de datos. Por ejemplo, la raíz cuadrada de 30 (número de artículos) es mayor que cinco, por lo que se seleccionan seis clases.
3. Establecer la longitud de clase: es igual al rango dividido por el número de clases.
4. Construir los intervalos de clases: Los intervalos resultan de dividir el rango de los datos en relación al resultado del PASO 2 en intervalos iguales.
5. Graficar el histograma: En caso de que las clases sean todas de la misma amplitud, se hace un gráfico de barras, las bases de las barras son los intervalos de clases y altura son la frecuencia de las clases. Si se unen los puntos medios de la base superior de los rectángulos se obtiene el polígono de frecuencias.

Ejemplo 13.7 Continuando con el ejemplo 13.2 Su programación en python si

$L_{i-1} - L_i$	n_i	a_i	h_i
0 - 10	25	10	2,5
10 - 20	40	10	4
20 - 40	20	20	1
40 - 50	15	10	1,5

se quisiera la representación gráfica sería:

```
import matplotlib.pyplot as plt
from bokeh.plotting import figure
from bokeh.io import show
x = [1,1,2,3,3,5,7,8,9,10,
     1,1,2,3,3,5,7,8,9,10,
     1,1,2,3,3,
     10,11,11,13,13,15,16,17,18,18,
     14,14,19,13,13,15,16,17,18,18,
     10,13,19,13,13,15,16,17,18,18,
     10,11,11,13,13,15,16,17,18,18,
     25,25,26,26,26,27,27,27,27,27,
     29,30,30,31,33,34,34,34,35,36,
     40,41,41,42,41,
     43,44,45,45,46,47,48,48,49,50]

frecuencias, bordes = np.histogram(x, bins=[0,10,20,40,50])
# creamos la figura
histograma = figure(title='Histograma de horas de estudio ',
                    x_axis_label='Horas',
                    y_axis_label='Frecuencia')
# añadimos las subdivisiones al eje X
histograma.xaxis.ticker = bordes
# añadimos los rectángulos que representan las barras del histograma
histograma.quad(bottom=0, top=frecuencias,
                left=bordes[:-1], right=bordes[1:],
                fill_color='#F2AB6D', line_color='black')
show(histograma)
```

Pirámide de Población

La pirámide de población es una forma gráfica de representar datos estadísticos básicos, sexo y edad, de la población de un país, que permite las comparaciones internacionales y una fácil y rápida percepción de varios fenómenos demográficos tales como el envejecimiento de la población, el equilibrio o desequilibrio entre sexos, e incluso el efecto demográfico de catástrofes y guerras.




Figura 13.2: Histograma

Ejemplo 13.8 Si se quiere analizar por rango de edad y sexo de la población española en el año 2020, se tiene que: Su programación en python si se quisiera

Edad	Hombres	Mujeres
0-4	1018039	963653
5-9	1196380	1129063
10-14	1297635	1225863
15-19	1232566	1156455
20-24	1207902	1152765
25-29	1308197	1275776
30-34	1421558	1417845
35-39	1702135	1688865
40-44	2024303	1971909
45-49	1968659	1926866
50-54	1828015	1840434
55-59	1652558	1712299
60-64	1410111	1502563
65-69	1153768	1270544
70-74	1020478	1191698
75-79	773823	974046
80-84	513692	759379
85-89	361702	634714
90-94	133032	302885
95-99	27305	84007
+100	3732	13576

la representación gráfica sería:

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
```

1. VARIABLES ESTADÍSTICAS. TABLAS ESTADÍSTICAS

```
df = pd.DataFrame({'Edad': ['0-4', '5-9', '10-14', '15-19',  
    '20-24', '25-29', '30-34', '35-39',  
    '40-44', '45-49', '50-54', '55-59',  
    '60-64', '65-69', '70-74', '75-79',  
    '80-84', '85-89', '90-94', '95-99', '100+'],  
    'Hombre': [-1018039, -1196380, -1297635, -1232566,  
    -1207902, -1308197, -1421558, -1702135,  
    -2024303, -1968659, -1828015, -1652558,  
    -1410111, -1153768, -1020478, -773823,  
    -513692, -361702, -133032, -27305, -3732],  
    'Mujer': [963653, 1129063, 1225863, 1156455,  
    1152765, 1275776, 1417845, 1688865,  
    1971909, 1926866, 1840434, 1712299,  
    1502563, 1270544, 1191698, 974046,  
    759379, 634714, 302885, 84007, 13576]})  
  
AgeClass = ['100+', '95-99', '90-94', '85-89', '80-84',  
    '75-79', '70-74', '65-69', '60-64',  
    '55-59', '50-54', '45-49', '40-44',  
    '35-39', '30-34', '25-29', '20-24',  
    '15-19', '10-14', '5-9', '0-4']  
  
bar_plot = sns.barplot(x='Hombre', y='Edad', data=df, order=AgeClass)  
  
bar_plot = sns.barplot(x='Mujer', y='Edad', data=df, order=AgeClass)  
  
bar_plot.set(xlabel="Poblacion Española", ylabel="Edad-Grupo",  
    title = "Piramide Poblacional")  
plt.xticks(rotation=30)
```




Figura 13.3: Pirámide Poblacional

Diagrama de Sectores

Un diagrama de sectores es un gráfico que consiste en un círculo dividido en sectores de amplitud proporcional a la frecuencia de cada valor. Se utiliza con datos cualitativos y cuantitativos.

En un diagrama de sectores los datos se representan en un círculo dividido en sectores, de modo que el ángulo de cada sector es proporcional a la frecuencia absoluta correspondiente.

$$\alpha = \frac{2\pi}{N} \times f_i$$

Ejemplo 13.9 Se va a representar el diagrama de sectores de las elecciones a la Comunidad de Madrid del año 2021

Partido	Numero Votos
PP	1620213
Mas Madrid	614660
PSOE	610190
VOX	330660
Unidas Podemos	261010
Otros	147383

```
import matplotlib.pyplot as plt
Votos = [1620213,614660,610190,330660,261010,147383]
Partidos = ["PP","Mas Madrid","PSOE","Vox","Unidas Podemos","Otros"]
plt.pie(Votos, labels=Partidos, autopct="%0.1f %%")
plt.axis("equal")
plt.title("Elecciones Comunidad de Madrid 2021")
plt.show()
```



Figura 13.4: Diagrama de sectores

2. Momentos Centrados y No Centrados

El estudio de una gran cantidad de datos individuales de una población puede ser farragoso e inoperativo, por lo que se hace necesario realizar un resumen que permita tener una idea global de la población, compararla con otras, comprobar su ajuste a un modelo ideal, realizar estimaciones sobre datos desconocidos de la misma y, en definitiva, tomar decisiones. A estas tareas contribuyen de modo esencial los parámetros estadísticos.

Los momentos son unos valores calculados a partir de la distribución de frecuencias que resumen la información relativa a alguna propiedad de la variable. Como se verá adelante, la media aritmética y la varianza son casos particulares de momentos que resumen el valor global y la dispersión de los valores que presenta la variable estadística.

Otros momentos serán utilizados para medir ciertas características relativas a la forma de la distribución de frecuencias.

En la práctica utilizaremos momentos de órdenes uno a cuatro.

2.1. Momentos no Centrados

Se definen los momentos no centrados (o respecto al origen) como:

Observación 13.3 (para tablas con frecuencias)

$$\begin{aligned}a_r &= \frac{1}{n} \sum_{i=1}^k x_i^r n_i \\ &= \sum_{i=1}^k x_i^r f_i\end{aligned}$$

Observación 13.4 (para tablas sin frecuencias)

$$a_r = \frac{1}{n} \sum_{i=1}^k x_i^r$$

Definición 13.5 (Propiedades) *Se puede concluir que:*

- El momento no centrado a_1 se conoce también como media (aritmética) y se suele notar como $\bar{x}$
- $a_0 = 1$

2.2. Momentos Centrados

Se definen los momentos centrados (o respecto a la media) como:

Observación 13.5 (para tablas con frecuencias)

$$\begin{aligned}m_r &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^r n_i \\ &= \sum_{i=1}^k (x_i - \bar{x})^r f_i\end{aligned}$$

Observación 13.6 (para tablas sin frecuencias)

$$a_r = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^r$$

Definición 13.6 (Propiedades) Las propiedades de los momentos centrados son:

- El momento centrado m_2 se conoce también como varianza y se suele notar como S^2 .
- $m_0=1, m_1=0$
-

$$\begin{aligned} m_2 &= \frac{\sum_{i=1}^k (x_i - \bar{x})^2 n_i}{n} \\ &= \frac{\sum_{i=1}^k x_i^2 n_i}{n} + \frac{\sum_{i=1}^k \bar{x}^2 n_i}{n} - \frac{\sum_{i=1}^k 2x_i \bar{x} n_i}{n} \\ &= \frac{\sum_{i=1}^k x_i^2 n_i}{n} + \bar{x}^2 \frac{\sum_{i=1}^k n_i}{n} - \bar{x} \frac{\sum_{i=1}^k x_i n_i}{n} \\ &= a_2 + \bar{x}^2 - 2\bar{x}a_1 \\ &= a_2 + a_1^2 - 2a_1a_1 = a_2 - a_1^2 \end{aligned}$$

- Análogamente, desarrollando el correspondiente binomio elevado a r , cualquier momento centrado puede escribirse en función de los momentos no centrados. Señalamos por su importancia los casos $r=2$ y $r=3$.

$$\begin{aligned} m_3 &= a_3 - 3a_2a_1 + 2a_1^3 \\ m_4 &= a_4 - 4a_3a_1 + 6a_2a_1^2 - 3a_1^4 \end{aligned}$$

2.3. Cálculo de Momentos

Para facilitar la obtención de los momentos, los cálculos se disponen en una tabla como sigue:

Momentos no centrados

Ejemplo 13.10 Tabla sin frecuencias

x_i	x_i^2	x_i^3	x_i^4
3	9	27	81
3	9	27	81
2	4	8	16
2	4	8	16
3	9	27	81
5	25	125	625
18	60	222	900

$$\begin{aligned}\bar{x} = a_1 &= \frac{1}{n} \sum_{i=1}^k x_i = \frac{18}{6} = 3 \\ a_2 &= \frac{1}{n} \sum_{i=1}^k x_i^2 = \frac{60}{6} = 10 \\ a_3 &= \frac{1}{n} \sum_{i=1}^k x_i^3 = \frac{222}{6} = 37 \\ a_4 &= \frac{1}{n} \sum_{i=1}^k x_i^4 = \frac{900}{6} = 150\end{aligned}$$

Ejemplo 13.11 *Tabla con frecuencias. Variable discreta continuando el ejemplo 13.6*

x_i	n_i	$x_i n_i$	$x_i^2 n_i$	$x_i^3 n_i$	$x_i^4 n_i$
1	7	7	7	7	7
2	14	28	56	112	224
3	21	63	189	567	1701
4	21	84	336	1344	5376
5	7	35	175	875	4375
total	n=70	217	763	2905	11683

$$\begin{aligned}\bar{x} = a_1 &= \frac{1}{n} \sum_{i=1}^k x_i n_i = \frac{217}{70} = 3.1 \\ a_2 &= \frac{1}{n} \sum_{i=1}^k x_i^2 n_i = \frac{763}{70} = 10.9 \\ a_3 &= \frac{1}{n} \sum_{i=1}^k x_i^3 n_i = \frac{2905}{70} = 41.5 \\ a_4 &= \frac{1}{n} \sum_{i=1}^k x_i^4 n_i = \frac{11683}{70} = 166.9\end{aligned}$$

Ejemplo 13.12 *Tabla con frecuencias. Variable continua continuando el ejemplo 13.2*

$L_{i-1} - L_i$	x_i	n_i	$x_i n_i$	$x_i^2 n_i$	$x_i^3 n_i$	$x_i^4 n_i$
0-10	5	25	125	625	3125	15625
10-20	15	40	600	9000	135000	2025000
20-40	30	20	600	18000	540000	16200000
40-50	45	15	675	30375	1366875	61509375
total		100	2000	58000	2045000	79750000

$$\begin{aligned}\bar{x} = a_1 &= \frac{1}{n} \sum_{i=1}^k x_i n_i = \frac{2000}{100} = 20 \\ a_2 &= \frac{1}{n} \sum_{i=1}^k x_i^2 n_i = \frac{58000}{100} = 580 \\ a_3 &= \frac{1}{n} \sum_{i=1}^k x_i^3 n_i = \frac{2045000}{100} = 20450 \\ a_4 &= \frac{1}{n} \sum_{i=1}^k x_i^4 n_i = \frac{79750000}{100} = 797500\end{aligned}$$

Momentos Centrados

Ejemplo 13.13 *Tabla sin frecuencias*

x_i	$x_i - \bar{x}$	$x_i^2 - \bar{x}$	$x_i^3 - \bar{x}$	$x_i^4 - \bar{x}$
3	0	0	0	0
3	0	0	0	0
2	-1	1	-1	1
2	-1	1	-1	1
3	0	0	0	0
5	2	4	8	16
total	0	6	6	18

$$\begin{aligned}m_1 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x}) = \frac{0}{6} = 0 \\ m_2 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 = \frac{6}{6} = 1 \\ m_3 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^3 = \frac{6}{6} = 1 \\ m_4 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^4 = \frac{18}{6} = 3\end{aligned}$$

Otra forma de haber calculado estos momentos es a partir de los momentos no centrados como se ha visto en las propiedades 13.6.

El momento centrado de orden 2 (varianza) se suele calcular así

$$\begin{aligned}S^2 &= m_2 = a_2 - a_1^2 \\ &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \\ &= 10 - 3^2 = 1\end{aligned}$$

Dado que los cálculos para tablas con frecuencias son análogos para variables discretas y continuas, incluimos un solo ejemplo de momentos centrados con frecuencias.

Ejemplo 13.14 *Tabla con frecuencias. Variable continua*

$L_{i-1} - L_i$	x_i	n_i	$(x_i - \bar{x})$	$(x_i - \bar{x})n_i$	$(x_i - \bar{x})^2 n_i$	$(x_i - \bar{x})^3 n_i$	$(x_i - \bar{x})^4 n_i$
0-10	5	25	-15	-375	5625	-84375	1265625
10-20	15	40	-5	-200	1000	-5000	25000
20-40	30	20	10	200	28000	20000	200000
40-50	45	15	25	375	9375	234375	58859375
total		100		0	18000	165000	7350000

$$m_1 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x}) n_i = \frac{0}{100} = 0$$

$$m_2 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 n_i = \frac{18000}{100} = 180$$

$$m_3 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^3 n_i = \frac{165000}{100} = 1650$$

$$m_4 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^4 n_i = \frac{7350000}{100} = 73500$$

Otra forma de haber calculado estos momentos es a partir de los momentos no centrados como se ha visto en las propiedades 13.6.

El momento centrado de orden 2 (varianza) se suele calcular así

$$\begin{aligned}
 S^2 &= m_2 = a_2 - a_1^2 \\
 &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \\
 &= 580 - 20^2 = 180
 \end{aligned}$$

3. Medidas de Posición

Las medidas de posición son indicadores estadísticos que permiten resumir los datos en uno solo, o dividir su distribución en intervalos del mismo tamaño.

Las medidas de posición, por tanto, sirven para medir y para dividir.

De esta forma, unos resumirán los diferentes valores en uno que, en este caso, sea representativo. Por ejemplo, un promedio. Mientras los otros dividirán el conjunto de los datos en partes iguales, más sencillas de interpretar; se estaría hablando de los cuantiles.

3.1. Importancia de las medidas de posición

Son el primer paso que debe darse en el análisis descriptivo. Cuando se quiere conocer información sobre un fenómeno.

Pero estos, por sí mismos, no aportan información relevante, por eso hay que analizarlos. Las medidas de posición, junto con las de dispersión, ayudan a agruparlos e incluso, a codificarlos.

Las distintas medias, la moda y la mediana tratan de representar mediante un solo valor a un conjunto de datos y suelen tomar una posición central respecto de los mismos, motivo por el que son conocidas como medidas de posición central.

3.2. Media Aritmética

Es el promedio más familiar y utilizado en los más diversos ámbitos, aunque no es el único ni el más adecuado en todas las ocasiones. Se define como:

tablas con frecuencia

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^k x_i n_i \\ &= \sum_{i=1}^k x_i f_i\end{aligned}$$

tablas sin frecuencia

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i$$

Coincide con el momento no centrado $a_1 = \bar{x}$

Ejemplo 13.15 *Siguiendo el ejemplo 13.6*

x_i	n_i	$x_i n_i$
1	7	7
2	14	28
3	21	63
4	21	84
5	7	35
total	70	217

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i = \frac{217}{70} = 3.1$$

Ejemplo 13.16 *Siguiendo el ejemplo 13.2*

$L_{i-1} - L_i$	x_i	n_i	$x_i n_i$
0-10	5	25	125
10-20	15	40	600
20-40	30	20	600
40-50	45	15	675
total		100	2000

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i = \frac{2000}{100} = 20$$

Definición 13.7 (Propiedades de la media aritmética) *Las propiedades de la media aritmética son:*

- Si se consideran n observaciones agrupadas en s conjuntos de datos con $n_1, \dots, n_s$ observaciones cada uno y con medias $\bar{x}_1, \dots, \bar{x}_s$, respectivamente, entonces la media $\bar{x}$ de las n observaciones es:

$$\begin{aligned} \bar{x} &= \frac{\bar{x}_1 n_1 + \dots + \bar{x}_s n_s}{n_1 + \dots + n_s} \\ &= \frac{1}{n} \sum_{i=1}^s \bar{x}_i n_i \end{aligned}$$

- Con frecuencia se dividen o multiplican los valores de la variables por una constante, ex_i (**cambio de escala**), por ejemplo cuando se decide expresar los valores en millones de euros en lugar de en euros (en dólares en lugar de euros, etc). En otras ocasiones se suma o resta una constante a los valores de la variable, $x_i + c$ (**cambio de origen**). Si se realiza una o ambas transformaciones sobre la variable original se obtiene una nueva variable, $y_i = ex_i + c$, cuya media está relacionada con la media de la variable de partida según:

$$\bar{y} = e\bar{x} + c$$

Demostración

$$\begin{aligned} \bar{y} &= \frac{1}{n} \sum_{i=1}^s y_i n_i \\ &= \frac{1}{n} \sum_{i=1}^s (ex_i + c) n_i \\ &= \frac{1}{n} \sum_{i=1}^s ex_i n_i + \frac{1}{n} \sum_{i=1}^s cn_i \\ &= e \frac{1}{n} \sum_{i=1}^s x_i n_i + c \frac{1}{n} \sum_{i=1}^s n_i \\ &= e\bar{x} + c \end{aligned}$$

Ejemplo 13.17 Las notas del examen de matemáticas de 15 alumnos son las siguientes: 5, 3, 9, 7, 3, 6, 7, 5, 8, 7, 5, 4, 7, 6 y 8. Calcular la media

$$\begin{aligned}\bar{x} &= \frac{5 + 3 + 9 + 7 + 3 + 6 + 7 + 5 + 8 + 7 + 5 + 4 + 7 + 6 + 8}{15} \\ &= \frac{90}{15} = 6\end{aligned}$$

La programación en python sería:

```
import numpy as np
notas = [5, 3, 9, 7, 3, 6, 7, 5, 8, 7, 5, 4, 7, 6, 8]
np.mean(notas)
```

Ejercicio 13.1 Programe una función en python que calcule la media de cualquier vector

3.3. Media Geométrica

La media geométrica es un tipo de media que se calcula como la raíz del producto de un conjunto de números estrictamente positivos.

La media geométrica se calcula como un producto conjunto. Es decir, que todos los valores se multiplican entre sí. De modo que si uno de ellos fuera cero, el producto total sería cero. Por ello, se debe siempre tener en cuenta que a la hora de calcular la media geométrica que se necesitan números que sean únicamente positivos.

Uno de sus principales usos es para calcular medias sobre porcentajes, pues su cálculo ofrece unos resultados más adaptados a la realidad. es decir, en aquellos casos en los que la variable representa variaciones acumulativas. La media geométrica es menor que la media aritmética calculada sobre los mismos datos.

Definición 13.8 (Propiedades) Las propiedades que tiene son

1. El logaritmo de la media geométrica es igual a la media aritmética de los logaritmos de los valores de la variable.
2. La media geométrica de un conjunto de números positivos es siempre menor o igual que la media aritmética:

$$(x_1 \dots x_n)^{\frac{1}{n}} \leq \frac{x_1 + \dots + x_n}{n}$$

La igualdad sólo se alcanza si $x_1 = x_2 = \dots = x_n$

Observación 13.7 (Para tablas con frecuencias)

$$\begin{aligned}G &= \sqrt[n]{\prod_{i=1}^k x_i^{n_i}} \\ &= \sqrt[n]{x_1^{n_1} \dots x_k^{n_k}}\end{aligned}$$

Observación 13.8 (Para tablas sin frecuencias)

$$\begin{aligned} G &= \sqrt[n]{\prod_{i=1}^n x_i} \\ &= \sqrt[n]{x_1 \dots x_n} \end{aligned}$$

Ejemplo 13.18 *El valor de la vivienda ha sufrido en los últimos 5 años los siguientes incrementos. Obtenga el incremento anual medio del valor de la*

incremento
6 %
5 %
17 %
20 %
14 %

vivienda en estos cinco años.

Una vivienda cuyo valor fuese V_0 al comienzo de estos cinco años alcanzaría un valor:

$$V_1 = V_0 + \frac{6}{100}V_0 = 1,06 \times V_0$$

al final del primer año se transformaría en

$$\begin{aligned} V_2 &= V_1 + \frac{5}{100}V_1 = 1,05 \times V_1 \\ &= 1,05 \times (1,06V_0) \end{aligned}$$

después de transcurrir dos años.

Así sucesivamente, al final de los cinco años

$$\begin{aligned} V_5 &= V_4 + \frac{14}{100}V_4 = 1,14 \times V_4 \\ &= 1,14 \times 1,2 \times 1,17 \times 1,05 \times 1,06 \times V_0 \\ &= 1,7814V_0 \end{aligned}$$

Luego ha habido un incremento del precio de la vivienda en los últimos cinco años del 78,14 %

El incremento medio anual sería aquel valor r en tanto por uno tal que si se hubiera observado durante todo el periodo (últimos 5 años) ese incremento constante, el resultado habría sido el mismo

$$1,14 \times 1,2 \times 1,17 \times 1,05 \times 1,06 \times V_0 = (1+r) \times (1+r) \times (1+r) \times (1+r) \times (1+r) \times V_0$$

por tanto

$$\begin{aligned} (1+r)^5 &= 1,14 \times 1,2 \times 1,17 \times 1,05 \times 1,06 \\ 1+r &= \sqrt[5]{1,14 \times 1,2 \times 1,17 \times 1,05 \times 1,06} \\ r &= \sqrt[5]{1,7814} - 1 \\ r &= 1,1224 - 1 = 0,1224 \end{aligned}$$

Por tanto la rentabilidad media es de 12,24 %

Observación 13.9 $1 + r$ es la media geométrica de los valores $1 + r_i$, donde r_i es el incremento en cada año expresado en tanto por uno.

Teniendo en cuenta que

$$1,14 \times 1,2 \times 1,17 \times 1,05 \times 1,06 = \frac{V_5}{V_0}$$

otra forma de expresar r es

$$r = \sqrt[5]{\frac{V_5}{V_0}} - 1$$

o en general para n años

$$r = \sqrt[n]{\frac{V_n}{V_0}} - 1$$

Utilizaremos esto último cuando se desconozcan los incrementos anuales (6 %, 5 %, ...) pero se conozcan los valores inicial (V_0) y final (V_n) del bien que se esté analizando

Observación 13.10 La media aritmética no es adecuada en este contexto como puede verse

$$\bar{r} = \frac{0,06 + 0,05 + 0,17 + 0,20 + 0,14}{5} = 0,124$$

Según la media aritmética habría un incremento del valor de la vivienda en los 5 años de $(1,124)^5 = 1,794$ es decir, un 79,4 %, que no se corresponde con la realidad del ejemplo 13.18 (78,14 %).

Ejemplo 13.19 Una vivienda que en el año 2000 se compró por 125.000 euros se ha vendido en el año 2007 por 500.000 euros. Otra vivienda que se compró en 1995 por 100.000 euros se vendió en el 2006 por 700.000 euros. ¿Cuál de las viviendas incrementó más su valor?

Demostración Se utilizará en el incremento anual medio observado en el valor de cada vivienda

$$\begin{aligned} \sqrt[7]{\frac{V_{2007}}{V_{2000}}} &= \sqrt[7]{\frac{500000}{125000}} \\ &= \sqrt[7]{4} = 1,219 \end{aligned}$$

El incremento anual medio es del 21,9 %

$$\begin{aligned} \sqrt[11]{\frac{V_{2006}}{V_{1995}}} &= \sqrt[11]{\frac{700000}{100000}} \\ &= \sqrt[11]{7} = 1,1935 \end{aligned}$$

El incremento anual medio es del 19,35 % La primera vivienda experimentó un incremento anual medio del 21,9 % en su valor mientras que la segunda experimentó un incremento menor, 19,35 %.

3.4. Media Armónica

La media armónica es igual al número de elementos de un grupo de cifras entre la suma de los inversos de cada una de estas cifras.

En otras palabras, la media armónica es una medida estadística recíproca a la media aritmética, que es la suma de un conjunto de valores entre el número de observaciones.

La media armónica resulta poco influida por la existencia de determinados valores mucho más grandes que el conjunto de los otros, siendo en cambio sensible a valores mucho más pequeños que el conjunto.

La media armónica no está definida en el caso de que exista algún valor nulo.

Ésta no tiene un uso muy extenso en el mundo científico. Suele utilizarse principalmente para calcular la media de velocidades, tiempos o en electrónica.

Definición 13.9 (Propiedades) *Las propiedades que tiene son*

1. *La inversa de la media armónica es la media aritmética de los inversos de los valores de la variable.*
2. *Siempre se puede pasar de una media armónica a una media aritmética transformando adecuadamente los datos.*
3. *La media armónica siempre es menor o igual que la media aritmética, ya que para cualesquiera números reales positivos $x_i > 0$*

$$\frac{n}{\frac{1}{x_1} + \dots + \frac{1}{x_n}} \leq \frac{x_1 + \dots + x_n}{n}$$

Observación 13.11 (Para tablas con frecuencias)

$$H = \frac{n}{\sum_{i=1}^k \frac{n_i}{x_i}}$$

Observación 13.12 (Para tablas sin frecuencias)

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Ejemplo 13.20 *Si se sube en bicicleta a Sierra Nevada a una velocidad de 10 Km/h y se baja a una velocidad de 60 Km/h, a qué velocidad media se ha hecho el recorrido completo de ida y vuelta. Suponga que la distancia desde la casa del ciclista a Sierra Nevada es de 30 Km. **Demostración** Si se calcula la media aritmética, se obtiene*

$$\bar{x} = \frac{10 + 60}{2} = 35 \text{ Km/h}$$

que no es la solución.

Entendiendo por velocidad media aquella velocidad constante a la que si se realizara el recorrido se tardaría lo mismo, claramente 35 Km/h no lo cumple.

$$\frac{30 + 30}{35} = 1,7143h$$

mientras que se ha tardado $\frac{30}{10} = 3h$ en subir y $\frac{30}{60} = 0,5h$ en bajar, en total 3 horas y media.

La solución sería la media armónica

$$\begin{aligned} H &= \frac{2}{\sum_{i=1}^2 \frac{1}{x_i}} \\ &= \frac{2}{\frac{1}{10} + \frac{1}{60}} \\ &= \frac{2}{0,10 + 0,0167} \\ &= 17,1429 Km/h \end{aligned}$$

A esta velocidad media se tardaría $\frac{30+30}{17,1429} = 3,49999h$, es decir, 3,5h (la diferencia que se observa es debida a los errores de redondeo), lo que realmente se ha tardado en la subida y bajada.

Observación 13.13 Utilizando el valor de las distancias recorridas, la media se hubiera calculado como

$$\begin{aligned} H &= \frac{2}{\sum_{i=1}^2 \frac{1}{x_i}} \\ &= \frac{2}{\frac{1}{10} + \frac{1}{60}} \\ &= \frac{60}{\frac{30}{10} + \frac{30}{60}} \end{aligned}$$

y en general

$$\begin{aligned} H &= \frac{D}{\sum_{i=1}^k \frac{d_i}{v_i}} \\ &= \frac{D}{\frac{d_1}{v_1} + \dots + \frac{d_k}{v_k}} \\ &= \frac{\text{distancia total}}{\text{tiempo total como suma de los tiempos parciales}} \end{aligned}$$

Ejemplo 13.21 Una agencia inmobiliaria ha vendido las siguientes viviendas

Precio	Superficie	precio/ m^3
240000	60	4000
180000	90	2000
420000	100	4200

Cual ha sido el precio medio al que ha vendido el metro cuadrado.
Demostración

n_i	$\frac{n_i}{x_i}$	x_i
240000	60	4000
180000	90	2000
420000	100	4200
840000	250	

$$\begin{aligned} H &= \frac{n}{\sum_{i=1}^k \frac{n_i}{x_i}} \\ &= \frac{840000}{250} \\ &= 3360 \end{aligned}$$

3.5. Moda

Es el valor que se presenta con más frecuencia. Se nota Mo. Puede haber varias modas. Para variables discretas y atributos su cálculo es inmediato. En las variables continuas la mayor o menor frecuencia de las observaciones en un intervalo depende en parte de su amplitud, por lo que para calcular la moda consideraremos las frecuencias observadas en conjuntos de igual amplitud (amplitud unidad). Dentro del intervalo modal (el de mayor frecuencia por unidad de amplitud, mayor altura en el histograma) hay que seleccionar un punto como moda, para lo cual no hay un único criterio. Señalaremos tres criterios diferentes que notaremos como Mo(I), Mo(II) y Mo(III). Uno de ellos consiste en tomar el punto medio o marca de clase:

$$Mo(I) = \frac{L_{i-1} + L_i}{2} = x_i$$

Otro criterio sitúa la moda a una distancia de los extremos del intervalo proporcional a las alturas de los intervalos anterior y posterior al intervalo modal:

$$Mo(II) = L_{i-1} + \frac{h_{i+1}}{h_{i-1} + h_{i+1}} \times a_i$$

Y el tercero tiene en cuenta un procedimiento gráfico para situar la moda dentro del intervalo modal:

$$Mo(III) = L_{i-1} + \frac{h_i - h_{i-1}}{(h_i - h_{i-1}) + (h_i - h_{i+1})} \times a_i$$

En las expresiones anteriores L_{i-1} es el extremo inferior del intervalo modal, a_i la amplitud del intervalo modal y h_i la altura del intervalo modal (h_{i-1} la altura del intervalo anterior, h_{i+1} la altura del intervalo posterior).

Ejemplo 13.22 Continuando con los ejemplo 26.1, 13.2 y 13.6 para calcular la moda se tiene que

x_i	n_i
1	7
2	14
3	21
4	21
5	7

Mo=3 Mo=4

RH de la sangre	
Positivo	56
Negativo	14
Total	70

Mo=Positivo

$L_{i-1} - L_i$	n_i	a_i	h_i
0-10	25	10	2,5
10-20	30	10	3
20-40	40	20	2
40-50	15	10	1,5
total	100		

Intervalo modal= 10 - 20

Dentro del interval modal hay que seleccionar un punto como moda.

Hay diversos criterios

$$Mo(I) = \frac{L_{i-1} + L_i}{2} = \frac{10 + 20}{2} = 15$$

$$\begin{aligned} Mo(II) &= L_{i-1} + \frac{h_{i+1}}{h_{i-1} + h_{i+1}} \times a_i \\ &= 10 + \frac{2}{2,5 + 2} \times 10 = 14,44 \end{aligned}$$

$$\begin{aligned} Mo(III) &= L_{i-1} + \frac{h_i - h_{i-1}}{(h_i - h_{i-1}) + (h_i - h_{i+1})} \times a_i \\ &= 10 + \frac{3 - 2,5}{(3 - 2,5) + (3 - 2)} \times 10 = 13,33 \end{aligned}$$

su programación en python sería:

```
import statistics
set1 =[1, 2, 3, 3, 4, 4, 4, 5, 5, 6]
statistics.mode(set1)
```

3.6. Mediana

Es aquel valor, se nota como **Me**, que divide a la muestra ordenada en dos partes iguales, es decir, hay el mismo número de datos menores que la mediana como mayores que ella.

Para ello se debe ordenar todos los datos, de menor a mayor, la mediana es el valor que ocupa la posición central. Si hay un número impar de observaciones, la mediana es el único valor central

Ejemplo 13.23 5, 10, 30, 40, 50
por tanto $Me=30$

Si hay un número par de observaciones, la mediana es el punto medio de los dos valores centrales

Ejemplo 13.24 5, 10, 30, 45

$$Me = \frac{10 + 30}{2} = \frac{40}{2} = 20$$

Si tenemos los datos representados en una tabla estadística la mediana se calcula buscando el valor que deja por debajo de él una frecuencia acumulada igual a $\frac{n}{2}$

Ejemplo 13.25 Para variables discretas buscamos en la columna de frecuencias absolutas acumuladas el valor $\frac{n}{2}$ O bien como otro ejemplo, para

x_i	n_i	N_i
1	7	7
2	14	21
3	14	35
4	28	63
5	7	70
	70	

Pudiendo ocurrir que hay un $N_i = \frac{n}{2}$, en cuyo caso la mediana es:

$$Me = \frac{x_i + x_{i+1}}{2} = \frac{3 + 4}{2} = 3,5$$

todos los $N_i \neq \frac{n}{2}$. Entonces se busca el primer $N_i > \frac{n}{2}$ En variables continuas

x_i	n_i	N_i
1	7	7
2	14	21
3	21	42
4	21	63
5	7	70
	70	

siendo la modalidad x_i , asociada a esa frecuencia acumulada el valor que se toma como mediana, $Me = 3$

$L_{i-1} - L_i$	n_i	N_i
0-10	20	20
10- 20	30	50
20-40	35	85
40-50	15	100
total	100	

$N_i = \frac{n}{2}$ La mediana es el extremo superior del intervalo donde se alcanza la mitad de las observaciones.

$$Me = L_i = 20$$

$L_{i-1} - L_i$	n_i	N_i
100-110	25	25
110- 120	40	60
120-140	20	85
140-150	15	100
total	100	

Todos los $N_i \neq \frac{n}{2}$ La mediana está en el intervalo donde por primera vez $N_i > \frac{n}{2}$ y se calcula mediante:

se distinguen las mismas dos posibilidades:

$$\begin{aligned}
 Me &= L_{i-1} + \frac{\frac{n}{2} - N_{i-1}}{n_i} \times a_i \\
 &= 110 + \frac{50 - 25}{40} \times 10 \\
 &= 116,25
 \end{aligned}$$

que es el resultado de repartir homogéneamente las 40 observaciones sobre la amplitud 10 del intervalo. Según la tabla, hasta 110 hay una frecuencia acumulada de 25, hasta 120 hay una frecuencia acumulada de 65 (por tanto 40 observaciones entre 110 y 120), luego el valor Me hasta el que hay una frecuencia acumulada de $\frac{n}{2} = 50$ estará entre 110 y 120. Si las observaciones se reparten homogéneamente en el intervalo, la distancia entre la mediana y el extremo inferior del intervalo será proporcional al número de observaciones entre dichos valores

$$\frac{120 - 110}{Me - 110} = \frac{40}{50 - 25} \Rightarrow \frac{120 - 110}{40} \times (50 - 25) = Me - 110$$

$\frac{120-110}{40} =$ Amplitud entre cada una de las 40 observaciones del intervalo 110-120.

$(50 - 25) =$ Número de observaciones en el intervalo 110-Me. Despejando el valor Me se obtiene la anterior expresión para la mediana

$$\begin{aligned}\frac{10}{Me - 110} &= \frac{40}{50 - 25} \Rightarrow \\ \frac{Me - 110}{10} &= \frac{50 - 25}{40} \Rightarrow \\ Me - 110 &= \frac{50 - 25}{40} \times 10 \Rightarrow \\ Me &= 110 + \frac{50 - 25}{40} \times 10\end{aligned}$$

su programación en python sería:

```
import statistics
set1=[1, 2, 3, 3, 4, 4, 4, 5, 5, 6]
statistics.median(set1)
```

3.7. Percentiles

Estas medidas $(P_1, \dots, P_{99})$ o $(C_1, \dots, C_{99})$ dividen a la muestra ordenada en 100 conjuntos con igual número de observaciones, $\frac{n}{100}$ habiendo por tanto $\alpha \frac{n}{100}$ observaciones menores que P_α . La mediana coincide con P_{50} . Salvo este percentil, el resto de percentiles ocupan una posición no central respecto de los datos de la muestra, propiedad por la que reciben la denominación de medidas de posición no central. Otros casos particulares de percentiles son los denominados cuartiles

$$Q_1 = P_{25}, Q_2 = P_{50}, Q_3 = P_{75}$$

que dividen a la muestra en 4 conjuntos con igual número de observaciones, $\frac{n}{4}$ y los deciles

$$D_1 = P_{10}, D_2 = P_{20}, \dots, D_9 = P_{90}$$

que dividen a la muestra en 10 conjuntos con igual número de observaciones, $\frac{n}{10}$.

El cálculo de los percentiles es similar al de la mediana, cambiando $\frac{n}{2} = 50 \frac{n}{100}$ por $\alpha \frac{n}{100}$ dependiendo del percentil, P_α , que se quiera calcular.

En las distribuciones de variables discretas no hay consenso sobre la forma de calcular los percentiles, existiendo en la literatura científica nueve métodos diferentes que conducen a resultados diferentes.

Ejemplo 13.26 Calcule sobre las siguientes tablas los percentiles 30 y 85

x_i	n_i	N_i
1	7	7
2	14	21
3	14	35
4	28	63
5	7	70
	70	

$$\begin{aligned}
30 \frac{n}{100} &= 21 \Rightarrow \\
P_{30} &= \frac{x_i + x_{i+1}}{2} = \frac{2+3}{2} = 2,5 \\
85 \frac{n}{100} &= 59,5 \Rightarrow \\
P_{85} &= 4
\end{aligned}$$

$L_{i-1} - L_i$	a_i	n_i	N_i
100-110	10	25	20
110-120	10	40	60
120-140	20	20	85
140-150	10	15	100
total		100	

$$\begin{aligned}
85 \frac{n}{100} &= 85 \Rightarrow \\
P_{85} &= 140 \\
30 \frac{n}{100} &= 30 \Rightarrow \\
N_i &\neq \alpha \frac{n}{100}
\end{aligned}$$

Entonces P_α esta en el intervalo donde por primera vez $N_i > \alpha \frac{n}{100}$ se calcula con una expresión similar a la de la mediana, sustituyendo $\frac{n}{2}$ por $\alpha \times \frac{n}{100}$ que es el resultado de repartir homogeneamente las observaciones sobre la amplitud del intervalo

$$\begin{aligned}
P_\alpha &= L_{i-1} + \frac{\alpha \frac{n}{100} - N_{i-1}}{n_i} \times a_i \\
P_{30} &= L_{i-1} + \frac{30 \frac{n}{100} - N_{i-1}}{n_i} \times a_i \\
&= 110 + \frac{30 - 25}{40} \times 10 = 111,25
\end{aligned}$$

Ejemplo 13.27 Los saldos de las cuentas abiertas por los clientes de una sucursal bancaria se distribuyen de acuerdo a la siguiente tabla Se consideran

Saldos	Número de clientes
0-200	100
200-1000	400
1000-5000	300
5000-30000	50

clientes preferentes al 10 % de los clientes con mayores saldos, ¿cuál ha de ser el saldo para que un cliente sea considerado como tal? ¿Qué porcentaje de clientes tienen un saldo superior a 900 euros?

Saldos	Número de clientes	N_i
0-200	100	100
200-1000	400	500
1000-5000	300	800
5000-30000	50	850

Solución

$$\begin{aligned}n = 850 &\Rightarrow 90 \times \frac{850}{100} = 765 \\P_{90} &= L_{i-1} + \frac{90 \frac{n}{100} - N_{i-1}}{n_i} \times a_i \\&= 1000 + \frac{765 - 500}{300} \times 4000 = 4533,33\end{aligned}$$

Se considerarán clientes preferentes a los que tienen un saldo superior a 4533,33 euros.

$$\begin{aligned}P_{\alpha} &= L_{i-1} + \frac{\alpha \frac{n}{100} - N_{i-1}}{n_i} \times a_i \\900 &= 200 + \frac{\alpha \frac{850}{100} - 100}{400} \times 800 \\&\Rightarrow \alpha = 52,94\end{aligned}$$

El 52,94 % de los clientes tienen un saldo inferior a 900 euros, por tanto un 47,06 % = (100-52,94) % de clientes tienen un saldo superior a 900 euros.

Considerando el reparto homogéneo de las observaciones en cada intervalo, las anteriores cuestiones se podrían haber resuelto también de la siguiente manera

$$\begin{aligned}\frac{5000 - 1000}{P_{90} - 1000} &= \frac{800 - 500}{765 - 500} \\ \frac{4000}{P_{90} - 1000} &= \frac{300}{265} \\ P_{90} - 1000 &= \frac{4000 \times 265}{300} = 3533,33 \\ P_{90} &= 4533,33\end{aligned}$$

$$\begin{aligned}\frac{1000 - 200}{900 - 200} &= \frac{500 - 100}{x - 100} \\ \frac{800}{700} &= \frac{400}{x - 100} \\ x - 100 &= \frac{400 \times 700}{800} = 350 \\ x &= 450\end{aligned}$$

Hay 450 clientes con un saldo inferior a 900 euros que representan un $\frac{450}{850} \times 100 = 52,94\%$

4. Medidas de Dispersión

Las medidas de dispersión cuantifican la variabilidad o esparcimiento de los datos. Cuando esta dispersión se mide respecto de alguna medida de posición central (por ejemplo, la media) nos indica la mayor o menor representatividad de dicha medida.

4.1. Recorridos

El recorrido o rango R se define como la diferencia entre los valores extremos.

$$R = \text{máximo} - \text{mínimo}$$

Es la medida de dispersión más fácil de calcular pero tiene el inconveniente de que sólo utiliza dos valores (estando sujeta a posibles datos erróneos) por lo que no nos da una medida precisa de la dispersión de todos los datos. El recorrido intercuartílico R_I se define como la diferencia entre el tercer y primer cuartil,

$$R_I = Q_3 - Q_1 = P_{75} - P_{25}$$

representa la amplitud del intervalo donde se encuentra el 50% de las observaciones centrales de la muestra. Con esta medida se evita la fuerte influencia que tienen los valores extremos en el recorrido R . Con la misma idea se pueden definir distintos recorridos utilizando otros percentiles.

4.2. Varianza

La varianza coincide con el momento centrado de orden 2, $S^2 = m_2$. Mide la dispersión o distancia de los datos, x , respecto de la media aritmética, $\bar{x}$.

Observación 13.14 (para tablas con frecuencias)

$$\begin{aligned} m_2 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 n_i \\ &= \sum_{i=1}^k (x_i - \bar{x})^2 f_i \end{aligned}$$

Observación 13.15 (para tablas sin frecuencias)

$$m_2 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2$$

Esta medida está expresada en las unidades de los datos al cuadrado (p.e., m^2 , hab^2 , ...) por lo que no tiene una interpretación fácil.

Con frecuencia se dividen o multiplican los valores de la variable por una constante, ex_i (cambio de escala), por ejemplo cuando decidimos expresar los valores en millones en lugar de en euros (en \$ en lugar de en euros, ...). En otras ocasiones se suma o resta una constante a los valores de la variable, $x_i + c$ (cambio de origen).

Si realizamos una o ambas transformaciones sobre la variable original obtenemos una nueva variable, $y_i = ex_i + c$, cuya varianza está relacionada con la varianza de la variable de partida mediante:

$$S_y^2 = e^2 S_x^2$$

(los cambios de origen en los valores de la variable no afectan al valor de la varianza, pero sí los cambios de escala). **Demostración**

$$\begin{aligned} S_y^2 &= \frac{1}{n} \sum_{i=1}^s (y_i - \bar{y})^2 n_i \\ &= \frac{1}{n} \sum_{i=1}^s (ex_i + c - e\bar{x} - c)^2 n_i \\ &= \frac{1}{n} \sum_{i=1}^s (ex_i - e\bar{x})^2 n_i \\ &= \frac{1}{n} \sum_{i=1}^s (e^2 (x_i - \bar{x})^2) n_i \\ &= \frac{1}{n} \sum_{i=1}^s e^2 (x_i - \bar{x})^2 n_i \\ &= e^2 \frac{1}{n} \sum_{i=1}^s (x_i - \bar{x})^2 n_i \\ &= e^2 S_x^2 \end{aligned}$$

En general, para cualquier momento centrado se tiene que

$$m_r(y) = e^r m_r(x)$$

Definición 13.10 (Propiedades) *Algunas propiedades de la varianza son:*

- *La varianza es un valor siempre positivo.*
- *Si a todos los datos se les suma una constante, la varianza de esos datos sigue siendo la misma.*
- *Si todos los datos se multiplican por una constante, la varianza queda multiplicada por el cuadrado de la constante.*

4.3. Desviación Típica

La desviación típica se define como la raíz cuadrada positiva de la varianza. Tiene el mismo cometido que ésta y además la ventaja de que las unidades en las que se mide son las mismas que las de los datos de la distribución. Puede considerarse la medida de dispersión por excelencia y aparece como tecla o función directa en cualquier calculadora o programa estadístico.

Los cambios de origen en los valores de la variable no afectan al valor de la desviación típica, pero sí los cambios de escala según la expresión

$$S_y = e S_x$$

$L_{i-1} - L_i$	n_i
0-10	1
10-20	2
20-30	3
30-40	4
	10

Ejemplo 13.28 Calcule el rango, la varianza y la desviación típica para la siguiente distribución de frecuencias.

Demostración

$L_{i-1} - L_i$	n_i	x_i	$x_i n_i$	$(x_i - \bar{x})^2$	$(x_i - \bar{x})^2 n_i$
0-10	1	5	5	400	400
10-20	2	15	30	100	200
20-30	3	25	75	0	0
30-40	4	35	140	100	400
	10		250		1000

$$R = 40 - 0 = 40$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i = \frac{250}{10} = 25$$

$$S^2 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 n_i = \frac{1000}{10} = 100$$

$$S = \sqrt{S^2} = \sqrt{100} = 10$$

4.4. Desigualdad de Tchebycheff

La desigualdad de Tchebycheff es uno de los resultados clásicos más importantes de la teoría de probabilidad.

Esta desigualdad nos permite entender mejor el significado de la desviación típica como medida de dispersión.

La aplicación directa de las desigualdades tipo Tchebycheff es el de aproximar probabilidades por medio de cálculo de cotas.

Dado un conjunto de datos con media $\bar{x}$ y desviación típica S , la proporción de datos en el intervalo $(\bar{x} - kS, \bar{x} + kS)$ es mayor o igual que $1 - \frac{1}{k^2}$ ($k > 1$)

$$p[x_i \in (\bar{x} - kS, \bar{x} + kS)] \geq 1 - \frac{1}{k^2}$$

Otra forma equivalente de expresar el mismo resultado, haciendo

$$t = kS \Leftrightarrow k = \frac{t}{S} \Leftrightarrow k^2 = \frac{t^2}{S^2}$$

dice que la proporción de los datos en el intervalo $(\bar{x} - t, \bar{x} + t)$ es mayor o igual que $1 - \frac{S^2}{t^2}$. Por ejemplo, para $k=2$, $(\bar{x} - 2S, \bar{x} + 2S)$, tenemos que alejándonos de la media dos desviaciones típicas, a la derecha e izquierda, abarcaríamos más del 75 % de las observaciones,

$$1 - \frac{1}{k^2} = 1 - \frac{1}{2^2} = 0,75$$

Ejemplo 13.29 *Se sabe que el número medio de unidades diarias de un determinado producto que vende un supermercado es $\bar{x} = 100$ y la desviación típica $S = 40$. Si cada día el supermercado repone hasta completar 200 unidades del producto en sus estanterías:*

- *¿Cuántos días al año la demanda será mayor que su oferta?*
- *¿Cuánto habría que reponer para asegurar que no va a faltar producto en las estanterías el 95 % de los días?*

Demostración $\bar{x} + t = 200 \Rightarrow t = 100 \Rightarrow$ la proporción de observaciones dentro del intervalo $(\bar{x} - t, \bar{x} + t) = (0, 200)$ es mayor o igual que $1 - \frac{S^2}{t^2} = 1 - \frac{1600}{10000} = 0,84$ y por tanto fuera de dicho intervalo (demanda inferior a 0 o superior a 200) la proporción de observaciones es menor o igual a $0,16 = 1 - 0,84$. Es decir, en menos del 16 % de los días la demanda es superior a 200 unidades.

$$\begin{aligned} 1 - \frac{S^2}{t^2} &= 1 - \frac{1600}{t^2} = 0,95 \\ &\Rightarrow \\ \frac{1600}{0,05} &= 32000 = t^2 \\ &\Rightarrow \\ t = 178,9 &\Rightarrow \bar{x} + t \approx 279 \end{aligned}$$

Reponiendo hasta completar 279 unidades en las estanterías aseguramos que más del 95 % de los días no faltará producto en el supermercado.

4.5. Variable Tipificada

Se define la variable X tipificada como la nueva variable obtenida al realizar el siguiente cambio

$$Z = \frac{X - \bar{x}}{S}$$

Esta nueva variable se caracteriza por tener media cero y desviación típica 1. La tipificación de variables se puede utilizar para establecer comparaciones entre valores de dos variables (por ejemplo, las calificaciones de dos alumnos en dos centros diferentes).

Ejemplo 13.30 *Se quiere comparar los precios de dos viviendas con las mismas características, una en Madrid y otra en Granada. El precio medio de las viviendas del tipo considerado es 200.000 euros en Madrid y 140.000 euros en*

Granada, las desviaciones típicas son respectivamente 20.000 euros y 15.000 euros. Las dos viviendas a comparar tienen unos precios de 260.000 euros (Madrid) y 190.000 euros (Granada). ¿cuál de las dos viviendas está alcanzando un mayor valor en su mercado?

Demostración

$$\begin{aligned}\frac{260000 - 200000}{20000} &= \frac{60000}{20000} = 3 \\ \frac{190000 - 140000}{15000} &= \frac{50000}{15000} = 3,33\end{aligned}$$

como $3,33 > 3 \Rightarrow$ por tanto la vivienda de Granada está alcanzando mayor valor en su mercado que la de Madrid.

Una vivienda con las características de la de Granada en Madrid tendría un precio de unos 266.600 euros

$$\begin{aligned}\frac{x - 200000}{20000} &= 3,33 \\ x &= (20000 \times 3,33) + 200000 = 266600\end{aligned}$$

Los recorridos, la varianza y la desviación típica son medidas de dispersión absoluta que dependen de la unidad de medida de la variable (y por tanto les afecta el cambio de escala), lo anterior conlleva que no se puedan comparar estas medidas en dos variables con distinta unidad de medida. En la práctica para evitar este problema se prefiere trabajar con otras medidas de dispersión, obtenidas de las anteriores, que se denominan medidas de dispersión relativa. Las medidas de dispersión relativa son adimensionales (no dependen de la unidad de medida de la variable estadística y por tanto no les afectan los cambios de escala)

4.6. Coeficiente de Variación

El coeficiente de variación, también denominado como coeficiente de variación de Pearson, es una medida estadística que nos informa acerca de la dispersión relativa de un conjunto de datos.

Es decir, nos informa al igual que otras medidas de dispersión, de si una variable se mueve mucho, poco, más o menos que otra.

Su cálculo se obtiene de dividir la desviación típica entre el valor absoluto de la media del conjunto y por lo general se expresa en porcentaje para su mejor comprensión.

$$CV = \frac{S}{|\bar{x}|}$$

El coeficiente de variación se utiliza para comparar conjuntos de datos pertenecientes a poblaciones distintas. Si atendemos a su fórmula, vemos que este tiene en cuenta el valor de la media. Por lo tanto, el coeficiente de variación nos permite tener una medida de dispersión que elimine las posibles distorsiones de las medias de dos o más poblaciones.

Ejemplo 13.31 Las subvenciones, en millones de euros, a las pequeñas empresas en 2016 y 2017 según comunidades autonómicas se recogen en la siguiente tabla

Comunidad Autónoma	2016	2017
ANDALUCIA	42,95	69,15
ARAGON	5,91	19,25
ASTURIAS	2,23	28,5
BALEARES	1,24	12,5
CANARIAS	3,29	25,8
CANTABRIA	7,2	16,25
CASTILLA LA MANCHA	11,02	19,5
CASTILLA LEON	11,15	26,05
CATALUÑA	25,89	58,2
COMUNIDAD VALENCIANA	17,26	58,35
EXTREMADURA	6,08	41,5
GALICIA	6,75	29
MADRID	8,15	13,55
MURCIA	9,78	25,35
NAVARRA	1,84	15,5
PAIS VASCO	7,88	34,35
LA RIOJA	1,38	17,2

¿Se han mantenido las diferencias entre las subvenciones recibidas en 2006 y 2007? Si han variado, indique en qué sentido.

Demostración

Comunidad Autónoma	x_i 2016	$(x_i - \bar{x})^2$	y_i 2017	$(y_i - \bar{y})^2$
ANDALUCIA	42,95	1085,7025	69,15	1532,7225
ARAGON	5,91	16,7281	19,25	115,5625
ASTURIAS	2,23	60,3729	28,5	2,25
BALEARES	1,24	76,7376	12,5	306,25
CANARIAS	3,29	45,0241	25,8	17,64
CANTABRIA	7,2	7,84	16,25	189,0625
CASTILLA LA MANCHA	11,02	1,0404	19,5	110,25
CASTILLA LEON	11,15	1,3225	26,05	15,6025
CATALUÑA	25,89	252,4921	58,2	795,24
COMUNIDAD VALENCIANA	17,26	52,7076	58,35	803,7225
EXTREMADURA	6,08	15,3664	41,5	132,25
GALICIA	6,75	10,5625	29	1
MADRID	8,15	3,4225	13,55	270,6025
MURCIA	9,78	0,0484	25,35	21,6225
NAVARRA	1,84	66,5856	15,5	210,25
PAIS VASCO	7,88	4,4944	34,35	18,9225
LA RIOJA	1,38	74,3044	17,2	163,84
Total	170	1774,752	510	4706,79

$$\begin{aligned}
n &= 17 \\
\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i = \frac{170}{17} = 10 \\
\bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = \frac{510}{17} = 30 \\
S_x^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1774,75}{17} = 104,40 \\
S_y^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{4706,79}{17} = 276,87 \\
S_x &= \sqrt{S_x^2} = 10,22 \\
S_y &= \sqrt{S_y^2} = 16,64 \\
CV_{2016} &= \frac{S_x}{|\bar{x}|} = \frac{10,22}{|10|} = 1,022 \\
CV_{2017} &= \frac{S_y}{|\bar{y}|} = \frac{16,64}{|30|} = 0,555
\end{aligned}$$

Las diferencias entre las subvenciones recibidas por las distintas comunidades autonómicas han disminuido en 2007 en relación al año anterior.

5. Medidas de Forma

Momentos como la media y la varianza nos aportan información sobre la posición y dispersión de los datos. En este apartado, las denominadas medidas de forma cuantifican características observables en la forma de la representación gráfica que nos proporcionan más información sobre el fenómeno en estudio. Hay diversas medidas de forma, las más utilizadas se basan en los momentos.

5.1. Asimetría

Las medidas de asimetría sirven para tener una idea acerca de la forma de una distribución de frecuencias con sólo un número. Por supuesto, para realmente conocer la forma de la distribución es mejor graficarla, pero tener un número que nos permita tomar esta decisión puede ser útil; por ejemplo, si necesitamos que un programa tome una decisión dependiendo de la forma de la distribución.

Observación 13.16 (Coeficiente de asimetría de Fisher) *También conocido como el coeficiente de asimetría basado en momentos se basa en momentos centrales:*

$$\gamma_1 = \frac{m_3}{S^3}$$

Donde S^3 es la desviación típica elevada al cubo y m_r es lo que se conoce como el Momento central de orden r , donde r puede ser cualquier entero positivo y se

calcula se la siguiente manera.

$$m_r = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r$$

El uso de este coeficiente se justifica por el hecho de que en distribuciones simétricas todos los momentos centrados de orden impar son nulos. Es decir, se basa en que en distribuciones simétricas por cada observación a la derecha de la media hay otra a igual distancia a la izquierda, por tanto la expresión:

$$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3 = 0$$

Si la gráfica es asimétrica a la izquierda se rompe el anterior equilibrio entre sumandos positivos y negativos, resultando la suma negativa. Lo mismo ocurre cuando la distribución de frecuencias es asimétrica a la derecha, resultando la suma positiva. El signo del denominador de 1 g es siempre positivo, por tanto:

- Si la distribución es simétrica $\gamma_1 = 0$
- Si la distribución es asimétrica a la izquierda $\gamma_1 < 0$
- Si la distribución es asimétrica a la derecha $\gamma_1 > 0$

El signo de γ_1 lo aporta m_3 , se define dividiendo por S^3 para conseguir que el coeficiente sea una medida adimensional que pueda compararse con la asimetría de otras distribuciones, además también se consigue así que sea independiente de cambios de origen y escala.

5.2. Coeficiente de Curtosis de Fisher

Las medidas de curtosis se utilizan en distribuciones unimodales simétricas o levemente asimétricas para cuantificar la mayor o menor frecuencia de observaciones en torno a la media. La mayor frecuencia de observaciones próximas a la media dará lugar a una representación gráfica más apuntada, la menor frecuencia de observaciones próximas a la media dará lugar a una representación más aplanada. El perfil de apuntamiento que se toma como referencia es el de la conocida campana de Gauss o curva normal.

La medida de apuntamiento más utilizada es el coeficiente de curtosis de Fisher

$$\gamma_2 = \frac{m_4}{S^4} - 3$$

Donde

$$m_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$$

Al igual que el coeficiente de asimetría de Fisher es adimensional e independiente de cambios de origen y escala.

Los valores del coeficiente de curtosis de Fisher se interpretan de la siguiente manera:

- Si la distribución tiene un apuntamiento normal (mesocúrtica) $\gamma_2 = 0$
- Si la distribución es más aplanada que la curva normal (platicúrtica) $\gamma_2 < 0$
- Si la distribución es más apuntada que la curva normal (leptocúrtica) $\gamma_2 > 0$

6. Medidas de Concentración

Las medidas de concentración miden la mayor o menor igualdad en el reparto de una cantidad (por ejemplo, la masa salarial total de una empresa, ...). Ante este problema eminentemente económico, medidas estadísticas como la media, la varianza, ..., no son significativas, por lo que es necesario construir unos indicadores específicos. Debido a la naturaleza de los fenómenos que aquí se consideran, las variables tomarán sólo valores positivos (por éste y otros motivos, no deben hacerse cambios de origen).

La característica que se va a estudiar puede presentar las siguientes situaciones límite:

- Máxima concentración: Cuando un solo individuo recibe la cantidad total a repartir y el resto nada.
- Equidistribución (mínima concentración): Todos los individuos reciben la misma cantidad.

Entre ambas situaciones extremas hay infinidad de situaciones intermedias que trataremos de cuantificar con las siguientes medidas de concentración:

6.1. Curva de Concentración de Lorenz

La curva de Lorenz es una forma gráfica de mostrar la distribución de la renta en una población. En ella se relacionan los porcentajes de población (abscisas) con porcentajes de la renta (ordenadas) que esta población recibe. En la curva de Lorenz en el eje de abscisas, por tanto, se representa la población “ordenada” de forma que los percentiles de renta más baja quedan a la izquierda y los de renta más alta quedan a la derecha. El eje de ordenadas representa las rentas.




Figura 13.5: Curva de concentración de Lorenz

Situación ideal

Cuánto más cerca esté la curva, (línea roja), de la recta que une el $(0,0)$ con el $(1,1)$, mejor estará distribuida la renta, siendo la citada recta la distribución más igualitaria posible, en la que todos los ciudadanos de una población dispondrán exactamente de los mismos ingresos.

De la misma forma, cuanto mayor sea el área que queda entre la citada recta y la curva, mayor será la desigualdad existente.

Ilustraremos la construcción de la curva de Lorenz con un ejemplo.

Ejemplo 13.32 *Estudiar la concentración de los salarios/hora de 25 trabajadores recogidos en la siguiente tabla*

$L_{i-1} - L_i$	n_i
500-1500	3
1500 - 2500	7
2500 - 3500	8
3500 - 4500	4
4500 - 5500	2
5500 - 6500	1

Hacemos los siguientes cálculos Donde:

L_{i-1}	L_i	x_i	n_i	$x_i n_i$	N_i	u_i	p_i	q_i
500	1500	1000	3	3000	3	3000	0,12	0,04
1500	2500	2000	7	14000	10	17000	0,4	0,23
2500	3500	3000	8	24000	18	41000	0,72	0,56
3500	4500	4000	4	16000	22	57000	0,88	0,78
4500	5500	5000	2	10000	24	67000	0,96	0,92
5500	6500	6000	1	6000	25	73000	1	1,00
Total			25				4,08	3,534

- n_i son los trabajadores en cada intervalo.
- $x_i n_i$ es la suma de los salarios de los trabajadores en cada intervalo.
- acumulando los anteriores valores obtenemos N_i y u_i

$$N_i = \sum_{j=1}^i n_j \quad u_i = \sum_{j=1}^i x_j n_j$$

(representan el número de trabajadores y la suma de los salarios de todos los trabajadores hasta el intervalo i)

- por último p_i y q_i son los valores N_i y u_i expresados en porcentajes

$$p_i = \frac{N_i}{n} \quad q_i = \frac{u_i}{\sum_{j=1}^k x_j n_j}$$

(representan el porcentaje de trabajadores y el porcentaje de los salarios de todos los trabajadores hasta el intervalo i)

La curva de Lorenz, por tanto, es la representación gráfica de los puntos con coordenadas (p_i, q_i) , $i = 1, \dots, k$ a los que se le añade el punto $(0, 0)$.

Observación 13.17 (Interpretación de la curva de Lorenz) Si hay un reparto equitativo (todos reciben lo mismo), a un porcentaje p_i de trabajadores le corresponde un porcentaje q_i de la cantidad total repartida igual a p_i . Es decir, los valores p_i son iguales a los valores q_i y la curva de Lorenz coincide con la línea $y = x$ (bisectriz del primer cuadrante).

Cuanto más próximos se esté de esta situación de reparto equitativo más próxima estará la curva de Lorenz de la recta $y = x$, cuanto mayor sea la concentración del reparto más se alejará la curva de Lorenz de dicha línea

6.2. Índice de Gini

El ideólogo y estadístico italiano Corrado Gini (1884-1965), autor de Las bases científicas del fascismo (1927), desarrolló en 1912 un método para medir la desigualdad de una distribución en su obra Variabilità e mutabilità. En ella introdujo el valor de 0 para expresar la igualdad total y el valor de 1 para la máxima desigualdad.

El Coeficiente de Gini se basa en la Curva de Lorenz, que es una representación gráfica de una función de distribución acumulada, y se define matemáticamente como la proporción acumulada de los ingresos totales (eje y), que obtienen las proporciones acumuladas de la población (eje x). La línea diagonal representa la igualdad perfecta de los ingresos: todos reciben la misma renta (el 20 % de la población recibe el 20 % de los ingresos; el 40 % de la población el 40 % de los ingresos, etc). En la situación de máxima igualdad o equidad distributiva, el Coeficiente de Gini es igual a cero (el área A desaparece); a medida que aumenta la desigualdad, el Coeficiente de Gini se acerca al valor de 1.

El índice de Gini cuantifica la anterior propiedad de la curva de Lorenz basándose en la distancia de los puntos (p_i, q_i) $i = 1, \dots, k-1$ y la recta $y = x$

$$\begin{aligned} I_g &= \frac{\sum_{i=1}^{k-1} (p_i - q_i)}{\sum_{i=1}^{k-1} p_i} \\ &= 1 - \frac{\sum_{i=1}^{k-1} q_i}{\sum_{i=1}^{k-1} p_i} \end{aligned}$$

Interpretación del índice de Gini

- Si hay reparto equitativo $p_i = q_i$ entonces $I_G = 0$.
- Si hay máxima concentración $q_i = 0$ $i = 1, \dots, k-1$ $q_k = 1$ entonces $I_G = 1$

Luego el índice de Gini es un valor entre 0 y 1 que mide la concentración, indicando mayor concentración cuanto mayor sea y mayor equidistribución cuanto menor sea.

En el ejemplo 13.32 el índice de Gini vale

$$I_G = 1 - \frac{2,535}{3,08} = 0,1769$$

6.3. Mediala

La mediala o valor medial, Ml , es aquel valor tal que la suma de las observaciones menores que él es igual a la suma de las observaciones mayores que él.

Se trata pues de una mediana sobre los valores x_i n_i en lugar de sobre las frecuencias n_i . Su cálculo se realiza de forma análoga, buscando el valor de la variable asociado a la mitad de la cantidad total repartida $\frac{\sum_{j=1}^k x_j n_j}{2}$ o equivalentemente asociado a $q_i = 50\%$.

Según lo anterior, en variables continuas (valores agrupados en intervalos) la mediala se obtiene de

$$Ml = L_{i-1} + \frac{0,5 - q_{i-1}}{q_i - q_{i-1}} \times a_i$$

La mediala de los datos del ejemplo 13.32 es:

$$Ml = 2500 + \frac{0,5 - 0,233}{0,562 - 0,233} \times 1000 = 3311,55$$

¿De qué forma nos ayuda la mediala a medir la concentración? Si hay equidistribución la mediana y mediala coinciden, separándose más cuanto mayor sea la concentración. Por tanto la respuesta es

$$\Delta M = Ml - Me$$

En el ejemplo 13.32

$$Me = 2500 + \frac{12,5 - 10}{8} \times 1000 = 2812,5 \quad \Delta M = Ml - Me = 499,05$$

El valor ΔM , que depende de la unidad de medida de la variable, se suele relativizar en comparacion con el rango, $\frac{\Delta M}{R}$. En el ejemplo 13.32, $R = 6500 - 500 = 6000$ $\frac{\Delta M}{R} = 0,0832$, que confirma de nuevo lo que ya conocíamos por la curva de Lorenz e índice de Gini de que la concentracion es debil. En el anterior ejemplo hemos visto como sobre una variable continua se calculan las medidas de concentracion, en el siguiente ejemplo lo veremos sobre una variable discreta.

Ejemplo 13.33 *Dos familias con 4 y 5 hijos respectivamente deciden repartir parte de sus patrimonios entre ellos de la siguiente forma.*

Familia A	Familia B
300000	150000
500000	100000
200000	200000
150000	100000
	200000

¿Cuál de los dos repartos es más equitativo?

Demostración Familia A:

x_i	n_i	$x_i n_i$	N_i	u_i	p_i	q_i
1500000	1	1500000	1	1500000	0,25	0,13
2000000	1	2000000	2	3500000	0,5	0,30
3000000	1	3000000	3	6500000	0,75	0,57
5000000	1	5000000	4	11500000	1	1,00
Total	4	11500000			2,5	2,000

$$\begin{aligned}
 I_G(A) &= 1 - \frac{\sum_{i=1}^{k-1} q_i}{\sum_{i=1}^{k-1} p_i} \\
 &= 1 - \frac{0,13 + 0,30 + 0,57}{0,25 + 0,5 + 0,75} \\
 &= 0,334
 \end{aligned}$$

Para obtener la mediana, sencillamente buscamos en la columna de los q_i dónde se supera por primera vez el valor 50 %, $q_3 = 0,57 > 0,5$ $MI(A) = x_3 = 3000000$.

Familia B:

x_i	n_i	$x_i n_i$	N_i	u_i	p_i	q_i
1000000	2	2000000	2	2000000	0,4	0,267
1500000	1	1500000	3	3500000	0,6	0,467
2000000	2	4000000	5	7500000	1	1,000
Total	5	7500000			2	1,733

$$\begin{aligned}
 I_G(B) &= 1 - \frac{\sum_{i=1}^{k-1} q_i}{\sum_{i=1}^{k-1} p_i} \\
 &= 1 - \frac{0,4 + 0,6}{0,267 + 0,467} \\
 &= 0,266
 \end{aligned}$$

Para obtener la mediana, sencillamente buscamos en la columna de los i q donde se supera por primera vez el valor 50 %, $q_3 = 100 > 50$ $MI(B) = x_3 = 200000$. Comparando ambos índices de Gini se observa que es más equitativo el reparto de la familia B

$$I_G(A) = 0,334 > I_G(B) = 0,266$$

CAPÍTULO 14

Variables Estadísticas Bidimensionales

En el capítulo 29 se ha estudiado sobre cada individuo de la muestra sólo el valor que presenta un carácter. En este tema se medirá sobre cada individuo dos caracteres (por ejemplo: salario y edad), estos dos caracteres los notaremos como X e Y . A la variable que representa dicho estudio se denomina variable estadística bidimensional.

Con lo desarrollado en el capítulo 29 se pueden estudiar separadamente la variable X o la variable Y , calculando sus medidas de posición, dispersión, ... Pero lo más importante que se introduce en el estudio de variables estadísticas bidimensionales es el análisis conjunto de ambas variables para conocer la relación entre ellas.

1. Representaciones Numéricas en Dos Columnas y en Tablas de Contingencia

1.1. Dos Columnas

La tabla más sencilla para representar los valores de una variable estadística bidimensional consiste en colocar en dos columnas los pares de valores observados. Es la forma habitual de representarlos en hojas de cálculo y programas de estadística

x_i	y_i
x_1	y_1
x_2	y_2
...	...
x_n	y_n

1.2. Tablas de Contingencia

Una tabla de contingencia es una de las formas más comunes de resumir datos categóricos. En general, el interés se centra en estudiar si existe alguna asociación entre una variable denominada fila y otra variable denominada columna y se calcula la intensidad de dicha asociación.

De manera formal, se consideran X e Y dos variables categóricas con I y J categorías respectivamente. Una observación puede venir clasificada en una de las posibles $I \times J$ categorías que existen.

Cuando las casillas de la tabla contienen las frecuencias observadas, la tabla se denomina tabla de contingencia, término que fue introducido por Pearson en 1904. Una tabla de contingencia (o tabla de clasificación cruzada), con I filas y J columnas se denomina una tabla $I \times J$.

Ejemplo 14.1 *Por ejemplo, se considera la distribución conjunta de dos variables y la correspondiente tabla de contingencia en una muestra de pacientes de un hospital. Se tiene la siguiente tabla donde se consideran el riesgo de ataque al corazón respecto a la toma de aspirinas:*

- $X = \text{Se toma aspirina o placebo } (I = 2).$
- $Y = \text{Se sufre ataque cardíaco o no } (J = 3).$

	Mortal	No Mortal	No Ataque	Total
Placebo	18	171	10845	11034
Aspirina	5	99	10933	11037

Como resumen de la información que presenta la tabla 14.1, de los 11034 enfermos que tomaron un placebo, 18 tuvieron un ataque al corazón, mientras que de los 11037 que tomaron aspirina, 5 tuvieron ataques al corazón.

La distribución conjunta de dos variables categóricas determina su relación. Esta distribución también determina las distribuciones marginales y condicionales.

Ejemplo 14.2 *La distribución según salarios (Y) y edades (X) de un grupo de 100 jóvenes es*

X/Y	500-1000	1000-1500	1500-2000	$n_{i \cdot}$
20	10	3	2	15
21	5	15	5	25
22	2	20	15	37
23	0	13	10	23
$n_{\cdot j}$	17	51	32	100

En general la notación para este tipo de tablas es la siguiente

X/Y			B_1 $L_0^* - L_1^*$ y_1	$\dots$	B_j $L_{j-1}^* - L_j^*$ y_j	$\dots$	B_p $L_{p-1}^* - L_p^*$ y_p	$n_{i\bullet}$
A_1	$L_0 - L_1$	x_1	n_{11}	$\dots$	n_{1j}	$\dots$	n_{1p}	$n_{1\bullet}$
$\dots$			$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
A_i	$L_{i-1} - L_i$	x_i	n_{i1}	$\dots$	n_{ij}	$\dots$	n_{ip}	$n_{i\bullet}$
$\dots$			$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
A_k	$L_{k-1} - L_k$	x_k	n_{k1}	$\dots$	n_{kj}	$\dots$	n_{kp}	$n_{k\bullet}$
$n_{\bullet j}$			$n_{\bullet 1}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet p}$	n

El número de veces que se ha observado el par de valores (x_i, y_j) lo notamos como n_{ij} y se denomina frecuencia absoluta conjunta de dicho par.

La suma de todas las frecuencias absolutas es igual al número de observaciones,

$$\sum_{i=1}^j \sum_{j=1}^p n_{ij} = n$$

La frecuencia relativa conjunta se define a partir de la frecuencia absoluta como $f_{ij} = \frac{n_{ij}}{n}$ donde n es el número total de observaciones. Su suma es igual a la unidad,

$$\sum_{i=1}^j \sum_{j=1}^p f_{ij} = 1$$

Se denomina distribución bidimensional de frecuencias al conjunto de valores $((x_i, y_j), n_{ij}) i = 1, \dots, k \quad j = 1, \dots, p$ Si utilizamos las frecuencias relativas se denomina distribución bidimensional de frecuencias relativas.

1.3. Distribuciones Marginales y Condicionadas. Independencia de Variables Estadísticas

Distribuciones Marginales

Otros valores importantes que aparecen en la tabla de contingencia son: $n_{i\bullet}, i = 1, \dots, k$ y $n_{\bullet j}, j = 1, \dots, p$ conocidos como frecuencias absolutas marginales.

$$n_{i\bullet} = \sum_{j=1}^p n_{ij} \quad n_{\bullet j} = \sum_{i=1}^k n_{ij} \quad \sum_{i=1}^k n_{i\bullet} = \sum_{j=1}^p n_{\bullet j} = n$$

Utilizaremos estas frecuencias que aparecen en la última fila y columna de la tabla de contingencia para estudiar separadamente una variable de la otra. A estas distribuciones de frecuencias se les denominan distribuciones marginales. Para estudiar separadamente una variable de la otra cuando tenemos los datos en dos columnas basta con quedarnos sólo con la columna de datos de dicha variable.

Ejemplo 14.3 La distribución marginal de las edades en el ejemplo 14.2 es La distribución marginal de los salarios en el ejemplo 14.2 es

1. REPRESENTACIONES NUMÉRICAS EN DOS COLUMNAS Y EN TABLAS DE CONTINGENCIA

x_i	$n_{i\bullet}$
20	15
21	25
22	37
23	23
	100

y_j	$n_{\bullet j}$
500 -1000	17
1000 - 1500	51
1500-2000	32
	100

Sobre cada una de estas distribuciones marginales (unidimensionales) se puede estudiar todo lo que sobre distribuciones unidimensionales hemos visto (medias, percentiles, dispersión,...), permitiéndonos un conocimiento individual de cada una de estas variables, por ejemplo,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_{i\bullet} \quad S_x^2 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 n_{i\bullet}$$

$$\bar{y} = \frac{1}{n} \sum_{j=1}^p y_j n_{\bullet j} \quad S_y^2 = \frac{1}{n} \sum_{j=1}^p (y_j - \bar{y})^2 n_{\bullet j}$$

pero si queremos conocer la relación entre dichas variables hemos de analizar la distribución conjunta (bidimensional) de ambas variables X e Y.

Distribuciones Condicionadas

A partir de la representación conjunta de X e Y en la tabla de contingencia también se pueden estudiar las denominadas distribuciones condicionadas cuyo significado se expone con el siguiente ejemplo.

Ejemplo 14.4 *Distribución de los salarios condicionada a que el joven tiene 22 años Distribución de las edades de los jóvenes que tienen un salario mayor*

y_j	$n_{\bullet j}$
500 -1000	2
1000 - 1500	20
1500-2000	15
	37

que 1000 euros pero menor que 1500 euros

Cada columna de frecuencias de la tabla de contingencia (salvo la marginal) determina una distribución condicionada de X. Cada fila de frecuencias de la tabla de contingencia (salvo la marginal) determina una distribución condicionada de Y. A partir de los datos representados en dos columnas no

x_i	$n_{i\bullet}$
20	3
21	15
22	20
23	13
	51

es tan fácil ni inmediata la determinación de las distribuciones condicionadas como en las tablas de contingencia.

Independencia de Variables Estadísticas

Se dice que X e Y son independientes estadísticamente si todas las distribuciones condicionadas coinciden, en otras palabras, las frecuencias relativas de las distribuciones condicionadas son iguales (además también coinciden con las frecuencias relativas marginales). Esto es lo mismo que decir que el comportamiento de X no depende del valor de Y y que el comportamiento de Y tampoco depende del valor de X .

Ejemplo 14.5 *Comprobar si hay independencia estadística entre el salario, X , y el sexo, Y , en el grupo de 49 trabajadores representados en la siguiente tabla*

X/Y	Hombre	Mujer	Total
500-1000	20	8	28
1000-1500	10	4	14
1500-2000	5	2	7

Demostración *Luego hay independencia, el salario no depende del sexo, es*

X/Y	Hombre	Mujer	Total
500-1000	$\frac{20}{35} = 0,5714$	$\frac{8}{14} = 0,5714$	$\frac{28}{49} = 0,5714$
1000-1500	$\frac{10}{35} = 0,2857$	$\frac{4}{14} = 0,2857$	$\frac{14}{49} = 0,2857$
1500-2000	$\frac{5}{35} = 0,1429$	$\frac{2}{14} = 0,1429$	$\frac{7}{49} = 0,1429$

decir, los salarios de los hombres no son distintos de los de las mujeres.

Más cómodo, pero equivalente a comprobar que las frecuencias relativas de las distintas distribuciones condicionadas son iguales, es ver si se cumple

$$n_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n} \quad \forall i, j$$

O equivalentemente

$$\begin{aligned} n_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n} &\iff \frac{n_{ij}}{n} = \frac{n_{i\bullet}}{n} \frac{n_{\bullet j}}{n} \\ &\iff f_{ij} = f_{i\bullet} f_{\bullet j} \quad \forall i, j \end{aligned}$$

Ejemplo 14.6 *Usando esta caracterización de independencia, al trabajar con número enteros, evitamos los posibles errores de redondeo en los decimales de las frecuencias relativas.*


X/Y	Hombre	Mujer	$n_{i\bullet}$
500-1000	$\frac{28 \times 35}{49} = 20$	$\frac{28 \times 14}{49} = 8$	28
1000-1500	$\frac{14 \times 35}{49} = 10$	$\frac{14 \times 14}{49} = 4$	14
1500-2000	$\frac{7 \times 35}{49} = 5$	$\frac{7 \times 14}{49} = 2$	7
$n_{i\bullet}$	35	14	n=49

2. Covarianza y coeficiente de correlación lineal

La representación gráfica más utilizada en el caso bidimensional es la nube de puntos o diagrama de dispersión. Consiste en representar un punto por cada observación, donde las coordenadas del punto coinciden con los valores X e Y.

Ejemplo 14.7 Representación gráfica de nube de puntos

X	Y
3	1
5	2
4	1
6	3
7	3
5	3
4	2
2	1
1	0



La forma de la nube de puntos nos informa sobre la relación entre X e Y. Esta información se cuantifica con el cálculo de la covarianza.

2.1. Covarianza

Se define para datos en tablas de contingencia como

$$S_{xy} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p (x_i - \bar{x})(y_j - \bar{y})n_{ij}$$


y para datos en dos columnas como

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

La covarianza nos da una medida de la variabilidad conjunta y por tanto de la asociación o relación entre las variables X e Y. El signo de la covarianza indica en qué sentido varían conjuntamente las variables. Si la covarianza es positiva las dos variables cambian, en general, en el mismo sentido (si una variable aumenta de valor la otra también aumenta, análogamente si una disminuye la otra hará lo mismo, en este caso decimos que la relación entre las variables es positiva o directa). Si la covarianza es negativa las dos variables cambian, en general, en sentidos opuestos (si una aumenta la otra disminuye, en este caso decimos que la relación entre las variables es negativa o inversa).

Ejemplo 14.8 *Calcule la covarianza para la siguiente tabla de datos e interprete su valor de acuerdo a la representación gráfica. **Demostración***

X	Y
3	1
5	2
4	1
6	3
7	3
5	3
4	2
2	1
1	0
5	1
6	1



Calculamos la tabla para facilitarnos cálculos

2. COVARIANZA Y COEFICIENTE DE CORRELACIÓN LINEAL

	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
	3	1	-1,36	-0,64	0,87
	5	2	0,64	0,36	0,23
	4	1	-0,36	-0,64	0,23
	6	3	1,64	1,36	2,23
	7	3	2,64	1,36	3,60
	5	3	0,64	1,36	0,87
	4	2	-0,36	0,36	-0,13
	2	1	-2,36	-0,64	1,50
	1	0	-3,36	-1,64	5,50
	5	1	0,64	-0,64	-0,40
	6	1	1,64	-0,64	-1,04
Totales	48	18			13,45

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{48}{11} = 4,34 \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{18}{11} = 1,64$$

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{13,45}{11} = 1,22$$

Observemos los cuatro cuadrantes centrados en $(\bar{x}, \bar{y})$. Las observaciones en los cuadrantes 1º y 3º dan lugar a sumandos positivos en la expresión de la covarianza,

$$[(1^\circ) : x_i > \bar{x}, y_i > \bar{y}] [(3^\circ) : x_i < \bar{x}, y_i < \bar{y}] \Rightarrow (x_i - \bar{x})(y_i - \bar{y})$$

debido a que ambas diferencias son de igual signo. Mientras que los puntos en los cuadrantes 2º y 4º (sombreados en gris en la tabla anterior) dan lugar a sumandos negativos al tener dichas diferencias signos contrarios. Cuando la relación entre las variables es directa predominan los puntos en los cuadrantes 1º y 3º, por tanto pesan más los sumandos positivos en la expresión de la covarianza, arrojando ésta un valor positivo (como el caso que nos ocupa). Cuando la relación entre las variables es inversa predominan los puntos en los cuadrantes 2º y 4º provocando un valor negativo de la covarianza.

Una forma más cómoda para el cálculo de la covarianza se obtiene al desarrollar la expresión que la define

$$\begin{aligned}
S_{xy} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \\
&= \frac{1}{n} \sum_{i=1}^n (x_i y_i - \bar{x} y_i - \bar{y} x_i + \bar{x} \bar{y}) = \\
&= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \left(\bar{x} \frac{1}{n} \sum_{i=1}^n y_i \right) - \left(\bar{y} \frac{1}{n} \sum_{i=1}^n x_i \right) + \left(\bar{x} \bar{y} \frac{1}{n} \sum_{i=1}^n 1 \right) = \\
&= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} - \bar{x} \bar{y} + \bar{x} \bar{y} = \\
&= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}
\end{aligned}$$

datos en dos columnas $S_{xy} = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y}$

datos en tablas de contingencia $S_{xy} = \left(\frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p x_i y_j n_{ij} \right) - \bar{x} \bar{y}$

Ejemplo 14.9 Obtenga la covarianza utilizando esta última expresión a partir del ejemplo 14.8

	x_i	y_i	$x_i y_i$
	3	1	3
	5	2	10
	4	1	4
	6	3	18
	7	3	21
	5	3	15
	4	2	8
	2	1	2
	1	0	0
	5	1	5
	6	1	6
Total	48	18	92

$$n = 11 \quad \bar{x} = 4,36 \quad \bar{y} = 1,64$$

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i \bar{x} \bar{y} = \frac{92}{11} - 4,36 \times 1,64 = 1,21$$

Si realizamos un cambio de origen y escala sobre las variables originales X e Y

$$X^* = eX + c \quad Y^* = hY + d$$

la covarianza de las nuevas variables es

$$S_{X^*Y^*} = ehS_{XY}$$

(al valor de la covarianza no le afecta los cambios de origen pero sí los cambios de escala).

Demostración

$$\begin{aligned}
 S_{X^*Y^*} &= \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p (x_i^* - \bar{x}^*)(y_j^* - \bar{y}^*)n_{ij} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p (ex_i + c - e\bar{x} - c)(hy_j + d - h\bar{y} - d)n_{ij} = \\
 &= \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p (ex_i - e\bar{x})(hy_j - h\bar{y})n_{ij} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p e(x_i - \bar{x})h(y_j - \bar{y})n_{ij} = \\
 &= eh \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p (x_i - \bar{x})(y_j - \bar{y})n_{ij} = eh S_{XY}
 \end{aligned}$$

En caso de independencia estadística $\Rightarrow S_{xy} = 0$ (sin embargo, $S_{xy} = 0$ no implica necesariamente que se dé la condición de independencia estadística). Para demostrarlo nos apoyamos en la caracterización de la independencia estadística

$$n_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n}$$

$$\begin{aligned}
 S_{XY} &= \left(\frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p x_i y_j n_{ij} \right) - \bar{x}\bar{y} = \left(\frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p x_i y_j \frac{n_{i\bullet} n_{\bullet j}}{n} \right) - \bar{x}\bar{y} = \\
 &= \left(\frac{1}{n} \sum_{i=1}^k x_i n_{i\bullet} \sum_{j=1}^p y_j \frac{n_{\bullet j}}{n} \right) - \bar{x}\bar{y} = \left(\frac{1}{n} \sum_{i=1}^k x_i n_{i\bullet} \frac{1}{n} \sum_{j=1}^p y_j n_{\bullet j} \right) - \bar{x}\bar{y} = \\
 &= \bar{x}\bar{y} - \bar{x}\bar{y} = 0
 \end{aligned}$$

La covarianza no está acotada de forma uniforme para todas las variables ni está expresada en las mismas unidades, por lo que no es fácil interpretar su valor ni hacer comparaciones. Este problema se soluciona con el coeficiente de correlación lineal.

3. Coeficiente de Correlación Lineal

La correlación, también conocida como coeficiente de correlación lineal (de Pearson), es una medida de regresión que pretende cuantificar el grado de variación conjunta entre dos variables.

Por tanto, es una medida estadística que cuantifica la dependencia lineal entre dos variables, es decir, si se representan en un diagrama de dispersión los valores que toman dos variables, el coeficiente de correlación lineal señalará lo bien o lo mal que el conjunto de puntos representados se aproxima a una recta.

De una forma menos coloquial, la podemos definir como el número que mide el grado de intensidad y el sentido de la relación entre dos variables.

$$r_{xy} = \frac{S_{xy}}{S_x S_y}$$

Su signo es el mismo que el de la covarianza, además este coeficiente toma valores entre -1 y 1, $(-1 \leq r_{xy} \leq 1)$ midiendo objetivamente el grado de

CAPÍTULO 14. VARIABLES ESTADÍSTICAS BIDIMENSIONALES

variación conjunta que tienen las variables X e Y. Cuando las variables están tipificadas el coeficiente de correlación lineal coincide con la covarianza. El cambio de origen y escala no afecta al valor de este coeficiente. Se sabe que

$$X^* = eX + cY^* = hY + d \Rightarrow S_{X^*Y^*} = ehS_{XY} \quad S_{X^*} = eS_X \quad S_{Y^*} = hS_Y$$

por tanto

$$r_{x^*y^*} = \frac{S_{x^*y^*}}{S_{x^*}S_{y^*}} = \frac{ehS_{xy}}{eS_xhS_y} = \frac{S_{xy}}{S_xS_y} = r_{xy}$$

Al emplearse como medida de la fuerza de asociación entre dos variables se dice que:

- 0: asociación nula.
- ± 0.1 : asociación pequeña.
- ± 0.3 : asociación mediana.
- ± 0.5 : asociación moderada.
- ± 0.7 : asociación alta.
- ± 0.9 : asociación muy alta.

Ejemplo 14.10 Calcule el coeficiente de correlación lineal con los datos del ejemplo 14.8 **Demostración**

	x_i	y_i	$x_i y_i$	x_i^2	y_i^2
	3	1	3	9	1
	5	2	10	25	4
	4	1	4	16	1
	6	3	18	36	9
	7	3	21	49	9
	5	3	15	25	9
	4	2	8	16	4
	2	1	2	4	1
	1	0	0	1	0
	5	1	5	25	1
	6	1	6	36	1
Total	48	18	92	242	40

$$n = 11 \quad \bar{x} = 4,36 \quad \bar{y} = 1,64$$

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \frac{92}{11} - 4,36 \times 1,64 = 1,21$$

$$S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{242}{11} - 4,36^2 = 2,955 \Rightarrow S_x = 1,72$$

$$S_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n y_i^2 - \bar{y}^2 = \frac{40}{11} - 1,64^2 = 0,959 \Rightarrow S_y = 0,98$$

3. COEFICIENTE DE CORRELACIÓN LINEAL

$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{1,21}{1,72 \times 0,98} = 0,7238$$

En el ejemplo anterior se recogen todos los cálculos necesarios en el estudio de variables estadísticas bidimensionales para datos en dos columnas. Veamos en el siguiente ejemplo como se llevan a cabo dichos cálculos cuando los datos están en una tabla de contingencia.

Ejemplo 14.11 Calcule el coeficiente de correlación lineal con los datos del ejemplo 14.2

X/Y	500-1000	1000-1500	1500-2000	$n_{i \cdot}$
20	10	3	2	15
21	5	15	5	25
22	2	20	15	37
23	0	13	10	23
$n_{\cdot j}$	17	51	32	100

Demostración Si alguna de las variables es continua (datos agrupados en intervalos), como en este caso los salarios, tomaremos la marca de clase de cada intervalo, y_j , como valor representativo para hacer los cálculos. Junto a cada frecuencia n_{ij} calcularemos los productos $x_i y_j n_{ij}$ que incluiremos dentro de un recuadro para no confundirlos con los valores de las frecuencias.

X/Y	500-1000	1000-1500	1500-2000	$n_{i \cdot}$	$x_i n_{i \cdot}$	$x_i^2 n_{i \cdot}$
20	10	3	2	15	300	6000
21	5	15	5	25	525	11025
22	2	20	15	37	814	17908
23	0	13	10	23	529	12167
$n_{\cdot j}$	17	51	32	100	2168	47100
$y_j n_{\cdot j}$	12750	63750	56000	132500		
$y_j^2 n_{\cdot j}$	9562500	79687500	98000000	187250000		

$$\begin{aligned}
\bar{x} &= \frac{1}{n} \sum_{i=1}^k i = 1^k x_i n_{i\bullet} = \frac{2168}{100} = 21,68 \\
\bar{y} &= \frac{1}{n} \sum_{j=1}^p j = 1^p y_j n_{\bullet j} = \frac{132500}{100} = 1325 \\
S_{xy} &= \left(\frac{1}{n} \sum_{i=1}^k \sum_{j=1}^p x_i y_j n_{ij} \right) - \bar{x} \bar{y} = \\
&= \frac{1}{100} (20 \times 750 \times 10 + \dots 23 \times 1750 \times 10) - 21,68 \times 1325 = \frac{28888000}{100} - 28726 = 154 \\
S_x^2 &= \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 n_{i\bullet} = \frac{1}{n} \sum_{i=1}^k x_i^2 n_{i\bullet} - \bar{x}^2 = \frac{47100}{100} - 21,68^2 = 0,9776 \\
S_x &= 0,9887 \\
S_y^2 &= \frac{1}{n} \sum_{j=1}^p (y_j - \bar{y})^2 n_{\bullet j} = \frac{1}{n} \sum_{j=1}^p y_j^2 n_{\bullet j} - \bar{y}^2 = \frac{187250000}{100} - 1325^2 = 116875 \\
S_y &= 341,87 \\
r_{xy} &= \frac{S_{xy}}{S_x S_y} = \frac{154}{0,9887 \times 341,87} = 0,4556
\end{aligned}$$

4. Recta de Regresión de Mínimos Cuadrados

Uno de los objetivos en toda ciencia es encontrar relaciones entre los hechos que estudia. Esas relaciones normalmente se intentan traducir en expresiones matemáticas. Así, si se observa el tiempo empleado por un móvil para recorrer 500 Km. cuando éste se mueve con velocidad uniforme, pueden obtenerse los siguientes valores. Estos valores están claramente relacionados y esa relación

t(horas)	v (km/h)
5	100
10	50
2,5	200
1	500


puede expresarse mediante la función $vt=500$. Los datos observados son valores particulares que verifican dicha ecuación.

Representando gráficamente dicha función $v = \frac{500}{t}$ y los puntos observados (t_i, v_i) se tiene

Existen otro tipo de variables como el consumo y la renta, la oferta y la demanda,... donde no cabe duda de que hay una relación, pero donde es imposible definir sobre ellas una función matemática que verifiquen rigurosamente. A este tipo de dependencia entre variables la denominaremos dependencia estadística frente a la dependencia funcional que es el término utilizado para referirse a relaciones estrictas entre las variables, como la observada entre v y t .

Si dos variables presentan una dependencia estadística, no funcional, no es posible encontrar una ecuación tal que los valores de las variables la verifiquen.


4. RECTA DE REGRESIÓN DE MÍNIMOS CUADRADOS




Esto equivale gráficamente al hecho de que no es posible encontrar una función tal que su gráfica pase por todos los puntos del diagrama de dispersión asociado a las variables observadas

Ejemplo 14.12 Siguiendo el ejemplo 14.8

X	Y
3	1
5	2
4	1
6	3
7	3
5	3
4	2
2	1
1	0
5	1
6	1



Ante la imposibilidad de encontrar una gráfica que pase por todos los puntos de la nube hay que aceptar el razonamiento lógico de que la función cuya gráfica más se aproxime a los datos observados expresará mejor la relación entre los mismos. Hacer regresión consiste en ajustar lo mejor posible una función a una serie de valores observados, gráficamente equivale a encontrar la curva que esté lo más próxima que se pueda a los puntos del diagrama de dispersión. El



procedimiento analítico para obtener dicha función se basa en hacer mínima la suma de las distancias (al cuadrado) entre los puntos de la nube, (x_i, y_i) , y la

gráfica de la función, $\hat{y} = f(x_i)$.

Es decir se trata de minimizar

$$\sum_{i=1}^n (y_i - f(x_i))^2$$

Por este motivo se le conoce como ajuste por mínimos cuadrados. Una vez obtenida dicha función $y = f(x)$, para un valor dado $x = x_i$ estimaríamos el valor de y mediante $\hat{y} = f(x_i)$. Probablemente el verdadero valor de la variable Y asociado a x_i no coincidirá con $\hat{y}_i$ pero el ajuste por mínimos cuadrados nos garantiza que dicha diferencia ($y_i - \hat{y}_i$) será mínima en la medida de lo posible.

Ejemplo 14.13 La recta del ejemplo 14.12 se ha ajustado por mínimos cuadrado y su expresión es $y = 0,41 - 0,17x$, cuando $x_i = 3$, $\hat{y}_i = (0,41 \times 3) - 0,17 = 1,06$. Como podemos observar en la tabla y grafica del ejemplo 14.12, cuando $x_i = 3$ la variable y toma el valor $y_i = 1 \neq 1,06$, siendo en este caso el error de la estimación muy pequeño. En otros puntos como $x_i = 6$ los errores que se cometen son mayores, $y_i = 1$ o $y_i = 3$, $\hat{y}_i = (0,41 \times 6) - 0,17 = 2,29$

Aplicaciones de la Regresión

¿Qué aplicaciones puede tener la regresión? Las aplicaciones son varias aunque quizás la más interesante sea la de predecir, es decir, conociendo el valor de una variable estimar el valor que presentará otra variable relacionada con la primera. A la variable que se quiere predecir se denomina dependiente, endógena o explicada. La variable cuyo conocimiento se utiliza para hacer la predicción se llama independiente, exógena o explicativa. Utilizaremos la expresión regresión simple cuando se usa una sola variable independiente y regresión múltiple cuando se use más de una variable independiente.

Cuando se hace un ajuste por mínimos cuadrados hay que especificar el tipo de función que se quiere ajustar, recta $y = a + bx$, hipérbola $y = a + \frac{b}{x}$, potencia $y = ax^b$... Esto dependerá de la forma en que se relacionan las variables, forma que está reflejada en el diagrama de dispersión o nube de puntos. Vamos a considerar el caso más sencillo, además de ser el más utilizado, el de la línea recta, que se conoce como regresión lineal simple, recta de regresión, recta de mínimos cuadrados o recta de regresión de mínimos cuadrados.

4.1. Regresión Lineal

Aplicando el ajuste por mínimos cuadrados a funciones de la forma $y = a + bx$ obtenemos que la recta que mejor se ajusta a un conjunto de datos, (x_i, y_i) $i = 1, \dots, n$, tiene por coeficientes

$$b = \frac{S_{xy}}{S_x^2} \quad a = \bar{y} - b\bar{x} = \bar{y} - \frac{S_{xy}}{S_x^2} \bar{x}$$

A los coeficientes de la recta, $y = a + bx$, se les conocen como:

- a =ordenada en el origen (punto donde corta al eje Y).
- b =pendiente de la recta. Ambos tienen un significado propio que se ilustra en el ejemplo 14.14.

Otra forma de escribir una recta es la conocida expresión punto-pendiente, $y - y_0 = b(x - x_0)$ donde además de la pendiente se indica un punto, (x_0, y_0) , por el que la recta pasa. Sustituyendo a y b en la expresión $y = a + bx$ y reordenando convenientemente se obtiene la expresión punto-pendiente

$$y - \bar{y} = \frac{S_{xy}}{S_x^2}(x - \bar{x})$$

que se puede escribir también en función del coeficiente de correlación lineal como

$$y - \bar{y} = r \frac{S_y}{S_x}(x - \bar{x})$$

Según las anteriores expresiones, la recta de regresión siempre pasa por el punto $(\bar{x}, \bar{y})$.

La recta obtenida se denomina recta de regresión de Y/X, siendo una de sus aplicaciones predecir la variable Y, conocido el valor de la variable X. Si queremos predecir el valor de X, conocido el valor de Y, no se debe sustituir el valor conocido de Y en la anterior recta y despejar el valor de X. Para ello debemos utilizar la recta de regresión de X/Y que en general no coincide con la anterior, siendo su expresión

$$x - \bar{x} = \frac{S_{xy}}{S_y^2}(y - \bar{y}) \quad x - \bar{x} = r \frac{S_x}{S_y}(y - \bar{y})$$

Que habitualmente se simplifica reduciéndola a su forma más simple

$$x = a' + b'y$$

Ejemplo 14.14 *Se han observado precio y superficie de un conjunto de viviendas. Claramente esas variables están relacionadas. Se ha ajustado por mínimos cuadrados la siguiente recta*

$$p = 50000 + 3000m \quad p = \text{precio} \quad m = \text{superficie en m}^2$$

La ordenada en el origen nos dice lo que vale la variable dependiente cuando la independiente es cero. Esta cantidad es difícil de interpretar intuitivamente en algunos casos. La pendiente de la recta nos indica lo que aumenta la variable dependiente por cada unidad que aumenta la independiente. En este caso lo que se encarece el valor de la vivienda por cada metro más de superficie. La ordenada en el origen distinta de cero puede justificar situaciones como la siguiente: una vivienda de 50 m² tiene un precio de 200000 euros mientras que una vivienda con el doble de superficie, 100 m², tiene un precio de 350000 euros

$$200000 = 50000 + (3000 \times 50) \quad 350000 = 50000 + (3000 \times 100)$$

Analizando la forma punto-pendiente de las rectas de regresión observamos que ambas se cortan en el punto $(\bar{x}, \bar{y})$ y coincidirán dichas rectas si además tienen la misma pendiente (tomamos como referencia el eje X para la pendiente).

$$\begin{aligned} y - \bar{y} &= \frac{S_{xy}}{S_x^2}(x - \bar{x}) & x - \bar{x} &= \frac{S_{xy}}{S_y^2}(y - \bar{y}) \\ \frac{S_{xy}}{S_x^2} &= \frac{S_y^2}{S_{xy}} & \Leftrightarrow \frac{S_{xy}^2}{S_x^2 S_y^2} &= 1 \quad \Leftrightarrow r^2 = 1 \end{aligned}$$

Es decir, coinciden cuando $r^2 = 1$ (lo que significa, como veremos más adelante, que la relación lineal entre las variables es perfecta y la recta pasa por todos los puntos del diagrama de dispersión).

Ejemplo 14.15 Obtenga para los datos del ejemplo 14.12 los coeficientes de la recta de regresión de Y/X . **Demostración** Utilizaremos la expresión $y - \bar{y} = \frac{S_{xy}}{S_x^2}(x - \bar{x})$. Por tanto, todo se reduce a calcular las dos medias, la covarianza y la varianza de X . En el ejemplo 14.8 se calcularon todas estas cantidades

$$\begin{aligned}\bar{x} &= 4,364 & \bar{y} &= 1,636 \\ S_{xy} &= 1,22 & S_x^2 &= 2,955\end{aligned}$$

y sustituyendo obtenemos

$$\begin{aligned}y - 1,636 &= \frac{1,22}{2,955}(x - 4,364) \Leftrightarrow y - 1,636 = 0,4128(x - 4,364) \\ &\Leftrightarrow y = 0,4128x - 0,1655\end{aligned}$$

4.2. Correlación Lineal

Tan importante es conocer la forma en que se relacionan las variables como su grado de relación o asociación. De esto último se ocupa la correlación. El grado de asociación entre las variables indica en qué medida se puede encontrar una expresión que explica una variable en función de otra. Así en el ejemplo de la velocidad y el tiempo, donde el grado de asociación es completo, la expresión $vt=500$ explica perfectamente el valor de una variable conociendo la otra. En otros casos la asociación entre las variables no será tan fuerte y la expresión hallada no explicará exactamente a la variable dependiente en función de la independiente. Todo esto equivale gráficamente al hecho de que la gráfica ajustada pase por los puntos observados (caso de $vt=500$) o bien pase más o menos próxima a ellos. Según lo anterior, el estudio de la correlación equivale al estudio de la bondad del ajuste de una curva a un conjunto de puntos. Para medir la bondad del ajuste nos fijaremos en la distancia entre la gráfica de la función y los puntos de la nube o diagrama de dispersión. Estas distancias se conocen como errores o residuos. Cuando este análisis se aplica sobre la recta de regresión hablamos de correlación lineal.

4.3. Varianza Residual. Coeficiente de Determinación

La media de los residuos o errores al cuadrado que se cometen en un ajuste se conoce como varianza residual y es una medida de la bondad del ajuste (observe los residuos en el gráfico del ejemplo 14.12)

$$S_{ry}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2$$

Esta medida tiene el inconveniente de no estar acotada entre unos valores fijos por lo que tenemos el problema de no saber con precisión si está tomando valores

CAPÍTULO 14. VARIABLES ESTADÍSTICAS BIDIMENSIONALES

significativamente grandes o pequeños. Para superar dicho problema se define a partir de ella el coeficiente de determinación como

$$R^2 = 1 - \frac{S_{ry}^2}{S_y^2} \quad \text{siendo } 0 \leq R^2 \leq 1$$

En el caso de la recta, este coeficiente coincide con el coeficiente de correlación lineal al cuadrado, $R^2 = r^2$

Si $R^2 = 0$ tenemos el peor ajuste que se puede hacer por mínimos cuadrados. En el caso de la recta, ésta se reduce a

$$y - \bar{y} = r \frac{S_y}{S_x} (x - \bar{x}) \quad r = 0 \quad \Rightarrow \quad y - \bar{y} = 0 \\ y = \bar{y}$$

análogamente la recta de X/Y es $x - \bar{x} = 0 \Leftrightarrow x = \bar{x}$, y las dos rectas de regresión son perpendiculares

Al no relacionarse (linealmente) la variable independiente con la variable dependiente y por tanto no aportar ninguna información, la variable independiente no aparece en la expresión de la recta de regresión que se reduce a estimar los valores de la variable Y mediante y sea quien sea el valor de X. Si $R^2 = 1$ estamos ante un ajuste por mínimos cuadrados perfecto, la gráfica de la función pasa por todos los puntos de la nube (como en el ejemplo de $vt=500$). En el caso de la recta, como se dijo anteriormente, ambas rectas de regresión coinciden y pasan por todos los puntos. Para valores intermedios, $0 \leq R^2 \leq 1$ según esté R^2 más próximo a un extremo u otro nos indicará un peor o mejor ajuste. Además, en el caso de la recta, cuanto más se aproxime a 1 más se cierra el ángulo que forman las rectas de regresión y cuanto más se aproxime a cero mayor será dicho ángulo.

Otra interpretación de este coeficiente de determinación, R^2 , es la proporción de la varianza de Y (comportamiento de la variable Y) que puede atribuirse a su relación con X.

Ejemplo 14.16 *Dé una medida de la bondad del ajuste de la recta del ejemplo 14.15. Obtenga la varianza residual.*

Demostración *En el ejemplo 14.12 se calculó el coeficiente de correlación lineal para dichos datos*


$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{1,22}{1,72 \times 0,98} = 0,7238 \quad r_{xy}^2 = 0,5239$$

Varianza Residual

$$r^2 = 1 - \frac{S_{ry}^2}{S_y^2} \Rightarrow S_{ry}^2 = (1 - r^2) S_y^2 = \\ = (1 - 0,5239) 0,959 = 0,457$$

4.4. Predicciones

Predecir consiste en determinar a partir del modelo ajustado el valor de la variable dependiente para un valor dado de la variable independiente. Cuando la estimación se hace para un valor de la variable independiente situado fuera de su rango de variación se denomina extrapolación, si este valor se encuentra dentro del rango de valores analizados se denomina interpolación. Para la interpolación la fiabilidad de los valores pronosticados será tanto mayor cuanto mejor sea el ajuste, sin embargo cuando hacemos predicciones para valores muy alejados del rango de variación de la variable independiente se corre el riesgo adicional de que el modelo ajustado no sea válido para dichos valores en la medida dada por R^2 . Este hecho es fácil de entender gráficamente



Se ha ajustado la recta para valores de x comprendidos entre 10 y 40, donde la recta refleja la tendencia creciente de los valores de y en función de x . En este rango de valores las predicciones que se hicieran no estarían sujetas a graves errores. Supongamos que desconocemos cómo se comporta el fenómeno para valores de x mayores que 40 y decidiéramos hacer una predicción (extrapolación) para $x=70$, en tal caso cometeríamos un grave error de predicción.

Ejemplo 14.17 Se conoce que el consumo de pan en la dieta de los países desarrollados está relacionado con la renta per cápita. Ajuste una recta que explique dicha relación sobre los siguientes datos, interprete los coeficientes y halle la bondad del ajuste.

País	kg/Habitante	Renta per cápita
Alemania	40	14,8
Bélgica	41	15,1
Francia	57	13,5
Grecia	71	7,3
Holanda	61	12
Italia	42	14
Portugal	69	7,2

Demostración

x_i	y_i	$x_i y_i$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
14,8	40	592	7,92	208,18
15,1	41	619,1	9,70	180,33
13,5	57	769,5	2,29	6,61
7,3	71	518,3	21,96	274,61
12	61	732	0,00	43,18
14	42	588	4,06	154,47
7,2	69	496,8	22,90	212,33
83,9	381	4315,7	68,83	1079,71

$$\begin{aligned}\bar{x} &= \frac{83,9}{7} = 11,99 & \bar{y} &= \frac{381}{7} = 54,43 \\ S_x^2 &= \frac{68,83}{7} = 9,83 & S_y^2 &= \frac{1079,71}{7} = 154,24 \\ S_{xy} &= \frac{4315,7}{7} - \bar{x}\bar{y} = -35,836\end{aligned}$$

Sustituyendo en la ecuación de la recta de $Y/X, y - \bar{y} = \frac{S_{xy}}{S_x^2}(x - \bar{x})$ obtenemos

$$\begin{aligned}y - 54,43 &= \frac{-35,836}{9,83}(x - 11,99) \Leftrightarrow y - 54,43 = -3,64(x - 11,99) \\ y &= -3,64x + 98,1\end{aligned}$$

La pendiente negativa (-3.64) indica que a mayor renta per cápita menor es el consumo de pan en la dieta. Para hallar la bondad del ajuste calculamos el coeficiente de correlación lineal al cuadrado

$$r_{xy}^2 = \frac{S_{xy}^2}{S_x^2 S_y^2} = \frac{(-35,836)^2}{9,833 \times 154,24} = 0,85$$

Ejemplo 14.18 Una fábrica de cerveza ha tomado al azar 8 semanas del año, observando la temperatura media en cada una de ellas y los miles de litros de cerveza demandados ¿Puede la fábrica planificar la cantidad de producción en

Temperatura	Cerveza
10	26
28	82
30	98
35	103
20	60
12	35
27	68
25	71

función de la temperatura esperada? ¿De qué forma? **Demostración** En primer lugar estudiaremos el grado de asociación que hay entre las variables, si éste es importante hallaremos la expresión según la cual se relacionan.

4. RECTA DE REGRESIÓN DE MÍNIMOS CUADRADOS

x_i	y_i	$x_i y_i$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
10	26	260	178,89	1753,52
28	82	2296	21,39	199,52
30	98	2940	43,89	907,52
35	103	3605	135,14	1233,77
20	60	1200	11,39	62,02
12	35	420	129,39	1080,77
27	68	1836	13,14	0,02
25	71	1775	2,64	9,77
187	543	14332	535,88	5246,88

$$\begin{aligned}\bar{x} &= \frac{187}{8} = 23,375 & \bar{y} &= \frac{543}{8} = 67,875 \\ S_x^2 &= \frac{535,88}{8} = 66,98 & S_y^2 &= \frac{5246,88}{8} = 655,86 \\ S_{xy} &= \frac{14332}{8} - \bar{x}\bar{y} = 204,92 \\ r_{xy}^2 &= \frac{S_{xy}^2}{S_x^2 S_y^2} = \frac{(204,92)^2}{66,98 \times 655,86} = 0,956\end{aligned}$$

Podemos decir que existe una fuerte relación lineal entre las variables, $r_{xy}^2 \cong 1$, de modo que la fábrica podrá planificar con mucha fiabilidad la cantidad de producción en función de la temperatura utilizando la recta de regresión de Y/X :

$$y - \bar{y} = \frac{S_{xy}}{S_x^2}(x - \bar{x})$$

$$\begin{aligned}y - 67,875 &= \frac{204,92}{66,98}(x - 23,375) & \Leftrightarrow & y - 67,875 = 3,06(x - 23,375) \\ & & & y = 3,06x - 3,65\end{aligned}$$

Por ejemplo para una temperatura media de 33° se esperará una demanda de

$$y = (3,06 \times 33) - 3,65 = 97,33$$

CAPÍTULO 15

Números Índices

1. Tasas de Variación

Las tasas de variación son medidas que utilizamos para cuantificar la variación temporal (o espacial) de una variable. A lo largo del tema consideraremos siempre una variación temporal pero todo es igualmente aplicable al caso espacial.

1.1. Variación Absoluta

Sea una serie de observaciones de una variable X ordenadas en el tiempo, obtenidas en períodos temporales de la misma duración:

$$x_0, x_1, \dots, x_{t-1}, x_t, x_{t+1}, \dots, x_n$$

(supondremos para simplificar la exposición y por ser uno de los casos más frecuentes, que disponemos de observaciones mensuales. Lo mismo sería aplicable a otros períodos de tiempo). Se define la variación absoluta en el mes t respecto del mes anterior como la diferencia:

$$\Delta_1(x_t) = x_t - x_{t-1}$$

Y en general, la variación absoluta en el mes t respecto de k meses antes como la diferencia:

$$\Delta_k(x_t) = x_t - x_{t-k}$$

Su signo positivo o negativo nos indica una evolución creciente o decreciente respectivamente. Estas diferencias están expresadas en las mismas unidades que la serie original, lo que dificulta hacer comparaciones. Incluso cuando se usa la misma unidad de medida, el valor de la variación absoluta no es fácil de interpretar. Veámoslo en el siguiente ejemplo.

Ejemplo 15.1 Supongamos que el valor de una serie de datos, X , en el momento t es igual a 315 euros y en el momento $t-1$ era igual a 300 euros, la variación absoluta sería

$$\Delta_1(x_t) = x_t - x_{t-1} = 315 - 300 = 15$$

Consideremos otra serie, Y , que en momento $t-1$ era igual a 1000 euros y en el momento t igual a 1015 euros, su variación absoluta sería de igual signo que la anterior (ambas series tienen una evolución creciente) y de igual cuantía

$$\Delta_1(y_t) = y_t - y_{t-1} = 1015 - 1000 = 15$$

Sin embargo, es evidente que la evolución en ambos casos no tiene la misma importancia.

Para medir de forma más precisa estas variaciones, de forma que sean comparables, hay que observarlas en relación a los datos que las provocan, es decir, en términos relativos.

1.2. Variación Relativas: Tasas de Variación

La variación relativa de una variable en el período t , o tasa de variación, se define como el cociente (ratio o razón) de la variación absoluta sobre el valor previo de la variable en dicha variación absoluta:

$$T_1(t) = T_1(x_t) = \frac{\Delta_1(x_t)}{x_{t-1}} = \frac{x_t - x_{t-1}}{x_{t-1}} = \frac{x_t}{x_{t-1}} - 1$$

y en general para cualquier número de meses k , como:

$$T_k(t) = T_k(x_t) = \frac{\Delta_1(x_t)}{x_{t-k}} = \frac{x_t - x_{t-k}}{x_{t-k}} = \frac{x_t}{x_{t-k}} - 1$$

Dependiendo del intervalo de tiempo considerado ($x_{t-1} \rightarrow x_t, x_{t-k} \rightarrow x_t$), hablaremos de tasas de variación mensual, trimestral, anual, ...

La tasa de variación es una proporción o tanto por uno. Es habitual multiplicarla por 100 para expresarla en tanto por ciento o porcentaje.

Se trata de un valor adimensional por lo que se puede utilizar para comparar la evolución de series de observaciones, aunque estas estén expresadas en diferentes unidades.

Estas tasas se calculan sólo sobre variables que toman valores positivos en todo período t ($x_t > 0$)

Ejemplo 15.2 En el ejemplo 15.1 la tasa de variación para la serie de valores, X , sería:

$$\begin{aligned} T_1(t) &= \frac{\Delta_1(x_t)}{x_{t-1}} = \frac{x_t - x_{t-1}}{x_{t-1}} = \frac{x_t}{x_{t-1}} - 1 \\ &= \frac{315}{300} - 1 = 1,05 - 1 = 0,05 \\ &\Rightarrow 5\% \end{aligned}$$

Para la otra serie, Y , valdría:

$$\begin{aligned}T_1(t) &= \frac{\Delta_1(y_t)}{y_{t-1}} = \frac{y_t - y_{t-1}}{y_{t-1}} = \frac{y_t}{y_{t-1}} - 1 \\&= \frac{1015}{1000} - 1 = 1,015 - 1 = 0,015 \\&\Rightarrow 1,5\%\end{aligned}$$

Lo que muestra que aunque en ambos casos la variación absoluta es la misma, en la primera serie supone un 5 % sobre el valor inicial (300) y en la segunda serie sólo un 1,5 % sobre el valor inicial (1000), señalando la mayor importancia de la variación en la primera serie comparada con la segunda.

La tasa de variación toma el mismo valor cuando las cantidades que se comparan son proporcionales. Por ejemplo: $315 \times 5 = 1575$, $300 \times 5 = 1500$

$$\begin{aligned}T_1(t) &= \frac{\Delta_1(z_t)}{z_{t-1}} = \frac{z_t - z_{t-1}}{z_{t-1}} = \frac{z_t}{z_{t-1}} - 1 \\&= \frac{1575}{1500} - 1 = 1,05 - 1 = 0,05 \\&\Rightarrow 5\%\end{aligned}$$

Si la variación absoluta es positiva también lo será la correspondiente tasa de variación. Lo mismo vale para valores negativos. Por tanto, una tasa de variación positiva indica una evolución creciente (como en estos casos del ejemplo). Una tasa de variación negativa indica una evolución decreciente (por ejemplo, $T_1(t) = -0,03$, indica que la serie ha disminuido su valor en el período t un 3 % en relación a su valor en el período $t-1$).

Relacionado con la tasa de variación está el factor de variación unitaria que se define como

$$1 + T_1(t) = 1 + \frac{x_t}{x_{t-1}} - 1 = \frac{x_t}{x_{t-1}}$$

y en general para cualquier número de meses k , como:

$$1 + T_k(t) = 1 + \frac{x_t}{x_{t-k}} - 1 = \frac{x_t}{x_{t-k}}$$

Donde como puede observarse, se comparan por cociente el valor actual de la serie, x_t , con un valor anterior, x_{t-1} (o x_{t-k}). Se denomina así porque expresa en lo que se transforma una unidad entre los períodos de tiempo considerados.

Ejemplo 15.3 Siguiendo con el ejemplo 15.1, el factor de variación unitaria para la serie de valores, X , sería:

$$1 + T_1(t) = \frac{x_t}{x_{t-1}} = \frac{315}{300} = 1,05$$

Cada unidad en $t-1$ se transforma en 1,05 unidades en t , así las 300 unidades en $t-1$ se transforman en $300 \times 1,05 = 315$ unidades en t , 500 unidades se transformarían en $500 \times 1,05 = 525$, etc. Para la otra serie, Y , el factor de variación unitaria valdría:

$$1 + T_1(t) = \frac{y_t}{y_{t-1}} = \frac{1015}{1000} = 1,015$$

una unidad en $t-1$ se transformaría en 1,015 unidades en t , así las 1000 unidades en $t-1$ se transforman en $1000 \times 1,015 = 1015$ unidades en t , 300 unidades se transformarían en $300 \times 1,015 = 304,5$, etc.

1.3. Equivalencia entre Tasas de Variación de Diferentes Períodos

No sólo se utilizan tasas de variación mensuales, $T_1(t)$, también se trabaja frecuentemente con tasas de variación referidas a otros períodos como trimestres, $T_3(t)$, semestres, $T_6(t)$, o años, $T_{12}(t), \dots$, donde el subíndice 1, 3, 6 o 12 refleja la separación, en meses, entre los períodos que se comparan en las respectivas tasas.

Si la tasa de variación mensual de un determinado mes se mantuviera en los once meses siguientes, ¿cuál sería la tasa de variación anual (equivalente)? La respuesta es que la tasa de variación anual equivalente sería aquella que nos conduce a la misma variación absoluta: Un valor inicial, x_0 , que sufriera una variación mensual, $T_1(t)$, durante el primer mes y los once siguientes se transformaría en,

$$x_1 = (1 + T_1(t))x_0 \quad \text{al cabo del primer mes}$$

$$x_2 = (1 + T_1(t))x_1 = (1 + T_1(t))(1 + T_1(t))x_0 = (1 + T_1(t))^2 x_0 \quad \text{al cabo de dos meses}$$

y sucesivamente en

$$x_{12} = (1 + T_1(t))^{12} x_0 \quad \text{al cabo de un año}$$

La tasa de variación anual equivalente produciría la misma variación absoluta, pasando en un año del valor inicial x_0 al valor final x_{12} , es decir

$$x_{12} = (1 + \hat{T}_{12})x_0$$

Igualando las dos últimas expresiones obtenemos

$$(1 + T_1(t))^{12} = (1 + \hat{T}_{12}) \Leftrightarrow \hat{T}_{12} = (1 + T_1(t))^{12} - 1$$

La primera expresión indica que el producto del factor de variación unitaria mensual por sí mismo, las doce veces que se repite, nos da el factor de variación unitaria anual equivalente.

Observación 15.1 Nota lo notamos $\hat{T}_{12}$ (en lugar de T_{12}) para indicar que es un valor estimado bajo el supuesto de que la tasa de variación mensual es la misma para todos los meses, $T_1(t)$. T_{12} se obtendría a partir de la tasa de variación mensual de cada uno de los doce meses que forman el año como

$$\begin{aligned} (1 + T_{12}) &= (1 + T_1(t))(1 + T_1(t+1)) \dots (1 + T_1(t+11)) \\ &\Leftrightarrow \\ T_{12} &= (1 + T_1(t))(1 + T_1(t+1)) \dots (1 + T_1(t+11)) - 1 \end{aligned}$$

La primera igualdad expresa que el producto de los factores de variación unitaria de todos los meses que componen el año es igual al factor de variación unitaria anual.

Para indicar que esta tasa anual equivalente se obtiene a partir de una tasa mensual, la notaremos como

$$\hat{T}_{12}^{(1)} = (1 + T_1(t))^{12} - 1$$

Si la tasa anual equivalente se obtiene a partir del primer trimestre del año, se nota

$$\hat{T}_{12}^{(3)} = (1 + T_3(t))^4 - 1$$

Y si se ha obtenido a partir del primer semestre del año

$$\hat{T}_{12}^{(6)} = (1 + T_6(t))^2 - 1$$

Análogamente si se ha obtenido a partir de otros períodos en los que se pueda dividir el año. Leeremos $\hat{T}_{12}^{(1)}$ como tasa de variación mensual elevada a anual, $\hat{T}_{12}^{(3)}$ como tasa de variación trimestral elevada a anual, etc.

Ejemplo 15.4 *En el primer semestre de 2012 los precios han subido un 1,17%. ¿Cuál será la inflación anual estimada para el año 2012 si en el segundo semestre se mantiene la misma tendencia observada en el primero?* **Demostración** *Expresamos 1,17% en tanto por uno dividiendo por 100 y sustituimos en la expresión de la tasa de variación semestral elevada a anual*

$$\begin{aligned}\hat{T}_{12}^{(6)} &= (1 + T_6(t))^2 - 1 \\ &= (1 + 0,0117)^2 - 1 = 0,02354 \\ &\Rightarrow 2,354 \%\end{aligned}$$

Si en el segundo semestre de 2012 sigue la misma tendencia en la subida de precios que en el primer semestre, al cabo del año los precios habrán aumentado un 2,354 %

1.4. Tasas Medias de Variación

Sea la siguiente serie mensual de observaciones

$$x_0, x_1, \dots, x_{12}$$

con las siguientes tasas mensuales de variación asociadas

$$T_1(1) = \frac{x_1}{x_0} - 1 \quad T_1(2) = \frac{x_2}{x_1} - 1 \dots \quad T_1(12) = \frac{x_{12}}{x_{11}} - 1$$

¿Cuál sería el valor de la tasa mensual de variación que aplicada repetidamente a lo largo de los doce meses nos llevaría al mismo valor final del período anual, x_{12} , partiendo del valor inicial, x_0 ? Es decir, cuál sería la tasa mensual media de variación TM_1 . Con los factores de variación unitaria observados se tiene que

$$x_{12} = x_0(1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12))$$

Si se repite una tasa mensual TM_1 durante los doce meses, transformándose x_0 en x_{12}

$$x_{12} = x_0(1 + TM_1)(1 + TM_1) \dots (1 + TM_1) = x_0(1 + TM_1)^{12}$$

Igualando ambas expresiones

$$\begin{aligned} (1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12)) &= (1 + TM_1)^{12} \\ \Leftrightarrow \\ \sqrt[12]{(1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12))} &= (1 + TM_1) \end{aligned}$$

Esta última expresión indica que el factor de variación unitaria asociado a la tasa media de variación mensual es la media geométrica de los factores de variación unitaria asociados a las diferentes tasas de variación mensual. Despejando la tasa media de variación mensual se obtiene

$$TM_1 = \sqrt[12]{(1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12))} - 1$$

Por otra parte, es posible calcular la tasa media de variación a partir de los valores inicial y final del período como sigue

$$\begin{aligned} x_{12} &= x_0(1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12)) \\ \Leftrightarrow \\ \frac{x_{12}}{x_0} &= (1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12)) \\ TM_1 &= \sqrt[12]{(1 + T_1(1))(1 + T_1(2)) \dots (1 + T_1(12))} - 1 \\ &= \sqrt[12]{\frac{x_{12}}{x_0}} - 1 \end{aligned}$$

De forma similar se calcularía la tasa media de variación si en lugar de meses nos referimos a otros períodos o si en lugar de 12 datos se dispone de un número diferente.

Ejemplo 15.5 *El consumo de agua, en m^3 , de una comunidad de regantes fue de diciembre de 2010 a junio de 2011. Calcule*

t		consumo
2010	diciembre	15400
2011	enero	17300
2011	febrero	25600
2011	marzo	30200
2011	abril	27000
2011	mayo	26400
2011	junio	24800

- *La variación absoluta trimestral.*
- *Tasas mensuales de variación.*
- *Tasa semestral de variación.*
- *Tasa mensual media de variación en todo el período.*

Demostración La variación absoluta trimestral

t		$\Delta_t(x_t)$
2011	marzo	$30200-15400=14800$
2011	abril	$27000 - 17300=9700$
2011	mayo	$26400 -25600 =800$
2011	junio	$24800-30200=-5400$

Tasas mensuales de variación

t		consumo
2011	enero	$\frac{17300}{15400} - 1 = 0,1234$
2011	febrero	$\frac{25600}{17300} - 1 = 0,4798$
2011	marzo	$\frac{30200}{25600} - 1 = 0,1797$
2011	abril	$\frac{27000}{30200} - 1 = -0,1060$
2011	mayo	$\frac{26400}{27000} - 1 = -0,0222$
2011	junio	$\frac{24800}{26400} - 1 = -0,0606$

Tasa semestral de variación Dos formas:

$$T_6(2011 \text{ junio}) = \frac{24800}{15400} - 1 = 0,6104$$

o bien como

$$\begin{aligned} 1 + T_6(2011 \text{ junio}) &= (1 + T_1(2011 \text{ enero}))(1 + T_1(2011 \text{ febrero})) \times \dots (1 + T_1(2011 \text{ junio})) \\ &= 1,1234 \times 1,4798 \times 1,1797 \times 0,8940 \times 0,9778 \times 0,9394 = 1,6104 \end{aligned}$$

$$T_6(2011 \text{ junio}) = 61,04\%$$

Tasa mensual media de variación en todo el período Varias formas

$$\begin{aligned} 1 + TM_1 &= \sqrt[6]{\frac{24800}{15400}} \\ &= \sqrt[6]{(1 + T_1(2011 \text{ enero}))(1 + T_1(2011 \text{ febrero})) \times \dots (1 + T_1(2011 \text{ junio}))} \\ &= \sqrt[6]{1 + T_6(2011 \text{ junio})} \\ &= 1,0827 \\ &\Rightarrow \\ TM_1 &= 8,27\% \end{aligned}$$

2. Índice elemental. Índice sintético.

Sea la evolución temporal de una magnitud X: $x_0, x_1, \dots, x_t, \dots$, se denomina índice elemental (o índice simple) de la magnitud X en el período t respecto al periodo 0 al cociente

$$I_{t/0} = \frac{x_t}{x_0}$$

Observación 15.2 *Nota observe la relación del índice elemental con la tasa de variación y el factor de variación unitaria definidos anteriormente*

$$\begin{aligned} 1 + T_1(t) &= 1 + \frac{x_t}{x_{t-1}} - 1 = \frac{x_t}{x_{t-1}} \\ 1 + T_t(t) &= 1 + \frac{x_t}{x_{t-t}} - 1 = \frac{x_t}{x_0} \end{aligned}$$

es decir, el índice elemental es el factor de variación unitaria entre los períodos 0 y t .

El período 0 utilizado como período de referencia se denomina período base y el período t que se compara con el anterior es el período corriente (o período actual). Este índice expresa, en tanto por uno, la evolución que ha experimentado la magnitud X desde el período 0 hasta el período t . Valores mayores que uno indican que X ha aumentado, menores que uno expresan una disminución de la magnitud X e igual a uno que se ha mantenido su valor. Habitualmente los números índices se multiplican por 100 para expresarlos en porcentajes.

Ejemplo 15.6 *El precio de la gasolina ha pasado de 1,125 euros/litro a 1,328 euros/litro. Calculando el correspondiente índice elemental podemos ver que*

$$I_{1/0}(X) = \frac{x_1}{x_0} = \frac{1,328}{1,125} = 1,18$$

la gasolina es ahora un 18 % más cara que antes, o bien

$$\begin{aligned} I_{0/1}(X) &= \frac{x_0}{x_1} = \frac{1,125}{1,328} = 0,847 \\ \Rightarrow 1 - 0,847 &= 0,153 \end{aligned}$$

antes su valor era el 84,7 % de su valor actual, es decir, un 15,3 % más barata que actualmente.

De la misma definición de índice elemental resulta la siguiente propiedad (propiedad circular) que nos va a permitir referirnos a períodos base distintos del período 0

$$\begin{aligned} \frac{x_t}{x_0} &= \frac{x_t}{x_{t'}} \frac{x_{t'}}{x_0} \\ \Rightarrow \\ I_{t/0}(X) &= I_{t/t'}(X) I_{t'/0}(X) \end{aligned}$$

de donde

$$I_{t/t'}(X) = \frac{I_{t/0}(X)}{I_{t'/0}(X)}$$

Ejemplo 15.7 *El año pasado el precio de la gasolina ha experimentado entre los meses de enero y junio una subida, según el índice elemental, de 1,185 y entre los meses de enero y diciembre una subida, según el mismo índice, de*

1,225. ¿Qué subida ha experimentado el precio de la gasolina entre los meses de junio y diciembre?

Demostración Etiquetamos por comodidad como 0, 1 y 2 a los tres meses de enero, junio y diciembre respectivamente.

$$I_{2/1}(X) = \frac{I_{2/0}(X)}{I_{1/0}(X)}$$

De junio a diciembre ha aumentado 0,0338 en tanto por uno (3,38 %). Observe que no sería válido el siguiente razonamiento: de enero a junio ha aumentado un 18,5 %, de enero a diciembre ha aumentado un 22,5 %, por tanto de junio a diciembre ha aumentado un 22,5-18,5=4 %.

2.1. Índice Sintético

Consideremos ahora un conjunto X de magnitudes simples, $X_1, X_2, \dots, X_n$ (por ejemplo, precios de distintos artículos). Los índices elementales de las magnitudes simples X_i se definen como

$$I_{t/0}(X_i) = \frac{x_{it}}{x_{i0}}$$

Queremos resumir en un único índice (que llamaremos índice sintético, compuesto o complejo) los índices elementales de las magnitudes simples X_i . Hay distintas soluciones, todas ellas se basan en el cálculo de medias sobre dichos índices elementales. Distinguiremos entre índices sintéticos sin ponderar (a todas las magnitudes simples se le da la misma importancia) e índices sintéticos ponderados (a cada magnitud simple se le asigna una importancia diferente).

2.2. Índices sintéticos sin ponderar

Índice de Sauerbeck

Es la media aritmética de los índices elementales

$$S_{t/0}(X) = \frac{1}{n} \sum_{i=1}^n \frac{x_{it}}{x_{i0}}$$

Índice de Bradstreet y Dudot

Se define como la media agregativa

$$D_{t/0}(X) = \frac{\sum_{i=1}^n x_{it}}{\sum_{i=1}^n x_{i0}}$$

2.3. Índices Sintéticos Ponderados

Para el cálculo de estos índices se utilizan coeficientes de ponderación que cuantifican la importancia relativa de cada magnitud

- u_{i0} , importancia relativa de la magnitud simple X_i en el período base 0.

$$\sum_{i=1}^n u_{i0} = 1$$

3. ÍNDICES DE PRECIOS, DE CANTIDADES Y DE VALOR

- u_{it} , importancia relativa de la magnitud simple X_i en el período actual t.

$$\sum_{i=1}^n u_{it} = 1$$

Índice de Laspeyres

Es la media aritmética de los índices elementales con ponderaciones del período base

$$L_{t/0}(X) = \sum_{i=1}^n \frac{x_{it}}{x_{i0}} u_{i0}$$

Índice de Paasche

Es la media armónica de los índices elementales con ponderaciones del período actual

$$P_{t/0}(X) = \frac{1}{\sum_{i=1}^n \frac{x_{i0}}{x_{it}} u_{it}}$$

Índice de Fisher

Es la media geométrica de los índices de Laspeyres y Paasche

$$F_{t/0}(X) = \sqrt{L_{t/0}(X) P_{t/0}(X)}$$

3. Índices de Precios, de Cantidades y de Valor

Se tiene información sobre precios y cantidades de n artículos:

Periodo Base		Periodo Actual	
Precios	Cantidades	Precios	Cantidades
p_{10}	q_{10}	p_{1t}	q_{1t}
p_{20}	q_{20}	p_{2t}	q_{2t}
$\dots$	$\dots$	$\dots$	$\dots$
p_{i0}	q_{i0}	p_{it}	q_{it}
$\dots$	$\dots$	$\dots$	$\dots$
p_{n0}	q_{n0}	p_{nt}	q_{nt}

Se puede obtener fácilmente el valor total de cada artículo para el período base, $p_{i0}q_{i0}$, y para el período actual, $p_{it}q_{it}$. Por tanto el valor global de todos los artículos en el período base será $\sum_{i=1}^n p_{i0}q_{i0}$ y el valor de todos los artículos en el período actual $\sum_{i=1}^n p_{it}q_{it}$

Se suele tomar como factores de ponderación el valor relativo de cada artículo en relación al valor global

$$u_{i0} = \frac{p_{i0}q_{i0}}{\sum_{j=1}^n p_{j0}q_{j0}} \quad u_{it} = \frac{p_{it}q_{it}}{\sum_{j=1}^n p_{jt}q_{jt}}$$

3.1. Índices de Precios

Para hallar los índices sintéticos de precios utilizaremos como índices elementales $\frac{p_{it}}{p_{i0}}$

$$\begin{aligned}
 L_{t/0}^p &= \sum_{i=1}^n \frac{p_{it}}{p_{i0}} u_{i0} \\
 &= \sum_{i=1}^n \frac{p_{it}}{p_{i0}} \frac{p_{i0} q_{i0}}{\sum_{j=1}^n p_{j0} q_{j0}} \\
 &= \sum_{i=1}^n \frac{p_{it} q_{i0}}{\sum_{j=1}^n p_{j0} q_{j0}} \\
 &= \frac{\sum_{i=1}^n p_{it} q_{i0}}{\sum_{j=1}^n p_{j0} q_{j0}}
 \end{aligned}$$

Es decir, el índice de precios de Laspeyres consiste en calcular el valor de las cantidades del período base a precios del período base y período actual y compararlos por cociente.

Mientras que en el índice de precios de Paasche se consideran las cantidades del período actual, se determina su valor a precios del período base y actual y se comparan por cociente.

$$\begin{aligned}
 P_{t/0}^p &= \frac{1}{\sum_{i=1}^n \frac{p_{i0}}{p_{it}} u_{it}} \\
 &= \frac{1}{\sum_{i=1}^n \frac{p_{i0}}{p_{it}} \frac{p_{it} q_{it}}{\sum_{j=1}^n p_{jt} q_{jt}}} \\
 &= \frac{1}{\sum_{i=1}^n \frac{p_{i0} q_{it}}{\sum_{j=1}^n p_{jt} q_{jt}}} \\
 &= \frac{\sum_{j=1}^n p_{jt} q_{jt}}{\sum_{i=1}^n p_{i0} q_{it}}
 \end{aligned}$$

En el caso de que las cantidades del período base y actual coincidan también coincidirán los dos índices anteriores, $L_{t/0}^p = P_{t/0}^p$. Se llama cesta de la compra a un conjunto de artículos (y cantidades), obtenidos a partir de la encuesta de presupuestos familiares, representativos de un determinado nivel de vida. El índice de precios de consumo, I.P.C., es el índice de precios de Laspeyres sobre la cesta de la compra.

3.2. Indices de Cantidades

Para hallar los índices sintéticos de precios utilizaremos como índices elementales $\frac{q_{it}}{q_{i0}}$

$$\begin{aligned}
 L_{t/0}^q &= \sum_{i=1}^n \frac{q_{it}}{q_{i0}} u_{i0} \\
 &= \sum_{i=1}^n \frac{q_{i0}}{q_{it}} \frac{p_{i0} q_{i0}}{\sum_{j=1}^n p_{j0} q_{j0}} \\
 &= \sum_{i=1}^n \frac{p_{i0} q_{it}}{\sum_{j=1}^n p_{j0} q_{j0}}
 \end{aligned}$$

El índice de cantidades de Laspeyres compara el valor de las cantidades de los períodos base y actual con precios del período base. Mientras que el índice de cantidades de Paasche compara el valor de las cantidades de los períodos base y actual con precios del período actual.

$$P_{t/0}^q = \frac{\sum_{i=1}^n p_{it} q_{it}}{\sum_{i=1}^n p_{it} q_{i0}}$$

Tanto para precios como para cantidades se define el índice de Fisher como la media geométrica de los índices de Laspeyres y Paasche (por tanto su valor está comprendido entre ambos).

Índices de Marshall-Edgeworth

Adopta una posición (valor) intermedia entre los índices de Laspeyres y Paasche considerando la media de las cantidades en los períodos base y actual para hallar el índice de precios

$$\begin{aligned}
 E_{t/0}^p &= \frac{\sum_{i=1}^n p_{it} \frac{q_{i0} + q_{it}}{2}}{\sum_{i=1}^n p_{i0} \frac{q_{i0} + q_{it}}{2}} \\
 &= \frac{\sum_{i=1}^n p_{it} (q_{i0} + q_{it})}{\sum_{i=1}^n p_{i0} (q_{i0} + q_{it})}
 \end{aligned}$$

Para hallar el índice de cantidades considera la media de los precios en los períodos base y actual

$$\begin{aligned}
 E_{t/0}^q &= \frac{\sum_{i=1}^n q_{it} \frac{p_{i0} + p_{it}}{2}}{\sum_{i=1}^n q_{i0} \frac{p_{i0} + p_{it}}{2}} \\
 &= \frac{\sum_{i=1}^n q_{it} (p_{i0} + p_{it})}{\sum_{i=1}^n q_{i0} (p_{i0} + p_{it})}
 \end{aligned}$$

3.3. Índices de Valor

Supongamos un fenómeno caracterizado por un conjunto de cantidades y precios que varían a lo largo del tiempo (p.e. la producción). Nos planteamos estudiar la variación en el valor agregado de dicho fenómeno.

En el año base $V_0 = \sum_{i=1}^n p_{i0} q_{i0}$ y en el año actual $V_t = \sum_{i=1}^n p_{it} q_{it}$

Denominamos índice de valor agregado al cociente

$$I_{t/0}^V = \frac{V_t}{V_0} = \frac{\sum_{i=1}^n p_{it} q_{it}}{\sum_{i=1}^n p_{i0} q_{i0}}$$

Se puede demostrar fácilmente que el índice anterior puede obtenerse como el producto de un índice de precios por un índice de cantidades, según:

$$I_{t/0}^V = L_{t/0}^p P_{t/0}^q = L_{t/0}^q P_{t/0}^p$$

4. Enlace de Series de Números Índices con Distinta Base

Supongamos que tenemos un número índice referido al período base $t_1, I_{t/t_1}$, y queremos expresarlo con período base $t_2, I_{t/t_2}$, además conocemos el índice que relaciona los períodos t_1 y $t_2, I_{t_2/t_1}$. La forma de obtener I_{t/t_2} a partir de I_{t/t_1} consiste en aplicar la propiedad circular. Esta propiedad no la cumplen los índices sintéticos más usuales, a pesar de ello el procedimiento práctico actúa como si se verificase tal propiedad.

$$I_{t/t_2} = \frac{I_{t/t_1}}{I_{t_2/t_1}}$$

Si se quiere expresar el índice I_{t/t_2} en la base t_1 , haremos uso de la misma propiedad escrita como

$$I_{t/t_1} = \frac{I_{t/t_2}}{I_{t_2/t_1}}$$

Ejemplo 15.8 Dadas las siguientes series de números índices de precios al consumo obtenga una sola serie para todo el periodo con base 2011 y otra con base en 2013

Año	IPC(base 2000)	IPC(base 2011)	IPC(base 2014)
2007	115		
2008	123		
2009	129		
2010	132		
2011	135	100	
2012		103	
2013		107	
2014		113	100
2015			110
2016			120
2017			123

4. ENLACE DE SERIES DE NÚMEROS ÍNDICES CON DISTINTA BASE

Demostración Para aplicar la propiedad circular y cambiar de base, los números índices deben estar expresados en tanto por uno, para lo cual los dividimos primero por 100.

Año	IPC(base 2011)	IPC(base 2011) en %
2007	$\frac{115}{135}$	85,18
2008	$\frac{123}{135}$	91,11
2009	$\frac{129}{135}$	95,55
2010	$\frac{132}{135}$	97,77
2011	100	100
2012	103	103
2013	107	107
2014	113	113
2015	110×113	124,3
2016	120×113	135,6
2017	110×113	138,99

Año	IPC(base 2013)	IPC(base 2013) en %
2007	$\frac{85,18}{107}$	79,31
2008	$\frac{91,11}{107}$	85,15
2009	$\frac{95,55}{107}$	89,3
2010	$\frac{97,77}{107}$	91,37
2011	$\frac{100}{107}$	93,46
2012	$\frac{103}{107}$	96,26
2013	$\frac{107}{107}$	100
2014	$\frac{113}{107}$	105,61
2015	$\frac{124,3}{107}$	116,17
2016	$\frac{135,6}{107}$	126,73
2017	$\frac{138,99}{107}$	129,9

5. Deflación de series económicas

Un problema frecuente en estudios económicos consiste en el análisis de una sucesión de valores expresados en moneda corriente de cada año (también se utilizan las expresiones precios corrientes o nominales). Para poder comparar dichas cantidades es necesario homogeneizarlas en el sentido de que los valores estén expresados en los “mismos precios” (precios constantes o reales, también se utilizan las expresiones moneda constante o términos reales). La homogenización mencionada se denomina deflación y consiste en dividir los valores de la serie económica por un índice adecuado, conocido como deflactor. Cada fenómeno concreto exige de un deflactor adecuado, por ejemplo la capacidad de consumo tendría por deflactor el índice de precios al consumo.

Ejemplo 15.9 *En los últimos siete años el gasto en enseñanza, en millones de euros corrientes, y los índices de precios al consumo han sido* Calcúlese el

Año	Gastos en millones	IPC(base 2011)	IPC(base 2014)
2011	150	100	
2012	230	115	
2013	240	135	
2014	290	180	100
2015	300		105
2016	330		120
2017	400		150

porcentaje, en términos reales, en que ha variado el gasto en enseñanza durante los siete años considerados.

Demostración *A precios corrientes o valores nominales la evolución del gasto en enseñanza ha sido según la tasa de variación:*

$$\frac{400 - 150}{150} = 1,6667 \Rightarrow 166,67\%$$

Para obtener los gastos en enseñanza en términos reales hemos de deflactar los valores corrientes, transformando los euros corrientes de cada año en euros constantes del año base. En este ejemplo los IPC son tales que si procedemos a deflactar directamente tendríamos hasta el 2014 los gastos expresados en euros de 2011 y a partir de 2014 en euros de este año, por lo que las cantidades no serían comparables. Por ello en primer lugar vamos a expresar todos los índices en la misma base, usando $I_{t/2011} = I_{t/2014}I_{2014/2011}$ (índices expresados en tanto por uno) o bien, usando $I_{t/2014} = \frac{I_{t/2011}}{I_{2014/2011}}$ (índices expresados en tanto por uno)

5. DEFLACIÓN DE SERIES ECONÓMICAS

Año	IPC(base 2011)	IPC(base 2011) en %
2011	1	100
2012	1,15	115
2013	1,35	135
2014	1,80	180
2015	$1,05 \times 1,80$	189
2016	$1,2 \times 1,80$	216
2017	$1,5 \times 1,80$	270

IPC(base 2014)	IPC(base 2014) en %
$\frac{1}{1,8}$	55,55
$\frac{1,15}{1,8}$	63,86
$\frac{1,35}{1,8}$	75
1	100
1,05	105
1,2	120
1,5	150

Si expresamos los gastos en términos reales, en euros de 2011, tenemos:

Gastos en euros de 2011
$\frac{150}{1} = 150$
$\frac{230}{1,15} = 200$
$\frac{240}{1,35} = 177,78$
$\frac{290}{1,8} = 161,11$
$\frac{300}{1,89} = 158,73$
$\frac{330}{2,16} = 152,77$
$\frac{400}{2,7} = 148,15$

148,15-150 = -1,85, ha habido una disminución absoluta en términos reales de 1,85 millones de euros de 2011 lo que supone una disminución relativa (según tasa de variación)

$$\frac{148,15 - 150}{150} = \frac{-1,85}{150} = -0,0123 \Rightarrow -0,0123 \times 100 = -1,23\%$$

Si deflactamos tomando como referencia los euros de 2014, se tiene

Gastos en euros de 2014
$\frac{150}{0,55} = 270$
$\frac{230}{0,6389} = 359,94$
$\frac{240}{0,75} = 320$
$\frac{290}{1} = 290$
$\frac{300}{1,05} = 285,71$
$\frac{330}{1,2} = 275$
$\frac{400}{1,5} = 266,67$

266,67 - 270 = -3,33, ha habido una disminución absoluta del gasto en

Años	Salario	IPC
2008	1760	107
2009	1830	113
2010	1950	124,3
2011	2100	135,6
2012	2200	139

enseñanza durante el período 2011-2017 de 3,33 millones de euros de 2014, por tanto una disminución relativa de

$$\frac{266,67 - 270}{270} = \frac{-3,33}{270} = -0,0123 \Rightarrow -0,0123 \times 100 = -1,23\%$$

Obsérvese que se llega a la misma variación relativa en términos reales, tanto si se toma un año base como otro.

Ejemplo 15.10 El salario medio en los últimos cinco años en una empresa siderometalúrgica y los índices de precio de consumo han sido. Estudie el valor real de los salarios en euros constantes del 2012. Calcule la tasa de crecimiento medio anual de los salarios en términos reales. **Demostración**

Años	Salario	IPC	Salarios en euros constantes
2008	1760	$107/139 = 0,7698$	$1760/0,7698 = 2286,36$
2009	1830	$113/139 = 0,8129$	$1830/0,8129 = 2251,06$
2010	1950	$124,3/139 = 0,8942$	$1950/0,8942 = 2180,61$
2011	2100	$135,6/139 = 0,9755$	$2100/0,9755 = 2152,65$
2012	2200	$139/139 = 1,0000$	$2200/1 = 2200$

$$\sqrt[4]{\frac{S_4}{S_0}} - 1 = \sqrt[4]{\frac{2200}{2286,3}} - 1 = 0,99 - 1 = -0,01$$

Ha habido una disminución media anual del 1 % ($-0,01 \times 100 = -1\%$) en el período de tiempo considerado.

Ejemplo 15.11 El propietario de una vivienda alquiló esta en 500 euros mensuales a cuatro estudiantes del bootcamp de octubre de 2018. Este había pactado revisar el precio del alquiler en Enero de cada año de acuerdo al incremento de precios al consumo del último año. El valor del IPC se recoge en la siguiente tabla

Años	IPC
2017	113
2018	124,3
2019	135,6
2020	139

¿A cuánto ascenderá el precio del alquiler a partir de Enero de 2021?
Demostración

6. DEPENDENCIA DE UN ÍNDICE GENERAL RESPECTO DE UN GRUPO DE PRODUCTOS

Años	IPC	$IPC_{\text{año}_t/\text{año}_{t-1}}$	Alquiler
2017	113		
2018	124,3	$124,3/113=1,10$	500
2019	135,6	$135,6/124,3=1,0909$	$500 \times 1,10 = 550$
2020	139	$139/135,6 = 1,0251$	$550 \times 1,0909 = 599,99$
2021			$599,99 \times 1,0251 = 615,06$

6. Dependencia de un índice general respecto de un grupo de productos

Vamos a analizar cómo afecta a un índice general la variación en uno de los productos (artículos) o grupo de productos considerados en su construcción.

Muchos índices, entre ellos el IPC español, están basados en el índice de Laspeyres. Los índices de Laspeyres y Paasche poseen la propiedad de agregación: El índice de Laspeyres sobre un conjunto de productos es igual al índice de Laspeyres calculado sobre los índices de Laspeyres de cada subconjunto de productos. Lo mismo ocurre con el índice de Paasche. Escribiremos la propiedad de agregación con la siguiente notación general (donde el índice $I_{t/0}$ representa a $L_{t/0}$ en el caso del IPC, X_i representa al grupo i)

$$I_{t/0}(X) = \sum_{i=1}^n I_{t/0}(X_i)u_{i0}$$

La variación absoluta del índice entre dos períodos t y t' será

$$\begin{aligned} \Delta I(X) &= I_{t'/0}(X) - I_{t/0}(X) \\ &= \sum_{i=1}^n (I_{t'/0}(X_i) - I_{t/0}(X_i))u_{i0} \\ &= \sum_{i=1}^n \Delta I(X_i)u_{i0} \end{aligned}$$

Ejemplo 15.12 Las ponderaciones de los siguientes grupos en el IPC para el año base son Si el IPC de este año ha sido 115,96, calcule el IPC para el próximo

Grupo	Ponderación en %
Alimentos	35
Vestido	9
Vivienda	17
Menaje y Hogar	7
Salud	3
Transporte	12
Ocio	5
Enseñanzas	8
Otros	4
Total	100

año en los siguientes casos:

- *El índice de la vivienda se incrementa 15 puntos permaneciendo igual el resto de los índices.*
- *Los índices de vivienda y transporte se incrementan 10 y 5 puntos respectivamente, los índices de vestido y enseñanza disminuyen 2 y 1 punto respectivamente, no variando el resto de los índices.*

Demostración

■

$$\begin{aligned}\Delta I(X) &= \sum_{i=1}^n \Delta I(X_i) u_i = 0,15 \times 0,17 = 0,0255 \\ IPC(\text{prox año}) &= IPC(\text{año actual}) + \Delta IPC = 115,96 + 2,55 = 118,51\end{aligned}$$

■

$$\begin{aligned}\Delta I(X) &= \sum_{i=1}^n \Delta I(X_i) u_i \\ &= (0,10 \times 0,17) + (0,05 \times 0,12) + (-0,02 \times 0,09) + (-0,01 \times 0,08) \\ &= 0,0204 \\ IPC(\text{prox año}) &= IPC(\text{año actual}) + \Delta IPC = 115,96 + 2,04 = 118\end{aligned}$$

6. DEPENDENCIA DE UN ÍNDICE GENERAL RESPECTO DE UN
GRUPO DE PRODUCTOS

Análisis Descriptivo de Series Cronológicas

1. Definición de una serie cronológica. Representaciones numérica y gráfica

Una serie cronológica o temporal es una sucesión de observaciones de una variable Y , ordenadas en el tiempo, habitualmente obtenidas en períodos de tiempo de la misma duración. Gran parte de los datos publicados sobre actividades económicas tienen esta forma. Es frecuente representar dichos datos en una tabla como la que sigue

Tiempo	Obsevaciones
t_1	$y(t_1) = y_1$
t_2	$y(t_2) = y_2$
$\dots$	$\dots$
t_i	$y(t_i) = y_i$
$\dots$	$\dots$
t_n	$y(t_n) = y_n$


Utilizaremos la notación $y(t_i)$ o más abreviada y_i , indistintamente, según se quiera o no destacar explícitamente la dependencia de la variable Y respecto del tiempo.

Una serie cronológica puede considerarse un tipo especial de variable estadística bidimensional. Por tanto se le pueden aplicar técnicas propias de variables bidimensionales.

Por ejemplo, su representación gráfica es similar a la nube de puntos o diagrama de dispersión, dibujaremos un punto con coordenadas $(t_i, y(t_i))$ por cada observación. Para marcar la evolución (creciente o decreciente) a lo largo

2. COMPONENTES DE UNA SERIE CRONOLÓGICA. MODELOS

del tiempo de las observaciones, se unirán dichos puntos mediante segmentos. Si dentro de cada período de tiempo t_i se tienen varias observaciones, los



datos se representan en una tabla como la siguiente (por ejemplo, observaciones mensuales, trimestrales, ... en cada año)

Año/estaciones	1	...	j	...	s
t_1	y_{11}	...	y_{1j}	...	y_{1s}
...	...	...	...	...	...
t_i	y_{i1}	...	y_{ij}	...	y_{is}
...	...	...	...	...	...
t_n	y_{n1}	...	y_{nj}	...	y_{ns}

Ejemplo 16.1 Las denuncias en las Oficinas de Información al Consumidor en los últimos años han sido (expresadas en decenas de miles)

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13

2. Componentes de una serie cronológica. Modelos

Para el estudio de una serie cronologica, esta se descompone en cuatro componentes:

Tendencia secular, $\tau(t)$: Es el movimiento de la serie a largo plazo, es decir, refleja el comportamiento general de la serie. Por ejemplo, la tendencia creciente del IPC.

Variación estacional, $E(t)$: Representa fluctuaciones de la serie en periodos de tiempo que se repiten con una periodicidad conocida. Por ejemplo, los crecimientos y disminuciones en la serie por el hecho de estar en una determinada estación del año.

Variación cíclica, $C(t)$: Representa el comportamiento de la serie de carácter periódico, con periodos de duración diferente, desconocida y en general superior a un año. Por ejemplo, los ciclos económicos con etapas de prosperidad, recesión y recuperación.

Variación irregular, residual o aleatoria, $\epsilon(t)$:

Refleja hechos impredecibles que ocurren aleatoriamente y que normalmente suponen ligeras desviaciones de los valores de la variable respecto de las componentes anteriores, aunque en otras ocasiones no es así (catástrofes, pandemias, etc.)

El primer problema que se nos plantea es la construcción de un modelo que reuniendo las anteriores componentes explique el comportamiento de la serie cronológica. Básicamente consideramos dos modelos.

Definición 16.1 (Modelo aditivo) *Supone que las observaciones se generan como suma de las cuatro componentes*

$$Y(t) = \tau(t) + E(t) + C(t) + \epsilon(t)$$

En este modelo cada componente se expresa en la misma unidad que las observaciones. La variación irregular es independiente de las demás componentes, es decir, la magnitud de sus valores no depende de las otras componentes.

Definición 16.2 (Modelo multiplicativo) *Las observaciones están generadas por el producto de las componentes (modelo multiplicativo puro)*

$$Y(t) = \tau(t)E(t)C(t)\epsilon(t)$$

En este modelo la tendencia secular se expresa en la misma unidad que las observaciones y las demás componentes en tantos por uno. Aquí no se cumple la hipótesis de independencia de la variación irregular respecto de las demás componentes sino que es proporcional al resto de componentes.

En términos generales es más adecuado el modelo multiplicativo que el aditivo para la descripción de fenómenos económicos (por ejemplo, los factores estacionales y cíclicos no afectarán de la misma manera, en términos absolutos, a las ventas de un pequeño comercio y de un hipermercado, sino proporcionalmente al volumen de ventas de cada uno) Existen varios procedimientos para determinar el tipo de modelo al que responde una serie cronológica. La idea en todos consiste en poner de manifiesto si las fluctuaciones de la serie son aproximadamente constantes o proporcionales al valor de la tendencia. Uno de ellos es:

Análisis de la variabilidad de las diferencias y cocientes estacionales

Calculamos las diferencias y cocientes estacionales: Para cada estación j se comparan los datos en años consecutivos, $(i-1)$, i , mediante la diferencia y cociente de ambos

$$d_{ij} = y_{ij} - y_{(i-1)j} \quad k_{ij} = \frac{y_{ij}}{y_{(i-1)j}}$$

A continuación calculamos los coeficientes de variación sobre las diferencias y sobre los cocientes.

Si $CV(d) < CV(k)$ se elegirá el modelo aditivo, en caso contrario se optará por el modelo multiplicativo.

Ejemplo 16.2 *Estudiamos la conveniencia del modelo aditivo o multiplicativo sobre los datos del ejemplo 16.1*

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13

Demostración

$d_{ij} = y_{ij} - y_{(i-1)j}$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	—	—	—
2018	8-5=3	1,5	2
2019	10-8=2	2	1,5
2020	11,5-10=1,5	3	2,5

$k_{ij} = \frac{y_{ij}}{y_{(i-1)j}}$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	—	—	—
2018	$\frac{8}{5} = 1,6$	$\frac{5}{3,5} = 1,43$	$\frac{9}{7} = 1,29$
2019	1,25	1,4	1,17
2020	1,15	1,43	1,24

Con los datos de cada tabla calculamos la media, varianza y desviación típica para finalmente hallar el coeficiente de variación:

$$\begin{aligned} \bar{d} &= 2,11 & S_d^2 &= 0,321 & S_d &= 0,567 \\ \Rightarrow CV(d) &= \frac{S_d}{\bar{d}} = \frac{0,567}{2,11} = 0,268 \\ \bar{k} &= 1,328 & S_k^2 &= 0,019 & S_k &= 0,138 \\ \Rightarrow CV(k) &= \frac{S_k}{\bar{k}} = \frac{0,138}{1,328} = 0,104 \end{aligned}$$

3. Tendencia secular: ajuste de una recta de mínimos cuadrados y medias móviles

Estudiaremos dos procedimientos para la determinación de la tendencia secular en una serie cronológica:

- El primer método tiene un enfoque global, consiste en el ajuste de una recta de mínimos cuadrados al conjunto de todas las observaciones (podría considerarse el ajuste de otra función si las características de la serie así lo indicaran).
- El segundo método tiene un enfoque local, sólo se utilizan algunas observaciones para el cálculo de la tendencia en cada período mediante la media de dichas observaciones (medias móviles).

Es aconsejable utilizar métodos locales en las previsiones a corto plazo porque se adaptan mejor y más rápidamente a las circunstancias cambiantes. Sin embargo, en las previsiones a largo plazo donde nos apoyamos en aspectos permanentes de la evolución del fenómeno es mejor usar métodos globales.

3.1. Método del ajuste de una recta de mínimos cuadrados

Considerando una serie cronológica como un caso particular de variable estadística bidimensional, ajustaremos la recta de regresión de mínimos cuadrados de Y/X tal y como hemos visto en el tema 30

Ejemplo 16.3 *De nuevo utilizaremos los datos del ejemplo 16.1 para obtener la tendencia secular mediante el ajuste de una recta por mínimos cuadrados. Para que los datos sobre los que vamos a obtener la tendencia secular contengan fundamentalmente a ésta, se eliminan previamente las oscilaciones debidas a factores estacionales calculando los valores medios anuales (por estación). Y sobre dichos valores realizamos el ajuste.*

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13

$$\bar{y}_1 = \frac{5 + 3,5 + 7}{3} = 5,17 \quad \dots \quad \bar{y}_4 = \frac{11,5 + 10 + 13}{3} = 11,5$$

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre	Media anual
2017	5	3,5	7	5,17
2018	8	5	9	7,33
2019	10	7	10,5	9,17
2020	11,5	10	13	11,5

3. TENDENCIA SECULAR: AJUSTE DE UNA RECTA DE MÍNIMOS CUADRADOS Y MEDIAS MÓVILES

t_i	$x_i = t_i - 2016$	y_i media anual	x_i^2	$x_i y_i$
2017	1	5,17	1	5,17
2018	2	7,33	4	14,66
2019	3	9,17	9	27,51
2020	4	11,5	16	46
Total	10	33,17	30	93,34

Cuando se trabaja con años, un cambio de origen del tipo $x_i = t_i - 2016$ facilita notablemente los cálculos.

Exactamente igual que en el tema 30, obtenemos la recta de regresión de Y/X :

$$\begin{aligned}
 n = 4 \quad \bar{x} &= \frac{10}{4} = 2,5 \quad \bar{y} = \frac{33,17}{4} = 8,2917 \\
 S_x^2 &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \\
 &= \frac{30}{4} - 2,5^2 = 1,25 \\
 S_{xy} &= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} \\
 &= \frac{93,33}{4} - 2,5 \times 8,2917 = 2,604
 \end{aligned}$$

$$\begin{aligned}
 y - \bar{y} &= \frac{S_{xy}}{S_x^2} (x - \bar{x}) \\
 &\Leftrightarrow \\
 y - 8,2917 &= \frac{2,604}{1,25} (x - 2,5) \\
 &\Leftrightarrow \\
 y &= 3,08 + 2,083x
 \end{aligned}$$

Finalmente deshacemos el cambio de origen $x_i = t_i - 2016$ y expresamos y como la tendencia secular $\tau(t)$ a la que representa:

$$\begin{aligned}
 y &= 3,08 + 2,083x \\
 &\Leftrightarrow \\
 \tau(t) &= 3,08 + 2,083(t_i - 2016) \\
 &\Leftrightarrow \\
 \tau(t) &= -4196,248 + 2,083t_i
 \end{aligned}$$

3.2. Método de las medias móviles

En este método no se supone una forma funcional para la tendencia (ni una recta ni cualquier otro tipo de curva). El método de las medias móviles

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

es un método de suavizamiento de la serie cronológica que transforma las observaciones originales (con una representación gráfica típica de dientes de sierra) en unos valores con menores fluctuaciones. Para la aplicación de este método se van calculando sucesivamente medias aritméticas sobre subconjuntos de datos originales, en cada nueva media se elimina la observación más antigua e introduce la siguiente observación, avanzando así desde la primera hasta la última observación (de ahí su calificativo de móviles). Las medias móviles que utilizan igual ponderación para cada una de las observaciones se denominan medias móviles no ponderadas, otra posibilidad consiste en usar ponderaciones distintas para darle más importancia a las observaciones centrales en el cálculo de cada media (medias móviles ponderadas).

Se denomina media móvil de amplitud h a la que se calcula sobre h observaciones. Cuando este método se utiliza en la obtención de la tendencia secular, el conjunto de datos sobre los que se calcula cada media móvil debe contener a todas las estaciones para eliminar los altibajos debidos a factores estacionales (h debe ser igual al número de estaciones o un múltiplo de éste).

El valor de cada media móvil se asocia al período central de los períodos sobre los que se ha calculado. Si h es impar el período central está clara y unívocamente determinado (ejemplo 16.4), sin embargo, cuando h es par hay dos períodos centrales y la media móvil se asocia al punto intermedio entre ambos. Para que las medias móviles siempre estén referidas a los mismos períodos que las observaciones originales, en este último caso es necesario proceder a centrar las medias móviles para lo que se volverán a calcular medias móviles de amplitud 2 sobre las medias móviles de amplitud h (ejemplo 16.5)

Ejemplo 16.4 Utilizamos de nuevo los datos del ejemplo 16.1 para obtener la tendencia secular mediante medias móviles. Calculando medias móviles de


	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13

amplitud 3 incluiremos en su obtención una observación de cada cuatrimestre, compensando (suavizando como puede verse en el gráfico) así los mayores y menores valores que presentan las distintas estaciones.

$$\frac{5 + 3,5 + 7}{3} = 5,17 \quad \frac{3,5 + 7 + 8}{3} = 6,17 \quad \frac{7 + 8 + 5}{3} = 6,67 \dots$$

Medias Móviles	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	—	5,17	6,17
2018	6,67	7,33	8,00
2019	8,67	9,17	9,67
2020	10,67	11,50	—

3. TENDENCIA SECULAR: AJUSTE DE UNA RECTA DE MÍNIMOS CUADRADOS Y MEDIAS MÓVILES



Medias Móviles	1º trimestre	2º trimestre	3º trimestre	4º trimestre
2016	7	5	2,4	1,1
2017	10	7,1	3,6	1,4
2018	13,5	8,9	4,5	1,6
2019	17	11,2	5,3	2
2020	18,1	12,7	6,6	2,4

Ejemplo 16.5 Obtenga la tendencia secular mediante medias móviles.

Calculamos las medias móviles de amplitud 4 que estarán asociadas al punto central de los 4 trimestres sobre los que se calcula: donde las medias se han

2016	—	3,875	4,625	5,15
2017	5,45	5,525	6,4	6,85
2018	7,075	7,125	8	8,575
2019	8,775	8,875	9,15	9,525
2020	9,85	9,95	—	—

calculado de la siguiente forma:

$$\frac{7 + 5 + 2,4 + 1,1}{4} = 3,875 \quad \frac{5 + 2,4 + 1,1 + 10}{4} = 4,625 \quad \frac{2,4 + 1,1 + 10 + 7,1}{4} = 5,15$$

A continuación procedemos a centrar las medias móviles en los mismos períodos que las observaciones de la serie, tomando medias móviles de amplitud 2 sobre las anteriores medias móviles de amplitud 4:

Medias Móviles	1º trimestre	2º trimestre	3º trimestre	4º trimestre
2016	—	—	4,25	4,89
2017	5,30	5,49	5,96	6,63
2018	6,96	7,10	7,56	8,29
2019	8,68	8,83	9,01	9,34
2020	9,69	9,90	—	—

$$\frac{3,875 + 4,625}{2} = 4,25 \quad \frac{4,625 + 5,15}{2} = 4,89 \quad \frac{5,15 + 5,45}{2} = 5,3$$

4. Variación estacional. Desestacionalización

En el modelo multiplicativo la componente estacional de una serie cronológica se mide con un índice adimensional denominado índice de variación estacional, éste se expresa en porcentajes e indica la fluctuación del valor de la serie en dicha estación respecto del valor de la tendencia. Por ejemplo, un índice de variación estacional del 90 % indica que en esa estación hay una disminución del 10 % en relación al valor de la tendencia. En el modelo aditivo la componente estacional indica en términos absolutos (expresada en las mismas unidades que la variable observada) la cantidad en que se ha superado (si es positiva) o no se ha alcanzado (si es negativa) la tendencia. Por ejemplo, un valor de la componente estacional de -150 euros indica que a esa estación le corresponde un valor 150 euros por debajo del valor de la tendencia. Vamos a estudiar tres procedimientos para la obtención de la variación estacional:

4.1. Método de las medias simples

Denominado también método de las relaciones de las medias estacionales respecto a la tendencia.

Ejemplo 16.6 Explicamos el método con los datos del ejemplo 16.1 Sobre los

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre	Media anual
2017	5	3,5	7	5,17
2018	8	5	9	7,33
2019	10	7	10,5	9,17
2020	11,5	10	13	11,5

valores medios anuales ajustamos la recta de regresión de mínimos cuadrados como se hizo en el ejemplo 16.3

$$\begin{aligned}
 y &= 3,08 + 2,083x \\
 &\Leftrightarrow \\
 \tau(t) &= 3,08 + 2,083(t_i - 2016) \\
 &\Leftrightarrow \\
 \tau(t) &= -4196,248 + 2,083t_i
 \end{aligned}$$

La pendiente b de la recta estima lo que varia la tendencia por unidad de tiempo (un año en nuestro caso), por tanto la tendencia variará $\frac{b}{s}$ por cada estación que transcurra (s =número de estaciones).

En este ejemplo la tendencia crece $\frac{2,083}{3} = 0,694$ cada cuatrimestre. Calculamos los valores medios en cada estación

$$\frac{5 + 8 + 10 + 11,5}{4} = 8,625 \quad \dots \quad \frac{7 + 9 + 10,5 + 13}{4} = 9,875$$

4. VARIACIÓN ESTACIONAL. DESESTACIONALIZACIÓN

Seguidamente eliminamos la tendencia de los anteriores valores medios por estación, restando tantas veces $\frac{b}{s} = \frac{2,083}{3}0,694$ como estaciones del año han pasado, obteniendo las medias corregidas:

$$8,625 - \left(0 \times \frac{b}{s}\right) = 8,625 \quad 6,375 - \left(1 \times \frac{b}{s}\right) = 5,681 \quad 9,875 - \left(2 \times \frac{b}{s}\right) = 8,487$$

Calculamos la media de las medias corregidas (media global corregida):

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13
Media por estación	8,625	6,375	9,875
Media corregida	8,625	5,681	8,487

$$\frac{8,625 + 5,681 + 8,487}{3} = 7,5977$$

Comparando las medias corregidas con su promedio (por cociente o diferencia según el modelo sea multiplicativo o aditivo) obtenemos la variación estacional.

					Med Global Corre
					7,5977
I.V.E	Media Corre	8,625	5,681	8,487	
	Mod Multi	113,52 %	74,77 %	111,70 %	
	Mo Adi	1,0237	-1,9167	0,8893	

$$\begin{aligned} \frac{8,625}{7,5977} &= 113,52 \quad \dots \quad \frac{8,487}{7,5977} = 111,70 \\ 8,625 - 7,5977 &= 1,0237 \quad \dots \quad 8,487 - 7,5977 = 0,8893 \end{aligned}$$

En el modelo multiplicativo la variación estacional se expresa mediante los índices de variación estacional (IVE) que son valores adimensionales con la propiedad de que su media es 100 (1 si los IVE están expresados en tantos por uno). En el primer cuatrimestre el número de denuncias es un 13,52 % mayor que la tendencia, en el segundo cuatrimestre las denuncias no llegan a ser el 100 % de la tendencia sino que es un 25,23 % menor ($100 - 74,77 = 25,23$), ...

En el modelo aditivo la variación estacional esta expresada en las mismas unidades que la variable observada (decenas de miles de denuncias en este ejemplo) y su media es cero ($1,0273 + 1,9167 + 0,8893 = 0,0001 \neq 0$ debido a pequeños errores de redondeo). En el primer cuatrimestre hay 10273 decenas de miles de denuncias mas que la tendencia (10273 denuncias más), en el segundo cuatrimestre hay 19167 denuncias menos que la tendencia, ...

Ejemplo 16.7 Con el método de las medias simples obtenga la variación estacional de los datos del ejemplo 16.5

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

t_i	$x_i = t_i - 2015$	$y_i = \text{media anual}$	x_i^2	$x_i y_i$
2016	1	3,875	1	3,875
2017	2	5,525	4	11,05
2018	3	7,125	9	21,375
2019	4	8,875	16	35,5
2020	5	9,95	25	49,75
Total	15	35,35	55	121,55

- En primer lugar ajustamos la recta de tendencia sobre las medias anuales:

$$n = 5 \quad \bar{y} = \frac{15}{5} = 3 \quad \bar{y} = \frac{35,35}{5} = 7,07$$

$$S_x^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 = \frac{55}{5} - 3^2 = 2$$

$$S_{xy} = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} = \frac{121,55}{5} - (3 \times 7,07) = 3,1$$

$$\begin{aligned} y - \bar{y} &= \frac{S_{xy}}{S_x^2} (x - \bar{x}) \\ \Leftrightarrow \\ y - 7,07 &= \frac{3,1}{2} (x - 3) \\ \Leftrightarrow \\ y &= 2,42 + 1,55x \end{aligned}$$

deshacemos el cambio de origen $x_i = t_i - 2015$ y expresamos y como la tendencia secular $\tau(t)$

$$\begin{aligned} y &= 2,42 + 1,55x \\ \Leftrightarrow \\ \tau(t) &= 2,42 + 1,55(t - 2015) \\ \Leftrightarrow \\ \tau(t) &= -3125,67 + 1,55t \end{aligned}$$

- Seguidamente eliminamos la tendencia de los valores medios por estación, restando tantas veces $\frac{b}{s} = \frac{1,55}{4}$ como estaciones del año han pasado, obteniendo las medias corregidas:

$$13,12 - \left(0 \times \frac{b}{s} \right) = 13,12 \quad \dots \quad 1,7 - \left(3 \times \frac{b}{s} \right) = 0,5375$$

- Calculamos la media de las medias corregidas (media global corregida):

$$\frac{13,12 + 8,5952 + 3,705 + 0,5375}{4} = 6,48875$$

4. VARIACIÓN ESTACIONAL. DESESTACIONALIZACIÓN

Comparando las medias corregidas con su promedio (por cociente o diferencia según el modelo sea multiplicativo o aditivo) obtenemos la variación estacional.

$$\begin{aligned}\frac{13,12}{6,48875} \times 100 &= 202,196 & \dots & \frac{0,5375}{6,48875} \times 100 = 8,284 \\ 13,12 - 6,48875 &= 6,631 & \dots & 0,5375 - 6,48875 = -5,951\end{aligned}$$

En la siguiente tabla se recogen todos los cálculos:

	1º Trim	2º Trim	3º Trim	4º Trim	Med Anual
2016	7	5	2,4	1,1	3,875
2017	10	7,1	3,6	1,4	5,525
2018	13,5	8,9	4,5	1,6	7,125
2019	17	11,2	5,3	2	8,875
2020	18,1	12,7	6,6	2,4	9,95
Med estación	13,12	8,98	4,48	1,7	Med Global
Med Corre	13,12	8,59	3,71	0,54	6,49
Mod Multi	202,2	132,42	57,1	8,284	
Mod Adi	6,63	2,10	-2,78	-5,95	

En los dos métodos siguientes la idea básica es eliminar de las observaciones el valor de la tendencia secular, para ello es fundamental conocer el modelo que se adapta a la serie cronológica.

En el modelo multiplicativo eliminaremos la tendencia mediante cociente de las observaciones sobre la tendencia

$$\begin{aligned}Y(t) &= \tau(t)E(t)C(t)\epsilon(t) \\ \Rightarrow \\ \frac{Y(t)}{\tau(t)} &= E(t)C(t)\epsilon(t)\end{aligned}$$

Mientras que en el modelo aditivo lo haremos por diferencia

$$\begin{aligned}Y(t) &= \tau(t) + E(t) + C(t) + \epsilon(t) \\ \Rightarrow \\ Y(t) - \tau(t) &= E(t) + C(t) + \epsilon(t)\end{aligned}$$

Posteriormente se promedian estos valores $(E(t)C(t)\epsilon(t) \text{ o } E(t) + C(t) + \epsilon(t))$ sobre cada una de las estaciones, de esta forma los efectos unas veces positivos, otras negativos, de las componentes $C(t)$ y $\epsilon(t)$ se anulan, recogiendo en dicho promedio fundamentalmente el valor de la componente estacional.

4.2. Método de la razón (o diferencia) a la tendencia

Explicamos el método con los mismos datos del ejemplo 16.4 en el siguiente ejemplo.

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre	Media Anual
2017	5	3,5	7	5,167
2018	8	5	9	7,333
2019	10	7	10,5	9,167
2020	11,5	10	13	11,5

Ejemplo 16.8 ■ Sobre los valores medios anuales ajustamos la recta de regresión de mínimos cuadrados como se hizo en el ejemplo 16.3

$$\begin{aligned}
 y &= 3,08 + 2,083x \\
 &\Leftrightarrow \\
 \tau(t) &= 3,08 + 2,083(t - 2016) \\
 &\Leftrightarrow \\
 \tau(t) &= -4196,92 + 2,083t
 \end{aligned}$$

- Estimamos la tendencia secular para cada una de las estaciones de cada año, teniendo presente que la tendencia $\tau(t) = -4202,408 + 2,083t$ para un año t se asigna al período central del año (2º cuatrimestre en este ejemplo) y que la tendencia varía $\frac{b}{s} = \frac{2,083}{3}$ cada estación que pasa

$$\begin{aligned}
 \tau(2017) &= -4196,92 + (2,083 \times 2017) = 5,163 \\
 \tau(2020) &= -4196,92 + (2,083 \times 2020) = 11,413
 \end{aligned}$$

En el 3º cuatrimestre de 2017 la tendencia será $\frac{b}{s} = \frac{2,083}{3} = 0,694$ más que en el 2º cuatrimestre:

$$5,163 + 0,694 = 5,858$$

En el 1º cuatrimestre de 2017 la tendencia será $\frac{b}{s} = \frac{2,083}{3} = 0,694$ menos que en el 2º cuatrimestre:

$$5,163 - 0,694 = 4,469$$

Análogamente en el resto de los años.

También podríamos haber estimado la tendencia para todas las estaciones del primer año y sumando a éstas b se obtendría la tendencia para las estaciones del segundo año y así sucesivamente para todos los años.

El método que se sigue en este ejemplo evita la acumulación de errores de redondeo en la estimación de la tendencia.

- Se elimina de las observaciones, $Y(t)$, el valor de la tendencia, $\tau(t)$, realizando los cocientes $\frac{Y(t)}{\tau(t)}$ si suponemos el modelo multiplicativo y mediante las diferencias $Y(t) - \tau(t)$ si el modelo es aditivo. En lo que sigue supondremos el modelo multiplicativo (más adelante se

repetirá todo para el modelo aditivo).

$$\begin{array}{rcl} \frac{5}{4,469} & = & 1,12 \\ & \dots & \\ \frac{13}{12,11} & = & 1,07 \end{array}$$

- Calculamos la media por estación de los anteriores valores y la media de dichas medias (que es igual a la media global de todos los cocientes $\frac{Y(t)}{\tau(t)}$) Los índices de variación estacional (I.V.E.) se obtienen como cociente de las medias por estación sobre la media global (el resultado se multiplica por 100 para expresarlo en tantos por ciento)

$$\begin{array}{rcl} \frac{1,12 + 1,22 + 1,16 + 1,07}{4} & = & 1,14 \\ & \dots & \\ \frac{1,19 + 1,13 + 1,05 + 1,07}{4} & = & 1,11 \end{array}$$

$$\frac{1,14 + 0,75 + 1,11}{3} = 1,0012$$

$$\begin{array}{rcl} \frac{1,14}{1,0012} \times 100 & = & 114,13 \\ & \dots & \\ \frac{1,11}{1,0012} \times 100 & = & 111,1 \end{array}$$

En la siguiente tabla se recogen todos los cálculos (modelo multiplicativo): Repetimos los dos últimos pasos suponiendo el modelo aditivo

- Se elimina de las observaciones, $Y(t)$, el valor de la tendencia, $\tau(t)$, realizando las diferencias $Y(t) - \tau(t)$

$$5 - 4,47 = 0,53 \quad \dots \quad 13 - 12,11 = 0,89$$

Calculamos la media por estación de los anteriores valores y la media de dichas medias (que es igual a la media global de todas las diferencias $Y(t) - \tau(t)$). La variación estacional (V.E.) se obtiene como diferencia de la media por estación menos la media global

$$\begin{array}{rcl} \frac{0,531 + 1,448 + 1,364 + 0,781}{4} & = & 1,031 \\ & \dots & \\ \frac{1,142 + 1,059 + 0,476 + 0,892}{4} & = & 0,892 \\ \\ \frac{1,031 + -1,913 + 0,892}{3} & = & 0,003 \end{array}$$

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

Y(t)	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13
$\tau(t)$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	4,47	5,16	5,86
2018	6,55	7,25	7,94
2019	8,64	9,33	10,02
2020	10,72	11,41	12,11
$\frac{Y(t)}{\tau(t)}$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	1,119	0,678	1,195
2018	1,221	0,690	1,133
2019	1,158	0,750	1,047
2020	1,073	0,876	1,074
Media estación	1,143	0,749	1,112
I.V.E	1,141	0,748	1,111

$$1,031 - 0,003 = 1,028$$

...

$$0,892 - 0,003 = 0,889$$

En la siguiente tabla se recogen todos los cálculos (modelo aditivo):

Y(t)	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	5	3,5	7
2018	8	5	9
2019	10	7	10,5
2020	11,5	10	13
$\tau(t)$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	4,47	5,16	5,86
2018	6,55	7,25	7,94
2019	8,64	9,33	10,02
2020	10,72	11,41	12,11
$Y(t) - \tau(t)$	1º cuatrimestre	2º cuatrimestre	3º cuatrimestre
2017	0,53	-1,66	1,14
2018	1,45	-2,25	1,06
2019	1,36	-2,33	0,48
2020	0,78	-1,41	0,89
Media estación	1,031	-1,913	0,892
V.E	1,028	-1,917	0,889

Repetimos este método tanto para el modelo multiplicativo como aditivo en un ejemplo con un número par de estaciones. La única diferencia con el ejemplo anterior está en la etapa 2 donde el valor de la tendencia en un año t estará

asignada al punto medio del año, es decir, entre las dos estaciones centrales. Para referir los valores de la tendencia a los mismos períodos que las observaciones habrá que centrar las estimaciones de la tendencia en dichos períodos como se expone en el siguiente ejemplo.

Ejemplo 16.9 *Utilizamos los datos del ejemplo 16.5*

- *Sobre los valores medios anuales ajustamos la recta de regresión de mínimos cuadrados como se hizo en el ejemplo 16.3*

$$\begin{aligned} y &= 2,42 + 1,55x \\ &\Leftrightarrow \\ \tau(t) &= 2,42 + 1,55(t - 2015) \\ &\Leftrightarrow \\ \tau(t) &= 1,55t - 3120,83 \end{aligned}$$

- *Estimamos la tendencia secular para cada una de las estaciones de cada año, teniendo presente que la tendencia $\tau(t) = 1,55t - 3120,83$ para un año t se asigna al punto central del año (punto entre el 2º y 3º trimestre, en este ejemplo), que la tendencia varia*

$$\frac{b}{s} = \frac{1,55}{4} = 0,3875$$

cada estación que pasa y la mitad

$$\frac{b}{s} = \frac{0,3875}{2} = 0,19375$$

si sólo ha transcurrido media estación. Así:

$$\frac{b}{s} = \frac{0,3875}{2} = 0,19375$$

si sólo ha transcurrido media estación. Así:

- *Punto entre 2º y 3º trimestres de 2016*

$$\tau(2016) = 1,55 \times 2016 - 3120,83 = 3,97$$

- ...

- *Punto entre 2º y 3º trimestres de 2020*

$$\tau(2020) = 1,55 \times 2020 - 3120,83 = 10,17$$

- *La tendencia centrada en el 3º trimestre de 2016 será:*

$$3,97 + 0,19375 = 4,164$$

- ...

- *La tendencia centrada en el 3º trimestre de 2020 será:*

$$10,17 + 0,19375 = 10,364$$

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

- En el 4º trimestre de 2016 la tendencia será

$$\begin{aligned}\frac{b}{s} &= 1,554 = 0,3875 \\ 4,164 + 0,3875 &= 4,551\end{aligned}$$

- En el 2º trimestre de 2016 la tendencia será

$$\begin{aligned}\frac{b}{s} &= 1,554 = 0,3875 \\ 4,164 - 0,3875 &= 3,776\end{aligned}$$

- En el 1º trimestre de 2016 la tendencia será

$$\begin{aligned}\frac{b}{s} &= 1,554 = 0,3875 \\ 3,776 - 0,3875 &= 3,389\end{aligned}$$

Análogamente en el resto de los años.

Las etapas 3 y 4 son idénticas a las del ejemplo anterior.

En la siguiente tabla se recogen todos los cálculos (modelo multiplicativo): En

Y(t)	1º Trim	2º Trim	3º Trim	4º Trim	Med Anual
2016	7	5	2,4	1,1	3,875
2017	10	7,1	3,6	1,4	5,525
2018	13,5	8,9	4,5	1,6	7,125
2019	17	11,2	5,3	2	8,875
2020	18,1	12,7	6,6	2,4	9,95
$\tau(t)$	1º Trim	2º Trim	3º Trim	4º Trim	
2016	3,38875	3,77625	4,16375	4,55125	
2017	4,93875	5,32625	5,71375	6,10125	
2018	6,48875	6,87625	7,26375	7,65125	
2019	8,03875	8,42625	8,81375	9,20125	
2020	9,58875	9,97625	10,36375	10,75125	
$\frac{Y(t)}{\tau(t)}$	1º Trim	2º Trim	3º Trim	4 Trim	
2016	2,066	1,324	0,576	0,242	
2017	2,025	1,333	0,630	0,229	
2018	2,081	1,294	0,620	0,209	
2019	2,115	1,329	0,601	0,217	
2020	1,888	1,273	0,637	0,223	Med Global
Med Estación	2,035	1,311	0,613	0,224	1,046
I.V.E	194,594 %	125,356 %	58,610 %	21,440 %	

la siguiente tabla se recogen todos los cálculos (modelo aditivo):

El método de las medias simples (modelo aditivo) y el método de la diferencia a la tendencia coinciden, siempre nos conducen a los mismos valores para la variación estacional. (Compárense los resultados obtenidos en los diferentes ejemplos, las pequeñas diferencias que se aprecian se deben al tema de redondeo).

4. VARIACIÓN ESTACIONAL. DESESTACIONALIZACIÓN

Y(t)	1º Trim	2º Trim	3º Trim	4º Trim	Med Anual
2016	7	5	2,4	1,1	3,875
2017	10	7,1	3,6	1,4	5,525
2018	13,5	8,9	4,5	1,6	7,125
2019	17	11,2	5,3	2	8,875
2020	18,1	12,7	6,6	2,4	9,95
$\tau(t)$	1º Trim	2º Trim	3º Trim	4º Trim	
2016	3,389	3,776	4,164	4,551	
2017	4,939	5,326	5,714	6,101	
2018	6,489	6,876	7,264	7,651	
2019	8,039	8,426	8,814	9,201	
2020	9,589	9,976	10,364	10,751	
$Y(t) - \tau(t)$	1º Trim	2º Trim	3º Trim	4º Trim	
2016	3,611	1,224	-1,764	-3,451	
2017	5,061	1,774	-2,114	-4,701	
2018	7,011	2,024	-2,764	-6,051	
2019	8,961	2,774	-3,514	-7,201	
2020	8,511	2,724	-3,764	-8,351	Med Global
Med Estacion	6,631	2,104	-2,784	-5,951	0,00
V.E	6,631	2,104	-2,784	-5,951	

4.3. Método de la razón (o Diferencia) a las Medias Móviles

Este método es igual que el anterior con la única diferencia de que aquí se estima la tendencia para cada período (estación) mediante la técnica de suavizamiento de las medias móviles tal y como vimos en los ejemplos 16.4 y 16.5 (según el número de estaciones sea impar o par).

Ejemplo 16.10 *Utilizamos los datos del ejemplo 16.4 donde ya se calcularon las medias móviles para estimar la tendencia en cada estación*

Modelo Multiplicativo

Y(t)	1º Cuatri	2º Cuatri	3º Cuatri	
2017	5	3,5	7	
2018	8	5	9	
2019	10	7	10,5	
2020	11,5	10	13	
$\tau(t)$	1º Cuatri	2º Cuatri	3º Cuatri	
2017	—	5,167	6,17	
2018	6,667	7,333	8,00	
2019	8,667	9,167	9,67	
2020	10,667	11,5	—	
$\frac{Y(t)}{\tau(t)}$	1º Cuatri	2º Cuatri	3º Cuatri	
2017	—	0,677	1,135	
2018	1,200	0,682	1,125	
2019	1,154	0,764	1,086	
2020	1,078	0,870	—	Media Global
Media Estacion	1,144	0,748	1,115	1,003
I.V.E	114,112	74,623	111,265	

Modelo Aditivo

Y(t)	1º Cuatri	2º Cuatri	3º Cuatri	
2017	5	3,5	7	
2018	8	5	9	
2019	10	7	10,5	
2020	11,5	10	13	
$\tau(t)$	1º Cuatri	2º Cuatri	3º Cuatri	
2017	—	5,167	6,167	
2018	6,667	7,333	8,000	
2019	8,667	9,167	9,667	
2020	10,667	11,500	—	
$Y(t) - \tau(t)$	1º Cuatri	2º Cuatri	3º Cuatri	
2017	—	-1,667	0,833	
2018	1,333	-2,333	1,000	
2019	1,333	-2,167	0,833	
2020	0,833	-1,500	—	Media Global
Media Estacion	1,167	-1,917	0,889	0,0463
V.E	1,120	-1,963	0,843	

Ejemplo 16.11 Usamos los datos del ejemplo 16.5 donde se calcularon las medias móviles centradas en cada estación.

5. Desestacionalización

En ocasiones interesa conocer las variaciones estacionales y eliminarlas de las observaciones de la serie para poder ver mejor el comportamiento de ésta ajeno a causas estacionales. La eliminación de la componente estacional se conoce como desestacionalización de la serie y permite entre otras cosas comparar valores observados en estaciones distintas que están influidos, con toda seguridad, por

Modelo Multiplicativo

Y(t)	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	7	5	2,4	1,1	
2017	10	7,1	3,6	1,4	
2018	13,5	8,9	4,5	1,6	
2019	17	11,2	5,3	2	
2020	18,1	12,7	6,6	2,4	
$\tau(t)$	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	–	–	4,25	4,8875	
2017	5,3	5,4875	5,9625	6,625	
2018	6,9625	7,1	7,5625	8,2875	
2019	8,675	8,825	9,0125	9,3375	
2020	9,6875	9,9	–	–	
$\frac{Y(t)}{\tau(t)}$	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	–	–	0,565	0,225	
2017	1,887	1,294	0,604	0,211	
2018	1,939	1,254	0,595	0,193	
2019	1,960	1,269	0,588	0,214	
2020	1,868	1,283	–	–	Media Global
Media Estacion	1,913	1,275	0,588	0,211	0,997
I.V.E	191,965	127,896	58,980	21,159	

Modelo Aditivo

Y(t)	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	7	5	2,4	1,1	
2017	10	7,1	3,6	1,4	
2018	13,5	8,9	4,5	1,6	
2019	17	11,2	5,3	2	
2020	18,1	12,7	6,6	2,4	
$\tau(t)$	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	–	–	4,25	4,8875	
2017	5,3	5,4875	5,9625	6,625	
2018	6,9625	7,1	7,5625	8,2875	
2019	8,675	8,825	9,0125	9,3375	
2020	9,6875	9,9	–	–	
$Y(t) - \tau(t)$	1º Trim	2º Trim	3º Trim	4º Ttim	
2016	–	–	-1,850	-3,788	
2017	4,700	1,613	-2,363	-5,225	
2018	6,538	1,800	-3,063	-6,688	
2019	8,325	2,375	-3,713	-7,338	
2020	8,413	2,800	–	–	Media Global
Media Estacion	6,994	2,147	-2,747	-5,759	0,159
V.E	6,835	1,988	-2,905	-5,918	

este hecho. Así, si las ventas de juguetes presentan una variación estacional según un modelo multiplicativo del 48 % en el mes de marzo y del 156 % en el mes de diciembre no podremos comparar directamente las ventas de 13500 euros y 41500 euros respectivamente en los meses de marzo y diciembre del año pasado.

Suponiendo el modelo multiplicativo, como se ha indicado, y eliminando el efecto estacional mediante cociente (mediante diferencia si el modelo es aditivo), obtendríamos el valor de la serie si ésta no se hubiera visto afectada por factores estacionales

$$Y(t) = \tau(t)E(t)C(t)\epsilon(t) \Rightarrow \frac{Y(t)}{E(t)} = \tau(t)C(t)\epsilon(t)$$

$$\text{marzo} = \frac{13500}{0,48} = 28125$$

$$\text{diciembre} = \frac{41500}{1,56} = 26602,56$$

Donde se observa que el mes de marzo tuvo relativamente un mejor comportamiento que diciembre en cuanto a las ventas (aunque en términos absolutos éstas fueron claramente inferiores, 13500;41500).

Ejemplo 16.12 Desestacionalice la serie cronológica del ejemplo 16.3, considerando el modelo multiplicativo y los I.V.E. obtenidos con el método de la razón a las medias móviles. **Demostración** Desestacionalizar una serie consiste en eliminar los altibajos observados en la misma debidos a factores estacionales. Para ello, en el modelo multiplicativo, dividiremos las observaciones de cada estación por su I.V.E., expresado este último en tantos por uno (en el modelo aditivo restaremos a las observaciones de cada estación el valor de su variación estacional).

$$\frac{7}{1,9196} = 3,6466 \quad \frac{5}{1,279} = 3,909 \quad \dots$$

En la serie desestacionalizada se aprecia un aumento casi continuo de la

Y(t)	1º Trim	2º Trim	3º Trim	4º Ttim
2016	7	5	2,4	1,1
2017	10	7,1	3,6	1,4
2018	13,5	8,9	4,5	1,6
2019	17	11,2	5,3	2
2020	18,1	12,7	6,6	2,4
I.V.E	191,9645823	127,8959432	58,98024473	21,15922977
$\frac{Y(t)}{E(t)}$	1º Trim	2º Trim	3º Trim	4º Ttim
2016	3,647	3,909	4,069	5,199
2017	5,209	5,551	6,104	6,616
2018	7,033	6,959	7,630	7,562
2019	8,856	8,757	8,986	9,452
2020	9,429	9,930	11,190	11,343

variable observada sin las fluctuaciones causadas por los factores estacionales.

6. Predicción

Conociendo las cuatro componentes de una serie cronológica así como el modelo según el cual se relacionan podríamos conocer el valor de la serie en

cualquier período. La variación irregular es por naturaleza desconocida, del resto de componentes podemos tener a lo sumo una estimación de las mismas y el modelo es sencillamente un esquema artificial impuesto para facilitar el estudio de la serie. Por tanto, no se podrá conocer el valor de la serie para un período futuro, a lo sumo se podrá hacer una predicción. En este curso no se ha estudiado la variación cíclica por lo que la predicción se hará en base a la tendencia secular y variación estacional. Si el modelo es aditivo,

$$Y(t) = \tau(t) + E(t) + C(t) + \epsilon(t)$$

, la estimación del valor de la serie, $\hat{Y}(t)$, para un periodo futuro t estará dada por:

$$\hat{Y}(t) = \tau(t) + E(t)$$

Si la serie sigue un modelo multiplicativo,

$$Y(t) = \tau(t)E(t)C(t)\epsilon(t)$$

la predicción de su valor para un periodo futuro se hará mediante:

$$\hat{Y}(t) = \tau(t)E(t)$$

En ambos casos se está suponiendo que la variación cíclica no tiene una influencia fuerte en los valores de la serie.

Ejemplo 16.13 ¿Cuál sería el valor estimado de la serie del ejemplo 16.1 en el primer cuatrimestre de 2018?. Utilice los diferentes métodos y modelos.

Demostración Según la recta de tendencia ajustada,

$$\tau(t) = -4196,248 + 2,083t$$

el valor de la tendencia en el punto medio del año 2018 (punto medio del 2º cuatrimestre)0 se estima por:

$$\tau(2016) = -4196,248 + 2,083(2016) = 7,246$$

Cada cuatrimestre la tendencia aumenta $\frac{2,083}{3} = 0,694$, por tanto el valor de la tendencia en el primer cuatrimestre del año 2018 se estima en $7,246 - 0,694 = 6,552$. El valor estimado de la serie para el primer cuatrimestre de 2018 diferirá de este valor según la variación estacional para dicho cuatrimestre: Como se

Modelo Aditivo	
Método de las medias simples	Método de la diferencias a la tendencia
$\hat{Y}(t) = \tau(t) + E(t) = 6,552 + 1,028 = 7,580$	$\hat{Y}(t) = \tau(t) + E(t) = 6,552 + 1,028 = 7,580$

indicó anteriormente, estos dos métodos coinciden sobre el modelo aditivo (si se observa alguna diferencia es debida a errores de redondeo). En el método de la razón (diferencia) a las medias móviles la tendencia no se estima mediante el ajuste de una recta por mínimos cuadrados sobre las medias anuales sino mediante medias móviles, por lo que tendríamos que calcular el valor de la

CAPÍTULO 16. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

Modelo Multiplicativo	
Método de las medias simples	Método de la diferencias a la tendencia
$\hat{Y}(t) = \tau(t)E(t) = 6,552 \times \frac{113,52}{100} = 7,438$	$\hat{Y}(t) = \tau(t)E(t) = 6,552 \times \frac{114,11}{100} = 7,476$

tendencia a partir de ellas. Haría falta ajustar una recta a las medias móviles, esta recta no suele diferir mucho de la anterior recta de mínimos cuadrados sobre las medias anuales. Por este motivo, en la práctica, también para este último método se procede como en los dos anteriores: hallamos el valor estimado de la tendencia para las estaciones del año utilizando la recta de mínimos cuadrados sobre las media anuales y posteriormente se modifica de acuerdo al modelo y a la variación estacional estimada con el método de la razón (diferencia) a las medias móviles.

Método de la razón a las medias móviles	Método de la diferencias a las medias móviles
$\hat{Y}(t) = \tau(t)E(t) = 6,552 \times \frac{114,11}{100} = 7,476$	$\hat{Y}(t) = \tau(t) + E(t) = 6,552 + 1,1202 = 7,672$

CAPÍTULO 17

Probabilidad

1. Definición de Probabilidad. Asignación de Probabilidades

La distinción entre fenómenos determinísticos y aleatorios conduce a plantearse el problema de la medida de la incertidumbre mostrada por estos últimos.

Conviene recordar algunas de las propiedades de las frecuencias relativas de variables estadísticas que van a proporcionar un excelente apoyo intuitivo para la definición de la probabilidad.

Consideremos una tabla estadística en la que se recogen los resultados del lanzamiento de un dado en 300 ocasiones:

x_i	n_i	f_i
1	45	0,15
2	57	0,19
3	51	0,17
4	48	0,16
5	54	0,18
6	45	0,15
total	300	1

1. La frecuencia relativa de cualquier modalidad x_i es un número comprendido entre 0 y 1,

$$0 \leq f_i \leq 1$$

2. La frecuencia relativa de dos o más modalidades es la suma de las frecuencias relativas de cada una de las modalidades. Por ejemplo, la frecuencia relativa de obtener un número par es

$$g(\text{par}) = f(x_2 \cup x_4 \cup x_6) = f_2 + f_4 + f_6 = 0,19 + 0,16 + 0,15 = 0,50$$

3. La frecuencia relativa de todas las modalidades (suma de todas las frecuencias relativas) es 1,

$$\sum_{i=1}^6 f_i = 1$$

Llamaremos suceso a cada uno de los posibles resultados de un experimento o fenómeno aleatorio. Utilizaremos letras mayúsculas para referirnos a ellos. En el experimento de lanzar el dado, son ejemplos de sucesos: $A = \{\text{obtener par}\}$, $B = \{\text{obtener impar}\}$, $C = \{\text{obtener un 3}\}$, $D = \{\text{obtener un número mayor o igual que 4}\}$, $E = \{\text{obtener un número menor que 4}\} \dots$ Utilizaremos estos sucesos como ejemplos para ilustrar las siguientes definiciones y operaciones sobre sucesos.

Al suceso formado por un único resultado se denomina suceso elemental. Para estos sucesos, además de la notación general con letras mayúsculas, utilizaremos la notación ω_i . Un ejemplo de suceso elemental sería $C = \{\text{obtener un 3}\}$, ω_3 según esta última notación (notación análoga a la utilizada en variables estadísticas, x_i).

Se llama suceso seguro al suceso que siempre ocurre, está formado por todos los sucesos elementales, se nota Ω . En el ejemplo del dado $\Omega = \{1, 2, 3, 4, 5, 6\}$. Al conjunto vacío, que se nota $\emptyset$, se denomina suceso imposible.

1.1. Operaciones y Relaciones con Sucesos

El suceso A implica el suceso B si siempre que ocurre A ocurre B. Lo notaremos $A \subseteq B$.

En el ejemplo del dado: C implica B, $C \subseteq B$, $\{3\} \subseteq \{\text{impares}\}$. Se define la unión de dos sucesos A y B, $A \cup B$, como el suceso que ocurre cuando ocurre el suceso A o el suceso B. En el ejemplo del dado: $B = \{\text{impar}\}$, $D = \{\text{mayor o igual que 4}\}$, $B \cup D = \{1, 3, 4, 5, 6\}$.

La unión de sucesos cumple las propiedades conmutativa, asociativa e idempotente:

$$\begin{aligned} A \cup B &= B \cup A \\ A \cup (B \cup C) &= (A \cup B) \cup C \\ A \cup A &= A \end{aligned}$$

Se define la intersección de dos sucesos A y B, $A \cap B$, como el suceso que ocurre cuando ocurre el suceso A y el suceso B. En el ejemplo del dado: $B = \{\text{impar}\}$, $D = \{\text{mayor o igual que 4}\}$, $B \cap D = \{5\}$.

La intersección de sucesos cumple las propiedades conmutativa, asociativa e idempotente:

$$\begin{aligned} A \cap B &= B \cap A \\ A \cap (B \cap C) &= (A \cap B) \cap C \\ A \cap A &= A \end{aligned}$$

Las operaciones de unión e intersección conjuntamente cumplen las propiedades distributivas:

$$\begin{aligned} A \cap (B \cup C) &= (A \cap B) \cup (A \cap C) \\ A \cup (B \cap C) &= (A \cup B) \cap (A \cup C) \end{aligned}$$

y de absorción:

$$\begin{aligned} A \cup (A \cap B) &= A \\ A \cap (A \cup B) &= A \end{aligned}$$

Se define la diferencia de dos sucesos, $A - B$, como el suceso formado por los sucesos elementales que son de A pero no de B . Para poder definir correctamente esta operación se ha de cumplir que $B \subseteq A$. En el ejemplo del dado: $B = \{\text{impar}\}$, $C = \{3\}$, $B - C = \{1, 5\}$.

El suceso contrario (o complementario) de A es el que ocurre cuando no ocurre A . Se nota como $\bar{A}$. $\bar{A} = \Omega - A$. En el ejemplo del dado: $A = \{\text{par}\}$, $\bar{A} = \{\text{impar}\}$, $D = \{\text{mayor o igual que } 4\}$, $\bar{D} = \{\text{menor que } 4\}$.

Esta operación tiene las siguientes propiedades:

$$\begin{aligned} \bar{\bar{A}} &= A \\ A \subseteq B &\Rightarrow \bar{B} \subseteq \bar{A} \\ \bar{\emptyset} &= \Omega & \bar{\Omega} &= \emptyset \\ A \cap \bar{A} &= \emptyset & A \cup \bar{A} &= \Omega \\ \overline{A_1 \cup \dots \cup A_n} &= \bar{A}_1 \cap \dots \cap \bar{A}_n \\ \overline{A_1 \cap \dots \cap A_n} &= \bar{A}_1 \cup \dots \cup \bar{A}_n \end{aligned}$$

Los sucesos A y B son incompatibles si no pueden ocurrir ambos simultáneamente, $A \cap B = \emptyset$. Un suceso y su complementario son siempre sucesos incompatibles. En el ejemplo del dado: $A = \{\text{par}\}$ y $C = \{3\}$ son incompatibles.

Representaremos los resultados de un experimento aleatorio mediante el par $(\Omega, \mathcal{A})$, donde Ω es el conjunto de todos los sucesos elementales de un experimento aleatorio y $\mathcal{A}$ el conjunto de todos los sucesos (elementales y no elementales).

1.2. Definición de Probabilidad

Definimos una medida de probabilidad sobre $(\Omega, \mathcal{A})$ como una aplicación

$$\begin{aligned} (\Omega, \mathcal{A}) &\xrightarrow{P} \mathbb{R} \\ A \in \mathcal{A} &\rightarrow P(A) \in \mathbb{R} \end{aligned}$$

Verificando las siguientes condiciones:

1. $P(A) \geq 0 \quad \forall A \in \mathcal{A}$
2. Sean $A_1, \dots, A_n$ sucesos incompatibles

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

3. $P(\Omega) = 1$

Obsérvese la analogía entre estas tres condiciones y las propiedades de las frecuencias relativas que destacábamos al comienzo del capítulo 17.

1.3. Propiedades

1. $P(\bar{A}) = 1 - P(A)$ **Demostración**

$$\begin{aligned} 1 = P(\Omega) = P(A \cup \bar{A}) &= P(A) + P(\bar{A}) \\ &\Rightarrow \\ 1 - P(A) &= P(\bar{A}) \end{aligned}$$

2. Un caso particular de la propiedad anterior es $P(\emptyset) = 0$ **Demostración**

$$\begin{aligned} 1 = P(\Omega) = P(\emptyset \cup \Omega) &= P(\Omega) + P(\emptyset) \\ &\Rightarrow \\ 1 - P(\Omega) &= P(\emptyset) \\ P(\emptyset) &= 0 \end{aligned}$$

3. Si $B \subseteq A \Rightarrow P(A - B) = P(A) - P(B)$ **Demostración**

$$\begin{aligned} A = (A - B) \cup B \quad (A - B) \cap B = \emptyset &\Rightarrow P(A) = P(A - B) + P(B) \\ \Rightarrow &P(A - B) = P(A) - P(B) \end{aligned}$$

4. Si $B \subseteq A \Rightarrow P(B) \leq P(A)$ **Demostración**

$$P(B) = P(A) - P(A - B) \Rightarrow P(B) \leq P(A)$$

5. Un caso particular de la anterior propiedad nos conduce a que la probabilidad de todo suceso es menor o igual a 1.

$$A \subseteq \Omega \Rightarrow P(A) \leq 1$$

6. Probabilidad de la unión de sucesos compatibles:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración

$$\begin{aligned} A &= (A \cap B) \cup (A \cap \bar{B}) \Rightarrow P(A) = P(A \cap B) + P(A \cap \bar{B}) \\ B &= (B \cap A) \cup (B \cap \bar{A}) \Rightarrow P(B) = P(B \cap A) + P(B \cap \bar{A}) \\ P(A) + P(B) &= 2P(A \cap B) + P(A \cap \bar{B}) + P(B \cap \bar{A}) \\ A \cup B &= (A \cap B) \cup (A \cap \bar{B}) \cup (B \cap \bar{A}) \\ &\Rightarrow \\ P(A \cup B) &= P(A \cap B) + P(A \cap \bar{B}) + P(B \cap \bar{A}) \\ P(A) + P(B) &= 2P(A \cap B) + P(A \cap \bar{B}) + P(B \cap \bar{A}) \\ &= P(A \cup B) + P(A \cap B) \\ P(A) + P(B) - P(A \cap B) &= P(A \cup B) \end{aligned}$$

7. Consecuencia de la anterior propiedad es la subaditividad de P

$$P(\cup_{i=1}^n A_i) \leq \sum_{i=1}^n P(A_i)$$

Demostración

$$\begin{aligned}P(A_1 \cup A_2) &= P(A_1) + P(A_2) - P(A_1 \cap A_2) \\&\leq P(A_1) + P(A_2)\end{aligned}$$

y por inducción se demuestra para $\cup_{i=1}^n A_i$

1.4. Asignación de Probabilidad

Estas son las propiedades que tiene la medida de la probabilidad pero la teoría no especifica nada mas sobre los valores numéricos concretos que toma la función $P(A)$. Si el número de sucesos elementales, ω_i , es finito, es suficiente asignar probabilidades a los sucesos elementales, $P(\omega_i)$, y definir la probabilidad de un suceso A como

$$P(A) = \sum_{\omega_i \in A} P(\omega_i)$$

Si además de ser finito el conjunto de sucesos elementales, $\Omega = \omega_1, \dots, \omega_i, \dots, \omega_n$, suponemos que los sucesos elementales son *equiprobables*, $P(\omega_i) = \frac{1}{n} \quad \forall \omega_i$, obtenemos la conocida **regla de Laplace**

$$\begin{aligned}P(A) &= \sum_{\omega_i \in A} P(\omega_i) \\&= \sum_{\omega_i \in A} \frac{1}{n} \\&= \frac{k}{n} \\&= \frac{\text{Casos Favorables}}{\text{Casos Posibles}}\end{aligned}$$

Siendo k el número de sucesos elementales en A.

A esta concepción de la probabilidad se le denomina clásica o de Laplace. Según esta concepción de la probabilidad, en el ejemplo del dado se supondría que todas las caras (sucesos elementales) tienen la misma probabilidad de aparición y esta es:

$$P(\omega_i) = \frac{1}{6} = 0,16$$

En la semejanza entre las propiedades de las frecuencias relativas y la definición de probabilidad se basa la concepción frecuentista de la probabilidad. Considera que la probabilidad de un suceso es el valor límite en torno al cual se estabiliza la frecuencia relativa de ese suceso cuando se observa indefinidamente el fenómeno aleatorio. En el ejemplo del dado, si continuamos observando los resultados cuando lo lanzamos muchas veces (más de las 300 iniciales), se observará que el valor de las frecuencias relativas ya no cambia apenas y se estabiliza en torno a un valor que tomaremos como medida de la probabilidad de aparición de dicho suceso.

1. DEFINICIÓN DE PROBABILIDAD. ASIGNACIÓN DE PROBABILIDADES

x_i	n_i	f_i
1	45	0,15
2	57	0,19
3	51	0,17
4	48	0,16
5	54	0,18
6	45	0,15
Total	300	1

x_i	n_i	f_i
1	456	0,152
2	561	0,187
3	516	0,172
4	483	0,161
5	534	0,178
6	450	0,15
Total	3000	1

Cada una de estas concepciones tiene sus ventajas e inconvenientes. Por ejemplo, la concepción clásica no nos valdría para modelar el comportamiento de un dado, moneda, ... que estuviesen trucados para conseguir con mayor probabilidad determinados resultados o sencillamente mal contruidos. En contra de la concepción frecuentista se podría esgrimir el argumento de que multitud de fenómenos aleatorios no pueden repetirse de forma indefinida, especialmente fenómenos de tipo social y económico (elecciones, valores bursátiles, competiciones deportivas, ...). Esta y otras dificultades han llevado a considerar interpretaciones alternativas de la probabilidad como la concepción subjetiva en la que se considera un grado de creencia o confianza en la ocurrencia de un hecho (la probabilidad de que la selección española gane el próximo mundial de fútbol es de $4/5$).

Ejemplo 17.1 Calcule las probabilidades de los siguientes sucesos en el lanzamiento de un dado según la concepción clásica de Laplace y según la concepción frecuentista (tomando para este último caso como valores estables de las frecuencias los observados en los 3000 lanzamientos). Expréselo de distintas formas donde se pueda. $A=\{\text{obtener par}\}$, $B=\{\text{obtener impar}\}$, $C=\{\text{obtener un 3}\}$, $D=\{\text{obtener un número mayor o igual que 4}\}$, $E=\{\text{obtener un número menor que 4}\}$.

Demostración Concepción Clásica

$$\begin{aligned}
P(A) &= \sum_{\omega_i \in A} P(\omega_i) \\
&= \sum_{\omega_i \in A} \frac{1}{6} = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} \\
&= \frac{\text{Casos Favorables}}{\text{Casos Posibles}} \\
&= \frac{3}{6} = \frac{1}{2} = 0,5 \\
P(B) &= \frac{\text{Casos Favorables}}{\text{Casos Posibles}} \\
&= \frac{3}{6} = \frac{1}{2} \\
&= P(\bar{A}) = 1 - P(A) = 1 - \frac{1}{2} = \frac{1}{2} \\
P(C) &= \frac{\text{Casos Favorables}}{\text{Casos Posibles}} \\
&= \frac{1}{6} \\
P(D) &= \frac{\text{Casos Favorables}}{\text{Casos Posibles}} \\
&= \frac{3}{6} = \frac{1}{2} \\
P(E) &= \frac{\text{Casos Favorables}}{\text{Casos Posibles}} \\
&= \frac{3}{6} = \frac{1}{2}
\end{aligned}$$

Concepción Frecuentista

$$\begin{aligned}
P(A) &= \sum_{\omega_i \in A} P(\omega_i) \\
&= 0,187 + 0,161 + 0,150 \\
&= 0,498 \\
P(B) &= 0,152 + 0,172 + 0,178 \\
&= 0,502 \\
&= P(\bar{A}) = 1 - P(A) = 1 - 0,498 = 0,502 \\
P(C) &= 0,172 \\
P(D) &= \sum_{\omega_i \in D} P(\omega_i) \\
&= 0,161 + 0,178 + 0,150 = 0,489 \\
P(E) &= \sum_{\omega_i \in E} P(\omega_i) \\
&= 0,152 + 0,187 + 0,172 \\
&= 0,511
\end{aligned}$$

Ejemplo 17.2 En una ciudad se publican tres periódicos (A , B y C). Se sabe que un 60 % de la población está suscrito al periódico A , un 40 % al B , un 30 % al C , un 20 % a A y B , un 15 % a A y C , un 25 % a B y C , y un 10 % a los tres periódicos. ¿Qué parte de la población está suscrita al menos a un periódico?

Demostración En este ejemplo se hace una interpretación de la probabilidad según la concepción frecuentista.

Sean A , B y C los sucesos comprar el periódico A , B y C respectivamente. La pregunta se puede interpretar como qué parte de la población está suscrita a A o a B o a C . Lo que en la notación de sucesos equivale a la unión de los tres sucesos.

Utilizaremos la fórmula de la probabilidad de la unión de dos sucesos compatibles,

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$ y la propiedad asociativa de la unión de sucesos.

$$\begin{aligned}
 P(A \cup B \cup C) &= P(A \cup (B \cup C)) \\
 &= P(A) + P(B \cup C) - P(A \cap (B \cup C)) \\
 &= P(A) + P(B) + P(C) - P(B \cap C) - P(A \cap (B \cup C)) \\
 &= P(A) + P(B) + P(C) - P(B \cap C) - P((A \cap B) \cup (A \cap C)) \\
 &= P(A) + P(B) + P(C) - P(B \cap C) \\
 &\quad - (P(A \cap B) + P(A \cap C) - P(A \cap B \cap C)) \\
 &= P(A) + P(B) + P(C) - P(B \cap C) \\
 &\quad - P(A \cap B) - P(A \cap C) + P(A \cap B \cap C) \\
 &= \frac{60}{100} + \frac{40}{100} + \frac{30}{100} - \frac{25}{100} - \frac{20}{100} - \frac{15}{100} + \frac{10}{100} \\
 &= \frac{80}{100}
 \end{aligned}$$

El 80 % de la población está suscrita al menos a un periódico.

2. Definición de Probabilidad Condicionada. Sucesos Dependientes e Independientes

2.1. Probabilidad Condicionada

En determinadas situaciones es necesario calcular la probabilidad de sucesos dada la condición adicional de que cierto suceso ha ocurrido. A este tipo de probabilidad se denomina condicionada. Se define la probabilidad del suceso B condicionado a A , $P(B/A)$, como la probabilidad de que ocurra B supuesto que ha ocurrido A . Dicha probabilidad condicionada del suceso B al suceso A es igual a:

$$P(B/A) = \frac{P(B \cap A)}{P(A)} \quad P(A) > 0$$

Como en la probabilidad no condicionada, aquí se sigue tomando como modelo las frecuencias relativas. Supongamos el siguiente ejemplo sobre datos de los estudios completados por una población de 1000 habitantes. Entre los hombres

	Enseñanza Obligatoria	Bachillerato	Universitarios	Total
Hombres	250	160	40	450
Mujeres	350	140	60	550
Total	600	300	100	1000

(H sería el suceso conocido o que ha ocurrido) la frecuencia relativa de los que completaron los estudios universitarios (U sería el suceso sobre el que se quiere calcular la probabilidad, en este caso la frecuencia) es:

$$\begin{aligned}
 f(U/H) &= \frac{40}{450} \\
 &= \frac{\frac{40}{1000}}{\frac{450}{1000}} \\
 &= \frac{P(U \cap H)}{P(H)}
 \end{aligned}$$

Mientras que la frecuencia relativa de los que completaron los estudios universitarios (sin imponer ninguna condición sobre el sexo) es:

$$f(U) = \frac{100}{1000}$$

La definición de probabilidad condicionada, fijado A, verifica las condiciones de una medida de probabilidad:

- $P(B/A) \geq 0 \quad \forall B \in \mathcal{A}$
- Sean $B_1, \dots, B_n$ sucesos incompatibles

$$P\left(\bigcup_{i=1}^n B_i/A\right) = \sum_{i=1}^n P(B_i/A)$$

- $P(\Omega/A) = 1$

Demostración

- $P(B/A) = \frac{P(B \cap A)}{P(A)} \quad P(A) > 0 \text{ y } P(B \cap A) \geq 0$

$$\frac{P(B \cap A)}{P(A)} \geq 0$$

▪

$$\begin{aligned}
 P\left(\bigcup_{i=1}^n B_i/A\right) &= \frac{P\left(\left(\bigcup_{i=1}^n B_i\right) \cap A\right)}{P(A)} \\
 &= \frac{P\left(\bigcup_{i=1}^n (B_i \cap A)\right)}{P(A)} \\
 &= \frac{\sum_{i=1}^n P(B_i \cap A)}{P(A)} \\
 &= \sum_{i=1}^n \frac{P(B_i \cap A)}{P(A)} \\
 &= \sum_{i=1}^n P(B_i/A)
 \end{aligned}$$

2. DEFINICIÓN DE PROBABILIDAD CONDICIONADA. SUCESOS DEPENDIENTES E INDEPENDIENTES

$$\blacksquare P(\Omega/A) = \frac{P(\Omega \cap A)}{P(A)} = \frac{P(A)}{P(A)} = 1$$

Por tanto las propiedades de la probabilidad (no condicionada) también se cumplen para la probabilidad condicionada. De forma análoga a como se ha definido $P(B/A)$ se define $P(A/B)$ como:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} \quad P(B) > 0$$

De las definiciones de $P(B/A)$ y $P(A/B)$ se deduce la fórmula de la probabilidad compuesta o fórmula del producto de probabilidades

$$P(A \cap B) = P(A)P(B/A) = P(B)P(A/B)$$

Para tres sucesos el anterior resultado se puede enunciar de $3!=6$ formas alternativas, una de ellas es:

$$P(A \cap B \cap C) = P(A)P(B/A)P(C/A \cap B)$$

y para n sucesos una de sus posibles formas es:

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1)P(A_2/A_1) \dots P(A_n/A_1 \cap A_2 \cap \dots \cap A_{n-1})$$

2.2. Sucesos Dependientes e Independientes

En general $P(B/A) \neq P(B)$ y decimos en tal caso que B depende de A. Si $P(B/A) = P(B)$ diremos que B es independiente de A, es decir, que haya ocurrido A no modifica la probabilidad de B. En el caso de independendencia:

$$\begin{aligned} P(B/A) &= \frac{P(B \cap A)}{P(A)} = P(B) \\ \Rightarrow P(A \cap B) &= P(A)P(B) \end{aligned}$$

Y como consecuencia se sigue que también:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B)P(A)}{P(B)} = P(A)$$

luego si B es independiente de A, entonces A es independiente de B. Según todo lo anterior, se toma como definición de que los sucesos A y B son independientes la siguiente expresión:

$$P(A \cap B) = P(B)P(A)$$

La noción de independendencia es fundamental en la teoría de la probabilidad. La mayoría de los resultados en probabilidad se obtienen bajo la hipótesis de independendencia.

Ejemplo 17.3 En un dado con igual probabilidad de aparición para todas sus caras comprobar que los siguientes sucesos, dos a dos, son dependientes. $A=\{\text{obtener par}\}$, $B=\{\text{obtener impar}\}$, $C=\{\text{obtener un 3}\}$, $D=\{\text{obtener un número mayor o igual que 4}\}$, $E=\{\text{obtener un número menor que 4}\}$.

Demostración

$$\begin{aligned}
P(A \cap B) = 0 &\neq P(A)P(B) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4} \\
P(A \cap C) = 0 &\neq P(A)P(C) &= \frac{1}{2} \times \frac{1}{6} = \frac{1}{12} \\
P(A \cap D) = \frac{2}{6} &\neq P(A)P(D) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4} \\
P(A \cap E) = \frac{1}{6} &\neq P(A)P(E) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4} \\
P(B \cap C) = \frac{1}{6} &\neq P(B)P(C) &= \frac{1}{2} \times \frac{1}{6} = \frac{1}{12} \\
P(B \cap D) = \frac{1}{6} &\neq P(B)P(D) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4} \\
P(B \cap E) = \frac{2}{6} &\neq P(B)P(E) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4} \\
P(C \cap D) = 0 &\neq P(C)P(D) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{12} \\
P(C \cap E) = \frac{1}{6} &\neq P(C)P(E) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{12} \\
P(D \cap E) = 0 &\neq P(D)P(E) &= \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}
\end{aligned}$$

Ejemplo 17.4 En el bar de la academia el 90 % de los clientes son estudiantes. Se sabe que el 45 % de los clientes toman café y que el 30 % de los estudiantes toman café.

1. ¿Cuál es la probabilidad de que un cliente elegido al azar sea estudiante y tome café?
2. Se elige al azar un cliente que toma café, ¿cuál es la probabilidad de que sea estudiante?
3. ¿Son independientes los sucesos tomar café y ser estudiante?

Demostración Definimos los sucesos: E={el cliente es estudiante}, C={el cliente toma café}

1. Utilizamos la fórmula de la probabilidad compuesta:

$$P(C \cap E) = P(E)P(C/E) = \frac{90}{100} \frac{30}{100} = \frac{27}{100}$$

2. Según la definición de probabilidad condicionada:

$$P(E/C) = \frac{P(C \cap E)}{P(C)} = \frac{\frac{27}{100}}{\frac{45}{100}} = \frac{3}{5}$$

3. $P(C \cap E) = \frac{27}{100} \neq P(C)P(E) = \frac{45}{100} \frac{90}{100} = \frac{405}{10000}$

3. Formula de la Probabilidad Total. Fórmula de Bayes

Sean los sucesos $A_1, \dots, A_n$ una partición de Ω , es decir

$$A_i \cap A_j = \emptyset \quad \forall i \neq j \quad \bigcup_{i=1}^n A_i = \Omega$$

en este contexto, la fórmula de la probabilidad total afirma que:

$$P(B) = \sum_{i=1}^n P(B/A_i)P(A_i)$$

Demostración

$$\begin{aligned} P(B) &= P(B \cap \Omega) = P(B \cap (\bigcup_{i=1}^n A_i)) \\ &= P(\bigcup_{i=1}^n (B \cap A_i)) = \sum_{i=1}^n P(B \cap A_i) \\ &= \sum_{i=1}^n \frac{P(B/A_i)}{P(A_i)} P(A_i) \end{aligned}$$

Las probabilidades condicionadas de un suceso cualquiera B sobre cada uno de los elementos de la partición, $P(B/A_i)$ son normalmente conocidas. No es así con las probabilidades $P(A_i/B)$ Veamos cómo resolver este problema: por la fórmula de la probabilidad compuesta

$$P(A_k \cap B) = P(B)P(A_k/B) = P(A_k)P(B/A_k)$$

y según la fórmula de la probabilidad total

$$P(B) = \sum_{i=1}^n P(B/A_i)P(A_i)$$

de ambas expresiones se sigue:

$$P(A_k/B) = \frac{P(A_k \cap B)}{P(B)} = \frac{P(A_k)P(B/A_k)}{\sum_{i=1}^n P(B/A_i)P(A_i)}$$

Esta última expresión se conoce como fórmula de Bayes.

Ejemplo 17.5 La producción de una factoría se realiza en cuatro máquinas, M_1, M_2, M_3, M_4 . Diariamente la producción de cada una de las máquinas es la siguiente: Además sabemos que los porcentajes de piezas defectuosas producidas

M_1	M_2	M_3	M_4	Total
600	500	350	250	1700

por cada una de las máquinas son:

M_1	M_2	M_3	M_4
4 %	3,5 %	4,6 %	2 %

1. Si las piezas se almacenan conjuntamente, ¿cuál es la probabilidad de que al seleccionar una pieza al azar ésta sea defectuosa?
2. Se ha seleccionado una pieza defectuosa, ¿cuál es la probabilidad de que haya sido producida en la máquina M_2 ?

Demostración Sean M_1, M_2, M_3, M_4 los sucesos la pieza ha sido producida en M_1, M_2, M_3, M_4 respectivamente.

Sea D el suceso la pieza es defectuosa.

Los sucesos M_1, M_2, M_3, M_4 constituyen una partición de la producción total de la factoría.

- Según la fórmula de la probabilidad total

$$\begin{aligned}P(D) &= \sum_{i=1}^4 P(D/M_i)P(M_i) \\&= \frac{4}{100} \frac{600}{1700} + \frac{3,5}{100} \frac{500}{1700} + \frac{4,6}{100} \frac{350}{1700} + \frac{2}{100} \frac{250}{1700} \\&= \frac{6260}{1700000}\end{aligned}$$

- Según la fórmula de Bayes

$$\begin{aligned}P(M_2/D) &= \frac{P(D/M_2)P(M_2)}{\sum_{i=1}^4 P(D/M_i)P(M_i)} \\&= \frac{\frac{3,5}{100} \frac{500}{1700}}{\frac{6260}{1700000}} \\&= \frac{1750}{6260}\end{aligned}$$

Ejemplo 17.6 En una empresa el 8 % de los hombres y el 4,3 % de las mujeres ganan más de 25000 euros al año. Se sabe que el porcentaje de mujeres en la empresa es del 47 %. Se selecciona al azar un empleado que gana menos de 25000 euros, ¿cuál es la probabilidad de que sea mujer?

Demostración Definimos los sucesos, $H=\{\text{el empleado es hombre}\}$, $M=\{\text{el empleado es mujer}\}$ y $S=\{\text{el empleado supera los 25000 euros}\}$. Consecuentemente $\bar{S}=\{\text{el empleado gana menos de 25000 euros}\}$.

Sabemos

$$P(S/H) = \frac{8}{100} \quad P(S/M) = \frac{4,3}{100} \quad P(M) = \frac{47}{100}$$

por tanto:

$$\begin{aligned}P(\bar{S}/H) = 1 - P(S/H) &= 1 - \frac{8}{100} = \frac{92}{100} \\P(\bar{S}/M) = 1 - P(S/M) &= 1 - \frac{4,3}{100} = \frac{95,7}{100} \\P(H) &= P(\bar{M}) = 1 - P(M) = 1 - \frac{47}{100} = \frac{53}{100}\end{aligned}$$

3. FORMULA DE LA PROBABILIDAD TOTAL. FÓRMULA DE BAYES

Teniendo en cuenta que los sucesos H y M son una partición de los empleados de la empresa y aplicando la fórmula de Bayes, la probabilidad pedida es:

$$\begin{aligned}P(H/\bar{S}) &= \frac{P(\bar{S}/M)P(M)}{P(\bar{S}/M)P(M) + P(\bar{S}/H)P(H)} \\&= \frac{\frac{95,7}{100} \frac{47}{100}}{\frac{95,7}{100} \frac{47}{100} + \frac{92}{100} \frac{53}{100}} \\&= \frac{4497,9}{9373,9} = 0,4798323\end{aligned}$$

CAPÍTULO 18

Variables Aleatorias Y Distribuciones De Probabilidad

1. Concepto de Variable Aleatoria y Distribución de Probabilidad

Sea Ω el conjunto de sucesos elementales, ω_i , de un fenómeno aleatorio. Se define una variable aleatoria X como una función sobre Ω en $\mathbb{R}$

$$\begin{aligned}\Omega &\xrightarrow{X} \mathbb{R} \\ \omega_i &\rightarrow X(\omega_i) = x_i \in \mathbb{R}\end{aligned}$$

Es decir, mediante una variable aleatoria transformamos los resultados de un fenómeno aleatorio en valores numéricos que miden aquella característica del fenómeno que nos interesa destacar (en el siguiente ejemplo la característica es el número de cruces en tres lanzamientos de una moneda). Las probabilidades de que la variable aleatoria X tome los distintos valores dependen de las probabilidades, $P(\omega_i)$, asociadas al fenómeno aleatorio sobre el que se ha definido.

Se denomina distribución de probabilidad de la variable aleatoria X a las probabilidades asociadas a los distintos valores que puede tomar la variable aleatoria, $p_i = P[X = x_i]$

Toda distribución de probabilidad ha de cumplir:

- $p_i \geq 0 \quad \forall i$
- $\sum_{\forall i} p_i = 1$

(Esta definición es válida para variables que toman un conjunto discreto de valores, como el siguiente ejemplo. Sin embargo, cuando la variable aleatoria puede tomar un conjunto continuo de valores, la distribución de probabilidad no está caracterizada por probabilidades de valores aislados)

1. CONCEPTO DE VARIABLE ALEATORIA Y DISTRIBUCIÓN DE PROBABILIDAD

Ejemplo 18.1 Represente la variable aleatoria X =número de cruces en tres lanzamientos de una moneda y obtenga la distribución de probabilidad asociada.
Demostración

$$\odot = \text{Cara} \quad \otimes = \text{Cruz}$$

$$\begin{array}{rcl} \Omega & \xrightarrow{X} & \mathbb{R} \\ \odot\odot\odot & \rightarrow & X(\odot\odot\odot) = 0 \\ \otimes\odot\odot & \rightarrow & X(\otimes\odot\odot) = 1 \\ \odot\otimes\odot & \rightarrow & 1 \\ \odot\odot\otimes & \rightarrow & 1 \\ \otimes\otimes\odot & \rightarrow & 2 \\ \otimes\odot\otimes & \rightarrow & 2 \\ \odot\otimes\otimes & \rightarrow & 2 \\ \otimes\otimes\otimes & \rightarrow & 3 \end{array}$$

Suponemos que la probabilidad de cara y cruz es la misma, $\frac{1}{2}$. Por tanto, Por tanto la probabilidad de cada uno de los sucesos elementales de Ω es $(\frac{1}{2})^3 = \frac{1}{8}$ dado que son independientes los resultados de los tres lanzamientos de la moneda

$$P(\odot\odot\odot) = P(\odot \cap \odot \cap \odot) = P(\odot)P(\odot)P(\odot) = \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{8}$$

$$P(\otimes\otimes\otimes) = P(\otimes)P(\otimes)P(\otimes) = (\frac{1}{2})^3 = \frac{1}{8}$$

$$\begin{aligned} p_0 &= P[X = 0] = P[(\odot\odot\odot)] = \frac{1}{8} \\ p_1 &= P[X = 1] = P[(\otimes\odot\odot) \cup (\odot\otimes\odot) \cup (\odot\odot\otimes)] = \frac{1}{8} + \frac{1}{8} + \frac{1}{8} = \frac{3}{8} \\ p_2 &= P[X = 2] = P[(\otimes\otimes\odot) \cup (\odot\otimes\otimes) \cup (\otimes\odot\otimes)] = \frac{1}{8} + \frac{1}{8} + \frac{1}{8} = \frac{3}{8} \\ p_3 &= P[X = 3] = P[(\otimes\otimes\otimes)] = \frac{1}{8} \end{aligned}$$

La distribución de probabilidad se representa en una tabla como la que sigue como puede comprobarse $\sum_{i=1}^3 p_i = 1$

x_i	p_i
0	$\frac{1}{8}$
1	$\frac{3}{8}$
2	$\frac{3}{8}$
3	$\frac{1}{8}$

2. Función de Distribución. Variables Aleatorias Discretas y Variables Aleatorias Continuas

Se define la función de distribución de una variable aleatoria X como

$$F(X) = P[X \leq x] = P[\omega \in \Omega / X(\omega) \leq x] \quad x \in \mathbb{R}$$

Propiedades

- Si $x_i < x_j \Rightarrow F(x_i) \leq F(x_j)$ (La función es no decreciente)
- $F(-\infty)=0$ $F(+\infty)=1$
- $P[X > x]=1-F(x)$
- $P[x_1 < X \leq x_2]=F(x_2)-F(x_1)$


Ejemplo 18.2 Calcule la función de distribución asociada a la variable aleatoria X del ejemplo 18.1. Represente su gráfica. **Demostración** La distribución de probabilidad del ejemplo 18.1 está dada por: Su función de

x_i	p_i
0	$\frac{1}{8}$
1	$\frac{3}{8}$
2	$\frac{3}{8}$
3	$\frac{1}{8}$

distribución, por tanto será:

$$F(x) = P[X \leq x] = \sum_{x_i \leq x} p_i \begin{cases} 0 & \text{si } x < 0 \\ \frac{1}{8} & \text{si } 0 \leq x < 1 \\ \frac{4}{8} & \text{si } 1 \leq x < 2 \\ \frac{7}{8} & \text{si } 2 \leq x < 3 \\ 1 & \text{si } 3 \leq x \end{cases}$$

y su representación gráfica



2.1. Variables Aleatorias Discretas y Variables Aleatorias Continuas

Dependiendo del tipo de variable aleatoria, la función de distribución tendrá unas características diferentes. Si la variable aleatoria toma un conjunto de valores aislados (como el ejemplo 18.1 donde la variable aleatoria sólo toma los valores 0, 1, 2 y 3) diremos que es una variable aleatoria discreta.

Si la variable aleatoria toma un conjunto continuo de valores (por ejemplo la duración de una bombilla, que puede tomar cualquier valor a partir de 0) diremos que es una variable aleatoria continua. Como puede verse en el ejemplo 18.2, la función de distribución de una variable aleatoria discreta es una función escalonada, con saltos o discontinuidades de tamaño p_i en los valores x_i que toma la variable aleatoria. En este tipo de variables la función de distribución es igual a

$$F(x) = P[X \leq x] = \sum_{x_i \leq x} p_i$$

La función de distribución de una variable aleatoria continua es una función continua. La derivada de la función de distribución de una variable aleatoria continua se denomina función de densidad

$$F'(x) = f(x)$$

Como consecuencia de las propiedades de la función de distribución, toda función de densidad cumple que:

- $f(x) \geq 0 \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(x)dx = 1$

La probabilidad de que la variable aleatoria X tome valores en un determinado conjunto es igual a la integral definida de la función de densidad sobre dicho conjunto.

En particular:

$$\begin{aligned} P[X = a] &= \int_a^a f(x)dx = 0 \\ P[a < X < b] &= \int_a^b f(x)dx \\ P[a < X] &= \int_a^{+\infty} f(x)dx \\ P[X < a] &= \int_{-\infty}^a f(x)dx \end{aligned}$$

y por tanto la función de distribución se puede obtener a partir de la función de densidad:

$$F(x) = P[X \leq x] = \int_{-\infty}^x f(t)dt$$

3. Valor Esperado de una Variable Aleatoria. Momentos

Se define el valor esperado, esperanza matemática o media de una variable aleatoria discreta X como:

$$E[X] = \sum_{i=1}^{\infty} x_i p_i$$

(obsérvese la analogía con la media aritmética en Estadística Descriptiva en el capítulo 20) Esta definición puede generalizarse para cualquier potencia, de orden r , de la variable aleatoria. Son los momentos no centrados o respecto al origen:

$$\alpha_r = E[X^r] = \sum_{i=1}^{\infty} x_i^r p_i$$

La media es el momento no centrado de orden 1, adopta las siguientes notaciones en distintos contextos:

$$E[X] = \alpha_1 = \alpha = \mu$$

Se definen los momentos centrados, respecto a la esperanza o respecto a la media como:

$$\mu_r = E[(X - E[X])^r] = \sum_{i=1}^{+\infty} (x_i - E[X])^r p_i$$

La varianza es el momento centrado de orden 2, μ_2 , se suele notar como σ^2 . Su raíz cuadrada es la desviación típica que se nota como σ . Las mismas relaciones que se encontraron entre los momentos en el capítulo 20 siguen siendo válidas, destacando por su interés las siguientes:

$$\begin{aligned} \sigma^2 &= \mu_2 = \alpha_2 - \alpha_1^2 \\ \mu_3 &= \alpha_3 - 3\alpha_1\alpha_2 + 2\alpha_1^3 \\ \mu_4 &= \alpha_4 - 4\alpha_1\alpha_3 + 6\alpha_1^2\alpha_2 - 3\alpha_1^4 \end{aligned}$$

De forma análoga, se definen los momentos no centrados y centrados para una variable aleatoria continua X como:

$$\begin{aligned} \alpha_r &= E[X^r] = \int_{-\infty}^{+\infty} x^r f(x) dx \\ \mu_r &= E[(X - E[X])^r] = \int_{-\infty}^{+\infty} (x - E[x])^r f(x) dx \end{aligned}$$

Propiedades de la Media y de la Varianza

- $E[aX + b] = aE[X] + b$
- $\sigma^2[aX + b] = a^2\sigma^2[X]$
- **Desigualdad de Tchebycheff**

$$P[|X - E[X]| < k\sigma] = P[E[X] - k\sigma < X < E[X] + k\sigma] \leq 1 - \frac{1}{k^2}$$

Ejemplo 18.3 Calcule la media y la varianza de la distribución de probabilidad del ejemplo 18.2

Demostración

La distribución de probabilidad es:

x_i	p_i	$x_i p_i$	$x_i^2 p_i$
0	$\frac{1}{10}$	0	0
1	$\frac{1}{5}$	0,375	0,375
2	$\frac{1}{5}$	0,750	1,5
3	$\frac{1}{8}$	0,375	1,125
Total	1,5	3	

$$E[X] = \sum_{i=0}^3 x_i p_i = 1,5$$

$$\sigma^2 = \alpha_2 - \alpha_1^2 = \sum_{i=0}^3 x_i^2 p_i - \left(\sum_{i=0}^3 x_i p_i \right)^2 = 3 - 1,5^2 = 0,75$$

4. Otras medidas de Posición, Dispersión y Forma

4.1. Moda

Se define moda, **Mo**, como aquel valor de la variable aleatoria donde la función de densidad o distribución de probabilidad alcanza su máximo (según se trate de una variable aleatoria continua o discreta)

$$\begin{aligned} f(Mo) &\geq f(x) & \forall x \in \mathbb{R} \\ P[X = Mo] &\geq p_i & \forall i \end{aligned}$$

La variable aleatoria puede tener una o varias modas según se alcance el máximo en uno o más puntos.

4.2. Mediana, Cuartiles y Percentiles

Se define la mediana, Me , como aquel valor de la variable aleatoria tal que

$$F(Me) = P[X \leq Me] = \frac{1}{2}$$

De forma análoga, se definen los cuartiles Q_i y los percentiles P_i como aquellos valores de la variable aleatoria que verifican:

$$\begin{aligned} F(Q_i) &= P[X \leq Q_i] = \frac{i}{4} \\ F(P_i) &= P[X \leq P_i] = \frac{i}{100} \end{aligned}$$

(Estas definiciones valen para variables aleatorias continuas con función de distribución continua.

En variables aleatorias discretas con función de distribución escalonada, aunque el concepto es el mismo, la forma de calcularlas varía).

4.3. Coeficiente de Variación

Se define el coeficiente de variación, CV , como

$$CV = \frac{\sigma}{E[X]}$$

Es la medida de dispersión relativa más utilizada. Nos permite comparar la dispersión de distintas variables aleatorias.

4.4. Coeficiente de Asimetría

A partir de los momentos se define el coeficiente de asimetría de Fisher

$$\gamma_1 = \frac{\mu_3}{\sigma^3}$$

Si la distribución de probabilidad es simétrica $\gamma_1 = 0$, si es asimétrica a la izquierda $\gamma_1 < 0$ y si lo es a la derecha $\gamma_1 > 0$.

4.5. Coeficiente de Apuntamiento o Curtosis

A partir de los momentos se define el coeficiente de apuntamiento o curtosis de Fisher

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$$

Si la distribución de probabilidad tiene el mismo apuntamiento que la campana de Gauss o curva normal (mesocurtica) $\gamma_2 = 0$, si es menos apuntada (platicurtica) $\gamma_2 < 0$ y si es más apuntada (leptocurtica) $\gamma_2 > 0$

Ejemplo 18.4 Calcule la moda, mediana, percentil 75 y coeficiente de variación de las distribuciones de probabilidad del ejemplo 18.2

5. VARIABLES ALEATORIAS BIDIMENSIONALES. INDEPENDENCIA DE VARIABLES ALEATORIAS

x_i	p_i	p_i Acumulado
0	$\frac{1}{8}$	0,125
1	$\frac{3}{8}$	0,500
2	$\frac{3}{8}$	0,875
3	$\frac{1}{8}$	1

Demostración

Como puede observarse se trata de una distribución de probabilidad bimodal, la distribución de probabilidad $p_i = P[X = x_i]$ alcanza el máximo en dos puntos

$$Mo=1 \text{ y } Mo=2$$

Para el cálculo de la mediana y percentil 75 (tercer cuartil) procedemos de forma análoga a variables estadísticas en Estadística Descriptiva.

En el caso de la mediana, buscamos donde se alcanza o supera por primera vez la mitad de la probabilidad total $\frac{1}{2} = 0,5$ para $x_i = 1$ la probabilidad acumulada es igual a 0,5 por lo tanto se toma como mediana

$$Me = \frac{x_i + x_{i+1}}{2} = \frac{1 + 2}{2} = 1,5$$

En el caso del percentil 75, buscamos donde se alcanza o supera por primera vez el 75 % de la probabilidad total (0,75), para $x_i = 2$ la probabilidad acumulada es 0,875 > 0,75 por lo tanto

$$P_{75} = 2$$

Para calcular el coeficiente de variación utilizamos los valores de la media y varianza calculados en el ejemplo 18.3

$$\begin{aligned} CV &= \frac{\sigma}{E[X]} \\ &= \frac{\sqrt{0,75}}{1,5} \\ &= 0,577 \end{aligned}$$

5. Variables Aleatorias Bidimensionales. Independencia de Variables Aleatorias

Sea Ω el conjunto de sucesos elementales, ω_i , de un fenómeno aleatorio. Se define una variable aleatoria bidimensional (X,Y) como una función sobre Ω en $\mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$

$$\begin{aligned} \Omega &\xrightarrow{(X,Y)} \mathbb{R} \times \mathbb{R} \\ \omega_i &\rightarrow (X(\omega_i), Y(\omega_i)) \end{aligned}$$

Es decir, mediante una variable aleatoria bidimensional transformamos los resultados de un fenómeno aleatorio en dos valores numéricos que miden aquellas

CAPÍTULO 18. VARIABLES ALEATORIAS Y DISTRIBUCIONES DE PROBABILIDAD

dos características del fenómeno que nos interesan destacar. Una variable aleatoria bidimensional es un par de variables aleatorias unidimensionales definidas sobre el mismo fenómeno aleatorio que determina a Ω . Las probabilidades de que la variable aleatoria bidimensional (X, Y) tome los distintos valores dependen de las probabilidades, $P(\omega_i)$, asociadas al fenómeno aleatorio sobre el que se han definido.

Se denomina distribución de probabilidad bidimensional de las variables aleatorias (X, Y) a las probabilidades asociadas a los distintos valores que pueden tomar conjuntamente dichas variables aleatorias,

$$p_{ij} = P[(X, Y) = (x_i, y_j)] = P[X = x_i, Y = y_j]$$

Toda distribución de probabilidad bidimensional cumple (como en el caso unidimensional):

- $p_{ij} \geq 0 \quad \forall i, j$
- $\sum_i \sum_j p_{ij} = 1$

(Esta definición es válida cuando ambas variables son discretas, sin embargo cuando las variables aleatorias son continuas la distribución de probabilidad bidimensional está caracterizada por la función de densidad bidimensional).

Ejemplo 18.5 *Veamos un sencillo ejemplo de variable aleatoria bidimensional discreta.*

- X =número de cruces en tres lanzamientos de una moneda.
- Y =número de caras en los dos primeros lanzamientos de la moneda.

Demostración

$$\odot = \text{Cara} \quad \otimes = \text{Cruz}$$

La variable aleatoria bidimensional (X, Y) está definida por la siguiente aplicación:

Ω	$\xrightarrow{(X,Y)}$	$\mathbb{R} \times \mathbb{R}$
$\odot\odot\odot$	$\rightarrow$	$X(\odot\odot\odot) = (0, 2)$
$\otimes\odot\odot$	$\rightarrow$	$X(\otimes\odot\odot) = (1, 1)$
$\odot\otimes\odot$	$\rightarrow$	$(1, 1)$
$\odot\odot\otimes$	$\rightarrow$	$(1, 2)$
$\otimes\otimes\odot$	$\rightarrow$	$(2, 0)$
$\otimes\odot\otimes$	$\rightarrow$	$(2, 1)$
$\odot\otimes\otimes$	$\rightarrow$	$(2, 1)$
$\otimes\otimes\otimes$	$\rightarrow$	$(3, 0)$

Suponemos que la probabilidad de cara y cruz es la misma, $\frac{1}{2}$. Dado que son independientes los resultados de los tres lanzamientos de la moneda, la probabilidad de cada uno de los sucesos elementales de Ω es $\left(\frac{1}{2}\right)^3 = \frac{1}{8}$

$$P(\odot\odot\odot) = P(\odot \cap \odot \cap \odot) = P(\odot)P(\odot)P(\odot) = \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{8}$$

5. VARIABLES ALEATORIAS BIDIMENSIONALES. INDEPENDENCIA DE VARIABLES ALEATORIAS

$$P(\text{⊗⊗⊗}) = P(\text{⊗})P(\text{⊗})P(\text{⊗}) = \left(\frac{1}{2}\right)^3 = \frac{1}{8}$$

$$p_{02} = P[X = 0, Y = 2] = P[(\text{⊙⊙⊙})] = \frac{1}{8}$$

$$p_{11} = P[X = 1, Y = 1] = P[(\text{⊗⊙⊙}) \cup (\text{⊙⊗⊙})] = \frac{1}{8} + \frac{1}{8} = \frac{2}{8}$$

$$p_{12} = P[X = 1, Y = 2] = P[(\text{⊙⊙⊗})] = \frac{1}{8}$$

$$p_{20} = P[X = 2, Y = 0] = P[(\text{⊗⊗⊙})] = \frac{1}{8}$$

$$p_{21} = P[X = 2, Y = 1] = P[(\text{⊙⊗⊗}) \cup (\text{⊗⊙⊗})] = \frac{1}{8} + \frac{1}{8} = \frac{2}{8}$$

$$p_{30} = P[X = 3, Y = 0] = P[(\text{⊗⊗⊗})] = \frac{1}{8}$$

Las anteriores probabilidades se suelen recoger en una tabla de doble entrada (como las variables estadísticas bidimensionales en Estadística Descriptiva) como puede comprobarse

X Y	0	1	2
0	0	0	1/8
1	0	2/8	1/8
2	1/8	2/8	0
3	1/8	0	0

$$\sum_{i=0}^3 \sum_{j=0}^2 p_{ij} = 1$$

5.1. Función de Distribución Bidimensional. Función de Densidad Bidimensional

Dada una variable aleatoria bidimensional (X,Y) , se define la función de distribución (conjunta) de (X,Y) como:

$$\begin{aligned} F(X, Y) &= P[X \leq x, Y \leq y] \\ &= P[\omega \in \Omega / X(\omega) \leq x, Y(\omega) \leq y] \quad \forall (x, y) \in \mathbb{R}^2 \end{aligned}$$

Si las variables aleatorias son discretas la función de distribución es escalonada (discontinua). Si las variables aleatorias son continuas la siguiente derivada de la función de distribución conjunta es la función de densidad (conjunta) de (X, Y):

$$\frac{\partial^2 F(X, Y)}{\partial x \partial y} = f(x, y)$$

Toda función de densidad bidimensional cumple las siguientes propiedades que la caracterizan:

- $f(x, y) \geq 0 \quad \forall (x, y) \in \mathbb{R}^2$
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$

La probabilidad de que la variable aleatoria bidimensional (X,Y) tome valores en un determinado conjunto es igual a la integral definida de la función de densidad bidimensional sobre dicho conjunto.

En particular:

$$F(x, y) = P[X \leq x, Y \leq y] = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

5.2. Distribuciones de Probabilidad Marginales

Para variables aleatorias discretas, se define la distribución de probabilidad marginal de X como

$$\begin{aligned} p_{i\bullet} &= P[X = x_i] \\ &= P[X = x_i, Y = \text{cualquier valor}] \\ &= \sum_{\forall j} p_{ij} \end{aligned}$$

Análogamente para la variable aleatoria Y

$$\begin{aligned} p_{\bullet j} &= P[Y = y_j] \\ &= P[X = \text{cualquier valor}, Y = y_j] \\ &= \sum_{\forall i} p_{ij} \end{aligned}$$

Para variables aleatorias continuas, se define la función de densidad marginal de X como

$$\begin{aligned} f_1(x) &= f_X(x) \\ &= \int_{-\infty}^{+\infty} f(x, y) dy \end{aligned}$$

Análogamente para la variable aleatoria Y

$$\begin{aligned} f_2(y) &= f_Y(y) \\ &= \int_{-\infty}^{+\infty} f(x, y) dx \end{aligned}$$

Ejemplo 18.6 Calcule las distribuciones de probabilidad marginales para las distribuciones de probabilidad bidimensionales del ejemplo 18.5

Demostración Sumando en los márgenes de la tabla de la distribución de probabilidad bidimensional (de forma análoga a como se hizo en Estadística Descriptiva) se obtienen la distribución de probabilidad marginal de X ($p_{i\bullet}$) y la distribución de probabilidad marginal de Y ($p_{\bullet j}$). Como puede comprobarse, la distribución de probabilidad marginal de X coincide con la distribución de probabilidad unidimensional de X=número de cruces en tres lanzamientos de una moneda que se obtuvo en el ejemplo 18.1

5. VARIABLES ALEATORIAS BIDIMENSIONALES. INDEPENDENCIA DE VARIABLES ALEATORIAS

X Y	0	1	2	$p_{i\bullet}$
0	0	0	1/8	1/8
1	0	2/8	1/8	3/8
2	1/8	2/8	0	3/8
3	1/8	0	0	1/8
$p_{\bullet j}$	2/8	4/8	2/8	1

5.3. Independencia de Variables Aleatorias

Recordemos que dos sucesos A y B son independientes si

$$P(A \cap B) = P(A)P(B)$$

En el caso discreto, diremos que las variables X e Y son independientes si

$$P[X = x_i, Y = y_j] = P[X = x_i]P[Y = y_j] \quad \forall x_i, y_j$$

o lo que es lo mismo

$$p_{ij} = p_{i\bullet}p_{\bullet j} \quad \forall i, j$$

Ejemplo 18.7 Estudiar la independencia de las variables aleatorias del ejemplo 18.5

Demostración Como puede comprobarse fácilmente, $p_{00} = 0 \neq p_{0\bullet}p_{\bullet 0} = \frac{1}{8}\frac{2}{8} =$

X Y	0	1	2	$p_{i\bullet}$
0	0	0	1/8	1/8
1	0	2/8	1/8	3/8
2	1/8	2/8	0	3/8
3	1/8	0	0	1/8
$p_{\bullet j}$	2/8	4/8	2/8	1

$\frac{1}{32}$, luego no se cumple la condición de independencia, $p_{ij} \neq p_{i\bullet}p_{\bullet j} \quad \forall i, j$ En ese caso diremos que las variables aleatorias X e Y son dependientes.

5.4. Principales Momentos en Variables Aleatorias Bidimensionales

Definición y Propiedades

Media Marginal de X

- Variables discretas:

$$E[X] = \sum_{i=1}^{\infty} x_i p_{i\bullet}$$

- Variables continuas:

$$E[X] = \int_{-\infty}^{\infty} x f_1(x) dx$$

Media Marginal de Y

- Variables discretas:

$$E[Y] = \sum_{j=1}^{\infty} y_j p_{\bullet j}$$

- Variables continuas:

$$E[Y] = \int_{-\infty}^{\infty} y f_2(y) dy$$

Propiedades

$$E[X + Y] = E[X] + E[Y]$$

Esta propiedad es igualmente válida si la suma se refiere a más de dos variables aleatorias.

Varianza Marginal de X

- Variables discretas:

$$\begin{aligned} Var[X] &= \sigma^2[X] = \sigma_x^2 \\ &= \sum_{i=1}^{+\infty} (x_i - E[X])^2 p_{i\bullet} \\ &= E[X^2] - E[X]^2 \end{aligned}$$

- Variables continuas:

$$\begin{aligned} Var[X] &= \sigma^2[X] = \sigma_x^2 \\ &= \int_{-\infty}^{+\infty} (x - E[X])^2 f_1(x) dx \\ &= E[X^2] - E[X]^2 \end{aligned}$$

Varianza Marginal de Y

- Variables discretas:

$$\begin{aligned} Var[Y] &= \sigma^2[Y] = \sigma_y^2 \\ &= \sum_{j=1}^{+\infty} (y_j - E[Y])^2 p_{\bullet j} \\ &= E[Y^2] - E[Y]^2 \end{aligned}$$

- Variables continuas:

$$\begin{aligned} Var[Y] &= \sigma^2[Y] = \sigma_y^2 \\ &= \int_{-\infty}^{+\infty} (y - E[Y])^2 f_2(y) dy \\ &= E[Y^2] - E[Y]^2 \end{aligned}$$

Propiedades

$$\begin{aligned} \text{Var}[X + Y] &= \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X, Y] \\ \text{Var}[X - Y] &= \text{Var}[X] + \text{Var}[Y] - 2\text{Cov}[X, Y] \end{aligned}$$

Covarianza momento centrado de órdenes 1,1

- Variables discretas:

$$\begin{aligned} \text{Cov}[X, Y] &= \sigma[X, Y] = \sigma_{xy} \\ &= E[(X - E[X])(Y - E[Y])] \\ &= \sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} (x_i - E[X]) (y_j - E[Y]) p_{ij} \end{aligned}$$

- Variables continuas:

$$\begin{aligned} \text{Cov}[X, Y] &= \sigma[X, Y] = \sigma_{xy} \\ &= E[(X - E[X])(Y - E[Y])] \\ &= \int_{-\infty}^{+\infty} \sum_{-\infty}^{+\infty} (x - E[X]) (y - E[Y]) f(x, y) dx dy \end{aligned}$$

Propiedades

$$\text{Cov}[X + Y] = E[XY] - E[X]E[Y]$$

Si X e Y son independientes $E[XY] = E[X]E[Y]$ Por tanto en caso de independencia: $\text{Cov}[X, Y] = 0$ y $\text{Var}[X \pm Y] = \text{Var}[X] + \text{Var}[Y]$

CAPÍTULO 19

Distribuciones Discretas de Probabilidad

1. Distribución Uniforme Discreta

Una variable aleatoria discreta X sigue una distribución Uniforme en n puntos $x_1, \dots, x_n$, si su distribución de probabilidad es:

$$p_k = P[X = x_k] = \frac{1}{n} \quad k = 1, \dots, n$$

(Esta es la distribución que se asume en la concepción de la probabilidad clásica o de Laplace) La variable aleatoria que representa el valor obtenido al lanzar un dado no cargado sigue una distribución Uniforme discreta con probabilidad $\frac{1}{6}$ para cada uno de los seis posibles valores. La media y varianza para estas variables aleatorias se calculan como sigue:

Media

$$\begin{aligned} E[X] &= \sum_{k=1}^n x_k p_k \\ &= \sum_{k=1}^n x_k \frac{1}{n} \\ &= \frac{\sum_{k=1}^n x_k}{n} \end{aligned}$$

Varianza

$$\begin{aligned} E[X^2] &= \sum_{k=1}^n x_k^2 p_k \\ &= \sum_{k=1}^n x_k^2 \frac{1}{n} \\ &= \frac{\sum_{k=1}^n x_k^2}{n} \\ Var[X] &= E[X^2] - (E[X])^2 \\ &= \frac{\sum_{k=1}^n x_k^2}{n} - \left(\frac{\sum_{k=1}^n x_k}{n} \right)^2 \end{aligned}$$

2. Distribución Binomial**2.1. Distribución Binomial de Parámetros 1 y p (Distribución de Bernoulli)**

Consideramos un experimento que puede presentar dos resultados:

$$A = \text{éxito} \quad \bar{A} = \text{fracaso}$$

con probabilidad $P(A) = p$ y $P(\bar{A}) = q$, donde evidentemente $p+q=1$. A dicho experimento le asociamos la variable aleatoria:

$$X = \begin{cases} 1 & \text{si ocurre } A \\ 0 & \text{si ocurre } \bar{A} \end{cases}$$

su distribución de probabilidad será:

$$\begin{aligned} P[X = 1] &= p \\ P[X = 0] &= q = 1 - p \end{aligned}$$

La anterior distribución de probabilidad se conoce como distribución Binomial de parámetros 1 y p. Se nota como $X \sim \mathcal{B}(1, p)$, 1 es el número de veces que se observa o realiza el experimento y p es la probabilidad de obtener éxito.

Media

$$\begin{aligned} E[X] &= \sum_{k=1}^n x_k p_k \\ &= (0 \times q) + (1 \times p) \\ &= p \end{aligned}$$

Varianza

$$\begin{aligned}
E[X^2] &= (0^2 \times q) + (1^2 \times p) \\
&= p \\
Var[X] &= E[X^2] - (E[X])^2 \\
&= p - p^2 \\
&= p(1 - p) \\
&= p \times q
\end{aligned}$$

2.2. Distribución Binomial de Parámetros n y p

Sea la variable aleatoria X la suma de n variables aleatorias independientes e idénticamente distribuidas (i.i.d.) según una distribución de probabilidad $\mathcal{B}(1, p)$, es decir $X_i \sim \mathcal{B}(1, p)$ $i = 1, \dots, n$

$$X = X_1 + X_2 + \dots + X_n$$

La variable aleatoria X puede tomar todos los valores enteros comprendidos entre 0 y n, ambos inclusive, y representa el número de éxitos que se obtienen en n pruebas o experimentos idénticos e independientes.

A la distribución de esta variable aleatoria se le llama distribución Binomial de parámetros n y p. Se nota $\mathcal{B}(n, p)$, n es el número de pruebas idénticas e independientes que se realizan u observan y p la probabilidad de obtener éxito en cada prueba.

Vamos a calcular la distribución de probabilidad asociada a esta variable aleatoria X, es decir:

$$p_x = P[X = x] \quad x = 0, \dots, n$$

X toma el valor x si por ejemplo se observa en las n realizaciones del experimento una secuencia de éxitos y fracasos como la que sigue:

$$\underbrace{\underbrace{AA \dots A}_x \underbrace{\overline{AA} \dots \overline{A}}_{n-x}}_n$$

Dado que las pruebas o realizaciones del experimento son independientes:

$$\begin{aligned}
P(\underbrace{AA \dots A}_x \underbrace{\overline{AA} \dots \overline{A}}_{n-x}) &= \underbrace{pp \dots p}_x \underbrace{qq \dots q}_{n-x} \\
&= p^x q^{n-x}
\end{aligned}$$

Además, cualquier otra reordenación de la anterior secuencia de resultados tiene también x éxitos.

Dado que el número total de distintas reordenaciones es

$$\binom{n}{r} = \frac{n!}{x!(n-x)!}$$

Se sigue:

$$p_x = P[X = x] = \binom{n}{r} p^x q^{n-x} \quad x = 0, \dots, n$$

Se puede comprobar que los valores p_x verifican las dos condiciones que toda distribución de probabilidad ha de cumplir:

$$\blacksquare p_x \geq 0 \quad \forall x$$

$$\blacksquare \sum_{x=0}^n p_x = 1$$

Dado que p , q , n y x son no negativos x y p también lo será.

La suma de todas las probabilidades se corresponden con el desarrollo del binomio $(p + q)^n = 1^n = 1$

$$\begin{aligned} \sum_{x=0}^n p_x &= \sum_{x=0}^n \binom{n}{x} p^x q^{n-x} \\ &= (p + q)^n \end{aligned}$$

Media

$$\begin{aligned} E[X] &= E[X_1 + X_2 + \dots + X_n] \\ &= E[X_1] + E[X_2] + \dots + E[X_n] \\ &= p + p + \dots + p = n \times p \end{aligned}$$

Varianza Dado que $X_1 + X_2 + \dots + X_n$ son independientes la varianza de la suma de dichas variables es igual a la suma de las varianzas de cada variable

$$\begin{aligned} \sigma^2[X] &= \sigma^2[X_1 + X_2 + \dots + X_n] \\ &= \sigma^2[X_1] + \sigma^2[X_2] + \dots + \sigma^2[X_n] \\ &= p \times q + p \times q + \dots + p \times q = n \times p \times q \end{aligned}$$

Propiedad de Aditividad o Reproductividad Sean X e Y dos variables aleatorias independientes con distribuciones de probabilidad $X \sim \mathcal{B}(n, p)$ e $Y \sim \mathcal{B}(m, p)$. Entonces $X + Y \sim \mathcal{B}(n + m, p)$.

Ejemplo 19.1 En un almacén hay 6000 piezas de las cuales 900 son defectuosas. Se seleccionan aleatoriamente (con reemplazamiento) 10 piezas. Calcular la probabilidad de que todas estén en buen estado.

Demostración

$$\begin{aligned} X &= \text{número de piezas defectuosas en las 10 seleccionadas} \\ n &= 10 \\ p &= \frac{900}{6000} \\ &= \frac{9}{60} = \frac{3}{20} \end{aligned}$$

$$\begin{aligned} X &\sim \mathcal{B}(n, p) \\ X &\sim \mathcal{B}(10, \frac{3}{20}) \end{aligned}$$

$$P[X = 0] = \binom{10}{0} \left(\frac{3}{20}\right)^0 \times \left(\frac{17}{20}\right)^{10}$$

O bien:

$$\begin{aligned} Y &= \text{número de piezas en buen estado en las 10 seleccionadas} \\ n &= 10 \\ p &= \frac{5100}{6000} \\ &= \frac{51}{60} = \frac{17}{20} \end{aligned}$$

$$\begin{aligned} Y &\sim \mathcal{B}(n, p) \\ Y &\sim \mathcal{B}(10, \frac{17}{20}) \end{aligned}$$

$$P[Y = 10] = \binom{10}{10} \left(\frac{17}{20}\right)^{10} \times \left(\frac{3}{20}\right)^0$$

Ejemplo 19.2 *Un proceso de fabricación produce un 1 % de piezas defectuosas. Las piezas se empaquetan en cajas de 20 unidades. ¿Cuál es la probabilidad de que si se seleccionan 5 cajas al azar, ninguna de ellas tenga piezas defectuosas?*

Demostración

$$\begin{aligned} X &= \text{número de piezas defectuosas en una caja de 20 unidades} \\ n &= 20 \\ p &= \frac{1}{100} \end{aligned}$$

$$\begin{aligned} X &\sim \mathcal{B}(n, p) \\ X &\sim \mathcal{B}(20, \frac{1}{100}) \end{aligned}$$

$$\begin{aligned} P[X = 0] &= \binom{20}{0} \left(\frac{1}{100}\right)^0 \times \left(\frac{99}{100}\right)^{20} \\ &= \frac{20!}{0!20!} 1 \times 0,8179 \\ &= 0,8179 \end{aligned}$$

$$\begin{aligned} Y &= \text{número de cajas sin piezas defectuosas} \\ m &= 5 \\ p &= 0,8179 \end{aligned}$$

$$\begin{aligned} Y &\sim \mathcal{B}(m, p) \\ Y &\sim \mathcal{B}(5; 0,8179) \end{aligned}$$

$$\begin{aligned} P[Y = 5] &= \binom{5}{5} (0,8179)^5 \times (0,1821)^0 \\ &= \frac{5!}{5!0!} 0,366 \times 1 \\ &= 0,366 \end{aligned}$$

3. Distribución de Poisson

Una variable aleatoria X sigue una distribución de Poisson de parámetro λ si puede tomar todos los valores enteros no negativos $(0, 1, 2, \dots)$ con probabilidades:

$$P_x = P[X = x] = \frac{e^{-\lambda} \lambda^x}{x!} \quad x = 0, 1, \dots$$

Se nota abreviadamente como $X \sim \mathcal{P}(\lambda)$. Una de las aplicaciones comunes de la distribución de Poisson es calcular la probabilidad de un cierto número de eventos en un determinado período de tiempo (por ejemplo, el número de automóviles que se presenta a una estación de peaje de una autopista en el intervalo de un minuto).

Media

$$E[X] = \lambda$$

Varianza

$$\sigma^2[X] = \lambda$$

Propiedad de Aditividad o Reproductividad Sean X e Y dos variables aleatorias independientes con distribuciones de probabilidad $X \sim \mathcal{P}(\lambda_1)$ e $Y \sim \mathcal{P}(\lambda_2)$.

Entonces

$$X + Y \sim \mathcal{P}(\lambda_1 + \lambda_2)$$

Ejemplo 19.3 *El número de fallos por hora en un determinado mecanismo sigue una distribución de Poisson de media 1,5.*

- ¿Cuál es la probabilidad de que haya algún fallo durante una hora?
- ¿Cuál es la probabilidad de que haya algún fallo durante tres horas?

Demostración

$$\begin{aligned}X_1 &= \text{número de fallos durante una hora} \\ \lambda &= 1,5\end{aligned}$$

$$\begin{aligned}X_1 &\sim \mathcal{P}(\lambda) \\ X_1 &\sim \mathcal{P}(1,5)\end{aligned}$$

$$\begin{aligned}P[X_1 \geq 1] &= 1 - P[X_1 < 1] \\ &= 1 - P[X_1 = 0] \\ &= 1 - \frac{e^{-1,5} 1,5^0}{0!} \\ &= 1 - 0,2231 \\ &= 0,7769\end{aligned}$$

$$\begin{aligned}X &= \text{número de fallos durante tres hora} \\ X &= X_1 + X_2 + X_3 \\ X_1 &= \text{número de fallos durante la primera hora} \\ X_2 &= \text{número de fallos durante la segunda hora} \\ X_3 &= \text{número de fallos durante la tercera hora} \\ \lambda &= 1,5\end{aligned}$$

$$\begin{aligned}X_1 &\sim \mathcal{P}(\lambda) \\ X_2 &\sim \mathcal{P}(\lambda) \\ X_3 &\sim \mathcal{P}(\lambda) \\ X &\sim \mathcal{P}(1,5 + 1,5 + 1,5) = \mathcal{P}(4,5)\end{aligned}$$

$$\begin{aligned}P[X \geq 1] &= 1 - P[X < 1] \\ &= 1 - P[X = 0] \\ &= 1 - \frac{e^{-4,5} 4,5^0}{0!} \\ &= 1 - 0,0111 \\ &= 0,9889\end{aligned}$$

4. Distribución de Poisson Como Límite de la Distribución Binomial

Cuando en la distribución $\mathcal{B}(n, p)$ p es muy pequeño y n suficientemente grande, se puede aproximar por la distribución de Poisson $\mathcal{P}(np)$ para el cálculo de las probabilidades asociadas.

Esta propiedad sirve para caracterizar a una gran cantidad de fenómenos que siguen una distribución de Poisson, son fenómenos con una pequeña probabilidad de éxito que son observados en un número elevado de ocasiones.

Ejemplo 19.4 *La probabilidad de que aparezca una pieza defectuosa en un proceso es 0,0001. La producción de un año es de 36000 piezas. Calcular la probabilidad de que en la producción anual el número de piezas defectuosas sea por lo menos dos.*

Demostración

X = número de piezas defectuosas en la producción anual

$$\begin{aligned} X &\sim \mathcal{B}(36000; 0,0001) \\ &\rightarrow \mathcal{P}(36000 \times 0,0001) \\ &= \mathcal{P}(3,6) \end{aligned}$$

$$\begin{aligned} P[X \geq 2] &= 1 - P[X < 2] \\ &= 1 - P[X \leq 1] \\ &= 1 - P[X = 0] - P[X = 1] \\ &= 1 - \frac{e^{-3,6} 3,6^0}{0!} - \frac{e^{-3,6} 3,6^1}{1!} \\ &= 1 - 0,0273 - 0,0984 \\ &= 0,8743 \end{aligned}$$

Se podría haber resuelto también usando la distribución Binomial:

$$\begin{aligned} P[X \geq 2] &= 1 - P[X < 2] \\ &= 1 - P[X \leq 1] \\ &= 1 - P[X = 0] - P[X = 1] \\ &= 1 - \binom{36000}{0} 0,0001^0 0,9999^{36000} - \binom{36000}{1} 0,0001^1 0,9999^{35999} \\ &= 0,8743 \end{aligned}$$

Pero es más complicado e incluso a veces imposible realizar los cálculos debido a la magnitud de n y p .

5. Distribución Hipergeométrica

Se selecciona una muestra (subconjunto) de una población finita con N elementos donde los individuos están clasificados en dos categorías (éxito y fracaso). Se puede hacer básicamente de dos formas:

- Muestreo con reemplazamiento: los individuos se extraen, observan y devuelven a la población, de forma que la composición de la población es constante en cada extracción. Para calcular la probabilidad de que cierto número de individuos de la muestra presentan la característica éxito se utiliza la distribución Binomial.
- Muestreo sin reemplazamiento: los individuos extraídos se dejan fuera de la población con lo que la composición de la población va cambiando con cada extracción (es equivalente extraer de uno en uno o en conjunto). Para calcular la probabilidad de que cierto número de individuos de la muestra presentan la característica éxito se utiliza la distribución Hipergeométrica que vamos a estudiar a continuación.

Sea una población finita con N individuos de los cuales Np individuos presentan la característica éxito y $N(1 - p) = Nq$ individuos no la presentan. La probabilidad de obtener éxito en la primera extracción es $\frac{Np}{N} = p$ y la de no obtenerlo (u obtener fracaso) es q . En las sucesivas extracciones estas probabilidades de obtener éxito o fracaso van cambiando al modificarse la composición de la población. La variable aleatoria X = número de éxitos en una muestra sin reemplazamiento de tamaño n sigue una distribución de probabilidad Hipergeométrica, abreviadamente $X \sim \mathcal{H}(N, n, p)$ cuyas probabilidades asociadas son

$$p_x = P[X = x] = \frac{\binom{Np}{x} \binom{Nq}{n-x}}{\binom{N}{n}}$$

La variable aleatoria X puede tomar todos los valores enteros comprendidos entre $\max\{0, n - Nq\}$ y $\min\{n, Np\}$.

Cuando N es infinito (en la práctica un valor muy elevado) las distribuciones Hipergeométrica y Binomial coinciden.

Media

$$E[X] = np$$

Varianza

$$\sigma^2[X] = \frac{N-n}{N-1} npq$$

Ejemplo 19.5 Una urna contiene 15 bolas blancas y 5 bolas negras. Se extraen 5 bolas, ¿cuál es la probabilidad de que 2 sean negras?

- Se extraen las bolas una a una, se observa el color y se devuelven a la urna antes de la siguiente extracción.

- *Se extraen las 5 bolas de una vez.*

Demostración

X = número de bolas negras entre las 5 extraídas

$$\begin{aligned}n &= 5 \\p &= \frac{5}{20} = \frac{1}{4} \\X &\sim \mathcal{B}(5, \frac{1}{4}) = \mathcal{B}(5; 0, 25)\end{aligned}$$

$$P[X = 2] = \binom{5}{2} 0,25^2 (1 - 0,25)^3 = 0,26367$$

$$\begin{aligned}N &= 20 \\n &= 5 \\p &= \frac{5}{20} = \frac{1}{4} \\X &\sim \mathcal{H}(20, 5, \frac{1}{4}) = \mathcal{H}(20, 5; 0, 25) \\Np &= 20 \times 0,25 = 5 \\Nq &= 20 \times (1 - 0,25) = 15\end{aligned}$$

$$\begin{aligned}P[X = 2] &= \frac{\binom{5}{2} \binom{15}{3}}{\binom{20}{5}} \\&= 0,26367\end{aligned}$$

Ejemplo 19.6 *Si jugamos una combinación de la lotería primitiva. ¿Cuál es la probabilidad de que acertemos 4 números o más?*

Demostración En el sorteo de la lotería primitiva las extracciones se hacen sin reemplazamiento.

X = número de bolas extraídas iguales a alguno de nuestros 6 números

$$\begin{aligned}N &= 49 \\n &= 6 \\p &= \frac{6}{49} \\X &\sim \mathcal{H}(49, 6, \frac{6}{49}) \\Np &= 49 \times \frac{6}{49} = 6 \\Nq &= N(1 - p) = N - Np = 49 - 6 = 43\end{aligned}$$

$$\begin{aligned}
P[X \geq 4] &= P[X = 4] + P[X = 5] + P[X = 6] \\
&= \frac{\binom{6}{4} \binom{43}{2}}{\binom{49}{6}} + \frac{\binom{6}{5} \binom{43}{1}}{\binom{49}{6}} + \frac{\binom{6}{6} \binom{43}{0}}{\binom{49}{6}} \\
&= 0,00096862 + 0,00001845 + 0,000000071 = 0,000987141
\end{aligned}$$

6. Distribución Geométrica

Sea X la variable aleatoria que indica el número de fracasos antes de obtener el primer éxito en repeticiones idénticas e independientes de un experimento. La variable aleatoria X sigue una distribución Geométrica de parámetro p , abreviadamente $X \sim \mathcal{G}(p)$, donde p es la probabilidad de éxito. X puede tomar todos los valores enteros no negativos $(0, 1, 2, \dots)$ con probabilidades:

$$p_x = P[X = x] = (1 - p)^x p = q^x p \quad x = 0, 1, \dots$$

Si llamamos A al suceso éxito:

$$\begin{aligned}
p_x = P[X = x] &= P\left[\underbrace{\bar{A} \dots \bar{A}}_x A\right] \\
&= \underbrace{P[\bar{A}] \dots P[\bar{A}]}_x P[A] \\
&= \underbrace{q \dots q}_x p = p^x q
\end{aligned}$$

Dado que p y q son positivos lo serán las probabilidades $p_x = P[X = x]$. Y la suma de todas ellas es 1

$$\begin{aligned}
P[X = 0] + P[X = 1] + P[X = 2] + \dots + P[X = x] + \dots &= \\
= p + pq + pq^2 + \dots + pq^x + \dots &= \\
= p(1 + q + q^2 + \dots + q^x) &= \\
= p \frac{1}{1 - q} = p \frac{1}{p} = 1 &
\end{aligned}$$

Donde se ha utilizado que la suma de una progresión geométrica de razón r es igual a $\frac{a_1}{1-r}$ (a_1 = primer término de la progresión geométrica)

Media

$$E[X] = \frac{1 - p}{p} = \frac{q}{p}$$

Varianza

$$\sigma^2[X] = \frac{1-p}{p^2} = \frac{q}{p^2}$$

Ejemplo 19.7 *En una Facultad suelen aprobar el 70 % de los alumnos. Hallar la probabilidad de que un alumno apruebe en alguna de las 6 convocatorias de examen que dispone.*

Demostración

X = número de suspensos antes de aprobar sigue
= una distribución Geométrica de parámetro

$$p = 0,70$$

$$q = 0,30$$

$$n = 5$$

$$\begin{aligned} P[X \geq 5] &= P[X = 0] + P[X = 1] + P[X = 2] + \\ &\quad + P[X = 3] + P[X = 4] + P[X = 5] \\ &= (0,3^0 \times 0,7) + (0,3^1 \times 0,7) + (0,3^2 \times 0,7) + \\ &\quad + (0,3^3 \times 0,7) + (0,3^4 \times 0,7) + (0,3^5 \times 0,7) \\ &= 0,7 + 0,21 + 0,063 + 0,0189 + 0,00567 + 0,001701 = 0,999271 \end{aligned}$$

Parte IV

Inferencia Estadística

CAPÍTULO 20

Modelos Probabilísticos Univariantes Continuos

Los modelos probabilísticos son como los trajes que se guardan en un armario para ponérselos según las ocasiones, así las diferentes distribuciones se usan dependiendo de los datos que se dispongan para el problema que se desea resolver.

Como estos pueden ser de muy distinta naturaleza, es muy conveniente disponer de un amplio abanico de modelos para poder utilizar, en cada ocasión, aquel que se ajusta mejor a los datos concretos y al problema. Aún más, como los trajes, las distribuciones pueden ser sencillas o más sofisticadas y en su uso se tiene en cuenta la naturaleza de los datos con su mayor o menor complejidad y la acuracidad que se desee lograr, esto es, volviendo al símil anterior, que el traje (*distribución*) caiga como un guante (*ajuste*) a la persona determinada (*datos*), es la filosofía básica de la modelización de probabilidad.

En este capítulo se presentan algunos de los modelos continuos más usuales y otros que son básicos en el desarrollo de la **Inferencia Estadística**.

Se comienza con el estudio de aquellas distribuciones, cuya representación gráfica de su función de densidad es una figura geométrica simple, prosiguiendo con las distribuciones tipo exponencial, relacionadas con la cota inferior de la varianza de los estimadores eficientes, y la distribución normal que sigue siendo la más importante debido a que toda la Inferencia Estadística que se va a presentar se fundamenta en una o dos poblaciones normales. El esquema de estudio será el mismo:

presentación de la distribución mediante su función de densidad, comprobando que dicha función es una verdadera función de densidad, obtención de las funciones de distribución y generatriz de momentos y a partir de ella obtención de las características estocásticas más relevantes. A continuación, se estudian las distribuciones gamma y beta relacionadas con las integrales eulerianas poniendo de relieve que la distribución exponencial es un caso particular de la distribución gamma.

Terminando con la señalización de algunas aplicaciones interesantes de tales distribuciones en los campos económicos y probabilístico.

El esquema de estudio de las distribuciones relacionadas con la normal varia, ya que no interesa el conocimiento de las funciones de densidad, de distribución generatriz de momentos, etc. de ellas, sino la estructura de las variables aleatorias intervinientes para que se conozca la distribución de la mencionada estructura. Siendo, en estos casos, mucho más importante el manejo correcto de las tablas de probabilidad de tales distribuciones χ^2 , t y F así como sus relaciones, que el propio estudio probabilístico de ellas.

1. Distribución Rectangular Uniforme

Esta es la más sencilla de las distribuciones continuas, y surge al considerar una variable aleatoria que toma valores equiprobables en un intervalo finito, y su nombre se debe al hecho de que la densidad de probabilidad de esta variable aleatoria es uniforme sobre todo su intervalo de definición.

Una variable aleatoria se ajusta a este modelo si todos los valores con probabilidad no nula tienen la misma función de densidad. Es decir, supongamos una variable aleatoria X puede tomar valores al azar en un rango (a, b) . En este caso, se dice que X tiene una distribución uniforme entre a y b y se escribe:

$$X \sim U(a, b)$$

En este caso, la probabilidad de que X caiga en cualquier zona es la misma, y entonces la función de densidad es constante

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{en otros casos} \end{cases}$$

1.1. Condiciones de la función de densidad

1. $f(x) \geq 0$
2. $\int_{-\infty}^{\infty} f(x) \, dx = 1$

Demostración

1. Como $b > a$ entonces $f(x) > 0$ y $f(x) = 0$ en el resto

$$2. \int_{-\infty}^{\infty} f(x) \, dx = \underbrace{\int_{-\infty}^a f(x) \, dx}_a + \underbrace{\int_a^b f(x) \, dx}_b + \underbrace{\int_b^{\infty} f(x) \, dx}_c$$

$$a) \int_{-\infty}^a f(x) \, dx = \int_{-\infty}^a 0 \, dx = 0$$

$$\begin{aligned}
 b) \int_a^b f(x) \, dx &= \int_a^b \frac{1}{b-a} \, dx = \\
 &= \frac{1}{b-a} \int_a^b 1 \, dx = \\
 &= \frac{1}{b-a} \times x \Big|_a^b = \\
 &= \frac{1}{b-a} (b-a) = 1 \\
 c) \int_b^\infty f(x) \, dx &= \int_b^\infty 0 \, dx = 0
 \end{aligned}$$

1.2. Función de Distribución

Si $X \sim U(a, b)$

$$\begin{aligned}
 F(x) &= P[X \leq x] \\
 &= \int_a^x f(t) \, dt \\
 &= \int_a^x \frac{1}{b-a} \, dt \\
 &= \frac{1}{b-a} \int_a^x 1 \, dt \\
 &= \frac{1}{b-a} \times t \Big|_a^x \\
 &= \frac{x-a}{b-a}
 \end{aligned}$$

$$F(x) = \begin{cases} 0 & \text{si } x \leq a \\ \frac{x-a}{b-a} & a < x \leq b \\ 1 & x \geq b \end{cases}$$

1. DISTRIBUCIÓN RECTANGULAR UNIFORME

Las representaciones gráficas de la función de densidad (figura 5) y de la función de distribución (figura 20.2) son:




Figura 20.1: Función de Densidad Distribución Rectangular Uniforme




Figura 20.2: Función de Distribución Distribución Rectangular Uniforme

Las principales características estocásticas de esta distribución son

1.3. Esperanza Matemática o Media o Valor Esperado

$$E[X] = \frac{b+a}{2}$$

Demostración

$$\begin{aligned}
 E[X] &= \int_a^b x \times f(x) dx \\
 &= \int_a^b x \times \frac{1}{b-a} dx \\
 &= \frac{1}{b-a} \int_a^b x dx \\
 &= \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b \\
 &= \frac{1}{b-a} \times \frac{(b^2 - a^2)}{2} \\
 &= \frac{1}{b-a} \times \frac{(b-a) \times (b+a)}{2} \\
 &= \frac{b+a}{2}
 \end{aligned}$$

1.4. Varianza

$$Var[X] = \frac{(b-a)^2}{12}$$

Demostración

$$Var[X] = E[X^2] - E[X]^2$$

$$\begin{aligned}
 E[X^2] &= \int_a^b x^2 \times f(x) dx \\
 &= \int_a^b x^2 \times \frac{1}{b-a} dx \\
 &= \frac{1}{b-a} \int_a^b x^2 dx \\
 &= \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b \\
 &= \frac{1}{b-a} \times \frac{(b^3 - a^3)}{3} \\
 &= \frac{1}{b-a} \times \frac{(b-a) \times (b^2 + a^2 + a \times b)}{3} \\
 &= \frac{b^2 + a^2 + a \times b}{3}
 \end{aligned}$$

$$\begin{aligned}
 Var[X] &= \frac{b^2 + a^2 + a \times b}{3} - \left(\frac{b+a}{2} \right)^2 \\
 &= \frac{b^2 + a^2 + a \times b}{3} - \frac{(b+a)^2}{4} \\
 &= \frac{4(b^2 + a^2 + a \times b)}{12} - \frac{3(b^2 + a^2 + 2a \times b)}{12} \\
 &= \frac{4b^2 + 4a^2 + 4a \times b}{12} - \frac{3b^2 + 3a^2 + 6a \times b}{12} \\
 &= \frac{(4b^2 + 4a^2 + 4a \times b) - (3b^2 + 3a^2 + 6a \times b)}{12} \\
 &= \frac{b^2 + a^2 - 2a \times b}{12} \\
 &= \frac{(b-a)^2}{12}
 \end{aligned}$$

1.5. Momentos

Momento no centrado

$$a_k = E[X^k] = \frac{(b^{k+1} - a^{k+1})}{(b-a) \times (k+1)}$$

Momento centrado

$$m_k = E[(X - a_1)^k] = \frac{(b-a)^k \times (1 + (-1)^k)}{2^{k+1} \times (k+1)}$$

1.6. Función Generatriz de Momentos

$$M_X(t) = \begin{cases} \frac{e^{t \times b} - e^{t \times a}}{t \times (b-a)} & \text{si } t \neq 0 \\ 1 & \text{si } t = 0 \end{cases}$$

1.7. Medidas de Forma

Coefficiente de Asimetría de Fisher

$$g_1 = 0$$

Demostración

$$g_1 = \frac{m_3}{S^3}$$

$$\begin{aligned}
 m_3 &= \frac{(b-a)^3 \times (1 + (-1)^3)}{2^{3+1} \times (3+1)} \\
 &= \frac{(b-a)^3 \times (1-1)}{2^{3+1} \times (3+1)} \\
 &= \frac{(b-a)^3 \times (0)}{2^{3+1} \times (3+1)} = 0
 \end{aligned}$$

por tanto $g_1=0$

Coeficiente de Curtosis de Fisher

$$g_2 = -\frac{6}{5}$$

Se trata de una función platicúrtica

Demostración

$$g_2 = \frac{m_4}{S^4} - 3$$

$$\begin{aligned}
 m_4 &= \frac{(b-a)^4 \times (1 + (-1)^4)}{2^{4+1} \times (4+1)} \\
 &= \frac{(b-a)^4 \times (1+1)}{2^{4+1} \times (4+1)} \\
 &= \frac{2 \times (b-a)^4}{2^{4+1} \times (5)} \\
 &= \frac{(b-a)^4}{2^4 \times (5)}
 \end{aligned}$$

$$S^4 = \left(\frac{(b-a)^2}{12}\right)^2$$

$$\begin{aligned}
 \frac{m_4}{S^4} &= \frac{\frac{(b-a)^4}{2^4 \times (5)}}{\frac{(b-a)^4}{12^2}} \\
 &= \frac{9}{5}
 \end{aligned}$$

$$\begin{aligned}
 g_2 &= \frac{m_4}{S^4} - 3 \\
 &= \frac{9}{5} - 3 \\
 &= -\frac{6}{5}
 \end{aligned}$$

Ejemplo 20.1 El tiempo en minutos que tarda un señor para ir de su casa al trabajo oscila de forma uniforme entre 20 y 30. Si debe llegar al trabajo a las 8 de la mañana, ¿a qué hora debe salir de su casa para tener una probabilidad de 0.9 de no llegar tarde? Si X denota el tiempo en ir de casa al trabajo (en minutos), su distribución es $U(20,30)$. Buscamos el valor de a tal que $P[X \leq a] = 0,9$.

$$\begin{aligned} P[X \leq a] &= F_X(a) \\ &= \frac{a - 20}{30 - 20} = \frac{a - 20}{10} \\ 0,9 &= \frac{a - 20}{10} \\ a &\Rightarrow 29 \end{aligned}$$

Por tanto, debe salir de casa a las 7h 31m. El tiempo medio que tarda en ir de casa al trabajo es de 25 minutos, y la desviación típica de 2,88 minutos.

2. Distribución Exponencial

Sea X una variable aleatoria en el conjunto de $\mathbb{R}^+$, se dice que X se distribuye según una distribución exponencial de parámetro $\theta > 0$ lo que se notará $X \sim \text{Exp}(\theta)$ si y solo si su función de densidad responde a la siguiente expresión

$$f(x) = \begin{cases} \frac{1}{\theta} \times e^{-\frac{x}{\theta}} & \text{si } x \geq 0, \forall \theta > 0 \\ 0 & \text{en otros casos} \end{cases}$$

Se comprueba que fácilmente es una función de densidad ya que se verifica que:

1. $f(x) \geq 0 \quad \forall x \in (0, +\infty)$
2. $\int_{-\infty}^{\infty} f(x) \, dx = 1$

Demostración

1. Como $\theta > 0$ y la función exponencial nunca es negativa.

$$2. \int_{-\infty}^{\infty} f(x) \, dx = \underbrace{\int_{-\infty}^0 f(x) \, dx}_a + \underbrace{\int_0^{\infty} f(x) \, dx}_b$$

$$a) \int_{-\infty}^0 f(x) \, dx = \int_{-\infty}^0 0 \, dx = 0$$

$$\begin{aligned} b) \int_0^{\infty} f(x) \, dx &= \int_0^{\infty} \frac{1}{\theta} \times e^{-\frac{x}{\theta}} \, dx = \\ &= \left[-e^{-\frac{x}{\theta}} \right]_0^{\infty} = \\ &= -e^{-\frac{\infty}{\theta}} - (-e^{-\frac{0}{\theta}}) \\ &= 0 + 1 = 1 \end{aligned}$$

se verifica:

- $f(0) = \frac{1}{\theta}$ y $f(+\infty) = 0$, su gráfica comienza en $\frac{1}{\theta}$

- $\frac{\partial f}{\partial x} < 0$, $\forall x \in (0, +\infty)$ de donde se deduce que $f(x)$ es decreciente y no tiene extremos relativos
- $\frac{\partial^2 f}{\partial x^2} > 0$, $\forall x \in (0, +\infty)$ de donde se deduce que $f(x)$ es cóncava y no tiene puntos de inflexión

2.1. Función de Distribución

Si $X \sim \text{Exp}(\theta)$ entonces

$$\begin{aligned}
 F(x) &= P[X \leq x] \\
 &= \int_0^x f(t) \, dt \\
 &= \int_0^x \frac{1}{\theta} e^{-\frac{t}{\theta}} \, dt \\
 &= \left[-e^{-\frac{t}{\theta}} \right]_0^x \\
 &= -e^{-\frac{x}{\theta}} + 1 \\
 &= 1 - e^{-\frac{x}{\theta}}
 \end{aligned}$$

$$F(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\frac{x}{\theta}} & x > 0 \end{cases}$$

2.2. Esperanza Matemática o Media o Valor Esperado

$$E[X] = \theta$$

Demostración

$$\begin{aligned}
 E[X] &= \int_0^{\infty} x \times f(x) \, dx \\
 &= \int_0^{\infty} x \times \frac{1}{\theta} e^{-\frac{x}{\theta}} \, dx \\
 &= \theta
 \end{aligned}$$

2.3. Varianza

$$\text{Var}[X] = \theta^2$$

Demostración

$$\text{Var}[X] = E[X^2] - E[X]^2$$

$$\begin{aligned} E[X^2] &= \int_0^\infty x^2 \times f(x) dx \\ &= \int_0^\infty x^2 \times \frac{1}{\theta} e^{-\frac{x}{\theta}} dx \\ &= 2 \times \theta^2 \end{aligned}$$

$$\begin{aligned} Var[X] &= 2 \times \theta^2 - \theta^2 \\ &= \theta^2 \end{aligned}$$

2.4. Momentos

Momento no centrado

$$a_k = E[X^k] = \Gamma(k+1) \times \theta^k = k! \times \theta^k$$

2.5. Función Generatriz de Momentos

$$M_X(t) = (1 - \theta \times t)^{-1} \quad t < \frac{1}{\theta}$$

2.6. Medidas de Forma

Coficiente de Asimetría de Fisher

$$g_1 = 2$$

Demostración

$$g_1 = \frac{m_3}{S^3}$$

$$m_3 = a_3 - 3 \times a_2 \times a_1 + 2 \times a_1^3$$

$$a_3 = \theta^3 \times 3! \quad a_2 = \theta^2 \times 2! \quad a_1 = \theta$$

$$\begin{aligned} m_3 &= 6 \times \theta^3 - 3 \times 2 \times \theta^2 \times \theta + 2 \times \theta^3 \\ &= 2 \times \theta^3 \\ S &= \theta \\ g_1 &= 2 \times \frac{\theta^3}{\theta^3} = 2 \end{aligned}$$

por tanto $g_1=2$

Coefficiente de Curtosis de Fisher

$$g_2 = 6$$

Se trata de una función leptocúrtica

Demostración

$$g_2 = \frac{m_4}{S^4} - 3$$

$$m_4 = a_4 - 4 \times a_3 \times a_1 + 6 \times a_2 \times a_1^2 - 3 \times a_1^4$$

$$\begin{aligned} a_4 &= \theta^4 \times 4! & a_3 &= \theta^3 \times 3! \\ a_2 &= \theta^2 \times 2! & a_1 &= \theta \end{aligned}$$

$$\begin{aligned} m_4 &= \theta^4 \times 4! - 4 \times \theta^3 \times 3! \times \theta + 6 \times \theta^2 \times 2! \times \theta^2 - 3 \times \theta^4 \\ &= 9 \times \theta^4 \end{aligned}$$

$$S^4 = (\theta^2)^2$$

$$\begin{aligned} \frac{m_4}{S^4} &= \frac{9 \times \theta^4}{\theta^4} \\ &= 9 \end{aligned}$$

$$\begin{aligned} g_2 &= \frac{m_4}{S^4} - 3 \\ &= 9 - 3 \\ &= 6 \end{aligned}$$

La distribución exponencial se puede expresar también (usando el cambio de variable $\lambda = \frac{1}{\theta}$) como sigue

$$f(x) = \begin{cases} \lambda \times e^{-\lambda x} & \text{si } x \geq 0, \forall \lambda > 0 \\ 0 & \text{en otros casos} \end{cases}$$

En tal caso su función de distribución viene dada por

$$F(x) = \begin{cases} 0 & \text{Si } x < 0 \\ 1 - e^{-\lambda x} & \text{si } x \geq 0 \end{cases}$$

además $E[X] = \frac{1}{\lambda}$ y $Var[X] = (\frac{1}{\lambda})^2$

Proposición 20.1 *Propiedad Reproductiva* Si $X_1, \dots, X_n$ son n variables aleatorias independientes y distribuidas según una $Exp(\theta)$ La nueva variable aleatoria $Y = X_1 + \dots + X_n$ sigue una distribución $\Gamma(n, \theta)$

3. Función de Distribución Gamma $\Gamma(\alpha, \theta)$

Es una distribución con numerosos usos, entre los que se encuentra el siguiente: supongamos que una pieza metálica se encuentra sometida a cierta fuerza, de manera que se romperá después de aplicar un número específico de ciclos de fuerza. Si los ciclos ocurren de manera independiente y a una frecuencia promedio, entonces el tiempo que transcurre antes de que el material se rompa es una variable aleatoria con distribución gamma.

Esta distribución presenta como propiedad interesante la “falta de memoria”. Por esta razón, es muy utilizada en las teorías de la fiabilidad, mantenimiento y fenómenos de espera (por ejemplo en una consulta médica “tiempo que transcurre hasta la llegada del segundo paciente”).

Previamente al estudio de distribución, vamos a definir la función gamma que será de utilidad posteriormente:

3.1. Función Gamma $\Gamma(\alpha)$

Se define la función $\Gamma(\alpha) \quad \forall \alpha > 0$ mediante la siguiente integral

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx \quad \forall \alpha > 0$$

integrando por partes se tiene

$$\begin{aligned} u &= x^{\alpha-1} & du &= (\alpha-1) \times x^{\alpha-2} dx \\ dv &= e^{-x} dx & v &= e^{-x} \end{aligned}$$

Por tanto, tras hacer varias iteraciones y $\alpha \in \mathbb{N}$ tendremos que:

$$\Gamma(\alpha) = (\alpha-1)!$$

Algunas propiedades son:

Proposición 20.2 *Propiedades*

- $\Gamma(1) = 1$
- $\Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1) \quad \alpha > 1$
- Si $\alpha \in \mathbb{N}$, $\Gamma(p) = (p-1)!$
- Si $\theta > 0$,

$$\int_0^{+\infty} x^{\alpha-1} e^{-\frac{x}{\theta}} dx = \Gamma(\alpha) \times \theta^\alpha$$

En particular se verifica que

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

3.2. Función de Distribución Gamma

Se dice que una variable aleatoria de tipo continuo, sigue una distribución gamma de parámetros $\theta > 0$ y $\alpha > 0$ si su función de densidad es:

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\theta^\alpha} \times x^{\alpha-1} \times e^{-\frac{x}{\theta}} & \text{si } x > 0, \alpha \in \mathbb{N}, \theta > 0 \\ 0 & \text{en otros casos} \end{cases}$$


y se indicará que:

$$X \sim \Gamma(\alpha, \theta)$$

Se comprueba fácilmente que esta función es una función de densidad al cumplir las dos propiedades.

1. $f(x) \geq 0, \forall x \in \mathbb{R}^+$ En efecto, $\Gamma(\alpha) > 0$ si $\alpha > 0$, la función exponencial nunca es negativa y la función pontencial de la base positiva, tampoco es negativa
2. $\int_0^{+\infty} f(x) dx = 1$ Es obvio por la definición dada de la función de densidad a partir de la correspondiente función $\Gamma(\alpha)$

Nótese, que se cumplen las siguientes relaciones entre las distribuciones:



La distribución gamma tiene muchas aplicaciones a experimentos o fenómenos aleatorios que tienen asociadas variables aleatorias que siempre son no negativas y cuyas distribuciones son sesgadas a la derecha, es decir, el área bajo la función de densidad disminuye a medida que nos alejamos del origen.

La forma de la función de densidad difiere claramente si $\alpha \leq 1$ y para $\alpha > 1$; además, en este último caso presenta máximos en los puntos $x = \frac{\alpha-1}{\theta}$. Al parámetro α se le suele llamar parámetro forma y al parámetro θ , parámetro escala.

Observación 20.1 Ejemplos y/o aplicaciones

- Intervalos de tiempo entre dos fallos de un motor.
- Intervalos de tiempo entre dos llegadas de automóviles a una gasolinera.
- Tiempos de vida de sistemas electrónicos

Función de Distribución

$$F(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \frac{1}{\theta^\alpha \Gamma(\alpha)} \int_0^x t^{\alpha-1} e^{-\theta t} dx & \text{si } x > 0 \end{cases}$$

Las principales características estocásticas son:

Momentos

Momento no centrado

$$\begin{aligned} a_k &= E[X^k] = \frac{1}{\theta^\alpha \Gamma(\alpha)} \int_0^x t^{k+\alpha-1} e^{-\theta t} dx \\ &= \frac{1}{\theta^\alpha \Gamma(\alpha)} \theta^{\alpha+k} \Gamma(\alpha+k) \end{aligned}$$

Luego

$$\begin{aligned} a_1 &= \alpha\theta & a_2 &= (\alpha+1)\alpha\theta^2 \\ a_3 &= (\alpha+2)(\alpha+1)\alpha\theta^3 & a_4 &= (\alpha+3)(\alpha+2)(\alpha+1)\alpha\theta^4 \end{aligned}$$

Por tanto

$$\begin{aligned} \mu &= a_1 = \alpha\theta \\ \sigma^2 &= a_2 - a_1^2 = (\alpha^2 + \alpha)\theta^2 - \alpha^2\theta^2 \\ &= \alpha\theta^2 \\ \sigma &= \sqrt{\alpha}\theta \end{aligned}$$

Medidas de Forma

Coficiente de Asimetría de Fisher

$$g_1 = \frac{2}{\sqrt{\alpha}}$$

Demostración

$$g_1 = \frac{m_3}{S^3}$$

$$m_3 = a_3 - 3 \times a_2 \times a_1 + 2 \times a_1^3$$

$$\begin{aligned} a_3 &= (\alpha+2)(\alpha+1)\alpha\theta^3 \\ a_2 &= (\alpha+1)\alpha\theta^2 \\ a_1 &= \alpha\theta \end{aligned}$$

$$\begin{aligned}
 m_3 &= (\alpha + 2)(\alpha + 1)\alpha\theta^3 - 3 \times (\alpha + 1)\alpha\theta^2\alpha\theta + 2 \times \alpha^3\theta^3 \\
 &= (\alpha^3 + 3\alpha^2 + 2\alpha)\theta^3 - 3 \times (\alpha^3 + \alpha^2)\theta^3 + 2 \times \alpha^3\theta^3 \\
 &= 2\alpha\theta^3 \\
 S &= \sqrt{\alpha}\theta \\
 g_1 &= 2 \times \frac{\alpha\theta^3}{(\sqrt{\alpha}\theta)^3} = \frac{2}{\sqrt{\alpha}}
 \end{aligned}$$

por tanto $g_1 = \frac{2}{\sqrt{\alpha}}$ Por tanto es una distribución asimétrica a la derecha

Coefficiente de Curtosis de Fisher

$$g_2 = \frac{6}{\sqrt{\alpha}}$$

Se trata de una función leptocúrtica

Demostración

$$g_2 = \frac{m_4}{S^4} - 3$$

$$m_4 = a_4 - 4 \times a_3 \times a_1 + 6 \times a_2 \times a_1^2 - 3 \times a_1^4$$

$$\begin{aligned}
 a_1 &= \alpha\theta & a_2 &= (\alpha + 1)\alpha\theta^2 \\
 a_3 &= (\alpha + 2)(\alpha + 1)\alpha\theta^3 & a_4 &= (\alpha + 3)(\alpha + 2)(\alpha + 1)\alpha\theta^4
 \end{aligned}$$

$$\begin{aligned}
 m_4 &= (\alpha + 3)(\alpha + 2)(\alpha + 1)\alpha\theta^4 - 4 \times (\alpha + 2)(\alpha + 1)\alpha\theta^3 \times \alpha\theta + 6 \times (\alpha + 1)\alpha\theta^2 \times \alpha^2\theta^2 - 3 \times \alpha^4\theta^4 \\
 &= (3\alpha^2 + 6\alpha)\theta^4
 \end{aligned}$$

$$S^4 = \alpha^2\theta^4$$

$$\begin{aligned}
 \frac{m_4}{S^4} &= \frac{(3\alpha^2 + 6\alpha)\theta^4}{\alpha^2\theta^4} \\
 &= 3 + \frac{6}{\alpha}
 \end{aligned}$$

$$\begin{aligned}
 g_2 &= 3 + \frac{6}{\alpha} - 3 \\
 &= \frac{6}{\alpha}
 \end{aligned}$$

4. Distribución Beta

Es una distribución que permite generar una gran variedad de perfiles y se utiliza principalmente para representar variables físicas cuyos valores se encuentran restringidos a un intervalo de longitud finita y para obtener ciertas cantidades que se conocen como límites de tolerancia (en Inferencia no paramétrica) sin necesidad de la hipótesis de normalidad. Además, la distribución beta juega un papel importante en la Inferencia Bayesiana.

Previamente al estudio de distribución, vamos a definir la función beta que será de utilidad posteriormente:

Para $p, q > 0$ se define la *función beta* y la representamos por $\beta(p, q) \quad \forall p > 0$ y $q > 0$ mediante la siguiente integral:

$$\beta(p, q) = \int_0^1 x^{p-1}(1-x)^{q-1} dx \quad p, q > 0$$

la cual, se puede demostrar que es convergente para valores de $x \in (0, 1)$ para $p, q > 0$

A esta integral se le llama integral euleriana de primera especie. Algunas propiedades son:

Observación 20.2 Propiedades

1. $\beta(p, q) = \beta(q, p)$
2. La función $\beta(p, q)$ y $\Gamma(p)$ están relacionadas mediante la expresión:

$$\beta(p, q) = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

que es válido para todo p y para todo q reales positivos

La distribución beta tiene muchas aplicaciones a experimentos o fenómenos aleatorios que tienen asociadas variables aleatorias que representen proporciones (valores entre cero y uno).

Definición 20.1 Función de Densidad Sea X una variable aleatoria valuada en el intervalo $(0,1)$ se dice que se distribuye según una distribución beta, lo que se notará por $X \sim \beta(p, q)$ si y solo si su función de densidad responde a la siguiente expresión

$$f(x) = \begin{cases} \frac{1}{\beta(p, q)} x^{p-1}(1-x)^{q-1} dx & \text{si } x \in (0, 1) \quad p > 0 \quad q > 0 \\ 0 & \text{en otros casos} \end{cases}$$

o bien

$$f(x) = \begin{cases} \frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} x^{p-1}(1-x)^{q-1} dx & \text{si } x \in (0, 1) \quad p > 0 \quad q > 0 \\ 0 & \text{en otros casos} \end{cases}$$

CAPÍTULO 20. MODELOS PROBABILÍSTICOS UNIVARIANTES CONTÍNUOS

La forma de la función de densidad toma formas muy diferentes para los distintos valores de p y q , lo que nos permite, eligiendo adecuadamente los parámetros, seleccionar la forma de la función de densidad que más interese.

Es fácil comprobar que es una verdadera función de densidad, ya que se verifica:

1. $f(x) \geq 0, \forall x \in (0,1)$ En efecto, el producto de dos funciones potenciales de base positiva, nunca puede ser negativa
2. $\int_0^{+\infty} f(x) dx = 1$ Es obvio por la definición dada de la función de densidad, como recíproca de la correspondiente función $\beta(p, q)$

Observación 20.3 Propiedades

- Si $p = q$ la función de densidad es simétrica, siendo el eje de simetría la recta $x = 1/2$.
- Si $p = q = 1$, $\beta(p, q) = U(0, 1)$.
- Si $p \neq q$ es asimétrica a la derecha.
- Si $p \neq q$ es asimétrica a la izquierda.
- Si $p \neq 1$ y $q = 1$ es decreciente y cóncava.
- Si $q \neq 1$ y $p = 1$ es creciente y cóncava.
- Si $p \neq 1$ y $q \neq 1$ tiene un sólo máximo.
- Si $p \neq 1$ y $q \neq 1$ tiene un sólo mínimo.

Observación 20.4 Ejemplos y/o aplicaciones

- Fracción de tiempo que un equipo está en reparación.
- Proporción de piezas defectuosas en un lote.
- Proporción del gasto de una familia en alimentación con respecto a los gastos totales.
- La participación de la producción de una empresa con respecto al total de lo producido en ese sector.

Definición 20.2 Cambio de Variable Si se hace el cambio de variable $(1-x)=y$ se tiene que:

$$\begin{aligned}\beta(p, q) &= \int_0^1 x^{p-1} (1-x)^{q-1} dx \\ &= \int_0^1 (1-y)^{p-1} (y)^{q-1} (-dy) \\ &= \int_1^0 (y)^{q-1} (1-y)^{p-1} dy \\ &= \beta(q, p)\end{aligned}$$

Las principales características estocásticas de la distribución $\beta(p, q)$ son:

Momentos

Momento no centrado

$$\begin{aligned}
 a_k &= \int_0^1 \frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} x^{p-1} (1-x)^{q-1} dx \\
 &= \frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} \frac{\Gamma(p+k)\Gamma(q)}{\Gamma(p+q+k)} \\
 &= \frac{\Gamma(p+q)}{\Gamma(p)} \frac{\Gamma(p+k)}{\Gamma(p+q+k)}
 \end{aligned}$$

Luego

$$\begin{aligned}
 a_1 &= \frac{\Gamma(p+q)}{\Gamma(p)} \frac{\Gamma(p+1)}{\Gamma(p+q+1)} \\
 &= \frac{p}{p+q} \\
 a_2 &= \frac{\Gamma(p+q)}{\Gamma(p)} \frac{\Gamma(p+2)}{\Gamma(p+q+2)} \\
 &= \frac{(p+1)p}{(p+q+1)(p+q)} \\
 a_3 &= \frac{\Gamma(p+q)}{\Gamma(p)} \frac{\Gamma(p+3)}{\Gamma(p+q+3)} \\
 &= \frac{(p+2)(p+1)p}{(p+q+2)(p+q+1)(p+q)} \\
 a_4 &= \frac{\Gamma(p+q)}{\Gamma(p)} \frac{\Gamma(p+4)}{\Gamma(p+q+4)} \\
 &= \frac{(p+3)(p+2)(p+1)p}{(p+q+3)(p+q+2)(p+q+1)(p+q)}
 \end{aligned}$$

Por tanto

$$\begin{aligned}
 \mu &= a_1 = \frac{p}{p+q} \\
 \sigma^2 &= a_2 - a_1^2 = \frac{(p+1)p}{(p+q+1)(p+q)} - \left(\frac{p}{p+q} \right)^2 \\
 &= \frac{pq}{(p+q+1)(p+q)^2} \\
 \sigma &= \sqrt{\frac{pq}{(p+q+1)(p+q)^2}} \\
 &= \frac{1}{p+q} \sqrt{\frac{pq}{p+q+1}}
 \end{aligned}$$

Medidas de Forma

Coefficiente de Asimetría de Fisher Siendo

$$g_1 = \frac{2(q-p)\sqrt{q+p+1}}{(q+p+2)\sqrt{pq}}$$

Coefficiente de Curtosis de Fisher

$$g_2 = 6 \frac{p(p+1)(p-2q) + q(q+1)(q-2p)}{pq(q+p+2)(q+p+3)}$$

5. Distribución Normal

La distribución normal es la más importante y la de mayor uso en la Teoría de la Probabilidad y la Estadística Matemática. Fue obtenida inicialmente por De Moivre en 1733 como límite de la distribución binomial, siendo luego relegada al olvido hasta que Gauss en 1809 y Laplace en 1812 la obtuvieron empíricamente al estudiar la distribución de errores accidentales en Astronomía y Geodesia (de ahí que se conozca también como distribución de Gauss-Laplace).

Esta distribución es la piedra angular en la aplicación de la Inferencia Estadística en el análisis de datos, puesto que las distribuciones de muchos estadísticos muestrales tienden a la distribución normal cuando el tamaño de la muestra crece. Además, la distribución normal proporciona una adecuada representación de las distribuciones de una gran cantidad de variables físicas (de hecho, el nombre de normal tiene carácter histórico, ya que, en un principio se creyó que la mayoría de las distribuciones eran de este tipo). Algunos ejemplos son:

- Datos meteorológicos como la temperatura, lluvias, etc.
- Mediciones efectuadas en organismos vivos: altura, peso, etc.
- Calificaciones en pruebas de aptitud.
- Medidas físicas de productos manufacturados, etc.

Definición 20.3 Una variable aleatoria X , de tipo continuo, se dice que sigue una distribución normal si su función de densidad es

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x-\mu}{2\sigma^2}} \quad -\infty < x < \infty$$

Se notará $X \sim \mathcal{N}(\mu, \sigma^2)$. Los parámetros de la distribución, μ y σ^2 verifican $\mu \in \mathbb{R}$, $\sigma > 0$ y determinan completamente dicha función de densidad. Posteriormente se probará que estos parámetros son la media y desviación típica, respectivamente, de la variable aleatoria X .

Algunas de las propiedades de dicha función, útiles para obtener su representación gráfica, son

Definición 20.4 ■ $f(x)$ es continua en todo $\mathbb{R}$

- Es simétrica respecto de $x = \mu$, es decir $f(\mu - x) = f(\mu + x)$, $\forall x \in \mathbb{R}$
- Tiene una asíntota horizontal en $y = 0$ dado que $\lim_{x \rightarrow -\infty} f(x) = \lim_{x \rightarrow +\infty} f(x) = 0$.

- $f(x)$ es creciente para $x < \mu$ y decreciente para $x > \mu$, dado que $f'(x) = -\frac{\mu-x}{\sigma^2}f(x)$, que es positiva si $x < \mu$ y negativa si $x > \mu$.
- $f(x)$ tiene un máximo en $x = \mu$ y vale $f(\mu) = \frac{1}{\sigma\sqrt{2\pi}}$
- Es convexa ($f''(x) > 0$) para $x < \mu - \sigma$ y $x > \mu + \sigma$, cóncava ($f''(x) < 0$) para $\mu - \sigma < x < \mu + \sigma$ y en los puntos $x = \mu - \sigma$ y $x = \mu + \sigma$ tiene puntos de inflexión. Esto se deduce de que $f(x) > 0 \quad \forall x \in \mathbb{R}$ y

$$f''(x) = -\frac{1}{\sigma^2}f(x) + \frac{(x-\mu)^2}{\sigma^4}f(x)$$

Visto todo lo anterior, su representación gráfica queda como sigue:




Figura 20.3: Función de Densidad Distribución Normal

La forma es de campana y de ahí que usualmente se la conozca como campana de Gauss.

Además se observa que el parámetro μ corresponde al máximo y al centro de la distribución y el parámetro σ^2 influye en la apertura y aplastamiento o apuntamiento de la curva. Además μ es la moda y, al ser simétrica, coincide con la media y la mediana.

Su función de densidad es una verdadera función de densidad ya que verifica que:

- $f(x) \geq 0 \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(z)dz = 1$

5.1. Función de Distribución

La función de distribución de la variable aleatoria X es

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{t-\mu}{2\sigma^2}} dt$$

y coincide con el área entre la curva $y = f(x)$ y el eje de abscisas entre ∞ y x

La representación gráfica de la función de distribución es:




Figura 20.4: Función de Distribución Normal

Las principales características estocásticas de la distribución $\mathcal{N}(\mu, \sigma^2)$ son:

Momentos

Momento no centrado

$$a_k = \sum_{h=1}^k \binom{k}{h} \times \mu^{k-h} m_h$$

Momento centrado

$$m_k = \frac{(1 + (-1)^k) \sigma^k 2^{\frac{k}{2}}}{2\sqrt{\pi}} \Gamma\left(\frac{k+1}{2}\right)$$

Notemos que los momentos centrados de orden impar son nulos

5.2. Relación entre $\mathcal{N}(\mu, \sigma^2)$ y $\mathcal{N}(0, 1)$

Si en la función de densidad de $\mathcal{N}(\mu, \sigma^2)$ sustituimos $\mu = 0$ y $\sigma^2 = 1$ obtenemos una nueva distribución $\mathcal{N}(0, 1)$ que recibe el nombre de Distribución Normal Tipificada.

Si X es una variable aleatoria con distribución $\mathcal{N}(\mu, \sigma^2)$ entonces la variable tipificada Z sigue una distribución $\mathcal{N}(0, 1)$ siendo:

$$Z = \frac{x - \mu}{\sigma}$$

Su función de densidad es:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \quad \text{si } z \in \mathbb{R}$$

Que es una verdadera función de densidad ya que verifica que:

- $f(x) \geq 0 \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(z) dz = 1$

Características

- La curva es simétrica respecto al eje de ordenadas.
- $y=0$ es asíntota horizontal, es decir cuando $z \rightarrow \pm\infty$
- Para valores $z < 0$ la curva es decreciente y para $z > 0$ la curva es creciente.
- Para las abscisas $z = \pm 1$ hay dos puntos de inflexión.

Obsérvese que todas las distribuciones normales de parámetro μ y σ^2 mediante la tipificación se convierten en normales de parámetro (0,1) por lo que solo se requiere una tabla para obtener todas las probabilidades asociadas a dichas distribuciones.

Diremos que una variable Z está tipificada cuando su media es 0 y su varianza es 1. Luego, para tipificar una variable solo hay que transformarla mediante un cambio de origen y un cambio de escala. Es decir, hay que restar la media y dividir por su desviación típica.

$$Z = \frac{x - \mu}{\sigma}$$

Teorema 20.1 *Teorema de Adición. Cualquier combinación lineal de variables normales e independientes sigue una distribución normal. Si $X_1, \dots, X_n$ son independientes, tal que X_i se distribuye como $N(\mu_i, \sigma_i^2)$ con $\sigma^2 > 0 \quad \forall i = 1, \dots, n$ y dados $a_1, \dots, a_n, b$ números reales tal que $a_i \neq 0 \quad \forall i = 1, \dots, n$ se cumple:*

$$Y = \sum_{i=1}^n a_i X_i + b$$
$$Y \sim \mathcal{N}\left(\sum_{i=1}^n a_i \mu_i + b, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

Corolario 20.1 *Si $X_1, \dots, X_n$ son independientes y con la misma distribución normal, es decir, tal que X_i se distribuye como $\mathcal{N}(\mu, \sigma^2)$ con $\sigma^2 > 0 \quad \forall i = 1, \dots, n$:*

- $\sum_{i=1}^n X_i \sim \mathcal{N}(n \times \mu, \sigma^2)$
- La variable “media muestral” sigue una distribución normal:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

5.3. Teorema Central del Límite

La importancia de la distribución normal se basa en el Teorema Central del Límite, cuyo enunciado puede establecerse de la siguiente manera:

Teorema 20.2 *Teorema Central del Límite.* Sea $X_1, \dots, X_n$ un conjunto de variables aleatorias independientes (cualquiera que sea su distribución, discreta o continua) y si “n” es lo suficientemente grande, la suma de las variables X_i se distribuyen como una Distribución Normal

En la práctica n es grande cuando supra el valor 30. La Normal formada tendrá como media la suma de las medias y como varianza la suma de las varianzas.

5.4. Cálculo de probabilidades asociado a una distribución normal. Manejo de tablas

La probabilidad de que una variable aleatoria $X \sim \mathcal{N}(\mu, \sigma^2)$ esté comprendida entre dos valores x_1 y x_2 se calcula como:

$$\begin{aligned} P[x_1 \leq X \leq x_2] &= \int_{x_1}^{x_2} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= F_X(x_2) - F_X(x_1) \end{aligned}$$

y corresponde al área bajo la curva función de densidad entre los valores x_1 y x_2

La dificultad de resolver integrales de funciones de densidad normales nos lleva a la utilización de tablas de áreas bajo la curva normal, pero sería imposible disponer de tablas para todos los posibles valores de μ y σ . Teniendo en cuenta el proceso de tipificación de una variable aleatoria

$$P[x_1 \leq X \leq x_2] = P\left[\frac{x_1 - \mu}{\sigma} \leq Z \leq \frac{x_2 - \mu}{\sigma}\right]$$

con $Z \sim \mathcal{N}(0, 1)$ Por ello para el cálculo de probabilidades asociadas a una variable con distribución normal nos basta con disponer de tablas de la distribución $\mathcal{N}(0, 1)$

Definición 20.5 Propiedades

- $P[Z \geq a] = 1 - P[Z \leq a]$
- $P[Z \leq -a] = P[Z \geq a] = 1 - P[Z \leq a]$
- $P[Z \geq -a] = P[Z \leq a]$
- $P[|Z| \leq a] = P[-a \leq Z \leq a] = P[Z \leq a] - P[Z \leq -a] = 2P[Z \leq a] - 1$

Áreas Notables

Las áreas más importantes, por su aplicación, para una distribución $\mathcal{N}(\mu, \sigma^2)$ son:

1. Área comprendida en el intervalo de extremos $\mu \pm \sigma$

$$\begin{aligned} P[\mu - \sigma \leq X \leq \mu + \sigma] &= P\left[\frac{\mu - \sigma - \mu}{\sigma} \leq Z \leq \frac{\mu + \sigma - \mu}{\sigma}\right] \\ &= P[-1 \leq Z \leq 1] \\ &= P[Z \leq 1] - P[Z \leq -1] = 2P[Z \leq 1] - 1 \\ &= 2 \times 0,8413 - 1 = 0,6826 \end{aligned}$$

2. Área comprendida en el intervalo de extremos $\mu \pm 2\sigma$

$$\begin{aligned} P[\mu - 2\sigma \leq X \leq \mu + 2\sigma] &= P\left[\frac{\mu - 2\sigma - \mu}{\sigma} \leq Z \leq \frac{\mu + 2\sigma - \mu}{\sigma}\right] \\ &= P[-2 \leq Z \leq 2] \\ &= P[Z \leq 2] - P[Z \leq -2] = 2P[Z \leq 2] - 1 \\ &= 2 \times 0,97723 - 1 = 0,9544 \end{aligned}$$

3. Área comprendida en el intervalo de extremos $\mu \pm 3\sigma$

$$\begin{aligned} P[\mu - 3\sigma \leq X \leq \mu + 3\sigma] &= P\left[\frac{\mu - 3\sigma - \mu}{\sigma} \leq Z \leq \frac{\mu + 3\sigma - \mu}{\sigma}\right] \\ &= P[-3 \leq Z \leq 3] \\ &= P[Z \leq 3] - P[Z \leq -3] = 2P[Z \leq 3] - 1 \\ &= 2 \times 0,9987 - 1 = 0,9974 \end{aligned}$$

También es interesante la obtención de intervalos simétricos respecto de la media que contienen una determinada masa de probabilidad (es decir, la variable pertenece a ellos con una determinada probabilidad). Por ejemplo, para el 50 %, se tiene

$$\begin{aligned} P[-a \leq Z \leq a] &= 0,5 \\ \Rightarrow \\ 2P[Z \leq a] - 1 &= 0,5 \\ \Rightarrow \\ P[Z \leq a] &= 0,75 \\ \Rightarrow \\ a &= 0,6744898 \end{aligned}$$

6. Relaciones entre Modelos**6.1. Aproximación de una Binomial a una Poisson**

Sea X una variable aleatoria discreta que se distribuye como una Binomial con parámetros (n, p) donde n tiende a infinito y, p tiende a 0. Cuando esto ocurre

podemos aproximar una distribución Binomial por medio de una distribución de Poisson, es decir,

$$X \rightarrow \mathcal{P}(\lambda = n \times p)$$

Por convenio se realizará esto cuando se verifiquen una de estas condiciones: Cuando se verifique $n \geq 30$ y $p \in (0,1)$.

6.2. Aproximación de una Binomial por una Normal

Sea X una variable aleatoria discreta que se distribuye como una Binomial con parámetros (n, p) , entonces De Moivre demostró que cuando, p es aproximadamente 0,5, esa variable aleatoria se puede aproximar como una distribución Normal. El criterio que se toma es que $n \geq 50$ y $p \cong 0,5$. Cuando esto ocurre se verifica que

$$\begin{aligned} X &\rightarrow \mathcal{P}(\lambda) \\ \lambda &\rightarrow \infty \end{aligned}$$

Dado que la normal es una distribución de tipo continuo, el uso directo de la aproximación anterior puede conducir a graves errores ya que asignaría probabilidad cero a puntos aislados y a los extremos de intervalos cerrados. Se usa la siguiente corrección (corrección por continuidad)

$$\begin{aligned} P[X = k] &= P\left[k - \frac{1}{2} \leq X \leq k + \frac{1}{2}\right] \\ &= P\left[\frac{k - \frac{1}{2} - np}{\sqrt{np(1-p)}} \leq X \leq \frac{k + \frac{1}{2} - np}{\sqrt{np(1-p)}}\right] \\ &\quad \forall k = 0, 1, \dots, n \end{aligned}$$

En el caso de un intervalo cerrado por la derecha se sumará 0,5 en el extremo superior y si es cerrado por la izquierda se restará 0,5 antes de tipificar y aproximar por la normal.

Nota Mediante el uso del ordenador es posible calcular probabilidades asociadas a la binomial sin tener que recurrir a la aproximación comentada. En caso de usarse, se recomienda que se cumplan las siguientes condiciones $np > 5$, $p \leq 0,5$ o $n(1-p) > 5$ $p > 5$

6.3. Aproximación de una Binomial por una Normal

Sea X una variable aleatoria discreta que se distribuye como una Poisson de parámetro (λ) , se demuestra que cuando λ es muy grande, se puede aproximar por medio de una distribución normal, como ocurría anteriormente. Así, si

$$\begin{aligned} X &\rightarrow \mathcal{P}(\lambda) \\ \lambda &\rightarrow \infty \end{aligned}$$

entonces

$$X \rightarrow \mathcal{N}(\mu = \lambda; \sigma^2 = \lambda)$$

7. DISTRIBUCIONES RELACIONADAS CON LA DISTRIBUCIÓN NORMAL

De nuevo el error cometido al aproximar una variable aleatoria discreta por una continua se corrige de la forma

$$\begin{aligned} P[X = k] &= P\left[k - \frac{1}{2} \leq X \leq k + \frac{1}{2}\right] \\ &= P\left[\frac{k - \frac{1}{2} - \lambda}{\sqrt{\lambda}} \leq X \leq \frac{k + \frac{1}{2} - \lambda}{\sqrt{\lambda}}\right] \\ &\quad \forall k = 0, 1, \dots, n \end{aligned}$$

Nota Mediante el uso del ordenador es posible calcular probabilidades asociadas a la Poisson sin tener que recurrir a la aproximación comentada. En caso de usarse, se recomienda que se cumpla la condición $\lambda > 10$.

Resumen

$$\begin{aligned} X_n &\sim B(n, p) \\ \Rightarrow \\ \lim_{n \rightarrow +\infty} P\left(\frac{X_n - np}{\sqrt{np(1-p)}} \leq z\right) &= P(Z \leq z) \quad \text{con } Z \sim \mathcal{N}(0, 1) \\ X_n &\sim \mathcal{P}(\lambda) \\ \Rightarrow \\ \lim_{n \rightarrow +\infty} P\left(\frac{X_n - \lambda}{\sqrt{\lambda}} \leq z\right) &= P(Z \leq z) \quad \text{con } Z \sim \mathcal{N}(0, 1) \end{aligned}$$

7. Distribuciones Relacionadas con la Distribución Normal

7.1. Distribución χ^2 de Pearson

Si χ^2 de n grados de libertad es la suma de n distribuciones $\mathcal{N}(0, 1)$ y cada uno de ellas elevadas al cuadrado y siendo independientes entre si.

$$\chi_n^2 = Z_1^2 + \dots + Z_n^2 \quad \text{siendo} \quad \begin{cases} Z_i &\sim \mathcal{N}(0, 1) \\ \forall i &= 1, \dots, n \end{cases}$$

Por lo tanto, de esta propiedad anterior llamada reproductiva resulta evidente:

$$\begin{aligned} \chi_{n+m}^2 &= \chi_n^2 + \chi_m^2 & n, m \in \mathbb{N} \\ \chi_{n-m}^2 &= \chi_n^2 - \chi_m^2 & n, m \in \mathbb{N} \text{ y } n > m \end{aligned}$$

Propiedades

$$\begin{aligned} E[\chi_n^2] &= n \\ \text{Var}[\chi_n^2] &= 2 \times n \\ \chi_n^2 &= \Gamma\left(\frac{1}{2}, \frac{1}{2}\right) \quad \forall n \in \mathbb{N} \end{aligned}$$

Características

- La forma de la distribución es asimétrica positiva, y se acerca a la distribución Normal cuanto mayor sea el número de grados de libertad.
- Para valores grandes de n, la distribución χ^2 se aproxima a la distribución Normal. La aproximación se considera aceptable para $n > 30$.
- Las puntuaciones de χ^2 no puede tomar valores negativos.
- Es reproductiva.

7.2. Distribución t de Student

El cociente de una distribución normal tipificada entre la raíz cuadrada del cociente entre una χ_n^2 entre sus grados de libertad, es un t de Student con los mismos grados de libertad que la χ^2 utilizada en la definición. Es decir,

$$\left. \begin{array}{l} Z \sim \mathcal{N}(0,1) \\ Y \sim \chi_n^2 \end{array} \right\} \text{Independientes}$$

Entonces

$$\begin{aligned} t &= \frac{Z}{\sqrt{\frac{Y}{n}}} \\ &\sim \frac{\mathcal{N}(0,1)}{\sqrt{\frac{\chi_n^2}{n}}} \end{aligned}$$

Como se puede observar, el recorrido del estadístico t es todo $\mathbb{R}$ ya que este es el recorrido del numerador, ya que el denominador siempre es positivo.

Por otra parte, la representación gráfica de la función de densidad de la t de Student es similar a la Distribución Normal pero es más achatada por ser platicúrtica.

Proposición 20.3 *Propiedad Reproductividad Si $X_1, \dots, X_n$ son n variables aleatorias independientes y cada uno con k_i grados de libertad y distribuidas según una $t(k_i)$ La nueva variable aleatoria $Y = X_1 + \dots + X_n$ sigue una distribución $t(k_1 + \dots + k_n)$*

Características

$$\begin{aligned} E[t] &= 0 \\ \text{Var}[t] &= \frac{n}{n-2} \end{aligned}$$

Solo tiene sentido definir las para valores de $n > 2$, puesto que menores no se puede. Su gráfica es parecida a la distribución Normal Tipificada (y que tienen la misma media) y será por lo tanto más parecida cuanto mayor sea n , pues a medida que n tiende a infinito la varianza de la distribución t de Student tiende a 1.

Propiedades

- Es simétrica con respecto al eje de ordenadas
- $M_o = M_e = 0$
- Cuando el número de variables aleatorias es muy grande, es decir, cuando $n \rightarrow +\infty$, la variable se puede aproximar por una normal

7.3. Distribución F de Snedecor

Es el cociente de dos distribuciones χ^2 independientes que están divididas cada una de ellas por sus respectivos grados de libertad. Es decir, sean las variables aleatorias Y, W que verifican

$$\left. \begin{aligned} Y &\sim \chi_n^2 \\ W &\sim \chi_m^2 \end{aligned} \right\} \text{Independientes}$$

$$\begin{aligned} F_{n,m} &= \frac{\frac{Y}{n}}{\frac{W}{m}} \\ &= \frac{\frac{\chi_n^2}{n}}{\frac{\chi_m^2}{m}} \end{aligned}$$

Se dice que F tiene n grados de libertad en el numerador y m grados de libertad en el denominador.

Una propiedad importante y sobre todo muy útil de esta distribución en el manejo de las tablas es el siguiente: “Si una variable aleatoria X sigue una distribución F de Snedecor de n y m grados de libertad, entonces $1/X$ sigue una distribución F de Snedecor de m y n grados de libertad”

Es decir

$$F_{n,m}(1-\alpha) = \frac{1}{F_{m,n}(\alpha)}$$

Características

$$\begin{aligned} E[t] &= \frac{n}{n-2} \\ \text{Var}[t] &= \frac{2m^2(n+m-2)}{n(m-2)^2(m-4)} \quad \text{Si } m > 4 \end{aligned}$$

Propiedades

- Para valores grandes de n y m , la distribución F de Senedecor se aproxima a la distribución Normal.
- Si $m \rightarrow +\infty$, Entonces la distribución $X \sim F_{n,m} \rightarrow \chi_n^2$

7. DISTRIBUCIONES RELACIONADAS CON LA DISTRIBUCIÓN NORMAL

CAPÍTULO 21

Distribuciones Asociadas a los Estadísticos Muestrales de una Población Normal

El fundamento probabilístico de gran parte de la Inferencia Estadística clásica elemental se encuentra en las distribuciones de probabilidad que tienen ciertas variables aleatorias muy relacionadas con la media y varianza muestrales que se obtienen de poblaciones con distribución supuestamente normal.

Mediante estas distribuciones se calculan intervalos de confianza y cotas de error de estimación puntual para la media y varianza poblacionales o se formulan contrastes de hipótesis para dichos parámetros, como se estudiará en temas posteriores.

La metodología estadística que se construye sobre las distribuciones de probabilidad que se estudiará en este capítulo, es aplicable a gran cantidad de problemas diferentes, debido al elevado número de situaciones en las que la variable que se observa tiene distribución aproximadamente Normal. Esto se explica por lo que se conoce como problema del límite central, que expresa de forma analítica, mediante algunos teoremas de gran importancia, la sencilla idea de que cuando se acumulan en la consecución de un fenómeno muchas circunstancias diferentes que lo originan la variable aleatoria resultante es aproximadamente Normal. Por ejemplo, sobre la estatura de la población humana inciden gran cantidad de factores ambientales, alimentarios, genéticos, etc. Si se estudia esta variable sobre un número elevado de personas fácilmente puede comprobarse que el histograma y polígono de frecuencias adquieren una forma muy similar a una campana de Gauss que es la gráfica de la función de densidad de una distribución Normal.

Los mismos teoremas del límite central afirma que la media de una muestra, procedente de una variable que no es normal, tiene una distribución, que conforme el tamaño de la muestra crece, su parecido con la Normal se intensifica hasta hacerse prácticamente iguales. Por esta razón cuando los tamaños muestrales son suficientemente elevados (y esto en muchas ocasiones

puede significar mas de 30 ó 50 individuos), aunque la variable aleatoria estudiada no tenga distribución Normal, su media muestral si la tiene, al menos aproximadamente.

Todos estos razonamientos autorizan un alto grado de aplicabilidad de la metodología que se estudiará en próximos capítulos. Una metodología que no es excesivamente complicada y que sin embargo tiene un elevado rendimiento.

No se puede afirmar que la ley Normal sea el **patron universal** de la probabilidad y estadística

1. Concepto de Muestra y Estadístico

Un problema fundamental en la estadística consiste en estudiar alguna característica desconocida de una distribución de probabilidad de una variable aleatoria.

1.1. Muestra Aleatoria

Se le llama muestra de tamaño n , tomada de una población con función de distribución $F(x)$, al conjunto de los n valores observados $(X_1, \dots, X_n)$.

Se le denomina una realización de la muestra o simplemente muestra observada.

Es fundamental elegir adecuadamente los elementos de la muestra y el tamaño. Normalmente trabajaremos con lo que se conoce como muestreo aleatorio simple, que consiste en que todos los elementos de la población tienen la misma probabilidad de estar en la muestra y son independientes entre ellos.

1.2. Parámetros Poblacionales

Todas las medidas estadísticas, la media, la varianza, coeficientes de asimetría, de curtosis, ... cuando se refieren a todos los elementos de una población se les conoce con el nombre de parámetro poblacionales. Son valores constantes, aunque utilicemos distintas muestras siempre que se trabaje con la misma población.

El conocimiento del parámetro poblacional permite describir parcial o totalmente la distribución de probabilidad de la variable que estamos investigando.

Su verdadero valor se desconoce, a menos que se observen todos los elementos de la población, en cuyo caso la inferencia estadística carecería de sentido.

Algunos de estos parámetros, suelen aparecer en la función de distribución de la variable objeto de estudio. Por ejemplo, en una distribución de Poisson estará la media poblacional como parámetro λ . En la distribución Normal estarán la media μ y la varianza σ^2 como parámetros poblacionales.

1.3. Estadísticos Muestrales

Se le llama estadísticos muestral a cualquier función real de la muestra que sea a su vez una variable aleatoria. Por ejemplo: un estadístico muy utilizado es la media de valores observados a la que llamaremos media muestral $\bar{X}$. Este estadístico es, por lo tanto, una función que asigna a cada muestra observada, la media de sus valores.

Estadísticos Más utilizados

Media Muestral $\bar{X}$

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

Por lo tanto

$$n\bar{X} = \sum_{i=1}^n X_i$$

Varianza Muestral S_n^2

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

Demostración

$$\begin{aligned} S_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\ &= \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2 \right) \\ &= \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - 2\bar{X} \times n \times \bar{X} + n \times \bar{X}^2 \right) \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \end{aligned}$$

CuasiVarianza Muestral S_{n-1}^2

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Relación entre varianza y cuasivarianza muestral

$$\left. \begin{aligned} S_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ S_{n-1}^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \end{aligned} \right\} = \left\{ \begin{aligned} n \times S_n^2 &= \sum_{i=1}^n (X_i - \bar{X})^2 \\ (n-1) \times S_{n-1}^2 &= \sum_{i=1}^n (X_i - \bar{X})^2 \end{aligned} \right.$$

Por tanto nos queda que:

$$n \times S_n^2 = (n-1) \times S_{n-1}^2$$

Entonces

$$\begin{aligned} S_n^2 &= \frac{n-1}{n} \times S_{n-1}^2 \\ o \\ S_{n-1}^2 &= \frac{n}{n-1} \times S_n^2 \end{aligned}$$

1.4. Valores Esperado y Varianza de algunos Estadísticos

Esperanza de la Media Muestral $\bar{X}$

La esperanza de la media muestral coincide con la media de la población, en definitiva; la media de la media muestral es la media de la población:

$$E[\bar{X}] = \mu$$

Demostración La demostración no presenta ninguna dificultad

$$\begin{aligned} E[\bar{X}] &= E\left[\frac{X_1 + \dots + X_n}{n}\right] \\ &= \frac{1}{n}E[X_1 + \dots + X_n] \\ &= \frac{1}{n}(E[X_1] + \dots + E[X_n]) \\ &= \frac{1}{n}(\mu + \dots + \mu) \\ &= \frac{1}{n} \times n \times \mu = \mu \end{aligned}$$

Es decir, tal y como se pretendía demostrar, la esperanza de la distribución muestral de la media es igual a la media poblacional.

Varianza de la Media Muestral $\bar{X}$

En cuanto a la varianza de la media muestral, se tendrá que si el muestreo utilizado es aleatorio simple se cumple que

$$Var[\bar{X}] = \frac{Var[X]}{n}$$

Demostración

$$\begin{aligned} Var[\bar{X}] &= Var\left[\frac{X_1 + \dots + X_n}{n}\right] \\ &= \frac{1}{n^2}Var[X_1 + \dots + X_n] \\ &= \frac{1}{n^2}(Var[X_1] + \dots + Var[X_n]) \\ &= \frac{1}{n^2} \times n \times Var[X] = \frac{Var[X]}{n} \end{aligned}$$

CAPÍTULO 21. DISTRIBUCIONES ASOCIADAS A LOS ESTADÍSTICOS MUESTRALES DE UNA POBLACIÓN NORMAL

dado que en el muestreo aleatorio simple las observaciones o elementos son independientes tendremos covarianzas iguales a cero y dado que:

$$Var[X_i] = Var[X]$$

evidentemente la desviación típica será

$$D[\bar{X}] = \frac{D[X]}{\sqrt{n}}$$

En el caso de que el muestreo que hayamos realizado no sea aleatorio simple y que sea irrestricto y por tanto se plantee que no hay reemplazamiento siendo la población finita la media de la media muestral no sufrirá variaciones, pero no así la varianza de la media muestral que se verá afectada por el “coeficiente corrector de poblaciones finitas” (C.C.P.F.), o “coeficiente de exhaustividad”. Así la varianza de la media muestral quedaría:

$$Var[\bar{X}] = \frac{Var[X]}{n} \times \frac{N-n}{N-1}$$

siendo N el tamaño de la población (finita) y el resto lo habitual

Valor Esperado de la Varianza

Al igual que la media muestral la varianza muestral tendrá media y varianza dado que se trata también de una variable aleatoria.

La media de la varianza muestral con m.a.s. es:

$$E[S_n^2] = \frac{n-1}{n} Var[X]$$

Demostración Se sabe que

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Se puede sumar y restar dentro del paréntesis lo que queramos. Se suma lo que es la media poblacional μ

$$\begin{aligned} S_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2 \\ &= \frac{1}{n} \sum_{i=1}^n ((X_i - \mu) - (\bar{X} - \mu))^2 \end{aligned}$$

Se desarrollan los cuadrados.

$$\frac{1}{n} \sum_{i=1}^n ((X_i - \mu)^2 + (\bar{X} - \mu)^2 - 2(X_i - \mu) \times (\bar{X} - \mu))$$

Se desarrolla un poco y se tiene

$$\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 + \sum_{i=1}^n (\bar{X} - \mu)^2 - \sum_{i=1}^n 2(X_i - \mu) \times (\bar{X} - \mu) \right)$$

Todo lo que no dependa de i se saca

$$\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times \sum_{i=1}^n 1 - 2 \times (\bar{X} - \mu) \times \sum_{i=1}^n (X_i - \mu) \right)$$

quedando

$$\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times (\bar{X} - \mu) \times \left(\sum_{i=1}^n X_i - \sum_{i=1}^n \mu \right) \right)$$

Se sabe que

$$\sum_{i=1}^n X_i = n \times \bar{X}$$

Quedando

$$\begin{aligned} & \frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times (\bar{X} - \mu) \times (n \times \bar{X} - n \times \mu) \right) \\ &= \frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times n \times (\bar{X} - \mu) \times (\bar{X} - \mu) \right) \\ &= \frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \end{aligned}$$

Por tanto

$$\begin{aligned} E[S_n^2] &= E \left[\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \right] \\ &= \frac{1}{n} E \left[\left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \right] \\ &= \frac{1}{n} \left(E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] - n \times E[(\bar{X} - \mu)^2] \right) \end{aligned}$$

Se sabe que

$$\begin{aligned} E[(X_i - \mu)^2] &= \text{Var}[X] \\ E[(\bar{X} - \mu)^2] &= \text{Var}[\bar{X}] = \frac{\text{Var}[X]}{n} \end{aligned}$$

Se puede reescribir como:

$$\begin{aligned} E[S_n^2] &= \frac{1}{n} \left(\sum_{i=1}^n \text{Var}[X] - n \times \frac{\text{Var}[X]}{n} \right) \\ &= \frac{1}{n} (n \times \text{Var}[X] - \text{Var}[X]) \\ &= \frac{n-1}{n} (\text{Var}[X]) \end{aligned}$$

Varianza de la varianza muestral

En cuanto a la varianza de la varianza muestral diremos que su expresión es la siguiente ,que admitimos sin demostrar que :

$$Var[S_n^2] = \frac{(n-1)^2}{n^3} \left(\mu_4 - \frac{(n-3)}{n-1} \times Var[X]^4 \right)$$

Donde μ_4 es el momento poblacional de orden 4 con respecto a la media y $n > 1$

Valor Esperado de la Cuasivarianza Muestral

$$E[S_{n-1}^2] = Var[X]$$

Demostración Se sabe que

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Se puede sumar y restar dentro del paréntesis lo que queramos. Se suma lo que es la media poblacional μ

$$\begin{aligned} S_{n-1}^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n ((X_i - \mu) - (\bar{X} - \mu))^2 \end{aligned}$$

Se desarrollan los cuadrados.

$$\frac{1}{n-1} \sum_{i=1}^n ((X_i - \mu)^2 + (\bar{X} - \mu)^2 - 2(X_i - \mu) \times (\bar{X} - \mu))$$

Se desarrolla un poco y se tiene

$$\frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 + \sum_{i=1}^n (\bar{X} - \mu)^2 - \sum_{i=1}^n 2(X_i - \mu) \times (\bar{X} - \mu) \right)$$

Todo lo que no dependa de i se saca

$$\frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times \sum_{i=1}^n 1 - 2 \times (\bar{X} - \mu) \times \sum_{i=1}^n (X_i - \mu) \right)$$

quedando

$$\frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times (\bar{X} - \mu) \times \left(\sum_{i=1}^n X_i - \sum_{i=1}^n \mu \right) \right)$$

Se sabe que

$$\sum_{i=1}^n X_i = n \times \bar{X}$$

Quedando

$$\begin{aligned} & \frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times (\bar{X} - \mu) \times (n \times \bar{X} - n \times \mu) \right) \\ = & \frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 + (\bar{X} - \mu)^2 \times n - 2 \times n \times (\bar{X} - \mu) \times (\bar{X} - \mu) \right) \\ = & \frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \end{aligned}$$

Por tanto

$$\begin{aligned} E[S_{n-1}^2] &= E \left[\frac{1}{n-1} \left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \right] \\ &= \frac{1}{n-1} E \left[\left(\sum_{i=1}^n (X_i - \mu)^2 - n \times (\bar{X} - \mu)^2 \right) \right] \\ &= \frac{1}{n-1} \left(E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] - n \times E[(\bar{X} - \mu)^2] \right) \end{aligned}$$

Se sabe que

$$\begin{aligned} E[(X_i - \mu)^2] &= Var[X] \\ E[(\bar{X} - \mu)^2] &= Var[\bar{X}] = \frac{Var[X]}{n} \end{aligned}$$

Se puede reescribir como:

$$\begin{aligned} E[S_{n-1}^2] &= \frac{1}{n-1} \left(\sum_{i=1}^n Var[X] - n \times \frac{Var[X]}{n} \right) \\ &= \frac{1}{n-1} (n \times Var[X] - Var[X]) \\ &= \frac{n-1}{n-1} (Var[X]) \\ &= Var[X] \end{aligned}$$

Varianza de la cuasivarianza muestral

En cuanto a la varianza de la cuasivarianza muestral diremos que su expresión es la siguiente ,que admitimos sin demostrar que :

$$Var[S_{n-1}^2] = \frac{1}{n} \left(\mu_4 - \frac{(n-3)}{n-1} \times Var[X]^4 \right)$$

Donde μ_4 es el momento poblacional de orden 4 con respecto a la media y $n > 1$

2. Distribución para la media de una muestra procedente de una población normal con varianza conocida

Sea $X_1, \dots, x_n$ es una muestra independiente de tamaño n procedente de una población normal $\mathcal{N}(\mu, \sigma^2)$. Se verifica que la media muestral es una variable aleatoria Normal con media μ y $\frac{\sigma^2}{n}$. Como consecuencia

$$\frac{(\bar{X} - \mu)\sqrt{n}}{\sigma} \quad (21.1)$$

tiene una distribución normal $\mathcal{N}(0, 1)$.

Ejemplo 21.1 *Sabiendo que las ventas diarias de un comercio en una temporada determinada tienen una distribución normal de media 1500 euros y desviación típica 300 euros, calcular el porcentaje de muestras de tamaño 25 en las cuales la media muestral supere los 1600 euros*

$$\begin{aligned} P(\bar{X} > 1600) &= 1 - P(\bar{X} < 1600) \\ &= 1 - P\left(\frac{\bar{X} - 1500}{\frac{300}{\sqrt{25}}} < \frac{1600 - 1500}{\frac{300}{\sqrt{25}}}\right) \\ &= 1 - P(Z < 1,67) \\ &= 1 - \Phi(1,67) \\ &= 1 - 0,9522 = 0,0478 \end{aligned}$$

Donde Φ representa la función de distribución de la variable $\mathcal{N}(0, 1)$

3. Distribución para la cuasivarianza y la varianza y de una muestra procedente de una población normal

Dada una muestra independiente $X_1, \dots, X_n$ procedente de una población Normal $\mathcal{N}(\mu, \sigma^2)$, la variable aleatoria

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$$

tiene una distribución χ^2 con n grados de libertad, es decir una $\gamma(\frac{n}{2}, 2)$.

En efecto, cada variable $\frac{X_i - \mu}{\sigma}$ tiene una distribución $\mathcal{N}(0, 1)$, y su cuadrado tiene una distribución χ^2 con un grado de libertad. La suma de todas ellas (que son independientes) es una variable aleatoria χ^2 con n grados de libertad debido a la propiedad de reproductividad de la distribución gamma: la suma de variables gamma independientes con parámetros de escala común, es otra variable gamma cuyo parámetro de forma es suma de sus homólogos en las distribuciones de las variables sumandos, y con el mismo parámetros de escala que todas ellas.

3. DISTRIBUCIÓN PARA LA CUASIVARIANZA Y LA VARIANZA Y DE UNA MUESTRA PROCEDENTE DE UNA POBLACIÓN NORMAL

Se verifica que la variable

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} = \frac{nS_n^2}{\sigma^2} \quad (21.2)$$

$$= \frac{(n-1)S_{n-1}^2}{\sigma^2} \quad (21.3)$$

tiene una distribución χ^2 con n-1 grados de libertad, donde

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

reciben el nombre, respectivamente, de varianza y cuasivarianza muestral.

En efecto, por una parte se tiene en cuenta que la media y cuasivarianza (varianza) muestrales son variables aleatorias independientes. Por otra parte si consideramos que

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2$$

resulta

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} - \frac{n(\bar{X} - \mu)^2}{\sigma^2}$$

El miembro de la izquierda es la diferencia de dos variables aleatorias independientes ambas con distribución χ^2 de n y 1 grado de libertad respectivamente. el resultado es una variable aleatoria con la misma distribución y cuyos grados de libertad son la diferencia entre los del minuendo y los del sustraendo.

Ejemplo 21.2 *Un lote de piezas que deben tener una longitud media específica es rechazado cuando la desviación típica de las longitudes supera los 2 cm. Calcular la probabilidad de que en una muestra de 16 piezas seleccionadas al azar, la cuasivarianza típica muestral supere el valor de 2,14 cm si la desviación típica del lote es 1,5 cm*

$$\begin{aligned} P(S_{n-1} > 2,14) &= P(S_{n-1}^2 > 2,14^2) \\ &= P\left(\frac{(16-1)S_{n-1}^2}{1,5^2} > \frac{(16-1)2,14^2}{1,5^2}\right) \\ &= P(\chi_{15}^2 > 30,53) \cong 0,01 \end{aligned}$$

La última probabilidad se busca en la tabla de la distribución χ^2 con 15 grados de libertad.

4. Distribución para la media de una muestra procedente de una población normal con varianza desconocida: El cociente t-Student

Se verifica que la variable aleatoria

$$t = \frac{(\bar{X} - \mu)\sqrt{n}}{S_{n-1}} \quad (21.4)$$

$$= \frac{(\bar{X} - \mu)\sqrt{n-1}}{S_n} \quad (21.5)$$

tiene una distribución t-Student con n-1 grados de libertad.

En efecto, la variable $t = \frac{u}{\frac{v}{k}}$ donde u tiene una distribución $\mathcal{N}(0, 1)$ y v tiene una distribución χ^2 con k grados de libertad, ambas independientes, tiene una distribución t-Student con k grados de libertad.

La variables media muestral y cuasivarianza (varianza) muestral son independientes.

Por otra parte, según la expresión (21.1) y (21.2), el cociente

$$\begin{aligned} t &= \frac{\frac{(\bar{X} - \mu)\sqrt{n}}{\sigma}}{\sqrt{\frac{(n-1)S_{n-1}^2}{\frac{\sigma^2}{n-1}}}} \\ &= \frac{\frac{(\bar{X} - \mu)\sqrt{n}}{\sigma}}{\sqrt{\frac{nS_n^2}{\frac{\sigma^2}{n-1}}}} \end{aligned}$$

tiene una distribución t-Student con n-1 grados de libertad. Simplificando la expresión anterior queda (21.5).

Obsérvese que (21.5) puede considerarse resultante de (21.1) es la cual se sustituye la varianza poblacional (ahora desconocida) por la cuasivarianza (varianza) muestral.

Ejemplo 21.3 Si la demanda semanal de un artículo es una variable aleatoria cuya distribución puede considerarse aproximadamente Normal de media 150 unidades, calcular la probabilidad de que una muestra de semanas de lugar a una media muestral superior a 158 sabiendo que la cuasivarianza muestral es 64

$$\begin{aligned} P(\bar{X} > 158) &= P\left(t > \frac{(158 - 150)\sqrt{5}}{8}\right) \\ &= 1 - F_4(2, 236) \cong 0,05 \end{aligned}$$

donde F_4 representa la función de distribución de la variable t-Student con 4 grados de libertad

5. Distribuciones de probabilidad para la diferencia de medias de dos muestras independientes procedentes de sendas poblaciones normales

5.1. Caso en el que las varianzas de ambas poblaciones son conocidas

Dadas dos muestras independientes de tamaños n y m , procedentes de dos poblaciones normales $\mathcal{N}(\mu_1, \sigma_1^2)$ y $\mathcal{N}(\mu_2, \sigma_2^2)$, las respectivas medias muestrales, también tienen distribución Normal

$$\begin{aligned}\bar{X} &\rightarrow \mathcal{N}\left(\mu_1, \frac{\sigma_1^2}{n}\right) \\ \bar{Y} &\rightarrow \mathcal{N}\left(\mu_2, \frac{\sigma_2^2}{m}\right)\end{aligned}$$

cualquier combinación lineal de las variables normales también es variable aleatoria normal, con media combinación lineal de las medias (con los mismos coeficientes) y varianza combinación lineal de las varianzas (con los mismos coeficientes al cuadrado). Por tanto la diferencia $\bar{X} - \bar{Y}$, como combinación lineal de los coeficientes $+1$ y -1 tiene distribución Normal con media la diferencia de las medias y varianza la suma de las varianzas

$$\bar{X} - \bar{Y} \rightarrow \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right)$$

De esta expresión se deduce que la variable

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \quad (21.6)$$

tiene una distribución $\mathcal{N}(0, 1)$

Si las varianzas en ambas poblaciones coinciden ($\sigma_1^2 = \sigma_2^2 = \sigma^2$) entonces la expresión (21.6) queda

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{m+n}{nm}}} \quad (21.7)$$

5.2. Caso en el que las varianzas de ambas poblaciones son desconocidas pero iguales

Puesto que en (21.7), σ es cantidad desconocida, se sustituye por su homólogo muestral, aprovechando las dos muestras de las que se dispone: Si S_1^2 y S_2^2 representan las cuasivarianzas en cada una de las dos muestras disponibles, se construirá una cantidad única a partir de ellas de la siguiente forma:

$$S_e^2 = \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}$$

CAPÍTULO 21. DISTRIBUCIONES ASOCIADAS A LOS ESTADÍSTICOS MUESTRALES DE UNA POBLACIÓN NORMAL

S_e^2 prácticamente es una media de las cuasivarianzas muestrales ponderada por los tamaños de las mismas (menos una unidad). Observese que se puede obtener una expresión análoga, si en lugar de las cuasivarianzas muestrales se utilizan las varianzas muestrales. En sustitución de los coeficientes $(n-1)$ y $(m-1)$ en el numerador aparecen respectivamente n y m

La variable aleatoria

$$\frac{(n-1)S_1^2 + (m-1)S_2^2}{\sigma^2}$$

tiene distribución χ^2 con $m+n-2$ grados de libertad por ser suma de variables aleatorias χ^2 independientes con $(n-1)$ y $(m-1)$ grados de libertad.

Por tanto, mediante un proceso similar seguido en (5.1) llegamos a la conclusión de que si en (21.7) se sustituye la cantidad desconocida por σ por S_e se obtiene la variable aleatoria:

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_e \sqrt{\frac{m+n}{nm}}}$$

cuya distribución es t-Student con $m+n-2$ grados de libertad

5.3. Caso en el que la varianza de ambas poblaciones son desconocidas y desiguales (Aproximación de Welch)

Cuando las varianzas son desconocidas pero puede conocerse, al menos aproximadamente, la razón de ambas, la variable

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} \frac{S_2^2}{m}}}$$

tiene una distribución que puede aproximarse mediante una t-Student cuyos grados de libertad se calculan mediante la expresión

$$v = \frac{\left(\frac{\theta}{n} + \frac{1}{m}\right)^2}{\frac{\theta^2}{n^2(n-1)} + \frac{1}{m^2(m-1)}}$$

siendo $\theta = \frac{\sigma_1^2}{\sigma_2^2}$

θ se supone conocido, al menos aproximadamente mediante la información muestral.

5.4. Caso en que las dos varianzas son desconocidas y tamaños muestrales elevados

Se sustituye en (21.6) cada varianza poblacional, que es desconocida, por la correspondiente cuasivarianza muestral, considerando que en virtud de los elevados tamaños muestrales ambas están suficientemente próximas para proceder como si fuesen conocidas. De este modo, la variable

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$$

tiene una distribución que puede considerarse $\mathcal{N}(0, 1)$

6. Distribución para el cociente de varianzas

Dadas dos muestras independientes procedentes de sendas poblaciones normales $\mathcal{N}(\mu_1, \sigma_1^2)$ y $\mathcal{N}(\mu_2, \sigma_2^2)$, las variables aleatorias

$$\frac{(n-1)S_1^2}{\sigma_1^2} \quad \frac{(m-1)S_2^2}{\sigma_2^2}$$

tienen una distribución χ^2 con n-1 grados de libertad y m-1 grados de libertad respectivamente, siendo ambas independientes.

Por otra parte, la variable aleatoria $F = \frac{\frac{u}{k_1}}{\frac{v}{k_2}}$ tiene distribución F de de Snedecor con k_1 y k_2 grados de libertad para el numerador y denominador, cuando u y v son independientes y con distribución χ^2 con k_1 y k_2 grados de libertad respectivamente.

Como consecuencia,

$$F = \frac{S_1^2 \sigma_2^2}{S_2^2 \sigma_1^2}$$

es una variable aleatoria cuya distribución de F de Snedecor con n-1 y m-1 grados de libertad para el numerador y denominador, respectivamente

7. Distribución para la proporción muestral

Si $X_1, \dots, X_n$ es una muestra de pruebas de Bernoulli independientes de parámetros p, entonces si la variable aleatoria

$$Y = \sum_{i=1}^n X_i$$

tiene una distribución binomial $B(n, p)$. La proporción muestral

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$$

tiene distribución de probabilidad

$$P\left(\hat{p} = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k} \quad k = 0, 1, 2, \dots, n$$

CAPÍTULO 21. DISTRIBUCIONES ASOCIADAS A LOS ESTADÍSTICOS MUESTRALES DE UNA POBLACIÓN NORMAL

Si el tamaño de la muestra es suficientemente alto, entonces, en virtud del teorema del límite central, la variable Y tiene una distribución aproximadamente Normal de media np y varianza npq donde $q = 1 - p$. Como consecuencia la proporción muestral tiene distribución aproximadamente Normal

$$\mathcal{N}\left(p, \frac{pq}{n}\right)$$

a efectos prácticos, para la obtención de intervalos de confianza, se suele admitir que:

$$\frac{\hat{p} - p}{\sqrt{\frac{\hat{p}\hat{q}}{n}}} \rightarrow \mathcal{N}(0, 1)$$

8. Distribución para la diferencia de proporciones muestrales

Dadas dos muestras independientes con tamaños n y m , de pruebas de Bernoulli cuyos respectivos parámetros representamos por p_1 y p_2 , se verifica que la variable aleatoria

$$\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}}} \quad (21.8)$$

tiene una distribución aproximadamente $\mathcal{N}(0, 1)$ si los tamaños muestrales son suficientemente elevados

En efecto, según en 7 cada una de las proporciones muestrales tiene una distribución aproximadamente Normal y son independientes. La diferencia de ambas proporciones tienen una distribución aproximadamente Normal

$$\mathcal{N}\left(p_1 - p_2, \frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}\right) \rightarrow \mathcal{N}(0, 1)$$

Tipificando se obtiene la expresión 21.8 que obviamente tiene distribución $\mathcal{N}(0, 1)$

También en este caso, a efectos prácticos, para la construcción de intervalos de confianza, se suele aceptar que la variable

$$\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}}} \quad (21.9)$$

tiene distribución aproximadamente normal $\mathcal{N}(0, 1)$

8. DISTRIBUCIÓN PARA LA DIFERENCIA DE PROPORCIONES MUESTRALE

CAPÍTULO 22

Estimación Puntual de Parámetros

1. Introducción a la Estimación: Concepto de Estimador de un Parámetro

El problema de estimar una característica numérica, desconocida en una población, utilizando para ello la información recogida en una muestra, es bastante frecuente en el ámbito de la mayor parte de las ciencias y muy especialmente en las ciencias sociales.

Una o varias de estas características pueden formalizarse generalmente como parámetros en la distribución de probabilidad de la variable aleatoria considerada y de la que pueden observarse valores concretos sobre muestras obtenidas de la población objeto de estudio.

Supongamos una variable aleatoria cuya distribución es conocida, pero con una serie de parámetros desconocidos. Tomamos una muestra representativa de la población, a partir de estos valores de la muestra podemos estimar los parámetros de la población. Este proceso, recibe el nombre de “estimación paramétrica”

Por ejemplo, supóngase que el tiempo en servir a un cliente en un cierto establecimiento es una variable aleatoria X co distribución exponencial θ . El tiempo medio de servicio, en general, es una característica desconocida de esa población, que puede estimarse observando los tiempos en los que se despacha a un número determinado de clientes seleccionados al azar (muestra). Intuitivamente, no resulta difícil aceptar que la media aritmética de los tiempo observados en la muestra puede ser una aproximación más o menos satisfactoria del valor medio poblacional que es justamente el parámetro $\theta = E[X]$.

2. MÉTODO DE LA MÁXIMA VEROSIMILITUD PARA LA OBTENCIÓN DE ESTIMADORES PUNTUALES

1.1. Estimador de un Parámetro

Es un estadístico muestral que se utiliza para la determinación de un parámetro poblacional. Se trata pues de una variable aleatoria que asigna a cada muestra observada un número real, que es el valor (estimado) que asignamos al parámetro poblacional desconocido y que estamos tratando de conocer. Evidentemente, muestras distintas, aunque sean de la misma población pueden dar estimaciones diferentes. Parámetros poblacionales importantes son la media, varianza y la proporción poblacional. En la siguiente tabla expresamos diferentes parámetros poblacionales, sus estimadores y sus estimaciones:

Parámetro Poblacional	Estimador	Estimación
Media μ	$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Varianza σ^2	$\hat{\sigma}^2 = S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
Proporción	$\hat{P} = \frac{X}{n}$	$P_x = \frac{x}{n}$

El mejor estimador de la varianza poblacional es la cuasivarianza muestral

2. Método de la Máxima Verosimilitud para la Obtención de Estimadores Puntuales

2.1. Función de Verosimilitud

El método más común para estimar parámetros es el método de máxima verosimilitud. Sea X una variable aleatoria cuya función de distribución $F(X)$ y por tanto su función de densidad son conocidos. Sea la función $f(x; \theta)$ para los parámetros NO CONOCIDOS. Sean: Se llama función de verosimilitud de

X_1 : Primer Elemento de la Muestra $f(x_1; \theta)$
 X_2 : Primer Elemento de la Muestra $f(x_2; \theta)$
 $\dots$
 X_n : Primer Elemento de la Muestra $f(x_n; \theta)$

n variables aleatorias a la función de densidad (o función de probabilidad en el caso discreto) conjunta de la variable n -dimensional:

$$L(x_1, \dots, x_n; \theta) = f(x_1; \theta) \times \dots \times f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

Por ser una muestra aleatoria simple (m.a.s) independiente e idénticamente distribuida (i.i.d) La función de verosimilitud depende de la muestra observada, pues cada una de ellas tomara un valor, pero en la estimación máxima -verosimilitud en función de los parámetros. Se llama elemento de verosimilitud o verosimilitud de la muestra, a la función de verosimilitud considerada como función sólo de los parámetros, es decir, el valor que toma la función para una muestra dada y concreta $(x_1, \dots, x_n)$, la muestra permanece constante mientras los valores de los parámetros varían dentro de lo que se conoce con el nombre de espacio paramétrico o conjunto de posibles valores. El método de

máxima verosimilitud fue utilizado por Gauss en casos particulares e introducido como método de estimación por Fisher en 1922. Se fundamenta en el siguiente razonamiento intuitivo: “dado que aquellos sucesos con mayor probabilidad son los que mañan frecuente se espera observar, es lógico pensar que salvo en contadas ocasiones, los valores que se obtienen en una muestra se encuentran en la zona más probable o verosímil de la variable”.

Si se dispone de una muestra de n observaciones de una variable aleatoria y la distribución de las mismas posee uno o varios parámetros que son desconocidos, estimar esas cantidades desconocidas mediante aquellos valores que asignan mayor verosimilitud o posibilidad de realización a la muestra, debe ser la estrategia a seguir en este método.

Consiste en elegir como estimador del parámetro desconocido θ aquel valor $\hat{\theta}(X_1, \dots, X_n)$ que hace máxima la función de verosimilitud $L(x_1, \dots, x_n; \theta)$.

Es decir, consiste en encontrar aquel valor $\hat{\theta}(X_1, \dots, X_n)$ tal que:

$$L(x_1, \dots, x_n; \hat{\theta}) = \text{máx } L(x_1, \dots, x_n; \theta)$$

A este estimador $\hat{\theta}(X_1, \dots, X_n)$ se le llama estimador de máxima verosimilitud.

Dada una muestra, el método para encontrar el valor θ , que le asigna máxima verosimilitud, se convierte en el problema matemático de encontrar los valores extremos de una función de una sola variable. El elemento de verosimilitud de la muestra seleccionada considerado como función de θ .

El estimador de máxima verosimilitud no tiene porqué existir y en caso de que exista, la solución puede ser no única y coincidir con un extremo absoluto. Afortunadamente existe una clase amplia de distribuciones para las cuales la solución es única y coincide con el máximo relativo de la verosimilitud, localizado en el punto que anula la primera derivada y hace negativa la segunda. En tales circunstancias el estimador máximo verosímil es la solución de la ecuación

$$\frac{\partial}{\partial \theta} L(x_1, \dots, x_n; \theta) = 0$$

Aunque habitualmente resulta más sencillo encontrar el máximo sobre la función logaritmo de la verosimilitud.

Por ello, la ecuación que se resolverá, en la mayoría de los casos es:

$$\frac{\partial}{\partial \theta} \log L(x_1, \dots, x_n; \theta) = 0$$

La solución $\hat{\theta}$ obtenida de esta ecuación, ha de hacer negativa la segunda derivada, es decir:

$$\frac{\partial^2}{\partial \theta^2} \log L(x_1, \dots, x_n; \theta) \Big|_{\theta=\hat{\theta}} < 0$$

Pasos a Seguir

Paso 1 Obtener la función de verosimilitud L a partir de la función de probabilidad o de densidad según la variable aleatoria que nos definan sea discreta o continua.

Paso 2 Se toma Logaritmos neperianos en la función de verosimilitud.

3. MÉTODO DE LOS MOMENTOS PARA LA OBTENCIÓN DE ESTIMADORES PUNTUALES

Paso 3 Se obtiene la primera derivada respecto al parámetro en la función logaritmo.

Paso 4 Igualamos a 0 la primera derivada y despejamos el parámetro para obtener el estimador buscado.

Paso 5 Comprobamos si el estimador obtenido es un máximo y para ello tenemos que calcular la derivada parcial segunda respecto al parámetro en la función logaritmo de la función L de verosimilitud.

Paso 6 En esta segunda derivada sustituimos el parámetro por el estimador obtenido y si el valor que se obtiene es menor que cero, diremos que se trata de un máximo y en consecuencia el estimador obtenido será un buen estimador. Si por el contrario, la segunda derivada es mayor que cero, el estimador obtenido no sería de máxima verosimilitud.

3. Método de los Momentos para la Obtención de Estimadores Puntuales

Introducido por Pearson es el método general más antiguo y sencillo para la obtención de estimadores de parámetros poblacionales. Si una variable aleatoria tiene una distribución que depende de uno o varios parámetros, entonces los momentos de la variable también son función de ellos.

Consiste en igualar tantos momentos muestrales como parámetros hay que estimar a los correspondientes momentos poblacionales, que son funciones de los parámetros desconocidos y resolviendo el sistema de ecuaciones resultante, tendríamos los estimadores de los parámetros. Es decir, consiste en igualar los momentos poblacionales a los momentos muestrales.

Igualando los momentos de orden 1 tendremos

$$E[X] = \mu = \bar{x} \quad \hat{\mu} = \bar{x}$$

Que nos dice que el estimador de la esperanza o media poblacional es la media muestral.

También podemos escribir que en la distribución de Poisson:

$$E[X] = \lambda = \bar{x} \quad \hat{\lambda} = \bar{x}$$

Para los momentos de orden 2. Sabemos que $Var[X] = E[X^2] - E[X]^2$

$$E[X^2] = \frac{1}{n} \times \sum_{i=1}^n X_i^2$$

Entonces

$$\begin{aligned} \sigma^2 &= \frac{1}{n} \times \sum_{i=1}^n X_i^2 - \mu^2 \\ \Rightarrow \\ \frac{1}{n} \times \sum_{i=1}^n X_i^2 &= \sigma^2 + \mu^2 \end{aligned}$$

También podemos escribir que

$$\underbrace{\frac{1}{n} \times \sum_{i=1}^n X_i^2}_{S_n^2} = \sigma^2$$

De donde

$$\hat{\theta}^2 = S_n^2$$

Que nos dice que el estimador de la varianza poblacional es la varianza muestral. La obtención de los estimadores de los parámetros de una distribución normal por el método de los momentos es inmediata. En efecto, el sistema de dos ecuaciones con dos incógnitas nos quedará.

$$\begin{array}{rcl} & \mathcal{N}(\mu, \sigma^2) & \\ E[X] = \mu = \bar{x} & \rightarrow & \hat{\mu} = \bar{x} \\ Var[X] = \sigma^2 = S_n^2 & \rightarrow & \hat{\sigma}^2 = S_n^2 \end{array}$$

Los estimadores obtenidos por el método de los momentos son insesgados y consistentes.

4. Relación Entre los Métodos de Máxima Verosimilitud y de los Momentos

Los estimadores proporcionados por ambos métodos son en ocasiones coincidentes. Cabe especular si este hecho es circunstancial o si por el contrario existen determinadas condiciones bajo las cuales ambos métodos coinciden. Para las distribuciones en la que la derivada parcial del logaritmo de la función de densidad

$$\frac{\partial}{\partial \theta} \ln L(x_1, \dots, x_n; \theta)$$

Sea una función polinómica en X, los métodos de máxima verosimilitud y de los momentos coinciden.

5. Propiedades Deseables para un Estimador Paramétrico

A continuación vamos a estudiar una serie de propiedades que se desea que posean los estimadores. Un estimador puede cumplir alguna de ellas, todas o ninguna. Se entiende que un estimador es tanto mejor cuantas más propiedades verifique. En todo caso, se pretende que la estimación que de un parámetro, se realice utilizando un determinado estimador, esté lo más cerca posible del verdadero valor del parámetro.

Digamos que la letra θ es un parámetro poblacional cualquiera y con $\hat{\theta}$ al estimador de dicho parámetro.

5.1. Estimadores Insesgados

Se dice que un estimador $\hat{\theta}$ es insesgado (centrado) del parámetro θ , si su valor esperado o esperanza coincide con el valor del parámetro a estudiar:

$$E[\hat{\theta}] = \theta$$

En caso contrario, diremos que $\hat{\theta}$ es sesgado.

Sesgo de un Estimador

Se llama así a la diferencia que existe entre el valor esperado del estimador que se utiliza para ello el parámetro que se está estimando

$$\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

5.2. Eficiencia de un Estimador. Cota de Frechet - Kramer - Rao

Diremos que un estimador $\hat{\theta}$ del parámetro poblacional θ , es eficiente si es insesgado y además su varianza alcanza la cota de Frechet - Kramer - Rao. Esto es equivalente a decir que un estimador $\hat{\theta}$ es eficiente si su varianza coincide con la cota de F-K-R.

$$\text{Var}[\hat{\theta}] = \frac{1}{n \times E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right]}$$

En la práctica pueden obtenerse diferentes estimadores insesgados de un parámetro. Debemos encontrar un método que nos permite elegir entre ellos. Es preferible el estimador cuya distribución esté más centrada alrededor del parámetro que se está estimando. Ya que si $\hat{\theta}$ es insesgado

$$\begin{aligned} \text{Var}[\hat{\theta}] &= E \left[\left(\hat{\theta} - E[\hat{\theta}] \right)^2 \right] \\ &= E \left[(\hat{\theta} - \theta)^2 \right] \end{aligned}$$

Usaremos la varianza como medida de difusión. Resumiendo, diremos que un estimador $\hat{\theta}$, del parámetro poblacional θ es eficiente, si es insesgado y además su varianza alcanza la cota de F-K-R

$$\text{Var}[\hat{\theta}] = \frac{1}{n \times E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right]}$$

5.3. Estimadores Consistentes

Sean $\hat{\theta}_1, \dots, \hat{\theta}_n$ una sucesión de estimadores del parámetro θ , obtenidos a partir de muestras de tamaño $1, 2, \dots, n$ respectivamente, es decir:

$$\begin{aligned} \hat{\theta}_1 &= g(X_1) \\ \hat{\theta}_2 &= g(X_1, X_2) \\ &\dots \\ \hat{\theta}_n &= g(X_1, \dots, X_n) \end{aligned}$$

De manera que el estimador basado en la muestra de tamaño n , lo denotaremos por $\hat{\theta}_n$ en donde el subíndice n lo empleamos para hacer más evidente la dependencia del tamaño muestral.

Parece lógico pensar que un estimador será tanto mejor cuanto mayor sea el tamaño de la muestra. Así pues, cuando el tamaño de la muestra aumente y por tanto la información que nos proporciona es muestra es más completa, resulta que la varianza de estimador suele ser menor y la distribución muestral de eses estimador tenderá a encontrarse más concentrada alrededor del parámetro que pretendemos estimar. Además resulta que cuando el tamaño de la muestra es suficientemente grande, entonces la muestra puede llegar a proporcionar una información casi exacta de la población y en consecuencia el valor del estimador tiene a coincidir con el valor del parámetro. El error de estimación viene dado por $|\hat{\theta} - \theta|$. Diremos que un estimador es consistente si la probabilidad de cometer errores de estimación tiende a ser despreciable cuando el tamaño de la muestra aumenta considerablemente, es decir:

$$\lim_{n \rightarrow +\infty} P \left[|\hat{\theta}_n - \theta| > \varepsilon \right] = 0 \quad \forall \varepsilon > 0$$

$$\lim_{n \rightarrow +\infty} P \left[|\hat{\theta}_n - \theta| < \varepsilon \right] = 1 \quad \forall \varepsilon > 0$$

Bajo determinadas condiciones, los estimadores de máximo verosimilitud y los estimadores obtenidos por el método de los momentos son consistentes.

Si $E[\hat{\theta}_n] = \theta$ la desigualdad de Tchebychev dice que

$$P \left[|\hat{\theta}_n - \theta| > \varepsilon \right] \leq \frac{Var[\hat{\theta}_n]}{\varepsilon^2}$$

Por tanto, cuando $\hat{\theta}_n$ sea insesgado, $\hat{\theta}_n$ será consistente si

$$\lim_{n \rightarrow +\infty} Var[\hat{\theta}_n] = 0$$

5.4. Estimadores Suficientes

Un estimador es suficiente cuando no pierde ninguna información que contiene la muestra. Para comprobar que un estimador es suficiente, basta con demostrar que la función de verosimilitud puede factorizarse como:

$$L(x_1, \dots, x_n; \theta) = h(x_1, \dots, x_n) \times g(\hat{\theta}; \theta)$$

Que es el Teorema de Factorización de Neyman.

Se sabe que sólo las distribuciones de probabilidad que pertenece a un tipo especial conocido bajo el nombre de familia exponencial admiten estimadores suficientes. Todo estimador eficiente es también suficiente.

6. Error Cuadrático Medio del Estimador $\hat{\theta}$

Definimos el error cuadrático medio del estimado $\hat{\theta}$, que lo notaremos por $ECM(\hat{\theta})$ como el valor esperado del cuadrado de la diferencia entre el estimador

$\hat{\theta}$ y el parámetro poblacional θ , es decir,

$$\begin{aligned} ECM(\hat{\theta}) &= E[(\hat{\theta} - \theta)^2] \\ &= E[\hat{\theta} - \theta]^2 \end{aligned}$$

Demostración

$$\begin{aligned} ECM(\hat{\theta}) &= E[(\hat{\theta} - \theta)^2] \\ &= E[\hat{\theta}^2 - 2 \times \hat{\theta} \times \theta + \theta^2] \\ &= E[\hat{\theta}^2] - E[2 \times \hat{\theta} \times \theta] + E[\theta^2] \\ &= E[\hat{\theta}^2] - 2 \times \theta \times E[\hat{\theta}] + \theta^2 \end{aligned}$$

Se suma y resta $E[\hat{\theta}]^2$, quedará:

$$\begin{aligned} &E[\hat{\theta}^2] - E[\hat{\theta}]^2 + E[\hat{\theta}]^2 - 2 \times \theta \times E[\hat{\theta}] + \theta^2 \\ = &\underbrace{E[\hat{\theta}^2] - E[\hat{\theta}]^2}_{Var[\hat{\theta}]} + E[\hat{\theta}]^2 - 2 \times \theta \times E[\hat{\theta}] + \theta^2 \\ = &Var[\hat{\theta}] + \left(\underbrace{E[\hat{\theta}] - \theta}_{sesgo[\hat{\theta}]} \right)^2 \\ = &Var[\hat{\theta}] + (sesgo[\hat{\theta}])^2 \end{aligned}$$

Resultando que ECM del estimador $\hat{\theta}$ se puede descomponer en suma de dos cantidades no negativas: La varianza del estimador:

$$Var[\hat{\theta}] = E[\hat{\theta}^2] - (E[\hat{\theta}])^2$$

El cuadrado del sesgo del estimador

$$(Sesgo[\hat{\theta}])^2 = (E[\hat{\theta}] - \theta)^2$$

Evidentemente, ambas cantidades deberán ser tenidas en cuenta para las propiedades deseables de un estimador. Así pues, ambos sumandos, varianza y sesgo, debe ser lo más pequeños posibles lo cual equivale a que la distribución del estimador $\hat{\theta}$ debe de concentrarse en torno al valor del parámetro θ . La utilización del error cuadrático medio para la elección de un buen estimador es insuficiente, siendo necesario dar otros criterios, de tal manera que la elección de un buen estimador puntual, dependerá de otras propiedades que satisfaga ese estimador.

CAPÍTULO 23

Estimación de Parámetros Mediante Intervalos de Confianza

En este tema vamos a obtener intervalos de confianza para parámetros poblacionales desconocidos a partir de muestras procedentes de las variables aleatorias estudiadas.

1. Introducción

Los parámetros de la población se desconocen generalmente, siendo uno de los primordiales principios de la Estadística el estimarlos. El método o estadístico empleado para ello se denomina estimador del parámetro poblacional.

Hablamos de estimación por intervalos de confianza cuando asignamos al parámetro un intervalo de valores.

$$P[\theta \in [a, b]] = 1 - \alpha$$

La probabilidad de que el parámetro de la población se encuentre en un cierto intervalo se denomina nivel de confianza y se representa por $1-\alpha$ (habitualmente es 0.95 ó 95%). El valor α es el margen de error que se permite en cada estimación (habitualmente, 0.05 ó el 5%).

2. Funciones de Decisión e Intervalos de Confianza

Vamos a construir intervalos de confianza para los parámetros poblacionales desconocidos a partir de los estadísticos muestrales.

Llamamos función de decisión al estadístico muestral que utilizaremos para obtener el intervalo de confianza del parámetro desconocido, que han

3. CONSTRUCCIÓN DE UN INTERVALO DE CONFIANZA

sido obtenidos a partir de las distribuciones de los estadísticos muestrales ya estudiadas.

La probabilidad de que el parámetro de la población se encuentre en un cierto intervalo se denomina nivel de confianza y se representa por $1-\alpha$. El valor α es el margen de error que se permite en cada estimación.

Podemos hablar de intervalos de confianza bilaterales y unilaterales:

- Bilaterales: Especifican tanto un límite superior como inferior para el parámetro desconocido:

$$P[\omega_1 < \theta < \omega_2] = 1 - \alpha$$

- Unilaterales: Especifican una única cota, superior o inferior:

- Superior:

$$P[\theta < \omega_2] = 1 - \alpha$$

- Inferior:

$$P[\omega_1 < \theta] = 1 - \alpha$$

3. Construcción de un Intervalo de Confianza

Para construir un intervalo de confianza bilateral para un parámetro desconocido de una variable aleatoria X que sigue una conocida distribución de probabilidad, seguimos los siguientes pasos:

1. Elegir el parámetro θ desconocido de la distribución de probabilidad de la variable aleatoria X al que le vamos a obtener su intervalo de confianza.
2. Elegir la Función de Decisión (h) adecuada al parámetro desconocido y a la situación del resto de parámetros, que sigue una determinada (H) distribución de probabilidad ($h \sim H$).
3. La probabilidad de que el estadístico muestral varíe entre los percentiles $\frac{\alpha}{2}$ y $1 - \frac{\alpha}{2}$ de su distribución de probabilidad coincide con el nivel de confianza $1 - \alpha$.

$$P\left[H_{\frac{\alpha}{2}} < h < H_{1-\frac{\alpha}{2}}\right] = 1 - \alpha$$

4. Despejamos el parametro desconocido θ dentro de la probabilidad y obtenemos el intervalo confianza bilateral para el parametro desconocido θ . Si pretendemos construir un intervalo de confianza unilateral, seguimos los mismos pasos, teniendo en cuenta que en el paso 3:

- Para cota superior: $P[h < H_{1-\alpha}] = 1 - \alpha$
- Para cota inferior: $P[H_{\alpha} < h] = 1 - \alpha$

3.1. Intervalo de confianza para la media de una distribución normal

Cuando la varianza poblacional es conocida

Sea X una variable aleatoria con distribución de parámetros $\text{Normal}(\mu, \sigma^2)$ donde el parámetro μ es desconocido y la varianza poblacional es conocida. Se desea construir un intervalo de confianza para el parámetro μ a un nivel de confianza de $1 - \alpha$.

La construcción de un intervalo se hace en base al mejor estimador de μ que es la media muestral.

Para ello tomamos una muestra aleatoria de tamaño n ($X_1, \dots, X_n$) y buscamos un estadístico que dependa del parámetro μ y de su estimador.

En este caso el estadístico será $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$

Los pasos a seguir son:

1. El parametro elegido es la media poblacional μ .
2. La función de decisión es:

$$z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

3.

$$\begin{aligned} 1 - \alpha &= P \left[z_{\frac{\alpha}{2}} < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < z_{1 - \frac{\alpha}{2}} \right] \\ &= P \left[z_{\frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{1 - \frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} \right] \\ &= P \left[z_{\frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} - \bar{X} < -\mu < z_{1 - \frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} - \bar{X} \right] \\ &= P \left[\bar{X} - z_{1 - \frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} - z_{\frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} \right] \end{aligned}$$

4. Por tanto, el intervalo de confianza bilateral para μ con un nivel de confianza $1 - \alpha$ es:

$$\mu \in \left(\bar{X} - z_{1 - \frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}}, \bar{X} - z_{\frac{\alpha}{2}} \times \frac{\sigma}{\sqrt{n}} \right)$$

con nivel de confianza $1 - \alpha$ que simplificando debido a la simetria en cero de la distribución $\mathcal{N}(0, 1)$:

$$\bar{X} \pm |z_{\frac{\alpha}{2}}| \frac{\sigma}{\sqrt{n}}$$

donde $z_{\frac{\alpha}{2}}$ es aquel valor que en la distribución $\mathcal{N}(0, 1)$ deja por debajo una probabilidad $\frac{\alpha}{2}$.

3. CONSTRUCCIÓN DE UN INTERVALO DE CONFIANZA

5. Definimos el radio del intervalo de confianza como:

$$r = |z_{\frac{\alpha}{2}}| \frac{\sigma}{\sqrt{n}}$$

y constituye una cota del error de estimador puntual, ya que

$$P[|\bar{X} - \mu| < r] = 1 - \alpha$$

Si queremos fijar la cota de error de estimación, con un nivel de confianza también fijo, podemos calcular el tamaño muestral necesario, despejándolo en la expresión del radio del intervalo:

$$n = \left(\frac{z_{\frac{\alpha}{2}} \sigma}{r} \right)^2$$

6. Análogamente, construimos los intervalos unilaterales:

■ Unilateral Superior

$$\mu \leq \bar{X} - z_{\alpha} \frac{\sigma}{\sqrt{n}}$$

con nivel de confianza $1 - \alpha$

■ Unilateral Inferior

$$\mu \geq \bar{X} - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}$$

con nivel de confianza $1 - \alpha$

Ejemplo 23.1 Sea X una variable aleatoria con distribución $\mathcal{N}(\mu, 3^2)$. Buscamos un intervalo de confianza al nivel de confianza del 95 % para el parámetro μ desconocido.

Tomamos una muestra de valores de la variable aleatoria de tamaño 100, de donde se obtiene una media muestral $\bar{x}$ igual a 5. Entonces, el intervalo de confianza para la media al nivel de confianza del 95 % es:

$$\mu \in \left(5 \pm 1,96 \frac{3}{\sqrt{100}} \right)$$

es decir, la verdadera media poblacional va a estar en este intervalo con probabilidad 0.95. El radio del intervalo de confianza es:

$$r = 1,96 \frac{3}{\sqrt{100}}$$

El tamaño muestral necesario para que el error de estimación no supere 0.5 con nivel de confianza 0.95 es:

$$\begin{aligned} n &= \left(1,96 \frac{3}{0.5} \right)^2 \\ &= 138,30 = 139 \end{aligned}$$

Observación 23.1 ■ Cuanto mayor es el nivel de confianza, más ancho es el intervalo de confianza y, por tanto, mayor es la cota de error r .

CAPÍTULO 23. ESTIMACIÓN DE PARÁMETROS MEDIANTE INTERVALOS DE CONFIANZA

- Si aumenta el tamaño de la muestra n , disminuye la cota de error.
- En todos los intervalos de confianza podemos definir el radio del intervalo de confianza y calcular el tamaño muestral necesario para obtener una cota de error determinada con nivel de confianza dado, de manera análoga a la vista en este caso. Habitualmente, lo haremos en los casos en los que la distribución de probabilidad del estadístico sea simétrica, ya que en caso contrario se complica
- En todos los casos podemos definir los intervalos de confianza unilaterales.

Cuando la varianza poblacional es desconocida

Supongamos una población $\mathcal{N}(\mu; \sigma^2)$ en donde μ y σ^2 son desconocidos y se desea obtener un intervalo de confianza para el parámetro μ a un nivel de confianza de $1 - \alpha$.

Para ello se dispone de una muestra aleatoria de tamaño n ($X_1, \dots, X_n$), buscaremos un estadístico que dependa del parámetro μ y de su estimador y en cuya distribución no aparezca σ^2 .

Este estadístico será:

$$\begin{aligned} t &= \frac{\bar{X} - \mu}{\frac{S_n}{\sqrt{n-1}}} \\ &= \frac{\bar{X} - \mu}{\frac{S_{n-1}}{\sqrt{n-1}}} \sim t_{n-1} \end{aligned}$$

que se distribuye según una t-Student con $n-1$ grados de libertad, siendo S_n^2 la varianza muestral y S_{n-1}^2 la cuasivarianza muestral.

Utilizaremos las tablas de la distribución t-Student, pudiendo encontrar parejas de valores tales t_1 y t_2 que:

$$\begin{aligned} P \left[t_1 \leq \frac{\bar{X} - \mu}{\frac{S_n}{\sqrt{n-1}}} \leq t_2 \right] &= 1 - \alpha \\ & \text{o} \\ P \left[t_1 \leq \frac{\bar{X} - \mu}{\frac{S_{n-1}}{\sqrt{n-1}}} \leq t_2 \right] &= 1 - \alpha \end{aligned}$$

quitándonos el denominador y multiplicamos por los dos terminos de la desigualdad se obtiene:

$$P \left[t_1 \times \frac{S_n}{\sqrt{n-1}} \leq \bar{X} - \mu \leq t_2 \times \frac{S_n}{\sqrt{n-1}} \right] = 1 - \alpha$$

restando $\bar{X}$ a los dos extremos de la desigualdad nos quedaría:

$$P \left[t_1 \times \frac{S_n}{\sqrt{n-1}} - \bar{X} \leq -\mu \leq t_2 \times \frac{S_n}{\sqrt{n-1}} - \bar{X} \right] = 1 - \alpha$$

Multiplicamos por -1 e invertimos los terminos de la desigualdad

$$P \left[\bar{X} - t_2 \times \frac{S_n}{\sqrt{n-1}} \leq \mu \leq \bar{X} - t_1 \times \frac{S_n}{\sqrt{n-1}} \right] = 1 - \alpha$$

3. CONSTRUCCIÓN DE UN INTERVALO DE CONFIANZA

Obteniendo el siguiente intervalo:

$$\left[\bar{X} - t_2 \times \frac{S_n}{\sqrt{n-1}}; \bar{X} - t_1 \times \frac{S_n}{\sqrt{n-1}} \right]$$

También se puede reescribir como

$$\left[\bar{X} - t_2 \times \frac{S_{n-1}}{\sqrt{n}}; \bar{X} - t_1 \times \frac{S_{n-1}}{\sqrt{n}} \right]$$

ya que se sabe la relación

$$\frac{S_n}{\sqrt{n-1}} = \frac{S_{n-1}}{\sqrt{n}}$$

3.2. Intervalos de confianza para la proporción

Supongamos una población binomial de parámetros $B(1; p)$ y una muestra aleatoria de tamaño n , suficientemente grande, es decir, se realiza un número grande de repeticiones independientes del experimento de Bernoulli que se está considerando y se quiere obtener un intervalo de confianza de $1 - \alpha$ para el parámetro p .

El estimador de máxima verosimilitud del parámetro p viene dado por:

$$\begin{aligned} \hat{p} &= \frac{\text{numero de éxitos en } n \text{ pruebas}}{\text{número de pruebas}} \\ &= \frac{x}{n} \end{aligned}$$

como

$$\begin{aligned} E[\hat{p}] &= E\left[\frac{x}{n}\right] = \frac{1}{n} E[x] \\ &= \frac{n \times p}{n} = p \\ \text{Var}[\hat{p}] &= \text{Var}\left[\frac{x}{n}\right] = \frac{1}{n^2} \text{Var}[x] \\ &= \frac{n \times p \times q}{n^2} = \frac{p \times q}{n} \\ &= \frac{p \times (1-p)}{n} \end{aligned}$$

Entonces

$$\begin{aligned} \hat{p} &\sim \mathcal{N}\left(p, \frac{p \times (1-p)}{n}\right) \\ &\sim \mathcal{N}\left(\hat{p}, \frac{\hat{p} \times (1-\hat{p})}{n}\right) \end{aligned}$$

Lo cual, permite decir que el estadístico

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{\hat{p} \times (1-\hat{p})}{n}}} \sim \mathcal{N}(0, 1)$$

cuando n es suficientemente grande

Luego, el intervalo de confianza buscado sería

$$P \left[z_{\frac{\alpha}{2}} \leq \frac{\hat{p} - p}{\sqrt{\frac{\hat{p} \times (1 - \hat{p})}{n}}} \leq z_{1 - \frac{\alpha}{2}} \right] = 1 - \alpha$$

Multiplicamos cada termino de la desigualdad por el denominador del estadístico y restamos despues cada termino $\hat{p}$, multiplicamos por -1 e invertimos la desigualdad y nos quedará

$$P \left[\hat{p} - z_{1 - \frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq p \leq \hat{p} - z_{\frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right] = 1 - \alpha$$

Es decir, el intervalo de confianza para el parámetro p será:

$$\left[\hat{p} - z_{1 - \frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}; \hat{p} - z_{\frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$

Donde

Centro: $\hat{p}$

Radio: $r = z_{1 - \frac{\alpha}{2}} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$

Intervalo: $[\hat{p} - r; \hat{p} + r]$

4. Intervalo de confianza para la diferencia de medias de dos poblaciones normales

4.1. Se conocen las varianzas

Dados dos muestras $X_1, \dots, X_n$ y $Y_1, \dots, Y_m$ independientes de sendas poblaciones normales con medias μ_X y μ_Y cuyas varianzas σ_X^2 y σ_Y^2 son conocidas.

Los estadísticos muestrales correspondientes son:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{Y} = \frac{1}{m} \sum_{j=1}^m Y_j$$

Luego:

$$\bar{X} - \bar{Y} \sim \mathcal{N} \left(\mu_X - \mu_Y; \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m} \right)$$

El estadístico que depende de los parámetros μ_X y μ_Y y sus estimadores será:

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim \mathcal{N}(0, 1)$$

4. INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS DE DOS POBLACIONES NORMALES

Una vez fijada la probabilidad $1 - \alpha$ establecemos que:

$$P[-z_0 < z < z_0] = 1 - \alpha$$

Si se quiere construir un intervalo para $\mu_X - \mu_Y$ es tendrá que realizar las operaciones necesarias para que $\mu_X - \mu_Y$ quede en la parte central de la desigualdad

$$P \left[z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \leq (\bar{X} - \bar{Y}) - (\mu_X - \mu_Y) \leq z_{1-\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right] = 1 - \alpha$$

Restando $\bar{X} - \bar{Y}$ y multiplicamos por -1 e invirtiendo los terminos

$$P \left[(\bar{X} - \bar{Y}) - z_{1-\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \leq (\mu_X - \mu_Y) \leq (\bar{X} - \bar{Y}) + z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right] = 1 - \alpha$$

Luego el intervalo será:

$$\left[(\bar{X} - \bar{Y}) - z_{1-\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}; (\bar{X} - \bar{Y}) + z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right]$$

Donde

Centro: $\bar{X} - \bar{Y}$

Radio: Que es la cota o límite para el error

$$r = z_{\frac{\alpha}{2}} \times \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$$

4.2. Varianzas poblacionales desconocidas pero iguales $\sigma_1^2 = \sigma_2^2$

Considerando, como en el caso 4.1, una muestra de tamaño n procedente de una población $\mathcal{N}(\mu_1, \sigma_2^2)$ y otra muestra de tamaño m , independiente a la anterior, procedente de otra población normal $\mathcal{N}(\mu_2, \sigma_2^2)$ siendo $\bar{X}$ y $\bar{Y}$ las respectivas medias muestrales.

Se desconocen σ_1^2 y σ_2^2 , entonces no se puede utilizar la distribución dada en el apartado 4.1 y se tendrá que buscar otra distribución donde no aparezcan las varianzas poblacionales.

En el caso de la media muestral, este problema se resuelve buscando una t-Student, ahora se va a seguir un procedimiento parecido.

Si se tiene que

$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad S_2^2 = \frac{1}{m-1} \sum_{j=1}^m (Y_j - \bar{Y})^2$$

entonces

$$S_c = \sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}$$

Entonces la variable

$$t = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_c \sqrt{\frac{m+n}{n \times m}}}$$

tiene una distribución t-Student con $n + m - 2$ grados de libertad.

Si t_1 es el cuantil $\frac{\alpha}{2}$ y t_2 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución t-Student con $n+m-2$ grados de libertad, entonces se verifica que

$$P \left[t_1 \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_c \sqrt{\frac{m+n}{n \times m}}} \leq t_2 \right] = 1 - \alpha \quad (23.1)$$

Si en el suceso expresado en la desigualdad 23.1 multiplicamos por

$$S_c \sqrt{\frac{m+n}{n \times m}}$$

restamos la diferencia de medias muestrales

$$\bar{X} - \bar{Y}$$

y multiplicamos por -1 en todos sus miembros, queda un suceso equivalente y por tanto con la misma probabilidad

$$P \left[(\bar{X} - \bar{Y}) - t_2 S_c \sqrt{\frac{m+n}{n \times m}} \leq \mu_1 - \mu_2 \leq (\bar{X} - \bar{Y}) - t_1 S_c \sqrt{\frac{m+n}{n \times m}} \right] = 1 - \alpha$$

Donde

Centro: $\bar{X} - \bar{Y}$

Radio: Que es la cota o límite para el error

$$r = t_2 S_c \sqrt{\frac{m+n}{n \times m}} \quad (23.2)$$

Si se supone el tamaño de ambas muestras es igual a n entonces de la expresión 23.2 puede obtenerse el tamaño de ambas muestras, necesario para alcanzar una determinada cota de error con nivel de confianza dado:

$$n = 2 \left(\frac{t_2 \times S_c}{r} \right)^2$$

Para encontrar el valor de n se necesita conocer el cuantil t_2 , que depende de n pues t_2 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución de t-Student con $2n - 2$ grados de libertad, con lo cual la resolución de 23.3 para encontrar el tamaño muestral sólo es posible utilizando métodos de análisis numérico. Sin embargo, se puede llegar a una solución satisfactoria: Si se supone un tamaño muestral mayor a 30, puesto que la distribución t-Student se aproxima mediante la normal $\mathcal{N}(0, 1)$, podemos sustituir den 23.3 el cuantil t_2 por su aproximación normal Z_0 y obtener la solución:

$$n = 2 \left(\frac{Z_0 \times S_c}{r} \right)^2$$

4. INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS DE DOS POBLACIONES NORMALES

4.3. Varianzas poblacionales desconocidas y desiguales (Aproximación de Welch)

En este caso utilizaremos la variable

$$t = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$$

cuya distribución no es exactamente t-Student, aunque puede ser una aproximación satisfactoria si los grados de libertad se calculan mediante la expresión siguiente debida a Welch

$$\nu = \frac{\left(\frac{\theta}{n} + \frac{1}{m}\right)}{\frac{\theta^2}{n^2(n-1)} + \frac{1}{m^2(m-1)}}$$

donde θ representa el cociente entre las varianzas poblacionales

$$\theta = \frac{\sigma_1^2}{\sigma_2^2}$$

Este valor, habitualmente es desconocido. Si tenemos razones para sospechar que las varianzas poblacionales son diferentes es porque las dispersiones muestrales así lo indican. Siempre se tiene la posibilidad de calcular una cota superior de confianza para θ y utilizarla como valor más desfavorable.

Es decir, aquel θ (dentro del intervalo unilateral calculado para la razón de varianzas) para el cual la correspondiente aproximación de ν proporciona un intervalo más amplio para la diferencia de medias. Si no se desea exceder de precavido se puede utilizar como el valor θ el cociente de las varianzas muestrales.

Si t_2 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución t-Student con ν grados de libertad, entonces se verifica que:

$$P \left[t_1 \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}} \leq t_2 \right] = 1 - \alpha \quad (23.3)$$

si en el suceso expresado en la desigualdad de 23.3 multiplicamos por

$$\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}$$

restamos la diferencia de medias muestrales

$$\bar{X} - \bar{Y}$$

y multiplicamos por -1 en todos sus miembros, queda un suceso equivalente y por tanto con la misma probabilidad

$$P \left[(\bar{X} - \bar{Y}) - t_2 \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}} \leq (\mu_1 - \mu_2) \leq (\bar{X} - \bar{Y}) - t_1 \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}} \right] = 1 - \alpha$$

Donde

Centro: $\bar{X} - \bar{Y}$

Radio: Que es la cota o límite para el error

$$r = t_2 \sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}$$

el tamaño de ambas muestras asociado con un error r y un nivel de confianza $1 - \alpha$ para el estimador puntual es

$$n = \left(\frac{Z_0}{r} \right)^2 (S_1^2 + S_2^2)$$

donde Z_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución $\mathcal{N}(0, 1)$ y será necesario disponer de muestras previas para calcular las varianzas muestrales S_1^2 y S_2^2

5. Intervalo de confianza para la diferencia de proporciones

Se está interesado en estimar la diferencia entre dos parámetros poblacionales p_1 y p_2 , es decir, se quiere calcular el intervalo de confianza para la diferencia $p_1 - p_2$ de dos parámetros poblacionales.

Para ello se selecciona una muestra de tamaño n (suficientemente grande) procedente de una población binomial $\mathcal{B}(1, p_1)$ y otra muestra de tamaño m (suficientemente grande) independiente de la anterior procedente de una población binomial $\mathcal{B}(1, p_2)$

Se sabe que

$$\hat{p} \rightarrow \mathcal{N}\left(p, \frac{pq}{n}\right) \rightarrow \mathcal{N}\left(\hat{p}, \frac{\hat{p}\hat{q}}{n}\right)$$

por lo tanto tendremos que

$$\begin{aligned} \hat{p}_1 &\rightarrow \mathcal{N}\left(\hat{p}_1, \frac{\hat{p}_1\hat{q}_1}{n}\right) & \text{donde } \hat{q}_1 &= 1 - \hat{p}_1 \\ \hat{p}_2 &\rightarrow \mathcal{N}\left(\hat{p}_2, \frac{\hat{p}_2\hat{q}_2}{m}\right) & \text{donde } \hat{q}_2 &= 1 - \hat{p}_2 \end{aligned}$$

Por tanto, obteniendo la diferencia y tipificando se obtiene

$$\hat{p}_1 - \hat{p}_2 \rightarrow \mathcal{N}\left(\hat{p}_1 - \hat{p}_2, \frac{\hat{p}_1\hat{q}_1}{n} + \frac{\hat{p}_2\hat{q}_2}{m}\right)$$

Por tanto la variable aleatoria es:

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}}$$

tiene una distribución aproximadamente $\mathcal{N}(0, 1)$.

6. INTERVALO DE CONFIANZA PARA LA VARIANZA DE UNA POBLACIÓN NORMAL

Si Z_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución normal de media cero y varianza uno, entonces se verifica que:

$$P \left[-Z_0 \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}} < Z_0 \right] = 1 - \alpha \quad (23.4)$$

Si en el suceso expresado en la desigualdad de 23.4 multiplicamos por

$$\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}$$

restamos la diferencia de proporciones muestrales $(\hat{p}_1 - \hat{p}_2)$ y multiplicamos por -1 queda

$$P \left[(\hat{p}_1 - \hat{p}_2) - Z_0 \times \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}} < (p_1 - p_2) < (\hat{p}_1 - \hat{p}_2) + Z_0 \times \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}} \right] = 1 - \alpha$$

Donde

Centro: $\hat{p}_1 - \hat{p}_2$

Radio: Que es la cota o límite para el error

$$r = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}$$

Bajo el supuesto de que el tamaño de ambas muestras coinciden, dad una cota de error r y para el nivel de confianza $1 - \alpha$, dicho tamaño se calcula mediante la expresión:

$$n = \left(\frac{Z_0}{r} \right)^2 (\hat{p}_1(1-\hat{p}_1) + \hat{p}_2(1-\hat{p}_2))$$

donde Z_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución $\mathcal{N}(0, 1)$ y será necesario disponer de muestras previas para calcular las varianzas muestrales que son función de $\hat{p}_1$ y $\hat{p}_2$

6. Intervalo de confianza para la varianza de una población normal

Habitualmente interesa más, tener una cota superior de la varianza que un intervalo bilateral. En abstracto se puede justificar la anterior aserción con el siguiente argumento:

La varianza mide el grado de representatividad que la media tiene, de forma que cuanto mayor sea ésta, más dispersa es la población y más alejados tienden a estar los valores poblacionales de su centro (media). Si en una población se

desconoce la varianza puede ser interesante estimar qué cotas son difíciles de sobrepasar.

El control de la varianza puede hacerse mediante un intervalo de confianza unilateral calculado sobre muestras que se toman periódicamente.

6.1. Intervalos unilaterales cuando la media de la población es conocida

Dada una muestra aleatoria simple de tamaño n procedente de una población normal $\mathcal{N}(\mu, \sigma^2)$ se sabe que la variable

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$$

tiene una distribución de χ^2 con n grados de libertad

Cota superior para la varianza cuando la media poblacional es conocida

Si χ_0 representa el cuantil α de tal distribución entonces

$$P \left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} > \chi_0 \right] = 1 - \alpha$$

o equivalentemente

$$P \left[\sigma^2 < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_0} \right] = 1 - \alpha \quad (23.5)$$

El termino derecho de la desigualdad 23.5 es una variable aleatoria que toma valores según la muestra que toque en suerte. Tiene probabilidad $1 - \alpha$ de superar el valor desconocido de la varianza. Este es el grado de certeza de que, extraída una muestra concreta, la varianza se mayor que el valor

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_0}$$

calculado sobre dicha muestra

Cota inferior para la varianza cuando la media poblacional es conocida

De forma análoga, utilizando el cuantil $1 - \alpha$ de la distribución se puede construir una cota inferior para la varianza.

Si χ_1 representa el cuantil $1 - \alpha$ de la distribución dada

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$$

entonces

$$P \left[\chi_1 > \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \right] = 1 - \alpha$$

6. INTERVALO DE CONFIANZA PARA LA VARIANZA DE UNA POBLACIÓN NORMAL

o equivalentemente

$$P \left[\sigma^2 > \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_1} \right] = 1 - \alpha \quad (23.6)$$

El termino derecho de la desigualdad 23.6 es una variable aleatoria que toma valores según la muestra que toque en suerte. Tiene probabilidad $1 - \alpha$ de superar el valor desconocido de la varianza. Este es el grado de certeza de que, extraída una muestra concreta, la varianza se mayor que el valor

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_1}$$

calculado sobre dicha muestra

6.2. Intervalos unilaterales cuando la media de la población es desconocida

Si la media poblacional es desconocida se sabe que, como resultado de sustituir μ por su estimador la media muestral en

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$$

se obtiene la variable

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2}$$

que es una distribución χ^2 con $n-1$ grados de libertad

Cota superior para la varianza cuando la media poblacional es desconocida

Si χ_0 representa el cuantil α de tal distribución entonces

$$P \left[\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} > \chi_0 \right] = 1 - \alpha$$

o equivalentemente

$$P \left[\sigma^2 < \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\chi_0} \right] = 1 - \alpha$$

Por lo tanto el valor obtenido utilizando datos muestrales y del cuantil χ_0

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\chi_0}$$

supone una cota superior para la varianza de la población.

Cota inferior para la varianza cuando la media poblacional es desconocida

Si χ_1 representa el cuantil $1 - \alpha$ de tal distribución entonces

$$P \left[\chi_1 > \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \right] = 1 - \alpha$$

o equivalentemente

$$P \left[\sigma^2 > \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\chi_1} \right] = 1 - \alpha$$

Por lo tanto el valor obtenido utilizando datos muestrales y del cuantil χ_1

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\chi_1}$$

supone una cota superior para la varianza de la población.

6.3. Intervalos de confianza bilaterales

Media poblacional μ conocida

Supongamos una población $\mathcal{N}(\mu, \sigma^2)$ donde μ es conocido y σ^2 es desconocido, se desea obtener un intervalo de confianza para la varianza poblacional σ^2 a un nivel de confianza de $1 - \alpha$.

Para ello tomamos una muestra aleatoria simple de tamaño n ($X_1, \dots, X_n$) y se utiliza un estadístico que dependa del parámetro σ^2 y su estimador y cuya distribución muestral no dependa de σ^2 .

En este caso el estadístico cuya distribución muestral no dependa de σ^2 será

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \rightsquigarrow \chi_n^2$$

que para cada valor fijo de σ^2 sigue una distribución χ^2 de Pearson con n grados de libertad, por al ser la media μ conocida no hay que estimarla y el número de grados de libertad es n

Si χ_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución χ^2 con n grados de libertad y χ_1 es el cuantil $\frac{\alpha}{2}$ de la misma distribución, entonces según:
se tiene que

$$P \left[\chi_1 < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} < \chi_0 \right] = 1 - \alpha$$

Dividimos los dos términos extremos de la desigualdad por el numerador del estadístico

$$P \left[\frac{\chi_1}{\sum_{i=1}^n (X_i - \mu)^2} < \frac{1}{\sigma^2} < \frac{\chi_0}{\sum_{i=1}^n (X_i - \mu)^2} \right] = 1 - \alpha$$

6. INTERVALO DE CONFIANZA PARA LA VARIANZA DE UNA POBLACIÓN NORMAL

Invirtiendo los términos de la desigualdad

$$P \left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_1} > \sigma^2 > \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_0} \right] = 1 - \alpha$$

reordenando esta expresión se tiene

$$P \left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_0} < \sigma^2 < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_1} \right] = 1 - \alpha$$

Luego el intervalo buscado será

$$\left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_0}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_1} \right]$$

Media poblacional μ desconocida

Supongamos una población $\mathcal{N}(\mu, \sigma^2)$ donde μ y σ^2 son desconocidos, se desea obtener un intervalo de confianza para la varianza poblacional σ^2 a un nivel de confianza de $1 - \alpha$.

Para ello tomamos una muestra aleatoria simple de tamaño n ($X_1, \dots, X_n$) y se utiliza un estadístico que dependa del parámetro σ^2 y su estimador y cuya distribución muestral no dependa de σ^2 .

En este caso el estadístico cuya distribución muestral no dependa de σ^2 será

$$\frac{(n-1)S_{n-1}^2}{\sigma^2} \rightsquigarrow \chi_{n-1}^2$$

que se distribuye que para cada valor fijo de σ^2 sigue una distribución χ^2 de Pearson con $n - 1$ grados de libertad

Los estadísticos

$$\frac{nS_n^2}{\sigma^2} \quad \text{y} \quad \frac{(n-1)S_{n-1}^2}{\sigma^2}$$

son iguales

En la distribución χ_{n-1}^2 se puede obtener parejas de valores tales que χ_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución χ^2 con $n - 1$ grados de libertad y χ_1 es el cuantil $\frac{\alpha}{2}$ de la misma distribución. Se puede considerar que el intervalo de confianza del estadístico se obtiene a partir de:

$$P \left[\chi_1 < \frac{(n-1)S_{n-1}^2}{\sigma^2} < \chi_0 \right] = 1 - \alpha$$

Dividimos los dos términos extremos de la desigualdad por el numerador del estadístico

$$P \left[\frac{\chi_1}{(n-1)S_{n-1}^2} < \frac{1}{\sigma^2} < \frac{\chi_0}{(n-1)S_{n-1}^2} \right] = 1 - \alpha$$

Invirtiendo los términos de la desigualdad

$$P \left[\frac{(n-1)S_{n-1}^2}{\chi_1} > \sigma^2 > \frac{(n-1)S_{n-1}^2}{\chi_0} \right] = 1 - \alpha$$

reordenando esta expresión se tiene

$$P \left[\frac{(n-1)S_{n-1}^2}{\chi_0} < \sigma^2 < \frac{(n-1)S_{n-1}^2}{\chi_1} \right] = 1 - \alpha$$

Luego el intervalo buscado será

$$\left[\frac{(n-1)S_{n-1}^2}{\chi_0}, \frac{(n-1)S_{n-1}^2}{\chi_1} \right]$$

7. Intervalo de confianza para la razón de varianzas

En ocasiones, es necesario comparar la varianza de dos poblaciones. La comparación de dos varianzas se hace mediante cociente.

Se considera dos muestras aleatorias de tamaños n y m independientes y procedentes de poblaciones normales $\mathcal{N}(\mu_1, \sigma_1^2)$ y $\mathcal{N}(\mu_2, \sigma_2^2)$ respectivamente con medias y varianzas desconocidas y se pretende obtener un intervalo de confianza para el cociente de varianzas $\frac{\sigma_1^2}{\sigma_2^2}$.

En este caso se puede utilizar un estadístico que dependa de los parámetros desconocidos σ_1^2 y σ_2^2 y de sus estimadores y cuya distribución muestral no dependa de los parámetros, se tendrá

$$F = \frac{S_{n-1}^2}{S_{m-1}^2} \frac{\sigma_2^2}{\sigma_1^2} \rightsquigarrow F_{n-1, m-1}$$

que sigue una distribución F-Snedecor con $n-1$ y $m-1$ grados de libertad.

Utilizando este estadístico F y siendo F_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución F con $n-1$ y $m-1$ grados de libertad y F_1 es el cuantil $\frac{\alpha}{2}$ de la misma distribución.

Por tanto

$$P[F_1 \leq F \leq F_0] = 1 - \alpha$$

$$P \left[F_1 \leq \frac{S_{n-1}^2}{S_{m-1}^2} \frac{\sigma_2^2}{\sigma_1^2} \leq F_0 \right] = 1 - \alpha$$

Multiplicando cada término de la desigualdad por $\frac{S_{m-1}^2}{S_{n-1}^2}$

$$P \left[F_1 \frac{S_{m-1}^2}{S_{n-1}^2} \leq \frac{\sigma_2^2}{\sigma_1^2} \leq F_0 \frac{S_{m-1}^2}{S_{n-1}^2} \right] = 1 - \alpha$$

7. INTERVALO DE CONFIANZA PARA LA RAZÓN DE VARIANZAS

Si invertimos cada termino

$$P \left[\frac{S_{n-1}^2}{S_{m-1}^2} \frac{1}{F_1} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_{n-1}^2}{S_{m-1}^2} \frac{1}{F_0} \right] = 1 - \alpha$$

Luego el intervalo de confianza será

$$\left[\frac{S_{n-1}^2}{S_{m-1}^2} \frac{1}{F_1}, \frac{S_{n-1}^2}{S_{m-1}^2} \frac{1}{F_0} \right]$$

CAPÍTULO 24

Contraste de Hipótesis Paramétricos

Hasta ahora se ha planteado el problema de inferencia de parámetros en una distribución, mediante una aproximación puntual o por intervalos de confianza, obtenidos desde la información disponible de la muestra. Sin embargo, se puede emplear otra forma de razonamiento que consiste en especular previamente sobre los posibles valores que pueda tener un parámetro o varios y posteriormente cotejar el grado de compatibilidad entre el conjunto de valores propuestos y la información muestral obtenida.

En función de la coherencia entre ambos elementos, habrá que decidir mantener válida la hipótesis formulada sobre el parámetro, o por el contrario rechazarla por ser incompatible con lo observado en la muestra.

Por ejemplo, supóngase que se está estudiando el número medio de empleados en las empresas de España. Se puede estimar puntualmente dicha media, también se puede construir un intervalo de confianza, o bien formular la hipótesis que el tamaño medio está comprendido entre 50 y 60 empleados, y decidir mediante la información contenida en una muestra, si dicha hipótesis puede ser cierta o insostenible y rechazarla por falsa. Se puede aspirar a conocer la posibilidad que se tiene de cometer errores tanto en el caso de rechazar como de aceptar la hipótesis.

La parte de inferencia estadística que estudia la resolución de problemas bajo esta perspectiva, recibe el nombre de “Teoría del Contraste” o “Test de Hipótesis”.

1. Formulación de un Contraste

Un contraste de hipótesis es un procedimiento por el cual decimos si una propuesta sobre la población puede aceptarse o no.

1. FORMULACIÓN DE UN CONTRASTE

Sea $X_1, \dots, X_n$ una muestra de tamaño n procedente de una población X con familia de distribución $\{F(x; \theta); \theta \in \Theta\}$ donde θ es un parámetro desconocido y Θ es el espacio paramétrico (Conjunto de valores que puede tomar el parámetro).

Llamaremos hipótesis paramétrica a una afirmación referente al parámetro desconocido θ , que afirma que su verdadero valor se encuentra entre los valores de un subconjunto Θ_0 del espacio paramétrico. Cuando se plantea una hipótesis paramétrica nos referimos a ella como Hipótesis Nula H_0 y se notará:

$$H_0 : \theta \in \Theta_0$$

Es decir, la hipótesis nula consiste en afirmar que el parámetro toma determinados valores del espacio paramétrico.

Llamaremos hipótesis alternativa generalmente a la hipótesis opuesta a la nula:

$$H_1 : \theta \in \Theta_1 = \Theta - \Theta_0$$

Si Θ_0 (ó Θ_1) tiene solamente un punto, se dice que la hipótesis nula (o hipótesis alternativa) es simple; en caso contrario se dice que es compuesta.

La esencia del contraste radica en encontrar una regla que nos permita decidir entre aceptar o rechazar la hipótesis nula, frente la hipótesis alternativa, en base a los datos muestrales. Se trata de dividir el espacio muestrales en dos conjuntos disjuntos C y $\bar{C}$ tal que dada una realización de una muestra $x = (x_1, \dots, x_n)$ si $x \in C$ entonces la decisión es rechazar la hipótesis nula H_0 . Al conjunto C se le llama región crítica.

Podemos cometer dos tipos de errores al tomar la decisión:

- Al error que se comete al rechazar la hipótesis nula H_0 cuando es cierta se le llama error tipo I y notaremos con

$$\alpha = P[\text{Error Tipo I}]$$

También nos referimos a él como nivel de significación

- Al error que se comete al aceptar la hipótesis nula H_0 cuando es falsa se le llama error tipo II y notaremos con

$$\beta = P[\text{Error Tipo II}]$$

Decision		
	Rechazar H_0	Aceptar H_0
Hipótesis cierta H_0	α	Decisión correcta
Hipótesis falsa H_0	Decisión correcta (potencia)	β

Definimos una serie de términos habituales en el lenguaje de los contrastes de hipótesis:

Región de Aceptación: es el intervalo en el que no se rechaza la hipótesis nula

Región Crítica: es el intervalo en el que se rechaza la hipótesis nula

Niveles Críticos de Decisión: Son los extremos del intervalo o región crítica

Función de decisión: es el estadístico que permite resolver el contraste.

Se define función Potencia como la función que asocia cada valor del parámetro con la probabilidad de la región de rechazo, es decir, la probabilidad de rechazar la hipótesis nula con cada valor que se proponga del parámetro:

$$Pot(\theta) = \eta = P[(x_1, \dots, x_n) \in C/\theta]$$

Por tanto, para cualquier valor del parámetro perteneciente a la hipótesis nula $\theta \in \Theta_0$ es la probabilidad de rechazar la hipótesis nula siendo cierta. Mientras que para un valor perteneciente a la hipótesis alternativa es la probabilidad de rechazar la hipótesis nula siendo falsa, es decir:

- Si $\theta \in \Theta_0$ entonces $Pot(\theta) \leq \alpha$
- Si $\theta \in \Omega - \Theta_0$ entonces $Pot(\theta) \leq 1 - \beta$

Lo ideal sería encontrar una región crítica para la cual ambos errores fueran iguales a cero, pero lo que ocurre es que al reducir la probabilidad de un tipo de error, aumenta la probabilidad del otro. El procedimiento que se utiliza en la práctica es limitar la probabilidad del error tipo I y se busca una región crítica que minimice la probabilidad de error tipo II y, por tanto, maximice la potencia.

Los contrastes pueden ser de las siguientes formas:

H_0	H_1	Tipo	Región Aceptación
$\theta = \theta_0$	$\theta = \theta_1$	Unilateral	$(-\infty, \pi)$ si $\theta_0 < \theta_1$ $(\pi, +\infty)$ si $\theta_0 > \theta_1$
$\theta = \theta_0$	$\theta \neq \theta_0$	Bilateral	(π_1, π_2)
$\theta = \theta_0$	$\theta < \theta_0$	Unilateral	$(\pi, +\infty)$
$\theta = \theta_0$	$\theta > \theta_0$	Unilateral	$(-\infty, \pi)$
$\theta \geq \theta_0$	$\theta < \theta_0$	Unilateral	$(\pi, +\infty)$
$\theta \leq \theta_0$	$\theta > \theta_0$	Unilateral	$(-\infty, \pi)$

2. Contraste de hipótesis paramétricos

Una vez vista las distintas funciones de decisión, volvemos al estudio de los contrastes de hipótesis paramétrico, los pasos a seguir son:

1. Obtener la hipótesis nula del problema, que siempre va a contener el signo igual.
2. Se localizan las condiciones del problema para encontrar la función de densidad correspondiente al parámetro contrastado en las condiciones planteadas.

2.1. Contraste de Hipótesis de una Población Normal

Para hacer este contraste en sus diversos aspectos necesitamos las mismas distribuciones del capítulo 21 que fueron utilizadas para la obtención de intervalos de confianza de la media.

Esta situación no es casual, ya que la regla factible para rechazar un determinado valor de la media, propuesto como hipótesis nula, es que dicho valor se encuentra fuera del correspondiente intervalo de confianza. El contraste y los intervalos de confianza son pues, dos cuestiones estrechamente relacionadas

Contraste para la media cuando la varianza es conocida

cuando la varianza de la población se conoce, la variable aleatoria que juega un papel clave es la construcción de la región de rechazo es

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \quad (24.1)$$

cuya distribución, como ya hemos visto en repetidas ocasiones es $\mathcal{N}(0, 1)$

Contraste Bilateral Para este tipo de contraste, se dará la solución uniformemente más potente que proporciona el método del cociente de verosimilitudes. No obstante tendrá una presentación ligeramente diferente al objeto de facilitar el razonamiento para calcular la función de potencia y resaltar algún aspecto interesante referido a los tipos de error que se pueden cometer.

Supongamos que la varianza se conoce y que la distribución de probabilidades puede considerarse aproximadamente normal.

Dada una muestra de tamaño n y dado Z_0 cuantil $1 - \frac{\alpha}{2}$ de la distribución $\mathcal{N}(0, 1)$ se verifica que

$$P(\bar{X} - \mu > Z_0 \frac{\sigma}{\sqrt{n}}) = \frac{\alpha}{2} \quad (24.2)$$

$$P(\bar{X} - \mu < -Z_0 \frac{\sigma}{\sqrt{n}}) = \frac{\alpha}{2} \quad (24.3)$$

$$(24.4)$$

Estos resultados se obtienen trivialmente desde la expresión 24.1.

Imaginad que se desea saber si las notas de los diferentes bootcamp por termino medio es un 10. A la academia no le interesa que haya grandes diferencias. En este caso, lo más correcto es formular un contraste de hipótesis como el siguiente:

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

es decir: Las notas medias de los diferentes bootcamp es una cantidad específica $\mu_0(10)$ contra la hipótesis alternativa que es que la nota no es el especificado.

CAPÍTULO 24. CONTRASTE DE HIPÓTESIS PARAMÉTRICOS

Obsérvese que en este problema, así planteado, los conjuntos Ω y ω son:
 $\Omega = (0, +\infty)$, $\omega = \{\mu_0\}$

Si la hipótesis nula es cierta, entonces las expresiones 24.2 y 24.3 se particularizan a

$$P(\bar{X} - \mu > Z_0 \frac{\sigma}{\sqrt{n}}) = \frac{\alpha}{2} \quad (24.5)$$

$$P(\bar{X} - \mu < -Z_0 \frac{\sigma}{\sqrt{n}}) = \frac{\alpha}{2} \quad (24.6)$$

$$(24.7)$$

La media muestral, como variable aleatoria que debe oscilar alrededor de μ_0 y se aleja más allá de lo que determina 24.5, se ha de pensar:

- Ha salido una muestra de las pocas que verifican este suceso de baja probabilidad $\frac{\alpha}{2}$
- Por el contrario, la media poblacional es un valor mayor que μ_0 y más cercano a la media muestral. En este caso, el suceso observado tiene una probabilidad bastante superior a $\frac{\alpha}{2}$

Si la media muestral es inferior a μ_0 y esto se aleja del tal valor más allá de lo que determina 24.6, se está en una situación similar a la precedente. Ahora decidir que la media poblacional tiene un valor más pequeño μ_0 y por tanto más próximo a la citada media muestral.

Se definirá pues la región de rechazo para este tipo e contraste de la siguiente forma

$$W_\alpha = \left\{ (x_1, \dots, x_n) \left/ \begin{array}{ll} \bar{x} - \mu_0 > z_0 \frac{\sigma}{\sqrt{n}} & \text{si } \bar{x} > \mu_0 \\ \bar{x} - \mu_0 < -z_0 \frac{\sigma}{\sqrt{n}} & \text{si } \bar{x} < \mu_0 \end{array} \right. \right\}$$

Rechazamos la hipótesis nula si y solo si

$$\bar{x} > \mu_0 + z_0 \frac{\sigma}{\sqrt{n}} \quad \text{o bien} \quad \bar{x} < \mu_0 - z_0 \frac{\sigma}{\sqrt{n}}$$

Contraste cola a la derecha Hay ocasiones en la que la propia lógica del problema hay plantear el contraste de la siguiente forma

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu > \mu_0$$

por ejemplo, en una preselección de personal se desea eliminar a todas las personas que por termino medio necesite más tiempo μ_0 para realizar cierta tarea. Interesa detectar aquellos casos en los que la media esté por encima de dicho valor. En este caso, no interesa rechazar la hipótesis nula porque una media muestral es demasiado pequeña y por tanto el tiempo medio del candidato en cuestión, es bastante inferior a μ_0 . En este caso, se rechazará la hipótesis nula cuando:

$$\bar{X} - \mu_0 > Z_0 \frac{\sigma}{\sqrt{n}}$$

donde ahora, Z_0 representa el cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

2. CONTRASTE DE HIPÓTESIS PARAMÉTRICOS

Contraste cola a la izquierda En otras ocasiones en la que la propia lógica del problema hay plantear el contraste de la siguiente forma

$$\begin{aligned}H_0 &: \mu = \mu_0 \\H_1 &: \mu < \mu_0\end{aligned}$$

por ejemplo, en una preselección de personal se desea eliminar a todas las personas que por termino medio necesite menos tiempo μ_0 para realizar cierta tarea. Interesa detectar aquellos casos en los que la media esté por debajo de dicho valor. En este caso, no interesa rechazar la hipótesis nula porque una media muestral es demasiado pequeña y por tanto el tiempo medio del candidato en cuestión, es bastante inferior a μ_0 . En este caso, se rechazará la hipótesis nula cuando:

$$\bar{X} - \mu_0 < -Z_0 \frac{\sigma}{\sqrt{n}}$$

donde ahora, Z_0 representa el cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

Contraste para la media cuando la varianza es desconocida

cuando la varianza de la población se desconoce, para construir la región de rechazo utilizamos la variable

$$t = \frac{\bar{X} - \mu}{\frac{S_{n-1}}{\sqrt{n}}}$$

cuya distribución, como ya hemos visto en repetidas ocasiones es t-Student con n-1 grados de libertad

Contraste Bilateral Para este test se formula las hipótesis

$$\begin{aligned}H_0 &: \mu = \mu_0 \\H_1 &: \mu \neq \mu_0\end{aligned}$$

La region de rechazo es

$$W_\alpha = \left\{ (x_1, \dots, x_n) \left/ \begin{array}{ll} \bar{x} - \mu_0 > t_0 \frac{S_{n-1}}{\sqrt{n}} & \text{si } \bar{x} > \mu_0 \\ \bar{x} - \mu_0 < -t_0 \frac{S_{n-1}}{\sqrt{n}} & \text{si } \bar{x} < \mu_0 \end{array} \right. \right\}$$

donde t_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución t-Student n-1 grados de libertad.

Contraste cola a la derecha Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned}H_0 &: \mu = \mu_0 \\H_1 &: \mu > \mu_0\end{aligned}$$

En este caso, se rechazará la hipótesis nula cuando:

$$\bar{X} - \mu_0 > t_0 \frac{S_{n-1}}{\sqrt{n}}$$

donde ahora, t_0 representa el cuantil $1 - \alpha$ de la distribución t-Student con n-1 grados de libertad, que tiene valor positivo.

Contraste cola a la izquierda Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned}H_0 &: \mu = \mu_0 \\H_1 &: \mu < \mu_0\end{aligned}$$

En este caso, se rechazará la hipótesis nula cuando:

$$\bar{X} - \mu_0 < -t_0 \frac{S_{n-1}}{\sqrt{n}}$$

donde ahora, t_0 representa el cuantil $1 - \alpha$ de la distribución t-Student con $n-1$ grados de libertad, que tiene valor positivo.

3. Contraste de hipotesis para la proporción

Para resolver este tipo de contrastes se utilizan la variable

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$$

cuya distribución, si el tamaño muestral es suficientemente grande, puede considerarse aproximadamente $\mathcal{N}(0, 1)$. La formulación y resolución de cuestiones relativas a este problema es análogo a los casos anteriores.

Para un test de dos colas, se rechazará la hipótesis nula cuando

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} > z_0 \quad \text{o bien} \quad \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} < -z_0$$

donde z_0 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución $\mathcal{N}(0, 1)$.

Para el test de una cola a la derecha rechazamos la hipótesis nula si

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} > z_0$$

donde z_0 es el cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$.

Para el test de una cola a la izquierda rechazamos la hipótesis nula si

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} < -z_0$$

donde z_0 es el cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$.

4. Contraste de hipótesis para la diferencia de medias

El problema que se plantea en este apartado es el de formular hipótesis sobre la diferencia entre la media de dos poblaciones y decidir la veracidad de ellas según lo observado en las dos muestras que se escogen de sendas poblaciones.

4. CONTRASTE DE HIPÓTESIS PARA LA DIFERENCIA DE MEDIAS

4.1. Caso en el que se conocen las varianzas

Si las varianzas son conocidas el problema de contraste se plantea mediante la variable aleatoria

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim \mathcal{N}(0, 1)$$

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: \mu_X - \mu_Y = d_0 \\ H_1 &: \mu_X - \mu_Y \neq d_0 \end{aligned}$$

se rechazará la hipótesis nula cuando para z_0 cuantil $1 - \frac{\alpha}{2}$ de la distribución $\mathcal{N}(0, 1)$ se verifica que

$$\frac{(\bar{X} - \bar{Y}) - d_0}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} > Z_0 \quad (24.8)$$

$$\text{o bien} \quad (24.9)$$

$$\frac{(\bar{X} - \bar{Y}) - d_0}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} < -Z_0 \quad (24.10)$$

Para los test de cola a la derecha Z_0 cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

$$\frac{(\bar{X} - \bar{Y}) - d_0}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} > Z_0 \quad (24.11)$$

Para los test de cola a la izquierda Z_0 cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

$$\frac{(\bar{X} - \bar{Y}) - d_0}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} < -Z_0 \quad (24.12)$$

4.2. Caso en el que se desconocen las varianzas

Si las varianzas son desconocidas el problema de contraste se plantea mediante la variable aleatoria.

Se tiene que

$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad S_2^2 = \frac{1}{m-1} \sum_{j=1}^m (Y_j - \bar{Y})^2$$

entonces

$$S_c = \sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}$$

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: \mu_X - \mu_Y = d_0 \\ H_1 &: \mu_X - \mu_Y \neq d_0 \end{aligned}$$

$$t = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{S_c \sqrt{\frac{m+n}{n \times m}}}$$

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: \mu_X - \mu_Y = d_0 \\ H_1 &: \mu_X - \mu_Y \neq d_0 \end{aligned}$$

se rechazará la hipótesis nula cuando para t_0 cuantil $1 - \frac{\alpha}{2}$ de la distribución t-Student con $n+m-2$ grados de libertad se verifica que

$$\begin{aligned} \frac{(\bar{X} - \bar{Y}) - d_0}{S_c \sqrt{\frac{m+n}{n \times m}}} &> t_0 \\ &\text{o bien} \\ \frac{(\bar{X} - \bar{Y}) - d_0}{S_c \sqrt{\frac{m+n}{n \times m}}} &< -t_0 \end{aligned}$$

5. Contraste de hipótesis para la diferencia de proporciones

La variable aleatoria que se utilizará como base de construcción de la región de rechazo es

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}}$$

tiene una distribución aproximadamente $\mathcal{N}(0, 1)$.

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: p_1 - p_2 = d_0 \\ H_1 &: p_1 - p_2 \neq d_0 \end{aligned}$$

Las regiones de rechazo quedan determinado por las expresiones totalmente análogas 24.8, 24.10, 24.11, 24.12

$$\begin{aligned} \frac{(\hat{p}_1 - \hat{p}_2) - d_0}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}} &> Z_0 \\ &\text{o bien} \\ \frac{(\hat{p}_1 - \hat{p}_2) - d_0}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}} &< -Z_0 \end{aligned}$$

Para los test de cola a la derecha Z_0 cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

$$\frac{(\hat{p}_1 - \hat{p}_2) - d_0}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}} > Z_0$$

Para los test de cola a la izquierda Z_0 cuantil $1 - \alpha$ de la distribución $\mathcal{N}(0, 1)$

$$\frac{(\hat{p}_1 - \hat{p}_2) - d_0}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}} < -Z_0$$

6. Contraste de hipótesis para la varianza

Estudiar la variabilidad de un fenómeno es una cuestión de interés en problemas de evaluación de riesgos, control de calidad, etc.

La variable aleatoria que se utilizará para la construcción del contraste es:

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} = \frac{(n-1)S_{n-1}^2}{\sigma^2}$$

cuya distribución es χ^2 con n-1 grados de libertad

6.1. Región de rechazo

Test de dos colas

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: \sigma^2 = \sigma_0^2 \\ H_1 &: \sigma^2 \neq \sigma_0^2 \end{aligned}$$

Se rechazará la hipótesis nula cuando

$$\begin{aligned} S_{n-1}^2 &< \frac{A\sigma_0^2}{n-1} \\ &\text{o bien} \\ S_{n-1}^2 &> \frac{B\sigma_0^2}{n-1} \end{aligned}$$

Donde A es el cuantil $\frac{\alpha}{2}$ de la distribución χ^2 con n-1 grados de libertad y B es el cuantil $1 - \frac{\alpha}{2}$

Test de cola a la derecha

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned} H_0 &: \sigma^2 = \sigma_0^2 \\ H_1 &: \sigma^2 > \sigma_0^2 \end{aligned}$$

Se rechazará la hipótesis nula cuando

$$S_{n-1}^2 > \frac{B\sigma_0^2}{n-1}$$

Donde B es el cuantil $1 - \alpha$ de la distribución χ^2 con n-1 grados de libertad

Test de cola a la izquierda

Para este test la hipótesis nula y alternativa se enuncian de la siguiente forma

$$\begin{aligned}H_0 &: \sigma^2 = \sigma_0^2 \\H_1 &: \sigma^2 < \sigma_0^2\end{aligned}$$

Se rechazará la hipótesis nula cuando

$$S_{n-1}^2 > \frac{A\sigma_0^2}{n-1}$$

Donde A es el cuantil α de la distribución χ^2 con n-1 grados de libertad

7. Contraste de hipótesis para la razón de varianzas

A veces es aconsejable, comparar las varianzas, lo cual se realiza estudiando la razón o cociente de ambas. La variable sobre la que se construye el contraste es

$$\frac{S_{n-1}^2}{S_{m-1}^2} \frac{\sigma_2^2}{\sigma_1^2}$$

cuya distribución es F de Snedecor con n-1 grado de libertad para el numerador y m-1 grado de libertad para el denominador.

7.1. Contraste de dos colas

Las hipótesis del test son

$$\begin{aligned}H_0 &: \frac{\sigma_1^2}{\sigma_2^2} = r_0 \\H_1 &: \frac{\sigma_1^2}{\sigma_2^2} \neq r_0\end{aligned}$$

cuando $r_0 = 1$, estamos contrastando si la varianza de ambas poblaciones son iguales, o si por el contrario son distintas. Si F_0 es el cuantil $\frac{\alpha}{2}$ y F_1 es el cuantil $1 - \frac{\alpha}{2}$ de la distribución es F de Snedecor con n-1 grado de libertad para el numerador y m-1 grado de libertad para el denominador, se rechazará la hipótesis nula cuando

$$\begin{aligned}\frac{S_1^2}{S_2^2} > r_0 F_1 & \quad \text{si} \quad \frac{S_1^2}{S_2^2} > r_0 \\& \text{o bien} \\ \frac{S_1^2}{S_2^2} < r_0 F_0 & \quad \text{si} \quad \frac{S_1^2}{S_2^2} < r_0\end{aligned}$$

7.2. Contraste de una cola a la derecha

Las hipótesis del test son

$$H_0 : \frac{\sigma_1^2}{\sigma_2^2} = r_0$$

$$H_1 : \frac{\sigma_1^2}{\sigma_2^2} > r_0$$

cuando $r_0 = 1$, estamos contrastando si la varianza de ambas poblaciones son iguales, o si por el contrario son distintas. Si F_0 es el cuantil $1 - \alpha$ de la distribución es F de Snedecor con $n-1$ grado de libertad para el numerador y $m-1$ grado de libertad para el denominador, se rechazará la hipótesis nula cuando

$$\frac{S_1^2}{S_2^2} > r_0 F_0$$

Parte V

Machine Learning

CAPÍTULO 25

Introducción a la Ciencia de Datos

Entonces, ¿qué es la ciencia de datos y por qué es tan actual? ¿Es solo otra moda pasajera que se desvanecerá después del bombo publicitario?

Comenzaremos con una simple introducción a la ciencia de datos, definiendo qué es, por qué es importante y por qué es importante ahora. Este capítulo destacará el proceso de ciencia de datos con pautas y mejores prácticas. Presentará algunas de las técnicas y algoritmos más utilizados en la ciencia de datos. Y explorará modelos de conjuntos, una tecnología clave a la vanguardia de la ciencia de datos.

1. ¿Qué es la Ciencia de Datos?

La ciencia de datos es la práctica de obtener información útil a partir de los datos. Aunque también se aplica a los datos pequeños, la ciencia de datos es particularmente importante para los datos masivos, ya que ahora se es capaz de recopilar petabytes de datos estructurados y no estructurados de muchas fuentes dentro y fuera de una organización. Como resultado, ahora somos “ricos” en datos pero pobres en información. La ciencia de datos proporciona procesos y técnicas poderosos para obtener información procesable de este mar de datos. La ciencia de datos se basa en varias disciplinas que incluyen estadística, matemáticas, investigación de operaciones, procesamiento de señales, lingüística, bases de datos y almacenamiento, programación, aprendizaje automático y computación científica. La figura 25.1 ilustra las disciplinas más comunes de la ciencia de datos. Aunque el término ciencia de datos es nuevo en los negocios, existe desde 1960 cuando Peter Naur lo utilizó por primera vez para referirse a los métodos de procesamiento de datos en la informática. Desde finales de la década de 1990, estadísticos notables como C.F. Jeff Wu y William S. Cleveland también han utilizado el término ciencia de datos, una disciplina que consideran igual o una extensión de la estadística.

Los profesionales de la ciencia de datos son científicos de datos, cuyas habilidades abarcan estadística, matemáticas, investigación de operaciones, procesamiento de señales, lingüística, bases de datos y almacenamiento,




Figura 25.1: Disciplinas que constituyen la ciencia de datos

programación, machine learning y computación científica. Además, para ser eficaces, los científicos de datos también necesitan buenas habilidades de comunicación y visualización de datos. El conocimiento del dominio también es importante para ofrecer resultados significativos rápidamente.

Esta amplitud de habilidades es muy difícil de encontrar en una persona, por lo que la ciencia de datos es un trabajo en equipo, no un esfuerzo individual. Para ser eficaz, es necesario contratar un equipo con habilidades complementarias en ciencia de datos.

1.1. Gama de Análisis

Según Gartner, todos los análisis que se hacen se pueden clasificar en una de cuatro categorías:

- análisis descriptivo,
- análisis exploratorio,

- predictivo
- prescriptivo.

El análisis descriptivo generalmente ayuda a describir una situación y puede ayudar a responder preguntas como ¿Qué sucedió ?, ¿Quiénes son mis clientes ?, etc.

El análisis exploratorio lo ayuda a comprender por qué sucedieron las cosas y puede responder preguntas como ¿Por qué sucedió?

El análisis predictivo es prospectivo y puede responder preguntas como ¿Qué pasará en el futuro?

Como sugiere su nombre, el análisis prescriptivo es mucho más prescriptivo y ayuda a responder preguntas como ¿Qué debemos hacer ?, ¿Cuál es la mejor ruta hacia mi destino? O ¿Cómo debo asignar mis inversiones? En la figura 7.2 se ilustra la gama de análisis. También se muestra el grado de dificultad.




Figura 25.2: Gama de Análisis

Análisis Descriptivo

Es el más sencillo. Tiene como fin describir un conjunto de datos, obteniendo así los parámetros que distinguen las características de un conjunto de datos.

Por ejemplo, se puede saber el número de ventas realizadas, el número nuevo de clientes, número de productos que se tiene en stock.

Los motivos para realizar este análisis son que permite conocer al detalle la información que se posee y conocer la forma en la que se estructura la información. Se limita a realizar deducciones directamente a partir de los datos y parámetros obtenidos.

Análisis Exploratorio

Consiste en un conjunto de técnicas estadísticas cuya finalidad es conseguir un entendimiento básico de los datos, permitiendo detectar características

sobresalientes, como inesperadas y valores atípicos.

Por ejemplo, en que sucursal se vende más, de que producto hay más stock, qué diferencias hay entre el producto más vendido y el menos vendido, saber si hay diferencias económicas significativas por barrios, ...

Este análisis debe ser la primera etapa de todo análisis de datos, para evitar que datos erróneos o inesperados sean procesados de modo inapropiado. Se apoya en un planteamiento descriptivo y se realiza sin aceptar ideas preconcebidas sobre el contenido de la información de los datos.

La aplicación de este análisis permite estudiar la tendencia, distribución y forma de cada uno de los indicadores, estudiar la normalidad sobre un conjunto de indicadores y si este criterio no se cumpliera, este análisis orienta sobre el tipo de transformación que se debe someter a los datos.

El análisis exploratorio permite definir hipótesis que deberán ser demostradas con un análisis inferencial.

Análisis Predictivo

Se fundamenta en la identificación de relaciones entre variables en eventos pasados, para luego explotar dichas relaciones y predecir posibles resultados en futuras situaciones.

Por ejemplo, qué cantidad stock que se debe tener en el almacén para cada producto, o a partir de los datos del padrón que tipo de ayudas/servicios se solicitarán a un ayuntamiento el año que viene.

Cabe destacar que, mientras el análisis inferencial se preocupa de entender y demostrar la relación, el análisis predictivo sólo se preocupa del valor, y no busca en ningún caso entender el sistema o la relación entre elementos.

Este factor lo hace especialmente interesante para problemas complejos con gran cantidad de variables influyentes o de difícil comprensión para la mente humana que abarcan desde el genoma humano, a sistemas de recomendaciones en función de preferencias de usuarios pasando por la detección de texto, el modelado de redes sociales o incluso la conducción autónoma.

En este proceso se hace uso de los datos junto con técnicas analíticas, estadísticas y de aprendizaje automático a fin de crear un modelo predictivo. Se desarrolla el modelo mediante un conjunto de datos de entrenamiento y después se prueba (con un conjunto de datos diferente) y se valida para determinar su precisión.

Análisis Prescriptivo

El análisis prescriptivo sugerirá el mejor curso de acción a seguir para optimizar los resultados de su negocio. Por lo general, el análisis prescriptivo combina un modelo predictivo con reglas comerciales (como rechazar una transacción si la probabilidad de fraude está por encima de un umbral determinado). Por ejemplo, puede sugerir el mejor plan telefónico para ofrecer a un cliente determinado o, basándose en la optimización, puede proponer la mejor ruta para sus camiones de reparto. El análisis prescriptivo es muy útil en escenarios como la optimización de canales, la optimización de la cartera o la optimización del tráfico para encontrar la mejor ruta dadas las condiciones actuales del tráfico. Se pueden utilizar técnicas como árboles de decisión,

programación lineal y no lineal, simulación de Monte Carlo o teoría de juegos a partir de estadísticas y minería de datos para realizar análisis prescriptivos.

La complejidad analítica aumenta de la analítica descriptiva a la prescriptiva. En muchos sentidos, la analítica prescriptiva es el nirvana de la analítica y, a menudo, la utilizan las organizaciones más sofisticadas analíticamente.

Imagine una empresa de telecomunicaciones inteligente que tiene modelos analíticos integrados en sus sistemas de flujo de trabajo empresarial (figura25.3).




Figura 25.3: Análisis Prescriptivo Telecomunicaciones

Tiene los siguientes modelos analíticos integrados en su sistema de centro de atención telefónica para clientes:

Modelo de fuga de clientes : este es un modelo predictivo que predice la probabilidad de pérdida de clientes. En otras palabras, predice la probabilidad de que el cliente que llama al centro de llamadas finalmente se decante por la competencia.

Modelo de segmentación de clientes : esto coloca a los clientes en distintos segmentos de comportamiento con fines de marketing.

Modelo de propensión del cliente : este modelo predice la propensión del cliente a responder a cada una de las ofertas de marketing, como actualizaciones a planes premium.

Cuando un cliente llama, el sistema del centro de llamadas lo identifica en tiempo real desde su número de teléfono. Luego, el sistema del centro de llamadas califica al cliente usando estos tres modelos. Si el cliente obtiene una puntuación alta en el modelo de abandono de clientes, significa que es muy probable que se decante por la competencia. En ese caso, la empresa de telecomunicaciones enviará inmediatamente al cliente a un grupo de agentes del centro de llamadas que están facultados para hacer ofertas atractivas para evitar el desgaste. De lo contrario, si el modelo de segmentación califica al cliente como

un cliente rentable, se lo enruta a un servicio de conserjería especial con líneas de espera más cortas y el mejor servicio al cliente. Si el modelo de propensión puntúa alto al cliente para las actualizaciones, el agente de llamadas recibe una alerta e intentará vender al cliente con actualizaciones atractivas. La “belleza” de esta solución es que todos los modelos están integrados en el flujo de trabajo comercial de la empresa de telecomunicaciones, lo que permite a sus agentes tomar decisiones inteligentes que mejoran la rentabilidad y la satisfacción del cliente. Esto se ilustra en la figura 25.3.

1.2. ¿Por qué es importante y por qué ahora?

La ciencia de datos ofrece a las organizaciones una oportunidad real para tomar decisiones más inteligentes y oportunas basadas en todos los datos que recopilan. Con las herramientas adecuadas, la ciencia de datos le ofrece conocimientos nuevos y prácticos no solo de sus propios datos, sino también de las crecientes fuentes de datos fuera de su organización, como datos meteorológicos, datos demográficos de clientes, datos de crédito al consumidor de las oficinas de crédito y datos de sitios de redes sociales como Facebook, Twitter, Instagram, etc. A continuación, presentamos algunas razones por las que la ciencia de datos es ahora fundamental para el éxito empresarial.

1.3. Problemas que puede solucionar el Machine Learning

Los tipos de algoritmos de machine learning más exitosos son aquellos que automatizan los procesos de toma de decisiones al generalizar a partir de ejemplos conocidos. En esta configuración, que se conoce como aprendizaje supervisado, el usuario proporciona al algoritmo pares de entradas y salidas deseadas, y el algoritmo encuentra una manera de producir la salida deseada dada una entrada. En particular, el algoritmo puede crear una salida para una entrada que nunca antes había visto sin la ayuda de un humano. En el ejemplo de clasificación de correo spam, utilizando el aprendizaje automático, el usuario proporciona al algoritmo una gran cantidad de correos electrónicos (que son la entrada), junto con información sobre si alguno de estos correos electrónicos es spam (que es la salida deseada). Dado un nuevo correo electrónico, el algoritmo producirá una predicción sobre si el nuevo correo electrónico es spam.

Aprendizaje Supervisado

Los algoritmos de machine learning que aprenden de los pares de entrada / salida se denominan algoritmos de aprendizaje supervisado porque un “profesor” supervisa los algoritmos en forma de resultados deseados para cada ejemplo del que aprenden. Si bien la creación de un conjunto de datos de entradas y salidas suele ser un proceso manual laborioso, los algoritmos de aprendizaje supervisado se comprenden bien y su rendimiento es fácil de medir. Si su aplicación se puede formular como un problema de aprendizaje supervisado y puede crear un conjunto de datos que incluya el resultado deseado, es probable que el aprendizaje automático pueda resolver su problema.

Entre los ejemplos de tareas de aprendizaje automático supervisadas se incluyen:

- Identificar el código postal a partir de dígitos escritos a mano en un sobre. Aquí, la entrada es un escaneo de la escritura a mano y la salida deseada son los dígitos reales en el código postal. Para crear un conjunto de datos para crear un modelo de aprendizaje automático, se debe recopilar muchos sobres. Luego, se puede leer los códigos postales y almacenar los dígitos como los resultados deseados.
- Determinar si un tumor es benigno según una imagen médica. Aquí la entrada es la imagen y la salida es si el tumor es benigno. Para crear un conjunto de datos para construir un modelo, se necesita una base de datos de imágenes médicas. También se necesita una opinión de un experto, por lo que un médico debe examinar todas las imágenes y decidir qué tumores son benignos y cuáles no. Incluso podría ser necesario hacer un diagnóstico adicional más allá del contenido de la imagen para determinar si el tumor en la imagen es canceroso o no.
- Detectar actividad fraudulenta en transacciones con tarjetas de crédito. Aquí, la entrada es un registro de la transacción de la tarjeta de crédito y la salida es si es probable que sea fraudulenta o no. Suponiendo que la entidad que distribuye las tarjetas de crédito, recopilar un conjunto de datos significa almacenar todas las transacciones y registrar si un usuario informa alguna transacción como fraudulenta.

Algo interesante a tener en cuenta sobre estos ejemplos es que, aunque las entradas y salidas parecen bastante sencillas, el proceso de recopilación de datos para estas tres tareas es muy diferente. Si bien la lectura de sobres es laboriosa, es fácil y barata. La obtención de imágenes y diagnósticos médicos, por otro lado, requiere no solo una maquinaria costosa, sino también un conocimiento experto poco común y costoso, sin mencionar las preocupaciones éticas y las cuestiones de privacidad. En el ejemplo de detección de fraudes con tarjetas de crédito, la recopilación de datos es mucho más sencilla. Los clientes le proporcionarán el resultado deseado, ya que informarán sobre el fraude. Todo lo que tiene que hacer para obtener los pares de entrada / salida de actividad fraudulenta y no fraudulenta es esperar.

Aprendizaje No Supervisado

Los algoritmos no supervisados son el otro tipo de algoritmo que se explicará. En el aprendizaje no supervisado, solo se conocen los datos de entrada y no se proporcionan datos de salida conocidos al algoritmo. Si bien hay muchas aplicaciones exitosas de estos métodos, generalmente son más difíciles de comprender y evaluar. Algunos ejemplos de aprendizaje no supervisado incluyen:

- Identificar temas en un conjunto de publicaciones de blog. Si se tiene una gran colección de datos de texto, es posible que se desee resumirla y encontrar temas predominantes en ella. Es posible que no sepa de antemano cuáles son estos temas o cuántos temas podría haber. Por lo tanto, no hay salidas conocidas.
- Segmentar a los clientes en grupos con preferencias similares. Dado un conjunto de registros de clientes, es posible que se desee identificar qué clientes son similares y si hay grupos de clientes con preferencias

similares. Para un sitio de compras, estos pueden ser “padres”, “ratones de biblioteca” o “jugadores”. Debido a que no sabe de antemano cuáles podrían ser estos grupos, o incluso cuántos hay, no tiene resultados conocidos.

- Detectar patrones de acceso anormales a un sitio web. Para identificar abusos o errores, a menudo es útil encontrar patrones de acceso que sean diferentes a la norma. Cada patrón anormal puede ser muy diferente y es posible que no tenga ningún caso registrado de comportamiento anormal. Debido a que en este ejemplo solo observa el tráfico y no sabe qué constituye un comportamiento normal y anormal, este es un problema sin supervisión.

Tanto para tareas de aprendizaje supervisadas como no supervisadas, es importante tener una representación de los datos de entrada que un algoritmo pueda entender. A menudo es útil pensar en los datos como una tabla. Cada punto de datos sobre el que desea razonar (cada correo electrónico, cada cliente, cada transacción) es una fila, y cada propiedad que describe ese punto de datos (por ejemplo, la edad de un cliente o la cantidad o ubicación de una transacción) es una columna. Puede describir a los usuarios por su edad, su sexo, cuándo crearon una cuenta y con qué frecuencia han comprado en su tienda en línea. Puede describir la imagen de un tumor mediante los valores de escala de grises de cada píxel, o tal vez utilizando el tamaño, la forma y el color del tumor.

Cada entidad o fila aquí se conoce como una muestra (o punto de datos) en el machine learning, mientras que las columnas, las propiedades que describen estas entidades, se denominan características.

1.4. Los datos como activo competitivos

Los datos son ahora un activo crítico que ofrece una ventaja competitiva a las organizaciones inteligentes que los utilizan correctamente para la toma de decisiones. McKinsey y Gartner están de acuerdo en esto: en un documento reciente, McKinsey sugiere que las empresas que utilizan datos y análisis de negocios para tomar decisiones son más productivas y ofrecen un mayor retorno sobre el capital que aquellas que no lo hacen. En una línea similar, Gartner postula que las organizaciones que invierten en una infraestructura de datos moderna superarán a sus pares hasta en un 20 %.

Los macrodatos ofrecen a las organizaciones la oportunidad de combinar datos valiosos en silos para obtener nuevos conocimientos que impulsan decisiones más inteligentes.

Proposición 25.1 (Brad Brown et al., McKinsey Global Institute, 2011)

Las empresas que utilizan datos y análisis de negocios para guiar la toma de decisiones son más productivas y experimentan mayores retornos sobre el capital que los competidores que no lo hacen.

Proposición 25.2 (Regina Casonato et al., Gartner)

Para 2015, las organizaciones que integran fuentes y tipos de información

nuevos, diversos y de alto valor en una infraestructura de gestión de información coherente superarán financieramente a sus pares de la industria en más de un 20 %

Mayor Demanda de Empresas

La inteligencia empresarial (BI) ha sido la clave del análisis utilizado por la mayoría de las organizaciones en las últimas décadas. Sin embargo, con la aparición de big data, ahora más Empresas están deseando utilizar el análisis predictivo para mejorar el marketing y la planificación empresarial. La BI tradicional ofrece un buen análisis retrovisor de su negocio, pero no ayuda con ninguna pregunta prospectiva que incluya pronósticos o predicciones.

Los últimos años han visto un aumento en la demanda de empresas que desean de un análisis predictivo a medida que buscan técnicas analíticas más poderosas para descubrir el valor de los tesoros de datos que almacenan en sus negocios. No se ha visto tanta demanda de ciencia de datos por parte de las empresas como en los últimos dos años.

Mayor conocimiento de las Tecnologías de Minería de Datos

Hoy en día, un subconjunto de algoritmos de minería de datos y machine learning se comprenden más ampliamente hoy en día, ya que usuarios como Netflix y Amazon los han probado y probado, ya que los usan activamente en sus motores de recomendación. Si bien la mayoría de las empresas no comprenden completamente los detalles de los algoritmos de machine learning utilizados, su aplicación en las recomendaciones de películas de Netflix o los motores de recomendación en las tiendas en línea son muy importantes. De manera similar, muchos usuarios ahora conocen los anuncios dirigidos que ahora son muy utilizados por la mayoría de los proveedores en línea sofisticados. Por lo tanto, aunque es posible que muchas empresas no conozcan los detalles de los algoritmos utilizados, ahora comprenden cada vez más su valor comercial.

Acceso a más Datos

La digitalización de los datos se ha disparado en los últimos años y no muestra signos de disminuir. La mayoría de los expertos de la industria ahora están de acuerdo en que se está recopilando más datos que nunca. Según IDC, el universo digital creció a 35 zetabytes (es decir, 35 billones de terabytes) a nivel mundial en 2020. Otros postulan que los datos del mundo ahora están creciendo hasta 10 veces cada 5 años, lo cual es asombroso. En un estudio reciente, McKinsey Consulting también encontró que en 15 de los 17 sectores económicos de EE. UU., Las empresas con más de 1,000 empleados almacenan, en promedio, más de 235 terabytes de datos.

Esta explosión de datos está impulsada por el surgimiento de nuevas fuentes de datos como las redes sociales, telefonía móvil, sensores inteligentes y avances dramáticos en la industria de la computación. El auge de Internet de las cosas (IoT) solo exacerba esta tendencia, ya que los sensores generan más datos que nunca. Según Cisco, ¡había hasta 50 mil millones de dispositivos conectados en 2020!

Los grandes volúmenes de datos que se recopilan también le permiten crear modelos predictivos más precisos. Sabemos por las estadísticas que el intervalo

de confianza tiene una relación inversa con el tamaño de la muestra. Entonces, cuanto mayor sea el tamaño de la muestra, menor será el margen de error. Esto, a su vez, aumenta la precisión de las predicciones de su modelo.

1.5. Potencia de Procesamiento más Rápida y Económica

Ahora tenemos mucha más potencia informática a nuestra disposición que nunca. La ley de Moore propuso que el rendimiento del chip de computadora aumentaría exponencialmente, duplicándose cada 18 meses. Esta tendencia ha sido cierta durante la mayor parte de la historia de la informática moderna.

En 2010, la Hoja de ruta tecnológica internacional para semiconductores actualizó este pronóstico, prediciendo que el crecimiento se desaceleraría en 2013 cuando las densidades y conteos de computadoras se duplicarían cada 3 años en lugar de 18 meses. A pesar de esto, el crecimiento exponencial en el rendimiento del procesador ha generado ganancias en tecnología y productividad económica.

Hoy en día, el procesador de un teléfono inteligente es hasta cinco veces más potente que el de una computadora de escritorio hace 20 años.

En la década de los noventa, se requerían estaciones de trabajo costosas como los mainframes DEC VAX o las estaciones de trabajo DEC Alpha para ejecutar algoritmos avanzados de computación intensiva. Es notable que el teléfono inteligente actual también sea cinco veces más rápido que el potente procesador DEC Alpha de 1994, ¡cuya velocidad era de 200-300 MHz! Hoy en día, puede ejecutar los mismos algoritmos en estaciones de trabajo personales asequibles con procesadores de varios núcleos. Además, puede aprovechar la arquitectura MapReduce de Hadoop para implementar potentes algoritmos de minería de datos en una granja de servidores básicos a un costo mucho más bajo que nunca.

Con la ciencia de datos, ahora tenemos las herramientas para descubrir patrones ocultos en nuestros datos a través de la implementación inteligente de algoritmos de minería de datos y aprendizaje automático.

También se ha visto un aumento espectacular de la capacidad y una reducción exponencial del precio de la memoria de la computadora. Desde 1990, el precio promedio por MB de memoria ha caído de 59 dólares a unos escasos 0,49 centavos. ¡Reducción de precio del 99,2%! Al mismo tiempo, la capacidad de un módulo de memoria ha aumentado de 8 MB a la friolera de 8 GB. Como resultado, una computadora portátil modesta ahora es más poderosa que una estación de trabajo de alta gama de principios de los noventa.

2. El Proceso de Ciencia de Datos

El Proceso de ciencia de datos en equipo (TDSP) ofrece un ciclo de vida recomendado que se puede usar para estructurar los proyectos de ciencia de datos. En el ciclo de vida se describen los pasos completos que siguen los proyectos correctos. Si usa otro ciclo de vida de la ciencia de datos, como Cross Industry Standard Process for Data Mining (CRISP-DM), Knowledge Discovery in Databases (KDD) o propio proceso personalizado de la organización, puede seguir usando el TDSP basado en tareas.

Este ciclo de vida está diseñado para los proyectos de ciencia de datos que se enviarán como parte de aplicaciones inteligentes. Estas aplicaciones

implementan modelos de aprendizaje o inteligencia artificial de máquina para realizar un análisis predictivo. Los proyectos de ciencia de datos exploratorios y los proyectos de análisis improvisados también se pueden beneficiar del uso de este proceso. Pero para esos proyectos, algunos de los pasos descritos a continuación pueden no ser necesarios.

2.1. Cinco fases del ciclo de vida

El ciclo de vida de TDSP se compone de cinco fases principales que se ejecutan de forma iterativa. Estas fases incluyen:

1. Conocimiento del negocio
2. Adquisición y comprensión de los datos
3. Modelado
4. Implementación
5. Aceptación

Conocimiento del negocio

Esto es fundamental, ya que guía el resto del proyecto. Antes de construir cualquier modelo, es importante trabajar con el patrocinador del proyecto para identificar el problema comercial específico que está tratando de resolver. Sin esto, uno podría pasar semanas o meses construyendo modelos sofisticados que resuelven el problema equivocado, lo que lleva a un esfuerzo inútil. Un buen proyecto de ciencia de datos obtiene buenos conocimientos que impulsan decisiones comerciales más inteligentes. Por lo tanto, el análisis debe tener un objetivo comercial. ¡No debería ser un martillo en busca de un clavo!

Existen técnicas y marcos de consultoría formales (como talleres de descubrimiento guiado y metodología six sigma) que utilizan los profesionales para ayudar a las partes interesadas del negocio a priorizar y alcanzar sus objetivos comerciales.

Adquisición y Comprensión de los Datos

Este paso implica dos actividades. La primera es la adquisición de datos sin procesar de varios sistemas de origen, incluidas bases de datos, sistemas CRM, archivos de registro web, etc. Esto puede involucrar procesos ETL (extraer, transformar y cargar), administradores de bases de datos y personal de BI. Sin embargo, el científico de datos está íntimamente involucrado para garantizar que se extraigan los datos correctos en el formato correcto. Trabajar con los datos brutos también proporciona un contexto vital, que se requiere en sentido descendente.

En segundo lugar, una vez que se extraen los datos correctos, se analizan y se preparan para el modelado. Esto implica abordar los datos faltantes, los valores atípicos en los datos y las transformaciones de datos. Por lo general, si una variable tiene más del 40% de los valores perdidos, se puede rechazar, a menos que el hecho de que falte (o no) transmita información crítica. Por ejemplo, puede haber un fuerte sesgo en la demografía de quién completa el

campo opcional de “edad” en una encuesta. Por lo demás, debemos decidir cómo lidiar con los valores perdidos; ¿Deberíamos imputar con el valor promedio, la mediana o algo más? Existen varias técnicas estadísticas para detectar valores atípicos.

Con un diagrama de caja y bigotes, un valor atípico es una muestra (valor) mayor o menor que 1,5 veces el rango intercuartílico (IQR). Necesitamos decidir si descartar un valor atípico o no. Si tiene sentido mantenerlo, necesitamos encontrar una transformación útil para la variable. Por ejemplo, la transformación logarítmica suele ser útil para transformar los ingresos.

El análisis de correlación, el análisis de componentes principales o el análisis factorial son técnicas útiles que muestran las relaciones entre las variables. Finalmente, la selección de características se realiza en esta etapa para identificar las variables correctas para usar en el modelo en el siguiente paso.

Este paso puede resultar laborioso y requerir mucho tiempo. De hecho, en un proyecto típico de ciencia de datos, dedicamos entre el 75 % y el 80 % del tiempo a la adquisición y preparación de datos. Dicho esto, este es el paso vital que convierte los datos sin procesar en gemas de alta calidad para modelar.

El viejo adagio sigue siendo cierto: basura entra, basura sale. Invertir sabiamente en la preparación de datos mejora el éxito de su proyecto.

Modelado

Esta es la parte más divertida del proyecto, ya que es donde se desarrollan los modelos predictivos. En este paso, se determina el algoritmo correcto a utilizar para el modelado dado el problema empresarial y los datos. Por ejemplo, si se trata de un problema de clasificación binaria, podemos utilizar regresión logística, árboles de decisión, árboles de decisión potenciados o redes neuronales.

Si el modelo final tiene que ser explicable, esto descarta algoritmos como árboles de decisión potenciados. La construcción de modelos es un proceso iterativo: experimentamos con diferentes modelos para encontrar el que mejor predice.

Se debe validar varias veces para asegurarnos de que satisface las necesidades antes de salir de esta etapa.

Implementación

Una vez construido, el modelo final se debe implementar en producción, donde se utilizará para puntuar transacciones o por los clientes para impulsar decisiones comerciales reales.

Los modelos se implementan de muchas formas diferentes según el entorno de la empresa. En la mayoría de los casos, implementar un modelo implica implementar las transformaciones de datos y el algoritmo predictivo desarrollado por el científico de datos para integrarlo con una plataforma de gestión de decisiones existente. No hace falta decir que hoy en día es un proceso engorroso.

Aceptación

La ciencia de datos no termina con la implementación. Vale la pena señalar que cada modelo estadístico o de aprendizaje automático es solo una aproximación del mundo real y, por lo tanto, es imperfecto desde el principio.

Cuando un modelo validado se prueba y se implementa en producción, se debe monitorizar para garantizar que funcione según lo planeado. Esto es fundamental porque cualquier modelo basado en datos tiene una vida útil fija. La precisión del modelo se degrada con el tiempo porque fundamentalmente los datos en producción variarán con el tiempo por varias razones (como que la empresa puede lanzar nuevos productos para dirigirse a un grupo demográfico diferente). Por ejemplo, el proveedor de servicios inalámbricos que discutimos anteriormente puede optar por lanzar un nuevo plan de teléfono para niños adolescentes. Si continúan utilizando los mismos modelos de abandono y propensión, es posible que vean una degradación en el rendimiento de sus modelos después del lanzamiento de este nuevo producto. Esto se debe a que el conjunto de datos original utilizado para construir los modelos de abandono y propensión no contenía un número significativo de clientes adolescentes. Con un estrecho seguimiento del modelo en producción podemos detectar cuándo comienza a degradarse su rendimiento. Cuando su precisión se degrada significativamente, es hora de reconstruir el modelo volviéndolo a entrenar con el último conjunto de datos, incluidos los datos de producción, o reconstruyéndolo por completo con conjuntos de datos adicionales. En ese caso, volvemos al Paso 1, donde revisamos los objetivos comerciales y comenzamos de nuevo.

¿Con qué frecuencia debemos reconstruir un modelo? La frecuencia varía según el ámbito empresarial. En un entorno empresarial estable donde los datos no varían demasiado rápido, los modelos se pueden reconstruir una vez al año o dos. Un buen ejemplo son los productos de banca minorista, como hipotecas y préstamos para automóviles. Sin embargo, en un entorno muy dinámico donde los datos ambientales cambian rápidamente, los modelos se pueden reconstruir diaria o semanalmente. Un buen ejemplo de ello es la industria de los teléfonos móviles, que es tremendamente competitivo. Los modelos de abandono deben volver a capacitarse cada pocos días, ya que los clientes se ven atraídos por ofertas cada vez más atractivas de la competencia.

3. Técnicas Comunes en la Ciencia de Datos

La ciencia de datos ofrece un gran cuerpo de algoritmos de sus disciplinas constituyentes. Organizamos estos algoritmos en los siguientes grupos para simplificar:

- Clasificación
- Clusterización
- Regresión
- Simulación
- Análisis de Contenido
- Recomendación

3.1. Algoritmos de Clasificación

Los algoritmos de clasificación se utilizan comúnmente para clasificar personas o cosas en uno de los muchos grupos. También se utilizan ampliamente

para realizar predicciones. Por ejemplo, para evitar el fraude, el emisor de una tarjeta clasificará una transacción con tarjeta de crédito como fraudulenta o no. El emisor de la tarjeta normalmente tiene un gran volumen de transacciones históricas de tarjetas de crédito y conoce el estado de cada una de estas transacciones. Muchos de estos casos los informa el titular legítimo de la tarjeta que no quiere pagar cargos no autorizados. Entonces el emisor sabe si cada transacción fue fraudulenta o no. Usando estos datos históricos, el emisor ahora puede construir un modelo que predice si es probable que una nueva transacción con tarjeta de crédito sea fraudulenta o no. Este es un problema de clasificación binaria en el que todos los casos se dividen en una de dos clases.

Otro problema de clasificación es la propensión de los clientes a actualizar a un plan telefónico premium. En este caso, el proveedor de servicios necesita saber si un cliente se actualizará a un plan premium o no. Usando datos de ventas y uso, el operador puede determinar qué clientes actualizaron en el pasado. Por lo tanto, pueden clasificar a todos los clientes en uno de dos grupos: si actualizaron o no. Dado que el operador también tiene información sobre datos demográficos y de comportamiento de clientes nuevos y existentes, puede construir un modelo para predecir la probabilidad de que un nuevo cliente actualice; en otras palabras, el modelo agrupará a cada cliente en una de dos clases.

Las estadísticas y la minería de datos ofrecen muchas herramientas excelentes para la clasificación: esto incluye la regresión logística, que es ampliamente utilizada por los estadísticos para crear tarjetas de puntuación de crédito, o modelos de propensión a comprar, o algoritmos de redes neuronales como retropropagación, funciones de base radial o redes de regresión Ridge, también denominada regresión contraída o Tikhonov regularization.

Otros incluyen árboles de decisión o modelos de conjuntos, como árboles de decisión potenciados o bosques aleatorios. Para problemas de clasificación más complejos con más de dos clases, puede utilizar técnicas multimodales que predicen varias clases. Los problemas de clasificación generalmente usan algoritmos de aprendizaje supervisado que usan datos de etiquetas para el entrenamiento.

3.2. Algoritmos de Clusterización

La clusterización se utiliza el aprendizaje no supervisado para agrupar los datos en clases distintas. Una diferencia importante entre los problemas de agrupación y clasificación es que el resultado de la agrupación se desconoce de antemano. Antes de la agrupación, no sabemos a qué agrupación pertenece cada punto de datos. Por el contrario, con los problemas de clasificación tenemos datos históricos que muestran la clase a la que pertenece cada punto de datos. Por ejemplo, el prestamista sabe a partir de los datos históricos si un cliente incumplió con el pago de sus préstamos para coches o no.

Una buena aplicación de la agrupación en clústeres es la segmentación de clientes, en la que agrupamos a los clientes en distintos segmentos con fines de marketing. En un buen modelo de segmentación, los datos dentro de cada segmento son muy similares. Sin embargo, los datos de diferentes segmentos son muy diferentes. Por ejemplo, un especialista en marketing del segmento de los juegos debe comprender mejor a sus clientes para poder crear las ofertas adecuadas para ellos. Supongamos que solo tiene dos variables sobre los clientes:

la edad y la intensidad del juego. Al utilizar la agrupación en clústeres, el especialista en marketing descubre que hay tres segmentos distintos de clientes de juegos, como se muestra en la figura 25.4.




Figura 25.4: Algoritmo de clusterización

El segmento 1 es el de los jugadores intensos que juegan apasionadamente a los videojuegos todos los días y son típicamente jóvenes. El segmento 2 son los jugadores casuales que solo juegan ocasionalmente y generalmente tienen entre 30 y 40 años. Los que no juegan rara vez juegan videojuegos y suelen ser mayores; forman el segmento 3.

La estadística ofrece varias herramientas para la agrupación en clústeres, pero el más utilizado es el algoritmo k-means, que utiliza una métrica de distancia para agrupar datos similares. Con este algoritmo decides a priori cuántos clusters quieres; esta es la constante K. Si establece $K = 3$, el algoritmo produce tres grupos. El aprendizaje automático también ofrece algoritmos más sofisticados, como mapas autoorganizados (también conocidos como redes de Kohonen) desarrollados por Teuvo Kohonen, o redes de teoría de resonancia adaptativa (ART) desarrolladas por Stephen Grossberg y Gail Carpenter. Los algoritmos de agrupación en clústeres suelen utilizar el aprendizaje no supervisado, ya que no se conoce el resultado durante el entrenamiento.

3.3. Algoritmos de Regresión

Las técnicas de regresión se utilizan para predecir variables de respuesta con resultados numéricos. Por ejemplo, un proveedor de servicios inalámbricos puede utilizar técnicas de regresión para predecir el volumen de llamadas en sus centros de servicio al cliente. Con esta información, pueden asignar el número correcto de personal del centro de llamadas para satisfacer la demanda. Las variables de entrada para los modelos de regresión pueden ser numéricas o categóricas. Sin embargo, lo que es común con estos algoritmos es que la salida (o variable de respuesta) suele ser numérica. Algunas de las técnicas de regresión más comúnmente utilizadas incluyen regresión lineal, árboles de decisión, redes neuronales y regresión de árbol de decisión potenciada.

La regresión lineal es una de las técnicas de predicción más antiguas en estadística y su objetivo es predecir un resultado dado a partir de un conjunto de variables observadas. Un modelo de regresión lineal simple es una función lineal. Si solo hay una variable de entrada, el modelo de regresión lineal es la mejor línea que se ajusta a los datos. Para dos o más variables de entrada, el modelo de regresión es el mejor hiperplano que se ajusta a los datos subyacentes.

Las redes neuronales artificiales son un conjunto de algoritmos que imitan el funcionamiento del cerebro. Aprenden con el ejemplo y se les puede entrenar para hacer predicciones a partir de un conjunto de datos incluso cuando se desconoce la función que mapea la respuesta a las variables independientes. Hay muchos algoritmos de redes neuronales diferentes, incluidas las redes de retropropagación, las redes Hopfield, las redes Kohonen (también conocidas como mapas autoorganizados) y las redes de teoría de resonancia adaptativa (o ART). Sin embargo, la más común es la retropropagación, también conocida como perceptrón multicapa. Las redes neuronales se utilizan para regresión o clasificación.

Los algoritmos de árboles de decisión son técnicas jerárquicas que funcionan dividiendo el conjunto de datos de forma iterativa en función de ciertos criterios estadísticos. El objetivo de los árboles de decisión es maximizar la varianza entre los diferentes nodos del árbol y minimizar la varianza dentro de cada nodo. Algunos de los algoritmos de árbol de decisión más utilizados incluyen dicotomizador iterativo 3 (ID3), C4.5 y C5.0 (sucesores de ID3), detección automática de interacción (AID), detección automática de interacción chi-cuadrado (CHAID) y clasificación y Árbol de regresión (CART). Si bien son muy útiles, los algoritmos ID3, C4.5, C5.0 y CHAID son algoritmos de clasificación y no son útiles para la regresión. El algoritmo CART, por otro lado, se puede utilizar para clasificación o regresión.

3.4. Algoritmos de Simulación

La simulación se usa ampliamente en muchas industrias para modelar y optimizar procesos en el mundo real. Los ingenieros han utilizado durante mucho tiempo técnicas matemáticas como elementos finitos o volúmenes finitos para simular la aerodinámica de alas de aviones o automóviles. La simulación ahorra a las empresas de ingeniería millones de dólares en costos de I + D, ya que ya no tienen que hacer todas sus pruebas con modelos físicos reales. Además, la simulación ofrece la oportunidad de probar muchos más escenarios simplemente ajustando variables en sus modelos informáticos.

En los negocios, la simulación se utiliza para modelar procesos como optimizar los tiempos de espera en los centros de llamadas u optimizar las rutas para las empresas de transporte por carretera o las aerolíneas. A través de la simulación, los analistas de negocios pueden modelar un amplio conjunto de hipótesis para optimizar con fines de lucro u otros objetivos comerciales.

La estadística ofrece muchas técnicas poderosas para la simulación y optimización. Un método, el análisis de la cadena de Markov, se puede utilizar para simular cambios de estado en un sistema dinámico. Por ejemplo, se puede usar para modelar cómo los clientes fluirán a través de un centro de llamadas: ¿cuánto tiempo esperará un cliente antes de dejarlo, o cuáles son sus posibilidades de permanecer encendido después de activar el sistema de respuesta de voz interactiva (IVR)? La programación lineal se usa para optimizar las rutas de camiones o aerolíneas, mientras que la simulación Monte Carlo se usa para encontrar las mejores condiciones para optimizar para un resultado comercial dado, como las ganancias.

3.5. Algoritmo Análisis de Contenido

El análisis de contenido se utiliza para extraer contenido como archivos de texto, imágenes y videos para obtener información. La minería de textos utiliza análisis estadístico y lingüístico para comprender el significado del texto. La búsqueda simple de palabras clave es demasiado primitiva para la mayoría de las aplicaciones prácticas. Por ejemplo, comprender el sentimiento de los datos del feed de Twitter con una simple búsqueda de palabras clave es un proceso manual y laborioso porque tiene que almacenar palabras clave para sentimientos positivos, neutrales y negativos. Luego, a medida que escanea los datos de Twitter, califica cada feed de Twitter en función de las palabras clave específicas detectadas. Este enfoque, aunque útil en casos limitados, es engorroso y bastante primitivo. El proceso se puede automatizar con la minería de texto y el procesamiento del lenguaje natural (NLP), que extrae el texto e intenta inferir el significado de las palabras en función del contexto en lugar de una simple búsqueda de palabras clave.

El aprendizaje automático también ofrece varias herramientas para analizar imágenes y videos a través del reconocimiento de patrones. Mediante el reconocimiento de patrones, podemos identificar objetivos conocidos con algoritmos de reconocimiento facial. Los algoritmos de redes neuronales, como el perceptrón multicapa y las redes ART, se pueden usar para detectar y rastrear objetivos conocidos en secuencias de video o para ayudar en el análisis de imágenes de rayos X.

3.6. Algoritmos de Recomendación

Las tiendas online como Amazon han utilizado ampliamente los motores de recomendación para recomendar productos según las preferencias de los usuarios. Hay tres enfoques generales para los motores de recomendación. El filtrado de colaboración (CF) hace recomendaciones basadas en similitudes entre usuarios o elementos. Con el filtrado colaborativo basado en elementos, analizamos los datos de los elementos para encontrar qué elementos son similares. Con el filtrado colaborativo, esos datos son específicamente las interacciones de los usuarios con las películas, como las calificaciones o la

visualización, en contraposición a las características de las películas como el género, el director y los actores. Por lo tanto, cada vez que un cliente compra una película de este conjunto, recomendamos otras en función de la similitud.

La segunda clase de motores de recomendación hace recomendaciones analizando el contenido seleccionado por cada usuario. En este caso, se utilizan técnicas de minería de texto o procesamiento de lenguaje natural para analizar contenido, como archivos de documentos. Los tipos de contenido similares se agrupan y esto constituye la base de las recomendaciones para los nuevos usuarios. En el libro de Haralambos Marmanis y Dmitry Babenko encontrará más información sobre el filtrado colaborativo y los enfoques basados en contenido.

El tercer enfoque de los motores de recomendación utiliza algoritmos de aprendizaje automático para determinar la afinidad del producto. Este enfoque también se conoce como análisis de la canasta de mercado. Se utilizan algoritmos como Naïve Bayes, las Reglas de asociación de Microsoft o el paquete Arules en R para extraer datos de ventas para determinar qué productos se venden juntos.

4. Vanguardia de la Ciencia de Datos

Concluimos este capítulo con una descripción general rápida de los modelos que están a la vanguardia de la ciencia de datos.

4.1. El Auge de los Modelos de Conjuntos

Los modelos de conjuntos son un conjunto de clasificadores de aprendizaje automático que utilizan un panel de algoritmos en lugar de uno solo para resolver problemas de clasificación. Imitan nuestra tendencia humana a mejorar la precisión de las decisiones consultando a amigos o expertos conocedores. Cuando nos enfrentamos a decisiones importantes como un diagnóstico médico, tendemos a buscar una segunda opinión de otros médicos para mejorar nuestra confianza. De la misma manera, los modelos de conjuntos utilizan un conjunto de algoritmos como panel de expertos para mejorar la precisión y reducir la varianza de los problemas de clasificación.

La comunidad de aprendizaje automático ha trabajado en modelos de conjuntos durante décadas. De hecho, Dasarathy y Sheela publicaron artículos fundamentales ya en 1979. Sin embargo, desde mediados de la década de 1990, esta área ha experimentado un rápido progreso con varias contribuciones importantes que han dado como resultado aplicaciones muy exitosas en el mundo real.

4.2. Real Aplicación de los Modelos de Conjuntos

En los últimos años, se han encontrado modelos de conjuntos en excelentes aplicaciones del mundo real, incluido el reconocimiento facial en cámaras, bioinformática, recomendaciones de películas de Netflix y Xbox Kinect de Microsoft. Examinemos dos de estas aplicaciones.

Primero, los modelos de conjuntos fueron fundamentales para el éxito de la competencia del Premio Netflix. En 2006, Netflix organizó un concurso abierto con un premio de 1 millón de dólares por el mejor algoritmo de filtrado

colaborativo que mejoró su solución existente en un 10 %. En septiembre de 2009, el premio de 1 millón de dólares fue otorgado a Pragmatic Chaos de BellKor, un equipo de científicos de AT&T Labs que unió fuerzas con dos equipos menos conocidos. Al comienzo del concurso, la mayoría de los equipos utilizaron algoritmos de clasificador único: aunque superaron al modelo de Netflix en un 6 – 8 %, el rendimiento se estancó rápidamente hasta que los equipos comenzaron a aplicar modelos de conjuntos. Los principales concursantes pronto se dieron cuenta de que podían mejorar sus modelos combinando sus algoritmos con los de los equipos aparentemente más débiles. Al final, la mayoría de los mejores equipos, incluidos los ganadores, utilizaron modelos de conjuntos para superar significativamente el motor de recomendaciones de Netflix. Por ejemplo, el equipo del segundo lugar, acertadamente llamado The Ensemble, usó más de 900 modelos individuales en su conjunto.

El sensor Xbox Kinect de Microsoft también utiliza el modelado de conjuntos. Random Forests, una forma de modelo de conjunto, se usa de manera efectiva para rastrear los movimientos del esqueleto cuando los usuarios juegan con el sensor Xbox Kinect.

A pesar del éxito en las aplicaciones del mundo real, una limitación clave de los modelos de conjuntos es que son cajas negras en el sentido de que sus decisiones son difíciles de explicar. Como resultado, no son adecuados para aplicaciones en las que es necesario explicar las decisiones. Las tarjetas de puntuación de crédito son un buen ejemplo porque los prestamistas deben explicar la puntuación de crédito que asignan a cada consumidor. En algunos mercados, tales explicaciones son un requisito legal y, por lo tanto, los modelos de conjuntos serían inadecuados a pesar de su poder predictivo.

4.3. Construcción de Modelos de Conjuntos

Hay tres pasos clave para construir un modelo de conjunto:

1. Seleccionar datos.
2. Entrenar clasificadores.
3. Combinar clasificadores.

El primer paso para construir un modelo de conjunto es la selección de datos para los modelos de clasificador. Al muestrear los datos, un objetivo clave es maximizar la diversidad de los modelos, ya que esto mejora la precisión de la solución. En general, cuanto más diversos sean sus modelos, mejor será el rendimiento de su clasificador final y menor será la varianza de sus predicciones.

El paso 2 del proceso implica la formación de varios clasificadores individuales. Pero, ¿cómo se asignan los clasificadores? De las muchas estrategias disponibles, las dos más populares son el embolsado y el impulso. El algoritmo de ensacado utiliza diferentes subconjuntos de datos para entrenar cada modelo. El algoritmo de Random Forest utiliza este enfoque de ensacado. Por el contrario, el algoritmo de refuerzo mejora el rendimiento al hacer que los ejemplos mal clasificados en el conjunto de entrenamiento sean más importantes durante el entrenamiento. Entonces, durante el entrenamiento, cada modelo adicional se enfoca en los datos clasificados erróneamente. El algoritmo del árbol de decisión impulsado utiliza la estrategia de impulso.

Finalmente, una vez que entrenes a todos los clasificadores, el paso final es combinar sus resultados para hacer una predicción final. Existen varios enfoques para combinar los resultados, que van desde una mayoría simple hasta una votación por mayoría ponderada.

Los modelos de conjuntos son una parte realmente interesante del aprendizaje automático y ofrecen el potencial de lograr avances en los problemas de clasificación.

Sistemas de Recomendación

Los sistemas de recomendación son herramientas importantes que ayudan a los usuarios a conocer opciones o elementos de interés para personalizar la experiencia del usuario. Son tan efectivas que todos los días se recibe recomendaciones, sugerencias y “productos relacionados” aconsejo por distintas apps y webs. La popularidad de estos sistemas radica en que conforme las recomendaciones mejoran en precisión, generan en el usuario un sentimiento de pertenencia; pues el sitio recuerda quién es y qué le gusta.

Definición 26.1 *Los sistemas de recomendación, a veces llamados en inglés “recommender systems” son algoritmos que intentan “predecir” los siguientes ítems (productos, canciones, etc.) que querrá adquirir un usuario en particular.*

Por tanto, la finalidad de los Sistemas de Recomendación es intentar personalizar al máximo lo que se ofrece a cada usuario. Gracias a la cantidad de información que se obtiene de las personas da la posibilidad de tener una mejor tasa de aciertos, mejorando la experiencia del usuario sin ofrecer productos a ciegas.

1. Tipos de Motores

Entre las estrategias más usadas para crear sistemas de recomendación se encuentran:

- **Popularity:** Aconseja por la “popularidad” de los productos. Antes del Machine Learning, lo habitual era usar “rankings” ó listas con lo más votado, ó más popular de entre todos los productos. Esto hacía que a todos los usuarios se les recomendara lo mismo. Esta técnica, hoy a día se sigue usando, como se puede ver, por ejemplo, en librerías, donde ponen apartados con los libros más vendidos o “best seller”. La ventaja de esta estrategia es fácil de implementar y en algunos casos es efectiva.

- Content-based: Tomando en cuenta algunos datos del historial del usuario intenta predecir que busca el usuario y que sugerencias similares puede mostrar. Este tipo de sistemas es uno de los que tiene mayor presencia en la actualidad. Con ellos podemos descubrir opciones que se ajusten a las características de los productos o contenidos que hemos disfrutado con anterioridad y elegir elementos similares nuevos.
- Colaborative: Es el más novedoso, pues utiliza la información de los usuarios para identificar perfiles similares y aprender de los datos para recomendar productos de manera individual.

Cada una de estas formas de implementación tiene puntos fuertes y débiles que dependen de la información disponible. Por ejemplo, la falta de perfiles de usuario implicará que un sistema de recomendación basado en conocimiento no podrá ser utilizado y que un sistema de recomendación basado en contenido no tomará en cuenta los gustos de los usuarios, sino sólo las características de los objetos del catálogo. Si no se tienen calificaciones de los elementos a recomendar no podrá utilizarse un sistema de recomendación basado en filtrado colaborativo pues estos dependen de que los usuarios evalúen la mayor cantidad de ítems posibles del catálogo, de lo contrario la precisión de los resultados estará comprometida.

2. Filtro Colaborativo

Como se ha comentado, grandes compañías como Amazon o Netflix o ... hacen su propio sistema de recomendación. Para ello, utilizarán dos bits de información para hacer recomendaciones: lo que usuario ha visto y si otros clientes han visto lo mismo que el usuario también ha visto.

A este tipo de recomendaciones se le llama “filtración colaborativa” o “collaborative filtering”. Recibe el nombre de colaborativo porque hace recomendaciones utiliza la información de otros usuarios. Los sistemas de recomendación basados en filtro colaborativo pueden encontrarse con situaciones que no permiten su correcto funcionamiento. Algunas de ellas son:

- Matriz de ratings dispersa: Esto sucede cuando los usuarios no califican los ítems que van visitando. Resulta en un cálculo de similaridad inexacto, o en casos como Pearson, no pueden ser calculados debido a que no existen objetos evaluados en común.
- Ítems o usuarios sin ratings: Cuando el sistema de recomendación no dispone de suficiente información acerca de un usuario o contenido, es muy difícil poder realizar recomendaciones, y sobre todo, que sean válidas para él. El problema del arranque en frío se debe a la existencia de ítems que nadie ha valorado explícita o implícitamente dentro de un catálogo. En general, si no se asigna una calificación no es posible hacer inferencia sobre el interés o gusto de los usuarios.
- Ratings inexactos: Esto sucede cuando el usuario evalúa siempre con el mismo puntaje, ya sea muy alto o muy bajo. En este caso es posible que las recomendaciones obtenidas no sean de relevantes, dando lugar a falsos positivos o falsos negativos.

- Usuarios que han calificado todo: Puede existir alguien que haya calificado todos los ítems del catálogo, en este caso no será posible hacer una recomendación, puesto que las recomendaciones se hacen sobre elementos que aún no han sido valorados.

2.1. ¿Cómo se encuentra a alguien similar?

Un paso crítico en el algoritmo de filtro colaborativo basado en elementos es calcular qué tan parecidos son los elementos y luego seleccionar los que resulten más similares.

Para que pueda calcularse la similaridad entre dos usuarios, se debe cumplir dos condiciones:

1. Los usuarios deben tener ítems calificados.
2. Al menos un elemento debe haber sido evaluado en común.

si alguna de estas condiciones no se cumple, entonces debe trabajarse con otras técnicas que permitan realizar recomendaciones, por ejemplo, utilizar una base de conocimientos, o crear un perfil del usuario.

El primer paso es encontrar a alguien similar al usuario. Para ello, se utilizará un ejemplo en 2 dimensiones para poder graficarlo.

Supóngase en una biblioteca, los usuarios han leído dos libros y lo han valorado con un sistema de estrellas.

Como se representa en el siguiente gráfico




Figura 26.1: Puntuación de Libros

En la siguiente tabla, se muestra la puntuación de los tres usuarios

	Libro 1	Libro 2
José	5 ★	5 ★
Carmen	5 ★	2 ★
Olga	4 ★	1 ★

La Señora Y valoró esos dos libros con ★★ el libro 1 y con ★★ ★★ el libro 2. La persona encargada de la biblioteca deberá encontrar una persona similar o más próxima a los gustos de la Señora Y. Por tanto para ello se deberá calcular la distancia que los separa.

Distancia Manhattan

La distancia de Manhattan recibe muchos nombres ya que se le conoce como city block, geometría del taxista, distancia rectilínea o más formalmente como distancia L_1 .

Es la distancia más simple de todas. Su nombre proviene, de la aparentemente simple pregunta acerca del camino más corto que un taxista puede seguir para llevar a su pasaje al destino solicitado en medio de las calles y avenidas de la Nueva York.

Para diseñar distancias de mínimo recorrido en ciudades es lógico es usar esta distancia ya con otras distancias (como se verá con la distancia euclídea 2.1) se atravesaría edificios. La formula es:

$$d_{\text{man}}(A, B) = \sum_{i=0}^n |a_i - b_i|$$

Tan solo indica, que la distancia entre un punto A y un punto B en $\mathbb{R}^{n+1}$ es igual al sumatorio de las distancias entre cada uno de los valores de $a_i - b_i$. La ventaja de esta medida es que se ve menos afectada por outliers, por tanto es más robusta frente a otras distancias que se verá a continuación.

Continuando con el ejemplo de la biblioteca, la distancia entre la Señora Y y las tres personas son:

	Distancia Señora Y
José	4
Carmen	5
Olga	5

Al estar la Señora Y más próxima a José, se podría ver el historial de él y recomendarle los libros que José ha valorado con más estrellas

Distancia Euclídea

Probablemente la distancia más conocida y usada en las matemáticas.

También llamada más formalmente como distancia L_2 . La distancia euclídea entre dos puntos A y B en $\mathbb{R}^{n+1}$ se define como la longitud del segmento que une ambos puntos. En coordenadas cartesianas, la distancia euclídea se calcula empleando el teorema de Pitágoras.

La formula es:

$$d_{\text{euc}}(A, B) = \sqrt{\sum_{i=0}^n (a_i - b_i)^2}$$

Continuando con el ejemplo de la biblioteca, la distancia entre la Señora Y y las tres personas son:

Al estar la Señora Y más próxima a José, se podría ver el historial de él y recomendarle los libros que José ha valorado con más estrellas

	Distancia Señora Y
José	3.16
Carmen	3.61
Olga	3.61

Distancia Minkowski

Esta distancia puede considerarse una generalización de las distancias euclideas y Manhattan. También llamada más formalmente como distancia L_p .

La distancia Minkowski entre dos puntos A y B en $\mathbb{R}^{n+1}$ se define como

$$d_{min}(A, B) = \sqrt[p]{\sum_{i=0}^n (a_i - b_i)^p}$$

Obsérvese que para $p = 1$, la expresión anterior coincide con la distancia Manhattan, y que para $p = 2$, coincide con la distancia Euclidea.

Distancia de Chebyshev

La Distancia de Chebyshev o más conocidas como distancia máxima o más formalmente L_∞ . Se define como la distancia entre dos vectores es la mayor de sus diferencias a lo largo de cualquier dimensión de coordenadas.

Se utiliza mucho en el juego del ajedrez, ya que el número mínimo de movimientos que necesita un rey para ir de un cuadrado a otro en un tablero de ajedrez.

La distancia Chebyshev entre dos puntos A y B en $\mathbb{R}^{n+1}$ se define como

$$\begin{aligned} d_{\max}(A, B) &= \lim_{p \rightarrow \infty} \sqrt[p]{\sum_{i=0}^n (|a_i - b_i|)^p} \\ &= \max(|a_i - b_i|) \end{aligned}$$

2.2. Pensando a lo “Grande”

Pero una biblioteca con solo dos libros, es bastante extraño, ya que los usuarios suelen leer más de dos libros y las bibliotecas suelen tener más de dos libros. En la tabla siguiente se recoge las puntuaciones de una muestra de 8 libros y 8 usuarios.

Los huecos en blanco son libros que el usuario no ha dado una valoración.

Si se quiere ver la distancia entre José y Carmen, sólo se deberá tener en cuenta aquellos libros que ambos usuarios hubieran evaluado.

Utilizando la distancia Manhattan entre esos dos usuarios sería:

Utilizando la distancia euclídea entre esos dos usuarios sería:

2. FILTRO COLABORATIVO

	José	Carmen	Olga	Emilia	Fernando	Guillermo	Helena	Ignacio
Libro 1	3,5	2	5	3			5	3
Libro 2	2	3,5	1	4	4	4,5	2	
Libro 3		4	1	4,5	1	4		
Libro 4	4,5		3		4	5	3	5
Libro 5	5	2	5	3		5	5	4
Libro 6	1,5	3,5	1	4,5		4,5	4	2,5
Libro 7	2,5			4	4	4	5	3
Libro 8	2	3		2	1	4		

	José	Carmen	Diferencia
Libro 1	3,5	2	1,5
Libro 2	2	3,5	1,5
Libro 5	5	2	3
Libro 6	1,5	3,5	2
Libro 8	2	3	1
Distancia Manhattan			9

	José	Carmen	Diferencia
Libro 1	3,5	2	2,25
Libro 2	2	3,5	2,25
Libro 5	5	2	9
Libro 6	1,5	3,5	4
Libro 8	2	3	1
Suma de cuadrados			18,5
Distancia euclídea			4,3

2.3. Otras Métricas

Cuando se trabaja con calificaciones los usuarios tienen muy diferentes comportamientos cuando se trata de bandas de clasificación.

En la tabla 2.2 se comprueba los siguientes casos

- Fernando es una persona “binaria” ya que solo da dos valores, 4 ó 1.
- Guillermo da valores comprendidos en el rango de 4 a 5.
- Carmen da evita los valores extremos y da valores en el rango de 2 a 4.

Este tipo de comportamientos de los usuarios puede crear un caos en los sistema de recomendación, ya que ¿un 4 de Fernando debe de valer lo mismo que un 4 de Guillermo?

Coefficiente de Correlación de Pearson

Una forma de solucionar este problema es utilizar el coeficiente de correlación de Pearson ya visto en el capítulo 30.

El coeficiente de correlación de Pearson es uno de los métodos de análisis más fundamentales e importantes en estadística y machine learning.

	Libro 1	Libro 2	Libro 3	Libro 4	Libro 5
Diego	4,75	4,25	5	4	4,5
Alejandra	4	2	5	1	3

Se consideran los siguientes datos:

Se trata de un ejemplo de lo que se denomina “inflación de calificaciones” en la minería de datos en la valoración de Diego, esto se debe a que la valoración más baja es 4 y la más alta un 5.




Figura 26.2: inflación de calificaciones

Coseno de Similitud

Esta función es bastante popular dentro del text mining, y muy utilizada también en los filtros colaborativos. La similitud entre ellos se mide calculando el coseno del ángulo formado por la intersección de las representaciones vectoriales, es decir, considera que las puntuaciones de los usuarios son vectores y aquellos valores missing serán imputados a cero. El coseno está definido por:

$$\cos(x, y) = \frac{x \cdot y}{||x|| ||y||}$$

donde

$$||x||^2 = \sum_{i=1}^n x_i^2$$

Por tanto, utilizando los datos de la tabla 2.3 los dos vectores son:

$$\begin{aligned} x &= (4,75, 4,25, 5, 4, 4,5) \\ y &= (4, 2, 5, 1, 3) \end{aligned}$$

Entonces

$$\begin{aligned} ||x|| &= \sqrt{(4,75^2 + 4,25^2 + 5^2 + 4^2 + 4,5^2)} \\ &= \sqrt{101,875} = 10,09 \\ ||y|| &= \sqrt{(4^2 + 2^2 + 5^2 + 1^2 + 3^2)} \\ &= \sqrt{55} = 7,416 \end{aligned}$$

El producto escalar queda como:

$$\begin{aligned}x \cdot y &= (4.75, 4.25, 5, 4, 4.5) \cdot (4, 2, 5, 1, 3) \\ &= 70\end{aligned}$$

Por tanto

$$\begin{aligned}\cos(x, y) &= \frac{70}{10.09 \times 7.416} \\ &= 0.935\end{aligned}$$

Los valores del coseno varían entre los valores 1 y -1. Donde 1 indica similitud perfecta a -1 indica similitud perfecta negativa. Entonces 0.935 representa una muy buena similitud entre Diego y Alejandra.

3. Filtro Basados en Elementos

El rol de los datos es ahora más importante que nunca y pueden crear una ventaja competitiva ya que, el volumen de los datos que se gestionan al año en las empresas va a aumentando de manera exponencial.

Por ello, la clave para los sistemas de recomendación es la recopilación de datos de los usuarios.

Cuando se crea un perfil del usuario, se crea utilizando dos formas o métodos en la recolección de características.

Calificaciones explícitas

Los usuarios facilitan información de forma voluntaria al sistema.

Algunos ejemplos de recolección de datos de forma explícita son:

- Solicitar al usuario que pondere sobre la base de una escala proporcionada, algún tema en particular.
- Solicitar al usuario que pondere un conjunto de temas de una lista de temas favoritos.
- Presentar al usuario dos temas, y solicitarle que seleccione uno de ellos.
- Solicitar al usuario que cree una lista de temas de su preferencia.

Problemas En general esta información conlleva mucho sesgo porque un usuario puede dar una opinión u otra según el momento en el que se encuentre. Otros problemas son:

- El usuario es perezoso y no suele calificar un producto.
- El usuario puede mentir o dar sólo información parcial.
- El usuario no actualiza sus calificaciones.

Calificaciones implícitas

Hasta hace pocos años, la gran mayoría de los sistemas de recomendación, dependían de preferencias explícitas del usuario. Para las calificaciones implícitas, no se le pide a los usuarios que den ninguna calificación, solo se observa su comportamiento. Algunos ejemplos de recolección de datos de forma implícita son:

- Guardar un registro de los temas que el usuario ha visto en una tienda en línea.
- Analizar el número de visitas que recibe un artículo
- Guardar un registro de los artículos que el usuario ha seleccionado.
- Obtener un listado de los artículos que el usuario ha seleccionado o visto en su computadora.
- Analizar las redes sociales de las que el usuario forma parte y de esta manera conocer sus gustos y preferencias.

Problemas

- No hay feedback negativo.
- Contiene ruido.
- Es difícil cuantificar preferencia y confianza en esas preferencias.
- Hay una carencia de métricas de evaluación. A pesar de que este tipo de sistemas están tan extendidos, aún no hay estándares definidos para su evaluación, sino que cada grupo de investigación ha ido aplicando diferentes técnicas y métricas de evaluación, sin que en muchos casos existan relaciones entre ellas. Esta diversidad de métricas conlleva tres problemas fundamentales:
 1. Si dos investigadores distintos, evalúan sus sistemas con distintas métricas, los resultados no son comparables.
 2. Si la métrica usada no está estandarizada, podemos pensar que los investigadores han elegido la métrica más adecuada de cara a obtener los resultados deseados.
 3. Sin una métrica estandarizada, cada investigador debe realizar un esfuerzo extra en identificar o desarrollar una métrica apropiada.

3.1. El Problema del Éxito

El mayor problema que tiene este tipo de sistemas de recomendación explicados anteriormente es cuando se alcanza a tener un gran número de usuarios. Cuando se quiere hacer una recomendación para un usuario se necesitará calcular tantas distancias como usuarios hay. Imagine que hay un millón y uno de usuarios, esto implica hacer un millón de cálculos de distancias, esto hace que se lento el sistema de recomendaciones. Tiene un servicio de transmisión de música exitoso con un sistema de recomendación incorporado. Para decir esto de una manera más formal, la latencia puede ser un gran inconveniente de los sistemas de recomendación basados en usuarios.

Filtro Basado en Usuarios

Hasta ahora se estado haciendo filtrado colaborativo basado en el usuario. Se ha estado comparando un usuario con cualquier otro usuario para encontrar las coincidencias más cercanas. Hay dos problemas principales con esto

1. Escalabilidad. Como se acaba de explicar, el cálculo aumenta a medida que aumenta el número de usuarios aumenta. Los métodos basados en el usuario funcionan bien para miles de usuarios, pero la escalabilidad se vuelve ser un problema cuando se tiene un millón de usuarios.
2. Escasez. La mayoría de los sistemas de recomendación tienen muchos usuarios y muchos productos, pero el el usuario promedio califica una pequeña fracción del total de productos.

Debido a estos dos problemas, podría ser mejor hacer lo que se denomina filtrado basado en elementos.

3.2. Filtrado Basado en Elementos

Este tipo de filtro identifica los productos que son más similares entre sí. Por ejemplo, tal algoritmo podría encontrar que el elemento X es similar elemento Y. Si un usuario califica con una buena nota al elemento X se podría recomendar el elemento Y. Hay que tenet en cuenta que esto es diferente de lo que hizo para el filtrado basado en el usuario.

En el filtrado basado en usuarios se tenía un usuario, se debía encontrar el más similar persona (o usuarios) a ese usuario y usó las calificaciones de esa persona similar para hacer recomendaciones. En el filtrado basado en elementos, se encuentra con anticipación los artículos más similares y combine eso con la calificación de artículos de un usuario para generar una recomendación.

Una diferencia fundamental entre el cálculo de similaridad en el filtro colaborativo basado en el usuario y el basado en elementos es que, en el caso de primera, se calcula a lo largo de las filas de la matriz.

Funcionamiento

Para explicar el funcionamiento, se explicará con un ejemplo. Se tiene en la biblioteca los siguientes registros

ID_Usuario	Usuario	...	Libro X	...	Libro Y	...	Libro n
1	Carlos	...	5	...		...	...
2	Tamara	...		...	4	...	...
3	Juan	...	1	...	2	...	...
...	...	...		...		...	...
k	Olga	...	5	...	5	...	...
...	...	...		...		...	...
m-1	Carmen	...	4	...	5	...	...
m	Andrés	...	4	...		...	...

Se quiere calcular la similitud del Libro X con el Libro Y. Para ello sólo se utilizará lso usuarios que han calificado ambos libros. Cómo si se estuviera

haciendo filtro basado en el usuario se determinará la similitud entre filas. Para el filtrado basado en elementos se está determinando la similitud entre las columnas, en este caso entre Libro X y Libro Y.

Para calcular la similitud entre elementos, se utilizará la similitud de coseno 2.3. Cómo se comentó sobre la inflación de calificaciones 2.3 donde un usuario otorga calificaciones más altas de lo esperado. Para evitar eso se obtiene da la fórmula de similitud del coseno ajustada.

Similitud del Coseno Ajustada

La similitud de coseno ajustada compensa este inconveniente al restar el promedio de las calificaciones del usuario correspondiente de cada par clasificado conjuntamente. Formalmente, la similitud entre los elementos i y j , se calcula como se expresa en la ecuación 26.1 .

$$s(i, j) = \frac{\sum_{u \in U} (R_{u,i} - \hat{R}_u) (R_{u,j} - \hat{R}_u)}{\sqrt{\sum_{u \in U} (R_{u,i} - \hat{R}_u)^2} \sqrt{\sum_{u \in U} (R_{u,j} - \hat{R}_u)^2}} \quad (26.1)$$

donde $\hat{R}_u$ es el promedio de las calificaciones asignadas por el usuario u . El numerador expresa que por cada usuario que calificó ambos elementos multiplican la calificación normalizada de esos dos elementos y suman los resultados. En el denominador se suman los cuadrados de todas las calificaciones normalizadas para el elemento i y luego se toma la raíz cuadrada de ese resultado. Se hace lo mismo para el elemento j . Y luego se multiplican esos dos juntos.

Ejemplo 26.1 *La empresa de reproducción de música quiere predecir el gusto de los usuarios a partir de cinco grupos de música. En la siguiente tabla se muestra la valoración de cinco usuarios a esos cinco grupos de música: Lo*

Usuario	Media	LOL	VM	LM	LP	R
Tamara			3	5	4	1
Juan			3	4	4	1
Olga		4	3		3	1
Carmen		4	4	4	3	1
Andrés		5	4	5		3

primero que se debe calcular es la media de cada uno de los usuarios.

$$\begin{aligned}
 R_{Tamara} &= \frac{3 + 5 + 4 + 1}{4} \\
 R_{Juan} &= \frac{3 + 4 + 4 + 1}{4} \\
 R_{Olga} &= \frac{4 + 3 + 3 + 1}{4} \\
 R_{Carmen} &= \frac{4 + 4 + 4 + 3 + 1}{5} \\
 R_{Andrés} &= \frac{5 + 4 + 5 + 3}{4}
 \end{aligned}$$

3. FILTRO BASADOS EN ELEMENTOS

Por tanto, rellenando la tabla anterior se tiene

Usuario	Media	LOL	VM	LM	LP	R
Tamara	3.25		3	5	4	1
Juan	3		3	4	4	1
Olga	2.75	4	3		3	1
Carmen	3.2	4	4	4	3	1
Andrés	4.25	5	4	5		3

Ahora, para cada par de artistas musicales, se va a calcular su similitud. Entonces, la fórmula de similitud del coseno ajustada es

$$s(LOL, VM) = \frac{\sum_{u \in U} (R_{u,LOL} - \hat{R}_u) (R_{u,VM} - \hat{R}_u)}{\sqrt{\sum_{u \in U} (R_{u,LOL} - \hat{R}_u)^2} \sqrt{\sum_{u \in U} (R_{u,VM} - \hat{R}_u)^2}}$$

El numerador sería:

$$\begin{aligned} \sum_{u \in U} (R_{u,LOL} - \hat{R}_u) (R_{u,VM} - \hat{R}_u) &= \overbrace{(4 - 2.75)(3 - 2.75)}^{\text{Calificación Olga}} + \overbrace{(4 - 3.2)(4 - 3.2)}^{\text{Calificación Carmen}} + \\ &\quad \overbrace{(5 - 4.25)(4 - 4.25)}^{\text{Calificación Andrés}} \\ &= 0.765 \end{aligned}$$

El denominador sería

$$\begin{aligned} \sum_{u \in U} (R_{u,LOL} - \hat{R}_u)^2 &= (4 - 2.75)^2 + (4 - 3.2)^2 + (5 - 4.25)^2 \\ &= 2.765 \\ \sum_{u \in U} (R_{u,VM} - \hat{R}_u)^2 &= (3 - 2.75)^2 + (4 - 3.2)^2 + (4 - 4.25)^2 \\ &= 0.765 \end{aligned}$$

Por tanto se obtiene

$$\begin{aligned} s(LOL, VM) &= \frac{0.765}{\sqrt{2.765} \sqrt{0.765}} \\ &= \frac{0.765}{1.6628 \times 0.8746} \\ &= \frac{0.765}{1.4543} \\ &= 0.526 \end{aligned}$$

Si se repite los cálculos se llegará a tener la siguiente matriz

Una vez obtenida la matriz de valores similares, ahora procedemos a hacer las predicciones, para ello se utiliza

$$P(u, i) = \frac{\sum_{N \in \text{similiara}(i)} S_{i,N} \times R_{u,N}}{\sum_{N \in \text{similiara}(i)} |S_{i,N}|} \quad (26.2)$$

	LOL	VM	LM	LP	R
LOL	1	0,526	1	0,321	-0,9549
VM	0,526	1	0,0075	-0,2525	-0,6678
LM	1	0,0075	1	0,7841	-0,957
LP	0,321	-0,2525	0,7841	1	-0,9634
R	-0,9549	-0,6678	-0,957	-0,9634	1

Donde $P(u, i)$ significa la predicción del rating del usuario u dado el elemento i .
 N es cada uno de los elementos que la persona u calificó al elemento i .
 $S_{i,N}$ es la similitud entre el elemento i y N , obtenido de la matriz de valores similares.

$R_{u,N}$ es la calificación del usuario u dado el elemento N .

En cambio, para que no ocurra la inflación de calificaciones (como ya se vio en 26.2), se debe “normalizar” esa calificación del usuario y dado el elemento N . Por tanto, se normalizará la $R_{u,N}$ utilizando:

$$\begin{aligned} NR_{u,N} &= \frac{2 \times (R_{u,N} - \min_R) - (\max_R - \min_R)}{\max_R - \min_R} \\ &= 2 \times \frac{(R_{u,N} - \min_R)}{\max_R - \min_R} - 1 \end{aligned}$$

Se hace de esta forma para que así tengamos un rango de calificación que sea $[-1, 1]$. Para deshacer esta “normalización” se utiliza

$$R_{u,N} = \frac{1}{2} \times ((NR_{u,N} + 1) \times (\max_R - \min_R)) + \min_R$$

Entonces la formula 26.2 se debe ajustar y sería:

$$P(u, i) = \frac{\sum_{N \in \text{similares}(i)} S_{i,N} \times NR_{u,N}}{\sum_{N \in \text{similares}(i)} |S_{i,N}|} \quad (26.3)$$

Entonces siguiendo el ejemplo 26.1, la valoración de Tamara sería

Grupo	R	NR
VM	3	0
LM	5	1
LP	4	0.5
R	1	-1

Por tanto de la matriz de similitud

	LOL	VM	LM	LP	R
LOL	1	0,526	1	0,321	-0,9549
VM	0,526	1	0,0075	-0,2525	-0,6678
LM	1	0,0075	1	0,7841	-0,957
LP	0,321	-0,2525	0,7841	1	-0,9634
R	-0,9549	-0,6678	-0,957	-0,9634	1

Se calculará la calificación que le dará a LOL.
Utilizando la formula 26.3 se tiene:

$$\begin{aligned}
 P(u, i) &= \frac{\sum_{N \in \text{similiara}(i)} S_{i,N} \times NR_{u,N}}{\sum_{N \in \text{similiara}(i)} |S_{i,N}|} \\
 &= \frac{(0.526 \times 0) + (1 \times 1) + (0.321 \times 0.5) + (-0.955 \times -1)}{0.526 + 1 + 0.321 + 0.955} \\
 &= 0.753
 \end{aligned}$$

Por tanto Tamara le dará a LOL una califiación de 0.753 en una escala de -1 a 1.

Por tanto para ver la nota real:

$$\begin{aligned}
 R_{u,N} &= \frac{1}{2} \times ((NR_{u,N} + 1) \times (\underset{R}{\text{máx}} - \underset{R}{\text{mín}})) + \underset{R}{\text{mín}} \\
 &= \frac{1}{2} \times ((0.753 + 1) \times (5 - 1)) + 1 \\
 &= 4.506
 \end{aligned}$$

Así que Tamara calificará a LOL con un 4.506

3.3. Slope One

Este algoritmo presentado por Lemire, D., y Maclachlan, A. en abril de 2005 en su artículo *Slope One Predictors for Online Rating-Based Collaborative Filtering*, en donde los autores proponen tres esquemas relacionados de pendiente uno con predictores de la forma $f(x) = x + b$, que calculan previamente la diferencia promedio entre las calificaciones de un elemento y otro para los usuarios que calificaron ambos elementos.

Los algoritmos de *Slope One* (Pendiente uno) son fáciles de implementar, eficientes de consultar, razonablemente precisos, y admiten consultas en línea y actualizaciones dinámicas, lo que los convierte en buenos candidatos para sistemas del mundo real. El esquema básico Slope one se sugiere como un nuevo esquema de referencia para el filtrado colaborativo.

En la lectura mencionada, se comparan los algoritmos propuestos por Lamire y Maclachlan que son: Slope One, Slope One Ponderado(toma en consideración la cantidad de ratings) y Bi-Polar Slope One (usa Slope One ponderado para determinar los gustados y no gustados) con algoritmos de los que ya se comentado anteriores, como Pearson, Coseno Ajustado.

En este manual solo se explicará los dos primeros.

La idea es muy simple y se puede entender en la siguiente imagen 26.3

Si el usuario A le dio 1 al elemento I y 1.5 al elemento J, entonces el usuario B, que califico el elemento I con 2 entonces debería calificar el elemento J como 2,5.

Los métodos de Slope One tienen en cuenta tanto la información de otros usuarios que calificaron el mismo elemento (como el modelo basado en elemento) como de los otros elemento calificados por el mismo usuario (como el promedio por usuario). Sin embargo, los métodos también se basan en puntos de datos que no caen ni en la matriz de usuario ni en la matriz de elementos (por ejemplo, la clasificación del usuario A del elemento I en la




Figura 26.3: Slope One

figura 26.3), pero son información importante para la predicción de clasificación.

Gran parte de la solidez del enfoque proviene de datos que no se incluyen en factores. Específicamente, solo aquellas calificaciones de usuarios que han calificado algún elemento común con el usuario predicho, y solo aquellas clasificaciones de elementos que el usuario del predictor también ha calificado ingresan en la predicción de calificaciones bajo métodos de Slope One.

Dado un conjunto de datos χ y dos artículos i y j con calificaciones u_i y u_j respectivamente en alguna evaluación del usuario u .

Si se considera la desviación media del artículo i con respecto al artículo j como

$$\text{dev}_{j,i} = \sum_{u \in S_{j,i}(\chi)} \frac{u_j - u_i}{\text{card}(S_{j,i}(\chi))}$$

Dado que $\text{dev}_{j,i} + u(i)$ es una predicción para $u(j)$ dado $u(i)$, un predictor razonable podría ser el promedio de todas las predicciones

$$P(u)_j = \frac{1}{\text{card}(R_j)} \sum_{i \in R_j} \text{dev}_{j,i}(\chi) + u_i$$

escrito de otra forma:

$$P(u)_j = \bar{u} + \frac{1}{R_j} \sum_{i \in R_j} \frac{u_j - u_i}{\text{card}(\text{dev}_{j,i}(\chi))}$$

Para poner en práctica todo lo explicado, se verá en el siguiente ejemplo

Ejemplo 26.2 Una empresa de compra online tiene los siguientes registros de cuatro usuarios:

	Auriculares	Micrófono	Tablet
Olga	4	3	4
Carmen	5	2	
Aurora		3,5	4
Beltran	5		3

El primer paso será calcular todas las desviaciones.

3. FILTRO BASADOS EN ELEMENTOS

Se deberá calcular la desviación media del elemento i con respecto al elemento j

$$dev_{j,i} = \sum_{u \in S_{j,i}(\chi)} \frac{u_j - u_i}{card(S_{j,i}(\chi))}$$

donde χ es la tabla 26.2

$$dev_{j,i} = \sum_{u \in S_{j,i}(\chi)} \frac{u_j - u_i}{card(S_{j,i}(\chi))}$$

Donde $card(S_{j,i}(\chi))$ es el número de usuarios que han valorado en ambos elementos i y j .

Por tanto si el elemento i es auriculares y j es micrófono, solo ha habido dos personas valoraron auriculares y micrófono que son Olga y Carmen. El numerador $u_j - u_i$ es la valoración auriculares menos micrófono de cada usuario.

Así que la desviación es

$$\begin{aligned} dev_{A,M} &= \frac{4-3}{2} + \frac{5-2}{2} \\ &= \frac{1}{2} + \frac{3}{2} \\ &= 2 \end{aligned}$$

Esto quiere decir, que en media los usuarios valoran los auriculares con dos puntos más que al micrófono.

Si hacemos el recíproco, la desviación de micrófono con auriculares,

$$\begin{aligned} dev_{M,A} &= \frac{3-4}{2} + \frac{2-5}{2} \\ &= \frac{-1}{2} + \frac{-3}{2} \\ &= -2 \end{aligned}$$

Desarrollando los cálculos se obtiene la siguiente tabla de desviaciones: Por

	Auriculares	Micrófono	Tablet
Auriculares	0	2	1
Micrófono	-2	0	0,75
Tablet	-1	0,75	0

tanto, si se quiere saber la valoración de Carmen para la tablet se debe seguir los siguientes pasos:

■ Numerador

- Carmen valoró los auriculares con un 5 (este será el u_i)

- La desviación de tablet y auriculares es -1 (este será $dev_{j,i}$)
 - Por tanto $(dev_{j,i} + u_i) = 4$
 - Carmen valoró el micrófono con un 2
 - La desviación de tablet y microfono es 0,75
 - Por tanto $(dev_{j,i} + u_i) = 2,75$
 - Se suma ambos valores y se obtiene 6,75
- *Denominador*
- Se tiene que ver cuantos artículos que Carmen ha valorado, sumar el cardinal de esos artículos, es decir, cuantos usuarios ha valorado ese artículo y el artículo a predecir. En este ejemplo, Carmen ha valorado auriculares, y el cardinal de auriculares y tablet (el número total de personas que han valorado ambos objetos) es 2.
 - Carmen ha valorado micrófono, y el cardinal es también 2.
 - Por tanto el denominador es 4.
- Por tanto, la predicción de la valoración de Carmen para la tablet sería de $\frac{6,75}{4} = 1,69$

3.4. Slope One Ponderado

Uno de los inconvenientes de Slope One es que el número de calificaciones observadas no se toma en consideración. Intuitivamente, para predecir la valoración del usuario A del elemento i dada la calificación del usuario A de los elementos j y k , si 2000 usuarios clasificaron el par de elemento j y i mientras que solo 20 usuarios calificaron el par de elemento k y i , entonces la calificación del elemento j del usuario A es probable sea un recomendador mucho mejor para el ítem i que la calificación del ítem k . Por lo tanto, se define la predicción Slope One Ponderado como el siguiente promedio ponderado:

$$P(u)^w(u)_j = \frac{\sum_{i \in S(u) - \{j\}} (dev_{j,i} + u_i) c_{j,i}}{\sum_{i \in S(u) - \{j\}} c_{j,i}}$$

Donde

$$c_{j,i} = \text{card}(S_{j,i}(\chi))$$

Por tanto si se utiliza el ejemplo 26.2 de la valoración de Carmen a la tablet, se tendría

Ejemplo 26.3 ■ Numerador

- Carmen valoró los auriculares con un 5 (este será el u_i)
- La desviación de tablet y auriculares es -1 (este será $dev_{j,i}$)
- Por tanto $(dev_{j,i} + u_i) = 4$

3. FILTRO BASADOS EN ELEMENTOS

- Solo dos personas valoraron (Olga y Beltran) la tablet y los auriculares $c_{j,i} = 2$
 - Por tanto $(dev_{j,i} + u_i)c_{j,i} = 4 \times 2 = 8$
 - Carmen valoró el micrófono con un 2
 - La desviación de tablet y microfono es 0,75
 - Solo dos personas valoraron (Olga y Aurora) la tablet y el micrófono $c_{j,i} = 2$
 - Por tanto $(dev_{j,i} + u_i)c_{j,i} = 5,5$
 - Se suma ambos valores y se obtiene 13,5
- *Denominador*
- Se tiene que ver cuantos artículos que Carmen ha valorado, sumar el cardinal de esos artículos, es decir, cuantos usuarios ha valorado ese articulo y el artículo a predecir. En este ejemplo, Carmen ha valorado auriculares, y el cardinal de auriculares y tablet (el número total de personas que han valorado ambos objetos) es 2.
 - Carmen ha valorado micrófono, y el cardinal es también 2.
 - Por tanto el denominador es 4.
- Por tanto, la predicción de la valoración de Carmen para la tablet sería de $\frac{13,5}{4} = 3,375$

CAPÍTULO 27

Diseñando Modelos

Entre las ramas de la ingeniería, los modelos tratan de capturar las mejores prácticas y soluciones a problemas que ocurren comúnmente. Para ello, codifican el conocimiento y la experiencia para que todos puedan seguir.

1. ¿Qué es un Modelo?

La idea de modelos fue introducida en el campo de la arquitectura por Christopher Alexander y cinco coautores en un libro enormemente influyente titulado *A Pattern Language* (Oxford University Press, 1977). En su libro, catalogan 253 modelos, presentándolos de esta manera:

Cada modelo describe un problema que ocurre una y otra vez en nuestro entorno, y luego describe el núcleo de la solución a ese problema, de tal manera que puede usar esta solución un millón de veces, sin tener que hacerlo de la misma manera dos veces.

Cada solución está planteada de tal manera que brinda el campo esencial de relaciones necesarias para resolver el problema, pero de una manera muy general y abstracta, para que pueda resolver el problema por sí mismo, a su manera, adaptándolo a sus preferencias y las condiciones locales en el lugar donde lo está haciendo.

Erich Gamma, Richard Helm, Ralph Johnson y John Vlissides llevaron la idea al software catalogando 23 modelos orientados a objetos en un libro de 1994 titulado *Design Patterns: Elements of Reusable Object-Oriented Software* (Addison-Wesley, 1995). Su catálogo incluye modelos como Proxy, Singleton y Decorator y tuvo un impacto duradero en el campo de la programación orientada a objetos. En 2005, la Association of Computing Machinery (ACM) otorgó su premio anual *Programming Languages Achievement Award* a los autores, reconociendo el impacto de su trabajo “en la práctica de programación y el diseño de lenguajes de programación”.

1.1. Terminología Machine Learning

Debido al gran boom de los profesionales del machine learning, en la actualidad pueden tener diferentes áreas de especialización primaria (ingeniería de software, análisis de datos, DevOps o estadísticas), puede haber diferencias sutiles en la forma en que los distintos profesionales utilizan ciertos términos. En esta sección, se definirá la terminología que se usará durante el curso.

1.2. Modelos y Frameworks

En esencia, el machine learning es un proceso de creación de modelos que aprenden de los datos. Esto contrasta con la programación tradicional donde se escriben reglas explícitas que le dicen a los programas cómo comportarse. Los modelos de machine learning son algoritmos que aprenden patrones a partir de los datos. Para ilustrar este punto, imagine que una tour operadora que se necesita estimar los costos de un viaje a *Granada* para los clientes potenciales. En la programación tradicional, podríamos resolver esto con una declaración if:

```
if num_habitaciones == 2 and
    num_entradas_museo == 2:
    estimacion = 1500
elif num_habitaciones == 3 and
    num_entradas_museo > 5:
    estimacion = 2500
```

Se puede imaginar cómo esto se complicará rápidamente a medida que se agreguen más variables (cantidad de noches que se hospedan, cantidad de camas extras por habitación, cantidad de comidas en el hotel, etc.) e intente manejar los casos extremos. Más concretamente, pedir toda esta información a los clientes con anticipación puede hacer que abandonen el proceso de estimación. En su lugar, podemos entrenar un modelo de machine learning para estimar los costos del viaje en función de los datos anteriores de los viajes anteriores a los que nuestra empresa ha contratado.

A lo largo del curso, se hará referencia a modelos de regresión lineal, árboles de decisión, modelos de agrupamiento y otros. Las redes neuronales de retroalimentación, que comúnmente acortaremos como redes neuronales, son un tipo de algoritmo de machine learning mediante el cual múltiples capas, cada una con muchas neuronas, analizan y procesan información y luego envían esa información a la siguiente capa, lo que da como resultado una capa final, que produce una predicción como salida. Aunque no son de ninguna manera idénticas, las redes neuronales a menudo se comparan con las neuronas de nuestro cerebro debido a la conectividad entre los nodos y la forma en que pueden generalizar y formar nuevas predicciones a partir de los datos que procesan. Las redes neuronales con más de una capa oculta (capas distintas de la capa de entrada y salida) se clasifican como deep learning

Por el contrario, las redes neuronales con solo una capa de entrada y salida son otro subconjunto del machine learning conocido como modelos lineales. Los modelos lineales representan los patrones que han aprendido de los datos mediante una función lineal. Los árboles de decisión son modelos de machine



Figura 27.1: Diferentes Tipos de Algoritmos de Machine Learning

learning que utilizan sus datos para crear un subconjunto de rutas con varias ramas. Estas ramas se aproximan a los resultados de diferentes resultados de sus datos. Finalmente, los modelos de agrupamiento buscan similitudes entre diferentes subconjuntos de sus datos y utilizan estos patrones identificados para agrupar los datos en grupos.

Los problemas de machine learning (consulte la figura 27.1) se pueden dividir en dos tipos: aprendizaje supervisado y no supervisado. El aprendizaje supervisado define los problemas en los que conoce de antemano la etiqueta de verdad básica de sus datos. Por ejemplo, esto podría incluir etiquetar una imagen como “gato” o etiquetar a un bebé como de 2,3 kg al nacer. Alimenta estos datos etiquetados a su modelo con la esperanza de que pueda aprender lo suficiente para etiquetar nuevos ejemplos. Con el aprendizaje no supervisado, no conoce las etiquetas de sus datos de antemano y el objetivo es crear un modelo que pueda encontrar agrupaciones naturales de sus datos (llamado agrupamiento), comprimir el contenido de la información (reducción de dimensionalidad) o encontrar reglas de asociación. La mayor parte de este libro se centrará en el

aprendizaje supervisado porque la gran mayoría de los modelos de aprendizaje automático que se utilizan en la producción están supervisados.

Con el aprendizaje supervisado, los problemas generalmente se pueden definir como clasificación o regresión. Los modelos de clasificación asignan a sus datos de entrada una etiqueta (o etiquetas) de un conjunto de categorías predefinido y discreto. Algunos ejemplos de problemas de clasificación incluyen determinar el tipo de raza de mascota en una imagen, etiquetar un documento o predecir si una transacción es fraudulenta o no. Los modelos de regresión asignan valores numéricos continuos a sus entradas. Los ejemplos de modelos de regresión incluyen la predicción de la duración de un viaje en bicicleta, los ingresos futuros de una empresa o el precio de un producto.

1.3. Ingeniería de datos y características

Los datos están en el centro de cualquier problema de machine learning. Cuando se habla de conjuntos de datos (datasets), se refiere a los datos que se utilizan para entrenar, validar y probar un modelo de machine learning. La mayor parte de sus datos serán datos de entrenamiento: los datos alimentados al modelo durante el proceso de entrenamiento. Los datos de validación son datos que se guardan del conjunto de entrenamiento y se utilizan para evaluar el rendimiento del modelo después de cada época de entrenamiento (o pasar a través de los datos de entrenamiento). El rendimiento del modelo en los datos de validación se utiliza para decidir cuándo detener la ejecución de entrenamiento y elegir hiperparámetros, como la cantidad de árboles en un modelo de random forest. Los datos de prueba son datos que no se utilizan en absoluto en el proceso de entrenamiento y se utilizan para evaluar cómo funciona el modelo entrenado. Los informes de rendimiento del modelo de aprendizaje automático deben calcularse sobre los datos de prueba independientes, en lugar de las pruebas de capacitación o validación. También es importante que los datos se dividan de tal manera que los tres conjuntos de datos (entrenamiento, prueba, validación) tengan propiedades estadísticas similares.

Los datos que usa para entrenar un modelo pueden tomar muchas formas dependiendo del tipo de modelo. Se define datos estructurados como datos numéricos y categóricos. Los datos numéricos incluyen valores enteros y “flotantes”, y los datos categóricos incluyen datos que se pueden dividir en un conjunto finito de grupos, como el tipo de automóvil o el nivel educativo. También se puede pensar en los datos estructurados como datos que normalmente encontrará en una hoja de cálculo. Los datos no estructurados, por otro lado, incluyen datos que no se pueden representar tan claramente. Por lo general, esto incluye texto, imágenes, video y audio de formato libre.

Los datos numéricos a menudo se pueden enviar directamente a un modelo de machine learning, donde otros datos requieren varios preprocesos de datos antes de que estén listos para enviarse a un modelo. Este paso de preprocesamiento generalmente incluye escalar valores numéricos o convertir datos no numéricos a un formato numérico que su modelo pueda entender. Otro término para preprocesamiento es ingeniería de características.

Hay varios términos que se utilizan para describir los datos a medida que pasan por el proceso de ingeniería de características. La entrada describe una sola columna en su conjunto de datos antes de que se haya procesado, y la función describe una sola columna después de que se haya procesado. Por ejemplo, una

marca de tiempo podría ser su entrada y la función sería el día de la semana. Para convertir los datos de la marca de tiempo al día de la semana, deberá realizar un procesamiento previo de los datos. Este paso de preprocesamiento también se puede denominar transformación de datos.

Una instancia o registro es un elemento descrito mediante vectores que gustaría enviar al modelo para la predicción. Una instancia podría ser una fila en su conjunto de datos de prueba (sin la columna de etiqueta), una imagen que desea clasificar o un documento de texto para enviar a un modelo de análisis de opiniones. Dado un conjunto de características sobre la instancia, el modelo calculará un valor predicho. Para hacer eso, el modelo se entrena en ejemplos de entrenamiento, que asocian una instancia con una etiqueta. Un ejemplo de entrenamiento se refiere a una sola instancia (fila) de datos de su conjunto de datos que se enviará a su modelo. Sobre la base del caso de uso de la marca de tiempo, un ejemplo de capacitación completo podría incluir: “día de la semana”, “ciudad” y “tipo de automóvil”. Una etiqueta es la columna de salida en su conjunto de datos, el elemento que predice su modelo. La etiqueta puede referirse tanto a la columna de destino en su conjunto de datos (también llamada etiqueta de verdad del terreno) como a la salida proporcionada por su modelo (también llamada predicción). Una etiqueta de muestra para el ejemplo de capacitación descrito anteriormente podría ser “duración del viaje”, en este caso, un valor flotante que denota minutos.

Una vez que se haya reunido un conjunto de datos y determinado las características del modelo, la validación de datos es el proceso de realizar cálculos estadísticos en los datos, comprender su esquema y evaluar el conjunto de datos para identificar problemas como la desviación y la desviación de la entrega de entrenamiento. La evaluación de varios cálculos estadísticos sobre los datos puede ayudar a garantizar que el conjunto de datos contenga una representación equilibrada de cada característica. En los casos en los que no sea posible recopilar más datos, comprender el equilibrio de datos ayudará a diseñar un modelo para tener en cuenta esto. Comprender su esquema implica definir el tipo de datos para cada característica e identificar ejemplos de entrenamiento donde ciertos valores pueden faltar o ser incorrectos. Finalmente, la validación de datos puede identificar inconsistencias que pueden afectar la calidad del entrenamiento y conjuntos de prueba. Por ejemplo, tal vez la mayoría del conjunto de datos de entrenamiento contenga ejemplos de días de semana, mientras que el conjunto de prueba contiene principalmente ejemplos de fin de semana.

2. El Proceso de Machine Learning

El primer paso en un flujo de trabajo de machine learning típico es el entrenamiento: el proceso de pasar datos de entrenamiento a un modelo para que pueda aprender a identificar patrones. Después del entrenamiento, el siguiente paso del proceso es probar el rendimiento de su modelo en datos fuera del conjunto de entrenamiento. Esto se conoce como evaluación de modelos. Puede ejecutar la capacitación y evaluación varias veces, realizar ingeniería de funciones adicionales y ajustar la arquitectura de su modelo. Una vez que se esté satisfecho con el rendimiento del modelo durante la evaluación, es probable que se desee entregar el modelo para que otros puedan acceder a él para hacer predicciones. Usamos el término servir para referirnos a aceptar solicitudes

entrantes y enviar predicciones mediante la implementación del modelo como un microservicio. La infraestructura de servicio puede estar en la nube, en las instalaciones o en el dispositivo.

El proceso de enviar nuevos datos al modelo y hacer uso de su salida se llama predicción. Esto puede referirse tanto a la generación de predicciones a partir de modelos locales que aún no se han implementado como a la obtención de predicciones a partir de modelos implementados. Para los modelos implementados, nos referiremos a la predicción en línea y por lotes.

La predicción en línea se utiliza cuando se desea obtener predicciones sobre algunos ejemplos casi en tiempo real. Con la predicción en línea, el énfasis está en la baja latencia.

La predicción por lotes, por otro lado, se refiere a generar predicciones en un gran conjunto de datos fuera de línea. Los trabajos de predicción por lotes toman más tiempo que la predicción en línea y son útiles para precalcular predicciones (como en los sistemas de recomendación) y para analizar las predicciones de su modelo en una gran muestra de datos nuevos.

La palabra predicción es adecuada cuando se trata de pronosticar valores futuros, como para predecir la duración de un paseo en bicicleta o predecir si se abandonará un carrito de compras. Es menos intuitivo en el caso de modelos de clasificación de imágenes y texto. Si un modelo de machine learning analiza una revisión de texto y da como resultado que el sentimiento es positivo, no es realmente una “predicción” (no hay un resultado futuro). Por lo tanto, también se verá que se usa la inferencia de palabras para referirse a las predicciones. El término estadístico inferencia se está reutilizando aquí, pero en realidad no se trata de razonamiento.

A menudo, los procesos de recopilación de datos de entrenamiento, ingeniería de funciones, capacitación y evaluación de un modelo se manejan por separado del proceso de producción. Cuando este sea el caso, se reevaluará la solución siempre que se decida que tiene suficientes datos adicionales para entrenar una nueva versión del modelo. En otras situaciones, es posible que se ingieran nuevos datos de forma continua y se deba procesar estos datos inmediatamente antes de enviarlos al modelo para entrenamiento o predicción. Esto se conoce como transmisión. Para manejar datos de transmisión, se necesitará una solución de varios pasos para realizar ingeniería de funciones, capacitación, evaluación y predicciones. Estas soluciones de varios pasos se denominan canalizaciones de machine learning.

2.1. Roles

Dentro de una organización, hay muchos roles de trabajo diferentes relacionados con los datos y el machine learning. A continuación, definiremos algunos de los más comunes a los que se hace referencia con frecuencia.

Un científico de datos es alguien que se centra en recopilar, interpretar y procesar conjuntos de datos. Ejecutan análisis estadístico y exploratorio de datos. En lo que respecta al machine learning, un científico de datos puede trabajar en la recopilación de datos, la ingeniería de características, la creación de modelos y más. Los científicos de datos a menudo trabajan en Python o R

en un entorno de notebook y, por lo general, son los primeros en desarrollar los modelos de machine learning de una organización.

Un ingeniero de datos se centra en la infraestructura y los flujos de trabajo que impulsan los datos de una organización. Pueden ayudar a administrar cómo una empresa ingiere datos, canalizaciones de datos y cómo se almacenan y transfieren los datos. Los ingenieros de datos implementan infraestructura y canalizaciones alrededor de los datos.

Los ingenieros de machine learning realizan tareas similares a las de los ingenieros de datos, pero para los modelos de machine learning. Toman modelos desarrollados por científicos de datos y administran la infraestructura y las operaciones en torno al entrenamiento y la implementación de esos modelos. Los ingenieros de machine learning ayudan a crear sistemas de producción para gestionar la actualización de modelos, el control de versiones de modelos y la entrega de predicciones a los usuarios finales.

Cuanto más pequeño es el equipo de ciencia de datos de una empresa y más ágil es, más probable es que la misma persona desempeñe múltiples roles. Por lo general, se puede comenzar un proyecto de machine learning como ingeniero de datos y crear canalizaciones de datos para poner en funcionamiento la ingesta de datos. Luego, se pasa al rol de científico de datos y crea los modelos de machine learning. Finalmente, como ingeniero de machine learning y se traslada el modelo a producción. En organizaciones más grandes, los proyectos de machine learning pueden pasar por las mismas fases, pero es posible que diferentes equipos participen en cada fase.

Los científicos de investigación, los analistas de datos y los desarrolladores también pueden crear y utilizar modelos de IA.

Los científicos de investigación se centran principalmente en encontrar y desarrollar nuevos algoritmos para avanzar en la disciplina del machine learning. Esto podría incluir una variedad de subcampos dentro del machine learning, como arquitecturas de modelos, procesamiento del lenguaje natural, visión por computadora, ajuste de hiperparámetros, interpretabilidad de modelos y más. A diferencia de los otros roles discutidos aquí, los científicos de investigación pasan la mayor parte de su tiempo creando prototipos y evaluando nuevos enfoques para machine learning, en lugar de desarrollar sistemas de machine learning de producción.

Los analistas de datos evalúan y recopilan información a partir de los datos, luego resumen esta información para otros equipos dentro de su organización. Suelen trabajar en SQL y hojas de cálculo, y utilizan herramientas de inteligencia empresarial para crear visualizaciones de datos para compartir sus hallazgos. Los analistas de datos trabajan en estrecha colaboración con los equipos de productos para comprender cómo sus conocimientos pueden ayudar a abordar los problemas comerciales y crear valor. Mientras que los analistas de datos se centran en identificar tendencias en los datos existentes y obtener conocimientos de ellos, los científicos de datos se preocupan por utilizar esos datos para generar predicciones futuras y automatizar o ampliar la generación de conocimientos. Con la creciente democratización del machine learning, los analistas de datos pueden mejorar sus habilidades para convertirse en científicos de datos.

Los desarrolladores están a cargo de crear sistemas de producción que permitan a los usuarios finales acceder a los modelos de machine learning. A menudo participan en el diseño de API que consultan modelos y devuelven

predicciones en un formato fácil de usar a través de una aplicación web o móvil. Esto podría involucrar modelos alojados en la nube o modelos servidos en el dispositivo. Los desarrolladores utilizan la infraestructura de servicio de modelos implementada por los ingenieros de machine learning para crear aplicaciones e interfaces de usuario para mostrar predicciones a los usuarios del modelo.

3. Desafíos Comunes en el Machine Learning

El proceso de construcción de sistemas de machine learning presenta una variedad de desafíos únicos que influyen en el diseño del machine learning. Comprender estos desafíos ayudará a desarrollar un marco de referencia para las soluciones presentadas a lo largo del libro.

3.1. Calidad del Dato

Los modelos de machine learning son tan confiables como los datos utilizados para entrenarlos. Si se entrena un modelo de machine learning en un conjunto de datos incompleto, con características mal seleccionadas o que no representan con precisión la población que usa el modelo, las predicciones del modelo serán un reflejo directo de esos datos. Como resultado, los modelos de machine learning a menudo se denominan “basura que entra, basura sale”. A continuación, se destacan cuatro componentes importantes de la calidad de los datos: precisión, integridad, coherencia y puntualidad.

Precisión

La precisión de los datos se refiere tanto a las características de los datos de entrenamiento como a las etiquetas de verdad del terreno correspondientes a esas características. Comprender de dónde provienen los datos y cualquier error potencial en el proceso de recopilación de datos puede ayudar a garantizar la precisión de las funciones. Una vez que se hayan recopilado los datos, es importante realizar un análisis exhaustivo para detectar errores tipográficos, entradas duplicadas, inconsistencias de medición en los datos tabulares, características faltantes y cualquier otro error que pueda afectar la calidad de los datos. Los duplicados en su conjunto de datos de entrenamiento, por ejemplo, pueden hacer que su modelo asigne incorrectamente más peso a estos puntos de datos.

Las etiquetas de datos precisas son tan importantes como la precisión de las funciones. El modelo se basa únicamente en las etiquetas de verdad del terreno en los datos de entrenamiento para actualizar sus pesos y minimizar la pérdida. Como resultado, los ejemplos de entrenamiento etiquetados incorrectamente pueden causar una precisión de modelo engañosa. Por ejemplo, se está creando un modelo de análisis de sentimientos y el 25 % de los ejemplos de entrenamiento “positivos” se han etiquetado incorrectamente como “negativos”. El modelo tendrá una imagen inexacta de lo que debería considerarse sentimiento negativo, y esto se reflejará directamente en las predicciones.

Integridad

Para comprender la integridad de los datos, supongamos que está entrenando un modelo para identificar razas de gatos. Entrena el modelo en un extenso conjunto de datos de imágenes de gatos y el modelo resultante puede clasificar las imágenes en 1 de 10 categorías posibles (“Bengala”, “Siamés”, etc.) con un 99 % de precisión. Sin embargo, cuando se implementa el modelo en producción, se descubre que, además de cargar fotos de gatos para su clasificación, muchos de los usuarios están cargando fotos de perros y están decepcionados con los resultados del modelo. Debido a que el modelo fue entrenado solo para identificar 10 razas de gatos diferentes, esto es todo lo que sabe hacer. Estas 10 categorías de razas son, esencialmente, la “visión del mundo” completa del modelo. No importa lo que se envíe el modelo, puede esperar que lo coloque en una de estas 10 categorías. Incluso puede hacerlo con mucha confianza para una imagen que no se parece en nada a un gato. Además, no hay forma de que el modelo pueda devolver “no es un gato” si estos datos y etiqueta no se incluyeron en el conjunto de datos de entrenamiento.

Otro aspecto de la integridad de los datos es garantizar que los datos de entrenamiento contengan una representación variada de cada etiqueta. En el ejemplo de detección de razas de gatos, si todas las imágenes son primeros planos de la cara de un gato, el modelo no podrá identificar correctamente una imagen de un gato desde un lado o una imagen de gato de cuerpo completo. Para ver un ejemplo de datos tabulares, si se está creando un modelo para predecir el precio de un inmueble en una ciudad específica, pero solo incluye ejemplos de capacitación de casas de más de 2000 metros cuadrados, el modelo resultante tendrá un desempeño deficiente en casas más pequeñas.

Consistencia

El tercer aspecto de la calidad de los datos es la coherencia de los datos. Para grandes conjuntos de datos, es común dividir el trabajo de recopilación y etiquetado de datos entre un grupo de personas. Desarrollar un conjunto de estándares para este proceso puede ayudar a garantizar la coherencia en su conjunto de datos, ya que cada persona involucrada en esto inevitablemente traerá sus propios sesgos al proceso. Al igual que la integridad de los datos, las incoherencias de datos se pueden encontrar tanto en las características como en las etiquetas de los datos. Para ver un ejemplo de características inconsistentes, supongamos que está recopilando datos atmosféricos de sensores de temperatura. Si cada sensor ha sido calibrado con diferentes estándares, esto resultará en predicciones de modelos inexactas y poco confiables. Las inconsistencias también pueden referirse al formato de los datos. Si está capturando datos de ubicación, algunas personas pueden escribir una dirección postal completa como “Avenida de” y otras pueden abreviarla como “Av”. Las unidades de medida, como millas y kilómetros, también pueden diferir en todo el mundo.

En lo que respecta a las inconsistencias de etiquetado, como se vio en el ejemplo de sentimiento de texto. En este caso, es probable que las personas no siempre estén de acuerdo en lo que se considera positivo y negativo al etiquetar los datos de entrenamiento. Para resolver esto, se puede hacer que varias personas etiqueten cada ejemplo en su conjunto de datos, luego tome

la etiqueta aplicada con más frecuencia para cada elemento. Ser consciente del sesgo potencial del etiquetador e implementar sistemas para tenerlo en cuenta garantizará la coherencia de las etiquetas en todo su conjunto de datos.

Puntualidad

La puntualidad en los datos se refiere a la latencia entre el momento en que ocurrió un evento y el momento en que se agregó a su base de datos. Si se está recopilando datos en registros de aplicaciones, por ejemplo, es posible que un registro de errores tarde unas horas en aparecer en su base de datos de registros. Para un conjunto de datos que registra transacciones con tarjeta de crédito, puede pasar un día desde que ocurrió la transacción antes de que se informe en su sistema. Para lidiar con la puntualidad, es útil registrar la mayor cantidad de información posible sobre un punto de datos en particular y asegurarse de que la información se refleje cuando transforma sus datos en funciones para un modelo de machine learning. Más específicamente, se puede realizar un seguimiento de la marca de tiempo de cuándo ocurrió un evento y cuándo se agregó a su conjunto de datos. Luego, al realizar la ingeniería de funciones, puede tener en cuenta estas diferencias en consecuencia.

3.2. Reproducibilidad

En la programación tradicional, la salida de un programa es reproducible y garantizada. Por ejemplo, si escribe un programa de Python que invierte una cadena, sabe que una entrada de la palabra “banana” siempre devolverá una salida de “ananab”. De manera similar, si hay un error en su programa que hace que invierta incorrectamente cadenas que contienen números, puede enviar el programa a otra persona y esperar que pueda reproducir el error con las mismas entradas que utilizó (a menos que el error tenga algo que ver con el programa manteniendo algún estado interno incorrecto, diferencias en la arquitectura como la precisión del punto flotante o diferencias en la ejecución como el subprocesamiento).

Los modelos de machine learning, por otro lado, tienen un elemento inherente de aleatoriedad. Durante el entrenamiento, las ponderaciones del modelo machine learning se inicializan con valores aleatorios. Estos pesos luego convergen durante el entrenamiento a medida que el modelo itera y aprende de los datos. Debido a esto, el mismo código de modelo con los mismos datos de entrenamiento producirá resultados ligeramente diferentes entre las ejecuciones de entrenamiento. Esto presenta un desafío de reproducibilidad. Si se entrena un modelo con una precisión del 98,1 %, no se garantiza que una ejecución de entrenamiento repetida alcance el mismo resultado. Esto puede dificultar la realización de comparaciones entre experimentos.

El entrenamiento de un modelo de machine learning implica varios artefactos que deben corregirse para garantizar la reproducibilidad: los datos utilizados, el mecanismo de división utilizado para generar conjuntos de datos para el entrenamiento y la validación, la preparación de datos y los hiperparámetros del modelo, y variables como el tamaño del lote y la programación de la tasa de aprendizaje.

La reproducibilidad también se aplica a las dependencias del marco de machine learning. Además de establecer manualmente una semilla aleatoria,

los marcos también implementan elementos de aleatoriedad internamente que se ejecutan cuando se llama a una función para entrenar tu modelo. Si esta implementación subyacente cambia entre diferentes versiones del marco, no se garantiza la repetibilidad.

Finalmente, la reproducibilidad puede referirse al entorno de entrenamiento de un modelo. A menudo, debido a los grandes conjuntos de datos y la complejidad, muchos modelos requieren una cantidad significativa de tiempo para entrenarse. Esto puede acelerarse empleando estrategias de distribución como datos o paralelismo de modelos. Sin embargo, con esta aceleración, se presenta un desafío adicional de repetibilidad cuando se vuelve a ejecutar el código que hace uso del entrenamiento distribuido.

3.3. La Deriva de los Datos

Si bien los modelos de machine learning generalmente representan una relación estática entre entradas y salidas, los datos pueden cambiar significativamente con el tiempo. La deriva de los datos se refiere al desafío de garantizar que los modelos de machine learning sigan siendo relevantes y que las predicciones del modelo sean un reflejo preciso del entorno en el que se utilizan.

Por ejemplo, supongamos que se está entrenando un modelo para clasificar los titulares de artículos de noticias en categorías como “política”, “negocios” y “tecnología”. Si se entrena y evalúa el modelo en artículos de noticias históricos del siglo XX, es probable que no funcione tan bien con los datos actuales. Hoy en día, sabemos que un artículo con la palabra “teléfono inteligente” en el título probablemente sea sobre tecnología. Sin embargo, un modelo entrenado con datos históricos no tendría conocimiento de esta palabra. Para solucionar la deriva, es importante actualizar continuamente su conjunto de datos de entrenamiento, volver a entrenar el modelo y modificar el peso que su modelo asigna a grupos particulares de datos de entrada.

3.4. Escala

El desafío de escala está presente en muchas etapas de un flujo de trabajo típico de machine learning. Es probable que se encuentre desafíos de escalado en la recopilación y preprocesamiento, capacitación y servicio de datos. Al ingerir y preparar datos para un modelo de machine learning, el tamaño del conjunto de datos determinará las herramientas necesarias para su solución. A menudo, el trabajo de los ingenieros de datos es construir canalizaciones de datos que puedan reescalar para manejar conjuntos de datos con millones de filas.

Para el entrenamiento de modelos, los ingenieros de machine learning son responsables de determinar la infraestructura necesaria para un trabajo de entrenamiento específico. Dependiendo del tipo y tamaño del conjunto de datos, el entrenamiento del modelo puede llevar mucho tiempo y ser computacionalmente costoso, requiriendo infraestructura (como GPU) diseñada específicamente para cargas de trabajo de machine learning. Los modelos de imagen, por ejemplo, normalmente requieren mucha más infraestructura de entrenamiento que los modelos entrenados completamente en datos tabulares.

En el contexto del servicio de modelos, la infraestructura necesaria para respaldar a un equipo de científicos de datos que obtienen predicciones de un

prototipo de modelo es completamente diferente de la infraestructura necesaria para respaldar un modelo de producción que recibe millones de solicitudes de predicción cada hora. Los desarrolladores e ingenieros de machine learning suelen ser responsables de manejar los desafíos de escala asociados con la implementación del modelo y atender las solicitudes de predicción.

3.5. Múltiples Objetivos

Aunque a menudo hay un solo equipo responsable de crear un modelo de machine learning, muchos equipos de una organización utilizarán el modelo de alguna manera. Inevitablemente, estos equipos pueden tener diferentes ideas sobre lo que define un modelo exitoso.

Para comprender cómo puede funcionar esto en la práctica, supongamos que se está creando un modelo para identificar productos defectuosos a partir de imágenes. Como científico de datos, el objetivo puede ser minimizar la pérdida de entropía cruzada de su modelo. El gerente de producto, por otro lado, puede querer reducir la cantidad de productos defectuosos que se clasifican erróneamente y se envían a los clientes. Por último, el objetivo del equipo ejecutivo podría ser aumentar los ingresos en un 30%. Cada uno de estos objetivos varía en lo que se está optimizando, y equilibrar estas diferentes necesidades dentro de una organización puede presentar un desafío.

Como científico de datos, se podría traducir las necesidades del equipo de producto en el contexto de el modelo diciendo que los falsos negativos son cinco veces más costosos que los falsos positivos. Por lo tanto, se debe optimizar la recuperación sobre la precisión para satisfacer esto al diseñar su modelo. Luego, se puede encontrar un equilibrio entre el objetivo del equipo de producto de optimizar la precisión y el objetivo de minimizar la pérdida del modelo.

Al definir los objetivos del modelo, es importante considerar las necesidades de los diferentes equipos en una organización y cómo las necesidades de cada equipo se relacionan con el modelo. Al analizar para qué está optimizando cada equipo antes de construir la solución, se puede encontrar áreas de compromiso para equilibrar de manera óptima estos múltiples objetivos.

4. Primera Aplicación: Clasificación Especies de Iris

En esta sección, se calculará una aplicación de machine learning simple y se creará un primer modelo. En el proceso, se presentará algunos conceptos y términos básicos.

Supóngase que un botánico aficionado está interesado en distinguir las especies de algunas flores de iris que ha encontrado. Ha recopilado algunas medidas asociadas con cada iris: el largo y ancho de los pétalos y el largo y ancho de los sépalos, todos medidos en centímetros.

También tiene las medidas de algunos lirios que han sido previamente identificados por un botánico experto como pertenecientes a las especies setosa, versicolor o virginica. Para estas medidas, puede estar segura de a qué especie pertenece cada iris. Supóngase que estas son las únicas especies que el botánico aficionado encontrará en la naturaleza.

El objetivo es construir un modelo de machine learning que pueda aprender de las medidas de estos lirios cuya especie se conoce, de modo que se pueda predecir la especie para un nuevo iris.

4.1. Conociendo los Datos

El dataset que se utilizará para este ejemplo sera el dataset de Iris, un clásico dataset en machine learning y estadística. Está incluido en *scikit-learn* en el módulo de *dataset*

```
from sklearn.datasets import load_iris
iris_dataset = load_iris()
```

4.2. k-Nearest Neighbors

Hay muchos algoritmos de clasificación en *scikit-learn* que pueden usar. El clasificador de k vecinos más cercanos, es fácil de entender. La construcción de este modelo solo consiste en almacenar el conjunto de entrenamiento. Para hacer una predicción para un nuevo punto de datos, el algoritmo encuentra el punto en el conjunto de entrenamiento que está más cerca del nuevo punto. Luego, asigna la etiqueta de este punto de entrenamiento al nuevo punto de datos.

Todos los modelos de machine learning en *scikit-learn* se implementan en sus propias clases, que se denominan clases Estimator. El algoritmo de clasificación de los k vecinos más cercanos se implementa en la clase *KNeighborsClassifier* en el módulo de vecinos. Antes de que se pueda usar el modelo, se necesita crear una instancia de la clase en un objeto. Aquí es cuando se establece los parámetros del modelo. El parámetro más importante de *KNeighborsClassifier* es el número de vecinos, que es establecé en 1:

```
from sklearn.neighbors
import KNeighborsClassifier
knn = KNeighborsClassifier(n_neighbors=1)
```

El objeto *knn* encapsula el algoritmo que se utilizará para construir el modelo a partir de los datos de entrenamiento, así como el algoritmo para hacer predicciones sobre nuevos puntos de datos. También contendrá la información que el algoritmo ha extraído de los datos de entrenamiento. En el caso de *KNeighborsClassifier*, solo almacenará el conjunto de entrenamiento.

Datos de Entrenamiento y Test

Si se Quiere construir un modelo de machine learning a partir de estos datos que pueda predecir las especies de iris para un nuevo conjunto de medidas. Pero antes de que se pueda aplicar el modelo a nuevas medidas, se necesitará saber si realmente funciona, es decir, si se debe confiar en sus predicciones.

Desafortunadamente, no se puede usar los datos que se usa para construir el modelo para evaluarlo. Esto se debe a que el modelo siempre puede recordar todo el conjunto de entrenamiento y, por lo tanto, siempre predecirá la etiqueta correcta para cualquier punto del conjunto de entrenamiento. Este “recordar” no indica si el modelo se generalizará bien (en otras palabras, si también funcionará bien en nuevos datos).

4. PRIMERA APLICACIÓN: CLASIFICACIÓN ESPECIES DE IRIS

Para evaluar el rendimiento del modelo, se le mostrará nuevos datos (datos que no ha visto antes) para los que se tenga etiquetas. Esto generalmente se hace dividiendo los datos etiquetados que se ha recopilado (aquí, las 150 medidas de flores) en dos partes. Una parte de los datos se utiliza para construir el modelo de machine learning y se denomina datos de entrenamiento o conjunto de entrenamiento. El resto de los datos se utilizará para evaluar qué tan bien funciona el modelo; esto se denomina datos de prueba, conjunto de prueba o conjunto de reserva.

scikit-learn contiene una función que mezcla el conjunto de datos y lo divide: la función *train_test_split*. Esta función extrae el 75 % de las filas de los datos como conjunto de entrenamiento, junto con las etiquetas correspondientes para estos datos. El 25 % restante de los datos, junto con las etiquetas restantes, se declara como conjunto de prueba. Decidir cuántos datos se desea poner en el entrenamiento y el conjunto de prueba respectivamente es algo arbitrario, pero usar un conjunto de prueba que contenga el 25 % de los datos es una buena regla general.

En *scikit-learn*, los datos generalmente se indican con una X mayúscula, mientras que las etiquetas se indican con una y minúscula. Esto está inspirado en la formulación estándar $f(x) = y$ en matemáticas, donde x es la entrada a una función e y es la salida. Siguiendo más convenciones de las matemáticas, usamos una X mayúscula porque los datos son una matriz bidimensional (una matriz) y una y minúscula porque el objetivo es una matriz unidimensional (un vector).

Se utilizará *train_test_split* en los datos y se asignará las salidas usando esta nomenclatura:

```
from sklearn.datasets import load_iris
from sklearn.model_selection
    import train_test_split
iris_dataset = load_iris()
X_train, X_test, y_train, y_test =
    train_test_split(
        iris_dataset['data'],
        iris_dataset['target'],
        random_state=0)
```

Antes de realizar la división, la función *train_test_split* baraja el conjunto de datos utilizando un generador de números pseudoaleatorios. Si se toma el último 25 % de los datos como un conjunto de prueba, todos los puntos de datos tendrían la etiqueta 2, ya que los puntos de datos están ordenados por la etiqueta. El uso de un conjunto de test que contenga solo una de las tres clases no dirá mucho sobre qué tan bien se generaliza el modelo, por lo que se mezclan los datos para asegurar que los datos de test contengan datos de todas las clases.

Para asegurar que se obtiene el mismo resultado si se ejecuta la misma función varias veces, se proporcionará al generador de números pseudoaleatorios una semilla fija usando el parámetro *random_state*. Esto hará que el resultado sea determinista, por lo que esta línea siempre tendrá el mismo resultado. Siempre se arreglara *random_state* de esta manera cuando se use procedimientos aleatorios.

La salida de la función *train_test_split* es X_train, X_test, y_train y y_test, que son todas matrices *NumPy*. X_train contiene el 75 % de las filas del conjunto

de datos y `X_test` contiene el 25 % restante:

```
print("X_train forma:", X_train.shape)
print("y_train forma:", y_train.shape)
print("X_test forma:", X_test.shape)
print("y_test forma:", y_test.shape)
```

Construcción del Modelo

Para construir el modelo en el conjunto de entrenamiento, se llama al método de ajuste del objeto *knn*, que toma como argumentos la matriz `X_train` que contiene los datos de entrenamiento y la matriz `y_train` de las etiquetas de entrenamiento correspondientes:

```
knn.fit(X_train, y_train)
```

```
KNeighborsClassifier(algorithm='auto',
leaf_size=30, metric='minkowski',
                    metric_params=None, n_jobs=
None, n_neighbors=1, p=2,
                    weights='uniform')
```

el método *fit* que devuelve el objeto *knn* en sí (y lo modifica en su lugar), por lo que se obtiene una representación de cadena del clasificador. La representación 4.2 muestra qué parámetros se utilizaron para crear el modelo. Casi todos ellos son los valores predeterminados, pero también se puede encontrar `n_neighbors = 1`, que es el parámetro que se ha pasado. La mayoría de los modelos en *scikit-learn* tienen muchos parámetros, pero la mayoría de ellos son optimizaciones de velocidad o para casos de uso muy especiales. No hay que preocuparse por los otros parámetros que se muestran en esta representación.

Haciendo Predicciones

Ahora se puede hacer predicciones utilizando este modelo en datos nuevos para los que es posible que no se conozca las etiquetas correctas. Imagine que se encuentra un iris en la naturaleza con una longitud de sépalo de 5 cm, un ancho de sépalo de 2,9 cm, una longitud de pétalo de 1 cm y un ancho de pétalo de 0,2 cm. ¿Qué especie de iris sería este? Se puede poner estos datos en una matriz *NumPy*, nuevamente calculando la forma, es decir, el número de muestras (1) multiplicado por el número de características (4):

```
X_new = np.array([[5, 2.9, 1, 0.2]])
print("X_new.shape:", X_new.shape)
```

Se tiene que tener en cuenta que se hizo las medidas de esta única flor en una fila en una matriz *NumPy* bidimensional, ya que *scikit-learn* siempre espera matrices bidimensionales para los datos.

Para hacer una predicción, se llama al método de predicción del objeto *knn*:

4. PRIMERA APLICACIÓN: CLASIFICACIÓN ESPECIES DE IRIS

```
prediction = knn.predict(X_new)
print("Prediction:", prediction)
print("Predicted target name:",
      iris_dataset['target_names'][prediction])
```

```
Prediction: [0]
Predicted target name: ['setosa']
```

El modelo predice que este nuevo iris pertenece a la clase 0, lo que significa que su especie es setosa. Pero, ¿cómo se sabe si se puede confiar en el modelo? No se conoce la especie correcta de esta muestra.

Evaluación del Modelo

Aquí es donde entra en juego el conjunto de test que se creó anteriormente. Estos datos no se utilizaron para construir el modelo, pero se sabe cuál es la especie correcta para cada iris en el conjunto de test.

Por lo tanto, se puede hacer una predicción para cada iris en los datos de test y compararlo con su etiqueta (la especie conocida). Se puede medir qué tan bien funciona el modelo calculando la precisión, que es la fracción de flores para las que se predijo la especie correcta:

```
y_pred = knn.predict(X_test)
print("predicciones conjunto test:\n",
      y_pred)
```

```
predicciones conjunto test:
[2 1 0 2 0 2 0 1 1 1 2 1 1 1 0 1 1
 0 0 2 1 0 0 2 0 0 1 1 0 2 1 0 2 2 1 0
 2]
```

```
print("Puntacion conjunto test: {:.2f}".
      format(np.mean(y_pred == y_test)))
```

```
Puntacion conjunto test: 0.97
```

También se puede usar el método de puntuación del objeto knn, que calculará la precisión del conjunto test:

```
print("Puntacion conjunto test: {:.2f}".
      format(knn.score(X_test, y_test)))
```

```
Puntacion conjunto test: 0.97
```

Para este modelo, la precisión del conjunto test es de aproximadamente 0,97, lo que significa que se hizo la predicción correcta para el 97 % de los iris en el conjunto test. Bajo algunos supuestos matemáticos, esto significa que se puede esperar que el modelo sea correcto el 97 % del tiempo para iris nuevos. Para las aplicación de botánicos aficionados, este alto nivel de precisión significa que el modelo puede ser lo suficientemente confiable para su uso. En capítulos posteriores se analizará cómo se puede mejorar el rendimiento y qué advertencias existen al ajustar un modelo.

4. PRIMERA APLICACIÓN: CLASIFICACIÓN ESPECIES DE IRIS

CAPÍTULO 28

Aprendizaje Supervisado

Como se mencionó anteriormente, el aprendizaje supervisado es uno de los tipos de machine learning más utilizados y exitosos. En este capítulo, se describe el aprendizaje supervisado con más detalle y se explicará varios algoritmos populares de aprendizaje supervisado.

Hay que recordar que el aprendizaje supervisado se usa siempre que se quiere predecir un resultado determinado a partir de una entrada determinada, y se tiene como ejemplos de pares de entrada / salida. Se Construye un modelo de machine learning a partir de estos pares de entrada / salida, que componen el conjunto de entrenamiento. El objetivo es realizar predicciones precisas para datos nuevos y nunca antes vistos. El aprendizaje supervisado a menudo requiere un esfuerzo humano para construir el conjunto de capacitación, pero luego se automatiza y, a menudo, acelera una tarea que de otro modo sería laboriosa o inviable.

1. Clasificación y Regresión

Hay dos tipos principales de problemas de aprendizaje automático supervisados, denominados clasificación y regresión.

En la clasificación, el objetivo es predecir una etiqueta de clase, que es una elección de una lista predefinida de posibilidades. La clasificación a veces se divide en clasificación binaria, que es el caso especial de distinguir exactamente entre dos clases, y clasificación multiclase, que es la clasificación entre más de dos clases. Se puede pensar en la clasificación binaria como un intento de responder a una pregunta de sí o no. La clasificación de los correos electrónicos como spam o no spam es un ejemplo de un problema de clasificación binaria. En esta tarea de clasificación binaria, la pregunta de sí / no sería “¿Este correo electrónico es spam?”

Observación 28.1 *En la clasificación binaria, a menudo hablamos de que una clase es la clase positiva y la otra clase es la clase negativa. Aquí, positivo no representa tener beneficio o valor, sino cuál es el objeto del estudio. Por lo*

2. GENERALIZACIÓN, OVERFITTING, Y UNDERFITTING

tanto, al buscar spam, "positivo" podría significar la clase de spam.Cuál de las dos clases se llama positivo es a menudo un asunto subjetivo y específico del dominio.

El ejemplo del iris, por otro lado, es un ejemplo de un problema de clasificación multiclase. Otro ejemplo es predecir en qué idioma está un sitio web a partir del texto del sitio web. Las clases aquí serían una lista predefinida de posibles idiomas.

Para las tareas de regresión, el objetivo es predecir un número continuo o un número de punto flotante en términos de programación (o un número real en términos matemáticos). Predecir los ingresos anuales de una persona a partir de su educación, su edad y el lugar donde vive es un ejemplo de una tarea de regresión. Al predecir ingresos, el valor predicho es una cantidad y puede ser cualquier número en un rango dado. Otro ejemplo de una tarea de regresión es predecir el rendimiento de una granja de maíz dados atributos como rendimientos anteriores, clima y número de empleados que trabajan en la granja. El rendimiento nuevamente puede ser un número arbitrario.

Una forma fácil de distinguir entre tareas de clasificación y regresión es preguntarse si existe algún tipo de continuidad en el resultado. Si hay continuidad entre los posibles resultados, entonces el problema es un problema de regresión. Piense en predecir los ingresos anuales. Hay una clara continuidad en la salida. El hecho de que una persona gane 40 000\$ o 40 001\$ al año no significa una diferencia tangible, aunque se trate de cantidades de dinero diferentes; si nuestro algoritmo predice 39,999\$ o 40,001\$ cuando debería haber predicho 40,000\$, no importa mucho.

2. Generalización, Overfitting, y Underfitting

En el aprendizaje supervisado, se quiere construir un modelo a partir de los datos de entrenamiento y luego poder hacer predicciones precisas sobre datos nuevos y no vistos que tengan las mismas características que el conjunto de entrenamiento que se usa. Si un modelo es capaz de hacer predicciones precisas sobre datos invisibles, decimos que puede generalizar desde el conjunto de entrenamiento al conjunto de prueba. Se quiere construir un modelo que pueda generalizar con la mayor precisión posible.

Por lo general, se construye un modelo de tal manera que pueda hacer predicciones precisas sobre el conjunto de entrenamiento. Si los conjuntos de entrenamiento y test tienen suficiente en común, se espera que el modelo también sea preciso en el conjunto de test. Sin embargo, hay algunos casos en los que esto puede salir mal. Por ejemplo, si se construyen modelos muy complejos, siempre se puede ser tan precisos como se quiera en el conjunto de entrenamiento.

Ejemplo 28.1 *Supóngase que un científico de datos novato quiere predecir si un cliente comprará un barco. Dados los registros de compradores anteriores de barcos, se sabe que clientes están interesados en comprar un barco. El objetivo es enviar correos electrónicos promocionales a las personas que probablemente realice una compra, pero no moleste a los clientes que no estarán interesados.*

Supóngase que los registros de clientes se muestran en la tabla 28.1

Después de observar los datos durante un tiempo, el científico de datos novato propone la siguiente regla: "Si el cliente es mayor de 45 años y tiene

Edad	Núm Coches	Casa	Núm hijos	Est Civil	Perro	Compró
66	1	Sí	2	Viudo	No	Sí
52	2	Sí	3	Casado	No	Sí
22	0	No	0	Casado	Sí	No
25	1	No	1	Soltero	No	No
44	0	No	2	Divorciado	Sí	No
39	1	Sí	2	Casado	Sí	No
26	1	No	2	Soltero	No	No
40	3	Sí	1	Casado	Sí	No
53	2	Sí	2	Divorciado	No	Sí
64	2	Sí	3	Divorciado	No	No
58	2	Sí	2	Casado	Sí	Sí
33	1	No	1	Soltero	No	No

menos de 3 hijos o no está divorciado, entonces quiere comprar un barco". Cuando se le pregunta qué tan bien funciona esta regla suya, nuestro científico de datos responde: "¡Es 100 % precisa!" Y de hecho, en los datos que están en la tabla, la regla es perfectamente precisa. Hay muchas reglas posibles que se nos ocurren y que explican perfectamente si alguien en este conjunto de datos quiere comprar un barco. Ninguna edad aparece dos veces en los datos, por lo que se podría decir que las personas de 66, 52, 53 o 58 años quieren comprar un barco, mientras que el resto no. Si bien se puede crear muchas reglas que funcionen bien con estos datos, recuerde que no se está interesados en hacer predicciones para este conjunto de datos; ya que se conoce las respuestas para estos clientes. Se quiere saber si es probable que nuevos clientes compren un barco. Por lo tanto, se quiere encontrar una regla que funcione bien para los nuevos clientes, y lograr una precisión del 100 por ciento en el conjunto de capacitación no nos ayuda en eso. Es posible que no esperemos que la regla que ideó nuestro científico de datos funcione muy bien en nuevos clientes. Parece demasiado complejo y está respaldado por muy pocos datos. Por ejemplo, la parte de la regla "o no está divorciado" depende de un solo cliente.

La única medida de si un algoritmo funcionará bien con nuevos datos es la evaluación en el conjunto de test. Sin embargo, intuitivamente se espera que los modelos simples se generalicen mejor a los nuevos datos. Si la regla fuera "Las personas mayores de 50 años quieren comprar un bote", y esto explicara el comportamiento de todos los clientes, se confiaría más en ella que en la regla que involucra a los hijos y el estado civil además de la edad. Por eso, siempre se quiere encontrar el modelo más simple. Construir un modelo que es demasiado complejo para la cantidad de información que se tiene, como lo hizo el científico de datos novato, se llama *overfitting*. El *overfitting* se produce cuando ajusta un modelo demasiado de cerca a las particularidades del conjunto de entrenamiento y obtiene un modelo que funciona bien en el conjunto de entrenamiento pero no puede generalizar a nuevos datos. Por otro lado, si su modelo es demasiado simple, digamos, "Todos los propietarios de una casa compran un bote", es posible que no pueda capturar todos los aspectos y la variabilidad de los datos, y el modelo funcionará mal incluso en el set de entrenamiento. La elección de un modelo demasiado simple se llama *underfitting*.

Cuanto más complejo se permita que sea el modelo, mejor predecirá los datos

2. GENERALIZACIÓN, OVERFITTING, Y UNDERFITTING

de entrenamiento. Sin embargo, si el modelo se vuelve demasiado complejo, comienza a enfocar demasiado en cada punto de datos individual en el conjunto de entrenamiento, y el modelo no se generalizará bien a nuevos datos.

Hay un punto óptimo en el medio que producirá el mejor rendimiento de generalización. Este es el modelo que se quiere encontrar. La compensación entre underfitting y overfitting se ilustra en la figura 28.1




Figura 28.1: Compensación de la complejidad del modelo contra exactitud de entrenamiento y test

2.1. Relación entre la Complejidad del Modelo y el Tamaño del Conjunto de Datos

Es importante tener en cuenta que la complejidad del modelo está íntimamente ligada a la variación de las entradas contenidas en el conjunto de datos de entrenamiento: cuanto mayor sea la variedad de puntos de datos que contiene el conjunto de datos, más complejo es el modelo que se puede usar sin overfitting. Por lo general, la recopilación de más puntos de datos producirá más variedad, por lo que los conjuntos de datos más grandes permiten construir modelos más complejos. Sin embargo, simplemente duplicar los mismos puntos de datos o recopilar datos muy similares no ayudará.

Volviendo al ejemplo de la venta de barcos, si se tuviera 10.000 filas más de datos de clientes y todas cumplieran la regla “Si el cliente es mayor de 45 años y tiene menos de 3 hijos o no está divorciado, entonces quiere comprar un barco”, sería mucho más probable que creyéramos que esta es una buena regla que cuando se desarrolló utilizando solo las 12 filas de la Tabla 28.1

Tener más datos y construir modelos apropiadamente más complejos a menudo puede hacer maravillas para las tareas de aprendizaje supervisado. En el mundo real, a menudo tiene la capacidad de decidir cuántos datos recopilar,

lo que podría ser más beneficioso que ajustar y ajustar el modelo. Nunca se debe subestimar el poder de más datos.

3. Algoritmo Supervisados de Machine Learning

A continuación, se revisará los algoritmos de machine learning más populares y se explicará cómo aprenden de los datos y cómo hacen predicciones. También se comentará cómo se desarrolla el concepto de complejidad del modelo para cada uno de estos modelos y se dará una descripción general de cómo cada algoritmo construye un modelo. Se examinará las fortalezas y debilidades de cada algoritmo y a qué tipo de datos se pueden aplicar mejor. También se explicará el significado de los parámetros y opciones más importantes. Muchos algoritmos tienen una clasificación y una variante de regresión, y se describirá ambas.

No es necesario leer las descripciones de cada algoritmo en detalle, pero comprender los modelos le dará una mejor idea de las diferentes formas en que pueden funcionar los algoritmos de machine learning.

3.1. Algunas Muestras de Dataset

Se Usarán varios dataset para ilustrar los diferentes algoritmos. Algunos de los dataset serán pequeños y sintéticos (es decir, inventados), diseñados para resaltar aspectos particulares de los algoritmos. Otros conjuntos de datos serán ejemplos grandes del mundo real.

Un ejemplo de un conjunto de datos de clasificación sintético de dos clases es el conjunto de datos de forge, que tiene dos características. El siguiente código crea un diagrama de dispersión (Figura 28.2) que visualiza todos los puntos de datos en este dataset. La gráfica tiene la primera característica en el eje x y la segunda característica en el eje y. Como siempre ocurre en los gráficos de dispersión, cada punto de datos se representa como un punto. El color y la forma del punto indican su clase:

```
import mglearn
import matplotlib.pyplot as plt
X,y = mglearn.datasets.make_forge()
mglearn.discrete_scatter(X[:, 0], X[:, 1], y)
plt.legend(["Clase 0", "Clase 1"], loc=4)
plt.xlabel("Primera Característica")
plt.ylabel("Segunda Característica")
print("Forma de X:", X.shape)
```

Se puede ver como el dataset consiste en 26 puntos de datos, con dos características.

Para ilustrar los algoritmos de regresión, se usaremos el dataset de ondas sintéticas. El dataset de ondas tiene una característica de entrada única y una variable objetivo continua (o respuesta) que se quiere modelar. El gráfico creado aquí (Figura 28.3) muestra la característica única en el eje xy el objetivo de regresión (la salida) en el eje y:




Figura 28.2: Gráfico de dispersión

```
X, y = mglearn.datasets.make_wave(n_samples=40)
plt.plot(X, y, 'o')
plt.ylim(-3, 3)
plt.xlabel("Característica")
plt.ylabel("Target")
```




Figura 28.3: Gráfico del dataset de onda

Se está utilizando estos conjuntos de datos muy simples y de baja dimensión porque se puede visualizar fácilmente: una página impresa tiene dos dimensiones, por lo que los datos con más de dos características son difíciles de mostrar. Cualquier intuición derivada de conjuntos de datos con pocas características (también llamados conjuntos de datos de baja dimensión) podría no ser válida

en conjuntos de datos con muchas características (conjuntos de datos de alta dimensión). Siempre que se tenga esto en cuenta, inspeccionar algoritmos en conjuntos de datos de baja dimensión puede ser muy instructivo.

Se complementará estos pequeños conjuntos de datos sintéticos con dos conjuntos de datos del mundo real que se incluyen en *scikit-learn*. Uno es el conjunto de datos de Wisconsin Breast Cancer (cáncer, para abreviar), que registra las mediciones clínicas de los tumores de cáncer de mama. Cada tumor se etiqueta como “benigno” (para tumores inofensivos) o “maligno” (para tumores cancerosos), y la tarea es aprender a predecir si un tumor es maligno en función de las mediciones del tejido.

Se cargará usando la función `load_breast_cancer` desde *scikit-learn*

```
from sklearn.datasets import load_breast_cancer
cancer = load_breast_cancer()
print("cancer.keys():\n", cancer.keys())
```

```
cancer.keys():
dict_keys(['data', 'target', 'target_names',
'DESCR', 'feature_names', 'filename'])
```

Observación 28.2 *Los conjuntos de datos que se incluyen en scikit-learn generalmente se almacenan como objetos Bunch, que contienen cierta información sobre el conjunto de datos, así como los datos reales. Todo lo que se necesita saber acerca de los objetos Bunch es que se comportan como diccionarios, con el beneficio adicional de que puede acceder a los valores usando un punto (como en bunch.key en lugar de bunch ['key']).*

```
print("El dataset de los datos de
      cancer contiene: ",
      cancer.data.shape)
```

El dataset contiene 569 registros, con 30 característica

```
print("Recuento por clase:\n",
      {n: v for n, v in zip(cancer.target_names,
                           np.bincount(cancer.target))})
```

De esos 569 registros, 212 son etiquetados como malignos y 357 como benignos.

Para obtener una descripción del significado semántico de cada característica, se puede echar un vistazo al atributo `feature_names`:

```
print("Nombre de las caracter*sticas:\n",
      cancer.feature_names)
```

Puede obtener más información sobre los datos leyendo `cancer.DESCR` si se está interesado.

Nombre de las características:

```
['mean radius' 'mean texture' 'mean perimeter' 'mean area'  
'mean smoothness' 'mean compactness' 'mean concavity'  
'mean concave points' 'mean symmetry' 'mean fractal dimension'  
'radius error' 'texture error' 'perimeter error' 'area error'  
'smoothness error' 'compactness error' 'concavity error'  
'concave points error' 'symmetry error' 'fractal dimension error'  
'worst radius' 'worst texture' 'worst perimeter' 'worst area'  
'worst smoothness' 'worst compactness' 'worst concavity'  
'worst concave points' 'worst symmetry' 'worst fractal dimension']
```

También se usará el dataset de regresión del mundo real, el conjunto de datos de Boston Housing. La tarea asociada con este conjunto de datos es predecir el valor medio de las viviendas en varios vecindarios de Boston en la década de 1970, utilizando información como la tasa de delincuencia, la proximidad al río Charles, la accesibilidad a las carreteras, etc. El dataset contiene 506 puntos de datos, descritos por 13 características:

```
from sklearn.datasets import load_boston  
boston = load_boston()  
print("Forma del dataset:\n",  
      boston.data.shape)
```

Nuevamente, se puede obtener más información sobre el conjunto de datos leyendo el atributo *DESCR* de Boston. Para el propósito aquí, en realidad se expandirá este conjunto de datos no solo considerando estas 13 medidas como características de entrada, sino también observando todos los productos (también llamados interacciones) entre características. En otras palabras, no solo se considerará la tasa de delincuencia y la accesibilidad a las carreteras como características, sino también el producto de la tasa de delincuencia y la accesibilidad a las carreteras. Incluir características derivadas como estas se llama ingeniería de características, que se comentará con más detalle en próximos capítulos. Este conjunto de datos derivado se puede cargar usando la función *load_extended_boston*:

```
X, y = mglearn.datasets.load_extended_boston()  
print("X.shape:", X.shape)
```

El resultado es 104 características de las 13 características originales más las 91 combinaciones posibles de dos características dentro de esas 13.

Se usará este dataset para explicar e ilustrar las propiedades de los diferentes algoritmos de aprendizaje automático. Pero por ahora, solo se verá los algoritmos en sí.

Primero, se revisará el algoritmo de los *k* vecinos más cercanos (*k*-NN), que ya se dieron pequeñas pinceladas en la sección 4.2.

4. K-Nearest Neighbors

El algoritmo *k*-NN es posiblemente el algoritmo de machine learning más simple. La construcción del modelo consiste solo en almacenar el conjunto de

datos de entrenamiento. Para hacer una predicción de un nuevo punto de datos, el algoritmo busca los puntos de datos más cercanos en el conjunto de datos de entrenamiento: sus “vecinos más cercanos”.

4.1. Clasificación K-Neighbors

En la versión más simple, el algoritmo k-NN solo considera exactamente un vecino más cercano, que es el punto de datos de entrenamiento más cercano al punto para el que se quiere hacer una predicción. Entonces, la predicción es simplemente el resultado conocido para este punto de entrenamiento. La Figura 28.4 ilustra esto para el caso de clasificación en el conjunto de datos de *forge*:

```
mglearn.plots.plot_knn_classification(n_neighbors=1)
```




Figura 28.4: Predicciones hechas por el modelo de un vecino más cercano en el conjunto de datos de Forge

Aquí, se han agregado tres nuevos puntos de datos, que se muestran como estrellas. Para cada uno de ellos, se marcan el punto más cercano en el conjunto de entrenamiento. La predicción del algoritmo de un vecino más cercano es la etiqueta de ese punto (mostrado por el color de la cruz).

En lugar de considerar solo al vecino más cercano, también se puede considerar un número arbitrario, k , de vecinos. Aquí es de donde proviene el nombre del algoritmo de los k vecinos más cercanos. Cuando se considera a más de un vecino, se usa la votación para asignar una etiqueta. Esto significa que para cada punto de test se cuenta cuántos vecinos pertenecen a la clase 0 y cuántos vecinos pertenecen a la clase 1. Luego se asigna la clase que es más frecuente: en otras palabras, la clase mayoritaria entre los k vecinos más cercanos. El siguiente ejemplo (Figura 28.5) usa los tres vecinos más cercanos:

```
mglearn.plots.plot_knn_classification(n_neighbors=3)
```

Nuevamente, la predicción se muestra como el color de la cruz. Se puede ver que la predicción para el nuevo punto de datos en la parte superior izquierda no es la misma que la predicción cuando se usaba solo un vecino.




Figura 28.5: Predicciones hechas por el modelo de tres vecino más cercano en el conjunto de datos de Forge

Si bien esta ilustración es para un problema de clasificación binaria, este método se puede aplicar a conjuntos de datos con cualquier número de clases. Para más clases, se cuenta cuántos vecinos pertenecen a cada clase y nuevamente se predice la clase más común.

Ahora se verá cómo se puede aplicar el algoritmo de los k vecinos más cercanos usando *scikit-learn*. Primero, se dividen los datos en un entrenamiento y un conjunto de test para que se pueda evaluar el desempeño de la generalización, como se discutió en el 4.2:

```
from sklearn.model_selection
import train_test_split
X, y = mglearn.datasets.make_forge()
X_train, X_test, y_train, y_test =
    train_test_split(X, y, random_state=0)
```

A continuación, se importa y crea una instancia de la clase. Aquí es cuando se puede establecer parámetros, como el número de vecinos a utilizar. Se configurará en 3:

```
from sklearn.neighbors
import KNeighborsClassifier
clf = KNeighborsClassifier(n_neighbors=3)
```

Ahora, se ajusta el clasificador usando el conjunto de datos de entrenamiento. Para *KNeighborsClassifier*, esto significa almacenar el conjunto de datos, por lo que podemos calcular los vecinos durante la predicción:

```
clf.fit(X_train, y_train)
```

Para hacer predicciones sobre los datos de test, se utilizará el método *predict*. Para cada punto de datos en el conjunto test, esto calcula sus vecinos más cercanos en el conjunto de entrenamiento y encuentra la clase más común entre estos:

```
print("Predicciones conjunto test:",
      clf.predict(X_test))
```

```
Predicciones conjunto test: [1 0 1 0 1 0 0]
```

Para evaluar qué tan bien se generaliza el modelo, se utilizará el método de puntuación con los datos de test junto con las etiquetas de test:

```
print("Exactitud: {:.2f}".
      format(clf.score(X_test, y_test)))
```

```
Exactitud: 0.86
```

El modelo tiene una precisión del 86 %, lo que significa que el modelo predijo la clase correctamente para el 86 % de las muestras en el conjunto de datos de test.

Analizando KNeighborsClassifier

Para conjuntos de datos bidimensionales, también se puede ilustrar la predicción para todos los posibles puntos de test en el plano xy. Se Coloreará el plano de acuerdo con la clase que se le asignaría a un punto en esta región. Esto permite ver el límite de decisión, que es la división entre dónde el algoritmo asigna la clase 0 y dónde asigna la clase 1. El siguiente código produce las visualizaciones de los límites de decisión para uno, tres y nueve vecinos que se muestran en la Figura 28.6. :

```
fig, axes = plt.subplots(1, 3, figsize=(10, 3))

for n_neighbors, ax in zip([1, 3, 9], axes):
    #el método de ajuste devuelve el objeto self,
    #por lo que podemos instanciar
    # y caben en una línea
    clf = KNeighborsClassifier(
        n_neighbors=n_neighbors).fit(X, y)
    mglearn.plots.plot_2d_separator(
        clf, X, fill=True, eps=0.5,
        ax=ax, alpha=.4)
    mglearn.discrete_scatter(X[:, 0],
        X[:, 1], y, ax=ax)
    ax.set_title("{} vecinos(s)".
        format(n_neighbors))
    ax.set_xlabel("Característica 0")
    ax.set_ylabel("Característica 1")
axes[0].legend(loc=3)
```

Como se puede ver a la izquierda en la figura, el uso de un solo vecino da como resultado un límite de decisión que sigue de cerca los datos de entrenamiento.




Figura 28.6: Frontera de decisión creada para los diferentes modelos

Tener en cuenta cada vez más vecinos conduce a un límite de decisión más suave. Un límite más suave corresponde a un modelo más simple. En otras palabras, usar pocos vecinos corresponde a una alta complejidad del modelo (como se muestra en el lado derecho de la Figura 28.1) y usar muchos vecinos corresponde a una baja complejidad del modelo (como se muestra en el lado izquierdo de la Figura 28.1). Si se considera el caso extremo en el que el número de vecinos es el número de todos los puntos de datos en el conjunto de entrenamiento, cada punto de prueba tendría exactamente los mismos vecinos (todos los puntos de entrenamiento) y todas las predicciones serían iguales: la clase que es más frecuente en el conjunto de entrenamiento.

Si se comprueba si se puede confirmar la conexión entre la complejidad del modelo y la generalización que se comentaba anteriormente.

Se utilizará el conjunto de datos de cáncer de mama del mundo real. Se comienza dividiendo el conjunto de datos en un conjunto de entrenamiento y uno de test. Luego, se evalúa el rendimiento del equipo de entrenamiento y test con diferentes números de vecinos. Los resultados se muestran en la Figura 28.7:

```
from sklearn.datasets import load_breast_cancer

cancer = load_breast_cancer()
X_train, X_test, y_train, y_test =
    train_test_split(
        cancer.data,
        cancer.target,
        stratify=cancer.target,
        random_state=66)

training_accuracy = []
test_accuracy = []
# try n_neighbors from 1 to 10
neighbors_settings = range(1, 11)

for n_neighbors in neighbors_settings:
    # build the model
    clf = KNeighborsClassifier(
```

```
        n_neighbors=n_neighbors)
clf.fit(X_train, y_train)
# record training set accuracy
training_accuracy.append(
    clf.score(X_train, y_train))
# record generalization accuracy
test_accuracy.append(
    clf.score(X_test, y_test))

plt.plot(neighbors_settings, training_accuracy,
        label="Exactitud entrenamiento")
plt.plot(neighbors_settings, test_accuracy,
        label="Exactitud test")
plt.ylabel("Exactitud")
plt.xlabel("n_neighbors")
plt.legend()
```




Figura 28.7: Comparación de exactitud entre entrenamiento y test en función de los `n_vecinos`

La gráfica muestra la precisión del conjunto de entrenamiento y test en el eje Y contra la configuración de `n_neighbors` en el eje X. Si bien los gráficos del mundo real rara vez son muy suaves, aún se puede reconocer algunas de las características del overfitting y el underfitting (Hay que tener en cuenta que debido a que considerar menos vecinos corresponde a un modelo más complejo, el gráfico se invierte horizontalmente en relación con la ilustración de la Figura 28.1). Teniendo en cuenta un solo vecino más cercano, la predicción en el conjunto de entrenamiento es perfecta. Pero cuando se consideran más vecinos, el modelo se vuelve más simple y la precisión del entrenamiento disminuye. La precisión del conjunto de test para usar un solo vecino es menor que cuando usa más vecinos, lo que indica que usar el único vecino más cercano conduce a un modelo que es demasiado complejo. Por otro lado, al considerar 10 vecinos, el modelo es demasiado simple y el rendimiento es aún peor. El mejor rendimiento

se encuentra en algún punto intermedio, utilizando alrededor de seis vecinos. Aún así, es bueno tener en cuenta la escala de la trama. El peor rendimiento es de alrededor del 88 % de precisión, que aún podría ser aceptable.

4.2. Regresión k-neighbors

También hay una variante de regresión del algoritmo de los k vecinos más cercanos. Nuevamente, se comenzará por usar el único vecino más cercano, esta vez usando el conjunto de datos de ondas. Se agregan tres puntos de datos de prueba como estrellas verdes en el eje X. La predicción que utiliza un solo vecino es solo el valor objetivo del vecino más cercano. Estos se muestran como estrellas azules en la Figura 28.8:

```
mglearn.plots.plot_knn_regression(n_neighbors=1)
```




Figura 28.8: Predicción hecha por la regresión de un vecino más cercano en el dataset de ondas

Nuevamente, podemos usar más que el único vecino más cercano para la regresión. Cuando se utilizan varios vecinos más cercanos, la predicción es el promedio, o la media, de los vecinos relevantes (Figura 28.9):

```
mglearn.plots.plot_knn_regression(n_neighbors=3)
```




Figura 28.9: Predicción hecha por la regresión de tres vecino más cercano en el dataset de ondas

El algoritmo de k vecinos más cercanos para la regresión se implementa en la clase `KNeighborsRegressor` en *scikit-learn*. Se usa de manera similar a `KNeighborsClassifier`

```
from sklearn.neighbors import KNeighborsRegressor
```

```
X, y = mglearn.datasets.make_wave(n_samples=40)
```

```
# dividir el conjunto de datos de ondas en un  
# conjunto de entrenamiento y test
```

```
X_train, X_test, y_train, y_test =  
    train_test_split(X,  
                    y,  
                    random_state=0)
```

```
# Cree una instancia del modelo y establezca  
# el número de vecinos a considerar en 3  
reg = KNeighborsRegressor(n_neighbors=3)  
# ajustar el modelo utilizando los datos  
# de entrenamiento y los objetivos de entrenamiento  
reg.fit(X_train, y_train)
```

Ahora, se puede hacer predicciones con el conjunto test

```
print("Test set predictions:\n",  
      reg.predict(X_test))
```

También se puede evaluar el modelo utilizando el método de *score*, que para los regresores devuelvan el valor de R^2 . El valor de R^2 , también conocida como coeficiente de determinación, es una medida de bondad de una predicción para un modelo de regresión y produce un valor que suele estar entre 0 y 1.

```
Predicciones conjunto test:
[-0.05396539  0.35686046  1.13671923 -1.89415682
-1.13881398 -1.63113382
 0.35686046  0.91241374 -0.44680446 -1.13881398]
```

Un valor de 1 corresponde a una predicción perfecta y un valor de 0 corresponde a un modelo constante que solo predice la media de las respuestas del conjunto de entrenamiento, `y_train`. La formulación de R^2 utilizada aquí puede incluso ser negativa, lo que puede indicar predicciones anticorrelacionadas.

```
print("Conjunto test R^2: {:.2f}".
      format(reg.score(X_test, y_test)))
```

Conjunto Test R^2: 0.83

Hay un valor de 83 %, lo cual indica que el ajuste del modelo es relativamente bueno

Analizando KNeighborsRegressor

Para un conjunto de datos unidimensionales, se puede ver cómo se ven las predicciones para todos los valores de características posibles (Figura 28.10). Para hacer esto, se crea un conjunto de datos test que consta de muchos puntos en el eje Y, que corresponde a la característica única:

```
fig, axes = plt.subplots(1, 3, figsize=(15, 4))
# Se crea 1,000 puntos,
# igualmente espaciados entre -3 y 3
line = np.linspace(-3, 3, 1000).reshape(-1, 1)

for n_neighbors, ax in zip([1, 3, 9], axes):
    # Se hacen predicciones usando 1, 3,
    # o 9 vecinos
    reg = KNeighborsRegressor(
        n_neighbors=n_neighbors)
    reg.fit(X_train, y_train)
    ax.plot(line, reg.predict(line))
    ax.plot(X_train, y_train, '^',
            c=mplotlib.cm2(0), markersize=8)
    ax.plot(X_test, y_test, 'v',
            c=mplotlib.cm2(1), markersize=8)

    ax.set_title(
        "{} vecinos(s)\n train score: {:.2f}\n
        test score: {:.2f}".format(
            n_neighbors,
            reg.score(X_train, y_train),
```

```

        reg.score(X_test, y_test)))
    ax.set_xlabel("Característica")
    ax.set_ylabel("Target")
    axes[0].legend(["Modelos de predicciones",
                   "Training data/target",
                   "Test data/target"], loc="best")

```




Figura 28.10: Comparación de predicciones hechas por regresión de k vecinos cercanos por diferentes valores de vecinos

Como se puede observar en la gráfica, usando un solo vecino, cada punto en el conjunto de entrenamiento tiene una influencia obvia en las predicciones, y los valores predichos pasan por todos los puntos de datos. Esto conduce a una predicción muy inestable. Hay que tener en cuenta que más vecinos conduce a predicciones más fluidas, pero estas tampoco se ajustan a los datos de entrenamiento.

Fortalezas, debilidades y parámetros

En principio, hay dos parámetros importantes para el clasificador `KNeighbors`: el número de vecinos y cómo mide la distancia entre puntos de datos. En la práctica, el uso de una pequeña cantidad de vecinos, como tres o cinco, suele funcionar bien, pero sin duda se debería ajustar este parámetro. La elección de la medida de distancia correcta es un poco compleja. De forma predeterminada, se utiliza la distancia euclidiana, que funciona bien en muchos entornos.

Uno de los puntos fuertes de k -NN es que el modelo es muy fácil de entender y, a menudo, ofrece un rendimiento razonable sin muchos ajustes. El uso de este algoritmo es un buen método de referencia para probar antes de considerar técnicas más avanzadas. La construcción del modelo de vecinos más cercanos suele ser muy rápida, pero cuando su conjunto de entrenamiento es muy grande (ya sea en número de características o en número de muestras), la predicción puede ser lenta. Al utilizar el algoritmo k -NN, es importante preprocesar sus datos. Este enfoque a menudo no funciona bien en conjuntos de datos con muchas características (cientos o más), y lo hace particularmente mal con conjuntos de datos donde la mayoría de las características son 0 la mayor parte del tiempo (los denominados conjuntos de datos dispersos).

Entonces, aunque el algoritmo de los k vecinos más cercanos es fácil de entender, no se usa a menudo en la práctica, debido a que la predicción es lenta y su incapacidad para manejar muchas características.

5. Modelos Lineales

Los modelos lineales son una clase de modelos que se utilizan ampliamente en la práctica y se han estudiado ampliamente en las últimas décadas, con raíces que se remontan a más de cien años. Los modelos lineales hacen una predicción utilizando una función lineal de las características de entrada.

5.1. Modelos de Regresión Lineal

Para la regresión, la fórmula de predicción general para un modelo lineal tiene el siguiente aspecto:

$$\hat{y} = w[0] \times x[0] + w[1] \times x[1] + \dots + w[p] \times x[p] + b$$

Aquí, $x[i]$ denota las características (en este ejemplo, el número de características es $p + 1$) de un solo punto de datos, w y b son parámetros del modelo que se aprenden, y y es la predicción que hace el modelo.

Para un conjunto de datos con una sola característica, esto es:

$$\hat{y} = w[0] \times x[0] + b$$

Intentar aprender los parámetros $w[0]$ y b en el conjunto de datos de ondas unidimensionales puede llevar a la siguiente línea (Figura 28.11):

```
mglearn.plots.plot_linear_regression_wave()
```

Mirando $w[0]$ se ve que la pendiente debe estar alrededor de 0.4, lo cual se puede confirmar visualmente en la gráfica. La intersección es donde la línea de predicción debe cruzar el eje y : esto está ligeramente por debajo de cero, lo que también puede confirmar en la imagen.

Los modelos lineales de regresión se pueden caracterizar como modelos de regresión para los cuales la predicción es una línea para una sola característica, un plano cuando se usan dos características o un hiperplano en dimensiones más altas (es decir, cuando se usan más características).

Si se compara las predicciones hechas por la línea recta con las hechas por `KNeighborsRegressor` en la Figura 28.10, usar una línea recta para hacer predicciones parece muy restrictivo. Parece que se han perdido todos los detalles finos de los datos. En cierto sentido, esto es cierto. Es una suposición fuerte (y algo poco realista) de que la $target$ y es una combinación lineal de las características. Pero observar datos unidimensionales da una perspectiva algo sesgada. Para conjuntos de datos con muchas características, los modelos lineales pueden ser muy poderosos. En particular, si tiene más funciones que puntos de datos de entrenamiento, cualquier $target$ y se puede modelar perfectamente (en el conjunto de entrenamiento) como una función lineal.

Hay muchos modelos de regresión lineal diferentes. La diferencia entre estos modelos radica en cómo aprenden los parámetros del modelo w y b a partir de los datos de entrenamiento, y cómo se puede controlar la complejidad del modelo. A continuación se mencionarán los modelos de regresión lineal más populares.




Figura 28.11: Predicción del modelo lineal en el dataset de ondas

5.2. Regresión Lineal por Mínimos Cuadrados Ordinarios

El modelo de regresión lineal, o mínimos cuadrados ordinarios (MCO), es el método lineal más simple y clásico de regresión. El modelo de regresión lineal encuentra los parámetros w y b que minimizan el error cuadrático medio entre las predicciones y los verdaderos objetivos de la regresión, y , en el conjunto de entrenamiento. El error cuadrático medio es la suma de las diferencias cuadráticas entre las predicciones y los valores verdaderos, dividida por el número de muestras. La regresión lineal no tiene parámetros, lo cual es un beneficio, pero tampoco tiene forma de controlar la complejidad del modelo.

Aquí está el código que produce el modelo que puede ver en la Figura 28.11:

```
from sklearn.linear_model
    import LinearRegression
X, y = mglearn.datasets.make_wave(n_samples=60)
X_train, X_test, y_train, y_test =
    train_test_split(X, y, random_state=42)
lr = LinearRegression().fit(X_train, y_train)
```

Los parámetros de “pendiente” (w), también llamados pesos o coeficientes, se almacenan en el atributo *coef_*, mientras que el desplazamiento o intersección (b) se almacena en el atributo *intercept_*:

```
print("lr.coef_", lr.coef_)
print("lr.intercept_", lr.intercept_)
```

```
lr.coef_: [0.39390555]
lr.intercept_: -0.031804343026759746
```

Observación 28.3 *Es posible que observe el subrayado final de aspecto extraño al final de `coef_` e `intercept_`. scikit-learn siempre almacena todo lo que se deriva de los datos de entrenamiento en atributos que terminan con un guión bajo al final. Eso es para separarlos de los parámetros que establece el usuario.*

El atributo `intercept_` es siempre un único número flotante, mientras que el atributo `coef_` es una matriz NumPy con una entrada por característica de entrada. Como solo tenemos una característica de entrada única en el conjunto de datos de ondas, `lr.coef_` solo tiene una entrada única.

Si se ve el conjunto de entrenamiento y el rendimiento del conjunto test:

```
print("Score conjunto Entrenamiento: {:.2f}"\
      .format(lr.score(X_train, y_train)))
print("Score conjunto Test: {:.2f}"\
      .format(lr.score(X_test, y_test)))
```

```
Score conjunto Entrenamiento: 0.67
Score conjunto Test: 0.66
```

Un R^2 de aproximadamente 0.66 no es muy bueno. Pero se puede ver que los valores en los conjuntos de entrenamiento y test están muy cerca. Esto significa que es probable que esté underfitting, no overfitting. Para este conjunto de datos unidimensionales, existe poco peligro de overfitting, ya que el modelo es muy simple (o restringido). Sin embargo, con conjuntos de datos de mayor dimensión (es decir, conjuntos de datos con una gran cantidad de características), los modelos lineales se vuelven más poderosos y hay una mayor probabilidad de overfitting.

A continuación se expondrá como funciona *LinearRegression* en un conjunto de datos más complejo, como el conjunto de datos de **Boston Housing**. Recuerde que este conjunto de datos tiene 506 muestras y 104 características derivadas. Primero, se cargará el conjunto de datos y lo se dividirá en un conjunto de entrenamiento y uno de test. Luego se construye el modelo de regresión lineal como antes:

```
X, y = mglearn.datasets.load_extended_boston()

X_train, X_test, y_train, y_test =
    train_test_split(X,
                    y,
                    random_state=0)
lr = LinearRegression().fit(X_train, y_train)
```

Al comparar los “scores” del conjunto de entrenamiento y del conjunto de test, se encuentra que se predice con mucha precisión en el conjunto de entrenamiento, pero el R^2 en el conjunto de test es mucho peor:

```
print("Score conjunto Entrenamiento: {:.2f}"\
      .format(lr.score(X_train, y_train)))
print("Score conjunto Test: {:.2f}"\
      .format(lr.score(X_test, y_test)))
```

```
Score conjunto Entrenamiento: 0.95
Score conjunto Test: 0.61
```

Esta discrepancia entre el rendimiento en el conjunto de entrenamiento y el conjunto de test es una clara señal de overfitting y, por lo tanto, se debería intentar encontrar un modelo que permita controlar la complejidad. Una de las alternativas más utilizadas a la regresión lineal estándar es la Ridge Regression, que se verá a continuación.

Regresión Ridge

La regresión Ridge también es un modelo lineal de regresión, por lo que la fórmula que usa para hacer predicciones es la misma que se usa para mínimos cuadrados ordinarios. Sin embargo, en la regresión de Ridge, los coeficientes (w) se eligen no solo para que predigan bien los datos de entrenamiento, sino también para ajustarse a una restricción adicional. También se quiere que la magnitud de los coeficientes sea lo más pequeña posible; en otras palabras, todas las entradas de w deben ser cercanas a cero. De manera intuitiva, esto significa que cada característica debe tener el menor efecto posible en el resultado (lo que se traduce en tener una pequeña pendiente), sin dejar de predecir bien. Esta restricción es un ejemplo de lo que se llama regularización. La regularización significa restringir explícitamente un modelo para evitar el overfitting. El tipo particular utilizado por la regresión de Ridge se conoce como regularización L2.

La regularización Ridge penaliza la suma de los coeficientes elevados al cuadrado

$$\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2$$

A esta penalización se le conoce como L2 y tiene el efecto de reducir de forma proporcional el valor de todos los coeficientes del modelo pero sin que estos lleguen a cero. El grado de penalización está controlado por el hiperparámetro α . Cuando $\alpha = 0$ la penalización es nula y el resultado es equivalente al de un modelo lineal por mínimos cuadrados ordinarios (OLS). A medida que α aumenta, mayor es la penalización y menor el valor de los predictores.

$$\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \alpha \sum_{j=1}^p \beta_j^2$$

Suma de residuos al cuadrado + $\alpha \sum_{j=1}^p \beta_j^2$

La principal ventaja de aplicar ridge frente al ajuste por mínimos cuadrados ordinarios (MCO) es la reducción de varianza. Por lo general, en situaciones

en las que la relación entre la variable respuesta y los predictores es aproximadamente lineal, las estimaciones por mínimos cuadrados tienen poco sesgo pero aún pueden sufrir alta varianza (pequeños cambios en los datos de entrenamiento tienen mucho impacto en el modelo resultante). Este problema se acentúa conforme el número de predictores introducido en el modelo se aproxima al número de observaciones de entrenamiento, llegando al punto en que, si $p > n$, no es posible ajustar el modelo por mínimos cuadrados ordinarios. Empleando un valor adecuado de α , el método de ridge es capaz de reducir varianza sin apenas aumentar el sesgo, consiguiendo así un menor error total.

La desventaja del método ridge es que, el modelo final, incluye todos los predictores. Esto es así porque, si bien la penalización fuerza a que los coeficientes tiendan a cero, nunca llegan a ser exactamente cero (solo si $\alpha = \infty$). Este método consigue minimizar la influencia sobre el modelo de los predictores menos relacionados con la variable respuesta pero, en el modelo final, van a seguir apareciendo. Aunque esto no supone un problema para la precisión del modelo, sí lo es para su interpretación.

La regresión de ridge se implementa en `linear_model.Ridge`. A continuación se verá qué tan bien le va en el conjunto de datos ampliado de Boston Housing:

```
from sklearn.linear_model import Ridge

ridge = Ridge().fit(X_train, y_train)
print("Score conjunto Entrenamiento: {:.2f}".\
      format(ridge.score(X_train, y_train)))
print("Score conjunto Test: {:.2f}".\
      format(ridge.score(X_test, y_test)))
```

```
Score conjunto Entrenamiento: 0.89
Score conjunto Test: 0.75
```

Como se puede ver, el “score” del conjunto de entrenamiento de *Ridge* es más baja que la de *LinearRegression*, mientras que la puntuación del conjunto de test es más alta. Esto es consistente con las expectativas. Con la regresión lineal, se estaba sobreajustando los datos. *Ridge* es un modelo más restringido, por lo que es menos probable que se haga un sobreajuste. Un modelo menos complejo significa un peor rendimiento en el conjunto de entrenamiento, pero una mejor generalización. Como solo interesa el rendimiento de la generalización, se debe elegir el modelo *Ridge* sobre el modelo *LinearRegression*.

El modelo *Ridge* hace un compromiso entre la simplicidad del modelo (coeficientes cercanos a cero) y su rendimiento en el conjunto de entrenamiento. Se puede especificar la importancia que el modelo otorga a la simplicidad frente al rendimiento del conjunto de entrenamiento, utilizando el parámetro alfa. En el ejemplo anterior, se usó el parámetro predeterminado $\alpha = 1.0$. Sin embargo, no hay ninguna razón por la que esto dé la mejor compensación. La configuración óptima de alfa depende del conjunto de datos particular que se esté usando. El aumento de alfa obliga a los coeficientes a moverse más hacia cero, lo que disminuye el rendimiento del conjunto de entrenamiento, pero podría ayudar a la generalización. Por ejemplo:

```
ridge10 = Ridge(alpha=10).fit(X_train, y_train)
```

```
print("Score conjunto Entrenamiento: {:.2f}".\
      format(ridge10.score(X_train, y_train)))
print("Score conjunto Test: {:.2f}".\
      format(ridge10.score(X_test, y_test)))
```

```
Score conjunto Entrenamiento: 0.79
Score conjunto Test: 0.64
```

La disminución de alfa permite que los coeficientes sean menos restringidos, lo que significa que se desplaza hacia la derecha en la Figura 28.1. Para valores muy pequeños de alfa, los coeficientes apenas están restringidos y se obtiene un modelo que se parece a *LinearRegression*:

```
ridge01 = Ridge(alpha=0.1).fit(X_train, y_train)
print("Score conjunto Entrenamiento: {:.2f}".\
      format(ridge01.score(X_train, y_train)))
print("Score conjunto Test: {:.2f}".\
      format(ridge01.score(X_test, y_test)))
```

```
Score conjunto Entrenamiento: 0.93
Score conjunto Test: 0.77
```

También se puede obtener una visión más cualitativa de cómo el parámetro alfa cambia el modelo al inspeccionar el atributo *coef_* de modelos con diferentes valores de alfa. Un alfa más alto significa un modelo más restringido, por lo que se espera que las entradas de *coef_* tengan una magnitud menor para un valor alto de alfa que para un valor bajo de alfa. Esto se confirma en el gráfico de la Figura 28.12:

```
plt.plot(ridge.coef_, 's', label="Ridge alpha=1")
plt.plot(ridge10.coef_, '^',\
         label="Ridge alpha=10")
plt.plot(ridge01.coef_, 'v',\
         label="Ridge alpha=0.1")

plt.plot(lr.coef_, 'o', label="LinearRegression")
plt.xlabel("Coeficientes indices")
plt.ylabel("Coeficientes magnitudes")
plt.hlines(0, 0, len(lr.coef_))
plt.ylim(-25, 25)
plt.legend()
```

Aquí, el eje X enumera las entradas de *coef_*: $x = 0$ muestra el coeficiente asociado con la primera característica, $x = 1$ el coeficiente asociado con la segunda característica, y así sucesivamente hasta $x = 100$. El eje Y muestra los valores numéricos de los valores correspondientes de los coeficientes. La principal conclusión aquí es que para $\alpha = 10$, los coeficientes se encuentran principalmente entre -3 y 3 . Los coeficientes para el modelo Ridge con alfa





Figura 28.12: Comparación de magnitudes de coeficientes para regresión de ridge con diferentes valores de regresión alfa y lineal

$\alpha = 1$ son algo mayores. Los puntos correspondientes a $\alpha = 0.1$ tienen una magnitud aún mayor, y muchos de los puntos correspondientes a la regresión lineal sin ninguna regularización (que sería $\alpha = 0$) son tan grandes que están fuera del gráfico.

Otra forma de comprender la influencia de la regularización es fijar un valor de α pero variar la cantidad de datos de entrenamiento disponibles. Para la Figura 5.2, se submuestra el conjunto de datos de Boston Housing y se evalúa la regresión lineal y Ridge ($\alpha = 1$) en subconjuntos de tamaño creciente (las parcelas que muestran el rendimiento del modelo en función del tamaño del conjunto de datos se denominan curvas de aprendizaje):

```
mglern.plots.plot_ridge_n_samples()
```



Lasso

Una alternativa a Ridge para regularizar la regresión lineal es Lasso. Al igual que con la regresión de crestas, el lazo también restringe los coeficientes para que sean cercanos a cero, pero de una manera ligeramente diferente, llamada regularización L1. La consecuencia de la regularización L1 es que cuando se usa el lazo, algunos coeficientes son exactamente cero. Esto significa que el modelo ignora por completo algunas características. Esto puede verse como una forma de selección automática de funciones. Tener algunos coeficientes exactamente cero a menudo hace que un modelo sea más fácil de interpretar y puede revelar las características más importantes de su modelo.

La regularización Lasso penaliza la suma del valor absolutos de los coeficientes de regresión ($\|\beta\|_1 = \sum_{j=1}^p |\beta_j|$). A esta penalización se le conoce como L1 y tiene el efecto de forzar a que los coeficientes de los predictores tiendan a cero. Dado que un predictor con coeficiente de regresión cero no influye en el modelo, lasso consigue excluir los predictores menos relevantes. Al igual que en ridge, el grado de penalización está controlado por el hiperparámetro α . Cuando $\alpha=0$, el resultado es equivalente al de un modelo lineal por mínimos cuadrados ordinarios. A medida que α aumenta, mayor es la penalización y más predictores quedan excluidos.

$$\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \alpha \sum_{j=1}^p |\beta_j|$$

$$\text{Suma de residuos al cuadrado} + \alpha \sum_{j=1}^p |\beta_j|$$

Se aplicará el lasso al conjunto de datos extendido de Boston Housing:

```
from sklearn.linear_model import Lasso

lasso = Lasso().fit(X_train, y_train)
print("Score conjunto entrenamiento: {:.2f}"\
      .format(lasso.score(X_train, y_train)))
print("Score conjunto test: {:.2f}"\
      .format(lasso.score(X_test, y_test)))
print("numero de caracteristicas utilizado:",\
      np.sum(lasso.coef_ != 0))
```

```
Score conjunto entrenamiento: 0.29
Score conjunto test: 0.21
Número de características utilizado: 4
```

Como se puede ver, Lasso lo hace bastante mal, tanto en el entrenamiento como en el conjunto de test. Esto indica que está desajustado (underfitting) y solo utilizó 4 de las 104 variables. De manera similar a Ridge, Lasso también tiene un parámetro de regularización, alfa, que controla la fuerza con la que los coeficientes se empujan hacia cero. En el ejemplo anterior, usamos el valor

predeterminado de $\alpha = 1.0$. Para reducir el desajuste, se intentará disminuir el α . Cuando se hace esto, también se necesita aumentar la configuración predeterminada de `max_iter` (el número máximo de iteraciones para ejecutar):

```
lasso001 = Lasso(alpha=0.01,
                  max_iter=100000)\
                  .fit(X_train, y_train)
print("Score conjunto entrenamiento: {:.2f}"\
      .format(lasso001.score(X_train, y_train)))
print("Score conjunto test: {:.2f}"\
      .format(lasso001.score(X_test, y_test)))
print("Número de características utilizado:",\
      np.sum(lasso001.coef_ != 0))
```

```
Score conjunto entrenamiento: 0.90
Score conjunto test: 0.77
Número de características utilizado: 33
```

Un α más bajo permite ajustar un modelo más complejo, que funcionó mejor en los datos de entrenamiento y test. El rendimiento es ligeramente mejor que con Ridge, y solo se usan 33 de las 104 variables. Esto hace que este modelo sea potencialmente más fácil de entender.

Sin embargo, si se establece α demasiado bajo, nuevamente se elimina el efecto de regularización y se terminamos sobreajustando (overfitting), con un resultado similar a *LinearRegression*:

```
lasso00001 = Lasso(alpha=0.0001, max_iter=100000)\
              .fit(X_train, y_train)
print("Score conjunto entrenamiento: {:.2f}"\
      .format(lasso00001.score(X_train,\
                               y_train)))
print("Score conjunto test: {:.2f}"\
      .format(lasso00001.score(X_test,\
                               y_test)))
print("Número de características utilizado:",\
      np.sum(lasso00001.coef_ != 0))
```

```
Score conjunto entrenamiento: 0.95
Score conjunto test: 0.64
Número de características utilizado: 96
```

Nuevamente, se puede graficar los coeficientes de los diferentes modelos, de manera similar a la Figura 28.12. El resultado se muestra en la Figura 28.13:

```
plt.plot(lasso.coef_, 's', label="Lasso alpha=1")
plt.plot(lasso001.coef_, '^',\
         label="Lasso alpha=0.01")
plt.plot(lasso00001.coef_, 'v',\
```

```
label="Lasso alpha=0.0001")

plt.plot(ridge01.coef_, 'o', label="Ridge alpha=0.1")
plt.legend(ncol=2, loc=(0, 1.05))
plt.ylim(-25, 25)
plt.xlabel("Coefficient index")
plt.ylabel("Coefficient magnitude")
```




Figura 28.13: Comparación de magnitudes de coeficientes para regresión de 1asso con diferentes valores de regresión alfa y ridge

Para $\alpha = 1$, no solo se ve que la mayoría de los coeficientes son cero (que ya se sabía), sino que los coeficientes restantes también son pequeños en magnitud. Disminuyendo α a 0.01, se obtiene la solución que se muestra como un triángulo que apunta hacia arriba, lo que hace que la mayoría de las características sean exactamente cero. Usando $\alpha = 0.0001$, se obtiene un modelo que no está regularizado, con la mayoría de los coeficientes distintos de cero y de gran magnitud. A modo de comparación, la mejor solución de Ridge se muestra como círculos. El modelo Ridge con $\alpha = 0.1$ tiene un rendimiento predictivo similar al modelo de 1asso con $\alpha = 0.01$, pero al utilizar Ridge, todos los coeficientes son distintos de cero.

En la práctica, la regresión de Ridge suele ser la primera opción entre estos dos modelos. Sin embargo, si se tiene una gran cantidad de funciones y se espera que solo algunas de ellas sean importantes, Lasso podría ser una mejor opción. De manera similar, si se desea tener un modelo que sea fácil de interpretar, Lasso proporcionará un modelo que será más fácil de entender, ya que seleccionará solo un subconjunto de las características de entrada. *scikit-learn* también proporciona la clase ElasticNet, que combina las penalizaciones de Lasso y Ridge. En la práctica, esta combinación funciona mejor, aunque al precio de tener que ajustar dos parámetros: uno para la regularización L1 y otro para la

regularización L2.

Comparación Ridge y Lasso

La principal diferencia práctica entre lasso y ridge es que el primero consigue que algunos coeficientes sean exactamente cero, por lo que realiza selección de predictores, mientras que el segundo no llega a excluir ninguno. Esto supone una ventaja notable de lasso en escenarios donde no todos los predictores son importantes para el modelo y se desea que los menos influyentes queden excluidos.

Por otro lado, cuando existen predictores altamente correlacionados (linealmente), ridge reduce la influencia de todos ellos a la vez y de forma proporcional, mientras que lasso tiende a seleccionar uno de ellos, dándole todo el peso y excluyendo al resto. En presencia de correlaciones, esta selección varía mucho con pequeñas perturbaciones (cambios en los datos de entrenamiento), por lo que, las soluciones de lasso, son muy inestables si los predictores están altamente correlacionados.

Para conseguir un equilibrio óptimo entre estas dos propiedades, se puede emplear lo que se conoce como penalización elastic net, que combina ambas estrategias.

5.3. Modelos Lineales para Clasificación

Los modelos lineales también se utilizan ampliamente para la clasificación. Veamos primero la clasificación binaria. En este caso, se hace una predicción utilizando la siguiente fórmula:

$$\hat{y} = w[0] \times x[0] + w[1] \times x[1] + \dots + w[p] \times x[p] + b > 0$$

La fórmula es muy similar a la de la regresión lineal, pero en lugar de simplemente devolver la suma ponderada de las características, se establece el umbral del valor predicho en cero. Si la función es menor que cero, se predice la clase -1; si es mayor que cero, se predice la clase +1. Esta regla de predicción es común a todos los modelos lineales de clasificación. Nuevamente, hay muchas formas diferentes de encontrar los coeficientes (w) y la intersección (b).

Existen muchos algoritmos para aprender modelos lineales. Todos estos algoritmos difieren de las dos formas siguientes:

- La forma en que miden qué tan bien se ajusta una combinación particular de coeficientes e intersección a los datos de entrenamiento
- Si y qué tipo de regularización utilizan

Los diferentes algoritmos eligen diferentes formas de medir lo que significa “adaptarse bien al conjunto de entrenamiento”. Por razones técnicas matemáticas, no es posible ajustar w y b para minimizar el número de clasificaciones erróneas que producen los algoritmos, como cabría esperar. Para muchas aplicaciones, las diferentes opciones para el elemento 1 en la lista anterior (llamadas funciones de pérdida) son de poca importancia.

Los dos algoritmos de clasificación lineal más comunes son la regresión logística, implementada en `linear_model.LogisticRegression`, y las máquinas de vectores de soporte lineal (SVM lineales), implementadas en `svm.LinearSVC`

(SVC significa clasificador de vectores de soporte). A pesar de su nombre, *LogisticRegression* es un algoritmo de clasificación y no un algoritmo de regresión, y no debe confundirse con *LinearRegression*.

Se puede aplicar los modelos *LogisticRegression* y *LinearSVC* al conjunto de datos de forge y visualizar el límite de decisión tal como lo encuentran los modelos lineales (28.14).

```
from sklearn.linear_model \
    import LogisticRegression
from sklearn.svm import LinearSVC

X, y = mglearn.datasets.make_forge()

fig, axes = plt.subplots(1, 2, figsize=(10, 3))

for model, ax in zip([LinearSVC(), \
                      LogisticRegression()], \
                      axes):
    clf = model.fit(X, y)
    mglearn.plots.plot_2d_separator(clf, X,
                                   fill=False,
                                   eps=0.5,
                                   ax=ax,
                                   alpha=.7)
    mglearn.discrete_scatter(X[:, 0], \
                              X[:, 1], \
                              y, \
                              ax=ax)
    ax.set_title(clf.__class__.__name__)
    ax.set_xlabel("característica 0")
    ax.set_ylabel("característica 1")
axes[0].legend()
```




Figura 28.14: Límites de decisión de una SVM lineal y regresión logística en el conjunto de datos de forge con los parámetros predeterminados

En esta figura 28.14, se tiene la primera característica del conjunto de datos de *force* en el eje X y la segunda característica en el eje Y, como antes. Se Muestra los límites de decisión encontrados por *LinearSVC* y *LogisticRegression* respectivamente como líneas rectas, separando el área clasificada como clase 1 en la parte superior del área clasificada como clase 0 en la parte inferior. En otras palabras, cualquier punto de datos nuevo que se encuentre por encima de la línea negra será clasificado como clase 1 por el clasificador respectivo, mientras que cualquier punto que esté por debajo de la línea negra se clasificará como clase 0.

Hay otro aspecto interesante de cómo actúa el parámetro C . El uso de valores bajos de C hará que los algoritmos intenten ajustarse a la “mayoría” de los puntos de datos, mientras que el uso de un valor más alto de C enfatiza la importancia de que cada punto de datos individual se clasifique correctamente. Aquí hay una ilustración usando *LinearSVC*




Figura 28.15: Límites de decisión de una SVM lineal en el conjunto de datos de force para diferentes valores de C

En el lado izquierdo, se tiene una C muy pequeña que corresponde a mucha regularización. La mayoría de los puntos en la clase 0 están en la parte inferior y la mayoría de los puntos en la clase 1 están en la parte superior. El modelo fuertemente regularizado elige una línea relativamente horizontal, clasificando erróneamente dos puntos. En la gráfica central, C es ligeramente más alta y el

modelo se enfoca más en las dos muestras mal clasificadas, inclinando el límite de decisión. Finalmente, en el lado derecho, el valor muy alto de C en el modelo inclina mucho el límite de decisión, ahora clasificando correctamente todos los puntos en la clase 0. Uno de los puntos en la clase 1 todavía está mal clasificado, ya que no es posible correctamente clasifique todos los puntos en este conjunto de datos usando una línea recta. El modelo ilustrado en el lado derecho intenta clasificar correctamente todos los puntos, pero es posible que no capture bien el diseño general de las clases. En otras palabras, es probable que este modelo esté sobreajustado.

De manera similar al caso de la regresión, los modelos lineales para la clasificación pueden parecer muy restrictivos en espacios de baja dimensión, y solo permiten límites de decisión que son líneas rectas o planos. Nuevamente, en grandes dimensiones, los modelos lineales para clasificación se vuelven muy poderosos y la protección contra el sobreajuste se vuelve cada vez más importante cuando se consideran más características.

A continuación se analiza la regresión logística con más detalle en el conjunto de datos del cáncer de mama:

```
from sklearn.datasets import \
    load_breast_cancer
cancer = load_breast_cancer()
X_train, X_test, y_train, y_test = \
    train_test_split(
        cancer.data,
        cancer.target,
        stratify=cancer.target,
        random_state=42)
logreg = LogisticRegression()\
    .fit(X_train, y_train)
print("Score conjunto entrenamiento: {:.3f}"\
      .format(logreg.score(X_train, y_train)))
print("Score conjunto test: {:.3f}"\
      .format(logreg.score(X_test, y_test)))
```

```
Score conjunto entrenamiento: 0.955
Score conjunto test: 0.958
```

El valor predeterminado de $C = 1$ proporciona un rendimiento bastante bueno, con una precisión del 95 % tanto en el entrenamiento como en el conjunto de test. Pero como el rendimiento del conjunto de entrenamiento y de test está muy cerca, es probable que se esté desajustado. Se Intentará aumentar C para que se ajuste a un modelo más flexible:

```
logreg100 = LogisticRegression(C=100)\
    .fit(X_train, y_train)
print("Score conjunto entrenamiento: {:.3f}"\
      .format(logreg100\
              .score(X_train, y_train)))
print("Score conjunto test: {:.3f}"\
      .format(logreg100\
              .score(X_test, y_test)))
```

```
.format(logreg100\  
        .score(X_test, y_test)))
```

Score conjunto entrenamiento: 0.972

Score conjunto test: 0.965

El uso de $C = 100$ da como resultado una mayor precisión del conjunto de entrenamiento y también una precisión ligeramente mayor del conjunto de test, lo que confirma la intuición de que un modelo más complejo debería funcionar mejor.

También se puede investigar qué sucede si se usa un modelo aún más regularizado que el predeterminado de $C = 1$, estableciendo $C = 0.01$:

```
logreg001 = LogisticRegression(C=0.01)\  
        .fit(X_train, y_train)  
print("Score conjunto entrenamiento: {:.3f}"\  
      .format(logreg001.score(X_train, y_train)))  
print("Score conjunto test: {:.3f}"\  
      .format(logreg001.score(X_test, y_test)))
```

Score conjunto entrenamiento: 0.934

Score conjunto test: 0.930

Como era de esperar, cuando se mueve más hacia la izquierda a lo largo de la escala que se muestra en la Figura 28.1 desde un modelo que ya no está en forma, tanto el entrenamiento como la precisión del conjunto de test disminuyen en relación con los parámetros predeterminados.

Finalmente, se comprobará los coeficientes aprendidos por los modelos con las tres configuraciones diferentes del parámetro de regularización C (Figura 28.16):

```
plt.plot(logreg.coef_.T, 'o', label="C=1")  
plt.plot(logreg100.coef_.T, '^', label="C=100")  
plt.plot(logreg001.coef_.T, 'v', label="C=0.001")  
plt.xticks(range(cancer.data.shape[1]),  
          cancer.feature_names,  
          rotation=90)  
plt.hlines(0, 0, cancer.data.shape[1])  
plt.ylim(-5, 5)  
plt.xlabel("Característica")  
plt.ylabel("Coeficiente de magnitud")  
plt.legend()
```

Observación 28.4 Como *LogisticRegression* aplica una regularización L_2 por defecto, el resultado es similar al producido por *Ridge* en la Figura 28.12. Una regularización más fuerte empuja los coeficientes cada vez más hacia cero, aunque los coeficientes nunca llegan a ser exactamente cero. Al inspeccionar la




Figura 28.16: Coeficientes aprendidos por regresión logística en el conjunto de datos de cáncer de mama para diferentes valores de C

gráfica más de cerca, también se puede ver un efecto interesante en el tercer coeficiente, para el “perímetro medio”. Para $C = 100$ y $C = 1$, el coeficiente es negativo, mientras que para $C = 0.001$, el coeficiente es positivo, con una magnitud que es incluso mayor que para $C = 1$. Al interpretar un modelo como este, uno podría pensar que el coeficiente dice con qué clase está asociada una característica. Por ejemplo, se podría pensar que una característica de alto “error de textura” está relacionada con una muestra que es “maligna”. Sin embargo, el cambio de signo en el coeficiente de “perímetro medio” significa que, según el modelo que se mire, un “perímetro medio” alto podría considerarse como indicativo de “benigno” o como indicativo de “maligno”. Esto ilustra que las interpretaciones de los coeficientes de los modelos lineales siempre deben tomarse con cautela.

Si se desea un modelo más interpretable, el uso de la regularización L1 podría ayudar, ya que limita el modelo a usar solo unas pocas características. Aquí está el gráfico de coeficientes y las precisiones de clasificación para la regularización L1 (Figura 28.17):

```
for C, marker in zip([0.001, 1, 100],\
                    ['o', '^', 'v']):
    lr_l1 = LogisticRegression(C=C,\
                               penalty="l1")\
        .fit(X_train, y_train)
    print("Exactitud Entrenamiento de L1\n"
          "logreg con C={:.3f}: {:.2f}"\
```

```
        .format(
            C,
            lr_l1.score(X_train, y_train)))
print("Exactitud Test de L1
      logreg con C={:.3f}: {:.2f}" \
      .format(
          C,
          lr_l1.score(X_test, y_test)))
plt.plot(lr_l1.coef_.T,
         marker,
         label="C={:.3f}".format(C))

plt.xticks(range(cancer.data.shape[1]),
           cancer.feature_names,
           rotation=90)
plt.hlines(0, 0, cancer.data.shape[1])
plt.xlabel("Característica")
plt.ylabel("Coeficiente magnitud")

plt.ylim(-5, 5)
plt.legend(loc=3)
```

```
Exactitud Entrenamiento de L1 logreg con C=0.001: 0.91
Exactitud Test de L1 logreg con C=0.001: 0.92
Exactitud Entrenamiento de L1 logreg con C=1.000: 0.96
Exactitud Test de L1 logreg con C=1.000: 0.96
Exactitud Entrenamiento de L1 logreg con C=100.000: 0.99
Exactitud Test de L1 logreg con C=100.000: 0.98
```

Como se puede ver, existen muchos paralelismos entre los modelos lineales para la clasificación binaria y los modelos lineales para la regresión. Al igual que en la regresión, la principal diferencia entre los modelos es el parámetro de *penalty*, que influye en la regularización y si el modelo utilizará todas las funciones disponibles o seleccionará solo un subconjunto.

5.4. Modelos Lineales para Clasificación Multiclase

Muchos modelos de clasificación lineal son solo para clasificación binaria y no se extienden naturalmente al caso multiclase (con la excepción de la regresión logística). Una técnica común para extender un algoritmo de clasificación binaria a un algoritmo de clasificación multiclase es el enfoque de uno frente al resto. En el enfoque de uno contra el resto, se aprende un modelo binario para cada clase que intenta separar esa clase de todas las otras clases, lo que da como resultado tantos modelos binarios como clases. Para hacer una predicción, todos los clasificadores binarios se ejecutan en un punto de prueba. El clasificador que tiene la puntuación más alta en su clase única “gana” y esta etiqueta de clase se devuelve como predicción.

Tener un clasificador binario por clase da como resultado un vector de coeficientes (w) y una intersección (b) para cada clase. La clase para la cual




Figura 28.17: Coeficientes aprendidos por regresión logística con penalización L1 en el conjunto de datos de cáncer de mama para diferentes valores de C

el resultado de la fórmula de confianza de clasificación dada aquí es más alto es la etiqueta de clase asignada:

$$w[0] \times x[0] + w[1] \times x[1] + \dots + w[p] \times x[p] + b$$

Las matemáticas detrás de la regresión logística multiclase difieren un poco del enfoque de uno contra el resto, pero también dan como resultado un vector de coeficiente y una intersección por clase, y se aplica el mismo método para hacer una predicción.

Se va aplica el método de uno frente al resto a un conjunto de datos de clasificación simple de tres clases. Se usará un conjunto de datos bidimensionales, donde cada clase viene dada por datos muestreados de una distribución gaussiana (ver Figura 28.18):

```
from sklearn.datasets import make_blobs

X, y = make_blobs(random_state=42)
mglearn.discrete_scatter(X[:, 0], X[:, 1], y)
plt.xlabel("Feature 0")
plt.ylabel("Feature 1")
plt.legend(["Class 0", "Class 1", "Class 2"])
```

Ahora, se entrenara un clasificador *LinearSVC* en el conjunto de datos:

```
linear_svm = LinearSVC().fit(X, y)
print("Forma coeficientes: ", linear_svm.coef_.shape)
```




Figura 28.18: Conjunto de datos de juguetes bidimensionales que contiene tres clases

```
print("Forma ordenada en el origen: ", linear_svm.intercept_.shape)
```

```
Forma coeficientes: (3, 2)
Forma ordenada en el origen: (3,)
```

Se puede ver que la forma de los coeficientes es (3, 2), lo que significa que cada fila de coeficientes contiene el vector de coeficiente para una de las tres clases y cada columna contiene el valor del coeficiente para una característica específica (hay dos en este conjunto de datos). La ordenada en el origen es ahora una matriz unidimensional, que almacena las intersecciones con el eje Y para cada clase.

Si se visualiza las líneas dadas por los tres clasificadores binarios (Figura 28.19)

```
mglearn.discrete_scatter(X[:, 0], X[:, 1], y)
line = np.linspace(-15, 15)
for coef, intercept, color in\
    zip(linear_svm.coef_,
        linear_svm.intercept_,
        mglearn.cm3.colors):
    plt.plot(line,
             -(line * coef[0] + intercept) / coef[1],
             c=color)
plt.ylim(-10, 15)
plt.xlim(-10, 8)
plt.xlabel("Característica 0")
plt.ylabel("Característica 1")
plt.legend(['Clase 0', 'Clase 1',
            'Clase 2', 'Linea clase 0',
            'Linea clase 1',
```

```
'Line class 2'],
loc=(1.01, 0.3))
```

Se puede ver que todos los puntos que pertenecen a la clase 0 en los datos de entrenamiento están por encima de la línea correspondiente a la clase 0, lo que significa que están en el lado de la “clase 0” de este clasificador binario. Los puntos de la clase 0 están por encima de la línea correspondiente a la clase 2, lo que significa que están clasificados como “resto” por el clasificador binario de la clase 2. Los puntos pertenecientes a la clase 0 están a la izquierda de la línea correspondiente a la clase 1, que significa que el clasificador binario para la clase 1 también los clasifica como “resto”. Por lo tanto, cualquier punto en esta área será clasificado como clase 0 por el clasificador final (el resultado de la fórmula de confianza de clasificación para el clasificador 0 es mayor que cero, mientras que es menor que cero para las otras dos clases).

Pero, ¿qué pasa con el triángulo en el medio del gráfico? Los tres clasificadores binarios clasifican los puntos allí como “reposo”. ¿A qué clase se le asignaría un punto? La respuesta es la que tiene el valor más alto para la fórmula de clasificación: la clase de la línea más cercana.




Figura 28.19: Límites de decisión aprendidos por los tres clasificadores uno versus resto

El siguiente ejemplo (Figura 28.20) muestra las predicciones para todas las regiones del espacio 2D:

```
mglearn.plots.plot_2d_classification(linear_svm,
                                     X,
                                     fill=True,
                                     alpha=.7)
mglearn.discrete_scatter(X[:, 0],
                          X[:, 1],
                          y)
line = np.linspace(-15, 15)
for coef, intercept, color in zip(linear_svm.coef_,
                                   linear_svm.intercept_,
```

```

mglearn.cm3.colors):

plt.plot(line,
         -(line * coef[0] + intercept) / coef[1],
         c=color)
plt.legend(['Clase 0', 'Clase 1',
           'Clase 2', 'Linea clase 0',
           'Linea clase 1', 'Linea clase 2'], \
          loc=(1.01, 0.3))
plt.xlabel("Característica 0")
plt.ylabel("Característica 1")

```




Figura 28.20: Límites de decisión multiclase derivados de los tres clasificadores uno versus resto

Fortalezas, Debilidades y Parámetros

El principal parámetro de los modelos lineales es el parámetro de regularización, llamado alfa en los modelos de regresión y C en *LinearSVC* y *LogisticRegression*. Los valores grandes para alfa o los valores pequeños para C significan modelos simples. En particular para los modelos de regresión, el ajuste de estos parámetros es muy importante. Por lo general, C y alfa se buscan en una escala logarítmica. La otra decisión que debe tomar es si desea utilizar la regularización L1 o la regularización L2. Si asume que solo algunas de sus funciones son realmente importantes, debe usar L1. De lo contrario, debería utilizar L2 de forma predeterminada. L1 también puede ser útil si la interpretabilidad del modelo es importante. Como L1 usará solo algunas características, es más fácil explicar qué características son importantes para el modelo y cuáles son los efectos de estas características.

Los modelos lineales son muy rápidos de entrenar y también rápidos de predecir. Se escalan a conjuntos de datos muy grandes y funcionan bien con datos escasos. Si los datos constan de cientos de miles o millones de muestras, es posible que se desee investigar utilizando la opción `solver = 'sag'` en *LogisticRegression* y *Ridge*, que puede ser más rápida que la predeterminada en grandes conjuntos de datos. Otras opciones son la clase *SGDClassifier* y

la clase *SGDRegressor*, que implementan versiones aún más escalables de los modelos lineales descritos aquí.

Otro punto fuerte de los modelos lineales es que facilitan relativamente la comprensión de cómo se hace una predicción, utilizando las fórmulas que se han visto anteriormente para la regresión y la clasificación. Desafortunadamente, a menudo no está del todo claro por qué los coeficientes son como son. Esto es particularmente cierto si el conjunto de datos tiene características altamente correlacionadas; en estos casos, los coeficientes pueden ser difíciles de interpretar.

Los modelos lineales suelen funcionar bien cuando la cantidad de características es grande en comparación con la cantidad de muestras. También se utilizan a menudo en conjuntos de datos muy grandes, simplemente porque no es factible entrenar otros modelos. Sin embargo, en espacios de dimensiones inferiores, otros modelos pueden producir un mejor rendimiento de generalización. Más adelante se verán algunos ejemplos en los que los modelos lineales fallan.

Observación 28.5 *El método de ajuste (fit) de todos los modelos de scikit-learn devuelve self. Esto permite escribir código como el siguiente, que ya se ha utilizado ampliamente en este capítulo:*

```
logreg = LogisticRegression().fit(X_train, y_train)
```

Aquí, se ha el valor de retorno fit (que es self) para asignar el modelo entrenado a la variable logreg. Esta concatenación de llamadas a métodos (aquí __init__ y luego fit) se conoce como encadenamiento de métodos. Otra aplicación común del encadenamiento de métodos en scikit-learn es encajar y predecir en una línea:

```
logreg = LogisticRegression()
y_pred = logreg.fit(X_train, y_train).\
    predict(X_test)
```

Por último, incluso se puede crear instancias, ajustes y predicciones de modelos en una línea:

```
y_pred = LogisticRegression().\
    fit(X_train, y_train).\
    predict(X_test)
```

Sin embargo, esta variante muy corta no es ideal. Están sucediendo muchas cosas en una sola línea, lo que puede dificultar la lectura del código. Además, el modelo de regresión logística ajustado no se almacena en ninguna variable, por lo que no se puede inspeccionar ni usar para predecir sobre otros datos.

6. Clasificador Naive Bayes

Los clasificadores Naive Bayes son una familia de clasificadores que son bastante similares a los modelos lineales discutidos en la sección anterior. Sin embargo, tienden a ser incluso más rápidos en el entrenamiento. El precio que se paga por esta eficiencia es que los modelos Naive Bayes a menudo

proporcionan un rendimiento de generalización que es ligeramente peor que el de los clasificadores lineales como *LogisticRegression* y *LinearSVC*.

En un sentido amplio, los modelos de Naive Bayes son una clase especial de algoritmos de clasificación de Machine Learning. Se basan en una técnica de clasificación estadística llamada “teorema de Bayes”.

Estos modelos son llamados algoritmos “Naive”, o “Inocentes” en español. Asume que el efecto de una característica particular en una clase es independiente de otras características. Por ejemplo, un solicitante de préstamo es deseable o no dependiendo de sus ingresos, historial de préstamos y transacciones anteriores, edad y ubicación. Incluso si estas características son interdependientes, estas características se consideran de forma independiente. Esta suposición simplifica la computación, y por eso se considera ingenua. Esta suposición se denomina independencia condicional de clase.

La formula del teorema de Bayes es la siguiente:

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

Donde:

- $P(h)$: es la probabilidad de que la hipótesis h sea cierta (independientemente de los datos). Esto se conoce como la probabilidad previa de h .
- $P(D)$: probabilidad de los datos (independientemente de la hipótesis). Esto se conoce como probabilidad previa.
- $P(h|D)$: es la probabilidad de la hipótesis h dada los datos D . Esto se conoce como la probabilidad posterior.
- $P(D|h)$: es la probabilidad de los datos d dado que la hipótesis h era cierta. Esto se conoce como probabilidad posterior.

La razón por la que los modelos Naive Bayes son tan eficientes es que aprenden los parámetros al observar cada característica individualmente y recopilan estadísticas simples por clase de cada característica. Hay tres tipos de clasificadores Naive Bayes implementados en *scikit-learn*: *GaussianNB*, *BernoulliNB* y *MultinomialNB*.

GaussianNB se puede aplicar a cualquier dato continuo, mientras que *BernoulliNB* asume datos binarios y *MultinomialNB* asume datos de recuento (es decir, que cada característica representa un recuento entero de algo, como la frecuencia con la que aparece una palabra en una oración). *BernoulliNB* y *MultinomialNB* se utilizan principalmente en la clasificación de datos de texto.

El clasificador *BernoulliNB* cuenta la frecuencia con la que cada característica de cada clase no es cero. Esto se entiende más fácilmente con un ejemplo:

```
X = np.array([[0, 1, 0, 1],
              [1, 0, 1, 1],
              [0, 0, 0, 1],
              [1, 0, 1, 0]])
y = np.array([0, 1, 0, 1])
```

Aquí, se tiene cuatro puntos de datos, con cuatro características binarias cada uno. Hay dos clases, 0 y 1. Para la clase 0 (el primer y tercer punto de datos), la primera característica es cero dos veces y cero veces distinto de cero, la segunda característica es cero una vez y diferente de cero una vez, y así sucesivamente. Estos mismos recuentos se calculan luego para los puntos de datos de la segunda clase. En esencia, contar las entradas distintas de cero por clase se ve así:

```
counts = {}
for label in np.unique(y):
    # Itera sobre cada clase
    # recuenta (sum) entradas de 1 por caracterisitca
    counts[label] = X[y == label].sum(axis=0)
print("recuento de características:\n", counts)
```

Los otros dos modelos Naive de Bayes, *MultinomialNB* y *GaussianNB*, son ligeramente diferentes en los tipos de estadísticas que calculan. *MultinomialNB* tiene en cuenta el valor promedio de cada característica para cada clase, mientras que *GaussianNB* almacena el valor promedio así como la desviación estándar de cada característica para cada clase.

Para hacer una predicción, se compara un punto de datos con las estadísticas de cada una de las clases y se predice la mejor clase coincidente. Curiosamente, tanto para *MultinomialNB* como para *BernoulliNB*, esto conduce a una fórmula de predicción que tiene la misma forma que en los modelos lineales. Desafortunadamente, `coef_` para los modelos Naive de Bayes tiene un significado algo diferente al de los modelos lineales, ya que `coef_` no es lo mismo que `w`.

Fortalezas, Debilidades y Parámetros

GaussianNB se usa principalmente en datos de muy alta dimensión, mientras que las otras dos variantes de Naive Bayes se usan ampliamente para datos de recuento escasos, como texto. *MultinomialNB* generalmente funciona mejor que *BernoulliNB*, particularmente en conjuntos de datos con una cantidad relativamente grande de características distintas de cero (es decir, documentos grandes).

Los modelos de Naive Bayes comparten muchas de las fortalezas y debilidades de los modelos lineales. Son muy rápidos de entrenar y predecir, y el procedimiento de entrenamiento es fácil de entender. Los modelos funcionan muy bien con datos escasos de alta dimensión y son relativamente robustos a los parámetros. Los modelos Naive Bayes son excelentes modelos de línea de base y, a menudo, se usan en conjuntos de datos muy grandes, donde el entrenamiento incluso un modelo lineal puede llevar demasiado tiempo.

7. Árboles de Decisión


Muchos métodos predictivos generan modelos globales en los que una única ecuación se aplica a todo el espacio muestral. Cuando el caso de uso implica múltiples predictores, que interaccionan entre ellos de forma compleja y no lineal, es muy difícil encontrar un único modelo global que sea capaz de reflejar la relación entre las variables. Los métodos estadísticos y de machine

learning basados en árboles engloban a un conjunto de técnicas supervisadas no paramétricas que consiguen segmentar el espacio de los predictores en regiones simples, dentro de las cuales es más sencillo manejar las interacciones. Es esta característica la que les proporciona gran parte de su potencial.

Los árboles de decisión son modelos ampliamente utilizados para tareas de clasificación y regresión. Son modelos predictivos formados por reglas binarias (sí/no) con las que se consigue repartir las observaciones en función de sus atributos y predecir así el valor de la variable respuesta.

Estas preguntas son similares a las preguntas que se podrían hacer en un juego de 20 preguntas. Imaginad que se quiere distinguir entre los siguientes cuatro animales: osos, halcones, pingüinos y delfines. El objetivo es llegar a la respuesta correcta haciendo la menor cantidad posible de preguntas sí / no. Se puede comenzar preguntando si el animal tiene plumas, una pregunta que reduce sus posibles animales a solo dos. Si la respuesta es “sí”, se puede hacer otra pregunta que podría ayudar a distinguir entre halcones y pingüinos. Por ejemplo, se podría preguntar si el animal puede volar. Si el animal no tiene plumas, las posibles opciones de animales son los delfines y los osos, y se deberá hacer una pregunta para distinguir entre estos dos animales, por ejemplo, preguntar si el animal tiene aletas.

Esta serie de cuestiones se pueden expresar en un árbol de decisión, como se muestra en 7



En este gráfico, cada nodo del árbol representa una pregunta o un nodo terminal (también llamado hoja) que contiene la respuesta. Los bordes conectan las respuestas a una pregunta con la siguiente pregunta que haría.

En el lenguaje de machine learning, se crea un modelo para distinguir entre cuatro clases de animales (halcones, pingüinos, delfines y osos) utilizando las tres características “tiene plumas”, “puede volar” y “tiene aletas”. En lugar de construir estos modelos a mano, se pueden aprenderlos a partir de los datos mediante el aprendizaje supervisado.

7.1. Términos Asociados

Los árboles de decisión pueden manejar datos complejos, que es parte de lo que los hace útiles. Sin embargo, esto no significa que sean difíciles de entender. En esencia, todos los árboles de decisión constan de:

Nodo Raíz: representa toda la población o muestra y esta se divide en dos o más conjuntos homogéneos.

División: es un proceso de división de un nodo en dos o más subnodos.


Nodo de decisión: cuando un subnodo se divide en otros subnodos, se denomina nodo de decisión.

Nodo hoja / terminal: los nodos que no se dividen se denominan nodo hoja o terminal.

Poda: cuando eliminamos subnodos de un nodo de decisión, este proceso se llama poda. Se puede decir el proceso opuesto a la división.

Rama / Subárbol: una subsección de todo el árbol se denomina rama o subárbol.

Nodo padre e hijo: un nodo, que se divide en subnodos, se denomina nodo padre de subnodos, mientras que los subnodos son hijos de un nodo padre.



Si se utilizan de forma eficaz, los árboles de decisión son herramientas muy poderosas. Sin embargo, como cualquier algoritmo, no se adaptan a todas las situaciones. A continuación, se muestran algunas ventajas y desventajas clave de los árboles de decisión.

Ventajas

- Los árboles son fáciles de interpretar aun cuando las relaciones entre predictores son complejas.
- Los modelos basados en un solo árbol (no es el caso de random forest, boosting) se pueden representar gráficamente aun cuando el número de predictores es mayor de 3.

- Los árboles pueden, en teoría, manejar tanto predictores numéricos como categóricos sin tener que crear variables dummy o one-hot-encoding. En la práctica, esto depende de la implementación del algoritmo que tenga cada librería.
- Al tratarse de métodos no paramétricos, no es necesario que se cumpla ningún tipo de distribución específica.
- Por lo general, requieren mucha menos limpieza y preprocesado de los datos en comparación con otros métodos de aprendizaje estadístico (por ejemplo, no requieren estandarización).
- No se ven muy influenciados por outliers.
- Si para alguna observación, el valor de un predictor no está disponible, a pesar de no poder llegar a ningún nodo terminal, se puede conseguir una predicción empleando todas las observaciones que pertenecen al último nodo alcanzado. La precisión de la predicción se verá reducida pero al menos podrá obtenerse.
- Son muy útiles en la exploración de datos, permiten identificar de forma rápida y eficiente las variables (predictores) más importantes.
- Son capaces de seleccionar predictores de forma automática.
- Pueden aplicarse a problemas de regresión y clasificación.

Desventajas

- La capacidad predictiva de los modelos basados en un único árbol es bastante inferior a la conseguida con otros modelos. Esto es debido a su tendencia al overfitting y alta varianza. Sin embargo, existen técnicas más complejas que, haciendo uso de la combinación de múltiples árboles (bagging, random forest, boosting), consiguen mejorar en gran medida este problema.
- Son sensibles a datos de entrenamiento desbalanceados (una de las clases domina sobre las demás).
- Cuando tratan con predictores continuos, pierden parte de su información al categorizarlos en el momento de la división de los nodos.
- Tal y como se describe más adelante, la creación de las ramificaciones de los árboles se consigue mediante el algoritmo de recursive binary splitting. Este algoritmo identifica y evalúa las posibles divisiones de cada predictor acorde a una determinada medida (RSS, Gini, entropía ...). Los predictores continuos tienen mayor probabilidad de contener, solo por azar, algún punto de corte óptimo, por lo que suelen verse favorecidos en la creación de los árboles.
- No son capaces de extrapolar fuera del rango de los predictores observado en los datos de entrenamiento.

La principal implementación de árboles de decisión en Python está disponible en la librería **scikit-learn** a través de las clases **DecisionTreeClassifier** y **DecisionTreeRegressor**. Una característica importante para aquellos que han utilizado otras implementaciones es que, en **scikit-learn**, es necesario convertir las variables categóricas en variables dummy (*one-hot-encoding*).

7.2. Árboles de Regresión

Los árboles de regresión son el subtipo de árboles de predicción que se aplica cuando la variable respuesta es continua. En términos generales, en el entrenamiento de un árbol de regresión, las observaciones se van distribuyendo por bifurcaciones (nodos) generando la estructura del árbol hasta alcanzar un nodo terminal. Cuando se quiere predecir una nueva observación, se recorre el árbol acorde al valor de sus predictores hasta alcanzar uno de los nodos terminales. La predicción del árbol es la media de la variable respuesta de las observaciones de entrenamiento que están en ese mismo nodo terminal.

Entrenamiento del Árbol

El proceso de entrenamiento de un árbol de predicción (regresión o clasificación) se divide en dos etapas:

- División sucesiva del espacio de los predictores generando regiones no solapantes (nodos terminales) $R_1, R_2, R_3, \dots, R_j$. Aunque, desde el punto de vista teórico las regiones podrían tener cualquier forma, si se limitan a regiones rectangulares (de múltiples dimensiones), se simplifica en gran medida el proceso de construcción y se facilita la interpretación.
- Predicción de la variable respuesta en cada región.

A pesar de la sencillez con la que se puede resumir el proceso de construcción de un árbol, es necesario establecer una metodología que permita crear las regiones $R_1, R_2, R_3, \dots, R_j$, o lo que es equivalente, decidir donde se introducen las divisiones: en que predictores y en que valores de los mismos. Es en este punto donde se diferencian los algoritmos de árboles de regresión y clasificación.

En los árboles de regresión, el criterio empleado con más frecuencia para identificar las divisiones es el Residual Sum of Squares (RSS). El objetivo es encontrar las J regiones ($R_1, R_2, R_3, \dots, R_j$) que minimizan el *Residual Sum of Squares (RSS) total*:

$$\text{RSS} = \sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})$$

donde $\hat{y}_{R_j}$ es la media de la variable respuesta en la región R_j . Una descripción menos técnica equivale a decir que se busca una distribución de regiones tal que, el sumatorio de las desviaciones al cuadrado entre las observaciones y la media de la región a la que pertenecen sea lo menor posible.

Desafortunadamente, no es posible considerar todas las posibles particiones del espacio de los predictores. Por esta razón, se recurre a lo que se conoce como *recursive binary splitting* (división binaria recursiva). Esta solución sigue la misma idea que la selección de predictores *stepwise* (*backward* o *forward*) en

regresión lineal múltiple, no evalúa todas las posibles regiones pero, alcanza un buen balance computación-resultado.

Recursive binary splitting

El objetivo del método recursive binary splitting es encontrar, en cada iteración, el predictor X_j y el punto de corte (umbral) s tal que, si se distribuyen las observaciones en las regiones $\{X|X_j < s\}$ y $\{X|X_j = s\}$, se consigue la mayor reducción posible en el RSS. El algoritmo seguido es:

1. El proceso se inicia en lo más alto del árbol, donde todas las observaciones pertenecen a la misma región.
2. Se identifican todos los posibles puntos de corte s para cada uno de los predictores $(X_1, X_2, \dots, X_p)$. En el caso de predictores cualitativos, los posibles puntos de corte son cada uno de sus niveles. Para predictores continuos, se ordenan de menor a mayor sus valores, el punto intermedio entre cada par de valores se emplea como punto de corte.
3. Se calcula el RSS total que se consigue con cada posible división identificada en el paso 2.

$$\sum_{i: x_i \in R_1(j,s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j,s)} (y_i - \hat{y}_{R_2})^2$$

donde el primer término es el RSS de la región 1 y el segundo término es el RSS de la región 2, siendo cada una de las regiones el resultado de separar las observaciones acorde al predictor j y valor s .

1. Se selecciona el predictor X_j y el punto de corte S que resulta en el menor RSS total, es decir, que da lugar a las divisiones más homogéneas posibles. Si existen dos o más divisiones que consiguen la misma mejora, la elección entre ellas es aleatoria.
2. Se repiten de forma iterativa los pasos 1 a 4 para cada una de las regiones que se han creado en la iteración anterior hasta que se alcanza alguna norma de stop. Algunas de las más empleadas son: alcanzar una profundidad máxima, que ninguna región contenga menos de n observaciones, que el árbol tenga un máximo de nodos terminales o que la incorporación del más nodos no reduzca el error en al menos un % mínimo.

Observación 28.6 *Está metodología conlleva dos hechos:*

- *Que cada división óptima se identifica acorde al impacto que tiene en ese momento. No se tiene en cuenta si es la división que dará lugar a mejores árboles en futuras divisiones.*
- *En cada división se evalúa un único predictor haciendo preguntas binarias (sí, no), lo que genera dos nuevas ramas del árbol por división. A pesar de que es posible evaluar divisiones más complejas, hacer una pregunta sobre múltiples variables a la vez es equivalente a hacer múltiples preguntas sobre variables individuales.*

Aunque la anterior es la forma más común de obtener las predicciones de un árbol de regresión, existe otra aproximación. La predicción de un árbol de regresión puede verse como una variante de vecinos cercanos en la que, solo las observaciones que forman parte del mismo nodo terminal que la observación predicha, tienen influencia. Siguiendo esta aproximación, la predicción del árbol se define como la media ponderada de todas las observaciones de entrenamiento, donde el peso de cada observación depende únicamente de si forma parte o no del mismo nodo terminal.

$$\hat{\mu} = \sum_{i=1}^n w_i Y_i$$

El valor de las posiciones del vector de pesos w es 1 para las observaciones que están en el mismo nodo y 0 para el resto. En este ejemplo sería:

$$w = (0, 1, 1, 0, 1, 0, 0, 0, 1, 0)$$

Para que la suma de todos los pesos sea 1, se dividen por el número total de observaciones en el nodo terminal seleccionado, en este caso 4.

$$w = (0, \frac{1}{4}, \frac{1}{4}, 0, \frac{1}{4}, 0, 0, 0, \frac{1}{4}, 0)$$

Así pues, el valor predicho es:

$$\begin{aligned}\hat{\mu} &= (0 \times 10) + (\frac{1}{4} \times 18) + (\frac{1}{4} \times 24) + \\ &\quad + (0 \times 8) + (\frac{1}{4} \times 2) + (0 \times 9) + \\ &\quad + (0 \times 16) + (0 \times 10) + (\frac{1}{4} \times 20) + (0 \times 14) \\ &= 16\end{aligned}$$

7.3. Árboles de Clasificación

Los árboles de clasificación son el subtipo de árboles de predicción que se aplica cuando la variable respuesta es categórica.

Construcción del Árbol

Para construir un árbol de clasificación, se emplea el mismo método recursive binary splitting descrito en los árboles de regresión. Sin embargo, como la variable respuesta es cualitativa, no se puede emplear el RSS como criterio de selección de las divisiones óptimas. Existen varias alternativas, todas ellas con el objetivo de encontrar nodos lo más puros/homogéneos posible.

La decisión de realizar divisiones estratégicas afecta en gran medida la precisión de un árbol. La pureza del nodo debería aumentar con respecto a la variable objetivo después de cada división.

Los árboles de decisión utilizan múltiples algoritmos para decidir dividir un nodo en dos o más subnodos. La creación de subnodos aumenta la homogeneidad de los subnodos resultantes. En otras palabras, la pureza del nodo aumenta con respecto a la variable objetivo. El árbol de decisión divide los nodos en todas

las variables disponibles y luego selecciona la división que da como resultado los subnodos más homogéneos.

La creación de un árbol de decisión de un problema de clasificación se lleva a cabo aplicando el algoritmo de Hunt que se basa en la división en sub-conjuntos que buscan una separación óptima.

La construcción de un árbol de decisión consta de las siguientes tres partes:

1. Selección de nodos
2. Generación del árbol de decisiones
3. Poda del árbol de decisión

Selección de nodos Para seleccionar qué variable elegir para obtener la mejor división se puede considerar el Error de Clasificación, el índice Gini (rpart), la Entropía (C50) o Chi-cuadrado (χ^2).

Error de Clasificación Se define como la proporción de observaciones que no pertenecen a la clase mayoritaria del nodo.

$$E_m = 1 - \max_k(\hat{p}_{mk})$$

donde $\hat{p}_{mk}$ representa la proporción de observaciones del nodo m que pertenecen a la clase k . A pesar de la sencillez de esta medida, no es suficientemente sensible para crear buenos árboles, por lo que, en la práctica, no suele emplearse.

Índice de Gini El índice de Gini mide el grado de pureza de un nodo. Mide la probabilidad de no sacar dos registros de la misma clase del nodo. A mayor índice de Gini menor pureza, por lo que se seleccionará la variable con menor Gini ponderado. Suele seleccionar divisiones desbalanceadas, donde normalmente aísla en un nodo una clase mayoritaria y el resto de clases los clasifica en otros nodos.

Se cuantifica la varianza total en el conjunto de las K clases del nodo m , es decir, mide la pureza del nodo.

$$G_m = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$

Cuando $\hat{p}_{mk}$ es cercano a 0 o a 1 (el nodo contiene mayoritariamente observaciones de una sola clase), el término $\hat{p}_{mk}(1 - \hat{p}_{mk})$ es muy pequeño. Como consecuencia, cuanto mayor sea la pureza del nodo, menor el valor del índice Gini G .

Entropía La entropía es una forma de cuantificar el desorden de un sistema. En el caso de los nodos, el desorden se corresponde con la impureza. Si un nodo es puro, contiene únicamente observaciones de una clase, su entropía es cero. Por el contrario, si la frecuencia de cada clase es la misma, el valor de la entropía alcanza el valor máximo de 1.

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log_2 \hat{p}_{mk}$$

Chi-Cuadrado Esta aproximación consiste en identificar si existe una diferencia significativa entre los nodos hijos y el nodo parental, es decir, si hay evidencias de que la división consigue una mejora. Para ello, se aplica un test estadístico chi-square goodness of fit empleando como distribución esperada H_0 la frecuencia de cada clase en el nodo parental. Cuanto mayor el estadístico χ^2 , mayor la evidencia estadística de que existe una diferencia.

$$\chi^2 = \sum_k \frac{(\text{observado}_k - \text{esperado}_k)^2}{\text{esperado}_k}$$

Los árboles generados con este criterio de división reciben el nombre de CHAID

Independientemente de la medida empleada como criterio de selección de las divisiones, el proceso siempre es el mismo:

1. Para cada posible división se calcula el valor de la medida en cada uno de los dos nodos resultantes.
2. Se suman los dos valores, ponderando cada uno por la fracción de observaciones que contiene cada nodo. Este paso es muy importante, ya que no es lo mismo dos nodos puros con 2 observaciones, que dos nodos puros con 100 observaciones.

$$\frac{n \text{ observaciones nodo A}}{n \text{ observaciones totales}} \times \text{pureza A} + \frac{n \text{ observaciones nodo B}}{n \text{ observaciones totales}} \times \text{pureza B}$$

3. La división con menor o mayor valor (dependiendo de la medida empleada) se selecciona como punto de corte óptimo.

Para el proceso de construcción del árbol, acorde al libro Introduction to Statistical Learning, Gini index y cross-entropy son más adecuados que el classification error rate debido a su mayor sensibilidad a la homogeneidad de los nodos. Para el proceso de pruning (descrito en la siguiente sección) los tres son adecuados, aunque, si el objetivo es conseguir la máxima precisión en las predicciones, mejor emplear el classification error rate.

Predicción del Árbol

Tras la creación de un árbol, las observaciones de entrenamiento quedan agrupadas en los nodos terminales. Para predecir una nueva observación, se recorre el árbol en función del valor de sus predictores hasta llegar a uno de los nodos terminales. En el caso de clasificación, suele emplearse la moda de la variable respuesta como valor de predicción, es decir, la clase más frecuente del nodo. Además, puede acompañarse con el porcentaje de cada clase en el nodo terminal, lo que aporta información sobre la confianza de la predicción.

7.4. Controlar la complejidad de los árboles de decisión

El proceso de construcción de árboles descrito en las secciones anteriores tiende a reducir rápidamente el error de entrenamiento, es decir, el modelo se ajusta muy bien a las observaciones empleadas como entrenamiento.

La presencia de hojas puras significa que un árbol tiene una precisión del 100 % en el conjunto de entrenamiento; cada punto de datos en el conjunto de entrenamiento está en una hoja que tiene la clase mayoritaria correcta.

Como consecuencia, se genera un overfitting que reduce su capacidad predictiva al aplicarlo a nuevos datos. La razón de este comportamiento radica en la facilidad con la que los árboles se ramifican adquiriendo estructuras complejas. De hecho, si no se limitan las divisiones, todo árbol termina ajustándose perfectamente a las observaciones de entrenamiento creando un nodo terminal por observación. Existen dos estrategias para prevenir el problema de overfitting de los árboles: limitar el tamaño del árbol (parada temprana) y el proceso de podado (pruning).

Parada temprana (early stopping)

El tamaño final que adquiere un árbol puede controlarse mediante reglas de parada que detengan la división de los nodos dependiendo de si se cumplen o no determinadas condiciones. El nombre de estas condiciones puede variar dependiendo del software o librería empleada, pero suelen estar presentes en todos ellos.

Observaciones mínimas para división: define el número mínimo de observaciones que debe tener un nodo para poder ser dividido. Cuanto mayor el valor, menos flexible es el modelo.

Observaciones mínimas de nodo terminal: define el número mínimo de observaciones que deben tener los nodos terminales. Su efecto es muy similar al de observaciones mínimas para división.

Profundidad máxima del árbol: define la profundidad máxima del árbol, entendiendo por profundidad máxima el número de divisiones de la rama más larga (en sentido descendente) del árbol. Cuanto menor el valor, menos flexible es el modelo.

Número máximo de nodos terminales: define el número máximo de nodos terminales que puede tener el árbol. Una vez alcanzado el límite, se detienen las divisiones. Su efecto es similar al de controlar la profundidad máxima del árbol.

Reducción mínima de error: define la reducción mínima de error que tiene que conseguir una división para que se lleve a cabo.

Todos estos parámetros son lo que se conoce como hiperparámetros porque no se aprenden durante el entrenamiento del modelo. Su valor tiene que ser especificado por el usuario en base a su conocimiento del problema y mediante el uso de estrategias de validación.

Tree pruning

La estrategia de controlar el tamaño del árbol mediante reglas de parada tiene un inconveniente, el árbol se crece seleccionando la mejor división en cada momento. Al evaluar las divisiones sin tener en cuenta las que vendrán después, nunca se elige la opción que resulta en el mejor árbol final, a no ser que también sea la que genera en ese momento la mejor división. A este tipo de estrategias se les conoce como *greedy*.

Una alternativa no *greedy* que consigue evitar el overfitting consiste en generar árboles grandes, sin condiciones de parada más allá de las necesarias por

las limitaciones computacionales, y después podarlos (*pruning*), manteniendo únicamente la estructura robusta que consigue un test error bajo. La selección del sub-árbol óptimo puede hacerse mediante *cross-validation*, sin embargo, dado que los árboles se crecen lo máximo posible (tienen muchos nodos terminales) no suele ser viable estimar el test error de todas las posibles sub-estructuras que se pueden generar. En su lugar, se recurre al *cost complexity pruning* o *weakest link pruning*.

Cost complexity pruning es un método de penalización de tipo *Loss + Penalty*, similar al empleado en *ridge regression* o *lasso*. En este caso, se busca el sub-árbol $\mathbf{T}$ que minimiza la ecuación:

$$\sum_{j=1}^{|T|} \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2 + \alpha |T|$$

donde $|T|$ es el número de nodos terminales del árbol.

El primer término de la ecuación se corresponde con el sumatorio total de los residuos cuadrados RSS. Por definición, cuantos más nodos terminales tenga el modelo, menor será esta parte de la ecuación. El segundo término es la restricción, que penaliza al modelo en función del número de nodos terminales (a mayor número, mayor penalización). El grado de penalización se determina mediante el tuning parameter α . Cuando $\alpha = 0$, la penalización es nula y el árbol resultante es equivalente al árbol original. A medida que se incrementa α , la penalización es mayor y, como consecuencia, los árboles resultantes son de menor tamaño. El valor óptimo de α puede identificarse mediante *cross validation*.

Se comprobará el efecto de la poda previa con más detalle en el conjunto de datos de cáncer de mama. Como siempre, se importa el conjunto de datos y se divide en una parte de entrenamiento y otra de prueba. Luego, se construye un modelo usando la configuración predeterminada de desarrollar completamente el árbol (hacer crecer el árbol hasta que todas las hojas estén puras). Se arregla el *random.state* en el árbol, que se usa para romper empates internamente:

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split

cancer = load_breast_cancer()
X_train, X_test, y_train, y_test = train_test_split(
    cancer.data, cancer.target,
    stratify=cancer.target,
    random_state=42)
tree = DecisionTreeClassifier(random_state=0)
tree.fit(X_train, y_train)
print("Exactitud del entrenamiento: {:.3f}".\
      format(tree.score(X_train, y_train)))
print("Exactitud del conjunto test: {:.3f}".\
      format(tree.score(X_test, y_test)))
```

Como se esperaba, la precisión en el conjunto de entrenamiento es del 100 %; debido a que las hojas son puras, el árbol creció lo suficientemente profundo

CAPÍTULO 28. APRENDIZAJE SUPERVISADO

```
Exactitud del entrenamiento: 1.000  
Exactitud del conjunto test: 0.937
```

como para que pudiera memorizar perfectamente todas las etiquetas de los datos de entrenamiento. La precisión del conjunto de prueba es ligeramente peor que la de los modelos lineales que analizamos anteriormente, que tenían alrededor del 95 % de precisión.

Si no se restringe la profundidad de un árbol de decisiones, el árbol puede volverse arbitrariamente profundo y complejo. Por lo tanto, los árboles sin podar son propensos a sobreajustarse y no generalizarse bien a los nuevos datos. Ahora se aplicará la poda previa al árbol, lo que dejará de desarrollar el árbol antes de que encaje perfectamente con los datos de entrenamiento. Una opción es dejar de construir el árbol después de que se haya alcanzado una cierta profundidad. Aquí se establecerá *max_depth* = 4, lo que significa que solo se pueden hacer cuatro preguntas consecutivas. Limitar la profundidad del árbol disminuye el sobreajuste. Esto conduce a una menor precisión en el conjunto de entrenamiento, pero una mejora en el conjunto de prueba:

```
tree = DecisionTreeClassifier(max_depth=4, random_state=0)  
tree.fit(X_train, y_train)  
  
print("Exactitud del entrenamiento: {:.3f}".\n      format(tree.score(X_train, y_train)))  
print("Exactitud del conjunto test: {:.3f}".\n      format(tree.score(X_test, y_test)))
```

```
Exactitud del entrenamiento: 0.988  
Exactitud del conjunto test: 0.951
```

7.5. Importancia de las variables en los árboles

En lugar de mirar el árbol completo, lo que puede resultar agotador y tedioso, existen algunas propiedades útiles que se puede derivar para resumir el funcionamiento del árbol. El resumen más utilizado es la importancia de las variables, que califica la importancia de cada variable para la decisión que toma un árbol. Es un número entre 0 y 1 para cada función, donde 0 significa “no se usa en absoluto” y 1 significa “predice perfectamente el objetivo”. Las características importantes siempre suman 1:

```
print("Importancia de las variables:")  
print(tree.feature_importances_)
```


Importancia de las variables:

```
[0. 0. 0. 0. 0. 0.
 0. 0. 0. 0. 0.01019737 0.04839825
 0. 0. 0.0024156 0. 0. 0.
 0. 0. 0.72682851 0.0458159 0. 0.
 0.0141577 0. 0.018188 0.1221132 0.01188548 0.]
```

Se puede visualizar la importancia de las variables:

```
def plot_feature_importances_cancer(model):
    n_features = cancer.data.shape[1]
    plt.barh(np.arange(n_features), \
              model.feature_importances_, \
              align='center')
    plt.yticks(np.arange(n_features), cancer.feature_names)
    plt.xlabel("Importancia de las variables")
    plt.ylabel("Variables")
    plt.ylim(-1, n_features)
```

```
plot_feature_importances_cancer(tree)
```




Se puede ver que la característica utilizada en la división superior (“worst radius”) es, con mucho, la variable más importante. Esto confirma que el primer nivel ya separa bastante bien las dos clases.

Sin embargo, si una función tiene un valor bajo en *feature_importance_*, no significa que esta función no sea informativa. Solo significa que el árbol no seleccionó la variable, probablemente porque otra variable codifica la misma información.

A diferencia de los coeficientes en los modelos lineales, las variables importantes son siempre positivas y no codifican de qué clase es indicativa una variable. Las variables importantes dicen que el “worst radius” es importante, pero no si un radio alto es indicativo de que una muestra es benigna o maligna. De hecho, es posible que no exista una relación tan simple entre las características y la clase, como puede ver en el siguiente ejemplo

```
import mglearn
tree = mglearn.plots.plot_tree_not_monotone()
display(tree)
```

Feature importances: [0. 1.]



Un conjunto de datos bidimensional en el que la característica en el eje x tiene una relación no monótona con la etiqueta de clase y los límites de decisión encontrados por un árbol de decisión

La gráfica muestra un conjunto de datos con dos características y dos clases. Aquí, toda la información está contenida en $X[1]$, y $X[0]$ no se usa en absoluto. Pero la relación entre $X[1]$ y la clase de salida no es monótona, lo que significa que se puede decir “un valor alto de $X[1]$ significa clase 0, y un valor bajo significa clase 1” (o viceversa).

Si bien se centra la discusión en los árboles de decisión para la clasificación, todo lo que se dijo es igualmente cierto para los árboles de decisión para la regresión, como se implementó en *DecisionTreeRegressor*. El uso y análisis de los árboles de regresión es muy similar al de los árboles de clasificación. Sin embargo, hay una propiedad particular del uso de modelos basados en árboles para la regresión que se quiere señalar. *DecisionTreeRegressor* (y todos los demás modelos de regresión basados en árboles) no pueden extrapolar ni hacer predicciones fuera del rango de los datos de entrenamiento.


Se analizará esto con más detalle, utilizando un conjunto de datos de precios históricos de memoria de computadora (RAM) ¹. La figura 7.5 muestra el conjunto de datos, con la fecha en el eje x y el precio de un megabyte de RAM en ese año en el eje y :

```
import pandas as pd
import os
ram_prices = pd.read_csv(os.path.join(mglearn.datasets.DATA_PATH,
                                     "ram_price.csv"))

plt.semilogy(ram_prices.date, ram_prices.price)
plt.xlabel("Año")
plt.ylabel("Precio en $/Mbyte")
```

Hay que tener en cuenta la escala logarítmica del eje y . Cuando se grafica logarítmicamente, la relación parece ser bastante lineal y, por lo tanto, debería ser relativamente fácil de predecir, aparte de algunas irregularidades.

¹<https://www.kaggle.com/shubhankartiwari/ram-prices>



Se hará un pronóstico para los años posteriores al 2000 utilizando los datos históricos hasta ese momento, con la fecha como nuestra única característica. Se compararán dos modelos simples:

- *DecisionTreeRegressor*
- *LinearRegression*.

Se Reescalarán los precios usando un logaritmo, de modo que la relación sea relativamente lineal. Esto no hace una diferencia para *DecisionTreeRegressor*, pero sí marca una gran diferencia para *LinearRegression*. Después de entrenar los modelos y hacer predicciones, se aplicará el mapa exponencial para deshacer la transformación logarítmica. Se harán predicciones en todo el conjunto de datos con fines de visualización, pero para una evaluación cuantitativa solo se considerarían el conjunto de datos de prueba:

```
from sklearn.tree import DecisionTreeRegressor
from sklearn.linear_model import LinearRegression

data_train = ram_prices[ram_prices.date < 2000]
data_test = ram_prices[ram_prices.date >= 2000]

X_train = data_train.date[:, np.newaxis]

y_train = np.log(data_train.price)

tree = DecisionTreeRegressor(max_depth=3).\
    fit(X_train, y_train)
linear_reg = LinearRegression().\
    fit(X_train, y_train)


X_all = ram_prices.date[:, np.newaxis]

pred_tree = tree.predict(X_all)
pred_lr = linear_reg.predict(X_all)

price_tree = np.exp(pred_tree)
price_lr = np.exp(pred_lr)
```

La figura 7.5, creada aquí, compara las predicciones del árbol de decisión y el modelo de regresión lineal con la verdad fundamental:

```
plt.semilogy(data_train.date, data_train.price,
              label="Datos Entrenamiento")
plt.semilogy(data_test.date, data_test.price,
              label="Datos Test")
plt.semilogy(ram_prices.date, price_tree,
              label="Predicción Árbol")
plt.semilogy(ram_prices.date, price_lr,
              label="predicción Lineal")
plt.legend()
```



8. Ensamble de Árboles de Decisión

Los ensambles son métodos que combinan varios modelos de aprendizaje automático para crear modelos más potentes. Hay muchos modelos en la literatura sobre machine learning que pertenecen a esta categoría, pero hay dos modelos de conjunto que han demostrado ser efectivos en una amplia gama de conjuntos de datos para clasificación y regresión, los cuales usan árboles de decisión como sus bloques de construcción: **Random Forests** and **Gradient Boosted Decision Trees**.

8.1. Random Forests

Un inconveniente principal de los árboles de decisión es que tienden a sobreajustarse a los datos de entrenamiento. El método Random Forests es una forma de abordar este problema. Un Random Forests es esencialmente una colección de árboles de decisión, donde cada árbol es ligeramente diferente de los demás. La idea detrás del Random Forests es que cada árbol podría hacer un trabajo relativamente bueno de predicción, pero probablemente se sobreajustará en parte de los datos. Si se construye muchos árboles, todos

los cuales funcionan bien y se sobreajustan de diferentes maneras, se puede reducir la cantidad de sobreajuste promediando sus resultados. Esta reducción en el sobreajuste, aunque conserva el poder predictivo de los árboles, se puede demostrar utilizando matemáticas rigurosas.

Para implementar esta estrategia, se necesita construir muchos árboles de decisión. Cada árbol debe hacer un trabajo aceptable al predecir el objetivo y también debe ser diferente de los otros árboles. Random Forests obtiene su nombre al inyectar aleatoriedad en la construcción del árbol para garantizar que cada árbol sea diferente. Hay dos formas en las que los árboles de un Random Forests se asignan al azar: seleccionando los puntos de datos utilizados para construir un árbol y seleccionando las características en cada prueba de división.

Construcción de Random Forests

Para construir un modelo de Random Forests, se debe decidir la cantidad de árboles que se construirán (el parámetro *n_estimators* de *RandomForestRegressor* o *RandomForestClassifier*). Si se quiere construir 10 árboles, estos árboles se construirán de forma completamente independiente entre sí, y el algoritmo hará diferentes elecciones aleatorias para cada árbol para asegurarse de que los árboles sean distintos. Para construir un árbol, primero se toma lo que se llama una *muestra bootstrap* de los datos. Es decir, a partir del conjunto de datos se extra repetidamente una muestra al azar con reemplazo (lo que significa que la misma muestra se puede elegir varias veces).

Esto creará un conjunto de datos que es tan grande como el conjunto de datos original, pero faltarán algunos puntos de datos y algunos se repetirán. Es decir, se quiere crear una *muestra bootstrap* de la lista ['á', 'b', 'c', 'd']. Una posible muestra de bootstrap sería ['b', 'd', 'd', 'c']. Otra muestra posible sería ['d', 'á', 'd', 'á'].

A continuación, se crea un árbol de decisión basado en este conjunto de datos recién creado. Sin embargo, el algoritmo que se describe para el árbol de decisión está ligeramente modificado. En lugar de buscar la mejor prueba para cada nodo, en cada nodo el algoritmo selecciona aleatoriamente un subconjunto de las características y busca la mejor prueba posible que involucre una de estas características. El número de características que se seleccionan está controlado por el parámetro *max_features*. Esta selección de un subconjunto de funciones se repite por separado en cada nodo, de modo que cada nodo en un árbol puede tomar una decisión utilizando un subconjunto diferente de funciones.

La *muestra bootstrap* lleva a que cada árbol de decisión a construir en el bosque aleatorio un conjunto de datos ligeramente diferente. Debido a la selección de funciones en cada nodo, cada división en cada árbol opera en un subconjunto diferente de funciones. Juntos estos dos mecanismos aseguran que todos los árboles en el bosque aleatorio sean diferentes.

Un parámetro crítico en este proceso es *max_features*. Si se establece *max_features* como *n_features*, eso significa que cada división puede ver todas las variables del conjunto de datos, y no se introducirá aleatoriedad en la selección de variables (sin embargo, la aleatoriedad debida al bootstrapping permanece). Si establecemos *max_features* como 1, eso significa que las divisiones no tienen ninguna opción sobre qué variable probar y solo pueden buscar en diferentes umbrales para la variable que se seleccionó al azar. Por lo tanto, un *max_features* alto significa que los árboles del Random Forest serán bastante

similares y podrán ajustar los datos fácilmente, utilizando las características más distintivas. Un *max_features* bajo significa que los árboles del Random Forest serán bastante diferentes, y que cada árbol puede necesitar ser muy profundo para que se ajuste bien a los datos.

Para hacer predicciones usando Random Forest, el algoritmo primero hace una predicción por cada árbol del bosque. Para regresión, se calcula la media de estos resultados para obtener la predicción final. Para clasificación, se utiliza la estrategia de “*soft voting*”. Esto significa que cada algoritmo hace una ligera predicción, proporcionando una probabilidad para cada etiqueta posible. Se promedian las probabilidades predichas por todos los árboles y se predice la clase con la probabilidad más alta.

Analizando Random Forest

Se va a construir un random forest con cinco árboles con el dataset *two_moons*:

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.datasets import make_moons

X, y = make_moons(n_samples=100, noise=0.25, random_state=1234)
X_train, X_test, y_train, y_test = train_test_split(X, y, stratify=y,
                                                    random_state=1234)

bosque = RandomForestClassifier(n_estimators=5, random_state=1234)
bosque.fit(X_train, y_train)
```

Los árboles que se construyen como parte del Random Forest se almacenan en el atributo “*estimador*”. Si se visualiza las fronteras de decisión por cada árbol, junto con su predicción agregada hecha por el bosque


```
fig, axes = plt.subplots(2, 3, figsize=(20, 10))
for i, (ax, tree) in enumerate(zip(axes.ravel(), bosque.estimators_)):
    ax.set_title("Arbol {}".format(i))
    mglearn.plots.plot_tree_partition(X_train, y_train, tree, ax=ax)

mglearn.plots.plot_2d_separator(bosque, X_train, fill=True, ax=axes[-1, -1],
                               alpha=.4)
axes[-1, -1].set_title("Random Forest")
mglearn.discrete_scatter(X_train[:, 0], X_train[:, 1], y_train)
```

Se puede ver claramente que las fronteras de decisión aprendido por los cinco árboles difieren bastante. Cada uno de ellos comente algunos errores, ya que algunos de los puntos de entrenamiento que se dibujan, en realidad no se incluyeron en el conjunto de entrenamiento de los árboles, debido al muestreo bootstrap.

Random Forest se sobreajusta menos que cualquiera de los árboles individuales y proporciona un límite de decisión mucho más intuitivo. En cualquier aplicación real, se usaría muchos más árboles (a menudo cientos o miles), lo que conducirá a límites aun más parejos.

Otro ejemplo, podría ser aplicar un Random Forest que contenga 100 árboles con el dataset de “*Breast Cancer*”



```
X_train, X_test, y_train, y_test = train_test_split(
    cancer.data, cancer.target, random_state=1234)
bosque = RandomForestClassifier(n_estimators=100, random_state=1234)
bosque.fit(X_train, y_train)

print("Exactitud conjunto de entrenamiento: {:.3f}".format(bosque.score(X_train, y_train)))
print("Exactitud conjunto de test: {:.3f}".format(bosque.score(X_test, y_test)))
```

El Random Forest da una exactitud de 93 % mejor que el modelo lineal o incluso de un único árbol de decisión

CAPÍTULO 28. APRENDIZAJE SUPERVISADO

Exactitud conjunto de entrenamiento: 1.000
Exactitud conjunto de test: 0.930

Parte VI

Series Temporales

CAPÍTULO 29

Modelos tradicionales: conceptos iniciales

1. Introducción

Desde el comienzo de la historia el ser humano siempre ha tenido el deseo de predecir el futuro, de ser capaces de adelantarse en el tiempo. El estudio de las series temporales trata de eso, de predecir qué ocurrirá sabiendo lo que ya ha ocurrido.

El beneficio del conocimiento previo es útil en diversas áreas como las ciencias sociales, la ingeniería y, como era de pensar, en la economía y en las finanzas. Hoy en día es frecuente que las observaciones estén ligadas al tiempo o fechadas en un determinado momento, algunos ejemplos: tasas de inflación, el Producto Interior Bruto (PIB) anual, el volumen de ventas de una empresa, el número de estudiantes que aprueban la asignatura de Econometría III, etc.

Estos datos se obtienen en periodos regulares de tiempo, haciendo que las técnicas de inferencia estadística ya estudiadas en cursos anteriores no sean las más adecuadas dado que, como se explica más tarde, se disponen de s muestras de tamaño 1 procedentes de otras tantas poblaciones de características y distribución desconocidas. Para el estudio de este tipo de variables se necesitan nuevas herramientas que permitan predecir el futuro.

2. Proceso estocástico

Un proceso estocástico es un conjunto de variables aleatorias que representan una misma magnitud en distintos momentos de tiempo. En general se supone que el proceso es lineal, es decir, que cada variable puede ser obtenida como combinación lineal de las que le preceden.

Definición 29.1 (Proceso Estocástico) *Se llama proceso estocástico a la secuencia de variables aleatorias, ordenadas y equidistantes cronológicamente*

referidas a una (proceso univariante) o a varias (proceso multivariante) características de una unidad observable en diferentes momentos.

La representación más común de procesos estocásticos univariantes es:

$$\{Y_t : t = 0, \pm 1, \pm 2, \dots\},$$

y para procesos estocásticos multivariantes es:

$$\{\mathbf{Y}_t : t = 0, \pm 1, \pm 2, \dots\}$$

donde $\mathbf{Y}_t = (Y_{t1}, Y_{t2}, \dots, Y_{tM})'$ con $M \geq 2$ y $t1, t2, \dots, tM = 0, \pm 1, \pm 2, \dots$.

Como se detalla más tarde, se puede definir las series temporales como un caso particular de los procesos estocásticos, más concretamente, como una realización finita (muestra) de tamaño 1: $(y_1, \dots, y_t)$. Antes de centrarse en el estudio de las series temporales, se ven a continuación algunas propiedades de las distribuciones marginales de los procesos estocásticos.

2.1. Distribuciones marginales

Definición 29.2 (Función de medias) Se llama función de medias de un proceso a una función del tiempo que proporciona las esperanzas de las distribuciones marginales para cada instante:

$$E[Y_t] = \mu_t, \quad t = 1, \dots, T,$$

donde T es el número de observaciones disponibles. Si todas las variables tienen la misma media, entonces la función de medias es constante, las realizaciones de este proceso no mostrarán ninguna tendencia y se dice que es un proceso estable en media.

Definición 29.3 (Función de varianzas) Se denomina función de varianzas del proceso a la que proporciona las varianzas en cada instante temporal:

$$\text{Var}[Y_t] = \sigma_t^2, \quad t = 1, \dots, T.$$

y se dice que el proceso es estable en varianza si éstas son constantes en el tiempo.

La estructura de dependencia lineal entre las variables aleatorias del proceso se representa por las funciones de covarianza y correlación.

Definición 29.4 (Función de autocovarianzas) Se llama función de autocovarianzas del proceso a la función que describe las covarianzas entre dos variables del proceso en dos instantes cualesquiera:

$$\gamma_{t,t+k} = \text{Cov}(Y_t, Y_{t+k}) = E[(Y_t - \mu_t)(Y_{t+k} - \mu_{t+k})], \quad t = 1, \dots, T, \quad k \in \mathbb{Z}.$$

En particular, para $k = 0$ se tiene que $\gamma(t, t) = E[(Y_t - \mu_t)(Y_t - \mu_t)] = \text{Var}(Y_t)$ para $t = 1, \dots, T$.

Definición 29.5 (Función de autocorrelación) La Función de AutoCorrelación (que a partir de ahora se denota por FAC) del proceso proporciona medidas adimensionales de la dependencia lineal y se define como la función que describe las correlaciones entre dos variables del proceso en dos instantes cualesquiera:

Tiempo \ Muestras	Muestras			
	1	2	...	s
1	Y_{11}	Y_{12}	$\cdots$	Y_{1s}
2	Y_{21}	Y_{22}	$\cdots$	Y_{2s}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
T	Y_{T1}	Y_{T2}	$\cdots$	Y_{Ts}

Tabla 29.1: Representación de s muestras de un proceso estocástico

$$\rho_{t,t+k} = \frac{Cov(Y_t, Y_{t+k})}{\sqrt{Var[Y_t]}\sqrt{Var[Y_{t+k}]}} = \frac{\gamma_{t,t+k}}{\sqrt{\gamma_{t,t}}\sqrt{\gamma_{t+k,t+k}}}, \quad t = 1, \dots, T, \quad k \in \mathbb{Z}.$$

Definición 29.6 (Función de autocorrelación parcial) Se llama *Función de AutoCorrelación Parcial* (que a partir de ahora denotaremos por *FACP*) a la función que mide la correlación lineal existente entre dos variables del proceso en dos instantes cualesquiera pero eliminando el efecto que tienen los retardos intermedios sobre ellas:

$$Corr(Y_t, Y_{t+k} | Y_{t+1}, Y_{t+2}, \dots, Y_{t+k-1}), \quad t = 1, \dots, T, \quad k \in \mathbb{Z}.$$

3. Series temporales

Como ya se ha definido anteriormente, un proceso estocástico es una sucesión de T variables aleatorias, cada una de ellas referida a un instante de tiempo y ordenadas cronológicamente. Si se supone que se tienen s muestras de un proceso estocástico, los datos se podrían representar tal y como se muestran en la Tabla 29.1.

Una serie temporal quedará caracterizada cuando se conozcan las características del proceso estocástico que la genera. El problema es que en las ciencias no experimentales, como la Economía, los procesos estocásticos estudiados (por ejemplo, la tasa de paro) se generan solo una vez para cada instante temporal. Por tanto, una serie temporal es una muestra (realización finita) del proceso estocástico, o dicho de otra forma, es una muestra de tamaño 1 de cada una de las T variables aleatorias que conforman el proceso. Por ejemplo, si en la anterior tabla se toma la segunda muestra, entonces la serie sería: $(Y_{12}, Y_{22}, \dots, Y_{T2})$. Para conocer las T distribuciones de las T variables aleatorias del proceso se deben imponer algunos supuestos que se comentarán más tarde.


Las series temporales suelen representarse mediante un gráfico que muestra su evolución en el tiempo, permitiendo detectar las características más importantes del comportamiento de la serie. En la Figura 29.1 se presenta la representación gráfica de algunas series de tiempo.

3.1. Objetivo del análisis de series temporales


El objetivo principal del análisis de una serie temporal consiste en especificar un modelo estadístico que explique sus movimientos. Pero así como en los modelos de regresión se utiliza una variable endógena y variables explicativas,

3. SERIES TEMPORALES


Número de pasajeros mensuales aeropuerto de granada de enero 2011 a junio de 2015 y valor mensual del euribor de enero de 2005 a junio de 2015




Consumo de gasolina mensual de enero de 1945 a diciembre de 1999 y datos diarios del índice Dow Jones de enero a marzo de 1950



Ventas mensuales de vino tinto en Australia de enero de 1980 a octubre de 1991 y accidentes mortales mensuales



Índice de precios al consumo (IPC) mensual y su variación anual desde enero de 2002 a junio de 2015



PIB trimestral desde 1995 a 2015 y PIB per cápita anual desde 1980 a 214




Figura 29.1: Representación gráfica de algunas series temporales

CAPÍTULO 29. MODELOS TRADICIONALES: CONCEPTOS INICIALES

en este tipo de enfoque se utilizan como variables explicativas la propia variable endógena retardada.

Luego, en principio toda serie Y_t puede expresarse como combinación lineal de sus valores pasados (parte sistemática) más un término de error (parte aleatoria). Es decir:

$$Y_t = PS_t + a_t$$

donde:

- PS_t es la parte sistemática o comportamiento regular de las variables.
- a_t es la parte aleatoria o innovación.

El modelo que se obtenga debe cumplir tres requisitos fundamentales:

- **Describir** los cambios de esa variable con respecto al tiempo, y en particular: tendencia, estacionalidad, variaciones cíclicas y variaciones irregulares.
- **Predecir** los valores futuros.
- **Contrastar** hipótesis sobre las características o variables a las que se refieren los valores de dicha serie.

Con estas premisas, en 1970 Box y Jenkins [?] proponen una metodología que se puede resumir en cuatro etapas de análisis:

1. **Identificación del modelo:** Determinar la posible especificación que sigue la serie.
2. **Estimación:** Una vez seleccionado un modelo se estimarán sus parámetros.
3. **Diagnóstico:** Se verifica si el modelo estimado es el adecuado y es capaz de explicar los datos observados.
4. **Predicción:** Una vez obtenido el modelo adecuado se realizarán predicciones con el mismo.

El estudio de las series temporales es diferente al del resto de las variables estadísticas. La diferencia esencial entre las series temporales y los análisis no temporales (por ejemplo, estadística descriptiva, diseño de experimentos o modelos de regresión) es que en estos últimos no importa el orden en que están tomadas las observaciones y éste se podía variar sin problemas. En el análisis series temporales el orden es crucial y variarlo supone cambiar la información contenida en la serie.

La periodicidad de una serie es el lapso de tiempo de transcurrir entre la aparición de dos observaciones consecutivas, siendo las periodicidades más comunes: anual, mensual, semanal y diaria.

Finalmente, los modelos de series temporales se pueden clasificar en:

- **Modelos Univariantes:** El comportamiento de una única variable se explica a partir de su propio pasado.

- **Modelos Multivariantes:** El comportamiento de un conjunto de variables se explica a partir del pasado de ellas mismas.
- **Modelos de Función de Transferencia:** Además del propio pasado se incorporan otras variables explicativas. Una o varias series temporales se explican a partir de su pasado y de los valores presentes y pasados de otras variables exógenas.

Estos tipos de modelos serán estudiados en los próximos capítulos.

3.2. Operadores de retardo y de diferencias

Habitualmente en series temporales se utiliza una nomenclatura específica: operadores retardos B y de diferencias ∇ .

Definición 29.7 (Operador Retardo) *El operador retardo es un operador tal que aplicado a una variable temporal la retarda un periodo, es decir, $BY_t = Y_{t-1}$. En general, $B^k Y_t = Y_{t-k}$, $k \geq 1$. Lógicamente, cuando se aplica a una constante, ésta no varía: $B\delta = \delta$.*

Definición 29.8 (Diferencia Regular) *El operador diferencia regular es un operador tal que aplicado a una variable temporal la transforma de la siguiente manera: $\nabla Y_t = (1 - B)Y_t = Y_t - Y_{t-1}$. En general, $\nabla^k Y_t = (1 - B)^k Y_t$, $k \geq 1$.*

4. Ruido blanco

Ruido Blanco es un caso simple de proceso estocástico de particular importancia. Se define como una secuencia de variables aleatorias incorreladas denotadas por $\{\varepsilon_t\}$ que tienen esperanza cero y varianza constante. Esto es, $E[\varepsilon_t] = 0$, $Var[\varepsilon_t] = E[\varepsilon_t^2] = \sigma_\varepsilon^2$ y $Cov(\varepsilon_t, \varepsilon_s) = E[\varepsilon_t \cdot \varepsilon_s] = 0$, $\forall t, s$ con $t \neq s$.

Las principales propiedades de una serie de ruido blanco con media cero son:

- No hay correlación entre términos.
- Valores pasados no ayudan a pronosticar valores futuros.

Se llamará ruido blanco gaussiano (o normal) si la distribución de $\{\varepsilon_t\}$ es normal.

5. Estacionariedad

El problema que se tiene entre manos es el de conocer el proceso estocástico que genera la serie temporal con la que se trabaja. La dificultad de este problema reside en que es prácticamente imposible hacer inferencia (conocer las características) sobre un proceso estocástico con una sola realización (muestras de tamaño 1) del proceso, es decir, con la serie temporal. Para resolver este problema es necesario imponer el siguiente supuesto: trabajar con procesos estacionarios y ergódicos. Esta sección se centra en la estacionariedad y más adelante se tratará la ergodicidad.

La estacionariedad conlleva que la serie tenga un comportamiento estable a lo largo del tiempo. Esta condición es importante ya que se está interesado

en predecir el comportamiento del proceso en el futuro, y para ello se usa su historia pasada. Por tanto, la serie debe cumplir las siguientes características:

- No tener tendencia: no presentar un crecimiento o decrecimiento sistemático ni cambios de nivel.
- Ser homocedástica: a lo largo del tiempo las oscilaciones deben tener una amplitud más o menos constante.
- En caso de existir, deben detectarse comportamientos estacionales para su correcta modelización.
- Que su estructura de dependencia se mantenga constante, es decir, si una observación influye sobre la posterior, que esto ocurra siempre. Esta condición es importante para modelizar la serie.
- Que para explicar el comportamiento de una observación tengan mayor influencia aquellas que son más cercanas.

Definición 29.9 (Estacionariedad) *Un proceso estocástico es estacionario si sus propiedades estadísticas son invariantes ante una traslación en el tiempo.*

Es lógico pensar que las predicciones no serán correctas a menos que las condiciones futuras sean análogas a las pasadas. Por lo que se define:

Definición 29.10 (Estacionariedad estricta) *Un proceso estocástico es estacionario en sentido estricto cuando para toda m -upla y todo entero, k , el vector de variables $(Y_{t_1}, Y_{t_2}, \dots, Y_{t_m})$ tiene la misma distribución de probabilidad conjunta que el vector $(Y_{t_1+k}, Y_{t_2+k}, \dots, Y_{t_m+k})$. Esto es:*

$$F(Y_{t_1}, Y_{t_2}, \dots, Y_{t_m}) = F(Y_{t_1+k}, Y_{t_2+k}, \dots, Y_{t_m+k}), \quad \forall k.$$

Considerar sólo los procesos estacionarios estrictos es muy restrictivo ya que implicaría estudiar infinitas funciones de densidad conjunta, de manera que se opta por una solución intermedia, con los llamados procesos estacionarios en sentido débil, o simplemente, procesos estacionarios.

Definición 29.11 (Estacionariedad débil) *Un proceso estocástico es estacionario en sentido débil o estacionario de segundo orden cuando todos sus momentos de primer y segundo orden son invariantes en el tiempo. Es decir: $E[Y_t] = \mu$, $Var[Y_t] = \sigma^2$ y $Cov(Y_t, Y_{t+h}) = \gamma_{t,t+h} = \gamma_h$, $\forall t, h$.*

En la práctica, muchas de las series que se manejan presentan comportamientos claramente no estacionarios. Esto significa que será necesario introducir procedimientos que permitan transformar series no estacionarias en aproximadamente estacionarias.

Ejemplo 29.1 *El ruido blanco es un ejemplo de proceso estocástico estacionario de segundo orden ya que tiene media cero (constante), varianza constante y su covarianza es cero (no depende del tiempo)*




Figura 29.2: Paseo aleatorio (izquierda) y su primera diferencia (derecha)

Ejemplo 29.2 *Un paseo aleatorio es un proceso estocástico que se define como:*

$$Y_t = Y_{t-1} + \varepsilon_t,$$

donde ε_t es un ruido blanco. ¿Es este proceso estacionario?

Sustituyendo recursivamente obtenemos:

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \cdots = Y_0 + \sum_{i=0}^{t-1} \varepsilon_{t-i},$$

siendo Y_0 el primer valor que toma la serie. Dado que ε_t es un ruido blanco, la esperanza del paseo aleatorio es constante:

$$E[Y_t] = E[Y_0] + \sum_{i=0}^{t-1} E[\varepsilon_{t-i}] = Y_0.$$

Pero su varianza no lo es:

$$\text{Var}[Y_t] = E[(Y_t - Y_0)^2] = E\left[\left(\sum_{i=0}^{t-1} \varepsilon_{t-i}\right)^2\right] = E[\varepsilon_1^2 + \cdots + \varepsilon_t^2] = t\sigma_\varepsilon^2,$$

donde se ha tenido en cuenta que al ser ε_t ruido blanco se verifica que $E[\varepsilon_i^2] = \sigma_\varepsilon^2$ y $E[\varepsilon_i \cdot \varepsilon_j] = 0$, $\forall i, j = 1, \dots, t$ con $i \neq j$.

Por tanto, el paseo aleatorio es un proceso no estacionario. Sin embargo, la primera diferencia de un paseo aleatorio si lo es dado que coincide con un ruido blanco:

$$\nabla Y_t = Y_t - Y_{t-1} = \varepsilon_t.$$

En la Figura 29.2 se representa en la parte izquierda un paseo aleatorio (con $Y_0 = 0.0018$ y $\sigma_\varepsilon^2 = 0.01$) y en la derecha su primera diferencia.

Bajo el supuesto de estacionariedad (en sentido débil), el problema de conocer el proceso estocástico que genera a la serie temporal se reduce a conocer la media (μ), la varianza (σ^2) y las autocovarianzas (γ_k) del proceso. Recuerdese que todos esos parámetros son invariantes en el tiempo.

A continuación se estudian las propiedades de las funciones de autocovarianzas y de autocorrelación simple y parcial para procesos estacionarios.

5.1. Función de autocovarianzas y de autocorrelación

La función de autocovarianza de un proceso estocástico estacionario en sentido débil es una función del número de periodos de separación, k , entre las variables. Es decir, dada la Definición 29.4 la función de autocovarianza depende únicamente del desfase entre los dos instantes:

$$\gamma_{t,t+k} = \gamma_k, \quad k = 0, \pm 1, \pm 2, \dots$$

Sus propiedades son las siguientes:

- $\gamma_0 = \text{Var}(Y_t) \geq 0$.
- $\gamma_k = \gamma_{-k}, \quad \forall k \in \mathbb{Z}$ (simetría).
- $|\gamma_k| \leq \gamma_0, \quad \forall k \in \mathbb{Z}$.

Debido a la segunda propiedad, la función de autocovarianza se calcula solamente para los valores no negativos del retardo k , es decir, $k = 0, 1, 2, \dots$.

Cuando se quiere analizar la serie es necesario identificar la estructura que la genera, es decir, cómo influyen las observaciones del pasado en las observaciones del futuro. Esta dependencia está explicada por la función de autocovarianzas. El problema es que las autocovarianzas dependen de las unidades de medida de las variables. Por ello, para identificar esta dependencia se utilizan las funciones de autocorrelación simple y parcial.

5.2. Función de autocorrelación simple

El coeficiente de autocorrelación de un proceso estocástico estacionario es una función del número de periodos de separación, k , entre las variables. Es decir, dada la Definición 29.5 la función de autocorrelación depende únicamente del desfase entre los dos instantes:

$$\rho_k = \frac{\gamma_k}{\sqrt{\gamma_0 \gamma_0}} = \frac{\gamma_k}{\gamma_0}, \quad k = 0, \pm 1, \pm 2, \dots$$

La FAC de un proceso estocástico estacionario es una función de k que recoge el conjunto de los coeficientes de autocorrelación:

$$\rho_k, \quad k = 0, \pm 1, \pm 2, \dots$$

Se suele representar mediante un gráfico de barras denominado correlograma. Así, por ejemplo, en la Figura 29.3 se representa el correlograma del paseo aleatorio del Ejemplo 29.2 y sus primeras diferencias. Se aprecia un comportamiento bien diferenciado que será estudiado en los próximos capítulos.

Sus principales propiedades son:

- $\rho_0 = 1$.
- $\rho_k = \rho_{-k}, \quad \forall k \in \mathbb{Z}$ (simetría).
- $|\rho_k| \leq 1, \quad \forall k \in \mathbb{Z}$.
- $\rho_k \xrightarrow[k \rightarrow \infty]{} 0$.

Debido a la segunda propiedad, en el correlograma se representa la función de autocorrelación solamente para los valores no negativos del retardo k , es decir, $k = 0, 1, 2, \dots$.




Figura 29.3: Correlograma de un paseo aleatorio (izquierda) y de su primera diferencia (derecha)

5.3. Función de autocorrelación parcial

Como se expresó en la Definición 29.6, la FACP en el retardo k mide la influencia neta y directa que tendría Y_{t-k} sobre Y_t , es decir, se prescinde de las influencias que sobre Y_t tienen $Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$.

Siguiendo esta definición, la forma de calcular el coeficiente de la FACP en el retardo k es obtener el coeficiente ϕ_{kk} de la siguiente regresión:

$$\tilde{Y}_t = \phi_{k1}\tilde{Y}_{t-1} + \phi_{k2}\tilde{Y}_{t-2} + \dots + \phi_{kk}\tilde{Y}_{t-k} + v_t$$

donde $\tilde{Y}_t$ es el proceso centrado, es decir, $\tilde{Y}_t = Y_t - E[Y_t]$ y v_t es un proceso de media cero incorrelado con Y_{t-j} para todo j .

A partir de esta ecuación de regresión se puede calcular la expresión del coeficiente ϕ_{kk} de la FACP a partir de los coeficientes de la FAC. Multiplicando a ambos lados de la regresión por $\tilde{Y}_{t-j}$ para $j = 1, \dots, k$ se obtiene:

$$\tilde{Y}_t \tilde{Y}_{t-j} = \phi_{k1} \tilde{Y}_{t-1} \tilde{Y}_{t-j} + \phi_{k2} \tilde{Y}_{t-2} \tilde{Y}_{t-j} + \dots + \phi_{kk} \tilde{Y}_{t-k} \tilde{Y}_{t-j} + v_t \tilde{Y}_{t-j}, \quad j = 1, 2, \dots, k,$$

tomando esperanzas:

$$\gamma_j = \phi_{k1}\gamma_{j-1} + \phi_{k2}\gamma_{j-2} + \dots + \phi_{kk}\gamma_{kk} + \underbrace{E[v_t \tilde{Y}_{t-j}]}_0, \quad j = 1, 2, \dots, k,$$

y dividiendo por γ_0 :

$$\rho_j = \phi_{k1}\rho_{j-1} + \phi_{k2}\rho_{j-2} + \dots + \phi_{kk}\rho_{kk}, \quad j = 1, 2, \dots, k$$

Teniendo en cuenta que $\rho_0 = 1$ y que $\rho_k = \rho_{-k}$, estas k ecuaciones quedarían como:

$$\begin{aligned} \rho_1 &= \phi_{k1} + \phi_{k2}\rho_1 + \dots + \phi_{kk}\rho_{k-1} \\ \rho_2 &= \phi_{k1}\rho_1 + \phi_{k2} + \dots + \phi_{kk}\rho_{k-2} \\ &\vdots \\ \rho_k &= \phi_{k1}\rho_{k-1} + \phi_{k2}\rho_{k-2} + \dots + \phi_{kk} \end{aligned}$$

y utilizando la regla de Cramer se obtienen los valores de ϕ_{kk} para $k = 1, 2, \dots$. Por ejemplo, denotando por $\rho_k^p (= \phi_{kk})$ a los coeficientes de la FACP, los tres primeros coeficientes se obtendrían de la siguiente manera:

Para $k = 1$:

$$\rho_1 = \phi_{11} \Rightarrow \rho_1^p = \phi_{11} = \rho_1. \quad (29.1)$$

Para $k = 2$:

$$\begin{aligned} \rho_1 &= \phi_{21} + \phi_{22}\rho_1 \\ \rho_2 &= \phi_{21}\rho_1 + \phi_{22} \end{aligned} \Rightarrow \rho_2^p = \phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}. \quad (29.2)$$

Para $k = 3$:

$$\begin{aligned} \rho_1 &= \phi_{31} + \phi_{32}\rho_1 + \phi_{33}\rho_2 \\ \rho_2 &= \phi_{31}\rho_1 + \phi_{32} + \phi_{33}\rho_1 \\ \rho_3 &= \phi_{31}\rho_2 + \phi_{32}\rho_1 + \phi_{33} \end{aligned} \Rightarrow \rho_3^p = \phi_{33} = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_1 \\ \rho_1 & 1 & \rho_2 \\ \rho_2 & \rho_1 & \rho_3 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}}.$$

Y así sucesivamente.

6. Estimaciones muestrales

La forma correcta de estimar los parámetros de una serie temporal sería utilizando múltiples realizaciones del proceso estocástico que la genera. Por ejemplo, se podría estimar la media de la primera variable del proceso estocástico, Y_1 , de la Tabla 29.1 calculando la media muestral de los valores $Y_{11}, Y_{12}, \dots, Y_{1s}$. Pero para ello se necesitan s realizaciones del proceso, cosa que, como ya se ha comentado, en Economía es imposible. Por tanto, para realizar las estimaciones de la media, la varianza y covarianzas se utilizan las observaciones contenidas en la única serie temporal disponible.

Proposición 29.1 *Bajo estacionariedad de segundo orden, se pueden estimar los primeros momentos poblacionales del proceso mediante los correspondientes momentos muestrales de la serie temporal:*

- *Media muestral:* $\hat{\mu}_Y = \bar{Y} = \frac{1}{T} \sum_{t=1}^T Y_t$.
- *Varianza muestral:* $\hat{\sigma}_Y^2 = \hat{\gamma}_0 = \frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y})^2$.
- *Autocovarianza muestral en el retardo k :*

$$\hat{\gamma}_k = \frac{1}{T-k} \sum_{t=k+1}^T (Y_t - \bar{Y})(Y_{t-k} - \bar{Y}), \quad k = 1, 2, \dots$$

- *Coficiente de autocorrelación muestral en el retardo k :*

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\frac{1}{T-k} \sum_{t=k+1}^T (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y})^2}, \quad k = 1, 2, \dots$$

Ahora bien, cuando se trabaja con estos estimadores es necesario garantizar que el proceso estocástico que genera la serie verifique unas condiciones tales que los estimadores (generados con la serie temporal) tengan asintóticamente (cuando el número de observaciones es muy alto) las mismas propiedades que los estimadores generados con distintas réplicas del proceso. A dichas condiciones se les denomina condiciones de ergodicidad.

7. Ergodicidad

Definición 29.12 *Se dice que un proceso estacionario en sentido débil es ergódico respecto de la media si el estimador $\hat{\mu}_Y$ calculado con la serie temporal para estimar la media del proceso converge en media cuadrática al estimador de la media definido sobre una muestra de réplicas independientes del proceso.*

Definición 29.13 *Se dice que un proceso estacionario en sentido débil es ergódico respecto de las autocovarianzas si los estimadores $\hat{\gamma}_k$ calculados con la serie temporal para estimar las autocovarianzas del proceso convergen en media cuadrática a los estimadores de las autocovarianzas definidos sobre una muestra de réplicas independientes del proceso.*

Si un proceso es estacionario y ergódico, los estimadores presentados anteriormente verifican:

- $\hat{\mu}_Y$ es un estimador consistente (en media cuadrática) de la media del proceso.
- $\hat{\gamma}_0$ es un estimador consistente (en media cuadrática) de la varianza del proceso.
- $\hat{\gamma}_k$ son estimadores consistentes (en media cuadrática) de las autocovarianzas del proceso.
- $\hat{\rho}_k$ son estimadores consistentes (en media cuadrática) de los coeficientes de autocorrelación del proceso.

Cuando aumenta el número de observaciones de una serie temporal surge otro problema: el número de parámetros desconocidos a estimar también aumenta. La ergodicidad conlleva que variables del proceso suficientemente separadas en el tiempo no estén correladas o, dicho de otra manera, la influencia de una variable aleatoria sobre otra muy alejada en el tiempo se puede considerar nula.

CAPÍTULO 30

Modelos univariantes lineales estacionarios

En este tema se epecific modelos capaces de explicar el comportamiento de las series temporales. La metodología que se usa es la metodología de Box-Jenkins [?] o metodología ARIMA. Esta metodología trata de explicar el comportamiento actual de la serie en función de su pasado, es decir, reproduce la evolución de la serie en el tiempo de acuerdo a sus pautas de regularidad observadas. A diferencia de la Econometría tradicional, la estructura de dependencia de los modelos ARIMA y su formulación se basan en el propio comportamiento de la serie y no se consideran conocimientos teóricos sobre su relación con otras variables.

Como se verá al final del capítulo, el Teorema de Wold permite la utilización de tres tipos de modelos: Procesos Autorregresivos (AR), Procesos de Medias Móviles (MA) y Procesos Autorregresivos de Medias Moviles (ARMA). A continuación se presentan cada uno de ellos junto con sus principales características.

1. Proceso autorregresivo


Se define un proceso como autorregresivo si la variable endógena en un periodo t es explicada por las observaciones de ella misma correspondientes a períodos anteriores además de un término de perturbación.

Los procesos autorregresivos se abrevian con la palabra *AR* tras la que se indica el orden del proceso $AR(1)$, $AR(2)$,... El orden del proceso expresa el número de retardos de la serie temporal que intervienen en la ecuación.

La expresión genérica de un proceso autorregresivo de orden p , $AR(p)$, es la siguiente:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t,$$

donde δ es una constante, $\phi_1, \phi_2, \dots, \phi_p$ son los denominados parámetros

Figura 30.1: Procesos AR(1) con $\phi = 0.8$ y $\phi = -0.3$

autorregresivos y ε_t es ruido blanco. Dicha expresión puede escribirse de forma abreviada utilizando el operador retardo B como:

$$\phi_p(B)Y_t = \delta + \varepsilon_t,$$

donde $\phi_p(B) = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)$.

En la práctica, se suele trabajar con procesos autorregresivos de órdenes bajos o bien con órdenes coincidentes con la periodicidad de los datos de la serie analizada (si es trimestral $AR(4)$, si es mensual $AR(12)$,...).

En las siguientes secciones se estudian las características de los procesos autorregresivos $AR(1)$, $AR(2)$ y $AR(p)$.

1.1. Proceso autorregresivo de primer orden

Es el proceso autorregresivo más simple. Un proceso estocástico $\{Y_t\}$ sigue un proceso autorregresivo de orden 1, $AR(1)$, si se puede escribir como:

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t, \quad (30.1)$$

donde δ, ϕ son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 . Adviértase que para $\delta = 0$ y $\phi = 1$ se tiene el proceso conocido como paseo aleatorio estudiado en el Ejemplo 29.2. Como se verá en el Capítulo ??, el hecho de que ϕ pueda ser igual a uno constituye un caso de especial interés.

En la Figura 30.1 se representa un proceso $AR(1)$ con $\delta = 0$, $\phi = 0.8$ e $Y_0 = 5$ (derecha) y $\delta = 0$, $\phi = -0.3$ e $Y_0 = -2$ (izquierda).

El proceso $AR(1)$ puede escribirse utilizando el operador retardo B de la siguiente manera $(1 - \phi B)Y_t = \delta + \varepsilon_t$. Se denomina polinomio característico de un $AR(1)$ al polinomio $1 - \phi B$.

Sustituyendo de forma recursiva la expresión (30.1) se tiene que:

$$\begin{aligned} Y_t &= \delta + \phi(\delta + \phi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \delta(1 + \phi) + \phi^2 Y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &= \delta(1 + \phi) + \phi^2 \underbrace{(\delta + \phi Y_{t-3} + \varepsilon_{t-2})}_{Y_{t-2}} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &= \delta(1 + \phi + \phi^2) + \phi^3 Y_{t-3} + \phi^2 \varepsilon_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t \\ &= \dots = \delta(1 + \phi + \phi^2 + \dots + \phi^{j-1}) + \phi^j Y_{t-j} + \sum_{i=0}^{j-1} \phi^i \varepsilon_{t-i}. \end{aligned}$$

Teniendo en cuenta que el primer sumando es una suma geométrica finita, la expresión anterior queda como:

$$Y_t = \delta \frac{1 - \phi^j}{1 - \phi} + \phi^j Y_{t-j} + \sum_{i=0}^{j-1} \phi^i \varepsilon_{t-i}. \quad (30.2)$$

Suponiendo que $j \rightarrow +\infty$:

- Si $|\phi| > 1$ se tiene una serie explosiva. Este tipo de serie no es frecuente encontrarla en el entorno económico por lo que se obviarán su estudio.
- Si $|\phi| < 1$ se tiene que $\phi^j \rightarrow 0$ y la expresión (30.2) se reescribiría de la siguiente forma:

$$Y_t = \frac{\delta}{1 - \phi} + \sum_{i=0}^{+\infty} \phi^i \varepsilon_{t-i}. \quad (30.3)$$

A partir de la expresión (30.3) se pueden demostrar los siguientes resultados.

Proposición 30.1 ε_t está incorrelado con los valores previos del proceso Y_t .

Demostración

$$\begin{aligned} E[Y_{t-k}\varepsilon_t] &= E\left[\left(\frac{\delta}{1-\phi} + \sum_{i=0}^{+\infty} \phi^i \varepsilon_{t-k-i}\right) \varepsilon_t\right] \\ &= E\left[\frac{\delta}{1-\phi} \varepsilon_t\right] + \sum_{i=0}^{+\infty} \phi^i E[\varepsilon_{t-k-i} \varepsilon_t] \\ &= \frac{\delta}{1-\phi} \underbrace{E[\varepsilon_t]}_0 + \sum_{i=0}^{+\infty} \phi^i \underbrace{E[\varepsilon_{t-k-i} \varepsilon_t]}_0 = 0, \quad k > 0, \end{aligned}$$

donde se ha utilizado que al ser ε_t ruido blanco se verifica que $E[\varepsilon_t] = 0$ y $E[\varepsilon_{t-k-i} \varepsilon_t] = 0$ ya que $k+i \neq 0$.

Proposición 30.2 ε_t está correlado con los valores futuros del proceso Y_t .

Demostración

$$\begin{aligned} E[Y_{t+k}\varepsilon_t] &= E\left[\left(\frac{\delta}{1-\phi} + \sum_{i=0}^{+\infty} \phi^i \varepsilon_{t+k-i}\right) \varepsilon_t\right] \\ &= E\left[\frac{\delta}{1-\phi} \varepsilon_t\right] + \sum_{i=0}^{+\infty} \phi^i E[\varepsilon_{t+k-i} \varepsilon_t] \\ &= \frac{\delta}{1-\phi} \underbrace{E[\varepsilon_t]}_0 + \sum_{i=0}^{+\infty} \phi^i E[\varepsilon_{t+k-i} \varepsilon_t] = \phi^k \sigma_\varepsilon^2, \quad k \geq 0, \end{aligned}$$

donde se ha utilizado que al ser ε_t ruido blanco se verifica que $E[\varepsilon_t] = 0$, $E[\varepsilon_{t+k-i} \varepsilon_t] = \sigma_\varepsilon^2$ si $i = k$ y $E[\varepsilon_{t+k-i} \varepsilon_t] = 0$ si $i \neq k$.

Condición de estacionariedad

La modelización de una serie temporal a través de un proceso autorregresivo exige que el modelo sea estacionario en media y varianza. La condición de estacionariedad requiere que tanto la media como la varianza y autocovarianzas del proceso Y_t no dependan del tiempo y, además, deben ser finitas.

Si el proceso es estacionario en media se cumple que $E[Y_{t-i}] = \mu$, $\forall i \geq 0$. Entonces:

$$\begin{aligned} E[Y_t] &= E[\delta + \phi Y_{t-1} + \varepsilon_t] = \delta + E[\phi Y_{t-1}] + \underbrace{E[\varepsilon_t]}_0 = \delta + \phi E[Y_{t-1}] \\ \Rightarrow \mu - \phi\mu &= \delta \Rightarrow (1 - \phi)\mu = \delta \Rightarrow E[Y_t] = \mu = \frac{\delta}{1 - \phi}. \end{aligned}$$

Esta expresión es finita si y solo si $\phi \neq 1$.

Si el proceso es estacionario en varianza se cumple que $Var[Y_{t-i}] = \gamma_0$, $\forall i \geq 0$. Entonces:

$$Var[Y_t] = Var[\delta + \phi Y_{t-1} + \varepsilon_t] = Var[\phi Y_{t-1}] + Var[\varepsilon_t] + 2 \cdot Cov(\phi Y_{t-1}, \varepsilon_t).$$

Por la proposición 30.1 se tiene que la covarianza entre Y_{t-1} y ε_t es igual a cero, por tanto:

$$\begin{aligned} Var[Y_t] &= \phi^2 Var[Y_{t-1}] + Var[\varepsilon_t] \\ \Rightarrow \gamma_0 - \phi^2 \gamma_0 &= \sigma_\varepsilon^2 \Rightarrow (1 - \phi^2) \gamma_0 = \sigma_\varepsilon^2 \Rightarrow \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - \phi^2}. \end{aligned}$$

Esta expresión, al ser una varianza, debe ser positiva. Por tanto, dado que $\sigma_\varepsilon^2 > 0$, $1 - \phi^2$ debe ser mayor a cero, es decir $|\phi| < 1$. Entonces el proceso será estacionario si $|\phi| < 1$ o, dicho de otra manera, si el módulo de las raíces del polinomio característico son superiores a la unidad ya que:

$$1 - \phi B = 0 \Leftrightarrow B = \frac{1}{\phi}.$$

Se calcula a continuación la función de autocovarianzas. Para poder operar con mayor facilidad se transformará el modelo como sigue. Se sabe que:

$$E[Y_t] = \frac{\delta}{1 - \phi} \Rightarrow \delta = E[Y_t](1 - \phi).$$

Sustituyendo esta expresión en la ecuación (30.1):

$$\begin{aligned} Y_t &= \delta + \phi Y_{t-1} + \varepsilon_t = E[Y_t](1 - \phi) + \phi Y_{t-1} + \varepsilon_t \\ &= E[Y_t] + \phi(Y_{t-1} - E[Y_t]) + \varepsilon_t, \end{aligned}$$

y entonces:

$$Y_t - E[Y_t] = \phi(Y_{t-1} - E[Y_t]) + \varepsilon_t. \quad (30.4)$$

Si se denota $Y_t - E[Y_t]$ como $\tilde{Y}_t$, (30.4) se puede reescribir como:

$$\tilde{Y}_t = \phi \tilde{Y}_{t-1} + \varepsilon_t.$$

Proposición 30.3 *Los momentos de primer y segundo orden de $\tilde{Y}_t$ verifican:*

- $E[\tilde{Y}_t] = 0.$
- $Var[\tilde{Y}_t] = Var[Y_t] = \gamma_0.$
- $\tilde{\gamma}_k = \gamma_k.$


Demostración

$$\begin{aligned}
 E[\tilde{Y}_t] &= E[Y_t - E[Y_t]] = \underbrace{E[Y_t]}_{\mu} - \underbrace{E[E[Y_t]]}_{\mu} = \mu - \underbrace{E[\mu]}_{\mu} = \mu - \mu = 0. \\
 Var[\tilde{Y}_t] &= E[(\tilde{Y}_t - E[\tilde{Y}_t])^2] = E[\tilde{Y}_t^2] = E[(Y_t - E[Y_t])^2] = Var[Y_t] = \gamma_0. \\
 \tilde{\gamma}_k &= E[(\tilde{Y}_t - \underbrace{E[\tilde{Y}_t]}_0)(\tilde{Y}_{t+k} - \underbrace{E[\tilde{Y}_{t+k}]}_0)] = E[\tilde{Y}_t \tilde{Y}_{t+k}] \\
 &= E[(Y_t - E[Y_t])(Y_{t+k} - E[Y_{t+k}])] = \gamma_k.
 \end{aligned}$$

Por tanto, los momentos de segundo orden de $\tilde{Y}_t$ e Y_t coinciden por lo que la obtención de la función de autocovarianzas de Y_t se puede realizar, de forma más sencilla, a partir de la función de autocovarianzas de $\tilde{Y}_t$. Obsérvese que las propiedades de $\tilde{Y}_t$ obtenidas en esta proposición son ciertas sea cual sea el proceso que describe a Y_t .

A continuación se obtienen las expresiones de las autocovarianzas del proceso Y_t . Usando los resultados obtenidos en las Proposiciones 30.1 y 30.3.

$$\begin{aligned}
 \gamma_0 &= Var[Y_t] = Var[\tilde{Y}_t] = E[(\tilde{Y}_t - \underbrace{E[\tilde{Y}_t]}_0)^2] = E[(\phi \tilde{Y}_{t-1} + \varepsilon_t)^2] \\
 &= E[\phi^2 \tilde{Y}_{t-1}^2 + 2\phi \tilde{Y}_{t-1} \varepsilon_t + \varepsilon_t^2] \\
 &= \phi^2 \underbrace{E[\tilde{Y}_{t-1}^2]}_{\gamma_0} + 2\phi \underbrace{E[\tilde{Y}_{t-1} \varepsilon_t]}_0 + \underbrace{E[\varepsilon_t^2]}_{\sigma_\varepsilon^2} = \phi^2 \gamma_0 + \sigma_\varepsilon^2 \\
 \Rightarrow \gamma_0 - \phi^2 \gamma_0 &= \sigma_\varepsilon^2 \Rightarrow \gamma_0 = \frac{\sigma_\varepsilon^2}{1 - \phi^2}. \\
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[(\phi \tilde{Y}_{t-1} + \varepsilon_t) \tilde{Y}_{t-1}] = E[\phi \tilde{Y}_{t-1}^2 + \tilde{Y}_{t-1} \varepsilon_t] \\
 &= \phi \underbrace{E[\tilde{Y}_{t-1}^2]}_{\gamma_0} + \underbrace{E[\tilde{Y}_{t-1} \varepsilon_t]}_0 = \phi \gamma_0. \\
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[(\phi \tilde{Y}_{t-1} + \varepsilon_t) \tilde{Y}_{t-2}] = E[\phi \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \tilde{Y}_{t-2} \varepsilon_t] \\
 &= \phi \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-2}]}_{\gamma_1} + \underbrace{E[\tilde{Y}_{t-2} \varepsilon_t]}_0 = \phi \underbrace{\gamma_1}_{\phi \gamma_0} = \phi^2 \gamma_0.
 \end{aligned}$$

Figura 30.2: FAC para $\phi = 0.8$ y $\phi = -0.7$

Razonando de igual manera se tiene que:

$$\begin{aligned}
 \gamma_k &= \text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(\tilde{Y}_t, \tilde{Y}_{t-k}) = E[\tilde{Y}_t \tilde{Y}_{t-k}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-k}]}_0 \\
 &= E[(\phi \tilde{Y}_{t-1} + \varepsilon_t) \tilde{Y}_{t-k}] = E[\phi \tilde{Y}_{t-1} \tilde{Y}_{t-k} + \tilde{Y}_{t-k} \varepsilon_t] \\
 &= \underbrace{\phi E[\tilde{Y}_{t-1} \tilde{Y}_{t-k}]}_{\gamma_{k-1}} + \underbrace{E[\tilde{Y}_{t-k} \varepsilon_t]}_0 = \phi \gamma_{k-1} = \phi^k \gamma_0, \quad \forall k \geq 1.
 \end{aligned}$$

Por tanto, bajo la condición de estacionariedad obtenida para la varianza (la raíz del polinomio característico $1 - \phi B$ es mayor que uno en valor absoluto), se tiene que la función de autocovarianzas no depende del tiempo y el proceso es estacionario.

Función de autocorrelación simple

Como ya se vió en el tema anterior, siempre que el proceso sea estacionario la FAC se obtiene a partir de la función de autocovarianzas mediante la siguiente expresión

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad k = 0, 1, 2, \dots$$

Por tanto, la FAC de un AR(1) verifica:

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1, \quad \rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi^k \gamma_0}{\gamma_0} = \phi^k, \quad \forall k \geq 1.$$

Como se observa en esta expresión, Y_t está correlada con cualquier variable retardada Y_{t-k} . Por esta razón se dice que el proceso AR(1) tiene memoria infinita. Aunque si el proceso es estacionario, es decir si $|\phi| < 1$, dicha correlación es más débil a medida que aumenta el retardo.

En la Figura 30.2 se representa la FAC de un proceso AR(1) para $\phi = 0.8$ (derecha) y $\phi = -0.7$ (izquierda), respectivamente.

Función de autocorrelación parcial

La FACP mide para cada retardo k el efecto directo de la variable retardada Y_{t-k} sobre Y_t con independencia de los efectos indirectos.

A partir de la expresión (30.1), $Y_t = \gamma + \phi Y_{t-1} + \varepsilon_t$, se observa que existe un efecto directo de Y_{t-1} sobre Y_t , es decir, Y_{t-1} no necesita de ninguna variable

intermedia para influir sobre Y_t y la cuantía de ese efecto viene dada por ϕ . Sin embargo, si se sustituye la expresión de Y_{t-1} en la ecuación anterior:

$$Y_t = \gamma + \phi(\gamma + \phi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t.$$

Se observa que Y_{t-2} influye a Y_t utilizando como intermediaria a Y_{t-1} , es decir, si Y_{t-1} no existiera Y_{t-2} no podría influir en Y_t . Por tanto, no existe efecto directo de Y_{t-2} sobre Y_t y el coeficiente de autocorrelación de orden 2 sería igual a cero. Es fácil razonar que lo mismo ocurriría con los coeficientes de orden superior a 2. Resumiendo, teniendo en cuenta lo razonado y la ecuación (29.1), la FACP para un proceso AR(1) es:

$$\rho_1^p = \rho_1 = \phi, \quad \rho_k^p = 0, \quad \forall k \geq 2.$$

Resumen

Las principales particularidades de un proceso $AR(1)$ estacionario son:

- El parámetro autorregresivo debe verificar que $|\phi| < 1$.
- La FAC decae hacia cero (en valor absoluto) de forma rápida.
- La FACP se anula para retardos iguales o superiores a 2.

1.2. Proceso autorregresivo de segundo orden

Se dice que un proceso estocástico Y_t sigue un proceso autorregresivo de orden 2, $AR(2)$, si se puede escribir como:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t, \quad (30.5)$$

donde δ, ϕ_1, ϕ_2 son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 .

El proceso $AR(2)$ puede escribirse utilizando el operador retardo B de la siguiente manera:

$$Y_t - \phi_1 Y_{t-1} - \phi_2 Y_{t-2} = \delta + \varepsilon_t \iff (1 - \phi_1 B - \phi_2 B^2)Y_t = \delta + \varepsilon_t,$$

siendo $1 - \phi_1 B - \phi_2 B^2$ su polinomio característico.


En la Figura 30.3 se representan procesos $AR(2)$ con $\delta = 0$, $\phi_1 = 0.8$, $\phi_2 = -0.3$, $Y_0 = 3$ e $Y_1 = 5$ (derecha) y $\delta = 0$, $\phi_1 = 0.4$ y $\phi_2 = 0.5$, $Y_0 = 3$ e $Y_1 = 3$ (izquierda).

A continuación se estudian las características más importantes de este proceso.

Condición de estacionariedad

La modelización de una serie temporal a través de un proceso autorregresivo exige que el modelo sea estacionario en media y varianza.

La condición de estacionariedad en media exige que $E[Y_t]$ no dependa del tiempo, y además, debe ser finita. Por tanto, si un proceso es estacionario en


 Figura 30.3: Procesos AR(2) con $(\phi_1 = 0.8, \phi_2 = -0.3)$ y $(\phi_1 = 0.4, \phi_2 = 0.5)$

media se cumple que $E[Y_{t-i}] = \mu, \forall i \geq 0$. Entonces, la media de un proceso AR(2) se obtiene de la siguiente manera:

$$\begin{aligned}
 E[Y_t] &= E[\delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t] = \delta + E[\phi_1 Y_{t-1}] + E[\phi_2 Y_{t-2}] + \underbrace{E[\varepsilon_t]}_0 \\
 &= \delta + \phi_1 E[Y_{t-1}] + \phi_2 E[Y_{t-2}] \Rightarrow \mu - \phi_1 \mu - \phi_2 \mu = \delta \\
 &\Rightarrow \mu = \frac{\delta}{1 - \phi_1 - \phi_2}.
 \end{aligned} \tag{30.6}$$

Para que la media sea finita es necesario imponer que $\phi_1 + \phi_2 \neq 1$.

De esta última expresión se obtiene que $\delta = \mu(1 - \phi_1 - \phi_2) = E[Y_t](1 - \phi_1 - \phi_2)$ y sustituyendolo en la expresión (30.5) se obtiene:

$$\begin{aligned}
 Y_t &= \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t = E[Y_t](1 - \phi_1 - \phi_2) + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t \\
 &= E[Y_t] + \phi_1 (Y_{t-1} - E[Y_t]) + \phi_2 (Y_{t-2} - E[Y_t]) + \varepsilon_t,
 \end{aligned}$$

es decir:

$$Y_t - E[Y_t] = \phi_1 (Y_{t-1} - E[Y_t]) + \phi_2 (Y_{t-2} - E[Y_t]) + \varepsilon_t. \tag{30.7}$$

Lo que permite transformar el modelo como se hizo para el proceso AR(1) sustituyendo $\tilde{Y}_t = Y_t - E[Y_t]$ en (30.7):

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t.$$

Las propiedades del proceso $\tilde{Y}_t$ se obtuvieron en la Proposición 30.3.

A continuación se estudian las condiciones para que el proceso sea estacionario en varianza. La varianza del proceso se obtiene de la siguiente manera:

$$\begin{aligned}
 \gamma_0 &= Var[Y_t] = Var[\tilde{Y}_t] = E[\tilde{Y}_t^2] - \underbrace{E[\tilde{Y}_t]^2}_0 \\
 &= E[\tilde{Y}_t(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t)] \\
 &= E[\phi_1 \tilde{Y}_t \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_t \tilde{Y}_{t-2} + \tilde{Y}_t \varepsilon_t] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_t \tilde{Y}_{t-1}]}_{\gamma_1} + \phi_2 \underbrace{E[\tilde{Y}_t \tilde{Y}_{t-2}]}_{\gamma_2} + \underbrace{E[\tilde{Y}_t \varepsilon_t]}_{\sigma_\varepsilon^2} = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma_\varepsilon^2.
 \end{aligned} \tag{30.8}$$

Adviértase qe se ha usado la Proposición 30.2.

CAPÍTULO 30. MODELOS UNIVARIANTES LINEALES
ESTACIONARIOS

Como puede observarse, la expresión de la varianza depende de las autocovarianzas de ordenes 1 y 2. A continuación se obtienen sus expresiones:

$$\begin{aligned}
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t) \tilde{Y}_{t-1}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \tilde{Y}_{t-1} \varepsilon_t] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-1}]}_{\gamma_0} + \phi_2 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-2}]}_{\gamma_1} + \underbrace{E[\tilde{Y}_{t-1} \varepsilon_t]}_0 = \phi_1 \gamma_0 + \phi_2 \gamma_1. \\
 \\
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t) \tilde{Y}_{t-2}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-2} + \tilde{Y}_{t-2} \varepsilon_t] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-2}]}_{\gamma_1} + \phi_2 \underbrace{E[\tilde{Y}_{t-2} \tilde{Y}_{t-2}]}_{\gamma_0} + \underbrace{E[\tilde{Y}_{t-2} \varepsilon_t]}_0 = \phi_1 \gamma_1 + \phi_2 \gamma_0.
 \end{aligned}$$

Adviértase que se ha usado la Proposición 30.1.

Por tanto, resolviendo el siguiente sistema:

$$\begin{cases} \gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma_\varepsilon^2 \\ \gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_1 \\ \gamma_2 = \phi_1 \gamma_1 + \phi_2 \gamma_0 \end{cases}$$

conocido como ecuaciones de Yule-Walker, se tiene:

$$\gamma_0 = \frac{1-\phi_2}{(1+\phi_2)} \frac{\sigma_\varepsilon^2}{[(1-\phi_2)^2 - \phi_1^2]}, \quad \gamma_1 = \frac{\phi_1}{1-\phi_2} \gamma_0, \quad \gamma_2 = \left(\frac{\phi_1^2}{1-\phi_2} + \phi_2 \right) \gamma_0.$$

Para que $\gamma_0 > 0$ se debe cumplir que $|\phi_2| < 1$, $\phi_1 + \phi_2 < 1$ y $\phi_2 - \phi_1 < 1$. Estas restricciones se les denomina condiciones de estacionariedad de un proceso AR(2).

Si se analiza la estacionariedad utilizando el polinomio característico $1 - \phi_1 B - \phi_2 B^2$, que se cumplan las condiciones de estacionariedad es equivalente a comprobar que los módulos de las dos raíces del polinomio característico sean mayores que uno. Las soluciones (raíces) de la ecuación de segundo grado $1 - \phi_1 B - \phi_2 B^2 = 0$ son:

$$B_1 = \frac{\phi_1 - \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}, \quad B_2 = \frac{\phi_1 + \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}.$$

Así pues, el proceso AR(2) será estacionario si se cumplen las condiciones:

$$\left| \frac{\phi_1 + \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} \right| > 1, \quad \left| \frac{\phi_1 - \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2} \right| > 1.$$

Se observa que:

- Si el radicando $\phi_1^2 + 4\phi_2 \geq 0$, las raíces son reales; y
- si el radicando $\phi_1^2 + 4\phi_2 < 0$, las raíces son imaginarias.




Figura 30.4: FAC para $(\phi_1 = 0.8, \phi_2 = -0.7)$ y $(\phi_1 = -0.6, \phi_2 = 0.2)$

Finalmente, las autocovarianzas de ordenes mayores o iguales que 3:

$$\begin{aligned}
 \gamma_3 &= Cov(Y_t, Y_{t-3}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-3}) = E[\tilde{Y}_t \tilde{Y}_{t-3}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-3}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t) \tilde{Y}_{t-3}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-3} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-3} + \tilde{Y}_{t-3} \varepsilon_t] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-3}]}_{\gamma_2} + \phi_2 \underbrace{E[\tilde{Y}_{t-2} \tilde{Y}_{t-3}]}_{\gamma_1} + \underbrace{E[\tilde{Y}_{t-3} \varepsilon_t]}_0 = \phi_1 \gamma_2 + \phi_2 \gamma_1.
 \end{aligned}$$

Y en general se tiene que:

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}, \quad \forall k \geq 3. \quad (30.9)$$

Función de autocorrelación simple

Suponiendo estacionariedad, la FAC verifica $\rho_k = \frac{\gamma_k}{\gamma_0}$, por tanto:

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1, \quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\phi_1 \gamma_0}{\gamma_0} = \frac{\phi_1}{1 - \phi_2}, \quad \rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\phi_1 \gamma_1 + \phi_2 \gamma_0}{\gamma_0} = \frac{\phi_1^2}{1 - \phi_2} + \phi_2.$$

Los coeficientes de orden superior se pueden obtener a partir de la expresión (30.9) dividiendo por γ_0 :

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi_1 \gamma_{k-1}}{\gamma_0} + \frac{\phi_2 \gamma_{k-2}}{\gamma_0} = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}. \quad (30.10)$$

En la Figura 30.4 se representa la FAC para procesos $AR(2)$ con $\phi_1 = 0.8$, $\phi_2 = -0.7$ (derecha) y $\phi_1 = -0.6$, $\phi_2 = 0.2$ (izquierda).

Función de autocorrelación parcial

La FACP estima el efecto directo que tiene Y_{t-k} sobre Y_t , excluyendo el efecto indirecto de los valores intermedios $Y_{t-k+1}, Y_{t-k+2}, \dots, Y_{t-1}$.

Por la expresión del proceso $AR(2)$:

$$Y_t = \gamma + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t,$$

se observa que Y_{t-1} e Y_{t-2} tienen efectos directos sobre Y_t , sin embargo Y_{t-3} y las variables con retardo más alto necesitan de Y_{t-1} e Y_{t-2} para influir sobre Y_t , es decir, no tienen efectos directos. Por tanto, para un $AR(2)$ los coeficientes

ρ_k^p para $k \geq 3$ serán iguales a cero. Los dos primeros coeficientes parciales se pueden obtener a partir de las ecuaciones (29.1) y (29.2):

$$\rho_1^p = \rho_1 = \frac{\phi_1}{1 - \phi_2}, \quad \rho_2^p = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}. \quad (30.11)$$

Resumen

En un $AR(2)$ estacionario las principales particularidades son:

- La FAC decae de forma rápida hacia cero.
- La forma de decrecimiento de la FAC depende de si las raíces del polinomio característico son reales o complejas:
 - Si toman valores reales, la FAC decrecerá de forma similar a los procesos $AR(1)$.
 - Si toman valores complejos, la FAC mostrará oscilaciones sinusoidales decrecientes.
- La FACP se anula para retardos superiores o iguales a 3.

1.3. Proceso autorregresivo de orden p

Se dice que un proceso estocástico $\{Y_t\}$ sigue un proceso autorregresivo de orden p , $AR(p)$, si se puede escribir como:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t,$$

donde $\delta, \phi_1, \phi_2, \dots, \phi_p$ son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 .

El proceso $AR(p)$ puede escribirse utilizando el operador retardo B de la siguiente manera:

$$(1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p) Y_t = \delta + \varepsilon_t,$$

donde $1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$ se denomina el polinomio característico de un $AR(p)$.

A continuación se estudian sus características más importantes.

Estacionariedad

Un proceso $AR(p)$ es estacionario si el módulo de cada una de las p raíces del polinomio característico $1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$ es mayor que uno.

Media

Si el proceso es estacionario en media se cumple que $E[Y_{t-i}] = \mu$, $\forall i \geq 0$. Entonces:

$$\begin{aligned}
 E[Y_t] &= E[\delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t] \\
 &= \underbrace{E[\delta]}_{\delta} + E[\phi_1 Y_{t-1}] + E[\phi_2 Y_{t-2}] + \dots + E[\phi_p Y_{t-p}] + \underbrace{E[\varepsilon_t]}_0 \\
 &= \delta + \phi_1 E[Y_{t-1}] + \phi_2 E[Y_{t-2}] + \dots + \phi_p E[Y_{t-p}] \\
 \implies \mu - \phi_1 \mu - \phi_2 \mu - \dots - \phi_p \mu &= \delta \implies \mu = \frac{\delta}{1 - \phi_1 - \phi_2 - \dots - \phi_p}.
 \end{aligned}$$

Función de autocovarianzas

Puesto que:

$$\mu = \frac{\delta}{1 - \phi_1 - \phi_2 - \dots - \phi_p} \implies \delta = E[Y_t](1 - \phi_1 - \phi_2 - \dots - \phi_p),$$

se puede transformar el modelo de forma que:

$$\begin{aligned}
 Y_t &= \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \\
 &= E[Y_t](1 - \phi_1 - \phi_2 - \dots - \phi_p) + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \\
 &= E[Y_t] + \phi_1 (Y_{t-1} - E[Y_t]) + \phi_2 (Y_{t-2} - E[Y_t]) + \dots + \\
 &\quad \phi_p (Y_{t-p} - E[Y_t]) + \varepsilon_t,
 \end{aligned}$$

es decir:

$$Y_t - E[Y_t] = \phi_1 (Y_{t-1} - E[Y_t]) + \phi_2 (Y_{t-2} - E[Y_t]) + \dots + \phi_p (Y_{t-p} - E[Y_t]) + \varepsilon_t. \quad (30.12)$$

Denotando como $\tilde{Y}_t = Y_t - E[Y_t]$, la ecuación (30.12) se expresa como:

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \dots + \phi_p \tilde{Y}_{t-p} + \varepsilon_t.$$

Las características de $\tilde{Y}_t$ fueron estudiadas en la Proposición 30.3.

Teniendo en cuenta la Proposición 30.2, la varianza del proceso será:

$$\begin{aligned}
 \gamma_0 &= Var[Y_t] = Var[\tilde{Y}_t] = E[\tilde{Y}_t^2] - \underbrace{E[\tilde{Y}_t]^2}_0 \\
 &= E[\tilde{Y}_t(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \phi_p \tilde{Y}_{t-p} + \varepsilon_t)] \\
 &= E[\phi_1 \tilde{Y}_t \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_t \tilde{Y}_{t-2} + \dots + \phi_p \tilde{Y}_t \tilde{Y}_{t-p} + \varepsilon_t \tilde{Y}_t] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_t \tilde{Y}_{t-1}]}_{\gamma_1} + \phi_2 \underbrace{E[\tilde{Y}_t \tilde{Y}_{t-2}]}_{\gamma_2} + \dots + \phi_p \underbrace{E[\tilde{Y}_t \tilde{Y}_{t-p}]}_{\gamma_p} + \underbrace{E[\varepsilon_t \tilde{Y}_t]}_{\sigma_\varepsilon^2} \\
 &= \phi_1 \gamma_1 + \phi_2 \gamma_2 + \dots + \phi_p \gamma_p + \sigma_\varepsilon^2.
 \end{aligned}$$

De manera análoga, teniendo en cuenta la Proposición 30.1, el resto de

elementos de la función de autocovarianzas se calculan como sigue:

$$\begin{aligned}
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \phi_p \tilde{Y}_{t-p} + \varepsilon_t) \tilde{Y}_{t-1}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-1} + \cdots + \phi_p \tilde{Y}_{t-p} \tilde{Y}_{t-1} + \varepsilon_t \tilde{Y}_{t-1}] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-1}]}_{\gamma_0} + \phi_2 \underbrace{E[\tilde{Y}_{t-2} \tilde{Y}_{t-1}]}_{\gamma_1} + \cdots + \phi_p \underbrace{E[\tilde{Y}_{t-p} \tilde{Y}_{t-1}]}_{\gamma_{p-1}} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-1}]}_0 \\
 &= \phi_1 \gamma_0 + \phi_2 \gamma_1 + \cdots + \phi_p \gamma_{p-1}.
 \end{aligned}$$

$$\begin{aligned}
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \phi_p \tilde{Y}_{t-p} + \varepsilon_t) \tilde{Y}_{t-2}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-2} + \cdots + \phi_p \tilde{Y}_{t-p} \tilde{Y}_{t-2} + \varepsilon_t \tilde{Y}_{t-2}] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-2}]}_{\gamma_1} + \phi_2 \underbrace{E[\tilde{Y}_{t-2} \tilde{Y}_{t-2}]}_{\gamma_0} + \cdots + \phi_p \underbrace{E[\tilde{Y}_{t-p} \tilde{Y}_{t-2}]}_{\gamma_{p-2}} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-2}]}_0 \\
 &= \phi_1 \gamma_1 + \phi_2 \gamma_0 + \cdots + \phi_p \gamma_{p-2}.
 \end{aligned}$$

Para un $k \geq 3$:

$$\begin{aligned}
 \gamma_k &= Cov(Y_t, Y_{t-k}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-k}) = E[\tilde{Y}_t \tilde{Y}_{t-k}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-k}]}_0 \\
 &= E[(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \phi_k \tilde{Y}_{t-k} + \cdots + \phi_p \tilde{Y}_{t-p} + \varepsilon_t) \tilde{Y}_{t-k}] \\
 &= E[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-k} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-k} + \cdots + \phi_j \tilde{Y}_{t-j} \tilde{Y}_{t-k} + \cdots + \\
 &\quad \phi_p \tilde{Y}_{t-p} \tilde{Y}_{t-k} + \varepsilon_t \tilde{Y}_{t-k}] \\
 &= \phi_1 \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-k}]}_{\gamma_{k-1}} + \phi_2 \underbrace{E[\tilde{Y}_{t-2} \tilde{Y}_{t-k}]}_{\gamma_{k-2}} + \cdots + \phi_k \underbrace{E[\tilde{Y}_{t-k} \tilde{Y}_{t-k}]}_{\gamma_0} + \cdots + \\
 &\quad \phi_p \underbrace{E[\tilde{Y}_{t-p} \tilde{Y}_{t-k}]}_{\gamma_{p-k}} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-k}]}_0 \\
 &= \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \cdots + \phi_k \gamma_0 + \cdots + \phi_p \gamma_{p-k}.
 \end{aligned}$$

El sistema de ecuaciones resultante (ecuaciones de Yule-Walker) para la obtención de las autocovarianzas es:

$$\begin{cases} \gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \cdots + \phi_p \gamma_p + \sigma_\varepsilon^2 \\ \gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_1 + \cdots + \phi_p \gamma_{p-1} \\ \gamma_2 = \phi_1 \gamma_1 + \phi_2 \gamma_0 + \cdots + \phi_p \gamma_{p-2} \\ \vdots \\ \gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \cdots + \phi_k \gamma_0 + \cdots + \phi_p \gamma_{p-k} \\ \vdots \\ \gamma_p = \phi_1 \gamma_{p-1} + \phi_2 \gamma_{p-2} + \cdots + \phi_p \gamma_0 \end{cases}$$

Función de autocorrelación

Suponiendo estacionariedad, la FAC verifica $\rho_k = \frac{\gamma_k}{\gamma_0}$ y, de las ecuaciones de Yule-Walker presentadas anteriormente, se tiene que:

$$\begin{cases} \rho_1 = \phi_1 + \phi_2\rho_1 + \cdots + \phi_p\rho_{p-1} \\ \rho_2 = \phi_1\rho_1 + \phi_2 + \cdots + \phi_p\rho_{p-2} \\ \vdots \\ \rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} + \cdots + \phi_j + \cdots + \phi_p\rho_{p-k} \\ \vdots \\ \rho_p = \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \cdots + \phi_p \end{cases}$$

En forma matricial sería de la forma:

$$\begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \\ \vdots \\ \rho_p \end{pmatrix} = \begin{pmatrix} 1 & \rho_1 & \cdots & \rho_j & \cdots & \rho_{p-1} \\ \rho_1 & 1 & \cdots & \rho_{j-1} & \cdots & \rho_{p-2} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & 1 & \cdots & \rho_{p-k} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \cdots & \rho_{p-j} & \cdots & 1 \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_k \\ \vdots \\ \phi_p \end{pmatrix}.$$

Función de autocorrelación parcial

Razonando de igual manera que en los casos del $AR(1)$ y $AR(2)$, se tiene que las únicas variables que tendrán efectos directos sobre Y_t son $Y_{t-1}, \dots, Y_{t-p}$. Por tanto, los coeficientes de autocorrelación parcial con retardos superiores a p serán iguales a cero. Los primeros p coeficientes se pueden hallar a partir de las ecuaciones (29.1), (29.2) y sus generalizaciones:

$$\rho_1^p = \rho_1, \quad \rho_2^p = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}, \quad \rho_3^p = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_2 \\ \rho_2 & \rho_1 & \rho_3 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}},$$

$$\rho_p^p = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{p-1} & \rho_1 \\ \rho_1 & 1 & \rho_1 & \cdots & \rho_{p-2} & \rho_2 \\ \rho_2 & \rho_1 & 1 & \cdots & \rho_{p-3} & \rho_3 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \rho_{p-3} & \cdots & \rho_1 & \rho_p \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{p-1} & \rho_p \\ \rho_1 & 1 & \rho_1 & \cdots & \rho_{p-2} & \rho_{p-1} \\ \rho_2 & \rho_1 & 1 & \cdots & \rho_{p-3} & \rho_{p-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \rho_{p-3} & \cdots & \rho_1 & 1 \end{vmatrix}}.$$

Resumen

En un proceso $AR(p)$ estacionario las principales particularidades son:

- La FAC decae hacia cero de forma rápida.
- La FACP se anula para retardos superiores a p .

Ejemplo 30.1 Dado el proceso $Y_t = 2.5 - 1.8Y_{t-1} - 0.81Y_{t-2} + \varepsilon_t$ donde ε_t es ruido blanco. Se pide:

1. Comprobar si es estacionario.
2. Calcular la media del proceso.
3. Calcular la varianza del proceso sabiendo que $\sigma_\varepsilon^2 = 2$.
4. Calcular los coeficientes de retardos 1, 2 y 3 de la FAC.
5. Calcular la FACP.

Solución

1. Un proceso es estacionario cuando las raíces del polinomio característico de la parte AR son, en modulo, mayores que uno. La ecuación a resolver en este caso es $1 + 1.8B + 0.81B^2 = 0$. Su solución es:

$$B = \frac{-1.8 \pm \sqrt{1.8^2 - 4 \cdot (0.81)}}{2 \cdot (0.81)} = \frac{-1.8 \pm \sqrt{0}}{1.62} = -1.11$$

Es una raíz (doble) real y su valor absoluto es mayor que uno. Por tanto, el proceso es estacionario.

2. De la ecuación (30.6) se tiene que:

$$E[Y_t] = \frac{\delta}{1 - \phi_1 - \phi_2} = \frac{2.5}{1 + 1.8 + 0.81} = 0.6925.$$

3. De las ecuaciones (1.2) se obtienen las siguientes igualdades para calcular la varianza del proceso:

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma_\varepsilon^2 \quad (30.13)$$

$$\gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1 \quad (30.14)$$

$$\gamma_2 = \phi_1\gamma_1 + \phi_2\gamma_0 \quad (30.15)$$

De la ecuación (30.14) se tiene que:

$$\gamma_1 = \frac{-1.8}{1 + 0.81}\gamma_0 = -0.9945\gamma_0. \quad (30.16)$$

De la ecuación (30.15) se tiene que:

$$\gamma_2 = -1.8(-0.9945)\gamma_0 - 0.81\gamma_0 = 0.9801\gamma_0. \quad (30.17)$$

Sustituyendo (30.16) y (30.17) en (30.13):

$$\begin{aligned}\gamma_0 &= -1.8(-0.9945)\gamma_0 - 0.81(0.98)\gamma_0 + 2 \\ 0.0038\gamma_0 &= 2 \\ \gamma_0 &= 527.77\end{aligned}$$

4. De ecuación (30.16) se tiene que $\gamma_1 = -0.9945\gamma_0$, por tanto:

$$\rho_1 = \frac{-0.9945\gamma_0}{\gamma_0} = -0.9945.$$

De la ecuación (30.17) se tiene que $\gamma_2 = 0.98\gamma_0$, por tanto:

$$\rho_2 = \frac{0.9801\gamma_0}{\gamma_0} = 0.9801.$$

Por último, de la ecuación (30.10) se obtiene:

$$\rho_3 = -1.8\rho_2 - 0.81\rho_1 = -1.8 \cdot 0.9801 - 0.81 \cdot (-0.9945) = -0.9585$$

5. Al ser un proceso $AR(2)$, los coeficientes de la FACP de orden 3 o más son todos nulos. Los primeros dos coeficientes se obtienen a partir de las ecuaciones (30.11):

$$\rho_1^p = -0.9945, \quad \rho_2^p = \frac{0.9801 - (-0.9945)^2}{1 - (-0.9945)^2} = -0.8181.$$

2. Proceso de medias móviles

Un proceso se denomina de medias móviles cuando explica el valor de una determinada variable en un periodo t en función de un término independiente y una sucesión de perturbaciones correspondiente a períodos pasados ponderados convenientemente.

Los procesos de medias móviles se abrevian con la palabra MA tras la que se indica el orden del proceso $MA(1)$, $MA(2)$,... El orden del proceso expresa el número de retardos de la perturbación que intervienen en la ecuación. La expresión genérica de un proceso de medias móviles $MA(q)$ es la siguiente:

$$Y_t = \delta + \varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2} + \cdots + \theta_q\varepsilon_{t-q},$$

donde δ es una constante, $\theta_1, \theta_2, \dots, \theta_q$ son los denominados parámetros de media móvil y ε_t es ruido blanco.

Su expresión abreviada es:

$$Y_t = \delta + \theta_q(B)\varepsilon_t$$

donde $\theta_q(B) = 1 + \theta_1B + \theta_2B^2 + \cdots + \theta_qB^q$ es denominado polinomio característico o de retardos del proceso $MA(q)$.

En la práctica, como pasa con los procesos autorregresivos, se suele trabajar con procesos de medias móviles de órdenes bajos: $MA(1)$ o $MA(2)$ o bien con órdenes múltiplos de la periodicidad de los datos de la serie analizada (si es trimestral $MA(4)$, si es mensual $MA(12)$,...).

Media

Dado que el proceso ε_t es un ruido blanco y, por definición, su media es cero, la media de un proceso $MA(q)$ es igual a la constante δ del proceso (para cualquier orden q):

$$E[Y_t] = E[\delta] + \underbrace{E[\varepsilon_t]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1}]}_0 + \theta_2 \underbrace{E[\varepsilon_{t-2}]}_0 + \cdots + \theta_q \underbrace{E[\varepsilon_{t-q}]}_0 = \delta. \quad (30.18)$$

Denotando por $\tilde{Y}_t = Y_t - E[Y_t] = Y_t - \delta$, el proceso $MA(q)$ se puede expresar de la siguiente manera:

$$\tilde{Y}_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q},$$

expresión que facilitará algunos de los cálculos realizados a continuación. En la Proposición 30.3 se estudiaron las propiedades de $\tilde{Y}_t$.

Invertibilidad

Un proceso Y_t es invertible si puede ser representado como un proceso autoregresivo de orden finito o un proceso autoregresivo de orden infinito pero convergente. Intuitivamente que un proceso sea invertible significa que puede explicarse en función de su propio pasado hasta un determinado retardo (AR finito) o que la influencia del pasado se diluye con el tiempo (AR infinito convergente).

La propiedad de invertibilidad es importante ya que en la obtención de las FAC y FACP se asume que los procesos se pueden representar de forma autoregresiva. Los procesos AR son, por definición, invertibles. Sin embargo, es necesario estudiar qué condiciones son necesarias para que también lo sean los procesos de medias móviles.

De la expresión con el polinomio característico del proceso $MA(q)$:

$$\tilde{Y}_t = (1 + \theta_1 B + \cdots + \theta_q B^q) \varepsilon_t,$$

se obtiene:

$$(1 + \theta_1 B + \cdots + \theta_q B^q)^{-1} \tilde{Y}_t = \varepsilon_t. \quad (30.19)$$

Por las propiedades de los polinomios se sabe que el inverso de un polinomio finito es un polinomio infinito:

$$(1 + \theta_1 B + \cdots + \theta_q B^q)^{-1} = 1 + \varphi_1 B + \varphi_2 B^2 + \cdots, \quad (30.20)$$

cuya expresión es convergente si y solo si las q raíces del polinomio característico $1 + \theta_1 B + \cdots + \theta_q B^q$ son en módulo mayores que 1, es decir, $|B_i| > 1$, $i = 1, \dots, q$. A estas condiciones se les denomina condiciones de invertibilidad del proceso $MA(q)$.

Sustituyendo la ecuación (30.20) en (30.19):

$$\begin{aligned} (1 + \varphi_1 B + \varphi_2 B^2 + \cdots) \tilde{Y}_t &= \varepsilon_t \Rightarrow \tilde{Y}_t + \varphi_1 \tilde{Y}_{t-1} + \varphi_2 \tilde{Y}_{t-2} + \cdots = \varepsilon_t \Rightarrow \\ &\Rightarrow \tilde{Y}_t = \varepsilon_t - \varphi_1 \tilde{Y}_{t-1} - \varphi_2 \tilde{Y}_{t-2} - \cdots \end{aligned}$$




Figura 30.5: Procesos MA(1) con $\theta = -0.8$ y $\theta = 0.3$

Deshaciendo la transformación:

$$\begin{aligned} Y_t - \delta &= \varepsilon_t - \varphi_1(Y_{t-1} - \delta) - \varphi_2(Y_{t-2} - \delta) - \dots \\ Y_t &= \delta(1 - \varphi_1 - \varphi_2 - \dots) + \varepsilon_t - \varphi_1 Y_{t-1} - \varphi_2 Y_{t-2} - \dots \end{aligned} \quad (30.21)$$

se ha expresado Y_t como un $AR(\infty)$, por lo que depende de su propio pasado.

2.1. Proceso de medias móviles de primer orden

Es el proceso de medias móviles más simple. Se dice que un proceso estocástico $\{Y_t\}$ sigue un proceso de medias móviles de orden 1, $MA(1)$, si se puede escribir como:

$$Y_t = \delta + \varepsilon_t + \theta \varepsilon_{t-1},$$

donde δ, θ son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 .

El proceso $MA(1)$ puede escribirse utilizando el operador retardo B de la siguiente manera:

$$Y_t = \delta + (1 + \theta B)\varepsilon_t.$$

Se denomina polinomio característico de un $MA(1)$ al polinomio $1 + \theta B$.

En la Figura 30.5 se representa un proceso $MA(1)$ con $\delta = 0$, $\varepsilon_0 = 0.0252$, $\varepsilon_t \sim N(0, 1)$ para $t \geq 1$ en ambos casos y $\theta = -0.8$ (derecha) y $\theta = 0.3$ (izquierda).

A continuación se estudian sus características más importantes.

Estacionariedad

Un proceso es estacionario si su media y varianza son constantes y su función de autocovarianzas no depende del tiempo, solo depende del retardo que separa a las observaciones. Como se ha visto en la ecuación (30.18), la media del proceso es δ y, por tanto, constante.

La varianza del proceso verifica:

$$\begin{aligned} \gamma_0 &= \text{Var}[Y_t] = \text{Var}[\delta + \varepsilon_t + \theta \varepsilon_{t-1}] = \underbrace{\text{Var}[\varepsilon_t]}_{\sigma_\varepsilon^2} + \theta^2 \underbrace{\text{Var}[\varepsilon_{t-1}]}_{\sigma_\varepsilon^2} \\ &\quad + \underbrace{2\text{Cov}(\varepsilon_t, \theta \varepsilon_{t-1})}_0 \\ \Rightarrow \gamma_0 &= \sigma_\varepsilon^2 + \theta^2 \sigma_\varepsilon^2 = (1 + \theta^2) \sigma_\varepsilon^2. \end{aligned}$$

CAPÍTULO 30. MODELOS UNIVARIANTES LINEALES ESTACIONARIOS

Como $\sigma_\varepsilon^2 > 0$ y $1 + \theta^2 > 0$, la varianza es positiva y constante. Para confirmar la estacionariedad del proceso hace falta ver que la función de autocovarianzas no depende del tiempo.

Utilizando el proceso transformado $\tilde{Y}_t = Y_t - \delta$, cuyas propiedades se estudiaron en la Proposición 30.3, el proceso $MA(1)$ se expresa como:

$$\tilde{Y}_t = \varepsilon_t + \theta \varepsilon_{t-1}.$$

A partir de esta expresión los coeficientes de la función de autocovarianzas y de las Proposiciones 30.1 y 30.2 se obtienen de la siguiente manera:

$$\begin{aligned} \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\ &= E[\tilde{Y}_t \tilde{Y}_{t-1}] = E[(\varepsilon_t + \theta \varepsilon_{t-1}) \tilde{Y}_{t-1}] = E[\varepsilon_t \tilde{Y}_{t-1} + \theta \varepsilon_{t-1} \tilde{Y}_{t-1}] \\ &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-1}]}_0 + \theta \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-1}]}_{\sigma_\varepsilon^2} = \theta \sigma_\varepsilon^2. \end{aligned}$$

$$\begin{aligned} \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\ &= E[\tilde{Y}_t \tilde{Y}_{t-2}] = E[(\varepsilon_t + \theta \varepsilon_{t-1}) \tilde{Y}_{t-2}] = E[\varepsilon_t \tilde{Y}_{t-2} + \theta \varepsilon_{t-1} \tilde{Y}_{t-2}] \\ &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-2}]}_0 + \theta \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-2}]}_0 = 0. \end{aligned}$$

Razonando de igual manera se obtiene que todos los coeficientes con retardos superiores a dos son también nulos. Por tanto:

$$\gamma_0 = (1 + \theta^2) \sigma_\varepsilon^2, \quad \gamma_1 = \theta \sigma_\varepsilon^2, \quad \gamma_k = 0, \quad \forall k \geq 2.$$

Función de autocorrelación simple

Dado que el proceso $MA(1)$ es estacionario, los coeficientes de la FAC se obtienen mediante la expresión $\rho_k = \frac{\gamma_k}{\gamma_0}$ y, por tanto, la FAC viene dada por:

$$\rho_0 = 1, \quad \rho_1 = \frac{\theta \sigma_\varepsilon^2}{(1 + \theta^2) \sigma_\varepsilon^2} = \frac{\theta}{1 + \theta^2}, \quad \rho_k = \frac{0}{\gamma_0} = 0, \quad \forall k \geq 2.$$

En la Figura 30.6 se representa la FAC de un proceso $MA(1)$ para $\theta = 0.8$ (derecha) y $\theta = -0.7$ (izquierda).

Función de autocorrelación parcial

Si el proceso es invertible, es decir, si la raíz de su polinomio característico $1 + \theta B$ es mayor que 1 en valor absoluto, Y_t se puede expresar en función de su propio pasado tal y como se mostró en la ecuación (30.21).

En el siguiente ejemplo se muestra cómo encontrar la expresión $AR(\infty)$ para un proceso $MA(1)$ particular.




Figura 30.6: FAC para $\theta = 0.8$ y $\theta = -0.7$

Ejemplo 30.2 A continuación se expresa el proceso $Y_t = (1 - 0.2B)\varepsilon_t$ como un $AR(\infty)$.

Despejando de la expresión del proceso se tiene que:

$$(1 - 0.2B)^{-1}Y_t = \varepsilon_t,$$

y de las propiedades de los polinomios se sabe que el inverso de un polinomio es un polinomio infinito, es decir,

$$(1 + \psi_1 B + \psi_2 B^2 + \dots)Y_t = \varepsilon_t, \quad (30.22)$$

donde:

$$\begin{aligned} (1 - 0.2B)^{-1} &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ 1 &= (1 - 0.2B)(1 + \psi_1 B + \psi_2 B^2 + \dots) \\ 1 &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ &\quad - 0.2B - 0.2\psi_1 B^2 - 0.2\psi_2 B^3 + \dots \\ 1 + 0B + 0B^2 + \dots &= 1 + (\psi_1 - 0.2)B + (\psi_2 - 0.2\psi_1)B^2 + \dots \end{aligned}$$

Igualando términos que acompañan a B , B^2 ,... se tiene que:

$$\begin{aligned} B: \quad 0 &= \psi_1 - 0.2 \Rightarrow \psi_1 = 0.2 \\ B^2: \quad 0 &= \psi_2 - 0.2\psi_1 \Rightarrow \psi_2 = 0.2\psi_1 = 0.2^2 = 0.04 \\ &\dots \end{aligned}$$

Sustituyendo estos parámetros en la ecuación (30.22) se obtiene la expresión del proceso como un $AR(\infty)$:

$$(1 + 0.2B + 0.2^2 B^2 + \dots)Y_t = \varepsilon_t \Leftrightarrow Y_t = -0.2Y_{t-1} - 0.2^2 Y_{t-2} - \dots + \varepsilon_t.$$

Que el proceso $MA(1)$ se pueda expresar como un $AR(\infty)$ significa que existe un efecto directo entre la variable Y_t y todas las demás variables retardadas Y_{t-1} , Y_{t-2} ,... Por tanto, todos los coeficientes de la FACP son distintos de cero. Al ser el proceso invertible también se sabe que estos coeficientes decrecen a medida que aumenta el retardo, dicho con otras palabras, la influencia del pasado se debilita a medida que las variables se alejan en el tiempo.

La obtención de los coeficientes de la FACP se realiza a partir de las ecuaciones (29.1), (29.2) y sus generalizaciones imponiendo que $\rho_k = 0$, $k \geq 2$:

$$\begin{aligned}
 \rho_1^p &= \rho_1 = \frac{\theta}{1 + \theta^2} \\
 \rho_2^p &= \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{-\rho_1^2}{1 - \rho_1^2} = \frac{-\theta^2}{1 + \theta^2 + \theta^4} \\
 \rho_3^p &= \frac{\begin{vmatrix} 1 & \rho_1 & \rho_1 \\ \rho_1 & 1 & 0 \\ 0 & \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & 0 \\ \rho_1 & 1 & \rho_1 \\ 0 & \rho_1 & 1 \end{vmatrix}} = \frac{\rho_1^3}{1 - 2\rho_1^2} = \frac{\theta^3}{1 + \theta^2 + \theta^4 + \theta^6} \\
 &\vdots \\
 \rho_k^p &= \frac{\begin{vmatrix} 1 & \rho_1 & 0 & \cdots & 0 & \rho_1 \\ \rho_1 & 1 & \rho_1 & \cdots & 0 & 0 \\ 0 & \rho_1 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & 0 & \cdots & 0 & 0 \\ \rho_1 & 1 & \rho_1 & \cdots & 0 & 0 \\ 0 & \rho_1 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & \rho_1 & 1 \end{vmatrix}} = \frac{(-1)^{k-1} \theta^k}{1 + \theta^2 + \cdots + \theta^{2k}}.
 \end{aligned}$$

Resumiendo, la FACP tiene infinitos valores distintos de cero y van decreciendo exponencialmente a partir del primer valor hacia cero.

Resumen

En un $MA(1)$ invertible las principales particularidades son:

- Siempre es estacionario.
- La FAC sólo tiene un coeficiente no nulo en el retardo 1, siendo 0 en el resto.
- La FACP no se anula, pero tiene un comportamiento convergente a cero.

2.2. Proceso de medias móviles de segundo orden

Se dice que un proceso estocástico $\{Y_t\}$ sigue un proceso de medias móviles de orden 2, $MA(2)$, si se puede escribir como:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2},$$




Figura 30.7: Procesos $MA(2)$ con $(\theta_1 = -0.8$ y $\theta_2 = 0.3)$ y $(\theta_1 = -0.4$ y $\theta_2 = -0.5)$

donde $\delta, \theta_1, \theta_2$ son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 . El proceso $MA(2)$ puede escribirse utilizando el operador retardo B de la siguiente manera:

$$Y_t = \delta + (1 + \theta_1 B + \theta_2 B^2)\varepsilon_t.$$

A $1 + \theta_1 B + \theta_2 B^2$ se le denomina polinomio característico de un $MA(2)$.

En la Figura 30.7 se representan procesos $MA(2)$ con $\delta = 0$, $\varepsilon_0 = 0.0252 = \varepsilon_1$, $\varepsilon_t \sim N(0, 1)$ para $t \geq 2$ en ambos casos y $\theta_1 = -0.8$ y $\theta_2 = 0.3$ (derecha) y $\theta_1 = -0.4$ y $\theta_2 = -0.5$ (izquierda).

A continuación se estudian sus características más importantes.

Estacionariedad

Como ya se vió en la ecuación (30.18), la media de un proceso $MA(2)$ es igual a δ y, por tanto, constante.

Teniendo en cuenta que $Cov(\varepsilon_i, \varepsilon_j) = 0$, $\forall i \neq j$, la varianza de Y_t verifica:

$$\begin{aligned} \gamma_0 &= Var[Y_t] = Var[\delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}] \\ &= \underbrace{Var[\varepsilon_t]}_{\sigma_\varepsilon^2} + \theta_1^2 \underbrace{Var[\varepsilon_{t-1}]}_{\sigma_\varepsilon^2} + \theta_2^2 \underbrace{Var[\varepsilon_{t-2}]}_{\sigma_\varepsilon^2} \\ &= \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 + \theta_2^2 \sigma_\varepsilon^2 = (1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2. \end{aligned} \quad (30.23)$$

Como $\sigma_\varepsilon^2 > 0$ y $1 + \theta_1^2 + \theta_2^2 > 0$, la expresión de la varianza es positiva y constante.

Falta pues comprobar que la función de autocovarianzas no depende del tiempo, depende solo del retardo que separa a las variables.

Utilizando la transformación $\tilde{Y}_t = Y_t - E[Y_t] = Y_t - \delta$, el proceso $MA(2)$ se expresa de la siguiente forma:

$$\tilde{Y}_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}.$$

Usando las Propositiones 30.1 y 30.2, esta expresión ayuda a obtener los coeficientes de la función de autocovarianzas:

$$\begin{aligned}
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-1}] = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}) \tilde{Y}_{t-1}] \\
 &= E[\varepsilon_t \tilde{Y}_{t-1} + \theta_1 \varepsilon_{t-1} \tilde{Y}_{t-1} + \theta_2 \varepsilon_{t-2} \tilde{Y}_{t-1}] \\
 &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-1}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-1}]}_{\sigma_\varepsilon^2} + \theta_2 E[\varepsilon_{t-2} \tilde{Y}_{t-1}] \\
 &= \theta_1 \sigma_\varepsilon^2 + \theta_2 E[\varepsilon_{t-2} (\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3})] \\
 &= \theta_1 \sigma_\varepsilon^2 + \theta_2 \underbrace{(E[\varepsilon_{t-2} \varepsilon_{t-1}] + \theta_1 E[\varepsilon_{t-2}^2] + \theta_2 E[\varepsilon_{t-2} \varepsilon_{t-3}])}_0 \\
 &= \theta_1 \sigma_\varepsilon^2 + \theta_1 \theta_2 \sigma_\varepsilon^2 = \theta_1 (\theta_2 + 1) \sigma_\varepsilon^2.
 \end{aligned}$$

$$\begin{aligned}
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-2}] = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}) \tilde{Y}_{t-2}] \\
 &= E[\varepsilon_t \tilde{Y}_{t-2} + \theta_1 \varepsilon_{t-1} \tilde{Y}_{t-2} + \theta_2 \varepsilon_{t-2} \tilde{Y}_{t-2}] \\
 &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-2}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-2}]}_0 + \theta_2 \underbrace{E[\varepsilon_{t-2} \tilde{Y}_{t-2}]}_{\sigma_\varepsilon^2} = \theta_2 \sigma_\varepsilon^2.
 \end{aligned}$$

$$\begin{aligned}
 \gamma_3 &= Cov(Y_t, Y_{t-3}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-3}) = E[\tilde{Y}_t \tilde{Y}_{t-3}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-3}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-3}] = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}) \tilde{Y}_{t-3}] \\
 &= E[\varepsilon_t \tilde{Y}_{t-3} + \theta_1 \varepsilon_{t-1} \tilde{Y}_{t-3} + \theta_2 \varepsilon_{t-2} \tilde{Y}_{t-3}] \\
 &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-3}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-3}]}_0 + \theta_2 \underbrace{E[\varepsilon_{t-2} \tilde{Y}_{t-3}]}_0 = 0.
 \end{aligned}$$

Por tanto, la función de autocovarianzas de un proceso $MA(2)$ es:

$$\gamma_0 = (1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2, \quad \gamma_1 = \theta_1 (\theta_2 + 1) \sigma_\varepsilon^2, \quad \gamma_2 = \theta_2 \sigma_\varepsilon^2, \quad \gamma_k = 0, \quad \forall k \geq 3.$$

Como puede observarse, la función de autocovarianzas no depende del tiempo. Por tanto, no es necesario imponer ninguna condición para que el proceso $MA(2)$ sea estacionario.

Función de autocorrelación simple

Dado que $\rho_k = \frac{\gamma_k}{\gamma_0}$, la FAC de un proceso $MA(2)$ verifica:

$$\begin{aligned}
 \rho_0 &= 1, \quad \rho_1 = \frac{\theta_1 (\theta_2 + 1) \sigma_\varepsilon^2}{(1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2} = \frac{\theta_1 (\theta_2 + 1)}{1 + \theta_1^2 + \theta_2^2}, \\
 \rho_2 &= \frac{\theta_2 \sigma_\varepsilon^2}{(1 + \theta_1^2 + \theta_2^2) \sigma_\varepsilon^2} = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2}, \quad \rho_k = \frac{0}{\gamma_0} = 0, \quad \forall k \geq 3.
 \end{aligned}$$

En la Figura 30.8 se representa la FAC de procesos $MA(2)$ para $\theta_1 = 0.9$, $\theta_2 = -0.3$ y para $\theta_1 = -0.6$, $\theta_2 = 0.2$, respectivamente.




Figura 30.8: FAC de $MA(2)$ con $(\theta_1 = 0.9, \theta_2 = -0.3)$ y $(\theta_1 = -0.6, \theta_2 = 0.2)$

Función de autocorrelación parcial

Al igual que para el proceso $MA(1)$, si un proceso $MA(2)$ es invertible (las raíces del polinomio característico $1 + \theta_1 B + \theta_2 B^2$ son, en modulo, mayores que 1) entonces se puede expresar en función de su propio pasado, por tanto, existe influencia directa de todas las variables retardadas $Y_{t-1}, Y_{t-2}, \dots$ sobre Y_t . Es decir, todos los coeficientes de la FACP serán distintos de cero.

La obtención de los coeficientes de la FACP se realiza a partir de la ecuaciones (29.1), (29.2) y sus generalizaciones imponiendo que $\rho_k = 0, k \geq 3$.

$$\rho_1^p = \rho_1 = \frac{\theta_1(1 + \theta_2)}{1 + \theta_1^2 + \theta_2^2}, \quad \rho_2^p = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}},$$

$$\rho_3^p = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_1 \\ \rho_1 & 1 & \rho_2 \\ \rho_2 & \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_1 & \rho_1 & 1 \end{vmatrix}}, \quad \rho_4^p = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_2 & \rho_1 \\ \rho_1 & 1 & \rho_1 & \rho_2 \\ \rho_2 & \rho_1 & 1 & 0 \\ 0 & \rho_2 & \rho_1 & 0 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 & 0 \\ \rho_1 & 1 & \rho_1 & \rho_2 \\ \rho_2 & \rho_1 & 1 & \rho_1 \\ 0 & \rho_2 & \rho_1 & 1 \end{vmatrix}}, \dots$$

La FACP tiene infinitos valores distintos de cero que decrecen exponencialmente a partir del primer valor hacia cero.

Resumen

En un $MA(2)$ invertible las principales particularidades son:

- Siempre es estacionario.
- La FAC tiene sus dos primeros coeficientes distintos de cero.
- La FACP no se anula, pero tiene un comportamiento convergente a cero.

2.3. Proceso de medias móviles de orden q

Es la generalización de los modelos anteriores. Un proceso estocástico $\{Y_t\}$ se comporta como un modelo de medias móviles de orden q denotado por $MA(q)$,

si se puede escribir como:

$$Y_t = \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q},$$

donde $\delta, \theta_1, \dots, \theta_q$ son constantes y ε_t es ruido blanco con media cero y varianza σ_ε^2 .

El proceso $MA(q)$ puede escribirse utilizando el operador retardo B de la siguiente manera:

$$Y_t = \delta + (1 + \theta_1 B + \cdots + \theta_q B^q) \varepsilon_t,$$

donde $1 + \theta_1 B + \cdots + \theta_q B^q$ es el polinomio característico del $MA(q)$.

A continuación se estudian sus características más importantes.

Estacionariedad

Como ya se sabe de la ecuación (30.18), la media de un proceso $MA(q)$ es constante e igual a δ .

Teniendo en cuenta una vez más que se ha usado que $Cov(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$, la varianza de Y_t se obtiene de la siguiente manera:

$$\begin{aligned} \gamma_0 &= Var[Y_t] = Var[\delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}] \\ &= \underbrace{Var[\varepsilon_t]}_{\sigma_\varepsilon^2} + \theta_1^2 \underbrace{Var[\varepsilon_{t-1}]}_{\sigma_\varepsilon^2} + \cdots + \theta_q^2 \underbrace{Var[\varepsilon_{t-q}]}_{\sigma_\varepsilon^2} \\ &= \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 + \cdots + \theta_q^2 \sigma_\varepsilon^2 = (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2. \end{aligned}$$

Dado que $\sigma_\varepsilon^2 > 0$ y $1 + \theta_1^2 + \cdots + \theta_q^2 > 0$ la expresión de la varianza es positiva y constante. Falta demostrar que la función de autocovarianzas no depende del tiempo.

Utilizando la transformación $\tilde{Y}_t = Y_t - E[Y_t] = Y_t - \delta$ el proceso se expresa de la siguiente forma:

$$\tilde{Y}_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Esta expresión y las Proposiciones 30.1 y 30.2 ayudarán a obtener los coeficientes de la función de covarianzas:

$$\begin{aligned}
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-1}] = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}) \tilde{Y}_{t-1}] \\
 &= E[\varepsilon_t \tilde{Y}_{t-1} + \theta_1 \varepsilon_{t-1} \tilde{Y}_{t-1} + \cdots + \theta_q \varepsilon_{t-q} \tilde{Y}_{t-1}] \\
 &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-1}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-1}]}_{\sigma_\varepsilon^2} + \theta_2 E[\varepsilon_{t-2} \tilde{Y}_{t-1}] + \cdots + \theta_q E[\varepsilon_{t-q} \tilde{Y}_{t-1}] \\
 &= \theta_1 \sigma_\varepsilon^2 + \theta_2 E[\varepsilon_{t-2} (\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q-1})] + \cdots \\
 &\quad + \theta_q E[\varepsilon_{t-q} (\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q-1})] \\
 &= + \theta_1 \sigma_\varepsilon^2 + \theta_2 (\underbrace{E[\varepsilon_{t-2} \varepsilon_{t-1}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-2}^2]}_{\sigma_\varepsilon^2} + \cdots + \theta_q \underbrace{E[\varepsilon_{t-q-1} \varepsilon_{t-2}]}_0) + \cdots \\
 &\quad + \theta_q (\underbrace{E[\varepsilon_{t-1} \varepsilon_{t-q}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-2} \varepsilon_{t-q}]}_0 + \cdots + \theta_{q-1} \underbrace{E[\varepsilon_{t-q}^2]}_{\sigma_\varepsilon^2}) \\
 &\quad + \theta_q \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-q-1}]}_0 \\
 &= \sigma_\varepsilon^2 (\theta_1 + \theta_1 \theta_2 + \cdots + \theta_{q-1} \theta_q).
 \end{aligned}$$

$$\begin{aligned}
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-2}] = E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}) \tilde{Y}_{t-2}] \\
 &= E[\varepsilon_t \tilde{Y}_{t-2} + \theta_1 \varepsilon_{t-1} \tilde{Y}_{t-2} + \cdots + \theta_q \varepsilon_{t-q} \tilde{Y}_{t-2}] \\
 &= \underbrace{E[\varepsilon_t \tilde{Y}_{t-2}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-1} \tilde{Y}_{t-2}]}_0 + \theta_2 \underbrace{E[\varepsilon_{t-2} \tilde{Y}_{t-2}]}_{\sigma_\varepsilon^2} + \theta_3 E[\varepsilon_{t-3} \tilde{Y}_{t-2}] + \cdots \\
 &\quad + \theta_q E[\varepsilon_{t-q} \tilde{Y}_{t-2}] \\
 &= \theta_2 \sigma_\varepsilon^2 + \theta_3 E[\varepsilon_{t-3} (\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \cdots + \theta_{q-2} \varepsilon_{t-q} + \theta_{q-1} \varepsilon_{t-q-1} \\
 &\quad + \theta_q \varepsilon_{t-q-2})] + \cdots + \theta_q E[\varepsilon_{t-q} (\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \cdots + \theta_{q-2} \varepsilon_{t-q} \\
 &\quad + \theta_{q-1} \varepsilon_{t-q-1} + \theta_q \varepsilon_{t-q-2})] \\
 &= \theta_2 \sigma_\varepsilon^2 + \theta_3 (\underbrace{E[\varepsilon_{t-3} \varepsilon_{t-2}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-3}^2]}_{\sigma_\varepsilon^2} + \cdots + \theta_{q-2} \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-3}]}_0 \\
 &\quad + \theta_{q-1} \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-q-1}]}_0 + \theta_q \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-q-2}]}_0) + \cdots \\
 &\quad + \theta_q (\underbrace{E[\varepsilon_{t-2} \varepsilon_{t-q}]}_0 + \theta_1 \underbrace{E[\varepsilon_{t-3} \varepsilon_{t-q}]}_0 + \cdots + \theta_{q-2} \underbrace{E[\varepsilon_{t-q}^2]}_{\sigma_\varepsilon^2} \\
 &\quad + \theta_{q-1} \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-q-1}]}_0 + \theta_q \underbrace{E[\varepsilon_{t-q} \varepsilon_{t-q-2}]}_0) \\
 &= \sigma_\varepsilon^2 (\theta_2 + \theta_1 \theta_3 + \cdots + \theta_{q-2} \theta_q).
 \end{aligned}$$

Generalizando:

$$\gamma_k = \begin{cases} \sigma_\varepsilon^2(\theta_k + \sum_{j=1}^{q-k} \theta_j \theta_{j+k}), & k \leq q \\ 0, & k > q \end{cases}.$$

Dado que la función de autocovarianzas no depende del tiempo, se acaba de comprobar que no es necesario imponer ninguna condición para que el proceso $MA(q)$ sea estacionario.

Función de autocorrelación simple

Dado que $\rho_k = \frac{\gamma_k}{\gamma_0}$, la FAC tiene la siguiente forma:

$$\rho_0 = 1, \quad \rho_k = \begin{cases} \frac{\theta_k + \sum_{j=1}^{q-k} \theta_j \theta_{j+k}}{1 + \theta_1^2 + \dots + \theta_q^2} & k \leq q \\ 0 & k > q \end{cases}.$$

Función de autocorrelación parcial

Si el proceso Y_t es invertible (las q raíces del polinomio característico $1 + \theta_1 B + \dots + \theta_q B^q$ son, en módulo, mayores que uno) se puede expresar como un proceso $AR(\infty)$. Esto significa que todas las variables retardadas tienen influencia directa sobre Y_t y, por tanto, todos los coeficientes de la FACP serán no nulos. La obtención de dichos coeficientes se realiza a partir de las ecuaciones (29.1), (29.2) y sus generalizaciones imponiendo que $\rho_k = 0$ para $k > q$.

Resumiendo, la FACP tiene infinitos valores distintos de cero que decrecen exponencialmente a partir del primer valor hacia cero.

Resumen

En un $MA(q)$ invertible las principales particularidades son:

- Siempre es estacionario.
- La FAC tiene los primeros q coeficientes distintos de cero.
- La FACP no se anula, pero tiene un comportamiento convergente a cero.

Ejemplo 30.3 Considere el modelo $Y_t = 5 + \varepsilon_t - 0.8\varepsilon_{t-1} + 0.25\varepsilon_{t-2}$ donde ε_t es ruido blanco. Sabiendo que $\sigma_\varepsilon^2 = 2$ se pide:

1. Comprobar las condiciones de estacionariedad e invertibilidad.
2. Calcular la media y varianza del proceso.
3. Obtener la FAC.
4. Calcular los dos primeros términos de la FACP.
5. Hallar la representación $AR(\infty)$ del proceso.

Solución

1. Al ser un proceso $MA(2)$ se sabe que es estacionario sin necesidad de imponer ninguna condición. Para estudiar las condiciones de invertibilidad, expresamos el proceso en función del operador retardo:

$$Y_t = 5 + (1 - 0.8B + 0.25B^2)\varepsilon_t.$$

Las raíces del polinomio característico $1 - 0.8B + 0.25B^2$ son:

$$\begin{aligned} B &= \frac{0.8 \pm \sqrt{0.8^2 - 4 \cdot 0.25}}{2 \cdot 0.25} = \frac{0.8 \pm \sqrt{0.64 - 1}}{0.5} \\ &= \frac{0.8 \pm \sqrt{-0.36}}{0.5} = \frac{0.8 \pm 0.6i}{0.5} = 1.6 \pm 1.2i, \end{aligned}$$

donde $i = \sqrt{-1}$. Al ser las raíces complejas, se debe comprobar si el módulo¹ de las raíces es mayor que uno:

$$|B| = \sqrt{1.6^2 + 1.2^2} = 2 > 1.$$

Por tanto, el proceso es invertible.

2. La media del proceso es igual a δ , es decir, $E[Y_t] = 5$.

De la expresión (30.23) se tiene que la varianza del proceso verifica:

$$\gamma_0 = (1 + (-0.8)^2 + 0.25^2) \cdot 2 = 3.405.$$

3. De la expresión de la FAC para un proceso $MA(2)$ se tiene que:

$$\rho_0 = 1, \quad \rho_1 = \frac{\theta_1(\theta_2 + 1)}{1 + \theta_1^2 + \theta_2^2} = \frac{(-0.8)(0.25 + 1)}{(1 + (-0.8)^2 + 0.25^2)} = -0.5874.$$

$$\rho_2 = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2} = \frac{0.25}{(1 + (-0.8)^2 + 0.25^2)} = 0.1468,$$

$$\rho_k = \frac{0}{\gamma_0} = 0, \quad \forall k \geq 3.$$

4. De las expresiones de los coeficientes de la FACP para un proceso $MA(2)$ se tiene que:

$$\rho_1^p = \rho_1 = -0.5874, \quad \rho_2^p = \frac{\begin{vmatrix} 1 & -0.5874 \\ -0.5874 & 0.1468 \end{vmatrix}}{\begin{vmatrix} 1 & -0.5874 \\ -0.5874 & 1 \end{vmatrix}} = -0.3027.$$

5. Despejando de la expresión del proceso se tiene que:

$$(1 - 0.8B + 0.25B^2)^{-1}(Y_t - 5) = \varepsilon_t,$$

¹Dado un número complejo de la forma $z = a \pm b \cdot i$, su módulo corresponde a $|z| = \sqrt{a^2 + b^2}$.

y de las propiedades de los polinomios se sabe que el inverso de un polinomio es un polinomio infinito, es decir:

$$(1 + \psi_1 B + \psi_2 B^2 + \dots)(Y_t - 5) = \varepsilon_t, \quad (30.24)$$

donde:

$$\begin{aligned} (1 - 0.8B + 0.25B^2)^{-1} &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ 1 &= (1 - 0.8B + 0.25B^2)(1 + \psi_1 B + \psi_2 B^2 + \dots) \\ 1 &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ &\quad - 0.8B - 0.8\psi_1 B^2 - 0.8\psi_2 B^3 - \dots \\ &\quad + 0.25B^2 + 0.25\psi_1 B^3 + 0.25\psi_2 B^4 + \dots \\ 1 + 0B + 0B^2 + \dots &= 1 + (\psi_1 - 0.8)B + (\psi_2 - 0.8\psi_1 + 0.25)B^2 + \\ &\quad (\psi_3 - 0.8\psi_2 + 0.25\psi_1)B^3 + \dots \end{aligned}$$

Igualando términos que acompañan a B , B^2 ,... se tiene que:

$$\begin{aligned} B: \quad 0 &= \psi_1 - 0.8 \Rightarrow \psi_1 = 0.8. \\ B^2: \quad 0 &= \psi_2 - 0.8\psi_1 + 0.25 \Rightarrow \psi_2 = -0.25 + 0.8\psi_1 \\ &= -0.25 + 0.8^2 = 0.3. \\ B^3: \quad 0 &= \psi_3 - 0.8\psi_2 + 0.25\psi_1 \Rightarrow \psi_3 = 0.8 \times 0.89 - 0.25 \times 0.8 = 0.112. \\ &\dots \end{aligned}$$

Sustituyendo estos parámetros en la ecuación (30.24) se obtiene la expresión del proceso como un $AR(\infty)$:

$$(1 + 0.8B + 0.39B^2 + 0.112B^3 + \dots)(Y_t - 5) = \varepsilon_t.$$

De forma equivalente:

$$\begin{aligned} Y_t &= (1 + 0.8 + 0.39 + 0.112 + \dots) \cdot 5 - \\ &\quad 0.8Y_{t-1} - 0.39Y_{t-2} - 0.112Y_{t-3} + \dots + \varepsilon_t. \end{aligned}$$

3. Procesos autorregresivos y de medias móviles

Una extensión natural de los modelos $AR(p)$ y $MA(q)$ es un tipo de modelos que incluyen tanto términos autorregresivos como de medias móviles y que se denotan como $ARMA(p, q)$.

Se dice que un proceso $\{Y_t\}$ admite una representación autorregresiva y de medias móviles de orden p, q respectivamente, si se puede modelizar a través de la ecuación:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}.$$

Este modelo se puede escribir en términos del operador de retardos:

$$\begin{aligned} Y_t - \phi_1 Y_{t-1} - \phi_2 Y_{t-2} - \dots - \phi_p Y_{t-p} &= \delta + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \\ (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) Y_t &= \delta + (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q) \varepsilon_t, \\ \phi_p(B) Y_t &= \theta_q(B) \varepsilon_t. \end{aligned}$$

3. PROCESOS AUTORREGRESIVOS Y DE MEDIAS MÓVILES

donde $\phi_p(B)$ es el polinomio autorregresivo y $\theta_q(B)$ es el polinomio de medias móviles. Se supone que no hay raíces comunes que puedan cancelarse entre los polinomios de la parte AR y de la parte MA .

Teorema 30.1 *Un proceso autorregresivo de medias móviles finito $ARMA(p,q)$ es estacionario si y solo si el módulo de cada una de las raíces del polinomio autorregresivo $\phi_p(B)$ es superior a uno.*

Las condiciones de estacionariedad viene impuesta por la parte autorregresiva, ya que la parte de medias móviles siempre es estacionaria.

Teorema 30.2 *Un proceso autorregresivo y de medias móviles finito $ARMA(p,q)$ es invertible si y solo si el módulo de cada una de las raíces del polinomio de medias móviles $\theta_q(B)$ es superior a uno.*

Las condiciones de invertibilidad viene impuesta por la parte de medias móviles, ya que la parte autorregresiva siempre es invertible.

Resumiendo, un proceso $ARMA(p, q)$ es estacionario si lo es su componente AR y es invertible si lo es su componente MA .

El modelo $ARMA(p, q)$ comparte las características de los modelos $AR(p)$ y $MA(q)$:

- Tiene media y varianza constantes.
- Los primeros q coeficientes de la FAC están dados por la parte MA . A partir del retardo q se producirá un decrecimiento que vendrá dado por la estructura AR .
- Los primeros p coeficientes de la FACP están dados por la parte AR . A partir del retardo p se producirá un decrecimiento que vendrá dado por la estructura MA .

Como ejemplo ilustrativo se obtienen las características del proceso $ARMA(1, 1)$.

3.1. Proceso autorregresivo de medias móviles $ARMA(1, 1)$

Un proceso estocástico $\{Y_t\}$ sigue un modelo autorregresivo de medias móviles de orden $(1,1)$, denotado por $ARMA(1, 1)$, si se puede escribir como:

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1},$$

donde δ, ϕ, θ son constantes y ε_t es ruido blanco.

En la Figura 30.9 se representa un proceso $ARMA(1,1)$ con $\delta = 0$, $\theta = 0.8$, $Y_0 = 1.5$, $\phi = 0.8$, $\varepsilon_0 = -0.0878$ y $\varepsilon_t \sim N(0, 1)$ para $t \geq 1$.

Estacionariedad

Si Y_t es estacionario en media se cumple que $E[Y_{t-i}] = \mu$, $\forall i \geq 0$. Entonces:

$$\begin{aligned} \mu &= E[Y_t] = E[\delta + \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}] = \underbrace{E[\delta]}_{\delta} + \underbrace{E[\phi Y_{t-1}]}_{\phi \mu} + \underbrace{E[\varepsilon_t]}_0 + \underbrace{\theta E[\varepsilon_{t-1}]}_0 \\ &= \delta + \phi E[Y_{t-1}] \Rightarrow \underbrace{E[Y_t]}_{\mu} - \underbrace{\phi E[Y_{t-1}]}_{\phi \mu} = \delta \Rightarrow \mu = \frac{\delta}{1 - \phi}, \end{aligned}$$




Figura 30.9: Proceso ARMA(1,1) con $\theta = 0.8$ y $\phi = 0.8$

y entonces el proceso Y_t tiene media constante y finita si $|\phi| \neq 1$.

Si Y_t es estacionario en varianza se cumple que $Var[Y_{t-i}] = \gamma_0, \forall i \geq 0$. Entonces, teniendo en cuenta que $Cov(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$, y las Proposiciones 30.1 y 30.2:

$$\begin{aligned} \gamma_0 &= Var[Y_t] = Var[\delta + \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}] \\ &= \underbrace{\phi^2 Var[Y_{t-1}]}_{\gamma_0} + \underbrace{Var[\varepsilon_t]}_{\sigma_\varepsilon^2} + \underbrace{\theta^2 Var[\varepsilon_{t-1}]}_{\sigma_\varepsilon^2} + \underbrace{2\phi\theta Cov(Y_{t-1}, \varepsilon_{t-1})}_{\sigma_\varepsilon^2} \\ \Rightarrow \gamma_0 - \phi^2 \gamma_0 &= \sigma_\varepsilon^2 + \theta^2 \sigma_\varepsilon^2 + 2\phi\theta \sigma_\varepsilon^2 \Rightarrow \gamma_0 = \frac{(1 + 2\phi\theta + \theta^2)}{1 - \phi^2} \sigma_\varepsilon^2 \quad (30.25) \end{aligned}$$

Esta expresión es finita y positiva si y solo si $|\phi| < 1$ o, dicho de otra forma, la raíz del polinomio característico de la parte AR , $1 - \phi B$, es mayor que 1 en valor absoluto: $|B| = \frac{1}{|\phi|} > 1$.

A continuación se obtiene la función de autocovarianzas. Para ello se usa la transformación $\tilde{Y}_t = Y_t - E[Y_t]$ del proceso. Dado que:

$$E[Y_t] = \frac{\delta}{1 - \phi} \Rightarrow \delta = E[Y_t](1 - \phi).$$

Sustituyendo esta expresión de δ en la ecuación del modelo se obtiene:

$$\begin{aligned} Y_t &= \delta + \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} = E[Y_t](1 - \phi) + \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1} \\ &= E[Y_t] + \phi(Y_{t-1} - E[Y_t]) + \varepsilon_t + \theta \varepsilon_{t-1}. \end{aligned}$$

Entonces:

$$Y_t - E[Y_t] = \phi(Y_{t-1} - E[Y_t]) + \varepsilon_t + \theta \varepsilon_{t-1}, \quad (30.26)$$

y sustituyendo $\tilde{Y}_t = Y_t - E[Y_t]$ en (30.26), el proceso se expresa de la siguiente forma:

$$\tilde{Y}_t = \phi \tilde{Y}_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}. \quad (30.27)$$

Recuérdese que las propiedades de $\tilde{Y}_t$ se estudiaron en la Proposición 30.3.

A continuación, usando las Proposiciones 30.1 y 30.2, se calcula el coeficiente

3. PROCESOS AUTORREGRESIVOS Y DE MEDIAS MÓVILES

de orden 1 de la función de autocovarianzas:

$$\begin{aligned}
 \gamma_1 &= Cov(Y_t, Y_{t-1}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-1}) = E[\tilde{Y}_t \tilde{Y}_{t-1}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-1}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-1}] = E[(\phi \tilde{Y}_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \tilde{Y}_{t-1}] \\
 &= E[\phi \tilde{Y}_{t-1}^2 + \tilde{Y}_{t-1} \varepsilon_t + \theta \tilde{Y}_{t-1} \varepsilon_{t-1}] \\
 &= \underbrace{\phi E[\tilde{Y}_{t-1}^2]}_{\gamma_0} + \underbrace{E[\tilde{Y}_{t-1} \varepsilon_t]}_0 + \underbrace{\theta E[\tilde{Y}_{t-1} \varepsilon_{t-1}]}_{\sigma_\varepsilon^2} = \phi \gamma_0 + \theta \sigma_\varepsilon^2.
 \end{aligned}$$

Sustituyendo en esta ecuación la expresión de la varianza

$$\gamma_0 = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2} \sigma_\varepsilon^2,$$

se obtiene que:

$$\gamma_1 = \phi \frac{(1 + 2\phi\theta + \theta^2)}{1 - \phi^2} \sigma_\varepsilon^2 + \theta \sigma_\varepsilon^2 = \frac{(\phi + \phi^2\theta + \phi\theta^2 + \theta)}{1 - \phi^2} \sigma_\varepsilon^2.$$

El segundo coeficiente se calcula de la siguiente manera:

$$\begin{aligned}
 \gamma_2 &= Cov(Y_t, Y_{t-2}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-2}) = E[\tilde{Y}_t \tilde{Y}_{t-2}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-2}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-2}] = E[(\phi \tilde{Y}_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \tilde{Y}_{t-2}] \\
 &= E[\phi \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \varepsilon_t \tilde{Y}_{t-2} + \theta \varepsilon_{t-1} \tilde{Y}_{t-2}] \\
 &= \phi \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-2}]}_{\gamma_1} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-2}]}_0 + \underbrace{\theta E[\varepsilon_{t-1} \tilde{Y}_{t-2}]}_0 = \phi \gamma_1,
 \end{aligned}$$

donde se ha usado la Proposición 30.1.

Razonando de forma similar:

$$\begin{aligned}
 \gamma_k &= Cov(Y_t, Y_{t-k}) = Cov(\tilde{Y}_t, \tilde{Y}_{t-k}) = E[\tilde{Y}_t \tilde{Y}_{t-k}] - \underbrace{E[\tilde{Y}_t]}_0 \underbrace{E[\tilde{Y}_{t-k}]}_0 \\
 &= E[\tilde{Y}_t \tilde{Y}_{t-k}] = E[(\phi \tilde{Y}_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}) \tilde{Y}_{t-k}] \\
 &= E[\phi \tilde{Y}_{t-1} \tilde{Y}_{t-k} + \varepsilon_t \tilde{Y}_{t-k} + \theta \varepsilon_{t-1} \tilde{Y}_{t-k}] \\
 &= \phi \underbrace{E[\tilde{Y}_{t-1} \tilde{Y}_{t-k}]}_{\gamma_{k-1}} + \underbrace{E[\varepsilon_t \tilde{Y}_{t-k}]}_0 + \underbrace{\theta E[\varepsilon_{t-1} \tilde{Y}_{t-k}]}_0 = \phi \gamma_{k-1} = \phi^{k-1} \gamma_1, \quad \forall k \geq 2.
 \end{aligned}$$

Resumiendo, la función de autocovarianzas de un proceso $ARMA(1,1)$ verifica:

$$\gamma_0 = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2} \sigma_\varepsilon^2, \quad \gamma_1 = \frac{(\phi + \phi^2\theta + \phi\theta^2 + \theta)}{1 - \phi^2} \sigma_\varepsilon^2, \quad \gamma_k = \phi^{k-1} \gamma_1, \quad \forall k \geq 2,$$

y bajo la condición de que la raíz del polinomio característico de la parte AR es en valor absoluto mayor que uno, la función de autocovarianzas no depende del tiempo, por lo que el proceso es estacionario.




Figura 30.10: FAC y FACP de ARMA(1,1) con $\theta = -0.5$ y $\phi = 0.8$

Función de autocorrelación simple

Bajo la condición de estacionariedad se tiene que $\rho_k = \frac{\gamma_k}{\gamma_0}$, por tanto:

$$\rho_0 = 1, \quad \rho_1 = \frac{\phi + \phi^2\theta + \phi\theta^2 + \theta}{1 + 2\phi\theta + \theta^2}, \quad \rho_k = \phi^{k-1} \cdot \rho_1, \quad \forall k \geq 2.$$

Función de autocorrelación parcial

De la ecuación (30.27) se tiene que:

$$(1 - \phi B)\tilde{Y}_t = (1 + \theta B)\varepsilon_t.$$

Si el proceso ARMA(1,1) es invertible (la raíz del polinomio característico de la parte MA es mayor que 1 en valor absoluto), se puede expresar como:

$$(1 + \theta B)^{-1}(1 - \phi B)\tilde{Y}_t = \varepsilon_t$$

donde $(1 + \theta B)^{-1}$ es un polinomio infinito con sus coeficientes convergentes denotados por $1 + \psi_1 B + \psi_2 B^2 + \dots$. Sustituyendo esta expresión en la ecuación anterior:

$$\begin{aligned} (1 + \psi_1 B + \psi_2 B^2 + \dots)(1 - \phi B)\tilde{Y}_t &= \varepsilon_t, \\ (1 - \phi B + \psi_1 B - \psi_1 \phi B^2 + \psi_2 B^2 - \psi_2 \phi B^3 + \dots)\tilde{Y}_t &= \varepsilon_t, \\ (1 + (\psi_1 - \phi)B + (\psi_2 - \psi_1 \phi)B^2 + (\psi_3 - \psi_2 \phi)B^3 + \dots)\tilde{Y}_t &= \varepsilon_t, \end{aligned}$$

$$\tilde{Y}_t = (\psi_1 - \phi)\tilde{Y}_{t-1} + (\psi_2 - \psi_1 \phi)\tilde{Y}_{t-2} + (\psi_3 - \psi_2 \phi)\tilde{Y}_{t-3} + \dots + \varepsilon_t.$$

Por esta expresión se sabe que el proceso ARMA(1,1), si es invertible, se puede escribir en función de su propio pasado, es decir, todas las variables retardadas tienen influencia directa sobre Y_t . Por tanto, todos los coeficientes de la FACP serán distintos de cero aunque convergerán a cero a medida que las variables se distancien. La expresión de los coeficientes se obtendrá a partir de las ecuaciones (29.1), (29.2) y sus generalizaciones.

En la Figura 30.10 se representa la FAC de un proceso ARMA(1,1) para $\theta = -0.5$ y $\phi = 0.8$.

Resumen

- El primer coeficiente de la FAC depende de los parámetros autorregresivos y de medias móviles, pero a partir del retardo 2, decrece exponencialmente siguiendo la estructura dada por la parte autorregresiva de orden 1.
- La FACP no sigue un patrón definido, pero tendrá un comportamiento convergente a cero.

Ejemplo 30.4 Considere el modelo $Y_t = 0.4Y_{t-1} + \varepsilon_t + 0.8\varepsilon_{t-1}$ donde ε_t es ruido blanco. Sabiendo que $\sigma_\varepsilon^2 = 1$ se pide:

1. Comprobar las condiciones de estacionariedad e invertibilidad.
2. Calcular la media y varianza del proceso.
3. Obtener los coeficientes de orden 1 y 2 de la FAC.
4. Calcular los coeficientes de orden 1 y 2 de la FACP.
5. Hallar la representación $AR(\infty)$ del proceso.

Solución

1. Al ser un proceso $ARMA(1,1)$ se sabe que la estacionariedad depende de la parte AR y la invertibilidad de la parte MA . Para estudiar ambas condiciones se debe expresar el proceso en función del operador retardo:

$$(1 - 0.4B)Y_t = (1 + 0.8B)\varepsilon_t.$$

El proceso es estacionario si la raíz del polinomio característico de la parte AR es, en valor absoluto, mayor que uno. La raíz de la ecuación:

$$1 - 0.4B = 0,$$

es 2.5, cuyo valor absoluto es mayor que uno. Por tanto, el proceso es estacionario.

El proceso es invertible si la raíz del polinomio característico de la parte MA es, en valor absoluto, mayor que uno. La raíz de la ecuación:

$$1 + 0.8B = 0,$$

es -1.25, cuyo valor absoluto es mayor que uno. Por tanto, el proceso es invertible.

2. La media del proceso es igual a $\frac{\delta}{1-\phi}$. Como el proceso no tiene constante, $\delta = 0$, se tiene que $E[Y_t] = 0$.

De la expresión (30.25) se tiene que la varianza del proceso verifica:

$$\gamma_0 = \frac{1 + 2 \cdot 0.4 \cdot 0.8 + 0.8^2}{1 - 0.4^2} \cdot 1 = 2.71.$$

3. De la expresión de la FAC para un proceso ARMA(1,1) se tiene que:

$$\rho_1 = \frac{\phi + \phi^2\theta + \phi\theta^2 + \theta}{1 + 2\phi\theta + \theta^2} = \frac{0.4 + 0.4^2 \cdot 0.8 + 0.4 \cdot 0.8^2 + 0.8}{1 + 2 \cdot 0.4 \cdot 0.8 + 0.8^2} = 0.6947,$$

$$\rho_2 = \phi\rho_1 = 0.4 \cdot 0.6947 = 0.2779.$$

4. De las ecuaciones (29.1) y (29.2) se tiene que:

$$\begin{aligned} \rho_1^p &= \rho_1 = 0.6947, \\ \rho_2^p &= \frac{\begin{vmatrix} 1 & 0.6947 \\ 0.6947 & 0.2779 \end{vmatrix}}{\begin{vmatrix} 1 & 0.6947 \\ 0.6947 & 1 \end{vmatrix}} = -0.3956. \end{aligned}$$

5. Despejando de la expresión del proceso se tiene que:

$$(1 + 0.8B)^{-1}(1 - 0.4B)Y_t = \varepsilon_t,$$

y de las propiedades de los polinomios se sabe que el inverso de un polinomio es un polinomio infinito, es decir,

$$(1 + \psi_1 B + \psi_2 B^2 + \dots)(1 - 0.4B)Y_t = \varepsilon_t, \quad (30.28)$$

donde:

$$\begin{aligned} (1 + 0.8B)^{-1} &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ 1 &= (1 + 0.8B)(1 + \psi_1 B + \psi_2 B^2 + \dots) \\ 1 &= 1 + \psi_1 B + \psi_2 B^2 + \dots \\ &\quad + 0.8B + 0.8\psi_1 B^2 + \\ &\quad + 0.8\psi_2 B^3 + \dots \\ 1 + 0B + 0B^2 + \dots &= 1 + (\psi_1 + 0.8)B + (\psi_2 + 0.8\psi_1)B^2 + \dots \end{aligned}$$

Igualando términos que acompañan a B , B^2 ,... se tiene que:

$$\begin{aligned} B: \quad 0 &= \psi_1 + 0.8 \Rightarrow \psi_1 = -0.8, \\ B^2: \quad 0 &= \psi_2 + 0.8\psi_1 \Rightarrow \psi_2 = -0.8\psi_1 = 0.64. \\ &\dots \end{aligned}$$

Sustituyendo estos parámetros en la ecuación (30.28) se obtiene la expresión del proceso como un AR(∞):

$$\begin{aligned} (1 - 0.8B + 0.64B^2 + \dots)(1 - 0.4B)Y_t &= \varepsilon_t, \\ (1 - 0.8B + 0.64B^2 - 0.4B + 0.24B^2 - 0.256B^3 + \dots)Y_t &= \varepsilon_t, \\ (1 - 1.2B + 0.88B^2 + \dots)Y_t &= \varepsilon_t, \end{aligned}$$

$$Y_t = 1.2Y_{t-1} - 0.88Y_{t-2} + \dots + \varepsilon_t.$$

4. Teorema de Wold

El Teorema de Wold juega un papel crucial en el desarrollo de la metodología ARIMA ya que permite el uso de los procesos presentados a lo largo del capítulo (procesos *AR*, *MA* y *ARMA*) para describir procesos estacionarios.

Teorema 30.3 (Teorema de Wold) *Cualquier proceso estacionario Y_t puede representarse como la suma de dos procesos mutuamente incorrelados:*

$$Y_t = D_t + X_t,$$

donde D_t es un proceso determinista y X_t es un proceso $MA(\infty)$.

Que D_t sea un proceso determinista significa que es perfectamente pronosticable a partir del pasado de Y_t . Sin tener en cuenta la parte determinista, el Teorema de Wold establece que un proceso estacionario puede expresarse como un proceso $MA(\infty)$:

$$Y_t = \varepsilon_t + \varphi_1 \varepsilon_{t-1} + \varphi_2 \varepsilon_{t-2} + \cdots = (1 + \varphi_1 B + \varphi_2 B^2 + \cdots) \varepsilon_t$$

En la práctica no es útil utilizar una expresión con infinitos términos pero, bajo condiciones muy generales, un polinomio infinito se puede representar como el cociente de dos polinomios finitos:

$$Y_t = (1 + \varphi_1 B + \varphi_2 B^2 + \cdots) \varepsilon_t = \frac{\theta(B)}{\phi(B)} \varepsilon_t \Leftrightarrow \phi(B) Y_t = \theta(B) \varepsilon_t.$$

Por tanto, Y_t se puede expresar también como un proceso $ARMA(p, q)$ finito.

Resumiendo, el Teorema de Wold permite que cualquier proceso estacionario sea descrito como un proceso $ARMA(p, q)$ o, por supuesto, como sus casos particulares $AR(p)$ y $MA(q)$.

5. Identificación

Como se vió en la Sección 3.1 del Capítulo 29, la primera etapa en la metodología ARIMA es la identificación. Para realizarla se usan los datos muestrales disponibles, la serie temporal, para intentar encontrar uno o varias ecuaciones que describan el proceso que genera a dicha serie.

Ya se conoce el tipo de modelos que pueden describir a los procesos estacionarios: autorregresivos, de medias móviles y autoregresivos de medias móviles. Ahora se trata de elegir qué tipo de modelo se ajustaría mejor a la serie temporal bajo estudio. Para ello se comparan las características muestrales de la serie con las características teóricas de los modelos. Concretamente se hacen comparaciones sobre las funciones de autocorrelación simple y parcial.

5.1. Estadísticos muestrales

A partir de la Proposición 29.1, el estimador del coeficiente de autocorrelación en el retardo k es:

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0} = \frac{\frac{1}{T-k} \sum_{t=k+1}^T (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y})^2}, \quad k = 1, 2, \dots$$

CAPÍTULO 30. MODELOS UNIVARIANTES LINEALES
ESTACIONARIOS

	FAC	FACP
$AR(p)$	Decrecimiento exponencial y/o sinusoidal amortiguado	Nula para $k > p$
$MA(q)$	Nula para $k > q$	Decrecimiento exponencial y/o sinusoidal amortiguado
$ARMA(p, q)$	Decrecimiento exponencial y/o sinusoidal amortiguado	Decrecimiento exponencial y/o sinusoidal amortiguado

Tabla 30.1: Comportamiento de la FAC y FACP para los procesos AR, MA y ARMA

A partir de estos coeficientes y utilizando las ecuaciones (29.1), (29.2) y sus generalizaciones se pueden obtener los coeficientes de la FACP muestral:

$$\hat{\rho}_1^p = \hat{\rho}_1, \quad \hat{\rho}_2^p = \frac{\begin{vmatrix} 1 & \hat{\rho}_1 \\ \hat{\rho}_1 & \hat{\rho}_2 \end{vmatrix}}{\begin{vmatrix} 1 & \hat{\rho}_1 \\ \hat{\rho}_1 & 1 \end{vmatrix}} = \frac{\hat{\rho}_2 - \hat{\rho}_1^2}{1 - \hat{\rho}_1^2}, \quad \rho_3^p = \frac{\begin{vmatrix} 1 & \hat{\rho}_1 & \hat{\rho}_1 \\ \hat{\rho}_1 & 1 & \hat{\rho}_2 \\ \hat{\rho}_2 & \hat{\rho}_1 & \hat{\rho}_3 \end{vmatrix}}{\begin{vmatrix} 1 & \hat{\rho}_1 & \hat{\rho}_2 \\ \hat{\rho}_1 & 1 & \hat{\rho}_1 \\ \hat{\rho}_2 & \hat{\rho}_1 & 1 \end{vmatrix}},$$

y así sucesivamente.

Una vez que se conocen los estimadores, se trata de identificar similitudes con las funciones de autocorrelación simple y parcial de los modelos teóricos. En la Tabla 30.1 se resume el comportamiento de estas funciones para los tres modelos estudiados (AR , MA y $ARMA$).

Esta parte de la identificación es la más difícil puesto que depende de la intuición y la experiencia de la persona que la lleve a cabo. El primer consejo útil a seguir es intentar apostar por modelos lo más sencillos posible (principio de parsimonia). Las primeras apuestas deberían ser modelos puros AR o MA y despues estudiar los modelos mixtos $ARMA$.

Si la primera decisión es sobre elegir un modelo AR o MA , se debe decidir qué función de autocorrelación muestral, la simple o la parcial, decrece. Si se decide que la que decrece es la FAC muestral se apostaría por un modelo AR y el orden del modelo se decidiría viendo el número de coeficientes no nulos significativos (ver siguiente sección) en los primeros retardos de la FACP muestral. De manera similar, si se decide que la función de autocorrelación muestral que decrece es la parcial, se apostaría por un modelo MA y su orden se decidiría viendo el número de primeros coeficientes significativos de la FAC muestral. Por tanto, para llevar a cabo este estudio se necesitan herramientas que ayuden a decidir si los coeficientes se pueden considerar significativos o no. Estas herramientas son los contrastes de hipótesis.

5.2. Inferencia

Si se ha identificado una estructura AR , la elección de su orden se basa en contrastes de significación sobre los coeficientes de la FACP. Bajo la hipótesis nula de que $\rho_k^p = 0$, la distribución de los estimadores de los coeficientes de la FACP es aproximadamente $\hat{\rho}_k^p \rightarrow N(0, \frac{1}{T})$, por lo que se rechazará la hipótesis nula a un nivel de significación del 5 % si el estimador $\hat{\rho}_k^p$ está fuera del intervalo




Figura 30.11: Correlogramas de las series simuladas

$\pm \frac{2}{\sqrt{T}}$. Si se rechaza esta hipótesis nula para los p primeros coeficientes, se apostaría por describir la serie temporal bajo estudio con un proceso $AR(p)$. Habitualmente, en los programas econométricos suele representarse las cotas $\pm \frac{2}{\sqrt{T}}$ en los correlogramas para decidir de un solo vistazo si se pueden considerar los coeficientes significativos o no.

Si se ha identificado una estructura MA , la elección de su orden se basa en contrastes de significación sobre los coeficientes de la FAC. Bajo la hipótesis nula de que $\rho_k = 0$, la distribución de los estimadores de los coeficientes de la FAC es aproximadamente $\hat{\rho}_k \rightarrow N(0, \frac{1}{T})$, por lo que se rechazará la hipótesis nula a un nivel de significación del 5% si el estimador $\hat{\rho}_k$ está fuera del intervalo $\pm \frac{2}{\sqrt{T}}$. Si esto ocurre para los q primeros coeficientes, la serie bajo estudio se describiría mediante un proceso $MA(q)$.

Ejemplo 30.5 En este ejemplo se van a identificar los procesos que describen a dos series temporales estacionarias simuladas.

En la parte alta de la Figura 30.11 se encuentra el correlograma muestral de la serie 1. Como se ha comentado antes, el primer intento debe ser identificar modelos puros, es decir, AR o MA . Luego, la primera pregunta a contestar es: ¿cuál de los dos gráficos está decreciendo, la FAC o la FACP? Contestar esta pregunta algunas veces es fácil, como en este ejemplo: decrece la FAC, mientras que la FACP se trunca a partir del retardo 1. Otras veces no será fácil decidir cuál de los dos gráficos decrece y para identificar modelos se tendrán en cuenta

CAPÍTULO 30. MODELOS UNIVARIANTES LINEALES ESTACIONARIOS

todas las posibilidades.

Si se decide que la función de autocorrelación que decrece es la FAC, se apostaría por un AR. Una vez que se tiene claro quien decrece (y qué modelo es) hay que decidir el orden. Para ello se mira en el otro gráfico (en nuestro caso el FACP) cuántos de los primeros coeficientes son significativamente distintos de cero. En este caso se tiene que el primero significativo (distinto de cero desde un punto de vista estadístico). Luego la apuesta clara es un AR(1)

En la parte baja de la Figura 30.11 se encuentra el correlograma de otra serie temporal estacionaria simulada. En este caso parece que decrece la FACP, por lo que se apostaría por un proceso MA. Como la FAC solo tiene el primer coeficiente significativo se tendría un MA(1).

CAPÍTULO 31

Modelos univariantes lineales no estacionarios

Las series de datos (económicos) se suelen caracterizar por ser no estacionarias. En tal caso se hacen necesarias transformaciones que induzcan estacionariedad en media y/o varianza en los datos para así poder aplicar la metodología desarrollada en el capítulo anterior. De esta forma se obtienen los modelos autorregresivos y de medias móviles integrados, conocidos como modelos ARIMA.

En este capítulo también se incorpora al estudio de la serie el análisis de sus características estacionales dando lugar a los modelos ARIMA multiplicativos.

Finalmente, se aborda el principal objetivo que persigue el análisis de series temporales: la predicción.

1. Transformaciones que inducen estacionariedad en media y varianza

Una serie temporal es no estacionaria en media cuando tiene tendencia creciente o decreciente, o cambios de nivel. Es decir, una serie no estacionaria no se mueve de forma estable alrededor de una constante. Un ejemplo de serie no estacionaria se presenta en la Figura 31.1. En ella se puede ver la evolución temporal de un paseo aleatorio (AR(1) con $\delta = 0$ y $\phi = 1$) con tendencia decreciente. Otra pista de que la serie no es estacionaria se puede encontrar en la FAC, como puede observarse esta función decrece de forma muy lenta.

A menudo la tendencia puede eliminarse tomando diferencias regulares (ver definición 29.8). Esto es, si Y_t no es estacionaria en media, es posible encontrar $d \in \mathbb{N}$ de forma que $\nabla^d Y_t$ lo sea. En la práctica, a lo sumo es necesario una ($d = 1$) o dos ($d = 2$) diferencias regulares para obtener un comportamiento estable. Cuando se especifica un modelo ARMA(p,q) para la variable $\nabla^d Y_t$ se dice que se tiene un modelo ARIMA(p,d,q) para Y_t .

1. TRANSFORMACIONES QUE INDUCEN ESTACIONARIEDAD EN MEDIA Y VARIANZA




Figura 31.1: Gráfico, FAC y FACP de un paseo aleatorio




Figura 31.2: Gráfico, FAC y FACP de las primeras diferencias

Ejemplo 31.1 El caso más sencillo donde se comprueba la utilidad de esta transformación es sobre el paseo aleatorio: $Y_t = Y_{t-1} + \varepsilon_t$. Dado que $\phi = 1$, se sabe que no es un proceso estacionario pero su primera diferencia:

$$\nabla Y_t \Leftrightarrow Y_t - Y_{t-1} = \varepsilon_t$$

es un ruido blanco y, por tanto, estacionario.

En la Figura 31.2 se encuentra la gráfica, FAC y FACP de las primeras diferencias del paseo aleatorio presentado en la Figura 31.1. Como se puede observar, se mueve de forma estable alrededor de cero y tanto los coeficientes de la FAC como los de la FACP son no significativos (ver Ejemplo 29.2).

Si una serie es no estacionaria en varianza, su variabilidad no es constante a lo largo de todo su recorrido (ver primer gráfico de la figura 31.3). El procedimiento habitual para convertirla en estacionaria consiste en transformar la variable tomando logaritmos y pasar a analizar la variable transformada, $\ln Y_t$, en lugar de la original, Y_t . La transformación logarítmica de la serie de la Figura 31.3 da como resultado una serie cuya variabilidad parece más constante.

Es importante destacar que esta transformación además de inducir estacionariedad en varianza también induce normalidad en los datos en algunos casos.

Si es necesario inducir estacionariedad en media y varianza, primero se aplicarán logaritmos y luego diferencias. Como ejemplo, en la representación gráfica de la izquierda de la Figura 31.4 se aplica en primer lugar logaritmos y después primeras diferencias obteniéndose una serie estacionaria. En la




Figura 31.3: Número de fallecidos desde Enero de 1993 a Diciembre de 2013 y su logaritmo




Figura 31.4: Número de fallecidos desde Enero de 1993 a Diciembre de 2013: orden de las transformaciones

representación gráfica de la derecha se aplica en primer lugar primeras diferencias (siendo algunas de ellas negativas) y después se toman logaritmos. Los valores perdidos corresponden a los logaritmos de los valores negativos.

2. Estacionalidad

Cuando la serie temporal presenta una pauta de comportamiento que se repite con una periodicidad inferior a un año (meses, trimestres, cuatrimestres,...) se dice que la serie presenta estacionalidad. A la periodicidad de los datos se le denota por s ($s = 12$ para meses, $s = 4$ para trimestres, $s = 3$ para cuatrimestres y $s = 2$ para semestres).

Durante la modelización de un proceso ARIMA se debe tener en cuenta el comportamiento estacional ya que si, por ejemplo, se trabaja con datos mensuales, las observaciones cada 12 meses estarán correladas. Por tanto, además de estudiar el comportamiento regular de la serie (relación entre observaciones sucesivas) hay que tener en cuenta la relación lineal existente entre observaciones del mismo mes en años consecutivos (comportamiento estacional).

La identificación y especificación del modelo para la estructura estacional se hace exactamente igual a la descrita hasta ahora, con la novedad de que en la FAC y FACP hay que prestar especial atención a los múltiplos de s : $s, 2s, 3s, 4s, \dots$

A continuación se estudian las características de los procesos estacionales más sencillos, los procesos estacionales puros.

2.1. Proceso estacional autorregresivo

Sea el proceso estacional puro autorregresivo de orden 1 con periodicidad s , $AR(1)_s$:

$$Y_t = \Phi Y_{t-s} + \varepsilon_t \Leftrightarrow (1 - \Phi B^s)Y_t = \varepsilon_t,$$

donde ε_t es ruido blanco.

Al ser un proceso autorregresivo es invertible para cualquier valor de Φ y será estacionario si y solo si las s raíces del polinomio $(1 - \Phi B^s)$ son, en modulo, mayores que la unidad. Suponiendo que el proceso es estacionario, se obtiene:

Media

$$\mu = E[Y_t] = 0, \text{ ya que el modelo no tiene constante.}$$

Varianza

$$\begin{aligned} \gamma_0 &= \text{Var}(Y_t) = E[Y_t^2] = \Phi^2 E[Y_{t-s}^2] + E[\varepsilon_t^2] + 2\Phi E[Y_{t-s}\varepsilon_t] \\ &= \Phi^2 \gamma_0 + \sigma_\varepsilon^2 \Rightarrow \\ \gamma_0 &= \frac{\sigma_\varepsilon^2}{1 - \Phi^2}. \end{aligned}$$

Función de autocovarianzas

Comenzando estudiando qué pasa con los retardos s y los múltiplos de s :

$$\begin{aligned} \gamma_s &= E[Y_t Y_{t-s}] = \Phi E[Y_{t-s} Y_{t-s}] + E[\varepsilon_t Y_{t-s}] = \Phi \gamma_0, \\ \gamma_{2s} &= E[Y_t Y_{t-2s}] = \Phi E[Y_{t-s} Y_{t-2s}] + E[\varepsilon_t Y_{t-2s}] = \\ &= \Phi E[Y_{t-2s} Y_{t-2s}] + E[\varepsilon_{t-s} Y_{t-2s}] = \Phi^2 \gamma_0, \\ \gamma_{js} &= \Phi^j \gamma_0 \end{aligned}$$

Dado que Y_t se relaciona solo con las variables retardadas $Y_{t-s}, Y_{t-2s}, \dots$ para los retardos distintos de s o sus múltiplos se tiene que:

$$\begin{aligned} h \neq s \cdot j, \quad \gamma_h &= E[Y_t Y_{t-h}] = E[(\Phi Y_{t-s} + \varepsilon_t) Y_{t-h}] \\ &= \Phi E[Y_{t-s} Y_{t-h}] + E[\varepsilon_t Y_{t-h}] = 0 \end{aligned}$$

Función de autocorrelación simple

Dado que $\rho_j = \frac{\gamma_j}{\gamma_0}$, la FAC, para $j = 1, 2, 3, \dots$, será:

$$\rho_0 = 1, \quad \rho_h = \Phi^j, \quad h = s \cdot j, \quad \rho_h = 0, \quad h \neq s \cdot j.$$

Función de autocorrelación parcial

Atendiendo a la expresión del modelo $AR(1)_s$ parece claro que la única influencia directa sobre Y_t la tiene Y_{t-s} , luego el único valor no nulo de la FACP será para $j = s$:

$$\rho_s^p = \rho_s = \Phi, \quad \rho_j^p = 0, \quad \forall j \neq s.$$




Figura 31.5: FAC y FACP para un proceso $AR(1)_4$ con $\Phi = 0.8$




Figura 31.6: FAC y FACP para un proceso $AR(1)_4$ con $\Phi = -0.7$

En las Figuras 31.5 y 31.6 se representan la FAC y FACP para un proceso $AR(1)_4$ con $\Phi = 0.8$ y con $\Phi = -0.7$, respectivamente.

Para el proceso $AR(P)_s$:

$$Y_t = \Phi_1 Y_{t-s} + \Phi_2 Y_{t-2s} + \cdots + \Phi_P Y_{t-Ps} + \varepsilon_t,$$

la FAC decrece con valores no nulos en los retardos estacionales, mientras que la FACP será nula excepto para los valores ρ_h^p con $h = s, 2s, \dots, Ps$.

2.2. Comportamiento de medias móviles

Sea el proceso estacional de medias móviles de orden 1 con periodicidad s , $MA(1)_s$:

$$Y_t = \varepsilon_t + \Theta \varepsilon_{t-s} \Leftrightarrow Y_t = (1 + \Theta B^s) \varepsilon_t,$$

donde ε_t es ruido blanco.

Como es un proceso de medias móviles es estacionario. El proceso será invertible si las s raíces del polinomio $(1 + \Theta B^s)$ son, en módulo, mayores que uno. Sus principales características son:

Media

$$\mu = E[Y_t] = 0$$




Figura 31.7: FAC y FACP para un proceso $MA(1)_4$ con $\Phi = 0.8$

Varianza

$$\gamma_0 = \text{Var}(Y_t) = E[Y_t^2] = E[\varepsilon_t^2] + \Theta^2 E[\varepsilon_{t-s}^2] + 2\Theta E[\varepsilon_t \varepsilon_{t-s}] = (1 + \Theta^2)\sigma_\varepsilon^2$$

Función de autocovarianzas

$$\begin{aligned} h \neq s, \quad \gamma_h &= E[Y_t Y_{t-h}] = E[(\varepsilon_t + \Theta \varepsilon_{t-s})(\varepsilon_{t-h} + \Theta \varepsilon_{t-s-h})] \\ &= E[\varepsilon_t \varepsilon_{t-h} + \Theta \varepsilon_t \varepsilon_{t-s-h} + \Theta \varepsilon_{t-s} \varepsilon_{t-h} + \Theta^2 \varepsilon_{t-s} \varepsilon_{t-s-h}] = 0, \\ h = s, \quad \gamma_h &= E[Y_t Y_{t-h}] = E[(\varepsilon_t + \Theta \varepsilon_{t-s})(\varepsilon_{t-h} + \Theta \varepsilon_{t-s-h})] \\ &= E[\varepsilon_t \varepsilon_{t-s} + \Theta \varepsilon_t \varepsilon_{t-2s} + \Theta \varepsilon_{t-s}^2 + \Theta^2 \varepsilon_{t-s} \varepsilon_{t-2s}] = \Theta \sigma_\varepsilon^2. \end{aligned}$$

Función de autocorrelación simple

$$\rho_0 = 1, \quad \rho_h = \frac{\Theta}{1 + \Theta^2}, \quad h = s, \quad \rho_h = 0, \quad h \neq s.$$

Función de autocorrelación parcial

Teniendo en cuenta que el inverso del polinomio $(1 + \Theta B^s)$ es

$$\frac{1}{1 + \Theta B^s} = 1 + \Theta B^s + \Theta^2 B^{2s} + \dots$$

el modelo $MA(1)_s$ puede expresarse como un $AR(\infty)_s$:

$$(1 + \Theta B^s + \Theta^2 B^{2s} + \dots) Y_{t-j} = \varepsilon_t \Leftrightarrow Y_t = -\Theta Y_{t-s} - \Theta^2 Y_{t-2s} - \Theta^3 Y_{t-3s} - \dots + \varepsilon_t,$$

y entonces la FACP será nula excepto para los valores

$$\rho_h^p = -\Theta^j, \quad h = s \cdot j, \quad j = 1, 2, 3, \dots$$

En las Figuras 31.7 y 31.8 se representan la FAC y FACP para un proceso $MA(1)_4$ con $\Phi = 0.8$ y con $\Phi = -0.7$, respectivamente.




Figura 31.8: FAC y FACP para un proceso $MA(1)_4$ con $\Phi = -0.7$

Para el proceso $MA(Q)_s$:

$$Y_t = \varepsilon_t + \Theta_1 \varepsilon_{t-s} + \Theta_2 \varepsilon_{t-2s} + \cdots + \Theta_Q \varepsilon_{t-Qs},$$

la FAC será nula excepto en los retardos estacionales, mientras que la FACP decrece con valores no nulos en los retardos estacionales.

2.3. Proceso estacional autorregresivo y de medias móviles

Sea el proceso estacional autorregresivo y de medias móviles de orden (1,1) y periodicidad s , $ARMA(1,1)_s$:

$$Y_t = \Phi Y_{t-s} + \varepsilon_t + \Theta \varepsilon_{t-s} \Leftrightarrow (1 - \Phi B^s) Y_t = (1 + \Theta B^s) \varepsilon_t,$$

donde ε_t es ruido blanco.

La FAC y FACP son funciones infinitas que decrecen tomando valores no nulos en los retardos estacionales $s, 2s, 3s, \dots$, es decir, son análogas a las de los modelos $ARMA(p,q)$. En estas funciones es posible encontrar en los retardos cercanos a los estacionales coeficientes significativamente distintos de cero. Esto se interpreta como un posible contagio de los coeficientes limítrofes debido a la interacción de la parte regular y la parte estacional.

A la hora de identificar modelos, la identificación de la parte regular se hace mirando los primeros retardos de los correlogramas y la identificación de la parte estacional mirando los retardos estacionales $(s, 2s, \dots)$.

Ejemplo 31.2 En la Figura 31.9 se representan la FAC y FACP de una serie temporal sobre temperaturas mensuales. Atendiendo a la parte regular se podría pensar en un proceso $MA(1)$ (la FAC se corta en el primer retardo y la FACP decrece). Idéntico comportamiento se podría pensar para la parte estacional (múltiplos de 12).

3. Modelos autorregresivos y de medias móviles integrados (ARIMA) multiplicativos

Una serie temporal puede tener una estacionalidad muy persistente, es decir, si se tienen datos mensuales, puede ocurrir que la influencia del pasado sobre

3. MODELOS AUTORREGRESIVOS Y DE MEDIAS MÓVILES INTEGRADOS (ARIMA) MULTIPLICATIVOS




Figura 31.9: FAC y FACP del proceso Temperaturas

el mes de Enero, por ejemplo, se remonte a los meses de Enero de muchos años atrás. Esto significaría que los coeficientes estacionales en las funciones de autocorrelación decrecerían de forma muy lenta. Para eliminar la persistencia estacional fuerte se toman diferencias estacionales: $\nabla_s = 1 - B^s$ donde s es el periodo estacional.

La forma más eficiente de incluir la estacionalidad en los modelos de series temporales es de forma multiplicativa, así un proceso estocástico $\{Y_t\}$ sigue un modelo $ARIMA(p, d, q) \times (P, D, Q)_s$ si responde a la siguiente expresión:

$$\phi(B)\Phi(B^s)\nabla^d\nabla_s^DY_t = \theta(B)\Theta(B^s)\varepsilon_t,$$

donde:

- $\nabla_s = (1 - B^s)$ es la diferencia estacional y D indica el número de diferencias estacionales a realizar para eliminar la estacionalidad persistente. Generalmente D es igual a cero (no es necesario realizar diferencias estacionales) o uno (se realiza solo una diferencia).
- $\nabla = (1 - B)$ es la diferencia regular y d indica el número de diferencias necesarias para convertir el proceso en estacionario. Generalmente, en series económicas, d es menor o igual que dos. El orden en que se apliquen las diferencias regular y estacional es indiferente.
- $\phi(B) = 1 - \phi_1B - \phi_2B^2 - \dots - \phi_pB^p$.
- $\Phi(B^s) = 1 - \Phi_1B^s - \Phi_2B^{2s} - \dots - \Phi_PB^{Ps}$.
- $\theta(B) = 1 + \theta_1B + \theta_2B^2 + \dots + \theta_qB^q$.
- $\Theta(B) = 1 + \Theta_1B^s + \Theta_2B^{2s} + \dots + \Theta_QB^{Qs}$.

Si además se consideran logaritmos para inducir estacionariedad en varianza, el modelo se expresaría de la siguiente manera:

$$\phi(B)\Phi(B^s)\nabla^d\nabla_s^D \ln Y_t = \theta(B)\Theta(B^s)\varepsilon_t.$$

4. Estimación de modelos ARIMA

Tras la identificación y especificación del modelo, el siguiente paso es la estimación de los parámetros del mismo. Con tal objetivo se pueden aplicar distintas técnicas tales como:

- Métodos de los momentos.
- Método de máxima verosimilitud: condicional y exacta (usada por la gran mayoría de paquetes informáticos).
- Estimación no lineal.
- Estimación por Mínimos Cuadrados Ordinarios (cuando el término de error no tenga autocorrelación: modelos AR).

Destacar que la gran mayoría se basa en la normalidad de los datos.

5. Predicción puntual en modelos ARIMA

Como se avanzó al inicio del Capítulo 29, el principal objetivo al trabajar con series temporales es predecir los valores futuros contando con la información proporcionada por las observaciones disponibles, $t = 1, \dots, T$. Para simplificar la exposición, durante toda la sección se supone que $Y_1, \dots, Y_T$ y $\varepsilon_1, \dots, \varepsilon_T$ son conocidas.

Denotando por $\hat{Y}_T(k)$ al predictor de Y_{T+k} suponiendo que se tiene información hasta el periodo T ($Y_1, \dots, Y_T, \varepsilon_1, \dots, \varepsilon_T$ son conocidas). A k se le denomina horizonte de predicción. Se puede demostrar que el predictor que minimiza el error cuadrático medio de predicción $E_T[(Y_{T+k} - \hat{Y}_T(k))^2]$ es la esperanza de la variable Y_{T+k} condicionada a la información disponible:

$$\hat{Y}_T(k) = E[Y_{T+k}/Y_1, \dots, Y_T] \equiv E_T[Y_{T+k}].$$

Adviértase que:

- $E_T[Y_{T+s}] = Y_{T+s}$ para $s \leq 0$ ya que estos valores han sido observados.
- $E_T[Y_{T+s}] = \hat{Y}_T(s)$ para $s > 0$.
- $E_T[\varepsilon_{T+s}] = \varepsilon_{T+s}$ para $s \leq 0$ ya que estos valores son conocidos.
- $E_T[\varepsilon_{T+s}] = 0$ para $s > 0$ por ser ε_t ruido blanco.

Como ejemplos, a continuación, se obtiene la expresión de los predictores puntuales para varios modelos.

5.1. Procesos autorregresivos

Sea el proceso $AR(1)$: $Y_t = \delta + \phi Y_{t-1} + \varepsilon_t$. La expresión del predictor para los distintos horizontes es:

$$\begin{aligned}
 k = 1 : \hat{Y}_T(1) &= E_T[Y_{T+1}] = E_T[\delta + \phi Y_T + \varepsilon_{T+1}] = \delta + \phi Y_T. \\
 k = 2 : \hat{Y}_T(2) &= E_T[Y_{T+2}] = E_T[\delta + \phi Y_{T+1} + \varepsilon_{T+2}] = \delta + \phi E_T[Y_{T+1}] \\
 &= \delta + \phi \hat{Y}_T(1) = \delta + \phi(\delta + \phi Y_T) = \delta(1 + \phi) + \phi^2 Y_T. \\
 k = 3 : \hat{Y}_T(3) &= E_T[Y_{T+3}] = E_T[\delta + \phi Y_{T+2} + \varepsilon_{T+3}] = \delta + \phi E_T[Y_{T+2}] \\
 &= \delta + \phi \hat{Y}_T(2) = \delta + \phi(\delta(1 + \phi) + \phi^2 Y_T) \\
 &= \delta(1 + \phi + \phi^2) + \phi^3 Y_T \\
 k \geq 4 : \hat{Y}_T(k) &= \delta + \phi \hat{Y}_T(k-1) = \delta(1 + \phi + \phi^2 + \dots + \phi^{k-1}) + \phi^k Y_T.
 \end{aligned}$$

Si el proceso es estacionario ($|\phi| < 1$), la media del proceso es $\mu = \frac{\delta}{1-\phi}$ y $1 + \phi + \phi^2 + \dots + \phi^{k-1} = \frac{1-\phi^k}{1-\phi}$, por tanto:

$$\hat{Y}_T(k) = (1 - \phi^k)\mu + \phi^k Y_T.$$

Luego si el proceso es estacionario la predicción es una combinación lineal de la última observación, Y_T , y la media estacionaria del proceso. Según se avanza al futuro (mayor es k), la última observación recibe una ponderación más pequeña ($|\phi| < 1$), por lo que aumenta la incertidumbre con la que se predice. De hecho, para un horizonte de predicción grande (cuando k tiende a infinito), la predicción será la media del proceso.

Sea el proceso $AR(2)$:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t.$$

La expresión del predictor para los distintos horizontes es:

$$\begin{aligned}
 k = 1 : \hat{Y}_T(1) &= E_T[Y_{T+1}] = E_T[\delta + \phi_1 Y_T + \phi_2 Y_{T-1} + \varepsilon_{T+1}] \\
 &= \delta + \phi_1 Y_T + \phi_2 Y_{T-1}. \\
 k = 2 : \hat{Y}_T(2) &= E_T[Y_{T+2}] = E_T[\delta + \phi_1 Y_{T+1} + \phi_2 Y_T + \varepsilon_{T+2}] \\
 &= \delta + \phi_1 E_T[Y_{T+1}] + \phi_2 Y_T = \delta + \phi_1 \hat{Y}_T(1) + \phi_2 Y_T \\
 &= \delta + \phi_1(\delta + \phi_1 Y_T + \phi_2 Y_{T-1}) + \phi_2 Y_T \\
 &= \delta(1 + \phi_1) + (\phi_1^2 + \phi_2)Y_T + \phi_1 \phi_2 Y_{T-1}. \\
 k = 3 : \hat{Y}_T(3) &= E_T[Y_{T+3}] = E_T[\delta + \phi_1 Y_{T+2} + \phi_2 Y_{T+1} + \varepsilon_{T+3}] \\
 &= \delta + \phi_1 E_T[Y_{T+2}] + \phi_2 E_T[Y_{T+1}] = \delta + \phi_1 \hat{Y}_T(2) + \phi_2 \hat{Y}_T(1) \\
 &= \dots \\
 &= \delta(1 + \phi_1 + \phi_2 + \phi_1^2) + \phi_1(\phi_1^2 + 2\phi_2)Y_T + (\phi_1^2 \phi_2 + \phi_2^2)Y_{T-1}.
 \end{aligned}$$

No existe una forma analítica sencilla para generalizar la predicción, sin embargo, se puede apreciar que la predicción para cualquier horizonte (valor de k) depende de los dos últimos valores observados. En un $AR(p)$ dependerá de las últimas p observaciones.

5.2. Procesos de medias móviles

Sea un proceso $MA(1)$:

$$Y_t = \delta + \varepsilon_t + \theta\varepsilon_{t-1}.$$

La expresión del predictor para los distintos horizontes es:

$$\begin{aligned} k = 1 : \hat{Y}_T(1) &= E_T[Y_{T+1}] = E_T[\delta + \varepsilon_{T+1} + \theta\varepsilon_T] = \delta + \theta\varepsilon_T. \\ k = 2 : \hat{Y}_T(2) &= E_T[Y_{T+2}] = E_T[\delta + \varepsilon_{T+2} + \theta\varepsilon_{T+1}] = \delta. \\ k \geq 3 : \hat{Y}_T(k) &= E_T[Y_{T+k}] = E_T[\delta + \varepsilon_{T+k} + \theta\varepsilon_{T+k-1}] = \delta. \end{aligned}$$

Con un $MA(1)$ sólo se puede predecir con un valor distinto a la media de la serie en un período hacia delante.

Sea un proceso $MA(2)$:

$$Y_t = \delta + \varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2}.$$

La expresión del predictor para los distintos horizontes es:

$$\begin{aligned} k = 1 : \hat{Y}_T(1) &= E_T[Y_{T+1}] = E_T[\delta + \varepsilon_{T+1} + \theta_1\varepsilon_T + \theta_2\varepsilon_{T-1}] \\ &= \delta + \theta_1\varepsilon_T + \theta_2\varepsilon_{T-1}. \\ k = 2 : \hat{Y}_T(2) &= E_T[Y_{T+2}] = E_T[\delta + \varepsilon_{T+2} + \theta_1\varepsilon_{T+1} + \theta_2\varepsilon_T] = \delta + \theta_2\varepsilon_T. \\ k = 3 : \hat{Y}_T(3) &= E_T[Y_{T+3}] = E_T[\delta + \varepsilon_{T+3} + \theta_1\varepsilon_{T+2} + \theta_2\varepsilon_{T+1}] = \delta. \\ k \geq 3 : \hat{Y}_T(k) &= E_T[Y_{T+k}] = E_T[\delta + \varepsilon_{T+k} + \theta_1\varepsilon_{T+k-1} + \theta_2\varepsilon_{T+k-2}] = \delta \end{aligned}$$

Con un $MA(2)$ sólo se pueden predecir valores distintos a la media de la serie en uno o dos períodos hacia delante.

En un $MA(q)$ para cualquier horizonte superior a q , la predicción es la media del proceso.

5.3. Procesos autorregresivos y de medias móviles

Sea un proceso $ARMA(1, 1)$:

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1}.$$

La expresión del predictor para los distintos horizontes es:

$$\begin{aligned} k = 1 : \hat{Y}_T(1) &= E_T[Y_{T+1}] = E_T[\delta + \phi Y_T + \varepsilon_{T+1} + \theta\varepsilon_T] = \delta + \phi Y_T + \theta\varepsilon_T. \\ k = 2 : \hat{Y}_T(2) &= E_T[Y_{T+2}] = E_T[\delta + \phi Y_{T+1} + \varepsilon_{T+2} + \theta\varepsilon_{T+1}] \\ &= \delta + \phi E_T[Y_{T+1}] = \delta + \phi \hat{Y}_T(1) = \delta(1 + \phi) + \phi^2 Y_T + \phi\theta\varepsilon_T. \\ k = 3 : \hat{Y}_T(3) &= E_T[Y_{T+3}] = E_T[\delta + \phi Y_{T+2} + \varepsilon_{T+3} + \theta\varepsilon_{T+2}] \\ &= \delta + \phi E_T[Y_{T+2}] = \delta + \phi \hat{Y}_T(2) \\ &= \delta(1 + \phi + \phi^2) + \phi^3 Y_T + \phi^2\theta\varepsilon_T. \\ k \geq 3 : \hat{Y}_T(k) &= E_T[Y_{T+k}] = \delta(1 + \phi + \phi^2 + \dots + \phi^{k-1}) + \phi^k Y_T - \phi^{k-1}\theta\varepsilon_T \\ &= (1 - \phi^k)\mu + \phi^k Y_T + \phi^{k-1}\theta\varepsilon_T. \end{aligned}$$

Si el proceso es estacionario ($|\phi| < 1$), la predicción cuando el horizonte de predicción es muy alto (k tiende a infinito) es igual a la media del proceso.

6. Actualización de predicciones en modelos ARIMA

En esta sección se ve cómo se puede actualizar una predicción cuando se dispone de una nueva observación Y_{T+1} .

De igual manera que en el Capítulo 30 se vió como cualquier proceso ARMA se podía expresar como un $AR(\infty)$ (invertibilidad), cualquier proceso ARIMA se puede expresar como un $MA(\infty)$. Por ejemplo, sea proceso $ARIMA(p, d, q)$:

$$\phi_p(B)\nabla^d Y_t = \theta_q(B)\varepsilon_t.$$

Su expresión como un proceso $MA(\infty)$ se obtiene invirtiendo el polinomio de la parte autorregresiva:

$$Y_t = (\phi_p(B)\nabla^d)^{-1}\theta_q(B)\varepsilon_t.$$

Suponiendo entonces que la representación $MA(\infty)$ del proceso Y_t es:

$$Y_t = \delta + \varepsilon_t + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{t-s},$$

la expresión del predictor a horizonte k es:

$$\hat{Y}_T(k) = E_T[Y_{T+k}] = \delta + E_T[\varepsilon_{T+k}] + \sum_{s=1}^{+\infty} \psi_s E_T[\varepsilon_{T+k-s}] = \delta + \sum_{s=k}^{+\infty} \psi_s \varepsilon_{T+k-s}, \quad (31.1)$$

donde se ha usado que:

$$E_T[\varepsilon_{T+k-s}] = \begin{cases} 0, & \text{si } k-s > 0 \leftrightarrow s < k \\ \varepsilon_{T+k-s}, & \text{si } k-s \leq 0 \leftrightarrow s \geq k \end{cases}.$$

Entonces es inmediato que:

$$\hat{Y}_T(k+1) = E_T[Y_{T+k+1}] = \delta + \sum_{s=k+1}^{+\infty} \psi_s \varepsilon_{T+k+1-s} = \delta + \psi_{k+1}\varepsilon_T + \psi_{k+2}\varepsilon_{T-1} + \dots$$

Suponiendo que se observa Y_{T+1} , el predictor a horizonte k teniendo información hasta el instante $T+1$ es:

$$\begin{aligned} \hat{Y}_{T+1}(k) &= E_{T+1}[Y_{T+1+k}] = E_{T+1} \left[\delta + \varepsilon_{T+1+k} + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{T+1+k-s} \right] \\ &= \delta + \sum_{s=k}^{+\infty} \psi_s \varepsilon_{T+1+k-s} = \delta + \psi_k \varepsilon_{T+1} + \psi_{k+1} \varepsilon_T + \psi_{k+2} \varepsilon_{T-1} + \dots \end{aligned}$$

donde se ha usado que:

$$E_{T+1}[\varepsilon_{T+1+k-s}] = \begin{cases} 0, & \text{si } k-s > 0 \leftrightarrow s < k \\ \varepsilon_{T+1+k-s}, & \text{si } k-s \leq 0 \leftrightarrow s \geq k \end{cases}.$$

Por tanto:

$$\begin{aligned}\hat{Y}_{T+1}(k) - \hat{Y}_T(k+1) &= \delta + \psi_{k+1}\varepsilon_T + \psi_{k+2}\varepsilon_{T-1} + \dots \\ &\quad - \delta - \psi_k\varepsilon_{T+1} - \psi_{k+1}\varepsilon_T - \psi_{k+2}\varepsilon_{T-1} - \dots \\ &= -\psi_k\varepsilon_{T+1}.\end{aligned}\tag{31.2}$$

De la ecuación (31.1) se tiene que:

$$\hat{Y}_T(1) = \delta + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{T+1-s},$$

y de la expresión del proceso Y_t como un $MA(\infty)$ se obtiene:

$$Y_{T+1} = \delta + \varepsilon_{T+1} + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{T+1-s}.$$

Por tanto:

$$Y_{T+1} - \hat{Y}_T(1) = \varepsilon_{T+1}$$

es decir, la diferencia entre la observación del proceso en el instante $T+1$ y su predicción a horizonte 1 coincide con la innovación en el instante $T+1$.

A partir de la ecuación (31.2) se tiene que:

$$\hat{Y}_{T+1} - \hat{Y}_T(k+1) = -\psi_k \left(Y_{T+1} - \hat{Y}_T(1) \right),$$

o equivalentemente:

$$\hat{Y}_{T+1}(k) = \hat{Y}_T(k+1) - \psi_k \left(Y_{T+1} - \hat{Y}_T(1) \right).$$

7. Predicción mediante intervalos de confianza en modelos ARIMA

Para estudiar la calidad de la predicción realizada se analiza el error de predicción, que no es más que la diferencia entre el valor de la variable y la predicción realizada. Así, el error de predicción para el periodo $T+k$ sería:

$$e_T(k) = Y_{T+k} - \hat{Y}_T(k).$$

Además, su varianza ofrece una medida del error cometido. Más concretamente, su raíz cuadrada es usada para construir intervalos de confianza para las predicciones realizadas anteriormente mediante la expresión:

$$\hat{Y}_T(k) \pm 1.96 \sqrt{\text{Var}(e_T(k))},$$

donde se ha supuesto que el ruido blanco es gaussiano y que el intervalo se ha construido con un 95 % de confianza.

Como se verá a continuación, las amplitudes del intervalo de confianza para las sucesivas predicciones de un modelo $AR(p)$ crecen con el aumento de k , mientras que para un modelo $MA(q)$ permanecen constantes a partir de $k = q+1$.

Para la obtención de los errores de predicción obtenidos en los siguientes apartados se ha utilizado las expresiones de los predictores puntuales obtenidos en la Sección 5

7.1. Procesos autorregresivos

Considerando un proceso $AR(1)$:

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t.$$

Error de predicción:

$$\begin{aligned} k = 1 : e_T(1) &= Y_{T+1} - \hat{Y}_T(1) = (\delta + \phi Y_T + \varepsilon_{T+1}) - (\delta + \phi Y_T) = \varepsilon_{T+1}. \\ k = 2 : e_T(2) &= Y_{T+2} - \hat{Y}_T(2) \\ &= (\delta + \phi(\delta + \phi Y_T + \varepsilon_{T+1}) + \varepsilon_{T+2}) - (\delta(1 + \phi) + \phi^2 Y_T) \\ &= \varepsilon_{T+2} + \phi \varepsilon_{T+1}. \\ k > 2 : e_T(k) &= Y_{T+k} - \hat{Y}_T(k) \\ &= \varepsilon_{T+k} + \phi \varepsilon_{T+k-1} + \phi^2 \varepsilon_{T+k-2} + \cdots + \phi^{k-1} \varepsilon_{T+1}. \end{aligned}$$

Varianza del error de predicción:

$$\begin{aligned} k = 1 : Var(e_T(1)) &= \sigma_\varepsilon^2. \\ k = 2 : Var(e_T(2)) &= E[e_T(2)^2] = E[\varepsilon_{T+2}^2 + \phi^2 \varepsilon_{T+1}^2 + 2\phi \varepsilon_{T+2} \varepsilon_{T+1}] \\ &= (1 + \phi^2) \sigma_\varepsilon^2. \\ k > 2 : Var(e_T(k)) &= (1 + \phi^2 + \phi^4 + \cdots + \phi^{2(k-1)}) \sigma_\varepsilon^2 = \frac{1 - \phi^{2k}}{1 - \phi^2} \sigma_\varepsilon^2. \end{aligned}$$

Si el proceso es estacionario, cuando k tiende a infinito la varianza del error de predicción tiende a $\frac{\sigma_\varepsilon^2}{1 - \phi^2}$ que es la varianza de un proceso $AR(1)$.

Considerando un proceso $AR(2)$:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t.$$

Error de predicción:

$$\begin{aligned} k = 1 : e_T(1) &= Y_{T+1} - \hat{Y}_T(1) \\ &= (\delta + \phi_1 Y_T + \phi_2 Y_{T-1} + \varepsilon_{T+1}) - (\delta + \phi_1 Y_T + \phi_2 Y_{T-1}) = \varepsilon_{T+1}. \\ k = 2 : e_T(2) &= Y_{T+2} - \hat{Y}_T(2) \\ &= (\delta + \phi_1(\delta + \phi_1 Y_T + \phi_2 Y_{T-1} + \varepsilon_{T+1}) + \phi_2 Y_T + \varepsilon_{T+2}) - \\ &\quad (\delta(1 + \phi_1) + (\phi_1^2 + \phi_2) Y_T + \phi_1 \phi_2 Y_{T-1}) \\ &= \varepsilon_{T+2} + \phi_1 \varepsilon_{T+1}. \\ k = 3 : e_T(3) &= Y_{T+3} - \hat{Y}_T(3) = \cdots = \varepsilon_{T+3} + \phi_1 \varepsilon_{T+2} + (\phi_1^2 + \phi_2) \varepsilon_{T+1}. \end{aligned}$$

Varianza del error de predicción:

$$\begin{aligned} k = 1 : Var(e_T(1)) &= \sigma_\varepsilon^2. \\ k = 2 : Var(e_T(2)) &= (1 + \phi_1^2) \sigma_\varepsilon^2. \\ k = 3 : Var(e_T(3)) &= E[e_T(3)^2] = E[\varepsilon_{T+3}^2] + \phi_1^2 E[\varepsilon_{T+2}^2] + (\phi_1^2 + \phi_2)^2 E[\varepsilon_{T+1}^2] \\ &= (1 + \phi_1^2 + (\phi_1^2 + \phi_2)^2) \sigma_\varepsilon^2. \end{aligned}$$

7.2. Procesos de medias móviles

Considerando un proceso $MA(1)$:

$$Y_t = \delta + \varepsilon_t + \theta\varepsilon_{t-1}.$$

Error de predicción:

$$\begin{aligned} k = 1 : e_T(1) &= Y_{T+1} - \hat{Y}_T(1) = (\delta + \varepsilon_{T+1} + \theta\varepsilon_T) - (\delta + \theta\varepsilon_T) = \varepsilon_{T+1}. \\ k = 2 : e_T(2) &= Y_{T+2} - \hat{Y}_T(2) = (\delta + \varepsilon_{T+2} + \theta\varepsilon_{T+1}) - \delta = \varepsilon_{T+2} + \theta\varepsilon_{T+1}. \\ k > 2 : e_T(k) &= Y_{T+k} - \hat{Y}_T(k) = (\delta + \varepsilon_{T+k} + \theta\varepsilon_{T+k-1}) - \delta \\ &= \varepsilon_{T+k} + \theta\varepsilon_{T+k-1}. \end{aligned}$$

Varianza del error de predicción:

$$\begin{aligned} k = 1 : \text{Var}(e_T(1)) &= \sigma_\varepsilon^2. \\ k = 2 : \text{Var}(e_T(2)) &= E[e_T(2)^2] = E[\varepsilon_{T+2}^2 + \theta^2\varepsilon_{T+1}^2 + 2\theta\varepsilon_{T+1}\varepsilon_{T+2}] \\ &= (1 + \theta^2)\sigma_\varepsilon^2. \\ k > 2 : \text{Var}(e_T(k)) &= E[e_T(k)^2] = E[\varepsilon_{T+k}^2 + \theta^2\varepsilon_{T+k-1}^2 + 2\theta\varepsilon_{T+k-1}\varepsilon_{T+k}] \\ &= (1 + \theta^2)\sigma_\varepsilon^2. \end{aligned}$$

La varianza del error de predicción para $k \geq 2$ es la varianza del proceso $MA(1)$, es decir, alcanza su cota un periodo después de su orden.

Proceso de medias móviles de orden 2:

$$Y_t = \delta + \varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2}.$$

Error de predicción:

$$\begin{aligned} k = 1 : e_T(1) &= Y_{T+1} - \hat{Y}_T(1) \\ &= (\delta + \varepsilon_{T+1} + \theta_1\varepsilon_T + \theta_2\varepsilon_{T-1}) - (\delta + \theta_1\varepsilon_T + \theta_2\varepsilon_{T-2}) = \varepsilon_{T+1}. \\ k = 2 : e_T(2) &= Y_{T+2} - \hat{Y}_T(2) \\ &= (\delta + \varepsilon_{T+2} + \theta_1\varepsilon_{T+1} + \theta_2\varepsilon_T) - (\delta + \theta_2\varepsilon_T) = \varepsilon_{T+2} + \theta_1\varepsilon_{T+1}. \\ k > 2 : e_T(k) &= Y_{T+k} - \hat{Y}_T(k) = (\delta + \varepsilon_{T+k} + \theta_1\varepsilon_{T+k-1} + \theta_2\varepsilon_{T+k-2}) - \delta \\ &= \varepsilon_{T+k} + \theta_1\varepsilon_{T+k-1} + \theta_2\varepsilon_{T+k-2}. \end{aligned}$$

Varianza del error de predicción:

$$\begin{aligned} k = 1 : \text{Var}(e_T(1)) &= \sigma_\varepsilon^2. \\ k = 2 : \text{Var}(e_T(2)) &= E[e_T(2)^2] = E[\varepsilon_{T+2}^2 + \theta_1^2\varepsilon_{T+1}^2 + 2\theta_1\varepsilon_{T+1}\varepsilon_{T+2}] \\ &= (1 + \theta_1^2)\sigma_\varepsilon^2. \\ k > 2 : \text{Var}(e_T(k)) &= E[e_T(k)^2] = E[\varepsilon_{T+k}^2] + \theta_1^2E[\varepsilon_{T+k-1}^2] + \theta_2^2E[\varepsilon_{T+k-2}^2] \\ &= (1 + \theta_1^2 + \theta_2^2)\sigma_\varepsilon^2. \end{aligned}$$

7.3. Procesos autorregresivos y de medias móviles

Considerando el proceso $ARMA(1,1)$:

$$Y_t = \delta + \phi Y_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1}.$$

Error de predicción:

$$\begin{aligned}
 k = 1 : e_T(1) &= Y_{T+1} - \hat{Y}_T(1) \\
 &= (\delta + \phi Y_T + \varepsilon_{T+1} + \theta \varepsilon_T) - (\delta + \phi y_T + \theta \varepsilon_T) = \varepsilon_{T+1}. \\
 k = 2 : e_T(2) &= Y_{T+2} - \hat{Y}_T(2) \\
 &= (\delta + \phi Y_{T+1} + \varepsilon_{T+2} + \theta \varepsilon_{T+1}) - (\delta(1 + \phi) + \phi^2 Y_T + \phi \theta \varepsilon_T) \\
 &= \dots = \varepsilon_{T+2} - (\phi + \theta) \varepsilon_{T+1}. \\
 k = 3 : e_T(3) &= Y_{T+3} - \hat{Y}_T(3) \\
 &= (\delta + \phi Y_{T+2} + \varepsilon_{T+3} + \theta \varepsilon_{T+2}) - (\delta(1 + \phi + \phi^2) + \phi^3 Y_T + \phi^2 \theta \varepsilon_T) \\
 &= \dots = \varepsilon_{T+3} + (\phi + \theta) \varepsilon_{T+2} + \phi(\phi + \theta) \varepsilon_{T+1}.
 \end{aligned}$$

Varianza del error de predicción:

$$\begin{aligned}
 k = 1 : Var(e_T(1)) &= \sigma_\varepsilon^2. \\
 k = 2 : Var(e_T(2)) &= E[\varepsilon_{T+2}^2 + (\phi - \theta)^2 \varepsilon_{T+1}^2 - 2(\phi + \theta) \varepsilon_{T+1} \varepsilon_{T+2}] \\
 &= (1 + (\phi + \theta)^2) \sigma_\varepsilon^2. \\
 k = 3 : Var(e_T(3)) &= E[\varepsilon_{T+3}^2 + (\phi - \theta)^2 E[\varepsilon_{T+2}^2] + \phi^2 (\phi + \theta)^2 E[\varepsilon_{T+1}^2]] \\
 &= (1 + (\phi + \theta)^2 (1 + \phi^2)) \sigma_\varepsilon^2.
 \end{aligned}$$

7.4. Cálculo de la varianza del error de predicción en cualquier proceso ARIMA

Como se ha puesto de manifiesto, calcular la varianza del error de predicción en un proceso MA es relativamente sencillo. Puesto que se puede obtener la representación $MA(+\infty)$ de todo proceso ARIMA, dicha operación se puede usar para calcular los intervalos de confianza para la predicción de cualquier proceso.

Así, tal y como se muestra en la Subsección 6 del presente Capítulo, para un proceso $MA(+\infty)$ dado por $Y_t = \delta + \varepsilon_t + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{t-s}$ se verifica la expresión (31.1). En tal caso:

$$\begin{aligned}
 e_T(k) &= Y_{T+k} - \hat{Y}_T(k) = \delta + \varepsilon_{T+k} + \sum_{s=1}^{+\infty} \psi_s \varepsilon_{T+k-s} - \delta - \sum_{s=k}^{+\infty} \psi_s \varepsilon_{T+k-s} \\
 &= \varepsilon_{T+k} + \sum_{s=1}^{k-1} \psi_s \varepsilon_{T+k-s}.
 \end{aligned}$$

Entonces $Var(e_T(k)) = (1 + \psi_1^2 + \dots + \psi_{k-1}^2) \sigma_\varepsilon^2$ y, por tanto, el intervalo de confianza al 95 % para la predicción en un proceso ARIMA estacionario corresponde a:

$$\hat{Y}_T(k) \pm 1.96 \sqrt{Var(e_T(k))},$$

donde $Var(e_T(k)) = (1 + \psi_1^2 + \dots + \psi_{k-1}^2) \sigma_\varepsilon^2$ siendo $\psi_1, \dots, \psi_{k-1}$ los primeros $k - 1$ coeficientes de la representación $MA(+\infty)$ de dicho proceso.




Figura 31.10: Ciclo de identificación, estimación y diagnóstico de series temporales

8. Diagnóstico de modelos

Tras estimar una serie temporal mediante un modelo ARIMA hay que llevar un análisis de los coeficientes y residuos del mismo para comprobar su validez. También es interesante reestimar el modelo ya identificado suprimiendo las últimas observaciones, dejando éstas para predecirlas y evaluar así la capacidad predictiva del modelo (si el modelo es adecuado, las predicciones han de ser fiables).

Si se detectan indicios de una mala especificación se hace necesario reidentificar el modelo, volver a estimarlo y diagnosticarlo (ver Figura 31.10).

8.1. Diagnóstico sobre los parámetros

- Los parámetros estimados han de ser estadísticamente distintos de cero.
- Los parámetros estimados han de verificar las condiciones de estacionariedad y/o invertibilidad, es decir, las raíces de los polinomios característicos han de ser, en módulo, mayores que la unidad.
- Sobreparametrización: en un modelo adecuado no deben existir factores en la parte AR ni en la parte MA susceptibles de cancelarse. Por ejemplo,

$$(1 - 1.2B + 0.35B^2)\nabla Y_t = (1 - 0.7B)\epsilon_t$$

$$(1 - 0.7B)(1 - 0.5B)\nabla Y_t = (1 - 0.7B)\epsilon_t.$$

- Si se sobrediferencia (se diferencia la serie más veces de las necesarias), también se sobreparametriza el modelo. Así, si la parte MA no es invertible podría indicar que se ha sobrediferenciado y que el modelo correcto es más sencillo.
- Principio de parsimonia: el modelo ha de tener el mínimo número de parámetros posible.

8.2. Diagnosis sobre los residuos

Los residuos resultantes deben comportarse como un proceso de ruido blanco. Esta verificación es crucial ya que toda la metodología (identificación, estimación y predicción) está basada en dicho supuesto.

- La serie de los residuos ha de ser estacionaria en media y en varianza. Así, por ejemplo, si los residuos tienen tendencia (creciente o decreciente) habría que diferenciar alguna vez más. Si no es estacionaria en varianza, habría que replantearse una transformación de Box-Cox:

$$Y_t^{(\lambda)} = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln Y_t, & \lambda = 0 \end{cases}.$$

- Las FAC y FACP de los residuos no deben presentar ninguna estructura, es decir, los coeficientes han de ser estadísticamente cero. Si a partir de estas funciones se observa que los residuos presentan estructura autorregresiva habría que reespecificar el modelo teniéndolo en cuenta, igual si presenta una estructura de medias móviles.
- Usar los estadísticos de Ljung-Box o Box-Pierce para contrastar la hipótesis nula de que los residuos del modelo son ruido blanco. Más concretamente, su objetivo es el de contrastar si existe dependencia entre los m primeros residuos estimados, es decir, si estos residuos presentan correlación no nula:

$$\left. \begin{array}{l} H_0 : \text{los primeros } m \text{ coeficientes de autocorrelación} \\ \text{son conjuntamente cero} \\ H_1 : \text{existe algún coeficiente de autocorrelación no nulo} \end{array} \right\}.$$

En el caso del contraste de Ljung-Box se rechaza la hipótesis nula si

$$Q_{exp} > \chi_{m-p-q}^2(\alpha)$$

siendo p y q los órdenes del proceso ARMA analizado y

$$Q_{exp} = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{N-k}.$$

En el caso del contraste de Box-Pierce se rechaza la hipótesis nula si:

$$Q_{exp} = T \sum_{k=1}^m \hat{\rho}_k^2 > \chi_m^2(\alpha).$$




Figura 31.11: Capacidad predictiva del modelo

8.3. Capacidad predictiva del modelo

Una vez identificado el modelo, los resultados obtenidos pueden ser usados para volver a estimarlo considerando en este caso solo parte de la muestra y realizar predicción para aquellas observaciones no consideradas. De esta forma se pueden comparar las predicciones realizadas con el verdadero valor de la observación y obtener así una medida de la capacidad predictiva del modelo.

Considerando que de las T observaciones disponibles se usan las m primeras para estimar el modelo, algunos de los estadísticos básicos que pueden usarse con tal objetivo son:

Error Absoluto Medio (EAM):
$$EAM = \frac{1}{T-m} \cdot \sum_{t=T-m+1}^T |Y_t - \hat{Y}_t|.$$

Error Cuadrático Medio (ECM):
$$ECM = \frac{1}{T-m} \cdot \sum_{t=T-m+1}^T (Y_t - \hat{Y}_t)^2.$$

Valores del EAM o ECM próximos a cero son indicativos de una buena capacidad predictiva.

Para obtener una idea gráfica sobre la capacidad predictiva del modelo, pueden representarse los verdaderos valores de la serie temporal (eje horizontal) y las predicciones correspondientes (eje vertical) de forma que en caso de coincidir la nube de puntos debería quedar sobre la bisectriz del primer y/o tercer cuadrante. Ver, a modo de ejemplo, la Figura 31.11.

8.4. Selección de modelos

Tras la diagnosis es posible que se consideren válidos más de un modelo para una misma serie temporal. En tal caso, se hace necesaria una herramienta que permita seleccionar uno de ellos como el más idóneo. Para ello se recurre a los criterios de selección de modelos: criterios de información de Akaike (AIC), el bayesiano de Schwarz (BIC) y el de Hannan-Quinn (HQC).

Teniendo en cuenta que la verosimilitud de un modelo viene dada por

$$\mathfrak{L} = -\frac{T}{2} \cdot (1 + \ln(2 \cdot \pi) - \ln(T)) - \frac{T}{2} \cdot \ln(SCR)$$

donde T es el número de observaciones disponibles y SCR es la suma de cuadrados de los residuos, los criterios de información se definen como:

- Criterio de Akaike: $AIC = -2 \cdot \mathfrak{L} + 2 \cdot p$.
- Criterio de Schwarz: $BIC = -2 \cdot \mathfrak{L} + p \cdot \ln(T)$.
- Criterio de Hannan-Quinn: $HQC = -2 \cdot \mathfrak{L} + 2 \cdot p \cdot \ln(\ln(T))$.

donde p es el número de parámetros que tiene el modelo y que actúa como un factor de penalización. Como se puede observar, un modelo más complejo (con más parámetros) reducirá la suma de cuadrados de los residuos pero aumentará el factor de penalización.

Utilizando estos criterios se escogería aquel modelo con un menor valor de AIC, BIC o HQC.

CAPÍTULO 32

Modelos de volatilidad estocástica

1. Introducción

Como se ha estudiado en capítulos anteriores, dentro de la metodología de Box y Jenkins se asume que la varianza del ruido blanco de la serie temporal es constante, implicando que la varianza del proceso también lo sea. Sin embargo, la volatilidad es una característica inherente a algunas series temporales económicas con perfil (fundamentalmente) financiero¹ que muestran cambios en la varianza de la serie haciendo que no permanezca constante. En consecuencia, los modelos de series de tiempo tradicionales que suponen varianza homocedástica no son adecuados para modelar estas series temporales.

La volatilidad puede entenderse como las variaciones bruscas que pueden encontrarse en una serie de tiempo. Es decir, aunque en el largo plazo la serie sea estacionaria y tenga, por tanto, varianza constante, puede presentar oscilaciones a corto plazo donde cada periodo esté influenciado por los inmediatamente anteriores, que es lo que recoge la varianza condicional para el estudio de predicciones a corto plazo. Así por ejemplo, en la Figura 32.1 se observa que la serie original no es estacionaria y, por tanto, se transforma la serie aplicando logaritmos y primeras diferencias, obteniendo la segunda representación. En ella se puede observar distintos periodos de volatilidad.

Con el modelo transformado, como se ha comentado, el ruido de estos modelos a largo plazo verifican tener la varianza constante y la varianza a corto plazo condicionada a los valores pasados de la serie. Por tanto, un buen modelo para abordar la volatilidad debe reflejar:

- Puesto que la volatilidad tiene tendencia a aparecer agrupada por periodos, a grandes cambios siguen cambios grandes y a pequeños cambios siguen cambios pequeños.

¹La Real Academia Española (<http://www.rae.es/>) define el concepto de volatilidad referido a la Economía como “inestabilidad de los precios en los mercados financieros”. Puesto que las series de finanzas se caracterizan por observarse con una alta frecuencia (normalmente diaria), este fenómeno suele aparecer en series con esta característica aunque no tengan el perfil estrictamente financiero.

2. MODELO AUTORREGRESIVO CONDICIONALMENTE HETEROCEDÁSTICO: ARCH




Figura 32.1: Observaciones de la bolsa de Nueva York cada 5 días (izquierda) y sus primeras diferencias

- A un periodo de alta/baja volatilidad, eventualmente, le sigue otro de volatilidad normal. Es decir, existe un nivel normal de volatilidad al cual ésta retorna eventualmente.
- El comportamiento de la serie transformada es asimétrico, es decir, no se responde igual a los cambios grandes que a los pequeños.

Estas características muestran la existencia de regularidades en el comportamiento que posibilitan la detección de la volatilidad y, por tanto, su modelización. Estos modelos reciben el nombre de procesos con varianza condicionalmente heterocedástica (modelos ARCH). En 1982, Engle [?] introduce este tipo de modelos presuponiendo que la varianza condicional (no constante) depende de sus valores pasados siguiendo una estructura autorregresiva. Posteriormente en 1986, Bollerslev [?] generaliza dichos modelos incorporando estructura de media móvil a la varianza condicional dando lugar a los modelos GARCH.

2. Modelo autorregresivo condicionalmente heterocedástico: ARCH

2.1. Modelo ARCH(1)

En los procesos con varianza condicionalmente heterocedástica se considera que la varianza condicionada del ruido de un modelo ARMA² está condicionada por los valores pasados:

$$E[\varepsilon_t^2 / \varepsilon_{t-1}, \dots] \equiv E_{t-1}[\varepsilon_t^2],$$

no siendo ésta constante pues depende en cada instante t de los valores pasados en $t-1, t-2, \dots$

Si se considera el caso más sencillo, donde se depende de un único valor pasado, se tiene que:

$$\varepsilon_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + v_t,$$

donde v_t es ruido blanco. Ahora bien, la relación lineal no tiene un tratamiento algebraico cómodo, siendo más manejable especificar el ruido de forma multiplicativa.

²Para simplificar se considerará que ε es el ruido de un proceso ARMA, si bien se podría considerar que lo es de modelos ARIMA multiplicativos donde la serie original puede o no estar transformada por logaritmos y por diferencias regulares o estacionales.

Definición 32.1 (Proceso ARCH(1)) Se dice que $\{\varepsilon_t\}$ sigue un proceso autorregresivo condicionalmente heterocedástico de orden 1, ARCH(1), si:

$$\varepsilon_t = v_t \sqrt{\alpha_0 + \alpha_1 \varepsilon_{t-1}^2} \Leftrightarrow \varepsilon_t^2 = v_t^2 (\alpha_0 + \alpha_1 \varepsilon_{t-1}^2),$$

donde v_t es ruido blanco con varianza igual a 1 e independiente de ε_{t-1} .

Llamando $h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$ en la definición anterior y teniendo en cuenta que v_t tiene media 0, varianza 1 y es independiente de ε_{t-1} (esperanza del producto es igual al producto de las esperanzas), se deduce que:

- La media marginal (o no condicionada) y la media condicionada (a los valores pasados de la serie) son cero:

$$\begin{aligned} E[\varepsilon_t] &= E[v_t \sqrt{h_t}] = \underbrace{E[v_t]}_0 \cdot E[\sqrt{h_t}] = 0, \\ E_{t-1}[\varepsilon_t] &= E_{t-1}[v_t \sqrt{h_t}] = E_{t-1}[v_t] \cdot E_{t-1}[\sqrt{h_t}] \\ &= \underbrace{E[v_t]}_0 \cdot E_{t-1}[\sqrt{h_t}] = 0. \end{aligned}$$

- Teniendo en cuenta que la varianza marginal es estacionaria, se tiene que:

$$E[\varepsilon_t^2] = E[v_t^2 h_t] = \underbrace{E[v_t^2]}_1 \cdot E[h_t] = \alpha_0 + \alpha_1 E[\varepsilon_{t-1}^2] \Rightarrow E[\varepsilon_t^2] = \frac{\alpha_0}{1 - \alpha_1}.$$

Para que la varianza sea positiva se ha de verificar que $\alpha_0 > 0$ y $0 \leq \alpha_1 < 1$.

- La varianza condicional corresponde a una estructura AR(1):

$$\begin{aligned} E_{t-1}[\varepsilon_t^2] &= E_{t-1}[v_t^2 h_t] = E_{t-1}[v_t^2] \cdot E_{t-1}[h_t] = \underbrace{E[v_t^2]}_1 \cdot E_{t-1}[h_t] \\ &= \alpha_0 + \alpha_1 E_{t-1}[\varepsilon_{t-1}^2] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 = h_t. \end{aligned}$$

En tal caso, considerando la expresión $E_{t-1}[\varepsilon_t^2] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 = h_t$ se deducen las características deseables de los modelos con volatilidad:

- Un valor alto/bajo de ε_{t-1}^2 conduce a un valor alto/bajo de la varianza del siguiente valor condicionada a ε_{t-1}^2 , $E_{t-1}[\varepsilon_t^2]$. De esta forma, se hace más probable que el siguiente dato, ε_t^2 , sea también alto/bajo. Luego, fuertes fluctuaciones inesperadas tienden a venir seguidas de períodos de iguales características.
- Por otro lado, como tanto la media marginal como la condicionada son cero, es posible que el valor de ε_t^2 sea pequeño (retorne a su media). De esta forma disminuirá la varianza condicionada de la observación siguiente, de manera que períodos de estabilidad tienden a venir seguidos por períodos igualmente estables.

Sin embargo, debido a que se considera el cuadrado de ε_{t-1} , se estaría tratando de igual forma a los cambios grandes y pequeños, por lo que no estaría recogiendo la asimetría de la volatilidad. Es decir, un proceso ARCH(1) es adecuado para modelar períodos de volatilidad excepto por la característica de asimetría.

2.2. Modelo ARCH(q)

Definición 32.2 (Proceso ARCH(q)) Se dice que $\{\varepsilon_t\}$ sigue un proceso autorregresivo condicionalmente heterocedástico de orden q , $ARCH(q)$, si:

$$\varepsilon_t = v_t \sqrt{h_t},$$

donde $h_t = \alpha_0 + \sum_{k=1}^q \alpha_k \varepsilon_{t-k}^2$ y v_t es ruido blanco con varianza igual a 1 e independiente de $\varepsilon_{t-1}, \dots, \varepsilon_{t-q}$.

De manera análoga a la anterior se obtiene que:

- $E[\varepsilon_t] = 0 = E_{t-1}[\varepsilon_t]$.
- $E[\varepsilon_t^2] = \frac{\alpha_0}{1 - \sum_{k=1}^q \alpha_k}$ de donde se deduce que $\alpha_0, \alpha_1, \dots, \alpha_q \geq 0$ y $\sum_{k=1}^q \alpha_k < 1$.
- $E_{t-1}[\varepsilon_t^2] = \alpha_0 + \sum_{k=1}^q \alpha_k \varepsilon_{t-k}^2 = h_t$ (la varianza condicionada depende de los últimos q valores de ε_{t-1}^2 , luego tiene estructura AR(q)).

3. Modelo condicionalmente heterocedástico generalizado: GARCH

3.1. Modelo GARCH(1,1)

Si el valor q del $ARCH(q)$ es grande, se tiene que estimar un gran número de parámetros, $\alpha_1, \dots, \alpha_q$, con los problemas que esto puede suponer. Para evitarlos, en los capítulos anteriores se ha visto que una alternativa natural para aproximar un proceso autorregresivo de orden alto es considerar la inclusión de medias móviles, es decir, incluir la dependencia de las varianzas condicionadas de retardos suyos.

El caso más sencillo responde a la expresión:

$$E_{t-1}[\varepsilon_t^2] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1},$$

donde a la estructura autorregresiva de orden 1 se le ha añadido otra de medias móviles del mismo orden.

Definición 32.3 (Proceso GARCH(1,1)) Se dice que $\{\varepsilon_t\}$ sigue un proceso autorregresivo condicionalmente heterocedástico generalizado de orden (1,1), $GARCH(1,1)$, si:

$$\varepsilon_t = v_t \sqrt{h_t},$$

donde $h_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1}$ y v_t es ruido blanco con varianza igual a 1 e independiente de ε_{t-1} .

Teniendo en cuenta que v_t tiene media 0, varianza 1 y es independiente de ε_{t-1} , de la definición anterior se deduce que:

- Por idénticos motivos a los expuestos para el ARCH(1) la media marginal y condicionada son cero: $E[\varepsilon_t] = 0 = E_{t-1}[\varepsilon_t]$.

- Teniendo en cuenta que la varianza marginal es estacionaria³ y la ley de esperanzas iteradas⁴ se tiene que:

$$\begin{aligned} E[\varepsilon_t^2] &= E[v_t^2 h_t] = \underbrace{E[v_t^2]}_1 \cdot E[h_t] = \alpha_0 + \alpha_1 E[\varepsilon_{t-1}^2] + \beta_1 E[h_{t-1}] \\ &= \alpha_0 + \alpha_1 E[\varepsilon_{t-1}^2] + \beta_1 E[\varepsilon_{t-1}^2] \Rightarrow E[\varepsilon_t^2] = \frac{\alpha_0}{1 - \alpha_1 - \beta_1}. \end{aligned}$$

Para que la varianza sea positiva se ha de verificar que $\alpha_0, \alpha_1, \beta_1 \geq 0$ y $\alpha_1 + \beta_1 < 1$.

- La varianza condicionada corresponde a una estructura ARMA(1,1):

$$\begin{aligned} E_{t-1}[\varepsilon_t^2] &= E_{t-1}[v_t^2 h_t] = E_{t-1}[v_t^2] \cdot E_{t-1}[h_t] = \alpha_0 + \alpha_1 E_{t-1}[\varepsilon_{t-1}^2] \\ &\quad + \beta_1 E_{t-1}[h_{t-1}] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1} = h_t. \end{aligned}$$

La novedad en este caso radica en la aparición del término de medias móviles que hace que la varianza condicionada, h_t , dependa de un retardo suyo, h_{t-1} . Así, es de esperar que haya rachas de mayor variabilidad que con los modelos ARCH(1) debido al efecto directo de las varianzas condicionadas altas/bajas del instante anterior. En cualquier caso, dicho efecto quedará ponderado por el coeficiente β_1 (que ha de verificar que $\beta_1 < 1 - \alpha_1$).

Por tanto, al igual que antes, considerando que se verifica que $E_{t-1}[\varepsilon_t^2] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1} = h_t$, vuelven a tener sentido los comentarios anteriores que manifestaban la adecuación de los modelos ARCH(1) para analizar modelos con volatilidad excepto por la característica de asimetría. Puesto que este aspecto no es recogido por los modelos ARCH ni GARCH, surgen en la literatura otras variaciones más completas que los modelos estudiados en este capítulo como, por ejemplo, los modelos autorregresivos condicionalmente heterocedásticos generalizados exponenciales, EGARCH.

3.2. Modelo GARCH(p,q)

Definición 32.4 (Proceso GARCH(p,q)) Se dice que $\{\varepsilon_t\}$ sigue un proceso autorregresivo condicionalmente heterocedástico generalizado de orden (p,q), GARCH(p,q), si:

$$\varepsilon_t = v_t \sqrt{h_t},$$

donde $h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j h_{t-j}$ y v_t es ruido blanco con varianza igual a 1 e independiente de $\varepsilon_{t-1}, \dots, \varepsilon_{t-q}$.

De manera análoga a la anterior se obtiene que:

³ $E[\varepsilon_t^2] = E[\varepsilon_{t-1}^2] = E[\varepsilon_{t-2}^2] = \dots$

⁴La ley de esperanzas iteradas establece que $E[E[Y/X]] = E[Y]$. En efecto, en el caso de variables continuas (para variables discretas el desarrollo es análogo) se tiene que:

$$\begin{aligned} E[E[Y/X]] &= \int E[Y/X] f_X(x) dx = \int \left(\int y f_{Y/X}(y/x) dy \right) f_X(x) dx \\ &= \int \int y f_{X,Y}(x, y) dx dy = \int y \left(\int f_{X,Y}(x, y) dx \right) dy = \int y f_Y(y) dy = E[Y]. \end{aligned}$$

En tal caso, es claro que $E[h_{t-1}] = E[E_{t-2}[\varepsilon_{t-1}^2]] = E[E[\varepsilon_{t-1}^2/\varepsilon_{t-2}, \dots]] = E[\varepsilon_{t-1}^2]$.

- $E[\varepsilon_t] = 0 = E_{t-1}[\varepsilon_t]$.
- $E[\varepsilon_t^2] = \frac{\alpha_0}{1 - \sum_{i=1}^q \alpha_i - \sum_{j=1}^p \beta_j}$ de donde se deduce que $\alpha_0, \alpha_1, \dots, \alpha_q \geq 0$,
 $\beta_1, \dots, \beta_q > 0$ y $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$.
- $E_{t-1}[\varepsilon_t^2] = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j h_{t-j} = h_t$ (la varianza condicionada tiene estructura ARMA(p,q)).

4. Construcción de modelos GARCH

4.1. Identificación de modelos GARCH

Como se ha puesto de manifiesto a lo largo del presente capítulo, la modelización de modelos GARCH reside en el comportamiento del cuadrado del ruido. Por tanto, para la identificación de los mismos habrá que basarse en los residuos al cuadrado del modelo de series temporales analizado.

Los pasos a seguir son los siguientes:

- Estimar el proceso estocástico $\{Y_t\}$ con el mejor modelo ARMA posible. En tal caso, dicho proceso es estacionario (media y varianza constantes) y sus residuos deben responder a las características de un ruido blanco.
- Calcular el cuadrado de los errores y representar sus funciones de autocorrelación simple y parcial. La identificación de un patrón ARMA(p,q) para los cuadrados de los residuos sería indicativo de la adecuación de un modelo GARCH(p,q).

Por otro lado, un procedimiento más formal para detectar la presencia de estructura ARCH en los errores es el siguiente:

1. Estimar el proceso estocástico $\{Y_t\}$ con el mejor modelo ARMA posible y obtener el cuadrado de los errores.
2. Realizar una regresión de dichos residuos al cuadrado sobre una constante y q retardos de los mismos: $e_t^2 = \alpha_0 + \alpha_1 e_{t-1}^2 + \dots + \alpha_q e_{t-q}^2 + v_t$.
3. Si no hay un patrón ARCH, los valores estimados de α_i , con $i = 1, \dots, q$, deberían ser estadísticamente cero y el coeficiente de determinación de esta regresión auxiliar, R_{aux}^2 , muy bajo. Así, se rechazaría la hipótesis nula $H_0 : \alpha_1 = \dots = \alpha_q = 0$ si $\chi_{exp}^2 = T \cdot R_{aux}^2 > \chi_q^2(1 - \alpha)$.

En definitiva, si se rechaza la hipótesis nula anterior se podría concluir (al nivel de significación usado) que hay estructura ARCH en los errores.

Ejemplo 32.1 *Realizado el contraste para detectar la presencia de estructura ARCH en los errores del modelo ajustado que tiene por hipótesis nula $H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_q = 0$ se obtiene un coeficiente de determinación para la regresión auxiliar igual a 0.048.*




Figura 32.2: Correlograma de los residuos al cuadrado de los datos de la bolsa de New York

Teniendo en cuenta que $q = 1$ y se disponen de 167 observaciones se tiene que se rechaza la hipótesis nula $H_0 : \alpha_1 = 0$ ya que $\chi_{exp}^2 = 167 \cdot 0.048 = 8.016 > 3.81 = \chi_1^2(0.95)$.

Por tanto, en los errores hay estructura ARCH.

4.2. Estimación y adecuación de modelos GARCH

Recuérdese que un proceso GARCH(p,q) responde a la estructura:

$$\varepsilon_t = v_t \sqrt{h_t} = v_t \sqrt{\alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j h_{t-j}},$$

de forma que se hace necesario obtener una estimación de los coeficientes α_0 , α_i , β_j para $i = 1, \dots, q$ y $j = 1, \dots, p$.

El problema reside en que la varianza de este proceso condicionada a su pasado no es constante, más concretamente, $E_{t-1}[\varepsilon_t^2] = h_t$. Luego, la solución natural consistiría en aplicar mínimos cuadrados generalizados transformando el modelo dividiendo por $\sqrt{h_t}$.

Una práctica habitual es usar la estimación anteriormente comentada para obtener una solución inicial y aplicar a continuación un proceso iterativo donde se obtienen diversas estimaciones por máxima verosimilitud. Dicho proceso se detendría al obtener convergencia. Para más detalles ver, por ejemplo, Peña [?].

Teniendo en cuenta lo comentado anteriormente, los residuos al cuadrado del modelo ARMA ajustado al proceso original dividido entre h_t deben de comportarse como un ruido blanco. Por lo que sus correspondientes funciones de autocorrelación simple y parcial no han de presentar estructura alguna.

Ejemplo 32.2 *Dados los datos diarios del valor al cierre de la bolsa de New York, NY, representados en la Figura 32.1 y tras aplicar la metodología estudiada en los primeros capítulos se establece que un modelo adecuado es un ARIMA (0,1,1) cuya estimación conduce a la expresión:*

$$\nabla \ln NY_t = 0.00035 + (1 + 0.07513B)\varepsilon_t,$$

4. CONSTRUCCIÓN DE MODELOS GARCH

donde se pone de manifiesto que ha sido necesario inducir estacionariedad en varianza y media.

Si se guardan los residuos al cuadrado de este modelo y se representa su correlograma, Figura 32.2, se puede observar claramente una estructura autorregresiva e, incluso, autorregresiva y de medias móviles. Esta idea se confirma al realizar el contraste de estructura ARCH en los residuos considerando 3, 5 ó 7 retardos. En todos los casos se obtienen p-valores inferiores a 0.05 por lo que se rechaza la hipótesis nula de que todos los coeficientes son simultáneamente nulos.

Obtando por una estructura GARCH(1,1) se tiene que la estimación del modelo propuesto sería:

$$\nabla \ln NY_t = 0.00035 + (1 + 0.07513B)\varepsilon_t,$$

donde $\varepsilon_t = v_t \sqrt{h_t}$ con v_t ruido blanco con varianza igual a 1 y con $h_t = 0.000001314 + 0.1176\varepsilon_{t-1}^2 + 0.8787h_{t-1}$.

Parte VII

Ejercicios

CAPÍTULO 33

Ejercicios Álgebra Lineal

Ejercicio 33.1 *Se considera la matriz*

$$A = \begin{pmatrix} 0 & -1 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

Hallar una fórmula para A^n , siendo n un entero positivo.

Ejercicio 33.2 *Dada la matriz*

$$A = I_n - \frac{1}{n} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} (1 \quad 1 \quad \dots \quad 1)$$

probar que:

- *Es simétrica*
- $A^2 = A$
- $\text{tr}(A) = n - 1$

Ejercicio 33.3 *Transforme la matriz A en una matriz escalonada reducida por filas*

$$A = \begin{pmatrix} 2 & 3 & 1 & 4 \\ 3 & 1 & 2 & 0 \\ 1 & 2 & 4 & 1 \end{pmatrix}$$

Ejercicio 33.4 *Resuelva el sistema de ecuaciones*

$$S = \begin{cases} 2x + 2y + 3z = 6 \\ x + 3y + 5z = 1 \\ 5x + 5y + 4z = 6 \end{cases}$$

Ejercicio 33.5 Se considera la matriz

$$A = \begin{pmatrix} 1 & c & c \\ c & 1 & c \\ c & c & 1 \end{pmatrix}$$

Hallar el valor no nulo de c para el cual la matriz A^2 , es diagonal. Con ese valor de c calcular A^{-1}

Ejercicio 33.6 Resuelva el sistema de ecuaciones

$$S = \begin{cases} x - y + z = 6 \\ 2x + y + 3z = 0 \\ x + 2y + 2z = -6 \\ 3x + 4z = 6 \end{cases}$$

Ejercicio 33.7 Discuta y Resuelva el sistema de ecuaciones según los valores del parámetro a :

$$S = \begin{cases} 2x - 5y + 3z = 1 \\ x + 3y - (a-1)z = 0 \\ 3x - ay + 2z = a-1 \end{cases}$$

Ejercicio 33.8 Resuelva la ecuación

$$AX + B = C$$

donde

$$A = \begin{pmatrix} 0 & 1 & 3 \\ 1 & 1 & 0 \\ 2 & 0 & 0 \end{pmatrix} B = \begin{pmatrix} 2 & 1 \\ -1 & 0 \\ 3 & 4 \end{pmatrix} C = \begin{pmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 2 \end{pmatrix}$$

Ejercicio 33.9 Considere la matriz:

$$A = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

Siendo X una matriz columna, discute y, en su caso, resuelve la ecuación matricial

$$AA^t X = \lambda X$$

Según los valores del parámetro real λ

Ejercicio 33.10 La empresa Fulanito S.L. distribuye un producto en tres tipos de envases, A, B, C , cuyos precios y pesos son los que están en esta tabla:
A una tienda se le ha suministrado un pedido de 5 envases con un peso total de 2,5Kg por un importe de 8,9 euros. ¿Cuántos envases de cada tipo ha comprado la tienda?

	Peso	Precio
A	250	1
B	500	1,8
C	1000	3,3

Ejercicio 33.11 Se considera la matriz A

$$A = \begin{pmatrix} 179 & -99 \\ 255 & -139 \end{pmatrix}$$

y su vector propio

$$\vec{v} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$$

¿Cuál será el correspondiente valor propio?

Ejercicio 33.12 Supongamos que tres grupos de inversión que denominaremos A , B y C gestionan ellos mismos la mayor parte de su capital pero diversifican su inversión destinando un porcentaje a alguno de los otros dos grupos.

De un año a otro mantienen fijos los porcentajes de inversión de acuerdo a lo siguiente:

- El grupo A gestiona él mismo un 70 % de sus fondos e invierte un 40 % en B (si sumamos los porcentajes vemos que la inversión total del grupo A es de un $(70+40)\%=110\%$ y, por tanto, cada año, el grupo A recibe un 10 % de beneficios que destina nuevamente a la inversión).
- El grupo B gestiona él mismo un 40 % de sus fondos e invierte un 40 % en A y un 30 % en C .
- El grupo C gestiona él mismo un 70 % de sus fondos e invierte un 40 % en A .

Supongamos que, inicialmente, el capital, en millones de euros, en los grupos A , B y C es 351, 176 y 173, respectivamente.

1. Plantea un modelo matricial que permita calcular el capital en cada grupo en años sucesivos.
2. Calcula el capital en cada grupo pasados 5 años y pasados 10 años.
3. Estudia la tendencia de futuro de este problema, determinando si la cuantía de los capitales será estable, tenderá a crecer o a anularse, y calculando los porcentajes en que se distribuirán los capitales en cada grupo cuando pase un número suficientemente grande de años.

Ejercicio 33.13 Se considera la matriz A cuyos valores propios son $\lambda_1 = -5$ y $\lambda_2 = -7$ y los vectores propios asociados a cada valor propio son: $\vec{v}_1 = (\frac{-2}{3}, 1)$ y $\vec{v}_2 = (\frac{2}{3}, 1)$. Sin calcular A .

- Calcule el determinante de A
- Calcule la matriz inversa de A

Ejercicio 33.14 Sea la matriz

$$A = \begin{pmatrix} 5 & 2 & -2 \\ 2 & 5 & -2 \\ -2 & 2 & 5 \end{pmatrix}$$

- *Calcula sus valores y vectores propios.*
- *Compruebe que la matriz de vectores propios es ortogonal.*

Ejercicio 33.15 Calcule la forma cuadrática de la matriz A

$$A = \begin{pmatrix} 1 & 3 & 6 & 10 & -2 \\ 3 & 7 & 2 & 4 & -1 \\ 6 & 2 & 4 & 1 & 3 \\ 10 & 4 & 1 & -2 & 5 \\ -2 & -1 & 3 & 5 & -2 \end{pmatrix}$$

CAPÍTULO 34

Ejercicios Calculo Diferencial

Ejercicio 34.1 Halla el dominio de definición de las funciones siguientes:

$$y = \frac{x}{x^2 + 1} \quad y = \frac{1}{\sqrt[3]{x^2 - 7x + 10}} \quad \frac{x}{\sqrt{x^2 - 16}}$$

Ejercicio 34.2 Con 200 metros de valla queremos acotar un recinto rectangular aprovechando una pared:

- Construye la función que nos da el área del recinto.

Ejercicio 34.3 Clasifique las siguientes formas cuadráticas:

- $f(x, y, z) = x^2 - y^2 + z^2 - 3xy$
- $f(x, y, z, t) = xt - xy + z^2 - 3xt + y^2 - 2xz$
- $f(x, y) = x^2 + y^2 + 2xy$

Ejercicio 34.4 El precio por establecimiento de llamada en cierta tarifa telefónica es de 0,12 euros. Si hablamos durante 5 minutos, la llamada nos cuesta 0,87 euros en total. Halla la función que nos da el precio total de la llamada según los minutos que estemos hablando

Ejercicio 34.5 Calcula los puntos críticos de la siguiente función y clasifícalos:

$$f(x, y) = (3 - x)(3 - y)(x + y - 3)$$

Ejercicio 34.6 Calcula los puntos críticos de la siguiente función y clasifícalos:

$$f(x, y, z) = xy + yz + xz$$

CAPÍTULO 35

Estadística Descriptiva

1. Variable Estadística Unidimensional

Ejercicio 35.1 *La siguiente distribución de frecuencias recoge los salarios de una muestra de trabajadores en cientos de euros (75 representa 7500 euros).*

Salarios	Trabajadores
0-12	10
12-37	26
37-56	31
56-61	12
61 -75	5

Calcule:

- *El momento no centrado de orden 1 (media aritmética).*
- *El momento no centrado de orden 2.*
- *El momento no centrado de orden 3.*
- *El momento no centrado de orden 4.*
- *El momento centrado de orden 2 (varianza).*
- *El momento centrado de orden 3.*
- *El momento centrado de orden 4.*
- *La Moda (Criterio I, del punto medio): La mayor de todas ellas si hay varias*
- *La Moda (Criterio II): La mayor de todas ellas si hay varias*
- *La Moda (Criterio III): La mayor de todas ellas si hay varias*

1. VARIABLE ESTADÍSTICA UNIDIMENSIONAL

- *La Mediana*
- *El tercer cuartil*
- *Entre qué salarios (en cientos de euros) se encuentra el 50 % central de los individuos*
- *El percentil 37*
- *La desviación típica*
- *El coeficiente de variación.*
- *El coeficiente de asimetría de Fisher*
- *El coeficiente de curtosis de Fisher.*
- *El índice de Gini.*
- *La mediana*
- *El porcentaje de individuos que ganan menos de 2500 euros.*
- *El porcentaje de individuos que ganan más de 4500 euros.*
- *El porcentaje de masa salarial que perciben los trabajadores que ganan menos de 4500 euros.*
- *El porcentaje de masa salarial que perciben los trabajadores que ganan más de 2500 euros.*
- *El porcentaje de masa salarial que perciben los trabajadores que ganan entre 900 y 2500 euros.*
- *El porcentaje de trabajadores que ganan entre 900 y 2500 euros.*
- *El porcentaje de masa salarial que recibe el 20 % de los trabajadores peor pagados.*
- *El porcentaje de masa salarial que recibe el 20 % de los trabajadores mejor pagados.*
- *Por debajo de qué salario (en cientos de euros) se encuentra el 10 % de la masa salarial.*
- *Por encima de qué salario (en cientos de euros) se encuentra el 10 % de la masa salarial.*

Ejercicio 35.2 *La compañía de telefonía móvil Notoigo está considerando cambiar sus tarifas. Para ello ha observado la duración en segundos de 1000 llamadas realizadas por sus abonados: Obtenga:*

- *Duración media de las llamadas.*
- *Coste medio de las llamadas según las siguientes tarifas:*
 - *10 céntimos el establecimiento de llamada, más 6 céntimos por minuto (proporcionalmente las fracciones de minuto).*

CAPÍTULO 35. ESTADÍSTICA DESCRIPTIVA

Duración de llamadas	Número de Llamadas
0-20	15
20-60	180
60-90	195
90-180	405
180-300	205

- 8 céntimos por minuto (proporcionalmente las fracciones de minuto), sin coste de establecimiento de llamada.
- Porcentaje de llamadas que superan los 2 minutos de duración.

Ejercicio 35.3 Se dispone de la siguiente información sobre los salarios anuales brutos de los empleados de una empresa (en miles de euros):

Salarios	0-20	20-60	60-70	70-90
Num Empleados	10	45	30	15

- Obtenga el coeficiente de variación de los salarios.
- ¿Qué salario es superado por el 60
- ¿Qué tanto por ciento de empleados tienen un salario superior a 63000 euros?

Ejercicio 35.4 Se tienen datos sobre los beneficios en millones de euros (ya deflactados) obtenidos por las empresas de tres sectores productivos en los años 2017 y 2021:

	2017		2021	
Sector	Beneficio medio	Num empresas	Beneficio medio	Num empresas
A	40	800	35	735
B	65	1200	60	1165
C	50	1000	35	900

- El beneficio medio en 2017 y 2021.
- La disminución media anual (en %) de los beneficios en el periodo 2017-2021.

Ejercicio 35.5 El salario medio, la desviación típica de los salarios y el número de empleados en tres empresas filiales de B.O.O.T.S.A. son

	Salario medio	Desviación Típica	Num empleados
A	1365	105	100
B	1300	100	300
C	1560	120	170

Se decide subir el salario un 5 % en la filial A, un 6 % en la filial B y 50 euros a los empleados de la filial C.

2. VARIABLES ESTADÍSTICAS BIDIMENSIONALES

- ¿En cuál de las tres filiales son más homogéneos los salarios antes de la subida?
- ¿En cuál de las tres filiales son más homogéneos los salarios tras la subida?

Ejercicio 35.6 Sea una distribución de frecuencias con media 300, varianza 36 y $n=5000$. ¿Cuántas observaciones contiene el conjunto $(-\infty, 288] \cup [312, \infty)$?

Ejercicio 35.7 En un fenómeno se han observado 2000 individuos con media 1000 y varianza 100. ¿Cuántas observaciones, como mínimo, son mayores que 970 y menores que 1030?

Ejercicio 35.8 Para asignar los puestos de trabajo en una cadena de montaje se realiza un test a los 90 empleados; 12 de ellos realizarán un trabajo tipo A (los que obtengan mejor puntuación), otros tantos un trabajo tipo C (los que saquen puntuación más baja), y el resto realizarán labores tipo B. El resultado del test fue:

Puntuación	0-30	30-50	50-70	70-100	100-120	120-150
n_i	10	15	20	20	20	5

¿Cuál fue la puntuación en el test para los que desempeñarán un trabajo tipo B?

2. Variables Estadísticas Bidimensionales

Ejercicio 35.9 En ocho empresas los beneficios X y los gastos en investigación Y el año pasado fueron los siguientes (en miles de euros), obteniéndose así la siguiente tabla: calcule

x_i	y_i
32	37
17	26
26	21
27	32
31	47
42	56

1. $\sum_{i=1}^n x_i$
2. $\sum_{i=1}^n y_i$
3. $\sum_{i=1}^n x_i y_i$
4. $\sum_{i=1}^n x_i^2$
5. $\sum_{i=1}^n y_i^2$
6. Media marginal de X
7. Media marginal de Y

Temperatura	Cerveza
12	33
25	66
10	26
28	82
30	98
35	103
20	60
12	35
27	68
25	71

8. Varianza marginal de X
9. Varianza marginal de Y
10. Covarianza.
11. Coeficiente de correlación
12. Coeficiente de determinación
13. Varianza residual de la recta de regresión de Y/X
14. Pendiente de la recta de regresión de Y/X .
15. Ordenada en el origen de la recta de regresión de Y/X .
16. Predicción del valor de Y cuando $X=28$.

Ejercicio 35.10 Una fábrica de cerveza ha tomado al azar 10 semanas del año, observando la temperatura media en cada una de ellas y los miles de litros de cerveza demandados. Los datos recogidos se muestran en la siguiente tabla:

- Obtenga la recta de regresión que permita explicar la demanda de cerveza en función de la temperatura.
- ¿En qué proporción el consumo de cerveza puede atribuirse a la temperatura media semanal?
- ¿Qué demanda se espera para una semana con una temperatura media de 30 grados?

Ejercicio 35.11 Una empresa tiene a sus trabajadores clasificados según el salario (en miles de euros anuales) y la antigüedad (en años) en el puesto de trabajo.

- Calcule el índice de Gini de concentración de los salarios de todos los empleados de la empresa.
- ¿Qué porcentaje de empleados hay en la empresa con un salario superior a 30.000 euros al año?

2. VARIABLES ESTADÍSTICAS BIDIMENSIONALES

	Antigüedad			
Salario	0-10	10-20	20-30	30-50
10-20	4	2	1	0
20-25	1	0	3	0
25-30	5	2	1	10
30-40	0	1	2	5
40-50	0	1	4	6

- ¿Qué sueldo anual corresponde al 30 % de los empleados mejor remunerados?
- Calcule el salario medio de los empleados que no superan los 20 años de antigüedad en el puesto de trabajo.
- ¿Respecto de cuál de las dos variables son los trabajadores más homogéneos?
- Calcule el coeficiente de correlación lineal.
- Estime el sueldo para un empleado con una antigüedad de 12 años en el puesto de trabajo.

Ejercicio 35.12 Una oficina donde se alquilan apartamentos ha observado que durante el mes de julio el número de apartamentos alquilados varía según el precio de los mismos. Del año anterior se tiene la siguiente información:

Precio por día	Num Apartamento Alquilados
15	934
40	512
60	364
85	180
150	80

- Precio medio por día de los apartamentos alquilados.
- ¿En qué medida podemos considerar que el número de apartamentos alquilados depende de los precios? Si se mantienen el comportamiento de los clientes y los precios:
- ¿Cuántos apartamentos se alquilarían con un precio de 90 euros por día?
- ¿Cuál será el precio máximo al que se podrán ofrecer apartamentos en alquiler?

Ejercicio 35.13 Se consideran 50 establecimientos de alimentación, atendiendo a dos factores: tiempo que llevan funcionando (X , en años) y beneficio anual (Y , en cientos de miles de euros).

- De una estimación del beneficio anual para un establecimiento con 12 años de antigüedad.

X/Y	0-1	1-3	3-4
0-5	0	2	5
5-10	2	4	4
10-15	8	4	6
15-20	10	3	2

- Calcule la varianza residual.

Ejercicio 35.14 El valor promedio, en euros, de las acciones en un grupo de inmobiliarias y en un grupo de bancos en los años 2011-2020 aparecen en la siguiente tabla: X =promedio del precio de las acciones de las inmobiliarias.

Año	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020
X	35	40	42	43	40	53	54	49	40	55
Y	102	101	97	98	98	100	97	91	95	95

Y =promedio del precio de las acciones de los bancos.

- Calcule el coeficiente de correlación lineal.
- ¿Qué cabe esperar que le ocurrirá al valor de las acciones de las inmobiliarias si se sabe que las acciones de los bancos aumentarán su valor?

3. Números Índices

Ejercicio 35.15 En una empresa se fabrican tres artículos. Los datos sobre precios y producción son:

Articulos	2019		2020	
	q_{i0}	p_{i0}	q_{it}	p_{it}
Artículo 1	160	12	270	11
Artículo 2	210	37	260	32
Artículo 3	320	26	310	27
Artículo 4	690	75	840	70

Para el año 2019, tomando como año base 2020, calcule (en %):

1. El índice de precios de Sauerbeck.
2. El índice de producción (o cantidades) de Bradstreet-Dudot.
3. El índice de precios de Laspeyres.
4. El índice de producción de Laspeyres.
5. El índice de producción de Paasche.
6. El índice de producción de Fisher
7. El índice de precios de Edgeworth.

4. ANÁLISIS DESCRIPTIVO DE SERIES CRONOLÓGICAS

8. El índice de valor agregado.

Ejercicio 35.16 Los beneficios (en millones de euros) obtenidos por una empresa y los valores del IPC se muestran en la siguiente tabla:

Año	2015	2016	2017	2018	2019	2020
Beneficio	47	52	61	76	80	92
IPC 2015	100	111	126	132		
IPC 2020				100	117	121

- Complete la serie de IPC con base en el año 2015 (expresados en %):
 - $IPC_{2019/2015}$
 - $IPC_{2020/2015}$
- Construya la serie de IPC con base 2020 (expresados en %):
 - $IPC_{2015/2020}$
 - $IPC_{2016/2020}$
 - $IPC_{2017/2020}$
 - $IPC_{2018/2020}$
 - $IPC_{2019/2020}$
- Obtenga los beneficios de los distintos años en millones de euros constantes de 2010:
 - Beneficios en 2015
 - Beneficios en 2016
 - Beneficios en 2017
 - Beneficios en 2018
 - Beneficios en 2019
- ¿Cuál ha sido la variación relativa (en %) de los beneficios en el periodo 2015-2020, en euros corrientes?
- ¿Cuál ha sido la variación relativa (en %) de los beneficios en el periodo 2005-2020, en euros constantes de 2020?
- Calcule la tasa de variación anual media (en %) en el periodo 2015-2020, sobre los beneficios en euros constantes.

4. Análisis Descriptivo de Series Cronológicas

Ejercicio 35.17 El número de llamadas (expresado en millones) de los abonados de la compañía MOVORAN en cada trimestre ha sido:

- Tasa de variación media anual en el periodo 2008-2012 para el total de llamadas anuales.

CAPÍTULO 35. ESTADÍSTICA DESCRIPTIVA

t	1º trimestre	2º trimestre	3 trimestre	4 trimestre
2008	6,4	7,2	5,6	8
2009	8,8	9,6	6,4	8,8
2010	9,6	10,4	8,8	11,2
2011	12	12,8	9,6	13,6
2012	14,4	14,4	11,2	16

- *Indices de variación estacional (método de las medias simples, modelo multiplicativo). Nota: $\tau(t) = 4,84 + 1,8(t - 2007) = -3607,76 + 1,8t$*
- *Estimación del número de llamadas para el 2º trimestre de 2013.*

Ejercicio 35.18 *La tendencia de la serie cronológica de ventas trimestrales de automóviles en una provincia (en miles) es:*

$$\tau(t) = 135 + 16(t - 2008)$$

- *Estime el valor de la tendencia para cada uno de los cuatro trimestres de 2012.*
- *Estime, según la tendencia, las ventas para todo el año 2012.*

Ejercicio 35.19 *Las ventas de motocicletas (en miles) en un país han sido las siguientes: Calcule los índices de variación estacional según el método de las*

Cuatrimestre	2002	2003	2004	2005	2006
1	26	26	25	25	24
2	52	53	53	52	51
3	22	23	23	23	24

medias simples.

Ejercicio 35.20 *La tendencia de la serie de ventas cuatrimestrales de motocicletas en un país (en miles) y la variación estacional para cada cuatrimestre son:*

$$\tau(t) = 12 + 6(t - 2010)$$

Estime las ventas del tercer cuatrimestre del año 2012.

1º Cuatrimestre	2º Cuatrimestre	3º Cuatrimestre
69,4	125	105,6

Ejercicio 35.21 *Se han observado los beneficios trimestrales, en cientos de miles de euros, de una determinada empresa. Ajustando una recta de mínimos cuadrados para la tendencia secular y usando el método de la razón a la tendencia para los índices de variación estacional, haga una predicción de los beneficios para el tercer trimestre de 2013.*

Año/Trimestre	1º	2º	3º	4º
2010	5	3	7	5
2011	5	2	6	6
2012	4	2	7	4

5. Probabilidad

Ejercicio 35.22 En una caja hay 10 piezas de la fábrica A, 15 de la fábrica B y 25 de la C. La fábrica A produce un 80 % de piezas excelentes, siendo excelentes el 90 % de las piezas de la fábrica B y sólo el 70 % de la fábrica C.

1. Calcule la probabilidad de que si extraemos una pieza al azar, ésta resulte de calidad excelente.
2. Se extrae una pieza al azar y resulta que no es excelente, calcule la probabilidad de que proceda de la fábrica B. Predicción del valor de Y cuando $X=28$.

Ejercicio 35.23 En una comunidad autonómica, el 18 % de los hombres y el 15 % de las mujeres presentaron una declaración sobre el IRPF con rentas superiores a 35000 euros al año. El 45 % de todas las declaraciones recibidas corresponden a mujeres. Se pide:

- ¿Qué porcentaje de declaraciones no han superado los 35000 euros?
- Se selecciona al azar una declaración y resulta superior a los 35000 euros, determine la probabilidad de que corresponda a una mujer.

Ejercicio 35.24 La producción de una factoría se realiza en cuatro máquinas: A, B, C y D. Diariamente la máquina A produce 150 piezas, B produce 250, C produce 275 y D produce 325. Las probabilidades de que una pieza sea defectuosa son: 0,05 si la produce A, 0,04 si la produce B, 0,03 si la produce C y 0,06 si la produce D.

- Se ha elegido una pieza al azar y es defectuosa. Calcule la probabilidad de que haya sido producida por la máquina B.
- Calcule la probabilidad de que una pieza elegida al azar no sea defectuosa.

Ejercicio 35.25 Una empresa de electrónica recibe suministros de tres mayoristas distintos. El 25 % de los paquetes se los envía el mayorista A, el 40 % el mayorista B y el resto el mayorista C. Cinco de cada mil envíos hechos por el mayorista A salen defectuosos, así como dos de cada mil envíos del mayorista B y uno de cada mil del mayorista C. Se ha recibido un envío defectuoso, calcule la probabilidad de que haya sido remitido por el mayorista A.

6. Distribuciones Discretas de Probabilidad

Ejercicio 35.26 Una ciudad está dividida en dos barrios (A y B). El número de apagones que se producen en el barrio A sigue una distribución de Poisson con media dos apagones por mes. Siendo en el barrio B la media de un apagón por mes. Calcule la probabilidad de que en un mes:

- *Haya algún apagón en el barrio A.*
- *Hayan, a lo sumo, dos apagones en la ciudad.*

Ejercicio 35.27 *Una compañía de seguros tiene contratadas anualmente 10000 pólizas contra incendios:*

- *Sabiendo que hay una probabilidad $1/5000$ de que se produzca un incendio en una vivienda, calcule la probabilidad de que tenga que pagar a alguno de sus asegurados.*
- *¿Cuántos incendios, por término medio, hay que atender en un año?*
- *La compañía, en una campaña de publicidad, decide cobrar sólo la mitad a 1000 de sus asegurados. En un edificio en el que 20 de las viviendas tienen contratada una póliza con esta compañía, calcúlese la probabilidad de que alguno de los asegurados de este edificio se vea agraciado con el descuento. Calcúlese también la probabilidad de que todos los asegurados en ese edificio se vean agraciados por la reducción en el precio de la póliza.*

Ejercicio 35.28 *La probabilidad de que un individuo presente una cierta característica económica es $1/20$.*

- *Tomando una muestra de 8 individuos al azar, calcule la probabilidad de que 3 de ellos presenten la característica.*
- *Tomando una muestra de 120 individuos al azar, ¿cuál es la probabilidad de que a lo sumo 2 presenten la característica?*

Ejercicio 35.29 *Una entidad realiza anualmente tres mil préstamos hipotecarios. La probabilidad de impago es 0,002. Se pide:*

- *La probabilidad de que en un año se produzcan más de dos impagos.*
- *La probabilidad de que en tres años, en uno de ellos no se produzcan impagos.*
- *¿Cuántos impagos se esperan en cinco años?*

Ejercicio 35.30 *Diariamente se empaquetan dos mil quinientas unidades de un determinado producto. La probabilidad de que una de las unidades sea defectuosa es 0,001. Se pide:*

- *La probabilidad de que en un día aparezcan más de dos artículos defectuosos.*
- *¿Cuántos artículos defectuosos se espera que aparezcan en diez días de empaquetado?*

Ejercicio 35.31 *El número de accidentes por año en una obra sigue una distribución de probabilidad con media y varianza iguales a 6.*

- *Sin suponer ningún modelo para la anterior variable aleatoria, ¿tiene alguna idea sobre la probabilidad de que en un año el número de accidentes esté comprendido entre 2 y 10?*

6. DISTRIBUCIONES DISCRETAS DE PROBABILIDAD

- *Suponiendo que el número de accidentes sigue una distribución de Poisson, ¿cuál es la probabilidad del anterior número de accidentes? ¿Cuál es la probabilidad de que haya no más de 6 y no menos de 4 accidentes en un año?*

Ejercicio 35.32 *En un almacén hay 5000 piezas de las cuales 400 son defectuosas. Se seleccionan aleatoriamente 10 piezas, en una ocasión con reemplazamiento y en otra sin reemplazamiento. En cada caso determine la probabilidad de que todas las piezas estén en buen estado.*

Ejercicio 35.33 *Un proceso de fabricación produce por término medio 3 piezas defectuosas por cada 1000. Las piezas se empaquetan en cajas de 2500. ¿Cuál es la probabilidad de que entre 5 cajas, elegidas al azar, en dos de ellas no haya piezas defectuosas?*

CAPÍTULO 36

Inferencia Estadística

1. Modelos Probabilísticos Univariantes Contínuos

Ejercicio 36.1 *La distribución de un contaminante en una sustancia se distribuye de manera uniforme entre 4 y 20 partes por millón. Se considera tóxica una concentración de 15 o más.*

1. *¿Cuál es la probabilidad de que, al tomarse una muestra, la concentración sea tóxica?*
2. *¿Cuál es la probabilidad de que, al tomar una muestra, la concentración de contaminante oscile entre 5 y 10?*

Ejercicio 36.2 *El peso de un paquete de azúcar es aleatorio, con distribución uniforme entre 980 y 1030 gramos. ¿Cuál es la probabilidad de que pese menos de 1 Kg?*

Ejercicio 36.3 *Los minutos necesarios para ensamblar una unidad de producción en una cadena de montaje es una variable aleatoria con distribución exponencial de parámetro $\theta = 5$. Calcular:*

1. $P[X > 5]$ y $P[X < 10]$
2. *Unos números reales a y b tales que y*
3. *con a y b los del apartado anterior.*

Ejercicio 36.4 *En un servicio a domicilio los pedidos por teléfono se reciben con una frecuencia casi constante. El tiempo en horas que transcurre entre dos llamadas consecutivas sigue una distribución exponencial. Por término medio, el tiempo transcurrido entre dos llamadas consecutivas es de 15 minutos a cualquier hora entre las 9:00 de la mañana y las 9:00 de la noche. Si se recibe una llamada a las 11:30, calcular la probabilidad de que la siguiente llamada sea posterior a las 12:00.*

1. MODELOS PROBABILÍSTICOS UNIVARIANTES CONTÍNUOS

Ejercicio 36.5 Sea X una variable aleatoria que sigue una distribución $N(10, 25)$. Encontrar los valores que corresponden a las siguientes probabilidades:

1. $P[X < x] = 0.05$
2. $P[X < x] = 0.95$
3. $P[X < x] = 0.99$
4. $P[X < x] = 0.01$

Ejercicio 36.6 La media de las calificaciones de un test es 400 y la desviación típica es 100. Si las calificaciones siguen una distribución normal, calcular:

1. El porcentaje de la población que ha obtenido menos de 350 puntos.
2. El porcentaje de alumnos con calificaciones entre 300 y 500.
3. El porcentaje de alumnos con calificaciones superiores a 500 puntos.
4. La probabilidad de que elegido un alumno al azar su calificación difiera de la media 150 puntos como máximo.
5. Los límites del intervalo que contiene al 70 % de la población más cercano a la media.

Ejercicio 36.7 El gerente del hipermercado JC está preocupado por sus gastos en electricidad, que son este año de 57000 euros. La cadena de hipermercados tiene un gasto medio en electricidad de 55000 euros y una desviación típica de 2000 euros. Suponiendo normalidad en dichos gastos, calcular:

1. El porcentaje de establecimientos de la cadena con menos gasto en electricidad que JC
2. Comprobar si su gasto en electricidad está entre el 10 % de los hipermercados de la cadena que más gastan.
3. ¿Cuánto ha de reducir su gasto en electricidad para estar entre el 25 % de los de menor gasto?

Ejercicio 36.8 Las horas productivas por mes de un departamento de administración se distribuyen mediante una Normal. Se sabe que el 2.56 % de los meses las horas productivas son menos de 1305 y que el 15.87 % de los meses las horas productivas son más de 1600.

1. ¿Cuál es el número de horas productivas por término medio?
2. ¿Cuál es la probabilidad de que en un mes se trabajen entre 1450 y 1550 horas?

Ejercicio 36.9 El peso de los melocotones de un pedido se distribuye normalmente. Se sabe que el 9 % de los melocotones tiene un peso inferior a 50 gr. y un 20 % un peso superior a 70gr. ¿Qué porcentaje de melocotones tiene un peso entre 65 y 75 gr?

Ejercicio 36.10 *Un dado se lanza 720 veces. Sea X la variable aleatoria que mide el n° de veces que sale 6, calcular:*

- $P[99 < X < 126]$
- $P[X > 149]$

Ejercicio 36.11 *Un grupo de investigadores sabe que el 0.18 % de los animales afectados por un virus fallecen. Si hay 10000 animales enfermos, ¿cuál es la probabilidad de que fallezcan entre 25 y 40 animales?*

Ejercicio 36.12 *Si el número de piezas defectuosas en un proceso de fabricación sigue una ley de Poisson con media 26, calcular la probabilidad aproximada de que haya entre 24 y 28 defectuosas*

Ejercicio 36.13 *En el borrador de un libro aparecen 2 erratas, por término medio, en cada página. El borrador tiene 200 páginas. ¿Cuál es la probabilidad de que el borrador contenga entre 360 y 420 erratas?*

Ejercicio 36.14 *Dadas tres variables aleatorias X , Y , Z Normales independientes con medias 0, 2 y 4 y varianzas 4, 4 y 1, respectivamente, calcular:*

$$P[-7 \leq K \leq 10] \quad K = 4X + 5Y - 6Z + 6$$

1. MODELOS PROBABILÍSTICOS UNIVARIANTES CONTÍNUOS
